

Matemática aplicada a Economía

Juan Andrés Cabral

Sobre este libro

Este libro reúne notas y resoluciones de ejercicios de clase de Matemática Aplicada I (FCE–UBA). Su objetivo es acompañar la cursada: ordenar ideas, fijar métodos y ofrecer ejemplos resueltos. Puede contener errores u omisiones; toda corrección o sugerencia es bienvenida en jcabral@udesa.edu.ar.

Índice

1	Técnicas de estudio basadas en evidencia	3
2	Curvas de nivel	7
3	Curvas de nivel en Economía	12
4	Optimización con curvas de nivel	18
5	Continuidad	27
6	Derivadas parciales	30
7	Diferencial	36
8	Aplicación económica de diferencial	41
9	Clasificación de bienes y elasticidad	44
10	Derivadas compuestas	49
11	Derivadas implícitas	54
12	Derivadas implícitas en sistemas de ecuaciones	59
13	IS-LM	66
14	Homogeneidad	69
15	Autovalores y autovectores	73
16	Formas cuadráticas	84
17	Menores	95
18	Concavidad y convexidad	101
19	Optimización sin restricciones: cálculo univariable	116
20	Aplicaciones económicas de optimización libre	126
21	Optimización con restricciones de igualdad	132
22	Aplicaciones económicas con optimización con restricciones de igualdad	139
23	Optimización con restricciones de desigualdad	143
24	Temas adicionales de optimización	156
25	Apéndice sobre Álgebra	159

1 Técnicas de estudio basadas en evidencia

“Somos malos jueces de cuándo estamos aprendiendo bien y cuándo no. Cuando el progreso es más difícil y más lento y no se siente productivo, tendemos a recurrir a estrategias que parecen más fructíferas, sin darnos cuenta de que las ganancias de esas estrategias suelen ser temporales.”
Brown, Roediger y McDaniel, Make It Stick: The Science of Successful Learning. (traducción propia)

La evidencia es clara: solemos juzgar mal nuestro propio aprendizaje y preferimos métodos que “se sienten” productivos pero no son eficientes (Brown, Roediger, y Mark A. McDaniel 2014). Por eso el primer capítulo del libro no es de cálculo ni de álgebra sino, una breve introducción a **técnicas de estudio con respaldo empírico**.

Por qué empezar por el *cómo* aprender

Estudiar matemática y aplicarla a algún campo concreto como Economía requiere conectar definiciones formales con intuiciones económicas, derivar condiciones de primer orden y, a la vez, interpretar esas condiciones con conceptos económicos. Ese “puente” exige memoria a largo plazo y flexibilidad conceptual. La literatura en psicología del aprendizaje muestra que dos prácticas destacan mucho por su utilidad: **recuperación activa** (practice testing) y **práctica espaciada** (distributed practice) (Dunlosky et al. 2013; Roediger III y Butler 2011; Cepeda, Pashler, et al. 2006; Cepeda, Vul, et al. 2008). Este capítulo propone incorporar estas y otras desde el primer día, con procedimientos concretos orientados a los temas que se tratan en los otros capítulos.

Qué evitar al momento del estudio

En general, cuando uno estudia hay ciertas conductas que se aplican por defecto sin cuestionamiento ni crítica. Estas técnicas pueden no ser las mejores ya que no son tan efectivas para mejorar la retención de lo aprendido o porque ocupan el tiempo limitado que puede ser utilizado para otras técnicas con mayor respaldo. Aquí, algunas técnicas que **no** son recomendables debido a la falta de eficacia probada:

Releer sin más. Releer crea una *sensación* de familiaridad que no garantiza retención ni transferencia. Varios estudios no encuentran ventajas de la relectura frente a métodos activos Callender y M. A. McDaniel 2009; Weinstein, McDermott, y Roediger III 2010; Agarwal et al. 2008. En este sentido, no es recomendable releer 10 veces un teorema para intentar acordarse del mismo.

Subrayar sin criterio. La evidencia es mixta: hay trabajos que no hallan beneficios o incluso efectos negativos si se subraya demasiado o mal Peterson 1991; Lorch y Klusewitz 1995; Winchell et al. 2018, y otros que muestran que *con instrucciones precisas* puede ayudar Yue et al. 2015; Miyatsu, Nguyen, y M. A. McDaniel 2018. Si uno decide usar esta técnica, la recomendación es que sea mínima y con reglas (p.ej., una idea clave por párrafo).

Resumir. Resumir puede ayudar si uno sabe qué y cómo destilar Bretzing y Kulhavy 1979; Rinehart, Stahl, y Erickson 1986, pero su efectividad es muy variable y suele perder frente a estrategias más activas como la autoexplicación o el auto-cuestionamiento Bednall y Kehoe 2011; King 1992; Dunlosky et al. 2013.

Lo que sí funciona y cómo aplicarlo

1) Recuperación activa (Active Recall). Consiste en *intentar recordar y reconstruir* sin mirar el material. Funciona en laboratorio y en aula, a corto y largo plazo M. A. McDaniel et al. 2007; Roediger III y Butler 2011; Larsen, Butler, y Roediger III 2009; Schmidmaier et al. 2011; Agarwal et al. 2008. Esta idea se basa en intentar simular situaciones de exámenes constantemente, haciéndose preguntas como ¿Cómo era

esta fórmula? ¿Cuál es la intuición detrás de esta ecuación? ¿Qué regla se utiliza acá? Este autotesteo requiere esfuerzo mental, el cual facilita la retención de los contenidos. Existe una relación entre el esfuerzo mental invertido en responder una pregunta y la cantidad de tiempo que va a transcurrir hasta que uno se olvide de cómo responderla. A mayor esfuerzo, recordamos más.

Cómo implementarlo: Al momento de leer un libro en vez de simplemente ir pasando página por página, detenerse cada cierto tiempo y preguntarse el porqué de los pasos realizados o intentar averiguar cuál es el procedimiento posterior para resolver un problema. Obviamente estos testeos no pueden durar demasiado ya que consumirían mucho tiempo, pero tomarse unos minutos para plantearse si uno está entendiendo lo explicado siempre es buena idea. Una vez finalizada la lectura sobre un tema, una buena práctica que cuenta con mucha evidencia a favor es realizar “flashcards”. Las flashcards son tarjetas que de un lado contienen una pregunta y del otro lado una respuesta, son cortas y la idea es no estar demasiado tiempo pensando. Por ejemplo, una flashcard puede ser ¿Cuál es la fórmula para la elasticidad precio de la demanda? y del otro lado puede estar la fórmula. Estas flashcards pueden hacerse con lápiz y papel, pero también existen aplicaciones que permiten crearlas digitalmente como Anki.

2) Práctica espaciada. Repartir las sesiones en el tiempo aumenta la retención [Bahrick 1979](#); [Cepeda, Pashler, et al. 2006](#). El espaciado óptimo suele estar entre el 5–30% del intervalo hasta la evaluación [Rohrer y Pashler 2007](#); [Cepeda, Vul, et al. 2008](#).

Cómo implementarlo: Si el examen es en 30 días y se toma 10% como guía, conviene programar repasos cada 3 días ($30 \cdot 0.1 = 3$). Lo ideal es espaciar las sesiones de estudio y al momento de tenerlas, aplicar recuperación activa.

3) Autoexplicación y generación. Explicar con tus palabras por qué un paso es válido, o *generar* preguntas/respuestas propias, potencia el aprendizaje y supera en general al resumen pasivo [King 1992](#); [Weinstein, McDermott, y Roediger III 2010](#).

Cómo implementarlo: Después de una clase, tomar el cuaderno y ver si se entienden los pasos algebraicos o generar una explicación propia de la interpretación de las ecuaciones, etc.

4) Intercalado (*interleaving*) y variación. Alternar tipos de problemas, es decir, ir cambiando de tema constantemente. Esto dificulta un poco el estudio pero mejora la discriminación de métodos.

Cómo implementarlo: Por ejemplo, tomar ejercicios de las guías de forma aleatoria e intentar resolverlos uno después de otro, en vez de ir por los primeros 1, 2, 3 y así sucesivamente, saltarse ejercicios y resolver: 2, 6, 10, 3, 8,... y así.

Ejemplo

Supongamos que queremos estudiar dos temas diferentes: elasticidad de demanda y derivadas compuestas. La idea sería primero tener en cuenta que si el examen es dentro de un mes, planear estudiar cada cierta cantidad de días en vez de realizar pocas sesiones largas. Por otro lado, al momento de leer el material de estudio, ir preguntándose si uno entiende lo que está leyendo y generar flashcards con preguntas clave: ¿Cómo es la fórmula? ¿Para qué sirve? ¿Cómo interpreto este resultado? ¿Cuáles son los pasos a seguir? entre otras. Una vez hecho esto, practicar ejercicios combinando los dos temas en la misma sesión y no dejando un tema para una sesión de estudio y otro tema para otra sesión. Por último, al momento de realizar las últimas sesiones, intentar asemejar el contexto de estudio lo máximo posible al contexto de evaluación. Utilizar temporizadores, no tener a mano el libro para revisar las respuestas, solamente contar con las herramientas disponibles que van a estar en el examen, etc.

El rol de las inteligencias artificiales generativas

Es imposible ignorar que los chatbots generativos hoy en día cada vez son más populares. Más que un obstáculo, el uso de los mismos puede generar oportunidades. Algunas recomendaciones para utilizarlos

serían las siguientes:

1. Utilizarlos para generar problemas nuevos o que combinen ejercicios.
2. Solicitar intuiciones diferentes o puntos de vista distintos a los que uno tiene.
3. Usarlos para criticar nuestros razonamientos o intuiciones. Si creemos que tal vez nos equivocamos, una buena forma es darle a la IA nuestro razonamiento y pedirle que lo analice rigurosamente.
4. Generar ideas para flashcards.
5. Generar un plan de estudio separado por días y que tenga en cuenta las técnicas propuestas anteriormente.

Por último, es importante recordar que cualquier inteligencia artificial generativa al día de hoy comete errores, muchas veces sutiles y otras veces groseros. Esto último debe servir de advertencia no para restringir su uso sino, para ser críticos al momento de tomar en cuenta lo generado.

Referencias

- Agarwal, P. K. et al. (2008). “Examining the testing effect with open- and closed-book tests”. In: *Applied Cognitive Psychology* 22.7, pp. 861–876.
- Bahrick, H. P. (1979). “Maintenance of knowledge: Questions about memory we forgot to ask”. In: *Journal of Experimental Psychology: General* 108.3, p. 296.
- Bednall, T. C. y E. J. Kehoe (2011). “Effects of self-regulatory instructional aids on self-directed study”. In: *Instructional Science* 39.2, pp. 205–226.
- Bretzing, B. H. y R. W. Kulhavy (1979). “Notetaking and depth of processing”. In: *Contemporary Educational Psychology* 4.2, pp. 145–153.
- Brown, Peter C., III Roediger Henry L., y Mark A. McDaniel (2014). *Make It Stick*. Harvard University Press.
- Callender, A. A. y M. A. McDaniel (2009). “The limited benefits of rereading educational texts”. In: *Contemporary Educational Psychology* 34.1, pp. 30–41.
- Cepeda, N. J., H. Pashler, et al. (2006). “Distributed practice in verbal recall tasks: A review and quantitative synthesis”. In: *Psychological Bulletin* 132.3, p. 354.
- Cepeda, N. J., E. Vul, et al. (2008). “Spacing effects in learning: A temporal ridge of optimal retention”. In: *Psychological Science* 19.11, pp. 1095–1102.
- Dunlosky, J. et al. (2013). “Improving students’ learning with effective learning techniques: Promising directions from cognitive and educational psychology”. In: *Psychological Science in the Public Interest* 14.1, pp. 4–58.
- King, A. (1992). “Comparison of self-questioning, summarizing, and notetaking-review as strategies for learning from lectures”. In: *American Educational Research Journal* 29.2, pp. 303–323.
- Larsen, D. P., A. C. Butler, y H. L. Roediger III (2009). “Repeated testing improves long-term retention relative to repeated study: a randomised controlled trial”. In: *Medical Education* 43.12, pp. 1174–1181.
- Lorch, E. P. y M. A. Klusewitz (1995). “Effects of typographical cues on reading and recall of text”. In: *Contemporary Educational Psychology* 20.1, pp. 51–64.
- McDaniel, M. A. et al. (2007). “Testing the testing effect in the classroom”. In: *European Journal of Cognitive Psychology* 19.4–5, pp. 494–513.
- Miyatsu, T., K. Nguyen, y M. A. McDaniel (2018). “Five popular study strategies: Their pitfalls and optimal implementations”. In: *Perspectives on Psychological Science* 13.3, pp. 390–407.
- Peterson, S. E. (1991). “The cognitive functions of underlining as a study technique”. In: *Literacy Research and Instruction* 31.2, pp. 49–56.
- Rinehart, S. D., S. A. Stahl, y L. G. Erickson (1986). “Some effects of summarization training on reading and studying”. In: *Reading Research Quarterly*, pp. 422–438.

- Roediger III, H. L. y A. C. Butler (2011). “The critical role of retrieval practice in long-term retention”. In: *Trends in Cognitive Sciences* 15.1, pp. 20–27.
- Rohrer, D. y H. Pashler (2007). “Increasing retention without increasing study time”. In: *Current Directions in Psychological Science* 16.4, pp. 183–186.
- Schmidmaier, R. et al. (2011). “Using electronic flashcards to promote learning in medical students: retesting versus restudying”. In: *Medical Education* 45.11, pp. 1101–1110.
- Weinstein, Y., K. B. McDermott, y H. L. Roediger III (2010). “A comparison of study strategies for passages: Rereading, answering questions, and generating questions”. In: *Journal of Experimental Psychology: Applied* 16.3, p. 308.
- Winchell, A. et al. (2018). “Textbook annotations as an early predictor of student learning”. In: *Proceedings of the International Conference on Educational Data Mining (EDM)*.
- Yue, C. L. et al. (2015). “Highlighting and its relation to distributed study and students’ metacognitive beliefs”. In: *Educational Psychology Review* 27.1, pp. 69–78.

2 Curvas de nivel

Introducción

Las curvas de nivel (o líneas de contorno) de una función de dos variables $z = f(x, y)$ se obtienen fijando un valor constante $z = c$ y resolviendo la ecuación

$$f(x, y) = c$$

Cada valor de c determina una curva en el plano xy que representa los puntos en los que la función adquiere ese valor.

Regla Práctica para Graficar Curvas de Nivel

1. **Fijar el valor de z :** Escoger un número c (por ejemplo, $c = 0, 1, -1$, etc.).
2. **Obtener la ecuación en x e y :** Sustituir $z = c$ en $f(x, y) = c$ y simplificar la ecuación.
3. **Identificar la forma de la curva:** Reconocer si la ecuación representa un círculo, elipse, hipérbola, recta u otra figura.
4. **Determinar puntos clave:** Encontrar intersecciones con los ejes, vértices, asíntotas u otros puntos notables.
5. **Graficar:** Con la información anterior, traza la curva en el plano xy .

Ejemplos de Curvas de Nivel

1. Círculo: $z = x^2 + y^2$

- **Curva de nivel:** Al fijar $z = c$, se tiene

$$x^2 + y^2 = c$$

- **Condición:** $c \geq 0$, radio $r = \sqrt{c}$; si $c < 0$, no hay soluciones reales.




Figura 1: Curvas de nivel de $z = x^2 + y^2$: círculos para distintos valores de c .

2a. Elipse: $z = \frac{x^2}{a^2} + \frac{y^2}{b^2}$

- Curva de nivel:

$$\frac{x^2}{a^2} + \frac{y^2}{b^2} = c$$

- Semiejes: $a\sqrt{c}$ en x , $b\sqrt{c}$ en y ; si $c = 0$, la curva se reduce al punto $(0, 0)$

2b. Elipse: $z = \frac{x^2}{a} + \frac{y^2}{b}$

- Curva de nivel:

$$\frac{x^2}{a} + \frac{y^2}{b} = c$$

- Forma alternativa:

$$\frac{x^2}{ac} + \frac{y^2}{bc} = 1$$

- Semiejes: $\sqrt{ac}$ en x , $\sqrt{bc}$ en y ; para $c = 0$, punto $(0, 0)$




Figura 2: Curvas de nivel de $z = \frac{x^2}{4} + \frac{y^2}{1}$

3. Hipérbola: $z = axy$

- Curva de nivel:

$$y = \frac{c}{ax}$$

- Casos: Para $c = 0$, la curva es $x = 0 \cup y = 0$, es decir, los ejes coordenados.




Figura 3: Curvas de nivel de $z = axy$: hipérbolas $y = \frac{c}{ax}$

4. Plano: $ax + by = cz$

- Forma explícita:

$$z = \frac{a}{c}x + \frac{b}{c}y$$

- Curvas de nivel:

$$ax + by = ck$$

que representan rectas paralelas para distintos valores de k .




Figura 4: Curvas de nivel del plano $ax + by = cz$: rectas paralelas $ax + by = ck$ para distintos valores de k ,

5. Hipérbola: $z = x^2 - y^2$

- Curva de nivel:

$$x^2 - y^2 = c$$

- Casos:

- $c > 0$:

$$\frac{x^2}{c} - \frac{y^2}{c} = 1$$

vértices en $x = \pm\sqrt{c}$

- $c = 0$:

$$y = x \quad y = -x$$

- $c < 0$:

$$\frac{y^2}{|c|} - \frac{x^2}{|c|} = 1$$

vértices en $y = \pm\sqrt{|c|}$




Figura 5: Curvas de nivel de $z = x^2 - y^2$: para $c > 0$ abren sobre el eje x ; para $c < 0$ (rojo) abren sobre el eje y . El caso $c = 0$ son las rectas $y = \pm x$ (grises, punteadas).

3 Curvas de nivel en Economía

En esta sección se analiza la importancia de las **curvas de nivel** en el contexto económico, enfocándonos en su uso para representar y analizar funciones de producción y utilidad.


- **Curvas de nivel:** representan conjuntos de puntos en los cuales una función de dos variables mantiene un mismo valor. En economía, se utilizan para identificar **combinaciones de insumos o bienes que generan un mismo nivel de producción o satisfacción**
- **Isocuantas:** en funciones de producción, las curvas de nivel se denominan isocuantas y muestran las **combinaciones de factores productivos que producen una cantidad constante de producto**
- **Curvas de indiferencia:** en el análisis de la utilidad, las curvas de nivel se conocen como curvas de indiferencia y representan **combinaciones de bienes que proporcionan el mismo nivel de satisfacción al consumidor**

Propiedades usuales de las curvas de indiferencia

Las curvas de nivel derivadas de funciones de utilidad suelen exhibir ciertas propiedades para reflejar comportamientos económicos razonables. A continuación, se describen las características y la intuición económica asociada a cada una.

1. No se cortan


Cada curva de indiferencia representa un **nivel único de utilidad**. Si dos curvas correspondientes a niveles distintos se cruzaran, una misma combinación de bienes estaría asociada simultáneamente a **dos niveles diferentes de utilidad**, lo cual no es posible para una función de utilidad.



En el punto A , la misma canasta pertenece simultáneamente a las dos curvas dibujadas. Al cortarse, **no pueden representar niveles distintos de una misma función de utilidad**.

2. Pendiente negativa

Si ambos bienes son deseables, para mantener constante la utilidad un aumento en la cantidad de un bien debe ir acompañado de una disminución en la cantidad del otro.




Este contraejemplo muestra una curva de indiferencia **creciente**. En ella, al aumentar x_1 , también debe aumentar x_2 para permanecer sobre la misma curva.

3. Monotonicidad estricta

La **monotonicidad estricta** implica que, manteniendo constante la cantidad de un bien, un aumento en la cantidad del otro incrementa estrictamente la utilidad. Más generalmente, si una canasta contiene al menos tanta cantidad de ambos bienes como otra y una cantidad estrictamente mayor de al menos uno de ellos, el consumidor prefiere estrictamente la primera canasta.


Gráficamente, bajo monotonicidad estricta, las curvas de indiferencia asociadas a **niveles de utilidad más elevados** se encuentran hacia arriba y a la derecha.



Aquí la curva U_2 queda **más cerca del origen** que U_1 . Si se interpretara que U_2 representa un nivel de utilidad mayor, entonces más cantidad de ambos bienes no implicaría necesariamente mayor utilidad.

4. Continuidad


La **continuidad** asegura que pequeñas variaciones en las cantidades de bienes generan pequeños cambios en la utilidad. Esto permite representar las preferencias sin **saltos abruptos** en los niveles de satisfacción.



Este gráfico ilustra esquemáticamente una falla de continuidad: el círculo abierto representa una canasta excluida de la curva, aunque existen canastas de esa curva que se aproximan a ella. Si todas las canastas de la curva proporcionan utilidad U_0 , pero la canasta excluida pertenece al dominio y tiene una utilidad distinta, entonces **la función de utilidad no es continua en ese punto**.

5. Convexidad estricta al origen

La convexidad estricta refleja una preferencia por **combinaciones relativamente balanceadas de bienes**. Si dos canastas distintas proporcionan el mismo nivel de utilidad, cualquier combinación estrictamente intermedia de ambas proporciona un nivel de utilidad mayor.



En lugar de ser convexa al origen, es cóncava al origen. El segmento que une A y B queda por debajo de la curva. Si ambos bienes son deseables, sus puntos interiores representan canastas estrictamente menos preferidas que los extremos.

Recta presupuestaria y métodos de graficación

Dados un ingreso R y los precios p_1 y p_2 , el **conjunto presupuestario** está formado por todas las combinaciones de bienes que el consumidor puede adquirir sin superar su ingreso:

$$p_1x_1 + p_2x_2 \leq R$$

La **recta presupuestaria** corresponde a las combinaciones en las que el consumidor gasta exactamente todo su ingreso:

$$p_1x_1 + p_2x_2 = R$$

Por lo tanto, los puntos ubicados por debajo de la recta representan canastas que el consumidor puede adquirir sin gastar todo su ingreso, mientras que los puntos ubicados por encima representan canastas que no puede adquirir con el ingreso disponible.

Método 1: despejar una variable en función de la otra

Despejando x_2 en función de x_1 :

$$x_2 = \frac{R}{p_2} - \frac{p_1}{p_2}x_1$$

- Intuición: la ecuación muestra que, a medida que aumenta la cantidad de x_1 , la cantidad de x_2 debe disminuir para mantener constante el gasto total R . La **pendiente** $-\frac{p_1}{p_2}$ refleja la **tasa a la cual el mercado permite intercambiar un bien por el otro**
- Aplicación: este método permite graficar la recta presupuestaria como una función lineal, facilitando el **análisis algebraico** de las posibilidades de consumo

Método 2: utilizar los interceptos

Si el consumidor dedica todo su ingreso al bien 1, entonces

$$x_1 = \frac{R}{p_1}$$

Si dedica todo su ingreso al bien 2, entonces

$$x_2 = \frac{R}{p_2}$$

- Intuición: estos interceptos representan las **cantidades máximas** que pueden adquirirse de cada bien si todo el ingreso se destina exclusivamente a ese bien
- Aplicación: conociendo ambos interceptos, puede trazarse la recta que los une. El área comprendida entre la recta y los ejes representa las **combinaciones de bienes que resultan accesibles** para el consumidor

Isocuantas

Las **isocuantas** son las curvas de nivel asociadas a una función de producción. Representan todas las combinaciones de factores productivos que permiten obtener un mismo nivel de producción.

Si la función de producción es

$$q = F(x_1, x_2)$$

una isocuanta correspondiente al nivel de producción q_0 está determinada por

$$F(x_1, x_2) = q_0$$

Por ejemplo, si x_1 y x_2 representan dos factores productivos, distintos puntos pertenecientes a una misma isocuanta corresponden a distintas combinaciones de esos factores que permiten producir exactamente q_0 unidades.

- Las isocuantas asociadas a **mayores niveles de producción** se encuentran, en general, más alejadas del origen cuando una mayor utilización de los factores permite aumentar la producción
- Dos isocuantas correspondientes a niveles de producción diferentes **no pueden cruzarse**, ya que una misma combinación de factores no puede generar simultáneamente dos niveles distintos de producción bajo una misma función de producción
- Al igual que otras curvas de nivel, pueden graficarse fijando un nivel de producción y despejando uno de los factores en función del otro cuando esto sea posible

Curva de isocosto

La **curva de isocosto** representa las combinaciones de insumos que generan un mismo **costo total**. Si w_1 y w_2 son los precios de los insumos x_1 y x_2 , respectivamente, una curva de isocosto correspondiente al costo total C está dada por

$$w_1x_1 + w_2x_2 = C$$

Despejando x_2 en función de x_1 :

$$x_2 = \frac{C}{w_2} - \frac{w_1}{w_2}x_1$$

Por lo tanto, su pendiente es

$$-\frac{w_1}{w_2}$$

Los interceptos con los ejes son

$$x_1 = \frac{C}{w_1} \quad x_2 = \frac{C}{w_2}$$

- Intuición: los interceptos representan las cantidades máximas de cada insumo que pueden adquirirse si todo el costo se destina exclusivamente a uno de ellos
- La pendiente depende de los **precios relativos de los factores** y determina cómo debe modificarse la cantidad de un insumo cuando cambia la del otro para mantener constante el costo total
- Para precios de los factores dados, un aumento del costo total C desplaza la curva de isocosto hacia afuera de forma paralela

Isoingreso

La **línea de isoingreso** representa las combinaciones de productos o bienes que generan un **ingreso total constante**:

$$p_1q_1 + p_2q_2 = I$$

Curvas de indiferencia Cobb-Douglas

Las **curvas de indiferencia** derivadas de una función de utilidad Cobb-Douglas representan combinaciones de bienes que otorgan un **nivel constante de utilidad**. Una forma general de esta función es

$$U(x_1, x_2) = x_1^\alpha x_2^\beta$$

donde $\alpha, \beta > 0$.

Graficación

Para representar la curva de indiferencia correspondiente a un nivel de utilidad fijo $U_0 > 0$, partimos de

$$U_0 = x_1^\alpha x_2^\beta$$

y despejamos x_2 :

$$x_2 = \left(\frac{U_0}{x_1^\alpha} \right)^{\frac{1}{\beta}}$$

o, equivalentemente,

$$x_2 = \frac{U_0^{1/\beta}}{x_1^{\alpha/\beta}}$$

Esto permite graficar la curva de indiferencia para un nivel dado de utilidad U_0 , considerando distintos valores positivos de x_1 .

- Las curvas son **decrecientes y convexas al origen**, reflejando que distintas combinaciones de ambos bienes pueden proporcionar un mismo nivel de utilidad
- Para un nivel de utilidad $U_0 > 0$, las curvas **no tocan los ejes**, ya que si $x_1 = 0$ o $x_2 = 0$, la utilidad es igual a cero
- Las curvas correspondientes a niveles positivos de utilidad se encuentran en el primer cuadrante, dado que se consideran **cantidades positivas de ambos bienes**

Cada curva representa un **nivel fijo de utilidad**. Dado que $\alpha, \beta > 0$, mayores cantidades de los bienes generan mayores niveles de utilidad, por lo que las curvas correspondientes a niveles de utilidad más altos se encuentran hacia arriba y a la derecha.

Nota: Las funciones de producción también suelen tener forma Cobb-Douglas. En ese caso, sus curvas de nivel se denominan **isocuantas** y representan **combinaciones de factores productivos que permiten obtener un mismo nivel de producción**.

4 Optimización con curvas de nivel

Método de Igualación de Derivadas para la Optimización con Restricción

Supongamos que queremos optimizar (maximizar o minimizar) una función objetivo $F(x, y)$ sujeta a una restricción $G(x, y) = C$. La idea es asumir que, en el punto óptimo, el valor de la función objetivo es constante y, de esta forma, expresar una de las variables en función de la otra a partir de ambas ecuaciones (la función objetivo y la restricción). Luego, derivamos cada despeje respecto a la otra variable, igualamos las derivadas y, a partir de esa igualdad, **obtenemos una relación entre x y y que, al sustituirla en la restricción, permite hallar la solución óptima.**

El procedimiento se resume en los siguientes pasos:

1. **Fijar el nivel óptimo:** Se asume que en el óptimo la función objetivo alcanza un valor constante, digamos $F(x, y) = K$.
2. **Despejar x (o y) en función de y (o x):** Se resuelve la ecuación $F(x, y) = K$ para obtener una expresión del tipo

$$x = f(y),$$

y se despeja la misma variable a partir de la restricción:

$$x = g(y) \quad (\text{obtenido de } G(x, y) = C).$$

3. **Derivar respecto a la otra variable:** Se derivan ambas expresiones con respecto a y . Así se obtienen:

$$\left. \frac{dx}{dy} \right|_{\text{objetivo}} = f'(y) \quad \text{y} \quad \left. \frac{dx}{dy} \right|_{\text{restricción}} = g'(y).$$

4. **Igualar las derivadas:** En el punto óptimo ambas curvas son tangentes, por lo que sus pendientes deben coincidir. Esto implica:

$$f'(y) = g'(y).$$

Esta igualdad permite despejar una relación entre x y y (o encontrar el valor de y).

5. **Realizar el proceso con el otro despeje:** De manera análoga, se despeja y en función de x tanto a partir de la función objetivo como de la restricción:

$$y = h(x) \quad \text{y} \quad y = k(x),$$

y se derivan ambas expresiones respecto a x :

$$\left. \frac{dy}{dx} \right|_{\text{objetivo}} = h'(x) \quad \text{y} \quad \left. \frac{dy}{dx} \right|_{\text{restricción}} = k'(x).$$

Igualando estas derivadas se obtiene otra relación entre x e y . Esta segunda igualdad, junto con la anterior, permite eliminar el parámetro K (el valor fijo de la función objetivo) y obtener una relación única entre x e y .

6. **Sustituir en la restricción:** Con la relación obtenida se reemplaza en la restricción original $G(x, y) = C$ para calcular el valor óptimo de una de las variables y, a partir de allí, el otro.

Ejemplo: Optimización de $f(x, y) = x^2y$ sujeta a $5x + 2y = 100$

Sea la función objetivo

$$f(x, y) = x^2y,$$

y la restricción

$$5x + 2y = 100.$$

En el óptimo se asume que $f(x, y) = K$ es constante.

Despejar x en función de y

- **Desde la función objetivo:** Partiendo de

$$x^2y = K,$$

despejamos x (tomando la rama positiva¹):

$$x = \sqrt{\frac{K}{y}} = \sqrt{K} y^{-1/2}.$$

- **Desde la restricción:** De

$$5x + 2y = 100,$$

se obtiene:

$$x = \frac{100 - 2y}{5}.$$

- **Derivar respecto a y :**

– Para la función objetivo:

$$\frac{dx}{dy} = -\frac{1}{2}\sqrt{K} y^{-3/2}.$$

– Para la restricción:

$$\frac{dx}{dy} = -\frac{2}{5}.$$

- **Igualar las derivadas:** En el óptimo se tiene:

$$-\frac{1}{2}\sqrt{K} y^{-3/2} = -\frac{2}{5}.$$

Cancelando el signo negativo y despejando $\sqrt{K}$:

$$\frac{1}{2}\sqrt{K} y^{-3/2} = \frac{2}{5} \implies \sqrt{K} = \frac{4}{5} y^{3/2}.$$

Elevando al cuadrado se obtiene:

$$K = \frac{16}{25} y^3.$$

¹Tomar la solución positiva del despeje es algo que comúnmente se hace en ejemplos económicos ya que las variables suelen tener interpretación de bienes o precios, los cuales nunca podrían ser negativos.

Despejar y en función de x

- **Desde la función objetivo:** Partiendo de

$$x^2 y = K,$$

despejamos y :

$$y = \frac{K}{x^2}.$$

- **Desde la restricción:** De

$$5x + 2y = 100,$$

despejamos y :

$$y = \frac{100 - 5x}{2}.$$

- **Derivar respecto a x :**

– Para la función objetivo:

$$y = K x^{-2} \implies \frac{dy}{dx} = -2K x^{-3}.$$

– Para la restricción:

$$\frac{dy}{dx} = -\frac{5}{2}.$$

- **Igualar las derivadas:** Se igualan:

$$-2K x^{-3} = -\frac{5}{2}.$$

Cancelando el signo negativo y despejando K :

$$2K x^{-3} = \frac{5}{2} \implies K = \frac{5}{4} x^3.$$

Igualación de los valores de K y obtención de la relación entre x e y

De los dos procesos obtenemos:

$$K = \frac{16}{25} y^3 \quad \text{y} \quad K = \frac{5}{4} x^3.$$

Igualando:

$$\frac{16}{25} y^3 = \frac{5}{4} x^3.$$

Multiplicamos ambos lados por 100 (o directamente despejamos) para simplificar:

$$\frac{16 \cdot 4}{25 \cdot 4} y^3 = \frac{5 \cdot 25}{4 \cdot 25} x^3 \implies \frac{64}{100} y^3 = \frac{125}{100} x^3,$$

lo que simplifica a:

$$64 y^3 = 125 x^3.$$

Dividiendo ambos lados por x^3 :

$$\left(\frac{y}{x}\right)^3 = \frac{125}{64},$$

y, al tomar la raíz cúbica:

$$\frac{y}{x} = \frac{5}{4} \implies y = \frac{5}{4} x.$$

Sustitución en la restricción para hallar x y y

Sustituyendo $y = \frac{5}{4}x$ en la restricción

$$5x + 2y = 100,$$

se tiene:

$$5x + 2\left(\frac{5}{4}x\right) = 5x + \frac{10}{4}x = 5x + \frac{5}{2}x = \frac{10x + 5x}{2} = \frac{15x}{2} = 100.$$

Despejamos x :

$$x = \frac{100 \cdot 2}{15} = \frac{200}{15} = \frac{40}{3}.$$

Luego, y es:

$$y = \frac{5}{4}x = \frac{5}{4} \cdot \frac{40}{3} = \frac{200}{12} = \frac{50}{3}.$$

Valor óptimo de la función

Finalmente, el valor óptimo de la función es:

$$f\left(\frac{40}{3}, \frac{50}{3}\right) = \left(\frac{40}{3}\right)^2 \cdot \frac{50}{3} = \frac{1600}{9} \cdot \frac{50}{3} = \frac{80000}{27}.$$

Resumen del Método

1. Se despeja x en función de y (y viceversa) a partir de la función objetivo $x^2y = K$ y la restricción $5x + 2y = 100$.
2. Se derivan ambas expresiones con respecto a la variable correspondiente y se igualan, obteniéndose dos relaciones que involucran K .
3. Se igualan los valores de K obtenidos en ambos procesos para eliminar el parámetro K y obtener una relación única entre x e y .
4. Finalmente, se sustituye esta relación en la restricción para determinar los valores óptimos de x y y .

Ejemplo: Minimización de $C = 3x_1 + 6x_2 + 180$ sujeta a $x_1x_2 = 2$

Se desea minimizar

$$C = 3x_1 + 6x_2 + 180,$$

sujeto a la restricción

$$x_1x_2 = 2.$$

Fijamos un nivel constante para la función objetivo

$$3x_1 + 6x_2 + 180 = K,$$

Paso 1: Derivación de la Función Objetivo

Despejamos x_2 en función de x_1 :

$$x_2 = \frac{K - 180 - 3x_1}{6}.$$

Al derivar con respecto a x_1 se obtiene:

$$\frac{dx_2}{dx_1} = -\frac{3}{6} = -\frac{1}{2}.$$

Nótese que la derivada no depende de K (la constante desaparece).

Paso 2: Derivación de la Restricción

A partir de la restricción

$$x_1 x_2 = 2,$$

despejamos x_2 :

$$x_2 = \frac{2}{x_1}.$$

Derivamos respecto a x_1 se obtiene:

$$\frac{dx_2}{dx_1} = -\frac{2}{x_1^2}.$$

Paso 3: Igualar las Derivadas

En el punto de tangencia entre la curva de nivel de la función objetivo y la curva de la restricción, sus pendientes deben ser iguales. Es decir:

$$-\frac{1}{2} = -\frac{2}{x_1^2}.$$

Cancelando el signo negativo y resolviendo:

$$\frac{1}{2} = \frac{2}{x_1^2} \implies x_1^2 = 4 \implies x_1 = 2,$$

(considerando $x_1 > 0$).

Paso 4: Determinar x_2 y el Costo Óptimo

Sustituyendo $x_1 = 2$ en la restricción:

$$x_2 = \frac{2}{2} = 1.$$

Por tanto, el costo mínimo es:

$$C_{\min} = 3(2) + 6(1) + 180 = 6 + 6 + 180 = 192.$$

Método de Sustitución para la Optimización con Restricción

Supongamos que queremos optimizar (maximizar o minimizar) una función objetivo $F(x, y)$ sujeta a una restricción $G(x, y) = C$. Este método consiste en despejar de la restricción una variable, sustituir esa expresión en la función objetivo para **reducir el problema a una única variable**, derivar respecto a esa variable, igualar a cero y, finalmente, resolver para encontrar la solución óptima.

El procedimiento se resume en los siguientes pasos:

1. **Resolver la restricción:** Dada la restricción

$$G(x, y) = C,$$

se despeja una de las variables. Por ejemplo, si despejamos y obtenemos:

$$y = g(x).$$

2. **Sustituir en la función objetivo:** Se inserta $y = g(x)$ en la función objetivo $F(x, y)$ para obtener una función de una sola variable:

$$f(x) = F(x, g(x)).$$

3. **Derivar e igualar a cero:** Se deriva la función $f(x)$ respecto a x y se impone la condición de primer orden:

$$\frac{df(x)}{dx} = 0.$$

Esta ecuación se resuelve para hallar el valor óptimo x^* .

4. **Determinar la otra variable:** Finalmente, se sustituye x^* en la expresión $y = g(x)$ para obtener y^* .

Este método reduce el problema original de dos variables a uno de una sola variable, simplificando el proceso de optimización.

Ejemplo: Optimización de $f(x, y) = x^2y$ sujeta a $5x + 2y = 100$ (Método de Sustitución)

Sea la función objetivo

$$f(x, y) = x^2y,$$

y la restricción

$$5x + 2y = 100.$$

El método de sustitución consiste en despejar una variable de la restricción, insertar esa expresión en la función objetivo para obtener una función de una sola variable, derivar respecto a dicha variable, igualar a cero y finalmente despejar.

Paso 1: Resolver la restricción

De la ecuación

$$5x + 2y = 100,$$

despejamos y :

$$y = \frac{100 - 5x}{2}.$$

Paso 2: Sustituir en la función objetivo

Insertamos la expresión de y en $f(x, y) = x^2y$:

$$f(x) = x^2 \left(\frac{100 - 5x}{2} \right) = \frac{1}{2} (100x^2 - 5x^3).$$

Paso 3: Derivar e igualar a cero

Derivamos $f(x)$ respecto a x :

$$f'(x) = \frac{1}{2} (200x - 15x^2) = 100x - \frac{15}{2}x^2.$$

Para hallar el óptimo, igualamos la derivada a cero:

$$100x - \frac{15}{2}x^2 = 0.$$

Factorizamos x :

$$x \left(100 - \frac{15}{2}x \right) = 0.$$

Se obtienen dos soluciones: $x = 0$ (solución trivial) y

$$100 - \frac{15}{2}x = 0 \implies x = \frac{200}{15} = \frac{40}{3}.$$

Descartamos $x = 0$ y tomamos $x^* = \frac{40}{3}$.

Paso 4: Determinar y

Sustituyendo $x^* = \frac{40}{3}$ en la expresión de y :

$$y^* = \frac{100 - 5\left(\frac{40}{3}\right)}{2} = \frac{100 - \frac{200}{3}}{2} = \frac{\frac{300-200}{3}}{2} = \frac{\frac{100}{3}}{2} = \frac{50}{3}.$$

Paso 5: Valor óptimo de la función

El valor óptimo de la función es:

$$f\left(\frac{40}{3}, \frac{50}{3}\right) = \left(\frac{40}{3}\right)^2 \cdot \frac{50}{3} = \frac{80000}{27}.$$

Resumen del Método de Sustitución

1. Se despeja una variable de la restricción, en este caso $y = \frac{100-5x}{2}$.
2. Se sustituye en la función objetivo para obtener $f(x) = \frac{1}{2}(100x^2 - 5x^3)$.
3. Se deriva $f(x)$ respecto a x y se iguala a cero para encontrar el valor óptimo x^* .
4. Se utiliza x^* en la expresión de y para determinar y^* .
5. Se evalúa la función objetivo en (x^*, y^*) para obtener el valor óptimo.

Ejemplo: Minimización de $C = 3x_1 + 6x_2 + 180$ sujeta a $x_1x_2 = 2$ (Método de Sustitución)

Se desea minimizar

$$C = 3x_1 + 6x_2 + 180,$$

sujeto a la restricción

$$x_1x_2 = 2.$$

Paso 1: Despejar una variable de la restricción

A partir de la restricción $x_1x_2 = 2$, despejamos x_2 :

$$x_2 = \frac{2}{x_1}.$$

Paso 2: Sustituir en la función objetivo

Sustituimos la expresión de x_2 en la función objetivo simplificada:

$$\tilde{C}(x_1) = 3x_1 + 6\left(\frac{2}{x_1}\right) + 180 = 3x_1 + \frac{12}{x_1} + 180$$

Paso 3: Derivar e igualar a cero

Derivamos la función $\tilde{C}(x_1)$ respecto a x_1 :

$$\frac{d\tilde{C}}{dx_1} = 3 - \frac{12}{x_1^2}.$$

Para hallar el mínimo, igualamos la derivada a cero:

$$3 - \frac{12}{x_1^2} = 0.$$

Resolviendo:

$$\frac{12}{x_1^2} = 3 \implies x_1^2 = \frac{12}{3} = 4,$$

por lo que, considerando $x_1 > 0$,

$$x_1^* = 2.$$

Paso 4: Determinar x_2 y el costo óptimo

Sustituyendo $x_1 = 2$ en la expresión de x_2 :

$$x_2^* = \frac{2}{2} = 1.$$

El costo mínimo es, entonces:

$$C_{\min} = 3(2) + 6(1) + 180 = 6 + 6 + 180 = 192.$$

Resumen del Método de Sustitución

1. Se despeja x_2 de la restricción $x_1 x_2 = 2$: $x_2 = \frac{2}{x_1}$.
2. Se sustituye en la función objetivo simplificada $\tilde{C} = 3x_1 + 6x_2$ para obtener

$$\tilde{C}(x_1) = 3x_1 + \frac{12}{x_1}.$$

3. Se deriva respecto a x_1 e iguala la derivada a cero para hallar x_1^* .
4. Se determina x_2^* usando la expresión de la restricción y se evalúa C .

Soluciones de Esquina

Es importante notar que el método de sustitución (o igualación de derivadas) asume que la solución óptima es interior, es decir, que la curva de nivel de la función objetivo es tangente a la restricción. Este método no es aplicable cuando el óptimo se alcanza en una solución de esquina.

Ejemplo breve: Considera la maximización de

$$f(x, y) = x + y,$$

sujeta a las restricciones

$$\begin{cases} x + y \leq 1, \\ x \geq 0, \quad y \geq 0. \end{cases}$$

En este problema, el óptimo se alcanza en las esquinas $(0, 1)$ o $(1, 0)$, donde no existe tangencia entre la curva de nivel y la frontera. Por ello, métodos basados en la igualación de derivadas no serían adecuados en este caso.

5 Continuidad

En esta sección vamos a repasar rápidamente los [límites y la continuidad en una variable](#) y extenderemos las ideas al caso de [dos variables](#) (o más).

Repaso: límites y continuidad en una variable

Sea $f: I \subseteq \mathbb{R} \rightarrow \mathbb{R}$ y $a \in I$.

- **Continuidad en a :**

$$f \text{ es continua en } a \iff \lim_{x \rightarrow a} f(x) = f(a).$$

Esta definición engloba 3 condiciones:

- La función existe en el punto a
- El límite de la función existe cuando $x \rightarrow a$
- El valor de la función en el punto y el límite coinciden.

Ejemplos

Sea

$$f(x) = (x + 1)^2.$$

Tomemos $a = 1$. Verificamos continuidad en a con las tres condiciones:

- **Existencia de $f(1)$:** $f(1) = 1^2 + 2 \cdot 1 + 1 = 4$.
- **Existencia del límite:**

$$\lim_{x \rightarrow 1} f(x) = \lim_{x \rightarrow 1} (x^2 + 2x + 1) = 1^2 + 2 \cdot 1 + 1 = 4.$$

- **Coincidencia límite–valor:** $\lim_{x \rightarrow 1} f(x) = 4 = f(1)$.

Por lo tanto, f es continua en $x = 1$ (de hecho, en todo $\mathbb{R}$ por ser polinómica).

Veamos otro ejemplo. Definimos

$$g(x) = \begin{cases} \frac{x^2 - 1}{x - 1}, & x \neq 1, \\ 0, & x = 1. \end{cases}$$

Observemos que para $x \neq 1$,

$$\frac{x^2 - 1}{x - 1} = \frac{(x - 1)(x + 1)}{x - 1} = x + 1,$$

luego

$$\lim_{x \rightarrow 1} g(x) = \lim_{x \rightarrow 1} (x + 1) = 2.$$

Sin embargo, $g(1) = 0$. Entonces:

- **Existe $g(1)$:** $g(1) = 0$.
- **Existe el límite:** $\lim_{x \rightarrow 1} g(x) = 2$.
- **No coinciden:** $2 \neq 0$.

Por lo tanto, g es discontinua en $x = 1$ (discontinuidad *evitable*, ya que si redefiniéramos $g(1) = 2$ se volvería continua).

Veamos un último ejemplo. Sea

$$f(x) = \frac{1}{x-2}.$$

Analicemos en $a = 2$.

- **Existencia de $f(2)$:** $f(2)$ no está definida (el denominador se anula).
- **Comportamiento del límite:**

$$\lim_{x \rightarrow 2^-} \frac{1}{x-2} = -\infty, \quad \lim_{x \rightarrow 2^+} \frac{1}{x-2} = +\infty.$$

Por lo tanto, $\lim_{x \rightarrow 2} f(x)$ no existe como número finito.

En consecuencia, f presenta una discontinuidad *infinita* en $x = 2$ y la recta $x = 2$ es una *asíntota vertical*.

Límites y continuidad en dos variables

Sea $f: D \subseteq \mathbb{R}^2 \rightarrow \mathbb{R}$ y $a = (a_1, a_2) \in D$.

- **Continuidad en a :**

$$f \text{ es continua en } a \iff \lim_{(x,y) \rightarrow (a_1,a_2)} f(x,y) = f(a_1,a_2).$$

Como en una variable, esta condición resume tres hechos:

- **La función está definida en a :** $f(a_1, a_2)$ existe.
- **El límite existe al acercarse a a :** $\lim_{(x,y) \rightarrow (a_1,a_2)} f(x,y)$ existe (es único).
- **Coinciden límite y valor:** $\lim_{(x,y) \rightarrow (a_1,a_2)} f(x,y) = f(a_1, a_2)$.

Ejemplos

Sea

$$f(x,y) = x^2 + 2xy + 3y^2.$$

Verifiquemos primero la continuidad en el punto específico $a = (1, 2)$.

- **Existencia de $f(a)$:**

$$f(1, 2) = 1^2 + 2 \cdot 1 \cdot 2 + 3 \cdot 2^2 = 1 + 4 + 12 = 17.$$

- **Existencia del límite y coincidencia con el valor:** Como f es un polinomio (suma y producto de funciones continuas),

$$\lim_{(x,y) \rightarrow (1,2)} f(x,y) = f(1,2) = 17.$$

Por lo tanto, f es continua en $(1, 2)$.

Además, como f es polinómica en x y y , es continua en todo $\mathbb{R}^2$; es decir, para cualquier $a = (a_1, a_2)$,

$$\lim_{(x,y) \rightarrow (a_1, a_2)} f(x, y) = f(a_1, a_2).$$

Veamos otro caso, definimos

$$g(x, y) = \begin{cases} 1, & (x, y) \neq (0, 0), \\ 0, & (x, y) = (0, 0). \end{cases}$$

Al acercarse a $(0, 0)$, se tiene $\lim_{(x,y) \rightarrow (0,0)} g(x, y) = 1$, pero $g(0, 0) = 0$. Por lo tanto, $\lim_{(x,y) \rightarrow (0,0)} g(x, y) \neq g(0, 0)$ y g es discontinua en $(0, 0)$.

Un último ejemplo. Sea

$$h(x, y) = \begin{cases} \frac{xy}{x^2 + y^2}, & (x, y) \neq (0, 0), \\ 0, & (x, y) = (0, 0). \end{cases}$$

Cuando tenemos una sola variable independiente, uno puede acercarse al punto por izquierda y por derecha, pero al trabajar con dos variables independientes uno puede acercarse al punto de diferentes maneras, como por ejemplo a través de una relación lineal entre x e y . Considerando caminos rectos $y = mx$.

$$h(x, mx) = \frac{x(mx)}{x^2 + m^2 x^2} = \frac{m}{1 + m^2},$$

cuyo límite cuando $x \rightarrow 0$ depende de m . Por ejemplo, por $y = x$ el límite vale $\frac{1}{2}$, mientras que por $y = -x$ vale $-\frac{1}{2}$. Luego $\lim_{(x,y) \rightarrow (0,0)} h(x, y)$ no existe y h es discontinua en $(0, 0)$.


6 Derivadas parciales

Derivada para funciones de una variable

Para funciones de una variable la derivada relaciona el incremento de la función con el incremento de la variable independiente (cociente incremental) cuando el incremento de x tiende a cero

$$f'(x_0) = \lim_{h \rightarrow 0} \frac{f(x_0 + h) - f(x_0)}{h}$$

Gráficamente:



La función representada es:

$$f(x) = -(x-2)^2 + 4$$

En el punto $(1, 3)$, la pendiente de la recta tangente es precisamente la derivada de f respecto a x :

$$\left. \frac{df}{dx} \right|_{x=1} = 2$$

Como esta pendiente es positiva, la función en ese punto está aumentando.

Derivadas parciales

Para una función de dos variables debemos considerar el incremento de la función z asociada a cambios en las variables independientes x e y . Para ello, permitimos la variación de una variable manteniendo la otra constante.

Dada la función $z = f(x, y)$, se define la derivada parcial de f con respecto a x en el punto (x_0, y_0) como el valor del siguiente límite, si existe y es finito:

$$\frac{\partial f}{\partial x}(x_0, y_0) = \lim_{h \rightarrow 0} \frac{f(x_0 + h, y_0) - f(x_0, y_0)}{h}$$

Del mismo modo, se define la derivada parcial de f con respecto a y en el punto (x_0, y_0) como el siguiente límite, si existe y es finito:

$$\frac{\partial f}{\partial y}(x_0, y_0) = \lim_{h \rightarrow 0} \frac{f(x_0, y_0 + h) - f(x_0, y_0)}{h}$$

Intuición: Básicamente consideramos un pequeño incremento h (que luego hacemos tender a cero) en una sola variable — x o y — mientras la otra permanece fija. A ese desplazamiento le restamos el valor original de la función para medir cuánto ha cambiado f al pasar del punto viejo al nuevo, y dividimos por la distancia h recorrida. De este modo obtenemos la variación de f por unidad de desplazamiento en esa dirección, que es precisamente la derivada parcial en ese punto.

Derivadas parciales en $\mathbb{R}^n$

Para generalizar lo anterior podemos pasar a n variables: Sea $f: U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ y sea $a = (a_1, \dots, a_n) \in U$. Para cada $i = 1, \dots, n$, la derivada parcial de f con respecto a la variable x_i en el punto a se define como

$$\frac{\partial f}{\partial x_i}(a) = \lim_{h \rightarrow 0} \frac{f(a_1, \dots, a_{i-1}, a_i + h, a_{i+1}, \dots, a_n) - f(a_1, \dots, a_n)}{h}$$

Ejemplo

Sea la función

$$f(x, y) = x^2 y + 3x y^2$$

Por definición

$$\frac{\partial f}{\partial x}(1, 2) = \lim_{h \rightarrow 0} \frac{f(1+h, 2) - f(1, 2)}{h}$$

Calculamos

$$f(1+h, 2) = 2(1+h)^2 + 12(1+h) = 2 + 4h + 2h^2 + 12 + 12h = 14 + 16h + 2h^2 \quad f(1, 2) = 14$$

Luego

$$\frac{f(1+h, 2) - f(1, 2)}{h} = \frac{16h + 2h^2}{h} = 16 + 2h$$

y al tomar el límite

$$\left. \frac{\partial f}{\partial x} \right|_{(x,y)=(1,2)} = 16$$

También es posible aplicar reglas de derivadas como en el caso de funciones de una sola variable. Para esto las mismas reglas son aplicables teniendo en cuenta que las demás variables se mantienen constantes cuando derivamos con respecto a una:

Reglas de derivadas más utilizadas

- **Regla de la potencia:**

$$\frac{d}{dx}(x^n) = n x^{n-1}$$

- **Derivada de la función logarítmica:**

$$\frac{d}{dx}(\ln x) = \frac{1}{x} \quad (x > 0)$$

- Derivadas de las funciones trigonométricas:

$$\frac{d}{dx}(\sin x) = \cos x, \quad \frac{d}{dx}(\cos x) = -\sin x$$

- Derivadas de las funciones exponenciales:

$$\frac{d}{dx}(a^x) = a^x \ln a \quad (a > 0, a \neq 1)$$

- Regla del producto:

$$\frac{d}{dx}(u(x)v(x)) = \frac{du}{dx}v(x) + u(x)\frac{dv}{dx}$$

- Regla del cociente:

$$\frac{d}{dx}\left(\frac{u(x)}{v(x)}\right) = \frac{\frac{du}{dx}v(x) - u(x)\frac{dv}{dx}}{v(x)^2}$$

Siguiendo con el ejemplo anterior:

$$f(x, y) = x^2y + 3xy^2$$

Por regla

$$\frac{\partial f}{\partial x}(x, y) = 2xy + 3y^2 \implies \frac{\partial f}{\partial x}(1, 2) = 2 \cdot 1 \cdot 2 + 3 \cdot 2^2 = 16$$

Otro ejemplo

Sea la función

$$f(x, y) = x^3y^2 + 5xy^3 - x^2y$$

Por definición

$$\frac{\partial f}{\partial x}(x, y) = \lim_{h \rightarrow 0} \frac{f(x+h, y) - f(x, y)}{h}$$

$$f(x+h, y) = (x+h)^3y^2 + 5(x+h)y^3 - (x+h)^2y = x^3y^2 + 3x^2y^2h + 3xy^2h^2 + y^2h^3 + 5xy^3 + 5y^3h - x^2y - 2xyh - yh^2$$

$$\frac{f(x+h, y) - f(x, y)}{h} = 3x^2y^2 + 3xy^2h + y^2h^2 + 5y^3 - 2xy - yh \xrightarrow{h \rightarrow 0} 3x^2y^2 + 5y^3 - 2xy$$

$$\frac{\partial f}{\partial y}(x, y) = \lim_{h \rightarrow 0} \frac{f(x, y+h) - f(x, y)}{h}$$

$$f(x, y+h) = x^3(y+h)^2 + 5x(y+h)^3 - x^2(y+h) = x^3y^2 + 2x^3yh + x^3h^2 + 5xy^3 + 15xy^2h + 15xyh^2 + 5xh^3 - x^2y - x^2h$$

$$\frac{f(x, y+h) - f(x, y)}{h} = 2x^3y + x^3h + 15xy^2 + 15xyh + 5xh^2 - x^2 \xrightarrow{h \rightarrow 0} 2x^3y + 15xy^2 - x^2$$

Por reglas de derivación

$$\frac{\partial f}{\partial x}(x, y) = \frac{\partial}{\partial x}(x^3 y^2) + \frac{\partial}{\partial x}(5xy^3) - \frac{\partial}{\partial x}(x^2 y) = 3x^2 y^2 + 5y^3 - 2xy$$

$$\frac{\partial f}{\partial x}(x, y) = 3x^2 y^2 + 5y^3 - 2xy$$

$$\frac{\partial f}{\partial y}(x, y) = \frac{\partial}{\partial y}(x^3 y^2) + \frac{\partial}{\partial y}(5xy^3) - \frac{\partial}{\partial y}(x^2 y) = 2x^3 y + 15xy^2 - x^2$$

$$\frac{\partial f}{\partial y}(x, y) = 2x^3 y + 15xy^2 - x^2$$

Las reglas de derivación (regla de potencia, producto, cociente, etc.) se obtienen a partir de la definición límite de derivada. Sin embargo, cuando la función está definida por tramos, esas reglas pueden no ser aplicables en los puntos de unión. En dichos casos es necesario calcular la derivada parcial directamente mediante la definición por límites

Ejemplo con función partida

Sea la función

$$f(x, y) = \begin{cases} \frac{x^3}{x^2 + y^2}, & (x, y) \neq (0, 0) \\ 0, & (x, y) = (0, 0) \end{cases}$$

Por definición

$$\frac{\partial f}{\partial x}(0, 0) = \lim_{h \rightarrow 0} \frac{f(h, 0) - f(0, 0)}{h} = \lim_{h \rightarrow 0} \frac{\frac{h^3}{h^2} - 0}{h} = \lim_{h \rightarrow 0} \frac{h}{h} = 1$$

$$\frac{\partial f}{\partial y}(0, 0) = \lim_{h \rightarrow 0} \frac{f(0, h) - f(0, 0)}{h} = \lim_{h \rightarrow 0} \frac{\frac{0}{h^2} - 0}{h} = \lim_{h \rightarrow 0} \frac{0}{h} = 0$$

Derivadas sucesivas

En una sola variable ya conocemos las derivadas sucesivas:

$$f'(x), \quad f''(x), \quad f^{(n)}(x)$$

que se obtienen aplicando la definición de derivada reiteradamente sobre la función resultante.

En varias variables podemos también derivar más de una vez, ya sea respecto a la misma variable o a variables distintas. Así surgen las derivadas parciales de orden dos y superiores, por ejemplo:

$$\frac{\partial^2 f}{\partial x^2} = f_{xx}, \quad \frac{\partial^2 f}{\partial y \partial x} = f_{xy}, \quad \frac{\partial^2 f}{\partial x \partial y} = f_{yx}, \quad \frac{\partial^2 f}{\partial y^2} = f_{yy}$$

Las derivadas cruzadas f_{xy} y f_{yx} se obtienen derivando primero con respecto a x y luego a y , o viceversa. En general, las derivadas sucesivas se calculan tomando la derivada parcial de la derivada parcial considerada como nueva función, es decir, si $g(x, y) = \frac{\partial f}{\partial x}(x, y)$, entonces

$$\frac{\partial^2 f}{\partial y \partial x}(x, y) = \frac{\partial}{\partial y}(g(x, y))$$

y así sucesivamente para órdenes mayores.

Ejemplo

$$f(x, y) = e^x + e^y + y \sin(x)$$

Derivadas parciales de primer orden

$$\frac{\partial f}{\partial x}(x, y) = \frac{\partial}{\partial x}(e^x + e^y + y \sin(x)) = e^x + y \cos(x) \implies f_x(x, y) = e^x + y \cos(x)$$

$$\frac{\partial f}{\partial y}(x, y) = \frac{\partial}{\partial y}(e^x + e^y + y \sin(x)) = e^y + \sin(x) \implies f_y(x, y) = e^y + \sin(x)$$

Derivadas parciales de segundo orden

$$\frac{\partial^2 f}{\partial x^2} = \frac{\partial}{\partial x}(e^x + y \cos(x)) = e^x - y \sin(x) \implies f_{xx}(x, y) = e^x - y \sin(x)$$

$$\frac{\partial^2 f}{\partial y \partial x} = \frac{\partial}{\partial y}(e^x + y \cos(x)) = \cos(x) \implies f_{xy}(x, y) = \cos(x)$$

$$\frac{\partial^2 f}{\partial x \partial y} = \frac{\partial}{\partial x}(e^y + \sin(x)) = \cos(x) \implies f_{yx}(x, y) = \cos(x)$$

$$\frac{\partial^2 f}{\partial y^2} = \frac{\partial}{\partial y}(e^y + \sin(x)) = e^y \implies f_{yy}(x, y) = e^y$$

Teorema de Schwarz

El teorema de Schwarz garantiza que, cuando las segundas derivadas parciales cruzadas de una función existen y son continuas, éstas coinciden:

$$f_{x_i x_j} = f_{x_j x_i}$$

Esto resulta especialmente práctico porque, tras comprobar esta igualdad, basta calcular una sola de las dos derivadas cruzadas en lugar de ambas, ahorrando tiempo.

Condiciones de aplicabilidad

Supóngase que en un entorno de un punto (x_0, y_0) se cumplen:

- Existen las derivadas parciales $\frac{\partial f}{\partial x}$ y $\frac{\partial f}{\partial y}$.
- Existe una de las derivadas parciales cruzadas (por ejemplo $\frac{\partial^2 f}{\partial y \partial x}$) y es continua en (x_0, y_0) .

Bajo estas hipótesis, las derivadas parciales cruzadas van a ser iguales.

Ejemplo

Sea la función

$$f(x, y) = x^2 y + e^{xy}$$

En todo $\mathbb{R}^2$ se cumplen las condiciones:

- Existen las derivadas parciales $\frac{\partial f}{\partial x}$ y $\frac{\partial f}{\partial y}$.
- Existe la derivada parcial cruzada $\frac{\partial^2 f}{\partial y \partial x}$ y es continua en $\mathbb{R}^2$.

Por tanto, en cualquier punto (x, y) vale el teorema de Schwarz.

Cálculo de las derivadas parciales

$$f_x(x, y) = \frac{\partial}{\partial x}(x^2 y + e^{xy}) = 2x y + y e^{xy} \quad f_y(x, y) = \frac{\partial}{\partial y}(x^2 y + e^{xy}) = x^2 + x e^{xy}$$

Derivadas cruzadas

$$f_{xy}(x, y) = \frac{\partial}{\partial y}(2x y + y e^{xy}) = 2x + e^{xy} + x y e^{xy}$$

$$f_{yx}(x, y) = \frac{\partial}{\partial x}(x^2 + x e^{xy}) = 2x + e^{xy} + x y e^{xy}$$

$$f_{xy}(x, y) = f_{yx}(x, y)$$

7 Diferencial

Recordatorio: cálculo univariable

Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ diferenciable en x_0 . La *aproximación lineal* (o *linealización*) alrededor de x_0 es

$$f(x_0 + h) \approx f(x_0) + f'(x_0)h, \quad \text{con } h = x - x_0$$

El *diferencial* de f en x_0 se define como

$$df = f'(x_0) dx$$

Intuición: Al “hacer zoom” sobre la gráfica de f alrededor de x_0 , la curva se vuelve casi recta: la *recta tangente*, con pendiente $f'(x_0)$, es la mejor aproximación local de f .

Dar un pequeño paso dx en x provoca un cambio real

$$\Delta f = f(x_0 + dx) - f(x_0)$$

que es *aproximadamente igual* al diferencial:

$$\Delta f \approx df = f'(x_0) dx$$

es decir, *pendiente $\times$ paso*.

También se puede expresar como

$$f(x_0 + h) = f(x_0) + f'(x_0)h + o(h) \quad \text{cuando } h \rightarrow 0$$

donde $o(h)$ denota un término tal que

$$\lim_{h \rightarrow 0} \frac{o(h)}{h} = 0$$

Es decir, el error entre la aproximación lineal y el valor real es despreciable frente a $|h|$ cuando $h \rightarrow 0$.

Definición en dos variables independientes

Sea $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ diferenciable en (a, b) . El *diferencial* de f en (a, b) es

$$df = f'_x(a, b) dx + f'_y(a, b) dy$$

Equivalentemente,

$$f(a + dx, b + dy) \approx f(a, b) + f'_x(a, b) dx + f'_y(a, b) dy$$

Geometría: en dos variables, la aproximación *no es una recta*, sino un *plano tangente* a la gráfica $z = f(x, y)$ en (a, b) :

$$z \approx f(a, b) + f'_x(a, b)(x - a) + f'_y(a, b)(y - b)$$

Intuición: Lo que buscamos es aproximar el cambio de z a partir de cambios pequeños en x e y . Cada derivada parcial $f'_x(a, b)$ y $f'_y(a, b)$ mide cuán sensible es z a cambios en x o en y , respectivamente.

Si nos movemos dx en x y dy en y , el cambio total se aproxima sumando ambos aportes:

$$\Delta z \approx df = f'_x(a, b) dx + f'_y(a, b) dy$$

es decir, “*pendiente en x* ” $\times$ “*paso en x* ” + “*pendiente en y* ” $\times$ “*paso en y* ”.

Condiciones suficientes

Si f'_x y f'_y existen en un entorno de (a, b) y son continuas en (a, b) , entonces f es diferenciable en (a, b) y la aproximación lineal anterior es válida.

Intuición: Exigir que f'_x y f'_y sean continuas cerca de (a, b) garantiza que las pendientes en x y en y no cambien bruscamente. Si las pendientes varían de forma suave, entonces la superficie de f cerca de (a, b) se parece mucho a su plano tangente, y la aproximación lineal mediante el diferencial describe bien los cambios pequeños en z .

Caso general $\mathbb{R}^n \rightarrow \mathbb{R}$

Para $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en $\mathbf{a} \in \mathbb{R}^n$,

$$df = \frac{\partial f}{\partial x_1}(\mathbf{a}) dx_1 + \frac{\partial f}{\partial x_2}(\mathbf{a}) dx_2 + \cdots + \frac{\partial f}{\partial x_n}(\mathbf{a}) dx_n$$

Es decir,

$$df = \nabla f(\mathbf{a}) \cdot d\mathbf{x} = \sum_{i=1}^n \frac{\partial f}{\partial x_i}(\mathbf{a}) dx_i$$

De forma aproximada,

$$f(a_1 + dx_1, \dots, a_n + dx_n) \approx f(a_1, \dots, a_n) + df$$

Ejemplo

Sea $f(x, y) = x^2y + e^{xy}$. Entonces

$$f'_x = 2xy + y e^{xy}, \quad f'_y = x^2 + x e^{xy}$$

En $(a, b) = (1, 1)$,

$$df = (2 \cdot 1 \cdot 1 + 1 \cdot e) dx + (1^2 + 1 \cdot e) dy = (2 + e) dx + (1 + e) dy$$

Para $dx = 0.01$ y $dy = -0.02$,

$$\Delta f \approx df = (2 + e)(0.01) + (1 + e)(-0.02) \approx -0.0272$$

El resultado negativo indica que, con un pequeño incremento en x y una disminución en y , el valor de la función f tiende a reducirse levemente. En otras palabras, el efecto de disminuir y en 0.02 supera el

incremento positivo producido al aumentar x en 0.01, de modo que el cambio neto es una pequeña disminución en f .

Si calculamos la variación real, obtenemos

$$\begin{aligned}\Delta f &= f(1.01, 0.98) - f(1, 1) \\ &= (1.01)^2 \cdot 0.98 + e^{0.9898} - (1 + e) \\ &= 3.6903942793 - 3.7182818285 \\ &= -0.0278875492\end{aligned}$$

Este valor es cercano al obtenido mediante el diferencial. La pequeña diferencia se debe a que el diferencial proporciona una aproximación lineal del cambio real de la función.

Diferencial de segundo orden

Sea $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ con derivadas parciales primeras y segundas existentes en un entorno de (a, b) , y cuyas derivadas parciales de segundo orden son continuas en ese entorno. Su *diferencial de segundo orden* en (a, b) es

$$d^2 f = f''_{xx}(a, b) (dx)^2 + f''_{xy}(a, b) dx dy + f''_{yx}(a, b) dy dx + f''_{yy}(a, b) (dy)^2$$

El diferencial de segundo orden incorpora información sobre la *curvatura local* de la función y describe la contribución de segundo orden a su variación. En particular, puede utilizarse para construir aproximaciones más precisas, como el polinomio de Taylor de segundo orden.

Polinomio de Taylor

El polinomio de Taylor permite aproximar una función alrededor de un punto utilizando información sobre sus derivadas en ese punto. La idea es extender la aproximación lineal: en lugar de utilizar solamente la pendiente, incorporamos también información sobre la curvatura y, si fuera necesario, derivadas de órdenes superiores.

Caso univariable

Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ una función con suficientes derivadas alrededor de $x = a$. Recordemos que la aproximación lineal viene dada por

$$f(a + h) \approx f(a) + f'(a)h$$

Esta aproximación utiliza solamente el valor de la función y su pendiente en a . Si además queremos incorporar información sobre la curvatura de f , podemos agregar un término que involucra la segunda derivada:

$$f(a + h) \approx f(a) + f'(a)h + \frac{1}{2}f''(a)h^2$$

El lado derecho de esta expresión es el *polinomio de Taylor de segundo orden* de f alrededor de a .

Utilizando diferenciales, si $h = dx$, podemos escribir

$$f(a + dx) \approx f(a) + \underbrace{f'(a) dx}_{df} + \frac{1}{2} \underbrace{f''(a)(dx)^2}_{d^2 f}$$

Por lo tanto,

$$f(a + dx) \approx f(a) + df + \frac{1}{2}d^2 f$$

Intuición: El término de primer orden describe el cambio lineal predicho por la pendiente de la función. El término de segundo orden corrige esa aproximación teniendo en cuenta su *curvatura local*.²

Si utilizamos derivadas de órdenes superiores, obtenemos aproximaciones que incorporan cada vez más información local sobre la función. El polinomio de Taylor de orden n alrededor de a es

$$P_n(x) = f(a) + f'(a)(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \cdots + \frac{f^{(n)}(a)}{n!}(x-a)^n$$

De manera compacta,

$$P_n(x) = \sum_{k=0}^n \frac{f^{(k)}(a)}{k!}(x-a)^k$$

Así, para valores de x suficientemente cercanos a a ,

$$f(x) \approx P_n(x)$$

En general, al aumentar el orden del polinomio incorporamos más información local sobre la función y, bajo condiciones apropiadas, podemos obtener una mejor aproximación cerca del punto a .

Caso multivariable

La misma idea puede extenderse a funciones de varias variables.

Sea $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ una función con suficientes derivadas parciales alrededor de (a, b) . La aproximación de Taylor de primer orden es precisamente la aproximación lineal estudiada anteriormente:

$$f(a+dx, b+dy) \approx f(a, b) + f'_x(a, b)dx + f'_y(a, b)dy$$

Es decir,

$$f(a+dx, b+dy) \approx f(a, b) + df$$

Si además incorporamos las derivadas de segundo orden, obtenemos la aproximación de Taylor de segundo orden:

$$\begin{aligned} f(a+dx, b+dy) &\approx f(a, b) + f'_x(a, b)dx + f'_y(a, b)dy \\ &\quad + \frac{1}{2} \left[f''_{xx}(a, b)(dx)^2 + 2f''_{xy}(a, b)dx dy + f''_{yy}(a, b)(dy)^2 \right] \end{aligned}$$

donde hemos supuesto que las derivadas parciales mixtas son continuas, de modo que

$$f''_{xy}(a, b) = f''_{yx}(a, b)$$

Utilizando los diferenciales de primer y segundo orden, esta expresión puede escribirse de forma más compacta como

$$f(a+dx, b+dy) \approx f(a, b) + df + \frac{1}{2}d^2f$$

²El factor $\frac{1}{2}$ que aparece en el término de segundo orden puede escribirse como $\frac{1}{2!}$. En general, para el término de orden n aparece el factor $\frac{1}{n!}$, ya que al derivar n veces el término $(x-a)^n$ se obtiene $n!$. Dividir por $n!$ permite que la derivada de orden n del polinomio de Taylor, evaluada en $x = a$, coincida exactamente con la derivada de orden n de la función original evaluada en a .

Intuición: En varias variables ocurre algo similar al caso univariable. El diferencial de primer orden describe el comportamiento local de la función mediante su plano tangente, mientras que el diferencial de segundo orden incorpora información sobre su curvatura en las distintas direcciones.

Los términos

$$f''_{xx}(\mathrm{d}x)^2 \quad \text{y} \quad f''_{yy}(\mathrm{d}y)^2$$

describen las contribuciones de segundo orden asociadas a cada variable por separado, mientras que el término

$$2f''_{xy} \mathrm{d}x \mathrm{d}y$$

describe la interacción entre los cambios en x e y .

Plano tangente

En una variable, al “hacer zoom” alrededor de $x = a$, la gráfica se vuelve casi recta y la *recta tangente*, con pendiente $f'(a)$, constituye la mejor aproximación lineal local.

En dos variables, el análogo es el plano tangente a la superficie $z = f(x, y)$.

Sea $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ diferenciable en (a, b) . El *plano tangente* a la gráfica $z = f(x, y)$ en el punto $(a, b, f(a, b))$ es

$$z = f(a, b) + f'_x(a, b)(x - a) + f'_y(a, b)(y - b)$$

Ejemplo Tomemos $f(x, y) = \ln(x + y) + x^2y$, cuyo dominio está dado por $x + y > 0$. Entonces

$$f'_x = \frac{1}{x + y} + 2xy, \quad f'_y = \frac{1}{x + y} + x^2$$

En $(a, b) = (2, 1)$,

$$f(2, 1) = \ln 3 + 4, \quad f'_x(2, 1) = \frac{1}{3} + 4 = \frac{13}{3}, \quad f'_y(2, 1) = \frac{1}{3} + 4 = \frac{13}{3}$$

Por lo tanto, el plano tangente es

$$z = \ln 3 + 4 + \frac{13}{3}(x - 2) + \frac{13}{3}(y - 1)$$

El plano tangente proporciona una buena aproximación de la superficie original siempre que nos mantengamos en un entorno suficientemente cercano al punto analizado.

8 Aplicación económica de diferencial

Tasa marginal de sustitución (TMS)

Dada una función de utilidad que depende de las cantidades de dos bienes q_1 y q_2 , llamamos *tasa marginal de sustitución (TMS)* a la tasa de compensación entre ellos. Es decir, es la cantidad que se estaría dispuesto a ceder de uno de los bienes para obtener una unidad adicional del otro, manteniendo constante el nivel de utilidad.

Calculamos el diferencial de la función de utilidad $u(q_1, q_2)$:

$$du = \frac{\partial u}{\partial q_1} dq_1 + \frac{\partial u}{\partial q_2} dq_2$$


Como $du = 0$ sobre la curva de indiferencia:

$$\frac{\partial u}{\partial q_1} dq_1 + \frac{\partial u}{\partial q_2} dq_2 = 0 \Rightarrow \frac{dq_2}{dq_1} = -\frac{\frac{\partial u}{\partial q_1}}{\frac{\partial u}{\partial q_2}}$$

Esta pendiente o el módulo de la misma representa lo que se suele llamar tasa marginal de sustitución de bienes:

$$\text{TMS} = \left| \frac{dq_2}{dq_1} \right| = \frac{\frac{\partial u}{\partial q_1}}{\frac{\partial u}{\partial q_2}}$$

Graficamente



Ejemplo

Dada la función de utilidad $u(q_1, q_2) = 5q_1q_2$, calcular la TMS en el punto $(q_1 = 5, q_2 = 2)$.

$$\frac{\partial u}{\partial q_1} = 5q_2 = 5 \cdot 2 = 10$$

$$\frac{\partial u}{\partial q_2} = 5q_1 = 5 \cdot 5 = 25$$

$$\text{TMS} = \frac{10}{25} = 0.4$$

Interpretación: Para aumentar una unidad de q_1 , se deben ceder 0.4 unidades de q_2 para mantener constante el nivel de utilidad

Si se invierte la tasa y se calcula $\frac{dq_1}{dq_2}$, obtenemos:

$$\frac{dq_1}{dq_2} = \frac{\frac{\partial u}{\partial q_2}}{\frac{\partial u}{\partial q_1}} = \frac{25}{10} = 2.5$$

Interpretación: Para aumentar una unidad de q_2 , se deben ceder 2.5 unidades de q_1 para mantener constante el nivel de utilidad

Tasa de sustitución técnica

Dada una función de producción que depende de dos insumos x_1 y x_2 , llamamos *tasa marginal de sustitución técnica (TST)* a la tasa a la que una empresa puede sustituir un factor productivo por otro, manteniendo constante el nivel de producción.

Calculamos el diferencial de la función de producción $q(x_1, x_2)$:

$$dq = \frac{\partial q}{\partial x_1} dx_1 + \frac{\partial q}{\partial x_2} dx_2$$

Como $dq = 0$ sobre la isocuanta:

$$\frac{\partial q}{\partial x_1} dx_1 + \frac{\partial q}{\partial x_2} dx_2 = 0 \Rightarrow \frac{dx_2}{dx_1} = -\frac{\frac{\partial q}{\partial x_1}}{\frac{\partial q}{\partial x_2}}$$

El módulo de esta pendiente representa la tasa marginal de sustitución técnica:

$$\text{TST} = \left| \frac{dx_2}{dx_1} \right| = \frac{\frac{\partial q}{\partial x_1}}{\frac{\partial q}{\partial x_2}}$$

Ejemplo

Dada la función de producción:

$$q(a, b) = 20 - 7a + 8b - a^2 + b^2$$

calcular la TST en el punto $a = 1.2, b = 2.2$.

$$\frac{\partial q}{\partial a} = -7 - 2a = -7 - 2(1.2) = -9.4$$

$$\frac{\partial q}{\partial b} = 8 + 2b = 8 + 2(2.2) = 12.4$$

$$\text{TST} = \frac{-9.4}{12.4} \approx -0.758$$

Interpretación: Para aumentar una unidad de a , se deben ceder aproximadamente 0.758 unidades de b para mantener constante el nivel de producción

Si se invierte la tasa y se calcula $\frac{dx_1}{dx_2}$, obtenemos:

$$\frac{dx_1}{dx_2} = \frac{\frac{\partial q}{\partial b}}{\frac{\partial q}{\partial a}} = \frac{12.4}{-9.4} \approx -1.319$$

Interpretación: Para aumentar una unidad de b , se deben ceder aproximadamente 1.319 unidades de a para mantener constante el nivel de producción

Notación

En muchos textos se utiliza una notación abreviada del tipo $\text{TMS}(x_1/x_2)$ para referirse a las tasas marginales de sustitución.

$\text{TMS}(x_1/x_2)$ representa la tasa marginal de sustitución donde el numerador es la derivada respecto de x_2 y el denominador la derivada respecto de x_1 , es decir:

$$\text{TMS}(x_1/x_2) = \frac{dx_2}{dx_1} = \frac{\frac{\partial u}{\partial x_1}}{\frac{\partial u}{\partial x_2}}$$

Interpretación: indica cuántas unidades de x_2 deben cederse para obtener una unidad adicional de x_1 , manteniendo constante el nivel de utilidad

De manera inversa, $\text{TMS}(x_2/x_1)$ representa la tasa marginal de sustitución donde el numerador es la derivada respecto de x_1 y el denominador la derivada respecto de x_2 , es decir:

$$\text{TMS}(x_2/x_1) = \frac{dx_1}{dx_2} = \frac{\frac{\partial u}{\partial x_2}}{\frac{\partial u}{\partial x_1}}$$

Interpretación: indica cuántas unidades de x_1 deben cederse para obtener una unidad adicional de x_2 , manteniendo constante el nivel de utilidad

Interpretación intuitiva

Cuando aparece una expresión como

$$\frac{dx_2}{dx_1} = \frac{\frac{\partial u}{\partial x_1}}{\frac{\partial u}{\partial x_2}}$$

se interpreta como: “cuánto debe reducirse x_2 para aumentar en una unidad x_1 , manteniendo constante la utilidad”.

Una forma intuitiva de pensarlo es:

- El numerador es lo que aumenta
- El denominador es lo que se entrega o cede

9 Clasificación de bienes y elasticidad

Conceptos clave

- **Funciones de demanda:** Representan la relación entre la cantidad demandada de un bien y variables como su precio propio, el precio de bienes relacionados y el ingreso del consumidor
- **Derivadas parciales:** Permiten analizar el efecto marginal de un cambio en una variable (precio o ingreso) sobre la cantidad demandada, manteniendo constantes las demás
- **Elasticidad:** Es la medida de sensibilidad de la cantidad demandada ante cambios porcentuales en el precio o ingreso, ayudando a clasificar el bien según su comportamiento

Clasificación de bienes

1. Según el precio propio

- **Bienes típicos:** Al aumentar el precio del bien, la cantidad demandada disminuye. La mayoría de bienes se comporta así:

$$\frac{\partial Q}{\partial P} < 0$$

- **Bienes Giffen:** En situaciones excepcionales, el aumento en el precio del bien provoca un aumento en su demanda, debido al efecto ingreso que supera al efecto sustitución. No confundir con los bienes Veblen, que son bienes de lujo demandados por sus características de señalar estatus económico

$$\frac{\partial Q}{\partial P} > 0$$

Intuición: En condiciones normales, la relación inversa (mayor precio, menor demanda) es esperada; los bienes Giffen representan casos raros donde, por limitaciones presupuestarias, el aumento de precio lleva a consumir más del bien

2. Según el precio del otro bien

- **Bienes sustitutos:** Si al aumentar el precio de un bien la demanda del otro aumenta, se considera que los bienes son sustitutos. Esto ocurre cuando el consumidor opta por el bien relativamente más económico. Por ejemplo, marcas rivales: Coca Cola y Pepsi

$$\frac{\partial Q_1}{\partial P_2} > 0$$

- **Bienes complementarios:** Si el aumento en el precio de un bien reduce la demanda del otro, se clasifican como complementarios, ya que se consumen en conjunto. Por ejemplo, café y azúcar

$$\frac{\partial Q_1}{\partial P_2} < 0$$

Intuición: La existencia de bienes sustitutos permite al consumidor cambiar de producto al encarecerse uno, mientras que los bienes complementarios se consumen conjuntamente para satisfacer una necesidad

3. Según el ingreso

- **Bienes normales:** La demanda aumenta al incrementar el ingreso del consumidor, la mayoría de bienes tienden a ser normales

$$\frac{\partial Q}{\partial I} > 0$$

- **Bienes inferiores:** La demanda disminuye cuando aumenta el ingreso, ya que los consumidores optan por bienes de mayor calidad. Por ejemplo, marcas de segunda línea

$$\frac{\partial Q}{\partial I} < 0$$

Intuición: La clasificación según el ingreso refleja la capacidad del consumidor para ajustar sus hábitos de consumo en función de su poder adquisitivo

Elasticidad de la demanda

La elasticidad cuantifica la sensibilidad de la cantidad demandada ante cambios en precios o ingresos

Elasticidad precio e ingreso

$$\text{Elasticidad precio} = \frac{\Delta Q/Q}{\Delta P/P} = \frac{P}{Q} \frac{\partial Q}{\partial P}$$

- **Interpretación (en términos absolutos):**

– Si

$$\left| \frac{P}{Q} \frac{\partial Q}{\partial P} \right| > 1$$

la demanda es **elástica** (sensible a cambios en el precio)

– Si

$$\left| \frac{P}{Q} \frac{\partial Q}{\partial P} \right| < 1$$

la demanda es **inelástica** (poco sensible)

– Si

$$\left| \frac{P}{Q} \frac{\partial Q}{\partial P} \right| = 1$$

la elasticidad es **unitaria** (la demanda se mueve exactamente en la misma proporción que el precio)

– Si

$$\frac{\partial Q}{\partial P} = 0 \quad (\text{lo que implica que } \left| \frac{P}{Q} \frac{\partial Q}{\partial P} \right| = 0)$$

la demanda es **perfectamente inelástica** (la cantidad demandada permanece constante sin importar cambios en el precio)

- Aunque se presenta el concepto como **elasticidad precio**, esta noción se extiende a la **elasticidad ingreso** y a cualquier otra función que admita derivadas parciales. Por ejemplo, la elasticidad ingreso se define como:

$$\text{Elasticidad ingreso} = \frac{\Delta Q/Q}{\Delta I/I} = \frac{I}{Q} \frac{\partial Q}{\partial I}$$

donde I representa el ingreso

Bienes de lujo vs. bienes esenciales

La clasificación de bienes en términos de lujo o esencial se basa en la **elasticidad ingreso**, la cual mide la sensibilidad de la cantidad demandada ante cambios en el ingreso del consumidor. Es importante resaltar que esta clasificación se aplica únicamente a bienes **normales**

Bienes esenciales (necesidades básicas)

Para los bienes esenciales, la elasticidad ingreso se encuentra en el rango:

$$0 < E_I < 1$$

donde

$$E_I = \frac{I}{Q} \frac{\partial Q}{\partial I}$$

Esto significa que, ante un aumento porcentual en el ingreso, la cantidad demandada del bien aumenta en una proporción menor. Dichos bienes satisfacen necesidades básicas y su consumo tiende a estabilizarse incluso cuando el ingreso crece

Bienes de lujo

En cambio, los bienes de lujo se caracterizan por tener:

$$E_I > 1$$

Esto implica que un incremento porcentual en el ingreso genera un aumento porcentual mayor en la demanda del bien. Estos bienes son adquiridos en mayor medida cuando los consumidores disponen de mayores recursos, reflejando un comportamiento de consumo más discrecional

Ejemplos:

- **Bienes esenciales:** Alimentos básicos (por ejemplo, pan y arroz), medicamentos genéricos, vivienda
- **Bienes de lujo:** Ropa de diseñador, automóviles de alta gama, joyería fina

Ejemplo

Supongamos que la función de demanda de un bien se expresa como:

$$Q(P, I) = 200 + 0.3I - 4P$$

donde P es el precio del bien e I es el ingreso del consumidor

Cálculo de las derivadas parciales:

$$\frac{\partial Q}{\partial P} = -4, \quad \frac{\partial Q}{\partial I} = 0.3$$

El signo negativo en $\frac{\partial Q}{\partial P}$ indica que, al aumentar el precio, la cantidad demandada disminuye (bien típico). El signo positivo en $\frac{\partial Q}{\partial I}$ muestra que, al aumentar el ingreso, la demanda crece, lo que caracteriza al bien como normal

Evaluación en un punto específico:

Sea $P = 15$ e $I = 500$. Entonces:

$$Q(15, 500) = 200 + 0.3 \times 500 - 4 \times 15 = 200 + 150 - 60 = 290$$

Cálculo de la elasticidad precio:

La elasticidad precio se define como:

$$E_P = \frac{P}{Q} \frac{\partial Q}{\partial P}$$

Sustituyendo los valores:

$$E_P = \frac{15}{290} \times (-4) \approx -0.207$$

En valor absoluto, $|E_P| \approx 0.207$, lo que indica que la demanda es **inelástica** (poco sensible a cambios en el precio)

Cálculo de la elasticidad ingreso:

$$E_I = \frac{I}{Q} \frac{\partial Q}{\partial I}$$

Sustituyendo los valores:

$$E_I = \frac{500}{290} \times 0.3 \approx 0.517$$

Esto significa que, ante un aumento del 1% en el ingreso, la cantidad demandada incrementa aproximadamente en un 0.517%, también es inelástica respecto al ingreso

Interpretación respecto a bienes de lujo vs. esenciales:

Dado que $0 < E_I < 1$, el bien se clasifica como un **bien esencial** (o necesidad básica), ya que la respuesta de la demanda a cambios en el ingreso es relativamente baja

Nota sobre bienes Giffen

Como vimos anteriormente, los bienes Giffen son aquellos bienes para los cuales, cuando el precio aumenta, la demanda también aumenta

$$\frac{\partial Q}{\partial P} > 0$$

Los bienes Giffen aparecen en situaciones muy particulares. Se trata de bienes inferiores que suelen ocupar una parte importante del presupuesto de consumidores con ingresos bajos. Cuando el precio de ese bien básico aumenta, el consumidor pierde poder adquisitivo y, en algunos casos extremos, termina consumiendo aún más de ese mismo bien porque no puede reemplazarlo fácilmente por otros.

Un ejemplo clásico que suele utilizarse para ilustrar este fenómeno es el caso de la papa en Irlanda. La idea general es la siguiente: para muchos hogares pobres, la papa constituía una parte muy importante de la dieta porque era un alimento relativamente accesible y que aportaba una gran cantidad de calorías. Si el precio de ese bien básico aumentaba, esos hogares sufrían una caída fuerte de su poder adquisitivo real. En ese contexto, en lugar de poder reemplazar la papa por alimentos mejores o más variados, se veían obligados a reducir todavía más el consumo de otros bienes y a destinar una proporción aún mayor de su presupuesto a la compra de papas. Esto se debe a que los otros alimentos disponibles resultaban relativamente más caros en relación con las calorías que aportaban. En otras palabras, **el aumento del precio no generaba una sustitución hacia otros bienes, sino una mayor dependencia del bien básico encarecido**

Este ejemplo debe interpretarse con cuidado. No se trata de que el consumidor desee más el bien porque ahora sea más caro, sino de que, al empeorar su restricción presupuestaria, queda prácticamente forzado a concentrar más su consumo en ese bien de subsistencia. Por eso, el caso de los bienes Giffen requiere condiciones muy especiales: **el bien debe ser inferior, debe representar una fracción importante del gasto del consumidor y, además, deben existir pocas alternativas de reemplazo cercanas**

Por esta razón, los bienes Giffen son **casos muy limitados y poco frecuentes en la práctica**. Su importancia es sobre todo teórica, porque muestran que la relación entre precio y cantidad demandada no siempre tiene que ser negativa

No confundir con los bienes Veblen: un bien Giffen no es lo mismo que un bien Veblen. En ambos casos puede ocurrir que la demanda aumente cuando sube el precio, pero la razón económica es completamente distinta. En un **bien Giffen**, el aumento de la demanda se explica por una situación de restricción presupuestaria severa: el consumidor compra más del bien porque no puede desplazarse hacia alternativas mejores y necesita seguir cubriendo una necesidad básica. En cambio, en un **bien Veblen**, el aumento de la demanda se relaciona con el carácter de lujo, prestigio o señalización social del bien. Allí el precio alto vuelve al bien más atractivo precisamente porque comunica estatus, exclusividad o poder adquisitivo. De hecho, en un bien Veblen puede pensarse que el precio alto forma parte de la naturaleza misma del bien: si el precio dejara de ser el que es, el bien cambiaría también en su valor simbólico

10 Derivadas compuestas

En matemática aplicada a la economía es muy común que una variable dependa de otra *a través* de funciones intermedias. Por ejemplo, la cantidad demandada Q depende del precio P vía $Q = D(P)$, y el precio a su vez depende de un impuesto ad-valorem τ vía $P = P_0(1 + \tau)$. Esta *composición* se modela como

$$y = g(h(x))$$

donde g y h son funciones diferenciables. Una pregunta que puede surgir es ¿Cómo afecta el cambio en el impuesto a la demanda? La respuesta de esta pregunta se puede encontrar a través de la derivada de una función compuesta.

En una variable

Recordemos que si $y = f(x)$ y x cambia de a a $a + \Delta x$, definimos el incremento de y como

$$\Delta y = f(a + \Delta x) - f(a)$$

De acuerdo con la definición de derivada,

$$\lim_{\Delta x \rightarrow 0} \frac{\Delta y}{\Delta x} = f'(a)$$

Si denotamos por ε la diferencia entre el cociente incremental y la derivada, obtenemos

$$\lim_{\Delta x \rightarrow 0} \varepsilon = \lim_{\Delta x \rightarrow 0} \left(\frac{\Delta y}{\Delta x} - f'(a) \right) = f'(a) - f'(a) = 0$$

Pero

$$\varepsilon = \frac{\Delta y}{\Delta x} - f'(a) \implies \Delta y = f'(a) \Delta x + \varepsilon \Delta x$$

Definimos $\varepsilon = 0$ cuando $\Delta x = 0$.

Así, para una función f diferenciable, podemos escribir

$$\Delta y = f'(a) \Delta x + \varepsilon \Delta x, \quad \varepsilon \rightarrow 0 \text{ cuando } \Delta x \rightarrow 0 \quad (5)$$

y ε es función continua de Δx . Esta propiedad habilita la prueba de la regla de la cadena.

Prueba de la regla de la cadena

Supongamos $u = g(x)$ diferenciable en a y $y = f(u)$ diferenciable en $b = g(a)$. Si Δx es un incremento en x y $\Delta u, \Delta y$ los incrementos correspondientes en u e y , entonces, aplicando (5) a g en a ,

$$\Delta u = g'(a) \Delta x + \varepsilon_1 \Delta x = [g'(a) + \varepsilon_1] \Delta x, \quad \varepsilon_1 \rightarrow 0 \text{ cuando } \Delta x \rightarrow 0 \quad (6)$$

De modo análogo, aplicando (5) a f en b ,

$$\Delta y = f'(b) \Delta u + \varepsilon_2 \Delta u = [f'(b) + \varepsilon_2] \Delta u \quad \varepsilon_2 \rightarrow 0 \text{ cuando } \Delta u \rightarrow 0 \quad (7)$$

Sustituyendo Δu de (6) en (7), obtenemos

$$\Delta y = [f'(b) + \varepsilon_2] [g'(a) + \varepsilon_1] \Delta x, \quad \text{por lo tanto} \quad \frac{\Delta y}{\Delta x} = [f'(b) + \varepsilon_2] [g'(a) + \varepsilon_1]$$

Cuando $\Delta x \rightarrow 0$, la ecuación (6) muestra que $\Delta u \rightarrow 0$; así, $\varepsilon_1 \rightarrow 0$ y $\varepsilon_2 \rightarrow 0$. Luego

$$\frac{dy}{dx} = \lim_{\Delta x \rightarrow 0} \frac{\Delta y}{\Delta x} = \lim_{\Delta x \rightarrow 0} [f'(b) + \varepsilon_2] [g'(a) + \varepsilon_1] = f'(b) g'(a) = f'(g(a)) g'(a)$$

Ejemplo

Función: $y(x) = (1 + 2x)^5$.

Identificación de la composición:

$$g(u) = u^5, \quad h(x) = 1 + 2x, \quad y(x) = g(h(x))$$

Derivadas de cada capa:

$$g'(u) = 5u^4, \quad h'(x) = 2$$

Aplicación de la regla de la cadena:

$$y'(x) = g'(h(x)) \cdot h'(x) = 5(1 + 2x)^4 \cdot 2 = 10(1 + 2x)^4$$

Regla de la cadena (caso multivariable)

Un cambio Δt produce cambios $\Delta x = g(t_0 + \Delta t) - g(t_0)$ y $\Delta y = h(t_0 + \Delta t) - h(t_0)$. Por diferenciabilidad de f en (x_0, y_0) ,

$$\Delta z = f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0) = \frac{\partial f}{\partial x}(x_0, y_0) \Delta x + \frac{\partial f}{\partial y}(x_0, y_0) \Delta y + \varepsilon_1(\Delta x, \Delta y) \Delta x + \varepsilon_2(\Delta x, \Delta y) \Delta y,$$

donde $\varepsilon_1(\Delta x, \Delta y) \rightarrow 0$ y $\varepsilon_2(\Delta x, \Delta y) \rightarrow 0$ cuando $(\Delta x, \Delta y) \rightarrow (0, 0)$ (si $(\Delta x, \Delta y) = (0, 0)$, definimos $\varepsilon_1 = \varepsilon_2 = 0$).

Dividiendo por Δt ,

$$\frac{\Delta z}{\Delta t} = \frac{\partial f}{\partial x}(x_0, y_0) \frac{\Delta x}{\Delta t} + \frac{\partial f}{\partial y}(x_0, y_0) \frac{\Delta y}{\Delta t} + \varepsilon_1(\Delta x, \Delta y) \frac{\Delta x}{\Delta t} + \varepsilon_2(\Delta x, \Delta y) \frac{\Delta y}{\Delta t}.$$

Como g, h son derivables en t_0 , se tiene $\Delta x/\Delta t \rightarrow g'(t_0)$ y $\Delta y/\Delta t \rightarrow h'(t_0)$; además $\Delta t \rightarrow 0 \Rightarrow (\Delta x, \Delta y) \rightarrow (0, 0)$, luego $\varepsilon_1, \varepsilon_2 \rightarrow 0$. Por lo tanto,

$$\begin{aligned} \left. \frac{dz}{dt} \right|_{t_0} &= \lim_{\Delta t \rightarrow 0} \frac{\Delta z}{\Delta t} \\ &= \frac{\partial f}{\partial x}(x_0, y_0) \lim_{\Delta t \rightarrow 0} \frac{\Delta x}{\Delta t} + \frac{\partial f}{\partial y}(x_0, y_0) \lim_{\Delta t \rightarrow 0} \frac{\Delta y}{\Delta t} + \underbrace{\lim_{\Delta t \rightarrow 0} \varepsilon_1(\Delta x, \Delta y)}_0 \underbrace{\lim_{\Delta t \rightarrow 0} \frac{\Delta x}{\Delta t}}_{g'(t_0)} + \underbrace{\lim_{\Delta t \rightarrow 0} \varepsilon_2(\Delta x, \Delta y)}_0 \underbrace{\lim_{\Delta t \rightarrow 0} \frac{\Delta y}{\Delta t}}_{h'(t_0)} \\ &= \frac{\partial f}{\partial x}(x_0, y_0) g'(t_0) + \frac{\partial f}{\partial y}(x_0, y_0) h'(t_0). \end{aligned}$$

Forma compacta. Usando $\partial z/\partial x = \partial f/\partial x$ y $\partial z/\partial y = \partial f/\partial y$, la regla queda

$$\frac{dz}{dt} = \frac{\partial z}{\partial x} \frac{dx}{dt} + \frac{\partial z}{\partial y} \frac{dy}{dt}$$

Un ejemplo más complejo

Supongamos funciones diferenciables

$$z = f(x, y), \quad x = x(u, v), \quad y = y(u, v)$$

Ahora podemos encontrar dos derivadas z'_u y z'_v , las cuales se calculan con la misma regla que antes

$$z'_u = f_x x_u + f_y y_u, \quad z'_v = f_x x_v + f_y y_v$$

Cuando hay más dependencias de variables

En muchos problemas hay más dependencias entre variables. El esquema general es:

$$z = g(u_1, \dots, u_m), \quad u_i = u_i(x_1, \dots, x_n)$$

Aquí g es diferenciable en $\mathbb{R}^m$ y cada u_i es diferenciable en $\mathbb{R}^n$.

Para cada variable básica x_j ($j = 1, \dots, n$):

$$\frac{\partial z}{\partial x_j} = \sum_{i=1}^m \frac{\partial g}{\partial u_i} \frac{\partial u_i}{\partial x_j}$$

Dependencias encadenadas

Cuando hay varias capas, se *suman* los productos de derivadas a lo largo de cada camino.

$$y = y(u, v), \quad u = u(p, q), \quad v = v(q, s), \quad p = p(t), \quad q = q(t), \quad s = s(t)$$

Entonces

$$\frac{dy}{dt} = y_u(u_p p' + u_q q') + y_v(v_q q' + v_s s')$$

Ejemplos

$$z = f(x, y) = x^2 y, \quad x = g(t) = t^2, \quad y = h(t) = e^t$$

Derivadas

$$f_x = 2xy, \quad f_y = x^2, \quad \frac{dx}{dt} = 2t, \quad \frac{dy}{dt} = e^t$$

$$\frac{dz}{dt} = \frac{\partial f}{\partial x} \frac{dx}{dt} + \frac{\partial f}{\partial y} \frac{dy}{dt} = (2xy)(2t) + (x^2)(e^t)$$

Sustituyendo $x = t^2$ y $y = e^t$:

$$\frac{dz}{dt} = 2(t^2)(e^t)(2t) + (t^2)^2 e^t = 4t^3 e^t + t^4 e^t = e^t (4t^3 + t^4)$$

Comprobación directa. Como $z(t) = x(t)^2 y(t) = (t^2)^2 e^t = t^4 e^t$

$$\frac{d}{dt}(t^4 e^t) = 4t^3 e^t + t^4 e^t = e^t (4t^3 + t^4)$$

que coincide con el resultado obtenido por la regla de la cadena.

Otro caso

$$z = f(x, y) = x y^2, \quad x = x(v, w) = v + w, \quad y = y(v, w) = v - w$$

Derivadas parciales y derivadas de las dependencias:

$$f_x = y^2, \quad f_y = 2xy, \quad x_v = 1, \quad x_w = 1, \quad y_v = 1, \quad y_w = -1$$

Regla de la cadena:

$$z_v = f_x x_v + f_y y_v, \quad z_w = f_x x_w + f_y y_w$$

Cálculo:

$$z_v = y^2 \cdot 1 + (2xy) \cdot 1 = y^2 + 2xy, \quad z_w = y^2 \cdot 1 + (2xy) \cdot (-1) = y^2 - 2xy$$

Sustituyendo $x = v + w$, $y = v - w$:

$$z_v = (v - w)^2 + 2(v + w)(v - w) = (v - w)[(v - w) + 2(v + w)] = (v - w)(3v + w)$$

$$z_w = (v - w)^2 - 2(v + w)(v - w) = (v - w)[(v - w) - 2(v + w)] = (v - w)(-v - 3w)$$

Comprobación directa. Como $z(v, w) = x y^2 = (v + w)(v - w)^2$

$$\frac{\partial z}{\partial v} = (v - w)^2 + 2(v + w)(v - w) = (v - w)(3v + w)$$


$$\frac{\partial z}{\partial w} = (v - w)^2 - 2(v + w)(v - w) = (v - w)(-v - 3w)$$

coincidiendo con la regla de la cadena.

Otro ejemplo aún más complejo

$$z = z(u, v) = u^2 v, \quad u = u(p, q) = p + q, \quad v = v(q, s) = q s, \quad p = 2t, \quad q = t^2, \quad s = e^t$$

En esta situación conviene graficar la relación entre variables para que quede claro:



Derivadas parciales y derivadas de las dependencias

$$z_u = 2uv, \quad z_v = u^2$$

$$u_p = 1, \quad u_q = 1, \quad v_q = s, \quad v_s = q$$

$$p' = 2, \quad q' = 2t, \quad s' = e^t$$

Regla de la cadena

$$\frac{dz}{dt} = z_u(u_p p' + u_q q') + z_v(v_q q' + v_s s')$$

Cálculo

$$\frac{dz}{dt} = (2uv)(1 \cdot 2 + 1 \cdot 2t) + (u^2)(s \cdot 2t + q \cdot e^t)$$

$$= 2uv(2 + 2t) + u^2(2ts + qe^t)$$

Sustituyendo $u = p + q = 2t + t^2$, $v = qs = t^2e^t$, $s = e^t$ y $q = t^2$

$$\frac{dz}{dt} = 2(2t + t^2)(t^2e^t)(2 + 2t) + (2t + t^2)^2(2te^t + t^2e^t)$$

$$= 2(2t + t^2)(t^2e^t)(2 + 2t) + (2t + t^2)^2e^t(2t + t^2)$$

$$= 4t^3e^t(2 + t)(1 + t) + t^3e^t(2 + t)^3$$

$$= t^3e^t(2 + t)(4(1 + t) + (2 + t)^2)$$

$$\frac{dz}{dt} = e^t t^3(2 + t)(t^2 + 8t + 8)$$

Comprobación directa

Como

$$z(t) = u(t)^2v(t) = (2t + t^2)^2(t^2e^t) = t^4(2 + t)^2e^t$$

al derivar directamente

$$\frac{d}{dt}\left(t^4(2 + t)^2e^t\right) = e^t t^3(2 + t)(t^2 + 8t + 8)$$

que coincide con el resultado obtenido por la regla de la cadena

11 Derivadas implícitas

Derivación implícita: deducción de la fórmula y requerimientos

En muchos casos en matemáticas y economía, las relaciones entre variables se presentan de forma implícita, es decir, mediante una ecuación de la forma

$$F(x, y) = 0$$

donde y se define como función de x de forma implícita (i.e., $y = f(x)$). Para poder aplicar la derivación implícita, es fundamental cumplir con ciertos requerimientos y condiciones.

Requerimientos para la aplicación de la derivación implícita

1. **Verificación de la solución:** se asume que el punto de interés (x_0, y_0) satisface la ecuación, es decir, $F(x_0, y_0) = 0$ (esto implica que $y_0 = f(x_0)$)
2. **Diferenciabilidad de $F(x, y)$:** la función F debe ser diferenciable en un entorno del punto de interés (x_0, y_0) . Esto garantiza que existen las derivadas parciales F_x y F_y
3. **No nulidad de la derivada parcial respecto a y :** se requiere que $F_y(x_0, y_0) \neq 0$. Esta condición es esencial para aplicar el Teorema de la Función Implícita, el cual asegura que en un entorno de (x_0, y_0) se puede expresar y como una función diferenciable de x (i.e., $y = f(x)$)

Deducción de la fórmula de la derivada implícita

Consideremos la ecuación

$$F(x, y) = 0$$

donde suponemos que $y = f(x)$ y F es diferenciable en un entorno de (x_0, y_0) . Como $F(x, f(x)) = 0$ para todos los x en dicho entorno, derivamos ambos lados de la igualdad con respecto a x , aplicando la regla de la cadena:

$$\frac{d}{dx} F(x, f(x)) = F_x(x, f(x)) + F_y(x, f(x)) \cdot f'(x) = 0$$

Aquí, F_x y F_y representan las derivadas parciales de F con respecto a x y y , respectivamente. Despejamos $f'(x)$ de la siguiente forma:

$$\begin{aligned} F_y(x, f(x)) \cdot f'(x) &= -F_x(x, f(x)) \\ \implies f'(x) &= -\frac{F_x(x, f(x))}{F_y(x, f(x))} \end{aligned}$$

Esta es la fórmula general para la derivada de una función definida de forma implícita.

Ejemplo

Consideremos la ecuación de la circunferencia:

$$x^2 + y^2 = 25$$

Definimos la función $F(x, y)$ como:

$$F(x, y) = x^2 + y^2 - 25 = 0$$

Observamos que para cualquier punto (x, y) sobre la circunferencia se cumple $F(x, y) = 0$

Paso 1: calcular las derivadas parciales Se tiene:

$$F_x(x, y) = 2x \quad y \quad F_y(x, y) = 2y$$

Paso 2: aplicar la fórmula de la derivada implícita Utilizando la fórmula:

$$\begin{aligned} \frac{dy}{dx} &= -\frac{F_x(x, y)}{F_y(x, y)} = -\frac{2x}{2y} \\ \implies \frac{dy}{dx} &= -\frac{x}{y} \end{aligned}$$

Derivación implícita: función de dos variables independientes

En algunos problemas en matemáticas y economía, las relaciones entre variables se presentan de forma implícita mediante una ecuación de la forma

$$F(x, y, z) = 0$$

donde z se define implícitamente como función de x e y (i.e., $z = f(x, y)$). Para aplicar la derivación implícita en este contexto, es fundamental cumplir con ciertos requerimientos y condiciones.

Requerimientos para la aplicación de la derivación implícita

1. **Verificación de la solución:** se asume que el punto de interés $Q_0 = (x_0, y_0, z_0)$ satisface la ecuación, es decir, $F(x_0, y_0, z_0) = 0$ (lo que implica que $z_0 = f(x_0, y_0)$)
2. **Diferenciabilidad de $F(x, y, z)$:** la función F y sus derivadas parciales F_x , F_y y F_z deben existir y ser continuas en un entorno del punto Q_0
3. **No nulidad de la derivada parcial respecto a z :** se requiere que $F_z(x_0, y_0, z_0) \neq 0$. Esta condición es esencial para poder expresar z como una función diferenciable de x e y en el entorno de Q_0

Deducción de las fórmulas de las derivadas parciales

Consideremos la ecuación

$$F(x, y, z) = 0$$

donde suponemos que $z = f(x, y)$ y F es diferenciable en un entorno del punto $Q_0 = (x_0, y_0, z_0)$. Como $F(x, y, f(x, y)) = 0$ para todos los (x, y) en dicho entorno, derivamos ambos lados de la igualdad con respecto a x e y , aplicando la regla de la cadena.

Aplicación de la regla de la cadena

Para clarificar la deducción, se puede reescribir la función $F(x, y, z)$ definiendo $u = x$, $v = y$ y $z = f(x, y)$, de forma que

$$w = F(u, v, z) = 0$$

Aplicando la regla de la cadena respecto a x :

$$\frac{\partial w}{\partial x} = \frac{\partial F}{\partial u} \cdot \frac{\partial u}{\partial x} + \frac{\partial F}{\partial v} \cdot \frac{\partial v}{\partial x} + \frac{\partial F}{\partial z} \cdot \frac{\partial z}{\partial x} = 0$$

Como $\frac{\partial u}{\partial x} = 1$ y $\frac{\partial v}{\partial x} = 0$, se obtiene:

$$\frac{\partial F}{\partial x} + \frac{\partial F}{\partial z} \cdot \frac{\partial z}{\partial x} = 0 \implies \frac{\partial z}{\partial x} = -\frac{F_x}{F_z}$$

El mismo procedimiento se aplica para obtener $\frac{\partial z}{\partial y}$

Estas fórmulas permiten calcular las derivadas parciales de $z = f(x, y)$ de forma implícita, siempre y cuando se cumplan los requerimientos indicados.

Ejemplo

Consideremos la función:

$$F(x, y, z) = x^2y + \sin(z) - z \cos(y) + z^2 - 1 = 0$$

Observamos que para cualquier punto (x, y, z) que satisface esta ecuación se define implícitamente z como función de x e y (i.e., $z = f(x, y)$)

Paso 1: calcular las derivadas parciales Se tiene:

$$F_x(x, y, z) = 2xy$$

$$F_y(x, y, z) = x^2 + z \sin(y)$$

$$F_z(x, y, z) = \cos(z) - \cos(y) + 2z$$

Paso 2: aplicar la fórmula de la derivada implícita Las fórmulas para las derivadas parciales de $z = f(x, y)$ son:

$$\frac{\partial z}{\partial x} = -\frac{F_x(x, y, z)}{F_z(x, y, z)} \quad \text{y} \quad \frac{\partial z}{\partial y} = -\frac{F_y(x, y, z)}{F_z(x, y, z)}$$

Paso 3: evaluar en un punto Elijamos el punto $Q_0 = (1, 1, 0)$. Verificamos que:

$$1^2 \cdot 1 + \sin(0) - 0 \cdot \cos(1) + 0^2 - 1 = 1 - 1 = 0$$

por lo que Q_0 pertenece a la superficie definida por $F(x, y, z) = 0$

Evaluamos las derivadas parciales en Q_0 :

$$F_x(1, 1, 0) = 2 \cdot 1 \cdot 1 = 2$$

$$F_y(1, 1, 0) = 1^2 + 0 \cdot \sin(1) = 1$$

$$F_z(1, 1, 0) = \cos(0) - \cos(1) + 2 \cdot 0 = 1 - \cos(1) \approx 0.46$$

Por lo tanto:

$$\left. \frac{\partial z}{\partial x} \right|_{(1,1,0)} = -\frac{2}{1 - \cos(1)} \approx -4.35$$

$$\left. \frac{\partial z}{\partial y} \right|_{(1,1,0)} = -\frac{1}{1 - \cos(1)} \approx -2.17$$

Derivadas implícitas sucesivas

Consideremos la función implícita:

$$F(x, y, z) = 2 \sin(z) - xz + y^3 - 1 = 0$$

que define a $z = z(x, y)$. Se desea calcular las derivadas de segundo orden:

$$z_{xx}, \quad z_{xy}, \quad z_{yx}, \quad z_{yy}$$

evaluadas en el punto $Q_0 = (1, 1, 0)$

Paso 1: derivadas de primer orden

Dado que $F(x, y, z(x, y)) = 0$, diferenciamos implícitamente respecto de x :

$$F_x + F_z \cdot z_x = 0 \quad \Rightarrow \quad z_x = -\frac{F_x}{F_z}$$

Análogamente, derivando respecto de y :

$$F_y + F_z \cdot z_y = 0 \quad \Rightarrow \quad z_y = -\frac{F_y}{F_z}$$

Calculamos ahora las derivadas parciales necesarias:

$$F_x = \frac{\partial F}{\partial x} = -z, \quad F_y = \frac{\partial F}{\partial y} = 3y^2, \quad F_z = \frac{\partial F}{\partial z} = 2 \cos(z) - x$$

Entonces:

$$z_x = \frac{z}{2 \cos(z) - x}, \quad z_y = -\frac{3y^2}{2 \cos(z) - x}$$

A partir de estas expresiones, aplicamos la regla del cociente para obtener las segundas derivadas sin evaluar numéricamente hasta el final.

Cálculo de z_{xx}

Derivamos $z_x = \frac{z}{2 \cos(z) - x}$ respecto a x :

$$z_{xx} = \frac{d}{dx} \left(\frac{z}{2 \cos(z) - x} \right) = \frac{\frac{dz}{dx} (2 \cos(z) - x) - z \frac{d(2 \cos(z) - x)}{dx}}{(2 \cos(z) - x)^2}$$

$$\frac{d(2 \cos(z) - x)}{dx} = -2 \sin(z) \frac{dz}{dx} - 1 = -2 \sin(z) z_x - 1$$

Sustituyendo:

$$z_{xx} = \frac{(z_x)(2 \cos(z) - x) - z(-2 \sin(z) z_x - 1)}{(2 \cos(z) - x)^2}$$

$$z_{xx} = \frac{z_x(2 \cos(z) - x) + z(2 \sin(z) z_x + 1)}{(2 \cos(z) - x)^2}$$

Evaluando en $Q_0 = (1, 1, 0)$ (con $z = 0, z_x = 0, \sin(0) = 0, \cos(0) = 1, x = 1$):

$$z_{xx}(1, 1) = \frac{(0)(2(1) - 1) + 0(2(0)(0) + 1)}{(2(1) - 1)^2} = \frac{0 + 0}{1^2} = 0$$

Cálculo de z_{xy}

Derivamos $z_x = \frac{z}{2 \cos(z) - x}$ respecto a y :

$$z_{xy} = \frac{d}{dy} \left(\frac{z}{2 \cos(z) - x} \right) = \frac{\frac{dz}{dy}(2 \cos(z) - x) - z \frac{d(2 \cos(z) - x)}{dy}}{(2 \cos(z) - x)^2}$$

Calculamos las derivadas necesarias para el numerador:

$$\frac{d(2 \cos(z) - x)}{dy} = -2 \sin(z) \frac{dz}{dy} - 0 = -2 \sin(z) z_y$$

Sustituyendo:

$$z_{xy} = \frac{(z_y)(2 \cos(z) - x) - z(-2 \sin(z) z_y)}{(2 \cos(z) - x)^2}$$

$$z_{xy} = \frac{z_y(2 \cos(z) - x) + 2z \sin(z) z_y}{(2 \cos(z) - x)^2}$$

Evaluando en $Q_0 = (1, 1, 0)$ (con $z = 0, z_y = -3, \sin(0) = 0, \cos(0) = 1, x = 1$):

$$z_{xy}(1, 1) = \frac{(-3)(2(1) - 1) + 2(0)(0)(-3)}{(2(1) - 1)^2} = \frac{(-3)(1) + 0}{1^2} = -3$$

Por simetría de las derivadas cruzadas (asumiendo que se cumple el teorema de Schwarz):

$$z_{yx} = z_{xy}$$

Cálculo de z_{yy}

Derivamos $z_y = -\frac{3y^2}{2 \cos(z) - x}$ respecto a y :

$$z_{yy} = \frac{d}{dy} \left(-\frac{3y^2}{2 \cos(z) - x} \right) = -\frac{\frac{d(3y^2)}{dy}(2 \cos(z) - x) - (3y^2) \frac{d(2 \cos(z) - x)}{dy}}{(2 \cos(z) - x)^2}$$

Calculamos las derivadas necesarias para el numerador:

$$\frac{d(3y^2)}{dy} = 6y$$

$$\frac{d(2 \cos(z) - x)}{dy} = -2 \sin(z) z_y \quad (\text{calculado antes})$$

Sustituyendo:

$$z_{yy} = -\frac{(6y)(2 \cos(z) - x) - (3y^2)(-2 \sin(z) z_y)}{(2 \cos(z) - x)^2}$$

$$z_{yy} = -\frac{6y(2 \cos(z) - x) + 6y^2 \sin(z) z_y}{(2 \cos(z) - x)^2}$$

Evaluando en $Q_0 = (1, 1, 0)$ (con $y = 1, z = 0, z_y = -3, \sin(0) = 0, \cos(0) = 1, x = 1$):

$$z_{yy}(1, 1) = -\frac{6(1)(2(1) - 1) + 6(1)^2(0)(-3)}{(2(1) - 1)^2} = -\frac{6(1) + 0}{1^2} = -6$$

12 Derivadas implícitas en sistemas de ecuaciones

Derivación Implícita en Sistemas de Ecuaciones con una variable independiente

Así como una superficie puede estar definida en forma implícita por una ecuación, una curva en el espacio puede estar definida implícitamente por un sistema de dos ecuaciones

$$\begin{cases} F(x, y, z) = 0 \\ G(x, y, z) = 0 \end{cases}$$

Por ejemplo, puede ocurrir que el sistema defina implícitamente a $y = f(x)$ y $z = g(x)$ es decir, que ambas dependan de una única variable independiente. En ese caso, se dice que el sistema define a dos de las tres variables como funciones de la restante

Requerimientos para Aplicar la Derivación Implícita

Para que sea posible derivar y y z respecto a x se deben cumplir las siguientes condiciones

1. **Verificación de la solución:** El punto de interés (x_0, y_0, z_0) debe satisfacer ambas ecuaciones es decir

$$F(x_0, y_0, z_0) = 0 \quad \text{y} \quad G(x_0, y_0, z_0) = 0$$

2. **Diferenciabilidad de F y G :** Ambas funciones deben ser diferenciables en un entorno del punto, con derivadas parciales continuas
3. **No anulación del Jacobiano respecto a y y z :** El determinante

$$J = \frac{\partial(F, G)}{\partial(y, z)} = \begin{vmatrix} F_y & F_z \\ G_y & G_z \end{vmatrix} \neq 0$$

debe ser distinto de cero para que el sistema tenga solución única para $\frac{dy}{dx}$ y $\frac{dz}{dx}$

Deducción de las Fórmulas de Derivadas

Partimos de las ecuaciones implícitas

$$F(x, y, z) = 0, \quad G(x, y, z) = 0$$

Por la definición de la derivada y la regla de la cadena, al derivar la igualdad respecto a x obtenemos

$$\frac{d}{dx}F(x, y(x), z(x)) = \frac{\partial F}{\partial x}(x, y, z) + \frac{\partial F}{\partial y}(x, y, z) \frac{dy}{dx} + \frac{\partial F}{\partial z}(x, y, z) \frac{dz}{dx} = 0$$

Notamos que en este proceso se entiende que la derivada de x respecto a sí mismo es 1. Así, se llega directamente a

$$F_x(x, y, z) + F_y(x, y, z) \frac{dy}{dx} + F_z(x, y, z) \frac{dz}{dx} = 0$$

De manera similar, si además se tiene otra función $G(x, y, z) = 0$ (con y y z también funciones de x) aplicamos la regla de la cadena para obtener

$$G_x(x, y, z) + G_y(x, y, z) \frac{dy}{dx} + G_z(x, y, z) \frac{dz}{dx} = 0$$

Por lo tanto tenemos el siguiente sistema

$$\begin{cases} F_x + F_y \frac{dy}{dx} + F_z \frac{dz}{dx} = 0 \\ G_x + G_y \frac{dy}{dx} + G_z \frac{dz}{dx} = 0 \end{cases}$$

$$\begin{cases} F_y \frac{dy}{dx} + F_z \frac{dz}{dx} = -F_x \\ G_y \frac{dy}{dx} + G_z \frac{dz}{dx} = -G_x \end{cases}$$

Escribimos el sistema en forma matricial

$$\begin{pmatrix} F_y & F_z \\ G_y & G_z \end{pmatrix} \begin{pmatrix} \frac{dy}{dx} \\ \frac{dz}{dx} \end{pmatrix} = - \begin{pmatrix} F_x \\ G_x \end{pmatrix}$$

Resolución con Regla de Cramer

Este sistema lineal en las incógnitas $\frac{dy}{dx}$ y $\frac{dz}{dx}$ se resuelve usando determinantes

$$\frac{dy}{dx} = \frac{\begin{vmatrix} -F_x & F_z \\ -G_x & G_z \end{vmatrix}}{J} \quad \text{y} \quad \frac{dz}{dx} = \frac{\begin{vmatrix} F_y & -F_x \\ G_y & -G_x \end{vmatrix}}{J}$$

También puede escribirse de forma compacta como cocientes de derivadas parciales mixtas

$$\frac{dy}{dx} = -\frac{\partial(F, G)/\partial(x, z)}{\partial(F, G)/\partial(y, z)} \quad \text{y} \quad \frac{dz}{dx} = -\frac{\partial(F, G)/\partial(y, x)}{\partial(F, G)/\partial(y, z)}$$

Ejemplo

Consideremos el sistema de ecuaciones

$$\begin{cases} xy + z = 2 \\ x - y + z^2 = 0 \end{cases}$$

que define implícitamente a y y z como funciones de x (i.e., $y = y(x)$ y $z = z(x)$). Para aplicar la derivación implícita, definimos

$$F(x, y, z) = xy + z - 2 = 0 \quad G(x, y, z) = x - y + z^2 = 0$$

Paso 1: Calcular las derivadas parciales Para $F(x, y, z)$

$$F_x = y, \quad F_y = x, \quad F_z = 1$$

Para $G(x, y, z)$

$$G_x = 1, \quad G_y = -1, \quad G_z = 2z$$

Paso 2: Diferenciar implícitamente y escribir el sistema Aplicando la regla de la cadena, tenemos

$$F_x + F_y \frac{dy}{dx} + F_z \frac{dz}{dx} = 0 \implies y + x \frac{dy}{dx} + \frac{dz}{dx} = 0$$

$$G_x + G_y \frac{dy}{dx} + G_z \frac{dz}{dx} = 0 \implies 1 - \frac{dy}{dx} + 2z \frac{dz}{dx} = 0$$

Reorganizando, obtenemos

$$\begin{cases} x \frac{dy}{dx} + \frac{dz}{dx} = -y \\ -\frac{dy}{dx} + 2z \frac{dz}{dx} = -1 \end{cases}$$

Paso 3: Escribir el sistema en forma matricial El sistema se puede expresar de la siguiente manera

$$\begin{pmatrix} F_y & F_z \\ G_y & G_z \end{pmatrix} \begin{pmatrix} \frac{dy}{dx} \\ \frac{dz}{dx} \end{pmatrix} = - \begin{pmatrix} F_x \\ G_x \end{pmatrix}$$

es decir,

$$\begin{pmatrix} x & 1 \\ -1 & 2z \end{pmatrix} \begin{pmatrix} \frac{dy}{dx} \\ \frac{dz}{dx} \end{pmatrix} = - \begin{pmatrix} y \\ 1 \end{pmatrix}$$

Paso 4: Resolver el sistema con la Regla de Cramer El determinante del sistema (Jacobiano) es

$$J = \begin{vmatrix} x & 1 \\ -1 & 2z \end{vmatrix} = 2xz + 1$$

Luego, aplicando la regla de Cramer, se tiene

Para $\frac{dy}{dx}$

$$\frac{dy}{dx} = \frac{\begin{vmatrix} -y & 1 \\ -1 & 2z \end{vmatrix}}{J} = \frac{(-y)(2z) - (1)(-1)}{2xz + 1} = \frac{-2yz + 1}{2xz + 1}$$

Para $\frac{dz}{dx}$

$$\frac{dz}{dx} = \frac{\begin{vmatrix} x & -y \\ -1 & -1 \end{vmatrix}}{J} = \frac{x(-1) - (-y)(-1)}{2xz + 1} = \frac{-x - y}{2xz + 1}$$

Derivación Implícita en Sistemas de Ecuaciones (2 Variables Independientes)

Planteamos la situación en la que dos ecuaciones

$$F(x, y, u, v) = 0 \quad \text{y} \quad G(x, y, u, v) = 0$$

definen implícitamente dos funciones de dos variables independientes

$$u = h(x, y) \quad \text{y} \quad v = m(x, y)$$

Deducción de las Fórmulas de las Derivadas Parciales

Partimos de las ecuaciones implícitas

$$F(x, y, u, v) = 0 \quad \text{y} \quad G(x, y, u, v) = 0$$

Para obtener las derivadas parciales de u y v respecto de x (manteniendo y constante) procedemos de la siguiente manera

(1) Derivadas parciales respecto a x :

Consideramos $u = u(x, y)$ y $v = v(x, y)$. Entonces, aplicando la regla de la cadena a $F(x, y, u, v) = 0$ se tiene

$$\frac{d}{dx} F(x, y, u(x, y), v(x, y)) = \frac{\partial F}{\partial x} + \frac{\partial F}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial F}{\partial v} \frac{\partial v}{\partial x} = 0$$

Aquí se entiende que, al derivar con respecto a x , la variable y se considera constante

De manera similar, al derivar $G(x, y, u, v) = 0$ respecto a x se obtiene

$$\frac{d}{dx}G(x, y, u(x, y), v(x, y)) = \frac{\partial G}{\partial x} + \frac{\partial G}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial G}{\partial v} \frac{\partial v}{\partial x} = 0$$

Podemos escribir el sistema resultante como

$$\begin{cases} F_x(x, y, u, v) + F_u(x, y, u, v) \frac{\partial u}{\partial x} + F_v(x, y, u, v) \frac{\partial v}{\partial x} = 0 \\ G_x(x, y, u, v) + G_u(x, y, u, v) \frac{\partial u}{\partial x} + G_v(x, y, u, v) \frac{\partial v}{\partial x} = 0 \end{cases}$$

Reorganizando para aislar las derivadas parciales de u y v se tiene

$$\begin{cases} F_u \frac{\partial u}{\partial x} + F_v \frac{\partial v}{\partial x} = -F_x \\ G_u \frac{\partial u}{\partial x} + G_v \frac{\partial v}{\partial x} = -G_x \end{cases}$$

Este sistema se puede escribir en forma matricial

$$\begin{pmatrix} F_u & F_v \\ G_u & G_v \end{pmatrix} \begin{pmatrix} \frac{\partial u}{\partial x} \\ \frac{\partial v}{\partial x} \end{pmatrix} = - \begin{pmatrix} F_x \\ G_x \end{pmatrix}$$

(2) Derivadas parciales respecto a y :

Ahora, derivamos con respecto a y (manteniendo x constante). Aplicando la regla de la cadena a $F(x, y, u, v) = 0$ se obtiene

$$\frac{d}{dy}F(x, y, u(x, y), v(x, y)) = \frac{\partial F}{\partial y} + \frac{\partial F}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial F}{\partial v} \frac{\partial v}{\partial y} = 0$$

De forma análoga, para G se tiene

$$\frac{d}{dy}G(x, y, u(x, y), v(x, y)) = \frac{\partial G}{\partial y} + \frac{\partial G}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial G}{\partial v} \frac{\partial v}{\partial y} = 0$$

El sistema resultante es

$$\begin{cases} F_y(x, y, u, v) + F_u(x, y, u, v) \frac{\partial u}{\partial y} + F_v(x, y, u, v) \frac{\partial v}{\partial y} = 0 \\ G_y(x, y, u, v) + G_u(x, y, u, v) \frac{\partial u}{\partial y} + G_v(x, y, u, v) \frac{\partial v}{\partial y} = 0 \end{cases}$$

Reorganizando se tiene

$$\begin{cases} F_u \frac{\partial u}{\partial y} + F_v \frac{\partial v}{\partial y} = -F_y \\ G_u \frac{\partial u}{\partial y} + G_v \frac{\partial v}{\partial y} = -G_y \end{cases}$$

En forma matricial

$$\begin{pmatrix} F_u & F_v \\ G_u & G_v \end{pmatrix} \begin{pmatrix} \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial y} \end{pmatrix} = - \begin{pmatrix} F_y \\ G_y \end{pmatrix}$$

Resolución con Regla de Cramer:

Sea

$$J = \begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix}$$

Entonces, aplicando la regla de Cramer para el sistema respecto a x obtenemos

$$\frac{\partial u}{\partial x} = \frac{\begin{vmatrix} -F_x & F_v \\ -G_x & G_v \end{vmatrix}}{J} \quad \frac{\partial v}{\partial x} = \frac{\begin{vmatrix} F_u & -F_x \\ G_u & -G_x \end{vmatrix}}{J}$$

Y para el sistema respecto a y

$$\frac{\partial u}{\partial y} = \frac{\begin{vmatrix} -F_y & F_v \\ -G_y & G_v \end{vmatrix}}{J} \quad \frac{\partial v}{\partial y} = \frac{\begin{vmatrix} F_u & -F_y \\ G_u & -G_y \end{vmatrix}}{J}$$

De esta forma, hemos obtenido las cuatro derivadas parciales que describen cómo varían u y v respecto de x e y

$$\frac{\partial u}{\partial x}, \quad \frac{\partial v}{\partial x}, \quad \frac{\partial u}{\partial y}, \quad \frac{\partial v}{\partial y}$$

Ejemplo

Consideremos el siguiente sistema de ecuaciones

$$\begin{cases} F(x, y, u, v) = x u + y v - 2 = 0 \\ G(x, y, u, v) = u^2 - v + x y = 0 \end{cases}$$

el cual define implícitamente a u y v como funciones de x e y es decir, $u = u(x, y)$ y $v = v(x, y)$

Paso 1: Cálculo de las Derivadas Parciales de F y G

Para la función

$$F(x, y, u, v) = x u + y v - 2$$

se tiene

$$F_x = u, \quad F_y = v, \quad F_u = x, \quad F_v = y$$

Para la función

$$G(x, y, u, v) = u^2 - v + x y$$

se obtiene

$$G_x = y, \quad G_y = x, \quad G_u = 2u, \quad G_v = -1$$

Paso 2: Derivadas Parciales respecto a x

Dado que $u = u(x, y)$ y $v = v(x, y)$ aplicamos la regla de la cadena a cada ecuación (manteniendo y constante)

Para $F(x, y, u, v) = 0$

$$F_x + F_u u_x + F_v v_x = 0 \quad \implies \quad u + x u_x + y v_x = 0$$

Para $G(x, y, u, v) = 0$

$$G_x + G_u u_x + G_v v_x = 0 \quad \implies \quad y + 2u u_x - v_x = 0$$

Escribimos el sistema en forma matricial

$$\begin{pmatrix} F_u & F_v \\ G_u & G_v \end{pmatrix} \begin{pmatrix} u_x \\ v_x \end{pmatrix} = - \begin{pmatrix} F_x \\ G_x \end{pmatrix}$$

es decir,

$$\begin{pmatrix} x & y \\ 2u & -1 \end{pmatrix} \begin{pmatrix} u_x \\ v_x \end{pmatrix} = - \begin{pmatrix} u \\ y \end{pmatrix}$$

Definimos el Jacobiano del sistema (en las variables dependientes u y v)

$$J = \begin{vmatrix} x & y \\ 2u & -1 \end{vmatrix} = x(-1) - (y)(2u) = -x - 2u y$$

Aplicando la regla de Cramer

Para u_x

$$\frac{\partial u}{\partial x} = \frac{\begin{vmatrix} -F_x & F_v \\ -G_x & G_v \end{vmatrix}}{J} = \frac{\begin{vmatrix} -u & y \\ -y & -1 \end{vmatrix}}{-x - 2u y}$$

Calculamos el determinante

$$(-u)(-1) - y(-y) = u + y^2$$

Por lo tanto,

$$u_x = \frac{u + y^2}{-x - 2u y}$$

Para v_x

$$\frac{\partial v}{\partial x} = \frac{\begin{vmatrix} F_u & -F_x \\ G_u & -G_x \end{vmatrix}}{J} = \frac{\begin{vmatrix} x & -u \\ 2u & -y \end{vmatrix}}{-x - 2u y}$$

Calculamos el determinante

$$x(-y) - (-u)(2u) = -xy + 2u^2$$

Por lo tanto,

$$v_x = \frac{-xy + 2u^2}{-x - 2u y}$$

Paso 3: Derivadas Parciales respecto a y

Ahora, diferenciamos con respecto a y (manteniendo x constante)

Para $F(x, y, u, v) = 0$

$$F_y + F_u u_y + F_v v_y = 0 \implies v + x u_y + y v_y = 0$$

Para $G(x, y, u, v) = 0$

$$G_y + G_u u_y + G_v v_y = 0 \implies x + 2u u_y - v_y = 0$$

El sistema en forma matricial es el mismo

$$\begin{pmatrix} x & y \\ 2u & -1 \end{pmatrix} \begin{pmatrix} u_y \\ v_y \end{pmatrix} = - \begin{pmatrix} v \\ x \end{pmatrix}$$

Aplicando de nuevo la regla de Cramer

Para u_y

$$\frac{\partial u}{\partial y} = \frac{\begin{vmatrix} -F_y & F_v \\ -G_y & G_v \end{vmatrix}}{J} = \frac{\begin{vmatrix} -v & y \\ -x & -1 \end{vmatrix}}{-x - 2u y}$$

Determinante

$$(-v)(-1) - y(-x) = v + xy$$

Por lo tanto,

$$u_y = \frac{v + xy}{-x - 2u y}$$

Para v_y

$$\frac{\partial v}{\partial y} = \frac{\begin{vmatrix} F_u & -F_y \\ G_u & -G_y \end{vmatrix}}{J} = \frac{\begin{vmatrix} x & -v \\ 2u & -x \end{vmatrix}}{-x - 2u y}$$

Determinante

$$x(-x) - (-v)(2u) = -x^2 + 2u v$$

Por lo tanto,

$$v_y = \frac{-x^2 + 2u v}{-x - 2u y}$$

13 IS-LM

El modelo IS–LM determina simultáneamente el ingreso real Y y la tasa de interés r en el corto plazo, mediante el equilibrio en dos mercados: el de bienes y servicios (curva IS) y el monetario (curva LM). Además, incorpora la relación entre ingreso y recaudación fiscal.

$$\begin{cases} Y = C(Y_d) + I(r) + g \\ M_p = L(Y, r) \\ Y_d = Y - T(Y, \theta) \end{cases}$$

1. Mercado de bienes y servicios (IS)

$$Y = C(Y_d) + I(r) + g$$

- Y : producción (o ingreso) agregado.
- $C(Y_d)$: consumo de los hogares, función creciente de ingreso disponible Y_d .
- $I(r)$: inversión de las empresas, función decreciente de la tasa r .
- g : gasto público, exógeno.

La curva IS (“Investment–Saving”) es el conjunto de (Y, r) que satisfacen esta identidad.

2. Mercado monetario (LM)

$$M_p = L(Y, r)$$

- M_p : oferta real de dinero (stock), fijada por la autoridad monetaria.
- $L(Y, r)$: demanda de dinero, creciente en Y ($\partial L / \partial Y > 0$) y decreciente en r ($\partial L / \partial r < 0$).

La curva LM (“Liquidity preference–Money supply”) es el conjunto de puntos de (Y, r) que igualan oferta y demanda de dinero.

3. Ingreso disponible

$$Y_d = Y - T(Y, \theta)$$

donde $T(Y, \theta)$ es la recaudación fiscal, función creciente de Y . El ingreso disponible Y_d es el que efectivamente determina el consumo.

Resolución del modelo IS–LM por derivación implícita

Partimos del modelo:

$$\begin{cases} Y = C(Y_d) + I(r) + g \\ M_p = L(Y, r) \\ Y_d = Y - T(Y, \theta) \end{cases}$$

Variables endógenas	
Y	Ingreso (producción) de equilibrio
r	Tasa de interés de equilibrio

Variables exógenas	
g	Gasto público
M_p	Oferta real de dinero (stock monetario)
θ	Parámetro(s) fiscales en $T(Y, \theta)$

Hipótesis de comportamiento:

$$0 < C'(Y - T(Y, \theta)) < 1, \quad 0 < T_Y(Y, \theta) < 1, \quad I'(r) < 0, \quad L_Y(Y, r) > 0, \quad L_r(Y, r) < 0, \quad T_\theta(Y, \theta) > 0$$

Sustituyendo Y_d en la primera ecuación obtenemos dos ecuaciones en las variables endógenas Y y r :

$$\begin{cases} F(Y, r; g, \theta) = Y - C(Y - T(Y, \theta)) - I(r) - g = 0 \\ G(Y, r; M_p) = L(Y, r) - M_p = 0 \end{cases}$$

El objetivo es encontrar $\frac{\partial Y}{\partial g}$ y $\frac{\partial r}{\partial g}$. Es decir, el efecto que tiene un aumento del gasto público en el producto y en la tasa de interés.

Paso 1: Derivadas parciales

Derivamos ambas ecuaciones respecto a g , recordemos que Y depende de g , también r depende de g por lo tanto debemos utilizar regla de la cadena:

$$F'_g = \frac{\partial F}{\partial Y} \frac{\partial Y}{\partial g} + \frac{\partial F}{\partial r} \frac{\partial r}{\partial g} + \frac{\partial F}{\partial g} \frac{\partial g}{\partial g} = 0$$

$$G'_g = \frac{\partial G}{\partial Y} \frac{\partial Y}{\partial g} + \frac{\partial G}{\partial r} \frac{\partial r}{\partial g} + \frac{\partial G}{\partial g} \frac{\partial g}{\partial g} = 0$$

Derivamos ambas ecuaciones respecto a g , manteniendo M_p y θ constantes:

$$\frac{\partial}{\partial g} [Y - C(Y - T(Y, \theta)) - I(r) - g] = (1 - C'(Y - T(Y, \theta)) [1 - T_Y(Y, \theta)]) \frac{\partial Y}{\partial g} - I'(r) \frac{\partial r}{\partial g} - 1 = 0$$

$$\frac{\partial}{\partial g} [L(Y, r) - M_p] = L_Y(Y, r) \frac{\partial Y}{\partial g} + L_r(Y, r) \frac{\partial r}{\partial g} = 0$$

$$\begin{cases} \frac{\partial}{\partial g} [Y - C(Y - T(Y, \theta)) - I(r) - g] = (1 - C'(Y - T(Y, \theta)) [1 - T_Y(Y, \theta)]) \frac{\partial Y}{\partial g} - I'(r) \frac{\partial r}{\partial g} - 1 = 0 \\ \frac{\partial}{\partial g} [L(Y, r) - M_p] = L_Y(Y, r) \frac{\partial Y}{\partial g} + L_r(Y, r) \frac{\partial r}{\partial g} = 0 \end{cases}$$

Paso 2: Sistema matricial

De aquí obtenemos el sistema lineal

$$\begin{pmatrix} 1 - C'(Y - T(Y, \theta)) [1 - T_Y(Y, \theta)] & -I'(r) \\ L_Y(Y, r) & L_r(Y, r) \end{pmatrix} \begin{pmatrix} \frac{\partial Y}{\partial g} \\ \frac{\partial r}{\partial g} \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

Paso 3: Resolver con la Regla de Cramer

El determinante del sistema es

$$J = [1 - C'(Y - T(Y, \theta)) [1 - T_Y(Y, \theta)]] L_r(Y, r) - [-I'(r)] L_Y(Y, r)$$

Por Cramer,

$$\frac{\partial Y}{\partial g} = \frac{\begin{vmatrix} 1 & -I'(r) \\ 0 & L_r(Y, r) \end{vmatrix}}{J} = \frac{1 \cdot L_r(Y, r)}{J} = \frac{L_r(Y, r)}{J}$$

$$\frac{\partial r}{\partial g} = \frac{\begin{vmatrix} 1 - C'(Y - T(Y, \theta)) [1 - T_Y(Y, \theta)] & 1 \\ L_Y(Y, r) & 0 \end{vmatrix}}{J} = \frac{-L_Y(Y, r)}{J}$$

Paso 4: Signos e interpretación

Dado que

$$0 < C'(Y - T(Y, \theta)) < 1 \quad 0 < T_Y(Y, \theta) < 1 \quad I'(r) < 0 \quad L_Y(Y, r) > 0 \quad L_r(Y, r) < 0$$

se cumple

$$1 - C'(Y - T(Y, \theta)) [1 - T_Y(Y, \theta)] > 0 \quad -I'(r) > 0$$

Por tanto el determinante

$$J = \underbrace{\left[1 - \underbrace{C'(Y - T(Y, \theta))}_{0 < \cdot < 1} \times \underbrace{(1 - T_Y(Y, \theta))}_{0 < \cdot < 1} \right]}_{>0} \times \underbrace{L_r(Y, r)}_{<0} - \underbrace{(-I'(r))}_{>0} \times \underbrace{L_Y(Y, r)}_{>0} < 0$$

Como $L_r < 0$, $L_Y > 0$, el numerador de $\partial Y / \partial g$ es negativo y el de $\partial r / \partial g$ también es negativo:

$$\frac{\partial Y}{\partial g} = \frac{L_r}{J} > 0 \quad \frac{\partial r}{\partial g} = \frac{-L_Y}{J} > 0$$

Cuando el gobierno aumenta su gasto g , se desencadenan dos efectos:

Más demanda $\Rightarrow$ más producción (Y)

- *Gasto directo*: el gobierno inyecta recursos pagando obras, sueldos, compras de insumos, etc.
- *Cadena de efectos*: esos pagos se convierten en ingresos para empresas y trabajadores, que a su vez consumen parte de ese ingreso extra, generando más ventas e ingresos en otros sectores.
- *Multiplicador*: cada unidad de gasto público produce más de una unidad de aumento en el ingreso agregado, pues el dinero circula y se vuelve a gastar varias veces.

Mayor $Y \Rightarrow$ mayor demanda de dinero $\Rightarrow$ sube r

- *Demanda de dinero transaccional*: al crecer Y , hogares y empresas realizan más transacciones y necesitan más liquidez.
- *Curva LM*: $L(Y, r)$ crece con Y y cae con r . Con M_p fijo, un aumento de L empuja la tasa r al alza hasta reequilibrar oferta y demanda monetaria.
- *Crowding-out parcial*: al subir r , el crédito se encarece y la inversión privada se modera, atenuando algo el impulso inicial sobre Y , pero sin anularlo.

14 Homogeneidad

Definición de Homogeneidad

Una función $F : \mathbb{R}_+^n \rightarrow \mathbb{R}$ se dice *homogénea de grado k* si, para todo $\lambda > 0$ y todo $\mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}_+^n$, se cumple

$$F(\lambda x_1, \dots, \lambda x_n) = \lambda^k F(x_1, \dots, x_n).$$

Cuando $k = 0$, se dice que la función es *homogénea de grado cero*.

Ejemplos

1. **Homogeneidad de grado 1.** Sea

$$F(x, y) = 3x + 5y.$$

Entonces, para cualquier $\lambda > 0$,

$$F(\lambda x, \lambda y) = 3(\lambda x) + 5(\lambda y) = \lambda(3x + 5y) = \lambda^1 F(x, y).$$

Por tanto, F es homogénea de grado $k = 1$.

2. **Homogeneidad de grado 0 (relación de precios).** Sea

$$G(x, y) = \frac{x}{y}.$$

Para $\lambda > 0$,

$$G(\lambda x, \lambda y) = \frac{\lambda x}{\lambda y} = \frac{x}{y} = \lambda^0 G(x, y).$$

Así, G es homogénea de grado $k = 0$.

Propiedades de las Funciones Homogéneas

1. **Multiplicación de escala:** Si F es homogénea de grado k , entonces para todo $\lambda, \mu > 0$

$$F(\lambda \mu \mathbf{x}) = (\lambda \mu)^k F(\mathbf{x}) = \lambda^k F(\mu \mathbf{x}).$$

2. **Combinación lineal:** Si F y G son homogéneas de grado k , y $a, b \in \mathbb{R}$, entonces

$$H(\mathbf{x}) = a F(\mathbf{x}) + b G(\mathbf{x})$$

es homogénea de grado k .

3. **Producto:** Si F es homogénea de grado k y G de grado m , entonces

$$(F \cdot G)(\mathbf{x}) = F(\mathbf{x}) G(\mathbf{x})$$

es homogénea de grado $k + m$.

4. **Cociente:** Si $G(\mathbf{x}) \neq 0$ y F, G son homogéneas de grado k y m respectivamente, entonces

$$\left(\frac{F}{G} \right)(\mathbf{x}) = \frac{F(\mathbf{x})}{G(\mathbf{x})}$$

es homogénea de grado $k - m$.

5. **Derivadas:** Si F es homogénea de grado k y diferenciable, entonces todas sus derivadas parciales de orden m son homogéneas de grado $k - m$.

Teorema de Euler para Funciones Homogéneas

Teorema (Euler). Sea $F : \mathbb{R}_+^n \rightarrow \mathbb{R}$ una función diferenciable y homogénea de grado k . Entonces

$$\sum_{i=1}^n x_i \frac{\partial F}{\partial x_i}(x_1, \dots, x_n) = k F(x_1, \dots, x_n).$$

Demostración. Dado que F es homogénea de grado k , para todo $\lambda > 0$ se cumple

$$F(\lambda x_1, \lambda x_2, \dots, \lambda x_n) = \lambda^k F(x_1, x_2, \dots, x_n).$$

Definamos la función de una sola variable

$$\Phi(\lambda) = F(\lambda x_1, \lambda x_2, \dots, \lambda x_n).$$

Por la homogeneidad, también

$$\Phi(\lambda) = \lambda^k F(x_1, \dots, x_n).$$

Como F es diferenciable, Φ es diferenciable y podemos derivar ambas expresiones respecto a λ .

- Por la regla de la cadena,

$$\Phi'(\lambda) = \sum_{i=1}^n \frac{\partial F}{\partial x_i}(\lambda x_1, \dots, \lambda x_n) \frac{d}{d\lambda}(\lambda x_i) = \sum_{i=1}^n \frac{\partial F}{\partial x_i}(\lambda x_1, \dots, \lambda x_n) x_i.$$

- Por derivar $\lambda^k F(x_1, \dots, x_n)$,

$$\Phi'(\lambda) = \frac{d}{d\lambda}(\lambda^k F(x_1, \dots, x_n)) = k \lambda^{k-1} F(x_1, \dots, x_n).$$

Igualando ambas expresiones para $\Phi'(\lambda)$,

$$\sum_{i=1}^n x_i \frac{\partial F}{\partial x_i}(\lambda x_1, \dots, \lambda x_n) = k \lambda^{k-1} F(x_1, \dots, x_n).$$

Finalmente, evaluamos en $\lambda = 1$:

$$\sum_{i=1}^n x_i \frac{\partial F}{\partial x_i}(x_1, \dots, x_n) = k F(x_1, \dots, x_n),$$

como queríamos demostrar. ■

Ejemplo

Consideremos la función polinómica

$$F(x, y) = x^3 + 2xy^2.$$

1. **Verificación de homogeneidad.** Observamos que cada término es de grado 3:

$$(\lambda x)^3 = \lambda^3 x^3, \quad 2(\lambda x)(\lambda y)^2 = 2\lambda^3 xy^2.$$

Por tanto,

$$F(\lambda x, \lambda y) = (\lambda x)^3 + 2(\lambda x)(\lambda y)^2 = \lambda^3(x^3 + 2xy^2) = \lambda^3 F(x, y),$$

y concluimos que F es homogénea de grado $k = 3$.

2. Derivadas parciales.

$$F_x(x, y) = \frac{\partial}{\partial x}(x^3 + 2xy^2) = 3x^2 + 2y^2,$$

$$F_y(x, y) = \frac{\partial}{\partial y}(x^3 + 2xy^2) = 4xy.$$

3. **Comprobación del Teorema de Euler.** El teorema de Euler establece que, si F es homogénea de grado 3, entonces

$$x F_x(x, y) + y F_y(x, y) = 3 F(x, y).$$

Calculemos el lado izquierdo:

$$x(3x^2 + 2y^2) + y(4xy) = 3x^3 + 2xy^2 + 4xy^2 = 3x^3 + 6xy^2.$$

Y el lado derecho:

$$3 F(x, y) = 3(x^3 + 2xy^2) = 3x^3 + 6xy^2.$$

Como coinciden,

$$x F_x + y F_y = 3 F(x, y),$$

confirmamos que el teorema de Euler se cumple.

Interpretación Económica

En economía, la homogeneidad y el Teorema de Euler tienen aplicaciones directas en teoría de la producción y en demanda:

- **Funciones de producción con rendimientos a escala:** Si la función de producción $Y = F(K, L)$ (capital K , trabajo L) es homogénea de grado k :

$$F(\lambda K, \lambda L) = \lambda^k F(K, L),$$

entonces:

- $k = 1$ implica *rendimientos constantes a escala*: duplicar todos los insumos duplica la producción.
- $k > 1$ implica *rendimientos crecientes a escala*: duplicar insumos más que duplica la producción.
- $k < 1$ implica *rendimientos decrecientes a escala*: duplicar insumos menos que duplica la producción.
- **Demanda homogénea de grado cero en precios e ingreso:** Una función de demanda $x_i(p_1, \dots, p_n, M)$ (precios p_j , ingreso M) es homogénea de grado cero:

$$x_i(\lambda p_1, \dots, \lambda p_n, \lambda M) = x_i(p_1, \dots, p_n, M).$$

Esto significa que si todos los precios y el ingreso cambian en la misma proporción, las cantidades demandadas no varían: sólo importan los precios relativos y el poder de compra real.

- **Elasticidades parciales y grado de homogeneidad:** Sea $F(K, L)$ una función de producción diferenciable y homogénea de grado k . Definimos las elasticidades parciales de la producción con respecto a cada factor como

$$\varepsilon_K = \frac{\partial F}{\partial K} \frac{K}{F(K, L)}, \quad \varepsilon_L = \frac{\partial F}{\partial L} \frac{L}{F(K, L)}.$$

Aplicando el Teorema de Euler:

$$K F_K(K, L) + L F_L(K, L) = k F(K, L),$$

y dividiendo ambos lados por $F(K, L)$, obtenemos

$$\varepsilon_K + \varepsilon_L = k.$$

Interpretación: la suma de las elasticidades parciales de la producción respecto al capital y al trabajo coincide con el grado de homogeneidad de la función. Económicamente, esto significa que los rendimientos a escala coinciden con la suma de elasticidades parciales

- Si $\varepsilon_K + \varepsilon_L = k = 1$, rendimientos constantes a escala.
- Si $\varepsilon_K + \varepsilon_L = k > 1$, rendimientos crecientes a escala.
- Si $\varepsilon_K + \varepsilon_L = k < 1$, rendimientos decrecientes a escala.

15 Autovalores y autovectores

Definición de autovalor y autovector

Sea $A \in \mathbb{R}^{n \times n}$. En todo el capítulo, los vectores de $\mathbb{R}^n$ son vectores columna; cuando los escribimos en una línea usamos la notación $(x_1, \dots, x_n)^T$.

Un escalar $\lambda \in \mathbb{R}$ es autovalor de A si existe un vector $v \in \mathbb{R}^n \setminus \{0\}$ tal que

$$Av = \lambda v$$


El vector v que satisface esta igualdad se llama autovector asociado al autovalor λ .

Una breve intuición de qué significa esto es la siguiente. Pensemos la matriz A como una transformación: así como una función toma un valor de entrada y lo cambia, la matriz A , al multiplicar por la izquierda a un vector v (es decir, al calcular Av), puede girarlo, estirarlo, encogerlo, etc.

En este sentido, un autovector es un vector que, después de la transformación, queda sobre la misma recta por el origen: A no lo gira hacia otra dirección, solamente lo estira o lo encoge y, a veces, le invierte el sentido. El autovalor λ es el factor de escala de ese cambio:

- si $\lambda > 1$, el autovector se agranda, y si $0 < \lambda < 1$, se achica;
- si $\lambda = 1$, queda exactamente igual;
- si $\lambda < 0$, cambia de sentido (y además se agranda si $|\lambda| > 1$ o se achica si $|\lambda| < 1$);
- si $\lambda = 0$, es enviado al vector nulo, es decir, $Av = 0$ (lo que no puede ser nulo es el autovector, no el autovalor).

En el siguiente gráfico se puede ver la naturaleza de un autovector: en este caso, un vector v con la dirección de $(1, 1)^T$ (en el dibujo, $v = (2, 2)^T$, que corresponde a $\lambda = 1$). Al multiplicarlo por A , el resultado $Av = \lambda v$ queda siempre sobre la recta punteada: solamente puede agrandarse, achicarse o cambiar de sentido, según el valor de λ . Cada vector del gráfico muestra uno de esos resultados posibles (cada valor de λ corresponde a una matriz distinta, ya que para una matriz fija un autovector tiene un único autovalor).



Veamos ahora un ejemplo concreto. Sea

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$


Al multiplicarla por tres vectores se obtiene

$$A \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix} = 3 \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$A \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 1 \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

$$A \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

Los dos primeros vectores son autovectores (con autovalores 3 y 1): después de multiplicar por A siguen sobre la misma recta. El tercero, en cambio, no es autovector: $(2, 1)^T$ no es un múltiplo de $(1, 0)^T$, así que A lo hizo cambiar de dirección. En el gráfico, las rectas punteadas son las direcciones de los autovectores. Los vectores $v_2 = (1, 1)^T$ y $w = (1, 0)^T$ se dibujan en un tono claro y sus imágenes por A , en el mismo color pero más oscuro; para $v_1 = (1, -1)^T$ la imagen coincide con el propio vector.



Polinomio característico

Definición

Sea $A \in \mathbb{R}^{n \times n}$. El *polinomio característico*³ de A se define como

$$\chi_A(\lambda) = \det(\lambda I - A)$$

El polinomio característico proviene de la siguiente deducción, dado:

$$Av = \lambda v, \quad v \neq 0$$

³Se usa $\lambda I - A$ (y no $A - \lambda I$) para que χ_A sea un polinomio *mónico*, es decir, con coeficiente principal 1: $\chi_A(\lambda) = \lambda^n + c_{n-1}\lambda^{n-1} + \dots + c_1\lambda + c_0$. Con $A - \lambda I$ el coeficiente principal sería $(-1)^n$. Para n par las dos definiciones dan el mismo polinomio, y para n impar difieren solamente en el signo, lo que no cambia las raíces.

Reordenando

$$(A - \lambda I)v = 0$$

Este es un sistema homogéneo con solución no trivial $v \neq 0$ *si y solo si* la matriz $A - \lambda I$ es **singular**. Una matriz cuadrada es singular $\Leftrightarrow$ su determinante es cero, entonces

$$\det(A - \lambda I) = 0$$

Como $\lambda I - A = -(A - \lambda I)$, se cumple $\det(\lambda I - A) = (-1)^n \det(A - \lambda I)$ (se cambia el signo de las n filas). Por lo tanto, $\det(\lambda I - A)$ y $\det(A - \lambda I)$ se anulan exactamente para los mismos valores de λ , y la condición anterior equivale a

$$\det(\lambda I - A) = 0$$

Los λ que anulan $\det(\lambda I - A)$ son exactamente los **autovalores** de A . Por eso se define el *polinomio característico*

$$\chi_A(\lambda) = \det(\lambda I - A)$$

y los autovalores son las raíces de χ_A .⁴

Ejemplo para matriz 2×2

Sea

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

Entonces

$$\lambda I - A = \begin{pmatrix} \lambda - a & -b \\ -c & \lambda - d \end{pmatrix}$$

y

$$\chi_A(\lambda) = \det \begin{pmatrix} \lambda - a & -b \\ -c & \lambda - d \end{pmatrix} = (\lambda - a)(\lambda - d) - bc = \lambda^2 - \underbrace{(a + d)}_{\text{tr}(A)} \lambda + \underbrace{(ad - bc)}_{\det(A)}$$

Cálculo de autovalores y autovectores

Procedimiento

1. Formar la matriz $\lambda I - A$
2. Calcular $\chi_A(\lambda) = \det(\lambda I - A)$ y simplificarlo hasta obtener un polinomio en λ
3. Resolver $\chi_A(\lambda) = 0$ para obtener los autovalores $\lambda_1, \lambda_2, \lambda_3, \dots$
4. Para cada λ_i , resolver $(A - \lambda_i I)v = 0$ (equivalente a $(\lambda_i I - A)v = 0$) buscando vectores no nulos

⁴Un polinomio con coeficientes reales no siempre tiene todas sus raíces reales (por ejemplo, $\lambda^2 + 1$ no tiene ninguna). En este capítulo trabajamos con matrices cuyo polinomio característico tiene todas sus raíces reales, contadas con su multiplicidad; es decir, $\chi_A(\lambda) = (\lambda - \lambda_1) \cdots (\lambda - \lambda_n)$.

Ejemplo numérico para matriz 2×2

Sea

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

Entonces

$$\lambda I - A = \begin{pmatrix} \lambda & 0 \\ 0 & \lambda \end{pmatrix} - \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} \lambda - 2 & -1 \\ -1 & \lambda - 2 \end{pmatrix}$$

por lo que

$$\chi_A(\lambda) = \det(\lambda I - A) = \det \begin{pmatrix} \lambda - 2 & -1 \\ -1 & \lambda - 2 \end{pmatrix} = (\lambda - 2)^2 - 1 = \lambda^2 - 4\lambda + 3$$

Resolvemos

$$\lambda^2 - 4\lambda + 3 = 0$$

obteniendo

$$\lambda_1 = 1, \quad \lambda_2 = 3$$

Chequeo: como $\chi_A(\lambda) = \lambda^2 - \operatorname{tr}(A)\lambda + \det(A)$, la suma de las raíces debe ser $\operatorname{tr}(A)$ y su producto $\det(A)$:

$$\lambda_1 + \lambda_2 = 1 + 3 = 4 = \operatorname{tr}(A), \quad \lambda_1 \lambda_2 = 1 \cdot 3 = 3 = \det(A)$$

Cálculo paso a paso de los autovectores

Para $\lambda_1 = 1$ Calculamos

$$A - I = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} - \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

Resolvemos el sistema

$$\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Lo que equivale a la ecuación única

$$x + y = 0$$

De aquí $y = -x$, por lo que los autovectores asociados a $\lambda_1 = 1$ son todos los de la forma

$$\begin{pmatrix} x \\ y \end{pmatrix} = x \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \quad x \neq 0$$

Tomamos $x = 1$ y elegimos $v_1 = (1, -1)^T$.⁵

Para $\lambda_2 = 3$ Calculamos

$$A - 3I = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} - \begin{pmatrix} 3 & 0 \\ 0 & 3 \end{pmatrix} = \begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix}$$

Resolvemos el sistema

$$\begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Equivalente a

$$-x + y = 0 \implies y = x$$

⁵Los autovectores asociados a un mismo autovalor no son únicos: cualquier múltiplo no nulo de un autovector es también un autovector del mismo autovalor. En efecto, si $Av = \lambda v$ y $c \neq 0$, entonces $A(cv) = cAv = c\lambda v = \lambda(cv)$. Es decir, se pueden tomar cualquiera de los siguientes vectores como autovectores del autovalor $\lambda = 1$: $(1, -1)^T$, $(2, -2)^T$, $(-3, 3)^T$, etcétera; todos representan la misma dirección y son autovectores válidos del mismo autovalor.

Por lo tanto, los autovectores asociados a $\lambda_2 = 3$ son todos los de la forma

$$\begin{pmatrix} x \\ y \end{pmatrix} = x \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad x \neq 0$$

Tomamos $x = 1$ y elegimos $v_2 = (1, 1)^T$.

En conclusión, tomando $x = 1$ en cada caso, obtenemos como autovectores representativos $v_1 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$ para $\lambda = 1$ y $v_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ para $\lambda = 3$ (y todos sus múltiplos no nulos). Son los dos autovectores del segundo gráfico.

Verificación Comprobamos que se cumple $Av = \lambda v$:

$$Av_1 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 1 \cdot v_1$$

$$Av_2 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix} = 3 \cdot v_2$$

Propiedades de los autovalores

Sea el polinomio característico de A de grado n :

$$\chi_A(\lambda) = \det(\lambda I - A) = \lambda^n + c_{n-1}\lambda^{n-1} + \cdots + c_1\lambda + c_0$$

Coefficientes y autovalores

Si $\lambda_1, \dots, \lambda_n$ son las raíces de χ_A (cada una repetida tantas veces como indique su multiplicidad, concepto que se formaliza en la sección siguiente), entonces $\chi_A(\lambda) = (\lambda - \lambda_1) \cdots (\lambda - \lambda_n)$ y, al desarrollar el producto,

$$c_{n-1} = -\sum_{i=1}^n \lambda_i, \quad c_0 = (-1)^n \prod_{i=1}^n \lambda_i$$

En palabras: el coeficiente c_{n-1} representa el negativo de la suma de todos los autovalores, reflejando que la traza de A coincide con dicha suma. Por su parte, c_0 corresponde al producto de los autovalores multiplicado por $(-1)^n$.

Traza y determinante

Recordando que:

$$\text{tr}(A) = \sum_{i=1}^n a_{ii}$$

Existe una relación entre autovalores y traza y determinante (con las raíces contadas con su multiplicidad):

$$\sum_{i=1}^n \lambda_i = \text{tr}(A), \quad \prod_{i=1}^n \lambda_i = \det(A)$$

El caso $n = 2$ corresponde al ejemplo general 2×2 de la sección *Polinomio característico*.

Ejemplo numérico

Para la matriz

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

sus autovalores son $\lambda_1 = 1$ y $\lambda_2 = 3$ (los calculamos en la sección anterior). En este caso,

$$\operatorname{tr}(A) = 2 + 2 = 4 = \lambda_1 + \lambda_2 = 1 + 3, \quad \det(A) = 2 \cdot 2 - 1 \cdot 1 = 3 = \lambda_1 \lambda_2 = 1 \cdot 3$$

Matrices triangulares y diagonales

Si A es triangular (superior o inferior), en particular si es diagonal, sus autovalores son los elementos de su diagonal principal.

En efecto, $\lambda I - A$ también es triangular, con $\lambda - a_{11}, \dots, \lambda - a_{nn}$ en la diagonal, y el determinante de una matriz triangular es el producto de los elementos de su diagonal:

$$\chi_A(\lambda) = (\lambda - a_{11})(\lambda - a_{22}) \cdots (\lambda - a_{nn})$$

Cada autovalor se repite tantas veces como aparece en la diagonal. Por ejemplo, las matrices B , C y D de la sección siguiente son triangulares, y sus autovalores se leen directamente de la diagonal.

Autovalor cero y matrices singulares

$\lambda = 0$ es autovalor de A si y solo si A es singular (es decir, $\det(A) = 0$).

En efecto, 0 es autovalor $\Leftrightarrow$ existe $v \neq 0$ tal que $Av = 0 \cdot v = 0 \Leftrightarrow A$ es singular. Esto también se ve a partir de $\prod_{i=1}^n \lambda_i = \det(A)$: el producto es cero si y solo si algún factor es cero.

Autovectores de autovalores distintos

Autovectores asociados a autovalores distintos son linealmente independientes.

Veamos el caso de dos autovectores. Sean $Av_1 = \lambda_1 v_1$ y $Av_2 = \lambda_2 v_2$, con $\lambda_1 \neq \lambda_2$, y supongamos que

$$\alpha_1 v_1 + \alpha_2 v_2 = 0$$

Multiplicando por A se obtiene

$$\alpha_1 \lambda_1 v_1 + \alpha_2 \lambda_2 v_2 = 0$$

y restando λ_1 veces la primera igualdad queda

$$\alpha_2 (\lambda_2 - \lambda_1) v_2 = 0$$

Como $v_2 \neq 0$ y $\lambda_2 \neq \lambda_1$, resulta $\alpha_2 = 0$. Entonces $\alpha_1 v_1 = 0$ y, como $v_1 \neq 0$, también $\alpha_1 = 0$. El caso general se demuestra de la misma manera, por inducción.

En particular, si $A \in \mathbb{R}^{n \times n}$ tiene n autovalores distintos, tiene n autovectores linealmente independientes.

Raíces iguales y multiplicidad

Multiplicidad algebraica

Sea $A \in \mathbb{R}^{n \times n}$ y sean $\lambda_1, \dots, \lambda_k$ los autovalores *distintos* de A (ahora sin repetir).

- La *multiplicidad algebraica* de λ_i , denotada $\operatorname{mult}_{\text{alg}}(\lambda_i)$, es el grado con que λ_i aparece como raíz del polinomio característico $\chi_A(\lambda)$. Puede pensarse como la cantidad de veces que se repite el autovalor.

$$\chi_A(\lambda) = (\lambda - \lambda_1)^{m_1} \cdots (\lambda - \lambda_k)^{m_k}, \quad \operatorname{mult}_{\text{alg}}(\lambda_i) = m_i$$

- Obsérvese que $\sum_{i=1}^k m_i = n$, es decir, la suma de todas las multiplicidades algebraicas es el grado del polinomio característico (recordemos que estamos suponiendo que todas las raíces de χ_A son reales).

Espacio propio

Antes de definir la multiplicidad geométrica conviene mirar *todos* los autovectores de un mismo autovalor a la vez. Ya vimos que si v es un autovector de λ , cualquier múltiplo no nulo de v también lo es: todos esos vectores están sobre una misma recta por el origen. Y si u y w son autovectores de λ que no son múltiplos entre sí, cualquier combinación lineal de ellos sigue siendo un autovector de λ (o el vector nulo), porque

$$A(\alpha u + \beta w) = \alpha A u + \beta A w = \alpha \lambda u + \beta \lambda w = \lambda(\alpha u + \beta w)$$

Es decir, los vectores que A multiplica exactamente por λ forman una recta, un plano, etc., que pasa por el origen. A ese conjunto se lo llama *espacio propio* (o autoespacio) de λ :

$$E_\lambda = \{v \in \mathbb{R}^n : A v = \lambda v\} = \ker(A - \lambda I)$$

Recordemos que $\ker(M) = \{v : M v = 0\}$ es el núcleo (o espacio nulo) de una matriz M ; la igualdad anterior sale de $A v = \lambda v \Leftrightarrow (A - \lambda I) v = 0$.

El espacio propio E_λ contiene a todos los autovectores de λ y, además, al vector nulo (que no es un autovector, pero cumple $A 0 = \lambda 0$). Con el vector nulo incluido, E_λ es un subespacio vectorial de $\mathbb{R}^n$: contiene al 0 y es cerrado por sumas y por múltiplos escalares, como muestra la cuenta de arriba. Recordemos que la *dimensión* de un subespacio es la cantidad de vectores de una base suya; por ejemplo, en $\mathbb{R}^3$ los subespacios son el origen (dimensión 0), las rectas por el origen (dimensión 1), los planos por el origen (dimensión 2) y todo $\mathbb{R}^3$ (dimensión 3).

Ejemplo. Para $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, E_3 es la recta generada por $(1, 1)^T$ y E_1 es la recta generada por $(1, -1)^T$: son las dos rectas punteadas del segundo gráfico.

Multiplicidad geométrica

Para cada autovalor λ , definimos su *multiplicidad geométrica* como la dimensión de su espacio propio:

$$\text{mult}_{\text{geom}}(\lambda) = \dim(E_\lambda) = \dim(\ker(A - \lambda I))$$

Es el número de vectores de una base del espacio propio asociado a λ , es decir, la cantidad de autovectores linealmente independientes que se pueden conseguir para λ .

Entonces podemos preguntarnos:

¿Cuántos vectores necesito para formar una base de ese espacio propio?

Esa cantidad es la multiplicidad geométrica. En términos geométricos: $\text{mult}_{\text{geom}}(\lambda) = 1$ significa que los autovectores de λ llenan una recta, $\text{mult}_{\text{geom}}(\lambda) = 2$ que llenan un plano, y así sucesivamente.

Relación entre ambas multiplicidades

Para todo autovalor λ de A se tiene siempre:

$$1 \leq \text{mult}_{\text{geom}}(\lambda) \leq \text{mult}_{\text{alg}}(\lambda)$$

En particular, si $\text{mult}_{\text{alg}}(\lambda) = 1$ (raíz simple), entonces necesariamente $\text{mult}_{\text{geom}}(\lambda) = 1$: el espacio propio es una recta.

Ejemplo numérico

Considérese

$$B = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}$$

Su polinomio característico es

$$\chi_B(\lambda) = \det(\lambda I - B) = \begin{vmatrix} \lambda - 2 & -1 \\ 0 & \lambda - 2 \end{vmatrix} = (\lambda - 2)^2$$

luego $\lambda = 2$ tiene $\text{mult}_{\text{alg}}(2) = 2$.

Cálculo de los autovectores para $\lambda = 2$ Partimos de

$$B - 2I = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$$

y buscamos todos los vectores $v = (x, y)^T$ tales que

$$(B - 2I)v = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} y \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

De la igualdad $(y, 0)^T = (0, 0)^T$ se obtiene la única ecuación

$$y = 0$$

Así, x es libre y los autovectores asociados a $\lambda = 2$ son

$$v = \begin{pmatrix} x \\ 0 \end{pmatrix}, \quad x \neq 0$$

Por ejemplo, para $x = 1$ podemos tomar como autovector base

$$v = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

Y por lo tanto tenemos multiplicidad geométrica igual a 1, porque el espacio propio es una recta (solamente hay un vector linealmente independiente).

Otro ejemplo numérico

$$C = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

Polinomio característico

$$\chi_C(\lambda) = \det(\lambda I - C) = \begin{vmatrix} \lambda - 2 & 0 \\ 0 & \lambda - 2 \end{vmatrix} = (\lambda - 2)^2$$

Entonces,

$$\lambda = 2 \quad \text{con} \quad \text{mult}_{\text{alg}}(2) = 2$$

Autovectores para $\lambda = 2$

$$C - 2I = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \Rightarrow (C - 2I)v = 0 \quad \text{para todo } v \in \mathbb{R}^2$$

Por lo tanto, todos los vectores no nulos son autovectores y el espacio propio es todo $\mathbb{R}^2$, que tiene dimensión 2:

$$\text{mult}_{\text{geom}}(2) = 2$$

Conclusión: En este caso,

$$\text{mult}_{\text{alg}}(2) = \text{mult}_{\text{geom}}(2) = 2$$

Un conjunto base de autovectores puede ser:

$$v_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad v_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

Un tercer ejemplo Sea $D = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$. Por ser diagonal, sus autovalores son $\lambda_1 = 2$ y $\lambda_2 = 3$, ambos raíces simples; luego, por la relación $1 \leq \text{mult}_{\text{geom}}(\lambda) \leq \text{mult}_{\text{alg}}(\lambda)$, se tiene $\text{mult}_{\text{alg}} = \text{mult}_{\text{geom}} = 1$ para cada uno, con autovectores $(1, 0)^T$ y $(0, 1)^T$, respectivamente.

Resumen Los tres ejemplos juntos (una fila por autovalor):

Matriz	$\chi(\lambda)$	λ	mult_{alg}	$\text{mult}_{\text{geom}}$	$\text{¿mult}_{\text{geom}} = \text{mult}_{\text{alg}}?$
$B = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}$	$(\lambda - 2)^2$	2	2	1	No
$C = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$	$(\lambda - 2)^2$	2	2	2	Sí
$D = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$	$(\lambda - 2)(\lambda - 3)$	2	1	1	Sí
		3	1	1	Sí

Observemos que B y C tienen el mismo polinomio característico pero distinta multiplicidad geométrica: el polinomio característico determina mult_{alg} , pero no $\text{mult}_{\text{geom}}$.

Ejemplo con una matriz 3×3

Sea

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}$$

Seguimos los cuatro pasos del procedimiento.

Pasos 1 y 2: polinomio característico Formamos $\lambda I - A$:

$$\lambda I - A = \begin{pmatrix} \lambda - 2 & -1 & -1 \\ -1 & \lambda - 2 & -1 \\ -1 & -1 & \lambda - 2 \end{pmatrix}$$

y calculamos su determinante con la regla de Sarrus (las diagonales dan $(\lambda - 2)^3$, -1 y -1 ; las antidiagonales dan $\lambda - 2$ tres veces):

$$\chi_A(\lambda) = (\lambda - 2)^3 + (-1) + (-1) - [(\lambda - 2) + (\lambda - 2) + (\lambda - 2)] = (\lambda - 2)^3 - 3(\lambda - 2) - 2$$

Desarrollando,

$$\chi_A(\lambda) = \lambda^3 - 6\lambda^2 + 9\lambda - 4$$

Paso 3: autovalores Buscamos las raíces de $\lambda^3 - 6\lambda^2 + 9\lambda - 4 = 0$. Como el polinomio es mónico y tiene coeficientes enteros, sus raíces enteras (si las hay) son divisores del término independiente -4 , es decir, $\pm 1, \pm 2, \pm 4$. Probando, $\lambda = 1$ es raíz, porque $1 - 6 + 9 - 4 = 0$. Dividimos por $\lambda - 1$ con la regla de Ruffini:

$$\begin{array}{r|rrrr} & 1 & -6 & 9 & -4 \\ 1 & & 1 & -5 & 4 \\ \hline & 1 & -5 & 4 & 0 \end{array}$$

de donde

$$\chi_A(\lambda) = (\lambda - 1)(\lambda^2 - 5\lambda + 4) = (\lambda - 1)(\lambda - 1)(\lambda - 4) = (\lambda - 1)^2(\lambda - 4)$$

Por lo tanto

$$\lambda_1 = 1 \quad (\text{mult}_{\text{alg}}(1) = 2), \quad \lambda_2 = 4 \quad (\text{mult}_{\text{alg}}(4) = 1)$$

Chequeo con traza y determinante Tenemos $\text{tr}(A) = 2 + 2 + 2 = 6$ y $\det(A) = 4$ (por Sarrus, $8 + 1 + 1 - 2 - 2 - 2 = 4$). Contando cada autovalor tantas veces como su multiplicidad algebraica:

$$1 + 1 + 4 = 6 = \text{tr}(A), \quad 1 \cdot 1 \cdot 4 = 4 = \det(A)$$

También se ve en los coeficientes de $\chi_A(\lambda) = \lambda^3 - 6\lambda^2 + 9\lambda - 4$: $c_2 = -6 = -\text{tr}(A)$ y $c_0 = -4 = (-1)^3 \det(A)$. Aquí, con $n = 3$, el factor $(-1)^n$ sí se nota.

Paso 4: autovectores Para cada autovalor resolvemos $(A - \lambda I)v = 0$, con $v = (x, y, z)^T$.

Para $\lambda = 4$ Calculamos

$$A - 4I = \begin{pmatrix} -2 & 1 & 1 \\ 1 & -2 & 1 \\ 1 & 1 & -2 \end{pmatrix}$$

y resolvemos $(A - 4I)v = 0$:

$$\begin{cases} -2x + y + z = 0 \\ x - 2y + z = 0 \\ x + y - 2z = 0 \end{cases}$$

Restando la segunda ecuación de la primera se obtiene $-3x + 3y = 0$, o sea $y = x$; restando la tercera de la segunda, $-3y + 3z = 0$, o sea $z = y$. Luego $x = y = z$ y

$$v = x \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}, \quad x \neq 0$$

El espacio propio E_4 es la recta generada por $v_1 = (1, 1, 1)^T$, y $\text{mult}_{\text{geom}}(4) = 1$.

Para $\lambda = 1$ Calculamos

$$A - I = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}$$

Las tres ecuaciones de $(A - I)v = 0$ son la misma:

$$x + y + z = 0$$

Hay dos variables libres ($z = -x - y$), de modo que

$$v = \begin{pmatrix} x \\ y \\ -x - y \end{pmatrix} = x \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} + y \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}$$

Tomamos $v_2 = (1, 0, -1)^T$ y $v_3 = (0, 1, -1)^T$, que son linealmente independientes. El espacio propio E_1 es el plano $x + y + z = 0$ y $\text{mult}_{\text{geom}}(1) = 2$.

Verificación

$$A v_1 = \begin{pmatrix} 4 \\ 4 \\ 4 \end{pmatrix} = 4 v_1, \quad A v_2 = \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} = 1 \cdot v_2, \quad A v_3 = \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix} = 1 \cdot v_3$$

Conclusión:

$$\text{mult}_{\text{alg}}(1) = \text{mult}_{\text{geom}}(1) = 2, \quad \text{mult}_{\text{alg}}(4) = \text{mult}_{\text{geom}}(4) = 1$$

Aunque $\lambda = 1$ es raíz doble, tiene dos autovectores linealmente independientes: su espacio propio es un plano, no una recta.

16 Formas cuadráticas

Definición

Una forma cuadrática en las variables $x_1, \dots, x_n$ es un polinomio homogéneo de grado dos:

$$q(x_1, \dots, x_n) = a_{11}x_1^2 + a_{22}x_2^2 + \dots + a_{nn}x_n^2 + 2(a_{12}x_1x_2 + a_{13}x_1x_3 + \dots + a_{n-1,n}x_{n-1}x_n)$$

También se puede expresar de forma compacta mediante sumatorias:

$$q(x_1, \dots, x_n) = \sum_{i=1}^n a_{ii}x_i^2 + 2 \sum_{1 \leq i < j \leq n} a_{ij}x_i x_j$$

Representación matricial

Escribiendo

$$x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \quad \text{y} \quad Q = (a_{ij})_{i,j=1}^n$$

con Q simétrica (es decir, $a_{ij} = a_{ji}$), la forma cuadrática se expresa de modo compacto como

$$q(x) = x^T Q x$$

En esta matriz, cada entrada diagonal $Q_{ii} = a_{ii}$ multiplica a x_i^2 . Cada valor a_{ij} fuera de la diagonal aparece dos veces, en las posiciones (i, j) y (j, i) , y entre las dos aportan el término $2a_{ij}x_i x_j$. De ahí sale la regla práctica para armar la matriz:

En la diagonal va el coeficiente de x_i^2 , y fuera de la diagonal va la mitad del coeficiente de $x_i x_j$

¿Por qué pedimos que Q sea simétrica? Una misma forma cuadrática se puede escribir con muchas matrices distintas, porque en $x^T Q x$ solo importa la suma $Q_{ij} + Q_{ji}$, que es el coeficiente de $x_i x_j$. Por ejemplo, $x_1^2 + 4x_1 x_2 + x_2^2$ se obtiene tanto con

$$\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \quad \text{como con} \quad \begin{pmatrix} 1 & 4 \\ 0 & 1 \end{pmatrix}$$

Entre todas esas matrices hay una sola simétrica: la que reparte el coeficiente de cada término cruzado en dos mitades iguales. Trabajamos siempre con esa porque, como veremos más adelante, es la única con la que funciona la clasificación por autovalores.

Ejemplo para 2 variables

Con dos variables, la forma cuadrática general es

$$q(x_1, x_2) = a_{11}x_1^2 + 2a_{12}x_1x_2 + a_{22}x_2^2$$

y su matriz simétrica asociada es

$$Q = \begin{pmatrix} a_{11} & a_{12} \\ a_{12} & a_{22} \end{pmatrix}$$

Es la regla práctica aplicada a dos variables: el coeficiente $2a_{12}$ del término cruzado se reparte en dos mitades iguales, una en cada posición fuera de la diagonal.

Consideremos la forma cuadrática en (x_1, x_2) :

$$q(x_1, x_2) = 5x_1^2 - 4x_1x_2 + 2x_2^2$$

El coeficiente del término cruzado es -4 , así que en cada posición fuera de la diagonal va la mitad, -2 , con el mismo signo. La matriz asociada es

$$Q = \begin{pmatrix} 5 & -2 \\ -2 & 2 \end{pmatrix}$$

con lo que

$$q(x) = x^T Q x = \begin{pmatrix} x_1 & x_2 \end{pmatrix} \begin{pmatrix} 5 & -2 \\ -2 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

Primero multiplicamos las dos primeras matrices:

$$\begin{pmatrix} x_1 & x_2 \end{pmatrix} \begin{pmatrix} 5 & -2 \\ -2 & 2 \end{pmatrix} = \begin{pmatrix} 5x_1 - 2x_2 & -2x_1 + 2x_2 \end{pmatrix}$$

Entonces,

$$q(x) = \begin{pmatrix} 5x_1 - 2x_2 & -2x_1 + 2x_2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

Multiplicando ahora por la última matriz, obtenemos:

$$q(x) = (5x_1 - 2x_2)x_1 + (-2x_1 + 2x_2)x_2$$

Distribuyendo:

$$q(x) = 5x_1^2 - 2x_1x_2 - 2x_1x_2 + 2x_2^2$$

El término $-2x_1x_2$ aparece dos veces, una por cada entrada -2 fuera de la diagonal. Agrupando términos semejantes:

$$q(x) = 5x_1^2 - 4x_1x_2 + 2x_2^2$$

Por lo tanto, al calcular $x^T Q x$, recuperamos exactamente la forma cuadrática original

Ejemplo para 3 variables

Consideremos la forma cuadrática en (x_1, x_2, x_3) :

$$q(x_1, x_2, x_3) = 3x_1^2 + 4x_2^2 + 5x_3^2 + 2x_1x_2 + 4x_1x_3 + 6x_2x_3$$

La matriz asociada es

$$Q = \begin{pmatrix} 3 & 1 & 2 \\ 1 & 4 & 3 \\ 2 & 3 & 5 \end{pmatrix}$$

con lo que

$$q(x) = x^T Q x = \begin{pmatrix} x_1 & x_2 & x_3 \end{pmatrix} \begin{pmatrix} 3 & 1 & 2 \\ 1 & 4 & 3 \\ 2 & 3 & 5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

Primero multiplicamos las dos primeras matrices:

$$\begin{aligned} \begin{pmatrix} x_1 & x_2 & x_3 \end{pmatrix} \begin{pmatrix} 3 & 1 & 2 \\ 1 & 4 & 3 \\ 2 & 3 & 5 \end{pmatrix} \\ = \begin{pmatrix} 3x_1 + x_2 + 2x_3 & x_1 + 4x_2 + 3x_3 & 2x_1 + 3x_2 + 5x_3 \end{pmatrix} \end{aligned}$$

Entonces,

$$q(x) = \begin{pmatrix} 3x_1 + x_2 + 2x_3 & x_1 + 4x_2 + 3x_3 & 2x_1 + 3x_2 + 5x_3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

Multiplicando ahora por la última matriz, obtenemos:

$$q(x) = (3x_1 + x_2 + 2x_3)x_1 + (x_1 + 4x_2 + 3x_3)x_2 + (2x_1 + 3x_2 + 5x_3)x_3$$

Distribuyendo:

$$q(x) = 3x_1^2 + x_1x_2 + 2x_1x_3 + x_1x_2 + 4x_2^2 + 3x_2x_3 + 2x_1x_3 + 3x_2x_3 + 5x_3^2$$

Agrupando términos semejantes:

$$q(x) = 3x_1^2 + 4x_2^2 + 5x_3^2 + 2x_1x_2 + 4x_1x_3 + 6x_2x_3$$

Por lo tanto, al calcular $x^T Q x$, recuperamos exactamente la forma cuadrática original

Clasificación de formas cuadráticas según autovalores

Sea una forma cuadrática $q(x) = x^T Q x$ con matriz simétrica Q^6 y autovalores $\lambda_1, \dots, \lambda_n$.

- **Definida positiva:** $q(x) > 0$ para todo $x \neq 0$. Se cumple si y solo si $\lambda_i > 0 \quad \forall i$.
- **Semidefinida positiva:** $q(x) \geq 0$ para todo x . Se cumple si y solo si $\lambda_i \geq 0 \quad \forall i$.
- **Definida negativa:** $q(x) < 0$ para todo $x \neq 0$. Se cumple si y solo si $\lambda_i < 0 \quad \forall i$.
- **Semidefinida negativa:** $q(x) \leq 0$ para todo x . Se cumple si y solo si $\lambda_i \leq 0 \quad \forall i$.
- **Indefinida:** $q(x)$ toma valores positivos y negativos. Se cumple si y solo si $\exists i, j : \lambda_i > 0, \lambda_j < 0$.

Observación sobre las definiciones. Con estas definiciones, las categorías no son excluyentes: toda forma definida positiva también es semidefinida positiva (si todos los autovalores son > 0 , en particular son ≥ 0), y toda definida negativa también es semidefinida negativa.⁷ La forma nula, $q(x) = 0$, es semidefinida positiva y semidefinida negativa a la vez.

¿Por qué funcionan los autovalores?

Toda matriz simétrica se puede diagonalizar⁸ con una matriz ortogonal.⁹ Este resultado, conocido como *teorema espectral*, es el que necesita la simetría: existe una matriz ortogonal P , cuyas columnas son autovectores

⁶El criterio se aplica a los autovalores de la matriz simétrica Q . Con otra matriz que represente la misma forma, los autovalores pueden dar una clasificación equivocada. Por ejemplo, $q(x_1, x_2) = x_1^2 + 4x_1x_2 + x_2^2$ también se escribe con la matriz no simétrica $\begin{pmatrix} 1 & 4 \\ 0 & 1 \end{pmatrix}$, cuyos autovalores son 1 y 1 (es triangular), lo que sugeriría que la forma es definida positiva. Sin embargo, $q(1, -1) = -2 < 0$. Con la matriz simétrica $\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$ se obtienen los autovalores correctos, 3 y -1 : la forma es indefinida, como se ve en el Ejemplo 2 de esta sección.

⁷Algunos libros reservan la palabra *semidefinida* para las formas que son ≥ 0 (o ≤ 0) sin ser definidas, es decir, las que además tienen algún autovalor igual a 0.

⁸Diagonalizar una matriz cuadrada Q es encontrar una matriz invertible P tal que $P^{-1}QP = D$ sea diagonal. Cuando eso pasa, las columnas de P son autovectores de Q y la diagonal de D tiene los autovalores correspondientes. Para una forma cuadrática, diagonalizar equivale a encontrar un cambio de variables que elimine los términos cruzados.

⁹Una matriz P es ortogonal si $P^T P = I$, es decir, si su inversa es su traspuesta: $P^{-1} = P^T$. Equivalentemente, sus columnas tienen norma 1 y son perpendiculares entre sí. Multiplicar por una matriz ortogonal rota (o refleja) los vectores sin cambiar sus longitudes ni los ángulos entre ellos.

de Q , tal que

$$P^{-1}QP = P^TQP = D = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix}$$

Si hacemos el cambio de variables $x = Py$, la forma cuadrática queda

$$q(x) = x^T Q x = (Py)^T Q (Py) = y^T (P^T Q P) y = y^T D y$$

es decir,

$$q = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \cdots + \lambda_n y_n^2$$

En las nuevas variables no hay términos cruzados, y el signo de q depende solo de los signos de los λ_i . Además, como P es invertible, $x \neq 0$ si y solo si $y \neq 0$. Por eso:

- Si todos los λ_i son positivos, cada término $\lambda_i y_i^2$ es ≥ 0 y, si $y \neq 0$, al menos uno es > 0 : la forma es definida positiva.
- Si todos los λ_i son ≥ 0 , $q \geq 0$ siempre: la forma es semidefinida positiva. Si además algún $\lambda_i = 0$, la forma vale 0 a lo largo del autovector correspondiente, así que no es definida.
- Si hay un $\lambda_i > 0$ y un $\lambda_j < 0$, tomando y con un 1 en la posición i y ceros en el resto queda $q = \lambda_i > 0$, y con un 1 en la posición j queda $q = \lambda_j < 0$: la forma es indefinida.

Los casos negativos son análogos.

Por ejemplo, para la forma $5x_1^2 - 4x_1x_2 + 2x_2^2$ del ejemplo para 2 variables, los autovalores son 1 y 6 y, con

$$P = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & 2 \\ 2 & -1 \end{pmatrix}$$

el cambio $x = Py$ la convierte en $q = y_1^2 + 6y_2^2$, que es definida positiva.

En la sección de formas cuadráticas restringidas vamos a usar la misma idea: un cambio de variables $x = By$ que lleva la forma original a una forma más simple.

Intuición geométrica

La clasificación de una forma cuadrática nos dice qué forma tiene el gráfico de $q(x) = x^T Q x$.

En el caso de dos variables independientes, $q(x_1, x_2)$, podemos dibujar su gráfico en tres dimensiones. La matriz Q determina si ese gráfico se parece a un bowl abierto hacia arriba, a un bowl dado vuelta, a una canaleta (hacia arriba o dada vuelta) o a una silla de montar.

Por eso, los autovalores de Q nos dan información sobre cómo se curva el gráfico en distintas direcciones. Como vimos en la sección anterior, a lo largo de la dirección de cada autovector el gráfico es la curva $\lambda_i t^2$: una parábola hacia arriba si $\lambda_i > 0$, una parábola hacia abajo si $\lambda_i < 0$ y una recta horizontal si $\lambda_i = 0$.

- **Definida positiva:** el gráfico tiene forma de bowl abierto hacia arriba, como un bowl de cereales. El origen es el punto más bajo y, al movernos en cualquier dirección distinta de cero, el valor de q aumenta.
- **Semidefinida positiva:** el gráfico mira hacia arriba, pero puede tener alguna dirección plana. Si la tiene, se parece a una canaleta: sube hacia los costados, pero es plano a lo largo de una recta, donde q vale 0. Un bowl achatado, en cambio, sigue siendo definido positivo: sube en todas las direcciones, aunque sea despacio.
- **Definida negativa:** el gráfico tiene forma de bowl dado vuelta, abierto hacia abajo. El origen es el punto más alto.

- **Semidefinida negativa:** el gráfico mira hacia abajo, pero puede tener alguna dirección plana. Si la tiene, se parece a una canaleta dada vuelta: baja hacia los costados, pero es plano a lo largo de una recta.
- **Indefinida:** el gráfico sube en algunas direcciones y baja en otras. En dos variables independientes, la figura típica es una silla de montar.

Aclaración sobre dimensiones mayores

La intuición del bowl o de la silla de montar es más fácil de visualizar con dos variables, porque el gráfico puede dibujarse en tres dimensiones.

Si la forma cuadrática tiene más variables, el gráfico estaría en más dimensiones y ya no podemos dibujarlo directamente. Sin embargo, la idea sigue siendo la misma: los autovalores indican cómo se comporta $q(x)$ en distintas direcciones.

Si todos los autovalores son positivos, $q(x)$ crece en todas las direcciones; si todos son negativos, decrece en todas las direcciones; si hay positivos y negativos, sube en algunas direcciones y baja en otras

Ejemplo 1

Planteamos una forma cuadrática homogénea de grado 2

$$q(x_1, x_2, x_3) = 2x_1^2 + 2x_2^2 + 3x_3^2 + 2x_1x_2$$

La matriz simétrica asociada es

$$Q = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix}$$

de modo que $q(x) = x^T Q x$

Polinomio característico:

$$\chi_Q(\lambda) = \det(Q - \lambda I) = \det \begin{pmatrix} 2-\lambda & 1 & 0 \\ 1 & 2-\lambda & 0 \\ 0 & 0 & 3-\lambda \end{pmatrix} = (3-\lambda)((2-\lambda)^2 - 1)$$

Factorización: el segundo factor es una diferencia de cuadrados,

$$(2-\lambda)^2 - 1 = ((2-\lambda) - 1)((2-\lambda) + 1) = (1-\lambda)(3-\lambda)$$

así que

$$\chi_Q(\lambda) = (1-\lambda)(3-\lambda)^2$$

Autovalores

$$\lambda_1 = 1, \quad \lambda_2 = 3, \quad \lambda_3 = 3$$

($\lambda = 3$ es raíz doble del polinomio característico)

Como $\lambda_i > 0$ para todo i , concluimos que q es **definida positiva**

Ejemplo 2

Consideremos

$$q(x_1, x_2) = x_1^2 + 4x_1x_2 + x_2^2$$

cuya matriz simétrica es

$$Q = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$$

Polinomio característico:

$$\chi_Q(\lambda) = \det \begin{pmatrix} 1-\lambda & 2 \\ 2 & 1-\lambda \end{pmatrix} = (1-\lambda)^2 - 4 = \lambda^2 - 2\lambda - 3 = (\lambda - 3)(\lambda + 1)$$

Autovalores

$$\lambda_1 = 3, \quad \lambda_2 = -1$$

Hay un autovalor positivo y uno negativo, así que q toma valores de los dos signos. Lo podemos comprobar evaluando en las direcciones de los autovectores, $(1, 1)$ y $(1, -1)$: $q(1, 1) = 6 > 0$ y $q(1, -1) = -2 < 0$. A lo largo de la recta $x_2 = x_1$ el gráfico sube, y a lo largo de la recta $x_2 = -x_1$ baja.

Como $\lambda_1 > 0$ y $\lambda_2 < 0$, concluimos que q es **indefinida**: su gráfico es una silla de montar

Ejemplo 3

Consideremos

$$q(x_1, x_2) = x_1^2 - 2x_1x_2 + x_2^2 = (x_1 - x_2)^2$$

cuya matriz simétrica es

$$Q = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$$

Polinomio característico:

$$\chi_Q(\lambda) = (1 - \lambda)^2 - 1 = \lambda^2 - 2\lambda = \lambda(\lambda - 2)$$

Autovalores

$$\lambda_1 = 0, \quad \lambda_2 = 2$$

Los dos autovalores son ≥ 0 , y uno de ellos es nulo. Se ve también en la fórmula: $q = (x_1 - x_2)^2 \geq 0$, y vale 0 en todos los puntos de la recta $x_1 = x_2$, no solo en el origen. Esa recta es la dirección del autovector de $\lambda = 0$, y es donde el gráfico, una canaleta, es plano.

Como todos los autovalores son ≥ 0 y uno de ellos es 0, concluimos que q es **semidefinida positiva**, pero no definida positiva

Formas cuadráticas restringidas

Una forma cuadrática $q(x) = x^T Q x$ asigna a cada vector x un número real. Estudiar su signo significa preguntar si ese número es siempre positivo, siempre negativo, o si puede cambiar de signo según la dirección elegida.

Cuando aparecen restricciones lineales, ya no estudiamos la forma cuadrática en todo el espacio, sino solamente sobre los vectores que cumplen esas restricciones. Es decir, si las restricciones se escriben como

$$Cx = 0$$

entonces solo nos interesan los vectores x que satisfacen ese sistema de ecuaciones.

La idea central es que las restricciones reducen las direcciones posibles. Por eso, una forma cuadrática que no es definida positiva en todo el espacio podría ser definida positiva si la miramos solamente sobre las direcciones permitidas por las restricciones.

En cambio, una forma que ya es definida no deja de serlo al restringirla: si $q(x) > 0$ para todo $x \neq 0$, en particular $q(x) > 0$ para los $x \neq 0$ que cumplen las restricciones (y lo mismo pasa con las definidas negativas). Por eso:

Conviene empezar clasificando la forma sin restricciones: el análisis restringido aporta información nueva solo cuando la forma sin restricciones es indefinida o semidefinida

Procedimiento

Supongamos que hay m restricciones independientes (ninguna es combinación lineal de las otras) sobre n variables, escritas como $Cx = 0$, donde C es una matriz de $m \times n$ con una fila por restricción. La forma restringida se estudia en tres pasos.

1. Describir los vectores permitidos. Se resuelve el sistema $Cx = 0$ y se escribe la solución general en función de las variables libres. Como las restricciones son independientes, quedan $n - m$ variables libres, y todo vector permitido se puede escribir como

$$x = By$$

donde $y \in \mathbb{R}^{n-m}$ contiene las variables libres y B es una matriz de $n \times (n - m)$ cuyas columnas son las direcciones permitidas. Para comprobar que las columnas de B cumplen las restricciones se verifica que

$$CB = 0$$

Las columnas de B tienen que formar una *base* del conjunto de soluciones: ser linealmente independientes y, entre todas, generar todas las soluciones. Si fueran dependientes, la matriz M del paso siguiente tendría autovalores nulos que no vienen de la forma, y una forma definida parecería semidefinida. Si no generaran todas las soluciones, quedarían direcciones sin revisar, y se podría escapar justamente una dirección donde la forma es negativa. Al resolver el sistema como en los ejemplos, con una columna por cada variable libre, las dos condiciones se cumplen automáticamente.

2. Calcular la matriz restringida. Sustituimos $x = By$ en la forma cuadrática. Usando que $(By)^T = y^T B^T$:

$$q(By) = (By)^T Q (By) = y^T B^T Q B y$$

Por lo tanto, sobre los vectores permitidos, la forma original se convierte en una nueva forma cuadrática en las variables libres:

$$\psi(y) = y^T M y, \quad \text{con} \quad M = B^T Q B$$

La matriz M es simétrica y de tamaño $(n - m) \times (n - m)$. Calcular M es lo mismo que reemplazar la solución de las restricciones en la fórmula de q y simplificar: son dos maneras de hacer la misma cuenta.

3. Clasificar la matriz restringida. Se clasifica M con sus autovalores, igual que en la sección anterior. Su clasificación es la de q restringida a $Cx = 0$.

Ejemplo 1: una restricción que fija una variable

Estudiar el signo de

$$\varphi(x_1, x_2, x_3) = x_1^2 + 2x_2^2 - x_3^2$$

sujeta a la restricción

$$x_3 = 0$$

Sin restricciones. La matriz de la forma es

$$Q = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -1 \end{pmatrix}$$

con autovalores 1, 2 y -1 . Sin restricciones, φ es **indefinida**: por ejemplo, $\varphi(1, 0, 0) = 1 > 0$ y $\varphi(0, 0, 1) = -1 < 0$. Además, φ solo puede ser negativa cuando $x_3 \neq 0$, porque $x_1^2 + 2x_2^2 \geq 0$.

1. Vectores permitidos. Todo vector que cumple $x_3 = 0$ tiene la forma

$$x = \begin{pmatrix} x_1 \\ x_2 \\ 0 \end{pmatrix} = y_1 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} + y_2 \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$$

con variables libres $y_1 = x_1$ e $y_2 = x_2$. Entonces $x = By$, con

$$B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}, \quad y = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$$

La restricción es $Cx = 0$ con $C = (0 \ 0 \ 1)$, y efectivamente $CB = (0 \ 0)$.

2. Matriz restringida. Primero calculamos

$$QB = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 2 \\ 0 & 0 \end{pmatrix}$$

y luego

$$M = B^T QB = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 2 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$$

La forma restringida es

$$\psi(y_1, y_2) = y^T M y = y_1^2 + 2y_2^2$$

Como B solo toma las dos primeras coordenadas, M es la submatriz de Q que queda al tachar la tercera fila y la tercera columna. Esto pasa porque la restricción fija una variable sin mezclarla con las otras.

3. Clasificación. Los autovalores de M son 1 y 2, ambos positivos, así que la forma restringida es definida positiva.

Conclusión: φ es indefinida en $\mathbb{R}^3$, pero definida positiva sobre las direcciones permitidas por $x_3 = 0$. La restricción deja afuera justamente todas las direcciones donde φ podía ser negativa

Ejemplo 2: una restricción que mezcla las variables

Estudiar el signo de

$$\varphi(x_1, x_2, x_3) = 2x_1x_2 + 2x_1x_3 + 2x_2x_3$$

sujeta a

$$x_1 + x_2 + x_3 = 0$$

Sin restricciones. No hay términos al cuadrado, así que la diagonal de la matriz es nula, y cada término $2x_i x_j$ aporta un 1 en las posiciones (i, j) y (j, i) :

$$Q = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix}$$

Su polinomio característico es

$$\chi_Q(\lambda) = \det \begin{pmatrix} -\lambda & 1 & 1 \\ 1 & -\lambda & 1 \\ 1 & 1 & -\lambda \end{pmatrix} = -\lambda^3 + 3\lambda + 2 = -(\lambda - 2)(\lambda + 1)^2$$

así que los autovalores son 2, -1 y -1 . Sin restricciones, φ es **indefinida**: por ejemplo, $\varphi(1, 1, 1) = 6 > 0$ y $\varphi(1, -1, 0) = -2 < 0$.

1. Vectores permitidos. La restricción es $Cx = 0$ con

$$C = \begin{pmatrix} 1 & 1 & 1 \end{pmatrix}$$

Despejando $x_3 = -x_1 - x_2$ y tomando como variables libres $y_1 = x_1$ e $y_2 = x_2$:

$$x = \begin{pmatrix} y_1 \\ y_2 \\ -y_1 - y_2 \end{pmatrix} = y_1 \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} + y_2 \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}$$

Por lo tanto,

$$B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ -1 & -1 \end{pmatrix}$$

Con $m = 1$ restricción en $n = 3$ variables quedan $n - m = 2$ variables libres, por eso B tiene dos columnas. Verificamos que cumplen la restricción:

$$CB = \begin{pmatrix} 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ -1 & -1 \end{pmatrix} = \begin{pmatrix} 0 & 0 \end{pmatrix}$$

2. Matriz restringida. Primero calculamos

$$QB = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ -1 & -1 \end{pmatrix} = \begin{pmatrix} -1 & 0 \\ 0 & -1 \\ 1 & 1 \end{pmatrix}$$

y luego

$$M = B^T QB = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} -1 & 0 \\ 0 & -1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} -2 & -1 \\ -1 & -2 \end{pmatrix}$$

La forma restringida es

$$\psi(y_1, y_2) = y^T M y = -2y_1^2 - 2y_1y_2 - 2y_2^2$$

A diferencia del ejemplo anterior, M no es una submatriz de Q : la restricción mezcla las variables, y aparecen términos al cuadrado que φ no tenía.

Comprobación por sustitución. Reemplazando directamente $x_3 = -y_1 - y_2$ en φ se obtiene la misma forma:

$$\begin{aligned} \varphi(y_1, y_2, -y_1 - y_2) &= 2y_1y_2 + 2y_1(-y_1 - y_2) + 2y_2(-y_1 - y_2) \\ &= 2y_1y_2 - 2y_1^2 - 2y_1y_2 - 2y_1y_2 - 2y_2^2 \\ &= -2y_1^2 - 2y_1y_2 - 2y_2^2 \end{aligned}$$

3. Clasificación. El polinomio característico de M es

$$\det(M - \lambda I) = \det \begin{pmatrix} -2 - \lambda & -1 \\ -1 & -2 - \lambda \end{pmatrix} = (\lambda + 2)^2 - 1 = (\lambda + 1)(\lambda + 3)$$

Los autovalores de M son -1 y -3 , ambos negativos, así que la forma restringida es definida negativa.

Conclusión: φ es indefinida en $\mathbb{R}^3$, pero definida negativa sobre el plano $x_1 + x_2 + x_3 = 0$. El autovector del autovalor positivo es $(1, 1, 1)$, que es perpendicular a ese plano: la restricción deja afuera esa dirección

Ejemplo 3: la misma restricción con otra forma

Con la misma restricción $x_1 + x_2 + x_3 = 0$, estudiemos ahora

$$\varphi(x_1, x_2, x_3) = x_1^2 + x_2^2 - x_3^2$$

Sin restricciones es indefinida: su matriz es diagonal, con autovalores 1, 1 y -1 . La matriz B es la misma del ejemplo anterior, porque depende solo de la restricción. Entonces

$$QB = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ -1 & -1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}$$

$$M = B^T QB = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 0 & -1 \\ -1 & 0 \end{pmatrix}$$

La forma restringida es

$$\psi(y_1, y_2) = -2y_1y_2$$

Los autovalores de M son 1 y -1 (su polinomio característico es $\lambda^2 - 1$), así que la forma restringida sigue siendo indefinida. En las variables originales: $x = (1, -1, 0)$ cumple la restricción y da $\varphi = 2 > 0$, mientras que $x = (1, 1, -2)$ también la cumple y da $\varphi = -2 < 0$.

Conclusión: restringir no siempre cambia la clasificación. Acá el plano permitido contiene direcciones donde φ es positiva y direcciones donde es negativa

Ejemplo 4: dos restricciones

Estudiar el signo de

$$\varphi(x_1, x_2, x_3) = x_1^2 - 2x_1x_2 + 3x_2^2 + x_3^2$$

sujeta a

$$\begin{cases} x_1 + x_2 - x_3 = 0 \\ -x_1 + x_3 = 0 \end{cases} \quad \text{es decir,} \quad C = \begin{pmatrix} 1 & 1 & -1 \\ -1 & 0 & 1 \end{pmatrix}$$

1. Vectores permitidos. De la segunda ecuación se obtiene $x_3 = x_1$. Sustituyendo en la primera queda $x_1 + x_2 - x_1 = 0$, es decir, $x_2 = 0$. Entonces todo vector permitido es

$$x = \begin{pmatrix} x_1 \\ 0 \\ x_1 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} y, \quad \text{con } y = x_1$$

Con $m = 2$ restricciones en $n = 3$ variables queda $n - m = 1$ variable libre, así que B tiene una sola columna:

$$B = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}, \quad CB = \begin{pmatrix} 1+0-1 \\ -1+0+1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

2. Matriz restringida. La matriz de la forma es

$$Q = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 3 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Primero calculamos

$$QB = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 3 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix}$$

y luego

$$M = B^T QB = \begin{pmatrix} 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix} = (2)$$

La forma restringida es $\psi(y) = 2y^2$.

3. Clasificación. Como $2y^2 > 0$ para todo $y \neq 0$, la forma restringida es definida positiva.

Cuando queda una sola variable libre, el conjunto permitido es una recta y M es un número: la forma restringida siempre es del tipo cy^2 , y su signo es el signo de c .

En este ejemplo el resultado se podía anticipar, porque φ ya es definida positiva sin restricciones. Los autovalores de Q son 1, por la tercera variable, y $2 \pm \sqrt{2}$, las raíces de $\lambda^2 - 4\lambda + 2$, que es el polinomio característico del bloque $\begin{pmatrix} 1 & -1 \\ -1 & 3 \end{pmatrix}$. Todos son positivos.

Conclusión: φ es definida positiva sobre la recta que determinan las dos restricciones. Como ya lo era en todo $\mathbb{R}^3$, la restricción no aporta información nueva

17 Menores

Definiciones de menores

Sea $A = (a_{ij})_{i,j=1}^n \in \mathbb{R}^{n \times n}$ una matriz simétrica (aunque las definiciones de menores se aplican a cualquier matriz cuadrada, el contexto de formas cuadráticas usualmente implica simetría).

Notación. En todo el capítulo, el supraíndice entre paréntesis indica el *orden* del menor (el tamaño de la submatriz) y el subíndice indica las filas y columnas que se toman para calcularlo. En el subíndice, los índices de cada conjunto se escriben seguidos y sin llaves, como en a_{13} . El paréntesis evita confundir el orden con una potencia: $\Delta^{(2)}$ es un menor de orden 2, no Δ al cuadrado.

Menor (general) de orden k . Un *menor (general) de orden k* de A es el determinante de una submatriz $k \times k$ de A . Esta submatriz se forma seleccionando un conjunto $I = \{i_1, \dots, i_k\}$ de k índices de filas (con $i_1 < i_2 < \dots < i_k$) y un conjunto $J = \{j_1, \dots, j_k\}$ de k índices de columnas (con $j_1 < j_2 < \dots < j_k$). Si $A[I, J]$ denota la submatriz formada por las filas en I y las columnas en J , es decir, $A[I, J] = (a_{i_p j_q})_{p,q=1}^k$, el menor es

$$M_{I,J}^{(k)} = \det(A[I, J])$$

En el subíndice van primero las filas y después, separadas por una coma, las columnas. Por ejemplo, con las filas 1 y 3 y las columnas 2 y 3:

$$M_{13,23}^{(2)} = \det \begin{pmatrix} a_{12} & a_{13} \\ a_{32} & a_{33} \end{pmatrix}$$

Menor principal de orden k . Un *menor principal de orden k* es un menor de orden k donde el conjunto de índices de las filas seleccionadas es el mismo que el conjunto de índices de las columnas seleccionadas. Como las filas y las columnas coinciden, en el subíndice alcanza con escribir un solo conjunto: si $I = \{i_1, \dots, i_k\} \subseteq \{1, 2, \dots, n\}$ con $i_1 < i_2 < \dots < i_k$, el menor principal asociado a I es

$$\Delta_I^{(k)} = M_{I,I}^{(k)} = \det(A[I, I])$$

donde $A[I, I] = (a_{i_p i_q})_{p,q=1}^k$. Estos son los determinantes de las submatrices principales de A . Por ejemplo, con las filas y columnas 1 y 3:

$$\Delta_{13}^{(2)} = \det \begin{pmatrix} a_{11} & a_{13} \\ a_{31} & a_{33} \end{pmatrix}$$

Menor principal líder de orden k . Un *menor principal líder* de orden k (también llamado *inicial* o *dominante*) es el menor principal obtenido al seleccionar las primeras k filas y las primeras k columnas de A , es decir, $I = \{1, 2, \dots, k\}$. Como ese conjunto queda determinado por el orden, alcanza con el supraíndice¹⁰:

$$\Delta^{(k)} = \Delta_{12\dots k}^{(k)} = \det \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1k} \\ a_{21} & a_{22} & \cdots & a_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ a_{k1} & a_{k2} & \cdots & a_{kk} \end{pmatrix}$$

Para $k = n$ hay un único menor principal, que coincide con el líder: $\Delta^{(n)} = \det A$. En general, una matriz $n \times n$ tiene $\binom{n}{k}^2$ menores de orden k , $\binom{n}{k}$ menores principales de orden k y un único menor principal líder de orden k . En total tiene $2^n - 1$ menores principales: 7 si $n = 3$ y 15 si $n = 4$.

En resumen, para una matriz A

¹⁰En otros libros se escribe $|A_k|$ en lugar de $\Delta^{(k)}$, donde A_k es la submatriz $k \times k$ superior izquierda de A .

- *Menor (general) de orden k , $M_{I,J}^{(k)}$* : determinante de cualquier submatriz $k \times k$ (los índices de las k filas elegidas pueden ser distintos de los índices de las k columnas elegidas). Ejemplo: $M_{13,23}^{(2)}$.
- *Menor principal de orden k , $\Delta_I^{(k)}$* : determinante de una submatriz $k \times k$ formada tomando el mismo conjunto I de k índices para las filas y para las columnas. Ejemplo: $\Delta_{13}^{(2)} = M_{13,13}^{(2)}$.
- *Menor principal líder de orden k , $\Delta^{(k)}$* : determinante de la submatriz $k \times k$ superior izquierda de A . Es un caso particular de menor principal. Ejemplo: $\Delta^{(2)} = \Delta_{12}^{(2)}$.

Ejemplo: menores de una matriz 3×3

Sea

$$A = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 3 & 1 \\ 0 & 1 & 2 \end{pmatrix}$$

1. Menores de orden 1 (todos los elementos de A , $M_{i,j}^{(1)} = a_{ij}$):

$$\begin{array}{lll} M_{1,1}^{(1)} = 2 & M_{1,2}^{(1)} = -1 & M_{1,3}^{(1)} = 0 \\ M_{2,1}^{(1)} = -1 & M_{2,2}^{(1)} = 3 & M_{2,3}^{(1)} = 1 \\ M_{3,1}^{(1)} = 0 & M_{3,2}^{(1)} = 1 & M_{3,3}^{(1)} = 2 \end{array}$$

2. Menores principales de orden 1: Son los elementos de la diagonal, $\Delta_i^{(1)} = M_{i,i}^{(1)}$:

$$\Delta_1^{(1)} = 2 \quad \Delta_2^{(1)} = 3 \quad \Delta_3^{(1)} = 2$$

3. Menores de orden 2 (todas las submatrices 2×2): En la fila I y la columna J de la tabla está $M_{I,J}^{(2)}$, calculado con las filas I y las columnas J de A . Por ejemplo, $M_{12,13}^{(2)} = 2$:

	$J = \{1, 2\}$	$J = \{1, 3\}$	$J = \{2, 3\}$
$I = \{1, 2\}$	$\det \begin{pmatrix} 2 & -1 \\ -1 & 3 \end{pmatrix} = 5$	$\det \begin{pmatrix} 2 & 0 \\ -1 & 1 \end{pmatrix} = 2$	$\det \begin{pmatrix} -1 & 0 \\ 3 & 1 \end{pmatrix} = -1$
$I = \{1, 3\}$	$\det \begin{pmatrix} 2 & -1 \\ 0 & 1 \end{pmatrix} = 2$	$\det \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} = 4$	$\det \begin{pmatrix} -1 & 0 \\ 1 & 2 \end{pmatrix} = -2$
$I = \{2, 3\}$	$\det \begin{pmatrix} -1 & 3 \\ 0 & 1 \end{pmatrix} = -1$	$\det \begin{pmatrix} -1 & 1 \\ 0 & 2 \end{pmatrix} = -2$	$\det \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix} = 5$

Como A es simétrica, $M_{I,J}^{(2)} = M_{J,I}^{(2)}$: la tabla es simétrica respecto de su diagonal.

4. Menores principales de orden 2: Son los de la diagonal de la tabla ($I = J$):

$$\Delta_{12}^{(2)} = 5 \quad \Delta_{13}^{(2)} = 4 \quad \Delta_{23}^{(2)} = 5$$

5. Menores principales líderes: Son los menores principales $\Delta_1^{(1)}$, $\Delta_{12}^{(2)}$ y $\Delta_{123}^{(3)}$:

$$\Delta^{(1)} = \det(2) = 2 \quad \Delta^{(2)} = \det \begin{pmatrix} 2 & -1 \\ -1 & 3 \end{pmatrix} = 5 \quad \Delta^{(3)} = \det A = 8$$

Clasificación de formas cuadráticas mediante menores

Sea la forma cuadrática

$$Q(x) = x^T A x$$

con A simétrica y $x \in \mathbb{R}^n$. Usamos la notación de la sección anterior: $\Delta^{(k)}$ es el menor principal líder de orden k y $\Delta_I^{(k)}$ es el menor principal de orden k asociado a un conjunto $I \subseteq \{1, \dots, n\}$ de k índices.

Criterio de Sylvester (definitud estricta)

- Q es *definida positiva* si y solo si

$$\Delta^{(k)} > 0 \quad \text{para todo } k = 1, \dots, n$$

- Q es *definida negativa* si y solo si

$$(-1)^k \Delta^{(k)} > 0 \quad \text{para todo } k = 1, \dots, n$$

Criterio para semidefinitud

- Q es *semidefinida positiva* si y solo si todos sus menores principales son no negativos: $\Delta_I^{(k)} \geq 0$ para todo $k = 1, \dots, n$ y todo $I \subseteq \{1, \dots, n\}$ con k elementos.
- Q es *semidefinida negativa* si y solo si $(-1)^k \Delta_I^{(k)} \geq 0$ para todo $k = 1, \dots, n$ y todo $I \subseteq \{1, \dots, n\}$ con k elementos.

Criterio para formas cuadráticas indefinidas

Q es *indefinida* si y solo si no es semidefinida positiva ni semidefinida negativa. Por el criterio anterior, esto ocurre si y solo si

- algún menor principal de orden par es negativo: $\Delta_I^{(k)} < 0$ con k par, o
- hay dos menores principales de orden impar con signos opuestos: $\Delta_I^{(k)} > 0$ y $\Delta_J^{(m)} < 0$ con k y m impares.

Observaciones

- El criterio de Sylvester da condiciones necesarias y suficientes para la *definitud* de Q . Para la *semidefinitud*, en cambio, pedir lo mismo a los menores líderes con desigualdad débil ($\Delta^{(k)} \geq 0$, o $(-1)^k \Delta^{(k)} \geq 0$) es necesario pero no suficiente: hay que revisar todos los menores principales $\Delta_I^{(k)}$.
- Toda matriz definida positiva es también semidefinida positiva, y toda matriz definida negativa es también semidefinida negativa.

Algunos casos posibles con una matriz simétrica 4×4

Sea A una matriz simétrica 4×4 y sean $\Delta^{(1)}, \Delta^{(2)}, \Delta^{(3)}, \Delta^{(4)}$ sus menores principales líderes. En la práctica conviene empezar por ellos: si cumplen alguna de las dos condiciones del criterio de Sylvester, A es definida; si alguno de orden par es negativo, o dos de orden impar tienen signos opuestos, A es indefinida; si no ocurre nada de esto, hay que revisar todos los menores principales.

- (a) Si $\Delta^{(1)} > 0, \Delta^{(2)} > 0, \Delta^{(3)} > 0$ y $\Delta^{(4)} > 0$, entonces A es definida positiva.
- (b) Si $\Delta^{(1)} < 0, \Delta^{(2)} > 0, \Delta^{(3)} < 0$ y $\Delta^{(4)} > 0$, entonces A es definida negativa.
- (c) Si $\Delta^{(1)} > 0, \Delta^{(2)} > 0, \Delta^{(3)} = 0$ y $\Delta^{(4)} < 0$, entonces A es indefinida debido a $\Delta^{(4)} < 0$.
- (d) Si $\Delta^{(1)} < 0, \Delta^{(2)} < 0, \Delta^{(3)} < 0$ y $\Delta^{(4)} < 0$, entonces A es indefinida debido a $\Delta^{(2)} < 0$ y $\Delta^{(4)} < 0$.
- (e) Si $\Delta^{(1)} = 0, \Delta^{(2)} < 0, \Delta^{(3)} > 0$ y $\Delta^{(4)} = 0$, entonces A es indefinida debido a $\Delta^{(2)} < 0$.
- (f) Si $\Delta^{(1)} > 0, \Delta^{(2)} = 0, \Delta^{(3)} = 0$ y $\Delta^{(4)} = 0$, entonces A no es definida. No es semidefinida negativa, pero puede ser semidefinida positiva. Para comprobar la semidefinitud positiva, es necesario verificar los 15 menores principales de A , no solo los cuatro líderes. Si ninguno es negativo, A es semidefinida positiva; si al menos uno es negativo, A es indefinida. En 3×3 , las matrices C y E de los ejemplos de más abajo muestran las dos posibilidades.
- (g) Si $\Delta^{(1)} = 0, \Delta^{(2)} = 0, \Delta^{(3)} = 0$ y $\Delta^{(4)} = 0$, entonces A no es definida, pero puede ser semidefinida positiva o semidefinida negativa (o indefinida). Para decidirlo, es necesario comprobar nuevamente los 15 menores principales de A .

Ejemplo

Sea

$$B = \begin{pmatrix} -4 & 1 & 0 \\ 1 & -3 & 1 \\ 0 & 1 & -2 \end{pmatrix}$$

Menor principal líder de orden 1

$$\Delta^{(1)} = \det(-4) = -4$$

Menor principal líder de orden 2

$$\Delta^{(2)} = \det \begin{pmatrix} -4 & 1 \\ 1 & -3 \end{pmatrix} = (-4)(-3) - 1 \cdot 1 = 12 - 1 = 11$$

Menor principal líder de orden 3

$$\begin{aligned} \Delta^{(3)} &= \det B = -4 \det \begin{pmatrix} -3 & 1 \\ 1 & -2 \end{pmatrix} - 1 \det \begin{pmatrix} 1 & 1 \\ 0 & -2 \end{pmatrix} + 0 \det \begin{pmatrix} 1 & -3 \\ 0 & 1 \end{pmatrix} \\ &= -4((-3)(-2) - 1 \cdot 1) - 1(1 \cdot (-2) - 1 \cdot 0) \\ &= -4(6 - 1) - 1(-2) = -20 + 2 = -18 \end{aligned}$$

Verificación del criterio de Sylvester

$$\begin{aligned} (-1)^1 \Delta^{(1)} &= -(-4) = 4 > 0 & (-1)^2 \Delta^{(2)} &= 11 > 0 \\ (-1)^3 \Delta^{(3)} &= -(-18) = 18 > 0 \end{aligned}$$

Por tanto B es definida negativa.

Otro ejemplo

Sea

$$C = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

Menores principales de orden 1

$$\Delta_1^{(1)} = 1 \quad \Delta_2^{(1)} = 1 \quad \Delta_3^{(1)} = 0$$

Menores principales de orden 2

$$\Delta_{12}^{(2)} = \det \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = 0 \quad \Delta_{13}^{(2)} = \det \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = 0 \quad \Delta_{23}^{(2)} = \det \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = 0$$

Menor principal de orden 3

$$\Delta^{(3)} = \det C = 0$$

Como todos los menores principales son ≥ 0 , C es semidefinida positiva según el criterio completo de semidefinitud positiva. No es definida positiva, porque $\Delta^{(2)} = \Delta_{12}^{(2)} = 0$ y el criterio de Sylvester pide $\Delta^{(k)} > 0$ para todo k .

Otro ejemplo

Sea

$$D = \begin{pmatrix} -1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

Menores principales de orden 1

$$\Delta_1^{(1)} = -1 \quad \Delta_2^{(1)} = -2 \quad \Delta_3^{(1)} = 0$$

Menores principales de orden 2

$$\Delta_{12}^{(2)} = \det \begin{pmatrix} -1 & 0 \\ 0 & -2 \end{pmatrix} = (-1)(-2) - 0 \cdot 0 = 2$$

$$\Delta_{13}^{(2)} = \det \begin{pmatrix} -1 & 0 \\ 0 & 0 \end{pmatrix} = (-1) \cdot 0 - 0 \cdot 0 = 0$$

$$\Delta_{23}^{(2)} = \det \begin{pmatrix} -2 & 0 \\ 0 & 0 \end{pmatrix} = (-2) \cdot 0 - 0 \cdot 0 = 0$$

Menor principal de orden 3

$$\Delta^{(3)} = \det D = 0$$

Verificación del criterio de semidefinitud negativa

$$\begin{aligned} (-1)^1 \Delta_1^{(1)} &= (-1)(-1) = 1 \geq 0 & (-1)^1 \Delta_2^{(1)} &= (-1)(-2) = 2 \geq 0 \\ (-1)^1 \Delta_3^{(1)} &= (-1) \cdot 0 = 0 \geq 0 & (-1)^2 \Delta_{12}^{(2)} &= 2 \geq 0 \\ (-1)^2 \Delta_{13}^{(2)} &= 0 \geq 0 & (-1)^2 \Delta_{23}^{(2)} &= 0 \geq 0 \\ (-1)^3 \Delta^{(3)} &= (-1) \cdot 0 = 0 \geq 0 \end{aligned}$$

Por tanto D es semidefinida negativa. No es definida negativa, porque $(-1)^3 \Delta^{(3)} = 0$ y el criterio de Sylvester pide $(-1)^k \Delta^{(k)} > 0$ para todo k .

Otro ejemplo

Sea

$$E = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & -1 \end{pmatrix}$$

Menores principales líderes

$$\Delta^{(1)} = 1 \quad \Delta^{(2)} = \det \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = 0 \quad \Delta^{(3)} = \det E = 0$$

Son los mismos que los de C . Como $\Delta^{(2)} = 0$, E no es definida, y como $\Delta^{(1)} > 0$, tampoco es semidefinida negativa. Que los tres sean ≥ 0 no alcanza para concluir que sea semidefinida positiva: hay que revisar todos los menores principales.

Menores principales de orden 1

$$\Delta_1^{(1)} = 1 \quad \Delta_2^{(1)} = 0 \quad \Delta_3^{(1)} = -1$$

Menores principales de orden 2

$$\begin{aligned} \Delta_{12}^{(2)} &= \det \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = 0 & \Delta_{13}^{(2)} &= \det \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} = -1 \\ \Delta_{23}^{(2)} &= \det \begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix} = 0 \end{aligned}$$

Como $\Delta_{13}^{(2)} = -1 < 0$ es un menor principal de orden par negativo, E es indefinida. También alcanza con $\Delta_1^{(1)} = 1 > 0$ y $\Delta_3^{(1)} = -1 < 0$, dos menores principales de orden impar con signos opuestos.

18 Concavidad y convexidad

Definición de convexidad y concavidad para funciones de una variable

Sea $f: I \subseteq \mathbb{R} \rightarrow \mathbb{R}$, donde I es un intervalo. Decimos que:

- f es *convexa* si para todo $x_1, x_2 \in I$ y todo $t \in [0, 1]$ se cumple

$$f((1-t)x_1 + tx_2) \leq (1-t)f(x_1) + tf(x_2)$$

Intuición geométrica: El término

$$(1-t)f(x_1) + tf(x_2)$$

coincide con el valor que adopta la recta secante en la posición intermedia $(1-t)x_1 + tx_2$. Por tanto, la desigualdad

$$f((1-t)x_1 + tx_2) \leq (1-t)f(x_1) + tf(x_2)$$

expresa que, en cada punto entre x_1 y x_2 , la curva de f nunca queda por encima de esa secante.


- f es *cóncava* si para todo $x_1, x_2 \in I$ y todo $t \in [0, 1]$ se cumple

$$f((1-t)x_1 + tx_2) \geq (1-t)f(x_1) + tf(x_2)$$


Intuición geométrica: Aquí la desigualdad se invierte: entre los puntos dados, el gráfico de f nunca queda por debajo de la recta secante.

En los gráficos siguientes, el punto del medio corresponde a $t = \frac{1}{2}$.

Ejemplo convexo: $f(x) = x^2$



Ejemplo cóncavo: $f(x) = -x^2$




Los dos casos anteriores son de convexidad y concavidad **estrictas**: para cualquier par de puntos distintos, en el interior del segmento la curva queda estrictamente por debajo (o por encima) de la secante. Formalmente, f es *estrictamente convexa* si

$$f((1-t)x_1 + tx_2) < (1-t)f(x_1) + tf(x_2) \quad \text{para todo } x_1 \neq x_2 \text{ en } I \text{ y todo } t \in (0, 1),$$


y es *estrictamente cóncava* si vale lo mismo con la desigualdad $>$.

También puede ocurrir que, para algunos pares de puntos, la secante coincida con la gráfica en un tramo. Ahí la desigualdad se cumple con igualdad y la función es convexa (o cóncava), pero no estrictamente. Es lo que pasa en los dos gráficos siguientes, que tienen un tramo recto en $[-\frac{1}{2}, \frac{1}{2}]$:

Convexa no estricta: $f(x) = \max\{x^2, \frac{1}{4}\}$



Cóncava no estricta: $f(x) = \min\{-x^2, -\frac{1}{4}\}$



Relacionando la concavidad y convexidad con conjuntos convexos

Un conjunto $C \subseteq \mathbb{R}^n$ es *convexo* si, para todo par de puntos $a, b \in C$ y todo $t \in [0, 1]$, el punto $(1-t)a + tb$ también pertenece a C . Es decir, el segmento que une dos puntos cualesquiera de C queda completamente dentro de C .

- *Convexidad*: f es convexa si y solo si su *epígrafo*, la región

$$\{(x, y) \mid x \in I, y \geq f(x)\}$$


es un conjunto convexo. Esto significa que si tomamos dos puntos (x_1, y_1) y (x_2, y_2) por encima del gráfico de f , el segmento que los une nunca pasa por debajo de la curva.

- *Concavidad:* f es cóncava si y solo si su *hipógrafo*, la región


$$\{(x, y) \mid x \in I, y \leq f(x)\}$$

es un conjunto convexo. En este caso, cualquier segmento trazado entre dos puntos por debajo del gráfico de f queda enteramente dentro de esa región.

Epígrafo de $f(x) = x^2$



Hipógrafo de $f(x) = -x^2$



Concavidad y convexidad en $\mathbb{R}^2$

Definición: Sea $f: D \subseteq \mathbb{R}^2 \rightarrow \mathbb{R}$, donde D es un conjunto convexo (así, el segmento entre dos puntos de D queda dentro del dominio).

- f es *convexa* si para todo $(x_1, y_1), (x_2, y_2) \in D$ y todo $t \in [0, 1]$ se cumple

$$f((1-t)(x_1, y_1) + t(x_2, y_2)) \leq (1-t)f(x_1, y_1) + tf(x_2, y_2)$$

- f es *cóncava* si $-f$ es convexa, es decir, si la desigualdad se invierte.

Como en una variable, f es *estrictamente* convexa (o cóncava) si la desigualdad es estricta para todo par de puntos distintos y todo $t \in (0, 1)$. En $\mathbb{R}^n$ las definiciones son las mismas, con puntos de $D \subseteq \mathbb{R}^n$.

Intuición geométrica: La intuición se mantiene. Ahora la gráfica de f es una superficie, y la secante es el segmento que une $(x_1, y_1, f(x_1, y_1))$ con $(x_2, y_2, f(x_2, y_2))$: si f es convexa, la superficie nunca queda por encima de ese segmento. Además, el epígrafo de una función convexa y el hipógrafo de una función cóncava siguen siendo conjuntos convexos.

Criterio de las derivadas segundas

Recordatorio: criterio para funciones de una variable

Sea $g: I \subseteq \mathbb{R} \rightarrow \mathbb{R}$ de clase C^2 en un intervalo I . Entonces

$$\begin{cases} g''(t) \geq 0 & \forall t \in I \implies g \text{ es convexa en } I \\ g''(t) \leq 0 & \forall t \in I \implies g \text{ es cóncava en } I \end{cases}$$

Con desigualdades estrictas, la conclusión también es estricta: si $g''(t) > 0$ para todo $t \in I$, g es estrictamente convexa, y si $g''(t) < 0$ para todo $t \in I$, g es estrictamente cóncava.

Funciones de dos variables

Sea $f: D \subseteq \mathbb{R}^2 \rightarrow \mathbb{R}$ de clase C^2 , con D abierto y convexo. La desigualdad que define la convexidad de f solo involucra puntos de un segmento, así que alcanza con estudiar f sobre cada segmento. Para eso, dados dos puntos $a = (x_1, y_1)$ y $b = (x_2, y_2)$ de D , definimos

$$g(t) = f((1-t)x_1 + tx_2, (1-t)y_1 + ty_2), \quad t \in [0, 1]$$

Vamos a ver que g es convexa, porque su derivada segunda es la forma cuadrática de la hessiana en la dirección del segmento, y que su convexidad se transmite a f .

Intuición sobre g . Para entender qué hace g , primero observemos que

$$(x(t), y(t)) = ((1-t)x_1 + tx_2, (1-t)y_1 + ty_2)$$

es la parametrización del segmento rectilíneo que une los puntos (x_1, y_1) y (x_2, y_2) en el plano. Por tanto,

$$g(t) = f(x(t), y(t))$$

no es más que el valor de f al desplazarnos a lo largo de ese segmento:

- Cuando $t = 0$ estamos en (x_1, y_1) .
- Cuando $t = 1$ estamos en (x_2, y_2) .
- Para $t \in (0, 1)$ recorremos los puntos intermedios.

Paso 1: cálculo de g'' . Por la regla de la cadena aplicada a dos variables:

$$\begin{aligned} g'(t) &= f'_x(x(t), y(t)) \frac{d}{dt}((1-t)x_1 + tx_2) + f'_y(x(t), y(t)) \frac{d}{dt}((1-t)y_1 + ty_2) \\ &= f'_x(x(t), y(t)) (x_2 - x_1) + f'_y(x(t), y(t)) (y_2 - y_1) \\ g''(t) &= \frac{d}{dt} [f'_x(x(t), y(t))] (x_2 - x_1) + \frac{d}{dt} [f'_y(x(t), y(t))] (y_2 - y_1) \\ &= [f''_{xx}(x(t), y(t)) x'(t) + f''_{xy}(x(t), y(t)) y'(t)] (x_2 - x_1) \\ &\quad + [f''_{yx}(x(t), y(t)) x'(t) + f''_{yy}(x(t), y(t)) y'(t)] (y_2 - y_1) \end{aligned}$$

Sabiendo que $x'(t) = x_2 - x_1$ y $y'(t) = y_2 - y_1$:

$$\begin{aligned} g''(t) &= f''_{xx}(x(t), y(t)) (x_2 - x_1) (x_2 - x_1) + f''_{xy}(x(t), y(t)) (y_2 - y_1) (x_2 - x_1) \\ &\quad + f''_{yx}(x(t), y(t)) (x_2 - x_1) (y_2 - y_1) + f''_{yy}(x(t), y(t)) (y_2 - y_1) (y_2 - y_1) \end{aligned}$$

Como f es de clase C^2 , por el teorema de Schwarz $f''_{xy} = f''_{yx}$, y se agrupan los términos mixtos:

$$g''(t) = f''_{xx}(x(t), y(t)) (x_2 - x_1)^2 + 2 f''_{xy}(x(t), y(t)) (x_2 - x_1)(y_2 - y_1) + f''_{yy}(x(t), y(t)) (y_2 - y_1)^2$$

Redefiniendo para mayor claridad:

$$\begin{aligned} w &= x_2 - x_1 & z &= y_2 - y_1 \\ g''(t) &= f''_{xx}(x(t), y(t)) w^2 + 2 f''_{xy}(x(t), y(t)) w z + f''_{yy}(x(t), y(t)) z^2 \\ &= \begin{pmatrix} w & z \end{pmatrix} \begin{pmatrix} f''_{xx}(x(t), y(t)) & f''_{xy}(x(t), y(t)) \\ f''_{xy}(x(t), y(t)) & f''_{yy}(x(t), y(t)) \end{pmatrix} \begin{pmatrix} w \\ z \end{pmatrix} \end{aligned}$$

Paso 2: g es convexa. Si la matriz hessiana $H_f(x, y) = [f''_{ij}(x, y)]$ es semidefinida positiva en todo punto, entonces para cada $t \in [0, 1]$

$$g''(t) \geq 0,$$

y, por el criterio de una variable, g es convexa en $[0, 1]$.

Paso 3: la convexidad de g pasa a f . Definamos la *recta secante* entre $(0, g(0))$ y $(1, g(1))$:

$$L(t) = g(0) + t(g(1) - g(0)) = (1 - t)g(0) + t g(1)$$

Como g es convexa en $[0, 1]$, la definición de convexidad aplicada a los puntos 0 y 1 da

$$g(t) = g((1 - t) \cdot 0 + t \cdot 1) \leq (1 - t)g(0) + t g(1) = L(t)$$

Finalmente, usando $g(0) = f(x_1, y_1)$ y $g(1) = f(x_2, y_2)$, concluimos

$$f((1 - t)(x_1, y_1) + t(x_2, y_2)) = g(t) \leq (1 - t)f(x_1, y_1) + t f(x_2, y_2)$$

Como los puntos y t son arbitrarios, esta es precisamente la condición de convexidad de f en $\mathbb{R}^2$.

De forma análoga, si H_f es semidefinida *negativa*, entonces

$$g''(t) \leq 0 \implies g(t) \geq (1 - t)g(0) + t g(1)$$

y por tanto f es *cóncava*.

Extensión a $\mathbb{R}^n$

El mismo argumento se aplica en $\mathbb{R}^n$. Dados dos puntos $a, b \in D \subseteq \mathbb{R}^n$, la función $g(t) = f((1 - t)a + tb)$ tiene derivada segunda

$$g''(t) = (b - a)^T H_f((1 - t)a + tb) (b - a)$$

Si la matriz hessiana es semidefinida positiva en todo punto, entonces $g''(t) \geq 0$, g es convexa y, por tanto, f es convexa. Análogamente, si la hessiana es semidefinida negativa en todo punto, f es cóncava.

Además, si la hessiana $H_f(x)$ es *definida positiva* en todo punto, entonces f es *estrictamente convexa* (para $a \neq b$ resulta $g''(t) > 0$, y por el caso estricto del criterio de una variable g es estrictamente convexa); y si $H_f(x)$ es *definida negativa* en todo punto, entonces f es *estrictamente cóncava*.

En resumen

Hessiana $H_f(x)$	Condición para todo $x \in D$, $h \in \mathbb{R}^n$		Función f
Semidefinida positiva	$h^T H_f(x) h \geq 0$	$\iff$	Convexa
Definida positiva	$h^T H_f(x) h > 0$ si $h \neq 0$	$\implies$	Estr. convexa
Semidefinida negativa	$h^T H_f(x) h \leq 0$	$\iff$	Cóncava
Definida negativa	$h^T H_f(x) h < 0$ si $h \neq 0$	$\implies$	Estr. cóncava

(Aquí D , el dominio de f , es abierto y convexo. Las implicaciones $\implies$ no valen al revés.¹¹)

Ejemplo

Consideremos la función

$$f(x, y) = x^2 + 2xy + 3y^2 \quad (x, y) \in \mathbb{R}^2$$

Cálculo de la hessiana

Las derivadas parciales primeras son

$$f'_x = 2x + 2y, \quad f'_y = 2x + 6y$$

y las segundas son

$$f''_{xx} = 2, \quad f''_{xy} = 2, \quad f''_{yy} = 6$$

Por tanto la matriz hessiana es

$$H_f(x, y) = \begin{pmatrix} 2 & 2 \\ 2 & 6 \end{pmatrix}$$

Comprobación de definitud (criterio de Sylvester).

Calculamos los menores principales líderes:

$$\Delta^{(1)} = f''_{xx} = 2 > 0 \quad \Delta^{(2)} = \det H_f = (2)(6) - (2)^2 = 12 - 4 = 8 > 0$$

Como $\Delta^{(1)} > 0$ y $\Delta^{(2)} > 0$, H_f es *definida positiva* en todo $\mathbb{R}^2$.

Conclusión: al ser su hessiana definida positiva para todo (x, y) , la función f es *estrictamente convexa* en $\mathbb{R}^2$.

Otro ejemplo

Consideremos

$$f(x, y) = -x^2 + 2xy - y^2 \quad (x, y) \in \mathbb{R}^2$$

Cálculo de la hessiana

Las derivadas parciales primeras son

$$f'_x = -2x + 2y, \quad f'_y = 2x - 2y$$

y las segundas son

$$f''_{xx} = -2, \quad f''_{xy} = 2, \quad f''_{yy} = -2$$

Por tanto la matriz hessiana es

$$H_f(x, y) = \begin{pmatrix} -2 & 2 \\ 2 & -2 \end{pmatrix}$$

Comprobación de semidefinitud.

Los menores principales líderes son

$$\Delta^{(1)} = f''_{xx} = -2 < 0 \quad \Delta^{(2)} = \det H_f = (-2)(-2) - 2^2 = 4 - 4 = 0$$

¹¹Si D es abierto, las implicaciones para la convexidad y la concavidad valen también al revés. Si f es convexa, para cada $x \in D$ y cada dirección h la función $t \mapsto f(x + th)$ es convexa cerca de $t = 0$, así que su derivada segunda en $t = 0$, que es $h^T H_f(x) h$, es mayor o igual que cero: $H_f(x)$ es semidefinida positiva. Para las versiones estrictas, en cambio, la recíproca es falsa: $f(x) = x^4$ es estrictamente convexa y $f''(0) = 0$. En dos variables, $x^4 + y^4$ es estrictamente convexa y su hessiana en el origen es la matriz nula.

Como $\Delta^{(2)} = 0$, H_f no es definida negativa: el criterio de Sylvester pediría $(-1)^2 \Delta^{(2)} > 0$. Para ver si es semidefinida negativa hay que revisar todos los menores principales, como en el criterio de semidefinitud del capítulo de menores:

$$(-1)^1 \Delta_1^{(1)} = 2 \geq 0 \quad (-1)^1 \Delta_2^{(1)} = 2 \geq 0 \quad (-1)^2 \Delta_{12}^{(2)} = 0 \geq 0$$

Entonces H_f es *semidefinida negativa* en todo $\mathbb{R}^2$, pero no definida negativa, y f es cóncava.

¿Es estrictamente cóncava?

Que la hessiana no sea definida negativa no alcanza para responder, porque esa condición es suficiente pero no necesaria (ver la nota 11). Lo comprobamos con la definición. Como $f(x, y) = -(x - y)^2$, la función vale 0 en todos los puntos de la recta $y = x$. Con $a = (0, 0)$, $b = (1, 1)$ y $t = \frac{1}{2}$,

$$f\left(\frac{1}{2}a + \frac{1}{2}b\right) = f\left(\frac{1}{2}, \frac{1}{2}\right) = 0 = \frac{1}{2}f(a) + \frac{1}{2}f(b)$$

La desigualdad se cumple con igualdad, así que f no es estrictamente cóncava.

Lo mismo pasa sobre cualquier recta paralela a $y = x$: como f solo depende de la diferencia $x - y$, es constante a lo largo de cada una. Su gráfico es una canaleta dada vuelta, con la parte más alta sobre la recta $y = x$. Esa es justamente la dirección en la que se anula la forma cuadrática de la hessiana, y por eso la hessiana no es definida: con $h = (1, 1)^T$,

$$h^T H_f h = \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} -2 & 2 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix} = 0$$

Conclusión: la hessiana de f es semidefinida negativa, pero no definida negativa: f es cóncava, pero no estrictamente cóncava.

Cuasiconcavidad y cuasiconvexidad

En economía, de una función de utilidad interesa menos su concavidad que la forma de sus curvas de indiferencia: lo importante es que el conjunto de canastas al menos tan buenas como una dada sea convexo. Esa propiedad es la cuasiconcavidad. En particular, la convexidad estricta al origen de las curvas de indiferencia, que vimos en el capítulo *Curvas de nivel en Economía*, corresponde a una función de utilidad estrictamente cuasicóncava.

Conjuntos de nivel

Sea $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, con D convexo. Recordemos que la *curva de nivel* de f para un valor α es el conjunto

$$\{x \in D : f(x) = \alpha\}$$

Los conjuntos de nivel (subniveles y superniveles) son las regiones delimitadas por esas curvas:

$$L_\alpha(f) = \{x \in D : f(x) \leq \alpha\}$$

$$U^\alpha(f) = \{x \in D : f(x) \geq \alpha\}$$

Definición

- f es *cuasiconvexa* si todos sus *subniveles* $L_\alpha(f)$ son conjuntos convexos.
- f es *cuasicóncava* si todos sus *superniveles* $U^\alpha(f)$ son conjuntos convexos.

Equivalentemente, f es cuasiconvexa si y solo si, para todo $a, b \in D$ y todo $t \in [0, 1]$,

$$f((1 - t)a + tb) \leq \max\{f(a), f(b)\},$$

y es cuasicóncava si y solo si

$$f((1-t)a + tb) \geq \min\{f(a), f(b)\}.$$

En palabras: a lo largo de cualquier segmento, una función cuasicóncava nunca baja del menor de sus dos valores en los extremos, y una cuasiconvexa nunca supera el mayor.

Con esta forma se ve enseguida que:

- Toda función *cóncava* es *cuasicóncava*, porque $(1-t)f(a) + tf(b)$ es un promedio de $f(a)$ y $f(b)$, y un promedio nunca es menor que el mínimo:

$$f((1-t)a + tb) \geq (1-t)f(a) + tf(b) \geq \min\{f(a), f(b)\}$$

- Toda función *convexa* es *cuasiconvexa*, por el argumento análogo con el máximo.

Versión estricta

Un conjunto C es *estrictamente convexo* si, para todo par de puntos distintos $a, b \in C$ y todo $t \in (0, 1)$, el punto $(1-t)a + tb$ es un punto interior de C . Es decir: no solo C es convexo, sino que además su borde no tiene tramos rectos. Para f continua en un dominio abierto:

- f es **estrictamente cuasiconvexa** si cada subnivel $L_\alpha(f)$ es un conjunto estrictamente convexo y f no tiene mesetas.
- f es **estrictamente cuasicóncava** si cada supernivel $U^\alpha(f)$ es un conjunto estrictamente convexo y f no tiene mesetas.

Que f no tenga *mesetas* significa que no hay ningún disco, por chico que sea, en el que f tome el mismo valor en todos los puntos.¹² Equivalentemente, las desigualdades de la definición son estrictas: para todo $a \neq b$ en D y todo $t \in (0, 1)$,

$$f((1-t)a + tb) < \max\{f(a), f(b)\} \quad (\text{estrictamente cuasiconvexa})$$

$$f((1-t)a + tb) > \min\{f(a), f(b)\} \quad (\text{estrictamente cuasicóncava})$$


Ejemplos gráficos

En los siguientes ejemplos graficamos una curva de nivel de cada función y sombreamos el supernivel o el subnivel correspondiente. Cada gráfico muestra un solo nivel α , pero la definición pide que los superniveles (o subniveles) sean convexos para *todo* α ; en estas funciones, los demás niveles tienen la misma forma que el dibujado. Para mostrar que una función *no* es cuasicóncava (o cuasiconvexa), en cambio, alcanza con un solo nivel cuyo supernivel (o subnivel) no sea convexo, como en el último gráfico de los casos univariados.


¹²El disco de centro c y radio $r > 0$ es el conjunto de los puntos que están a distancia menor que r de c : la región encerrada por una circunferencia. En más de dos variables se llama bola, y en una variable es el intervalo $(c-r, c+r)$. Que f tome el mismo valor en muchos puntos cercanos entre sí no es una meseta: eso pasa a lo largo de cualquier curva de nivel. En una meseta, f toma el mismo valor en todos los puntos alrededor de uno dado, en todas las direcciones. En una variable, la condición dice que el gráfico de f no tiene tramos horizontales.

La condición no se puede omitir. Una función constante tiene como superniveles a todo su dominio o al conjunto vacío, que son estrictamente convexos, y sin embargo no es estrictamente cuasicóncava: al maximizarla, todos los puntos son óptimos. Un ejemplo menos trivial es $f(x, y) = \min\{0, 1 - \sqrt{x^2 + y^2}\}$: todos sus superniveles son discos, pero vale 0 en todo el disco unitario, como una curva de indiferencia “gruesa”. Sin esta condición fallaría la unicidad del óptimo de las funciones estrictamente cuasicóncavas que usaremos en optimización con restricciones.


Estrictamente cuasicóncava, pero no cóncava: $u(x, y) = xy, x > 0, y > 0$




Estrictamente cuasiconvexa: $v(x, y) = x^2 + y^2$




Cuasicóncava (no estricta): $u(x, y) = \min\{x, y\}$



Cuasiconvexa (no estricta): $f(x, y) = \max\{x, y\}$




Cuasiconvexa (no estricta) y cuasicóncava (no estricta): $u(x, y) = x + y$






Casos univariables

Para funciones de una sola variable el análisis gráfico es análogo. Los subniveles y superniveles son ahora subconjuntos de la recta: son convexos cuando forman un solo intervalo y no lo son cuando quedan cortados en varios pedazos.

Cuasicóncava



La función del gráfico anterior es cóncava. La campana $\varphi(x) = e^{-(x-1)^2}$ muestra que la cuasiconcavidad es más débil: es cuasicóncava, porque crece hasta $x = 1$ y después decrece, así que sus superniveles son intervalos; pero no es cóncava, porque en las colas se curva hacia arriba ($\varphi''(x) > 0$ cuando $|x - 1| > 1/\sqrt{2}$) y ahí la curva queda por debajo de sus secantes.



Teorema (monotonicidad, cuasiconcavidad y cuasiconvexidad en una variable). Sea $f: I \rightarrow \mathbb{R}$, con $I \subseteq \mathbb{R}$ un intervalo. Si f es creciente o decreciente en I , entonces es cuasicóncava y cuasiconvexa en I . Si f es derivable, alcanza con que $f'(x) \geq 0$ para todo $x \in I$, o $f'(x) \leq 0$ para todo $x \in I$.

La razón es que los subniveles y los superniveles de una función monótona son siempre intervalos. En una variable vale además una caracterización completa: una función continua es cuasicóncava si y solo si es monótona o primero crece y después decrece (tiene un solo pico), y es cuasiconvexa si y solo si es monótona o primero decrece y después crece.

Criterio de hessiano orlado para cuasiconvexidad y cuasiconcavidad

Sea $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ de clase C^2 en un conjunto D abierto y convexo. Definimos el *hessiano orlado* de f en x como la matriz

$$B(x) = \begin{pmatrix} 0 & \nabla f(x)^T \\ \nabla f(x) & H_f(x) \end{pmatrix}$$

donde $H_f(x)$ es la hessiana usual de f . Para $k = 1, \dots, n$ llamamos B_k a la submatriz formada por el borde y las primeras k variables, y $|B_k|$ a su determinante:

$$B_k = \begin{pmatrix} 0 & f'_1 & \cdots & f'_k \\ f'_1 & f''_{11} & \cdots & f''_{1k} \\ \vdots & \vdots & \ddots & \vdots \\ f'_k & f''_{k1} & \cdots & f''_{kk} \end{pmatrix}$$

Es el menor principal líder de orden $k+1$ de B : con la notación del capítulo de menores, $|B_k| = \Delta^{(k+1)}$ de B . El menor de orden 1 es siempre 0 y no interviene.

Las condiciones se evalúan en todo $x \in D$ y para $k = 1, \dots, n$:

	Condición necesaria	Condición suficiente (y estricta)
Cuasicóncava	$(-1)^k B_k \geq 0$	$(-1)^k B_k > 0$
Cuasiconvexa	$ B_k \leq 0$	$ B_k < 0$

En palabras: para la cuasiconcavidad, $|B_1|, |B_2|, \dots, |B_n|$ alternan de signo empezando por el negativo; para la cuasiconvexidad, son todos negativos. La condición necesaria admite ceros y se cumple siempre que f tenga la propiedad. La suficiente pide desigualdades estrictas y, cuando se cumple, asegura además la versión estricta.

Observación. Siempre vale

$$|B_1| = \det \begin{pmatrix} 0 & f'_1 \\ f'_1 & f''_{11} \end{pmatrix} = -(f'_1)^2 \leq 0$$

Por eso las dos condiciones necesarias empiezan igual, y la condición suficiente pide $|B_1| < 0$, es decir, $f'_1 \neq 0$. Por ejemplo, para $v(x, y) = x^2 + y^2$ resulta $|B_1| = -4x^2$ y $|B_2| = -8(x^2 + y^2)$: en el semiplano $x > 0$ se cumple la condición suficiente de cuasiconvexidad estricta, pero sobre el eje $x = 0$ el criterio no concluye, aunque v es estrictamente cuasiconvexa en todo $\mathbb{R}^2$. Las condiciones suficientes no son necesarias.

Ejemplo

Sea

$$f: A \rightarrow \mathbb{R}, \quad A = \{(x, y) \in \mathbb{R}^2 : x > 0, y > 0\}, \quad f(x, y) = xy$$

Derivadas parciales y hessiana

$$f'_x = y, \quad f'_y = x, \quad H_f(x, y) = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

Hessiano orlado

Definimos las siguientes matrices:

$$B_1 = \begin{pmatrix} 0 & y \\ y & 0 \end{pmatrix} \quad B_2 = \begin{pmatrix} 0 & y & x \\ y & 0 & 1 \\ x & 1 & 0 \end{pmatrix}$$

Cálculo de determinantes

$$|B_1| = -y^2 \quad |B_2| = 2xy$$

Para probar que f es estrictamente cuasicóncava usamos directamente la condición suficiente: alcanza con que $|B_1| < 0$ y $|B_2| > 0$ en todo A . Como $x, y > 0$, ambas se cumplen.

Conclusión: $f(x, y) = xy$ es estrictamente cuasicóncava en A .

Observación. En cambio, xy no es cóncava: su hessiana tiene $\Delta^{(2)} = \det H_f = -1 < 0$, así que es indefinida. Es el ejemplo típico de una función cuasicóncava que no es cóncava.

Relación y diferencias entre cuasiconcavidad y concavidad (o cuasiconvexidad y convexidad)

• Relación entre ambas:

- Toda función *cóncava* es *cuasicóncava*, pero la recíproca no es cierta: xy es cuasicóncava en A y no es cóncava (ver el ejemplo anterior).
- Toda función *convexa* es *cuasiconvexa*, pero la recíproca no es cierta: x^3 es creciente, y por lo tanto cuasiconvexa, pero no es convexa, porque su derivada segunda $6x$ es negativa para $x < 0$.
- Toda función *estrictamente cóncava* es *estrictamente cuasicóncava*. La recíproca tampoco vale: $\sqrt{xy}$ es estrictamente cuasicóncava en A ($|B_1| = -\frac{y}{4x} < 0$ y $|B_2| = \frac{1}{4\sqrt{xy}} > 0$), pero no es estrictamente cóncava: sobre cada rayo que sale del origen es lineal, porque $\sqrt{(\lambda x)(\lambda y)} = \lambda\sqrt{xy}$ para $\lambda > 0$, así que ahí la desigualdad de concavidad se cumple con igualdad. Por ejemplo, en $(1, 1)$ y $(2, 2)$ vale 1 y 2, y en el punto medio, $\frac{3}{2}$.
- Toda función *estrictamente convexa* es *estrictamente cuasiconvexa*. La recíproca tampoco vale: x^3 es estrictamente creciente, y por lo tanto estrictamente cuasiconvexa, pero no es convexa.

• Operaciones y composición:

- Una combinación lineal con coeficientes no negativos de funciones cóncavas (convexas) es cóncava (convexa).
- La suma de funciones cuasicóncavas no siempre es cuasicóncava, y lo mismo pasa con las cuasiconvexas. Por ejemplo, x^3 y $-3x$ son monótonas, y por lo tanto cuasicóncavas y cuasiconvexas, pero su suma no es ninguna de las dos: $x^3 - 3x \geq 0$ en $[-\sqrt{3}, 0] \cup [\sqrt{3}, \infty)$ y $x^3 - 3x \leq 0$ en $(-\infty, -\sqrt{3}] \cup [0, \sqrt{3}]$, y ninguno de esos conjuntos es convexo.
- La cuasiconcavidad se conserva bajo transformaciones crecientes: si f es cuasicóncava y g es creciente, $g \circ f$ es cuasicóncava. Si además f es estrictamente cuasicóncava y g es estrictamente creciente, $g \circ f$ es estrictamente cuasicóncava. Lo mismo vale para la cuasiconvexidad. Por eso la cuasiconcavidad es una propiedad *ordinal*: no depende de la escala con la que se mida la utilidad.
- Para la concavidad y la convexidad, en cambio, hace falta más. Sea

$$h(x) = (g \circ f)(x)$$

con

$$f: M \subseteq \mathbb{R}^n \rightarrow \mathbb{R}, \quad g: I \subseteq \mathbb{R} \rightarrow \mathbb{R}$$

donde M es convexo e I es un intervalo. Entonces:

1. Si f es convexa y g es creciente y convexa, entonces h es convexa.
2. Si f es cóncava y g es creciente y cóncava, entonces h es cóncava.

Ejemplo

Anteriormente probamos que $f(x, y) = xy$ es estrictamente cuasicóncava en A . Veamos la transformación

$$h(x, y) = \ln(xy) = \ln x + \ln y, \quad (x, y) \in A$$

Por composición. $h = g \circ f$ con $g(s) = \ln s$, que es estrictamente creciente en $(0, \infty)$. Como f es estrictamente cuasicóncava, h también lo es.

Con el hessiano orlado. Lo verificamos con el criterio:

$$\begin{aligned} h'_x &= \frac{1}{x}, \quad h'_y = \frac{1}{y}, \quad h''_{xx} = -\frac{1}{x^2}, \quad h''_{xy} = 0, \quad h''_{yy} = -\frac{1}{y^2} \\ B_1(x, y) &= \begin{pmatrix} 0 & h'_x \\ h'_x & h''_{xx} \end{pmatrix} = \begin{pmatrix} 0 & \frac{1}{x} \\ \frac{1}{x} & -\frac{1}{x^2} \end{pmatrix} \quad |B_1| = -\frac{1}{x^2} < 0 \\ B_2(x, y) &= \begin{pmatrix} 0 & h'_x & h'_y \\ h'_x & h''_{xx} & h''_{xy} \\ h'_y & h''_{xy} & h''_{yy} \end{pmatrix} = \begin{pmatrix} 0 & \frac{1}{x} & \frac{1}{y} \\ \frac{1}{x} & -\frac{1}{x^2} & 0 \\ \frac{1}{y} & 0 & -\frac{1}{y^2} \end{pmatrix} \quad |B_2| = \frac{2}{x^2 y^2} > 0 \end{aligned}$$

Se cumple la condición suficiente, como esperábamos.

Más aún, h es cóncava. Su hessiana

$$H_h(x, y) = \begin{pmatrix} -\frac{1}{x^2} & 0 \\ 0 & -\frac{1}{y^2} \end{pmatrix}$$

tiene $\Delta^{(1)} = -\frac{1}{x^2} < 0$ y $\Delta^{(2)} = \frac{1}{x^2 y^2} > 0$: es definida negativa en todo A , así que h es estrictamente cóncava. La transformación creciente $\ln$ volvió estrictamente cóncava a una función que no era cóncava: la concavidad depende de la escala, y la cuasiconcavidad, no.

Conclusión: $h(x, y) = \ln(xy)$ es estrictamente cuasicóncava en A ; de hecho, es estrictamente cóncava.

Nota final: otras condiciones suficientes

La condición suficiente del hessiano orlado prueba la versión estricta, y con ella también la no estricta. Pero si falla en algún punto, el criterio no concluye, y las condiciones débiles no sirven para probar nada porque son solo necesarias. Por ejemplo:

- $x + y$ es cuasicóncava y cuasiconvexa, pero $|B_2| = 0$ en todo punto, así que la condición suficiente nunca se cumple.
- $q(x) = (x^2 - 1)^2 + 0.2$, la función del gráfico “No cuasiconvexa”, cumple las condiciones débiles, porque $|B_1| = -q'(x)^2 \leq 0$, y sin embargo no es cuasicóncava ni cuasiconvexa.

Para esos casos hay otras condiciones suficientes que también usan derivadas:

- **Concavidad.** Si la hessiana de f es semidefinida negativa en todo D , f es cóncava y, por lo tanto, cuasicóncava. Así se prueba para $x + y$ y para $\sqrt{xy}$.
- **Una transformación creciente que la vuelva cóncava.** Si g es estrictamente creciente y la hessiana de $g \circ f$ es semidefinida negativa en todo D , entonces f es cuasicóncava, porque $f = g^{-1} \circ (g \circ f)$ y las transformaciones crecientes conservan la cuasiconcavidad. Si la hessiana de $g \circ f$ es definida negativa, f es estrictamente cuasicóncava. Es lo que vimos con xy y $\ln$. Lo mismo vale para cualquier Cobb-Douglas $x^a y^b$ con $a, b > 0$: $\ln(x^a y^b) = a \ln x + b \ln y$ es estrictamente cóncava, aunque $x^a y^b$ no sea cóncava cuando $a + b > 1$.

- **En una variable, el signo de f' .** Si f es monótona, o si $f' \geq 0$ hasta un punto y $f' \leq 0$ después, f es cuasicóncava, porque sus superniveles son intervalos.

Para la cuasiconvexidad valen las mismas condiciones, cambiando semidefinida negativa por semidefinida positiva, cóncava por convexa, y $f' \geq 0$ seguido de $f' \leq 0$ por $f' \leq 0$ seguido de $f' \geq 0$.

19 Optimización sin restricciones: cálculo univariable

Sea $f: I \rightarrow \mathbb{R}$ una función de clase C^2 , donde $I \subseteq \mathbb{R}$ es un intervalo abierto.¹³

Definiciones: Un punto $x^* \in I$ es un *mínimo local* de f si existe $r > 0$ tal que $f(x^*) \leq f(x)$ para todo $x \in I$ con $|x - x^*| < r$, es decir, si ningún punto cercano a x^* da un valor menor. Es un *mínimo global* si $f(x^*) \leq f(x)$ para todo $x \in I$. Cuando la desigualdad es estricta para todo $x \neq x^*$, el mínimo es *estricto*; un mínimo global estricto es el único mínimo global de f . Los máximos se definen igual, invirtiendo la desigualdad, y a los máximos y mínimos los llamamos *extremos* u *óptimos*.

Para encontrar extremos locales de f aplicamos el siguiente procedimiento:

1. **Condición de primer orden:** Calcular la derivada primera y resolver

$$f'(x^*) = 0$$

Los puntos x^* que satisfacen esta ecuación son los *puntos críticos*. Es una condición necesaria: como I es abierto, todo extremo local de f es un punto crítico. No es suficiente: más abajo veremos que x^3 tiene un punto crítico en 0 que no es un extremo.

2. **Condición de segundo orden:** Evaluar la derivada segunda en cada x^* :

$$f''(x^*) \begin{cases} > 0 & \Rightarrow x^* \text{ es un mínimo local} \\ < 0 & \Rightarrow x^* \text{ es un máximo local} \\ = 0 & \Rightarrow \text{el criterio no nos permite concluir nada} \end{cases}$$

Cuando $f''(x^*) = 0$, x^* puede ser un mínimo, un máximo o ninguno de los dos: x^4 , $-x^4$ y x^3 cumplen $f'(0) = f''(0) = 0$, y en 0 tienen, respectivamente, un mínimo, un máximo y un punto de inflexión.

Ejemplo rápido: Para $f(x) = x^3 - 3x$:

$$f'(x) = 3x^2 - 3, \quad f'(x) = 0 \Rightarrow x = \pm 1; \quad f''(x) = 6x.$$

$$f''(1) = 6 > 0 \Rightarrow x = 1 \text{ mínimo local}, \quad f''(-1) = -6 < 0 \Rightarrow x = -1 \text{ máximo local}.$$

Pasando a n variables

Denotemos

$$\vec{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$$

y sea

$$F: U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$$

una función de clase C^2 , con U abierto. Las definiciones de extremo local y global son las del caso univariable, cambiando $|x - x^*|$ por la distancia entre $\vec{x}$ y $\vec{x}^*$,

$$\|\vec{x} - \vec{x}^*\| = \sqrt{(x_1 - x_1^*)^2 + \dots + (x_n - x_n^*)^2}$$

¹³Pedimos I abierto para que alrededor de cada punto haya lugar a ambos lados. Si x^* es un mínimo, f no baja al movernos hacia la derecha ni hacia la izquierda: los cocientes incrementales son ≥ 0 de un lado y ≤ 0 del otro, y en el límite eso obliga a que $f'(x^*) = 0$. En el borde de un intervalo cerrado hay un solo lado, y un extremo puede tener $f' \neq 0$: $f(x) = x$ en $[0, 1]$ tiene su mínimo en 0, donde $f'(0) = 1$. Esos casos se estudian con restricciones de desigualdad; por la misma razón, en n variables pedimos U abierto.

Por ejemplo, $\vec{x}^*$ es un mínimo local de F si existe $r > 0$ tal que $F(\vec{x}^*) \leq F(\vec{x})$ para todo $\vec{x} \in U$ con $\|\vec{x} - \vec{x}^*\| < r$, es decir, en un entorno de $\vec{x}^*$.

La *condición de primer orden* se generaliza a

$$\nabla F(\vec{x}^*) = \vec{0}$$

es decir, todas las derivadas parciales de F deben anularse en $\vec{x}^* = (x_1^*, x_2^*, \dots, x_n^*)$. Los puntos que cumplen esta condición son los *puntos críticos* de F . Como en una variable, la condición es necesaria pero no suficiente: todo extremo local de F es un punto crítico, pero un punto crítico puede no ser un extremo. Un punto crítico que no es ni mínimo ni máximo local se llama *punto silla*: en cualquier entorno de $\vec{x}^*$ hay puntos donde F es mayor que $F(\vec{x}^*)$ y puntos donde es menor. (En una variable, un caso así, como el de x^3 en 0, suele llamarse punto de inflexión.)

La *condición de segundo orden* se extrae de la matriz hessiana $H(\vec{x}) = \nabla^2 F(\vec{x})$, que reúne todas las derivadas segundas de F . Como F es de clase C^2 , por el teorema de Schwarz las derivadas cruzadas coinciden, $F_{x_i x_j} = F_{x_j x_i}$, así que $H(\vec{x})$ es simétrica y le podemos aplicar los criterios de los capítulos de formas cuadráticas y de menores. De la misma manera que $f''(x^*)$ en una variable nos indica concavidad o convexidad, saber si $H(\vec{x}^*)$ es definida positiva, definida negativa o indefinida nos permitirá determinar si F tiene en $\vec{x}^*$ un mínimo local, un máximo local o un punto silla.¹⁴

Para abreviar, escribimos $H \succ 0$ si H es definida positiva, $H \succeq 0$ si es semidefinida positiva, $H \prec 0$ si es definida negativa y $H \preceq 0$ si es semidefinida negativa.

Condiciones suficientes y criterio de la matriz hessiana

Sea

$$F: U \subseteq \mathbb{R}^n \longrightarrow \mathbb{R}$$

de clase C^2 , con U abierto, y sea $\vec{x}^* \in U$ un punto crítico, es decir,

$$\nabla F(\vec{x}^*) = \vec{0}.$$

• Óptimo local (criterio de la hessiana).

- Si $H(\vec{x}^*)$ es *definida negativa*, entonces $\vec{x}^*$ es *máximo local*.
- Si $H(\vec{x}^*)$ es *definida positiva*, entonces $\vec{x}^*$ es *mínimo local*.
- Si $H(\vec{x}^*)$ es *indefinida*, entonces $\vec{x}^*$ no es ni mínimo ni máximo local (punto silla).

• Óptimo global (funciones convexas o cóncavas). Si además U es convexo:

- Si F es convexa en U y $\nabla F(\vec{x}^*) = \vec{0}$, entonces $\vec{x}^*$ es *mínimo global*.
- Si F es cóncava en U y $\nabla F(\vec{x}^*) = \vec{0}$, entonces $\vec{x}^*$ es *máximo global*.

Criterio de los menores principales para óptimo local

Sea

$$F: U \subseteq \mathbb{R}^n \longrightarrow \mathbb{R}$$

de clase C^2 , con U abierto, y supongamos que $\vec{x}^* \in U$ es un punto crítico:

$$\nabla F(\vec{x}^*) = \vec{0}$$

¹⁴Una forma de verlo es con el polinomio de Taylor de segundo orden del capítulo del diferencial: como $\nabla F(\vec{x}^*) = \vec{0}$, cerca de $\vec{x}^*$ vale $F(\vec{x}^* + \vec{h}) - F(\vec{x}^*) \approx \frac{1}{2} \vec{h}^T H(\vec{x}^*) \vec{h}$, así que, para $\vec{h}$ chico, el signo de la diferencia lo da la forma cuadrática asociada a $H(\vec{x}^*)$.

Denotemos por $\Delta^{(k)}$ el menor principal líder de orden k de la matriz hessiana evaluada en el punto crítico, como en el capítulo de menores.

Condición para máximo local. Si los menores principales líderes alternan de signo, empezando por el negativo:

$$\Delta^{(1)} < 0, \quad \Delta^{(2)} > 0, \quad \Delta^{(3)} < 0, \quad \dots, \quad (-1)^n \Delta^{(n)} > 0$$

entonces $\vec{x}^*$ es un *máximo local* de F .

Condición para mínimo local. Si todos los menores principales líderes son positivos:

$$\Delta^{(1)} > 0, \quad \Delta^{(2)} > 0, \quad \Delta^{(3)} > 0, \quad \dots, \quad \Delta^{(n)} > 0$$

entonces $\vec{x}^*$ es un *mínimo local* de F .

Condición para punto silla. Si $H(\vec{x}^*)$ es indefinida, $\vec{x}^*$ es un *punto silla*. Por el criterio para formas cuadráticas indefinidas del capítulo de menores, esto ocurre si algún menor principal de orden par es negativo, o si hay dos menores principales de orden impar con signos opuestos. En dos variables alcanza con que

$$\Delta^{(2)} = \det H(\vec{x}^*) < 0$$

Condición necesaria de segundo orden y casos no concluyentes

Los criterios anteriores dan condiciones suficientes. También hay una condición necesaria: si $\vec{x}^*$ es un mínimo local de F , entonces $H(\vec{x}^*)$ es semidefinida positiva, y si es un máximo local, $H(\vec{x}^*)$ es semidefinida negativa. Por eso, cuando $H(\vec{x}^*)$ es indefinida, $\vec{x}^*$ no puede ser ni mínimo ni máximo.

Si $H(\vec{x}^*)$ es semidefinida pero no definida, el criterio no nos permite concluir nada. Si $H(\vec{x}^*) \succeq 0$ y no es la matriz nula, la condición necesaria descarta que $\vec{x}^*$ sea un máximo, pero puede ser un mínimo o un punto silla. Por ejemplo, $x^2 + y^4$ y $x^2 - y^4$ tienen la misma hessiana en el origen,

$$H(0,0) = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}$$

y la primera tiene ahí un mínimo y la segunda, un punto silla. Con $H(\vec{x}^*) \preceq 0$ pasa lo análogo: puede haber un máximo o un punto silla. Si $H(\vec{x}^*)$ es la matriz nula, puede pasar cualquiera de las tres cosas: las funciones

$$x^4 + y^4, \quad -x^4 - y^4, \quad x^4 - y^4$$

tienen un punto crítico en el origen con hessiana nula, y ahí tienen, respectivamente, un mínimo, un máximo y un punto silla.

Criterio de los menores principales para óptimo global

En esta sección U es, además, convexo.

Mínimo global. Supongamos que la matriz hessiana $H(\vec{x})$ es semidefinida positiva en *todos* los puntos $\vec{x} \in U$. **En términos de menores principales, esto equivale a que para cualquier submatriz principal (es decir, para cualquier selección de filas y columnas con los mismos índices) el determinante sea mayor o igual a cero**, como en el criterio de semidefinitud del capítulo de menores. Cuando esto se cumple, F es convexa y cualquier punto crítico es automáticamente un mínimo global. La condición no asegura que F tenga un mínimo: en una variable, $F(x) = e^x$ es convexa y no tiene ningún punto crítico, porque $F'(x) = e^x$ nunca se anula.

Máximo global. Análogamente, supongamos que $H(\vec{x})$ es semidefinida negativa en todo U . **En lenguaje de menores principales, esto significa que para cada submatriz principal de orden k , el determinante de dicha submatriz multiplicado por $(-1)^k$ es mayor o igual a cero**. Bajo esta condición, F es cóncava y cada punto crítico será un máximo global. Tampoco aquí está asegurada la existencia: $-e^x$ es cóncava y no tiene máximo.

Diferencia entre óptimos locales y globales

La principal diferencia entre óptimos que son locales y óptimos globales es que, al momento de realizar el cálculo de segundas derivadas (con la matriz hessiana), para asegurar un óptimo local tenemos que evaluar la hessiana en un punto particular, de modo de mostrar que la función tiene un comportamiento similar al de una función estrictamente convexa/cóncava en un entorno de $\vec{x}^*$. Por otro lado, para confirmar con este criterio que un óptimo es global, hay que analizar la forma de la función: estudiar la hessiana sin evaluarla en ningún punto particular y ver si la función es convexa o cóncava.

La convexidad (o la concavidad) es una condición suficiente para que un óptimo sea global, pero no necesaria: $h(x) = 1 - e^{-x^2}$ tiene un mínimo global en $x = 0$, porque $h(x) \geq 0 = h(0)$, y no es convexa, porque $h''(x) = 2(1 - 2x^2)e^{-x^2}$ es negativa para $|x| > 1/\sqrt{2}$.

Resumiendo lo anterior tenemos:

Teorema (convexidad y óptimos globales). Sea $F: U \rightarrow \mathbb{R}$, con $U \subseteq \mathbb{R}^n$ abierto y convexo, $F \in C^1(U)$, y sea $\vec{x}^* \in U$ un punto crítico de F . Se verifica:

1. Si F es convexa en U , entonces F presenta en $\vec{x}^*$ un mínimo global.
2. Si F es estrictamente convexa en U , entonces F presenta en $\vec{x}^*$ un mínimo global único.
3. Si F es cóncava en U , entonces F presenta en $\vec{x}^*$ un máximo global.
4. Si F es estrictamente cóncava en U , entonces F presenta en $\vec{x}^*$ un máximo global único.

Ejemplo: $f(x, y) = x^2 + y^2$

1. Derivadas parciales y punto crítico

Sea

$$f(x, y) = x^2 + y^2, \quad (x, y) \in \mathbb{R}^2$$

Calculamos las derivadas parciales:

$$f_x = 2x, \quad f_y = 2y$$

El único punto crítico se obtiene resolviendo

$$2x = 0, \quad 2y = 0 \implies (x, y) = (0, 0)$$

2. Hessiana y clasificación de extremos locales

La hessiana es constante:

$$H(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

Sus menores principales líderes son

$$\Delta^{(1)} = 2 > 0, \quad \Delta^{(2)} = \det H = 4 > 0$$

de modo que la matriz es *definida positiva* en todo $\mathbb{R}^2$. Por el criterio de segundo orden, $(0, 0)$ es un *mínimo local*.

3. Convexidad global y mínimo global

Como $H(x, y) \succ 0$ en todo $\mathbb{R}^2$ (en particular, $H(x, y) \succeq 0$), f es *convexa* en $\mathbb{R}^2$, y en toda función convexa cualquier mínimo local es también *mínimo global*. Más aún, f es *estrictamente convexa*, así que $(0, 0)$ es el *único* mínimo global.

Ejemplo: $F(x, y) = x^3 - y^3 + 9xy$

1. Derivadas parciales y puntos críticos

Definimos

$$F(x, y) = x^3 - y^3 + 9xy$$

Calculamos las derivadas parciales:

$$F_x = \frac{\partial F}{\partial x} = 3x^2 + 9y \quad F_y = \frac{\partial F}{\partial y} = -3y^2 + 9x$$

Para hallar los puntos críticos resolvemos

$$\begin{cases} 3x^2 + 9y = 0 \\ -3y^2 + 9x = 0 \end{cases}$$

De la primera ecuación:

$$y = -\frac{x^2}{3}$$

Sustituyendo en la segunda:

$$\begin{aligned} -3\left(-\frac{x^2}{3}\right)^2 + 9x = 0 &\implies -3\frac{x^4}{9} + 9x = 0 \implies -\frac{x^4}{3} + 9x = 0 \\ &\implies -x^4 + 27x = 0 \implies x(-x^3 + 27) = 0 \end{aligned}$$

De aquí obtenemos

$$x = 0 \implies y = 0, \quad -x^3 + 27 = 0 \implies x^3 = 27 \implies x = 3 \implies y = -\frac{3^2}{3} = -3$$

Por tanto, los puntos críticos son

$$(0, 0) \quad \text{y} \quad (3, -3)$$

2. Hessiana y clasificación de extremos

La hessiana es

$$H(x, y) = \begin{pmatrix} F_{xx} & F_{xy} \\ F_{yx} & F_{yy} \end{pmatrix} = \begin{pmatrix} 6x & 9 \\ 9 & -6y \end{pmatrix}$$

1. **En** $(0, 0)$:

$$H(0, 0) = \begin{pmatrix} 0 & 9 \\ 9 & 0 \end{pmatrix}, \quad \Delta^{(1)} = 0, \quad \Delta^{(2)} = -81 < 0$$

Como $\Delta^{(2)} < 0$, la hessiana es indefinida y $(0, 0)$ es un punto silla (saddle point).


2. **En** $(3, -3)$:

$$H(3, -3) = \begin{pmatrix} 18 & 9 \\ 9 & 18 \end{pmatrix}, \quad \Delta^{(1)} = 18 > 0, \quad \Delta^{(2)} = 18 \cdot 18 - 9 \cdot 9 = 243 > 0$$

Aquí la hessiana es definida positiva, por lo que $(3, -3)$ es un mínimo local.

Conclusión: $(0, 0)$ es un punto silla y $(3, -3)$ es un mínimo local de F . No hay máximos locales.

En el gráfico de curvas de nivel se ven los dos casos. Alrededor del mínimo local las curvas de nivel son cerradas, y F crece a medida que nos alejamos de $(3, -3)$. En el punto silla, en cambio, se cruzan dos ramas de la curva de nivel $F = 0$: en dos de los cuatro sectores que forman, F es positiva, y en los otros dos, negativa. En el gráfico, cada curva está rotulada con su nivel, y las punteadas corresponden a niveles negativos.



3. Concavidad/convexidad global de F

Para determinar si los extremos locales son también globales, intentamos aplicar el teorema anterior, que pide que F sea convexa o cóncava en todo $\mathbb{R}^2$. Volvemos a la hessiana general:

$$H(x, y) = \begin{pmatrix} 6x & 9 \\ 9 & -6y \end{pmatrix}$$

Los menores principales no siguen un patrón ya que, por ejemplo, $6x$ puede ser negativo o positivo. Lo mismo con $-6y$ y $|H|$. Con este criterio, no podemos afirmar que tenemos un óptimo global.

De hecho, F no es convexa ni cóncava, y para verlo alcanza con el punto silla. Si F fuera convexa, por el teorema todo punto crítico sería un mínimo global, y $(0, 0)$ no lo es. Si fuera cóncava, $(0, 0)$ sería un máximo global, y tampoco lo es.

Que el teorema no se aplique no deja la pregunta sin respuesta: podemos comprobar directamente que $(3, -3)$ no es un mínimo global. Por ejemplo, $F(3, -3) = -27$ y $F(-4, 0) = -64 < -27$. Más aún, sobre el eje x la función queda $F(x, 0) = x^3$, que tiende a $-\infty$ cuando $x \rightarrow -\infty$, así que F no tiene mínimo global. Del mismo modo, $F(0, y) = -y^3$ tiende a $+\infty$ cuando $y \rightarrow -\infty$, así que tampoco tiene máximo global.

Conclusión: $(3, -3)$ es un mínimo local de F , pero no global, y F no tiene mínimo ni máximo global.

Ejemplo: $F(x, y) = (x + y)^2$

En este ejemplo pasa lo contrario que en el anterior: el criterio local no nos permite concluir nada, pero el global sí.

1. Derivadas parciales y puntos críticos

$$F_x = 2(x + y), \quad F_y = 2(x + y)$$

Las dos se anulan si y solo si $x + y = 0$, así que los puntos críticos son todos los puntos de la recta

$$y = -x$$

2. Hessiana y clasificación de extremos locales

La hessiana es constante:

$$H(x, y) = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}, \quad \Delta^{(1)} = 2 > 0, \quad \Delta^{(2)} = \det H = 0$$

Como $\Delta^{(2)} = 0$, la hessiana no es definida, y el criterio de los menores para óptimos locales no nos permite concluir nada en ninguno de los puntos críticos.

3. Convexidad global y mínimo global

Para el criterio global hay que revisar todos los menores principales, no solo los líderes:

$$\Delta_1^{(1)} = 2 \geq 0, \quad \Delta_2^{(1)} = 2 \geq 0, \quad \Delta_{12}^{(2)} = \det H = 0 \geq 0$$

Entonces $H(x, y) \succeq 0$ en todo $\mathbb{R}^2$, F es convexa y, por el teorema, todo punto crítico es un mínimo global. Lo confirma la función misma: $F(x, y) = (x + y)^2 \geq 0$, y vale 0 sobre toda la recta $y = -x$. El mínimo no es único porque F es convexa, pero no estrictamente convexa: es constante a lo largo de esa recta.

Conclusión: el mínimo global de F se alcanza en todos los puntos de la recta $y = -x$, así que no es único. Con el criterio global podemos concluir, aunque con el local no.

Preservación de máximos y mínimos bajo transformaciones crecientes

Sea $F: U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ y sea φ una función estrictamente creciente, definida en un conjunto que contiene a la imagen de F . Entonces F y $\varphi \circ F$ alcanzan sus máximos y mínimos, locales y globales, en los mismos puntos, porque

$$F(\vec{x}^*) \geq F(\vec{x}) \iff \varphi(F(\vec{x}^*)) \geq \varphi(F(\vec{x}))$$

Para esto no hace falta que φ sea derivable. Por eso, en microeconomía, en la teoría del consumidor, podemos aplicarle a la función de utilidad cualquier transformación estrictamente creciente antes de maximizarla, por ejemplo maximizar $\ln u$ en lugar de u : cambia la función objetivo, pero no la canasta óptima. Es la misma razón por la que la cuasiconcavidad, a diferencia de la concavidad, es una propiedad ordinal.

Con derivadas se puede decir algo más: el criterio de la hessiana sigue funcionando después de transformar. Sea $D \subseteq \mathbb{R}$ un conjunto abierto y sea $\varphi: D \rightarrow \mathbb{R}$ una función de clase C^2 tal que $\varphi'(t) > 0$ para todo $t \in D$. Sea $F: U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ de clase C^2 , con U abierto, tal que $F(\vec{x}) \in D$ para todo $\vec{x} \in U$. Entonces:

1. $\vec{x}^*$ es punto crítico de F si y solo si es punto crítico de $\varphi \circ F$.
2. Si $\vec{x}^*$ es punto crítico de F , la hessiana de $\varphi \circ F$ en $\vec{x}^*$ tiene la misma clasificación que $H_F(\vec{x}^*)$: si una es definida negativa (máximo local), definida positiva (mínimo local), indefinida (punto silla) o semidefinida, la otra también.

Demostración. Por la regla de la cadena,

$$\nabla(\varphi \circ F)(\vec{x}) = \varphi'(F(\vec{x})) \nabla F(\vec{x})$$

y como $\varphi' > 0$, un gradiente se anula si y solo si se anula el otro. Derivando otra vez,

$$H_{\varphi \circ F}(\vec{x}) = \varphi''(F(\vec{x})) \nabla F(\vec{x}) \nabla F(\vec{x})^T + \varphi'(F(\vec{x})) H_F(\vec{x})$$

En un punto crítico el primer término se anula, y queda

$$H_{\varphi \circ F}(\vec{x}^*) = \varphi'(F(\vec{x}^*)) H_F(\vec{x}^*)$$

La hessiana queda multiplicada por un número positivo, y eso no cambia el signo de $\vec{h}^T H \vec{h}$ para ningún $\vec{h}$: la clasificación es la misma.

Observación. Fuera de los puntos críticos, la definitud sí puede cambiar. Con $F(x, y) = 3x - x^2 - y^2$ y $\varphi(t) = e^t$, en el origen

$$H_F(0, 0) = \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix} \quad H_{\varphi \circ F}(0, 0) = \begin{pmatrix} 7 & 0 \\ 0 & -2 \end{pmatrix}$$

La primera es definida negativa y la segunda es indefinida. Por eso el ítem 2 pide que $\vec{x}^*$ sea un punto crítico.

Ejemplos de φ

- $\varphi(t) = at + b$, con $a > 0$.
- $\varphi(t) = e^t$.
- $\varphi(t) = \ln(t + c)$, con $c \in \mathbb{R}$ (dominio $t > -c$). Con $c = 0$ queda $\ln t$, que es la que lleva xy a $\ln(xy)$.
- $\varphi(t) = t^3$ (con $t \neq 0$).
- $\varphi(t) = \sqrt{t}$ (en $t > 0$).

El caso $\varphi(t) = t^3$ muestra la diferencia entre conservar los óptimos y conservar el criterio. Como t^3 es estrictamente creciente en todo $\mathbb{R}$, siempre conserva los óptimos. Pero $\varphi'(0) = 0$, y por eso se excluye $t = 0$: $F(x, y) = x^2 + y^2$ tiene un mínimo en el origen, donde vale 0, y la hessiana de $(x^2 + y^2)^3$ en el origen es la matriz nula. El mínimo sigue estando, pero el criterio de la hessiana ya no lo detecta.

Ejemplo

Busquemos los extremos de

$$F(x, y) = xy e^{-x-y}, \quad (x, y) \in U = \{(x, y) \in \mathbb{R}^2 : x > 0, y > 0\}$$

Se puede derivar F directamente, pero como $F > 0$ en U es más simple trabajar con $G = \ln F$, porque $\ln$ es estrictamente creciente:

$$G(x, y) = \ln x + \ln y - x - y$$

Puntos críticos.

$$G_x = \frac{1}{x} - 1 = 0, \quad G_y = \frac{1}{y} - 1 = 0 \quad \implies \quad (x, y) = (1, 1)$$

Por el ítem 1, $(1, 1)$ es también el único punto crítico de F en U .

Hessiana.

$$H_G(x, y) = \begin{pmatrix} -\frac{1}{x^2} & 0 \\ 0 & -\frac{1}{y^2} \end{pmatrix}, \quad \Delta^{(1)} = -\frac{1}{x^2} < 0, \quad \Delta^{(2)} = \frac{1}{x^2 y^2} > 0$$

La hessiana de G es definida negativa en todo U , que es abierto y convexo, así que G es estrictamente cóncava y $(1, 1)$ es su único máximo global. Por el primer resultado de esta sección, $(1, 1)$ es también el único máximo global de F , con $F(1, 1) = e^{-2}$.


Observación. F no es cóncava. Por ejemplo,

$$H_F(2, 2) = e^{-4} \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

es indefinida. El teorema de óptimos globales no se aplica a F , pero sí a $G = \ln F$: la transformación creciente es la que permite concluir.

Conclusión: $(1, 1)$ es el único máximo global de F en U .

Esquema de análisis (sin restricciones)



20 Aplicaciones económicas de optimización libre

Teorema de la envolvente (optimización sin restricciones)

Consideremos el problema de maximización sin restricciones

$$\max_{x,y} U = f(x, y, \phi)$$

donde x, y son variables endógenas y ϕ es un parámetro exógeno.

Condiciones de óptimo

Las condiciones necesarias de primer orden en el óptimo $(x^*(\phi), y^*(\phi))$ son

$$\frac{\partial f}{\partial x}(x^*(\phi), y^*(\phi), \phi) = 0, \quad \frac{\partial f}{\partial y}(x^*(\phi), y^*(\phi), \phi) = 0. \quad (1)$$

Bajo condiciones de segundo orden adecuadas, estas ecuaciones definen implícitamente $x^*(\phi)$ y $y^*(\phi)$.

$$x^* = x^*(\phi) \quad y^* = y^*(\phi)$$

Función de valor indirecta

Sustituyendo en la función objetivo obtenemos la función de valor máximo (función objetivo indirecta)

$$V(\phi) = f(x^*(\phi), y^*(\phi), \phi)$$

Esta es una función que depende en última instancia de ϕ , a diferencia de la función objetivo que depende de x y de y .

Derivada de la función de valor

Al diferenciar V con respecto a ϕ usando la regla de la cadena:

$$\frac{dV}{d\phi} = f_x \frac{\partial x^*}{\partial \phi} + f_y \frac{\partial y^*}{\partial \phi} + f_\phi$$

donde todos los términos f_x, f_y, f_ϕ se evalúan en $(x^*(\phi), y^*(\phi), \phi)$.

Pero por las condiciones de primer orden (1) se tiene $f_x = f_y = 0$ en el óptimo, y por tanto

$$\frac{dV}{d\phi} = f_\phi(x^*(\phi), y^*(\phi), \phi)$$

Este es el **teorema de la envolvente**: la derivada de la función de valor máximo con respecto al parámetro ϕ equivale al efecto directo de ϕ sobre la función objetivo, ignorando los efectos indirectos vía $x^*(\phi)$ y $y^*(\phi)$.

Interpretación

- La función de valor $V(\phi)$ “envuelve” la familia de funciones $f(x, y, \phi)$ optimizadas en $(x^*(\phi), y^*(\phi))$ al variar ϕ .
- El resultado muestra que, en el óptimo, no hace falta calcular $\partial x^*/\partial \phi$ ni $\partial y^*/\partial \phi$ para conocer $\frac{dV}{d\phi}$: basta con el efecto directo f_ϕ .

Intuición: ¿Por qué “teorema de la envolvente”?

El nombre proviene de la idea geométrica de que la función de valor indirecta

$$V(\phi) = \max_{x,y} f(x,y,\phi)$$

es la *envolvente* de la familia de gráficas $\{z = f(x,y,\phi) : (x,y) \in \mathbb{R}^2\}$ al variar el parámetro ϕ . A continuación presentamos varias perspectivas:

Envolvente de familias de curvas/superficies

Para cada ϕ se tiene un punto en el plano (ϕ, z) :

$$z = f(x^*(\phi), y^*(\phi), \phi)$$

Estos puntos conforman una curva al variar ϕ . La curva límite que toca tangencialmente a cada una de estas es la *envolvente*. Gráficamente, $V(\phi)$ “abrazo” o “envuelve” el punto más alto de cada miembro de la familia

Ejemplo de envolvente con $f(x;t) = tx^2 + x + 10$

Consideremos la familia de funciones

$$f(x;t) = tx^2 + x + 10 \quad x \in \mathbb{R}, t < 0$$

donde x es la variable de decisión y t un parámetro exógeno. Tomamos $t < 0$ para garantizar que la maximización en x sea bien comportada (coeficiente de x^2 negativo)

Función valor

Definimos la función de valor

$$V(t) = \max_{x \in \mathbb{R}} f(x;t)$$

Condición de primer orden

Para cada $t < 0$, el óptimo $x^*(t)$ satisface

$$\frac{\partial f}{\partial x} = 2tx + 1 = 0 \implies x^*(t) = -\frac{1}{2t}$$

Cálculo de la envolvente

Sustituyendo $x^*(t)$ en f :

$$V(t) = f(x^*(t);t) = t\left(-\frac{1}{2t}\right)^2 + \left(-\frac{1}{2t}\right) + 10 = \frac{1}{4t} - \frac{1}{2t} + 10 = 10 - \frac{1}{4t}$$

Teorema de la envolvente

Directamente,

$$V'(t) = \frac{d}{dt}\left(10 - \frac{1}{4t}\right) = \frac{1}{4t^2}$$

Por el teorema de la envolvente, también debe cumplirse

$$V'(t) = \frac{\partial f}{\partial t}(x^*(t);t) = x^*(t)^2 = \left(-\frac{1}{2t}\right)^2 = \frac{1}{4t^2}$$

confirmando que los efectos indirectos vía $x^*(t)$ se anulan en la derivada de la función valor

Interpretación

- Cada f es una parábola cóncava en x (porque $t < 0$)
- La envolvente $V(t) = 10 - \frac{1}{4t}$ toca tangencialmente a cada parábola en $x = x^*(t)$
- El teorema de la envolvente nos dice que para medir el impacto de t sobre el máximo, basta con $\partial f / \partial t$ evaluada en el óptimo

Para obtener la envolvente como función de la *variable* x , invertimos esta relación:

$$x = -\frac{1}{2t} \implies t = -\frac{1}{2x} \quad x > 0$$


Sustituyendo $t(x)$ en f hallamos

$$V(x) = f(x; t(x)) = \left(-\frac{1}{2x}\right)x^2 + x + 10 = -\frac{x}{2} + x + 10 = \frac{x}{2} + 10$$

Por tanto la envolvente viene dada por

$$y = V(x) = 10 + \frac{1}{2}x \quad x > 0$$

Gráficamente esta función toca todos los puntos máximos de la familia de parábolas:
 $f(x, t) = tx^2 + x + 10$



Ejemplo económico: maximización de beneficios sin restricciones

Consideremos una empresa que produce una cantidad $q \geq 0$ de un bien y enfrenta un precio de mercado $p > 0$. Su beneficio π viene dado por

$$\pi(q; p) = pq - C(q)$$

donde $C(q)$ es su función de costes, asumida de clase C^2 y estrictamente convexa ($C''(q) > 0$)

Problema de optimización

Para cada precio p la empresa elige q para

$$\max_{q \geq 0} \pi(q; p)$$

Las condiciones de primer y segundo orden son:

$$\frac{\partial \pi}{\partial q} = p - C'(q) = 0 \implies C'(q^*) = p$$

$$\frac{\partial^2 \pi}{\partial q^2} = -C''(q^*) < 0 \implies \pi \text{ es cóncava en } q \text{ y } q^*(p) \text{ es el único máximo}$$

Función de beneficio indirecto

Definimos la función valor (beneficio máximo) como

$$\Pi(p) = \pi(q^*(p); p) = p q^*(p) - C(q^*(p))$$

Teorema de la envolvente

Al derivar $\Pi(p)$ con respecto a p , aplicando el teorema de la envolvente se obtiene

$$\frac{d\Pi}{dp} = \frac{\partial \pi}{\partial p}(q^*(p); p) = q^*(p)$$

sin necesidad de calcular $\frac{dq^*}{dp}$, pues $\partial \pi / \partial q = 0$ en el óptimo

Función concreta

Supongamos $C(q) = \frac{1}{2} c q^2$ con $c > 0$. Entonces

$$C'(q) = c q \quad C''(q) = c > 0$$

y la condición de primer orden $p = c q$ da

$$q^*(p) = \frac{p}{c} \quad \Pi(p) = p \cdot \frac{p}{c} - \frac{1}{2} c \left(\frac{p}{c}\right)^2 = \frac{p^2}{2c}$$

Verifiquemos la envolvente:

$$\frac{d\Pi}{dp} = \frac{d}{dp} \left(\frac{p^2}{2c} \right) = \frac{p}{c} = q^*(p)$$

Interpretación

- La condición de envolvente $\partial \pi / \partial q = 0$ nos da la oferta óptima $q^*(p)$
- El teorema de la envolvente permite calcular la sensibilidad del beneficio máximo al precio p simplemente con $\partial \pi / \partial p = q$, sin derivar la curva de oferta $q^*(p)$. En este caso el resultado nos sugiere que ante un aumento del precio de venta, el beneficio máximo se incrementa.

Otro ejemplo: Monopolista multiproducto con dos bienes

Sea un monopolista que ofrece dos bienes $q_1, q_2 \geq 0$ con demanda inversa lineal

$$p_1(q_1, q_2) = a - b q_1 - c q_2 \quad p_2(q_1, q_2) = d - e q_1 - f q_2$$

y costos lineales

$$C(q_1, q_2) = g q_1 + h q_2$$

Entonces el beneficio es

$$\pi(q_1, q_2) = p_1 q_1 + p_2 q_2 - C(q_1, q_2) = (a - b q_1 - c q_2) q_1 + (d - e q_1 - f q_2) q_2 - (g q_1 + h q_2)$$

Condiciones de primer orden

Para encontrar el máximo, derivamos la función de beneficio respecto a cada cantidad e igualamos a cero.
Es crucial incluir todos los términos cruzados.

La derivada respecto a q_1 es:

$$\frac{\partial \pi}{\partial q_1} = (a - 2b q_1 - c q_2) + (-e q_2) - g = a - g - 2b q_1 - (c + e) q_2 = 0$$

La derivada respecto a q_2 es:

$$\frac{\partial \pi}{\partial q_2} = (-c q_1) + (d - e q_1 - 2f q_2) - h = d - h - (c + e) q_1 - 2f q_2 = 0$$

Esto nos da un sistema de dos ecuaciones lineales:

$$\begin{cases} 2b q_1 + (c + e) q_2 = a - g \\ (c + e) q_1 + 2f q_2 = d - h \end{cases}$$

Resolviendo este sistema (por ejemplo, usando la regla de Cramer o sustitución) se obtienen las cantidades óptimas:

$$q_1^* = \frac{2f(a - g) - (c + e)(d - h)}{4bf - (c + e)^2}$$

$$q_2^* = \frac{2b(d - h) - (c + e)(a - g)}{4bf - (c + e)^2}$$

Condición de segundo orden (Hessiano)

El Hessiano de π respecto a (q_1, q_2) es:

$$\nabla^2 \pi = \begin{pmatrix} \frac{\partial^2 \pi}{\partial q_1^2} & \frac{\partial^2 \pi}{\partial q_1 \partial q_2} \\ \frac{\partial^2 \pi}{\partial q_2 \partial q_1} & \frac{\partial^2 \pi}{\partial q_2^2} \end{pmatrix} = \begin{pmatrix} -2b & -(c + e) \\ -(c + e) & -2f \end{pmatrix}$$

Para que (q_1^*, q_2^*) sea un máximo local, este Hessiano debe ser **definido negativo**:

$$-2b < 0 \implies b > 0$$

y su determinante debe ser positivo:

$$\det(\nabla^2 \pi) = (-2b)(-2f) - (-(c + e))(-(c + e)) = 4bf - (c + e)^2 > 0$$

Note que este denominador es el mismo que el utilizado para calcular q_1^* y q_2^* .

Sensibilidad respecto de b y d

Al aplicar el **teorema de la envolvente** al beneficio máximo $\Pi(b, d)$, basta con derivar la función de beneficio π respecto a los parámetros b y d , y luego evaluar en el punto óptimo (q_1^*, q_2^*) .

$$\frac{\partial \pi}{\partial b} = -q_1^2 \implies \frac{d\Pi}{db} = -(q_1^*)^2$$

$$\frac{\partial \pi}{\partial d} = q_2 \implies \frac{d\Pi}{dd} = q_2^*$$

Interpretación

- Un aumento de b (la demanda del bien 1 es más sensible a su propia cantidad) **reduce el beneficio máximo**, ya que $\frac{d\Pi}{db} = -(q_1^*)^2 < 0$.
- Un aumento de d (mayor disposición a pagar por el bien 2) **incrementa el beneficio máximo**, ya que se asume que la cantidad óptima $\frac{d\Pi}{dd} = q_2^*$ será positiva.

21 Optimización con restricciones de igualdad

Optimización con restricciones y Lagrangiano

En muchos problemas de optimización no basta con minimizar (o maximizar) una función objetivo $f: \mathbb{R}^n \rightarrow \mathbb{R}$ libremente: es preciso hacerlo sujeto a ciertas restricciones que deben cumplirse. En este apartado vamos a revisar el método de los *multiplicadores de Lagrange* (o método del Lagrangiano) que es una herramienta fundamental para abordar problemas con restricciones de igualdad

Formulación del problema

Consideremos el problema

$$\begin{aligned} \min_{x \in \mathbb{R}^n} f(x) \\ \text{sujeto a } g_i(x) = 0, \quad i = 1, \dots, k \end{aligned}$$

donde $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$ son funciones (C^1) y las curvas $g_i(x) = 0$ definen el conjunto factible.

El Lagrangiano

Definimos la función Lagrangiana asociada al problema como

$$\mathcal{L}(x, \lambda) = f(x) + \sum_{i=1}^k \lambda_i g_i(x)$$

El lagrangiano también puede formularse como:

$$\mathcal{L}(x, \lambda) = f(x) - \sum_{i=1}^k \lambda_i g_i(x)$$

Ya que el término λ es una variable artificial que puede tener signo negativo o positivo. El resultado es indiferente de si aparece sumando o restando (de hecho véase que la restricción $g_i(x) = 0$ puede multiplicarse ambos lados por -1 y sigue siendo válida).

Condiciones de primer orden

Un par (x^*, λ^*) que resuelve el problema debe satisfacer las siguientes condiciones, que incluyen

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = \nabla f(x^*) + \sum_{i=1}^k \lambda_i^* \nabla g_i(x^*) = 0$$

$$g_i(x^*) = 0, \quad i = 1, \dots, k$$

Estas condiciones son las mismas para maximizar o minimizar un problema de optimización libre. Por lo que el método del lagrangiano nos proporciona una simplificación del problema a cambio de agregar un multiplicador lagrangiano por cada restricción.

Interpretación geométrica

Geométricamente, en el punto óptimo x^* el gradiente de la función objetivo debe poder expresarse como combinación lineal de los gradientes de las restricciones

$$\nabla f(x^*) \in \text{span}\{\nabla g_1(x^*), \dots, \nabla g_k(x^*)\}$$

Ejemplo: Minimización con restricción lineal

Consideremos el problema

$$\begin{aligned} \min_{x,y \in \mathbb{R}} f(x,y) &= x^2 + y^2 \\ \text{sujeto a } g(x,y) &= x + y - 1 = 0 \end{aligned}$$

El Lagrangiano asociado es

$$\mathcal{L}(x,y,\lambda) = x^2 + y^2 - \lambda(x + y - 1)$$

Las condiciones de primer orden son

$$\frac{\partial \mathcal{L}}{\partial x} = 2x - \lambda = 0 \quad , \quad \frac{\partial \mathcal{L}}{\partial y} = 2y - \lambda = 0 \quad , \quad \frac{\partial \mathcal{L}}{\partial \lambda} = -(x + y - 1) = 0$$

Es conveniente recordar que la condición $\frac{\partial \mathcal{L}}{\partial \lambda} = 0$ no es más que $g(x,y) = 0$.
De las dos primeras ecuaciones se obtiene

$$x = \frac{\lambda}{2} \quad , \quad y = \frac{\lambda}{2}$$

y substituyendo en la restricción $x + y = 1$ resulta $\lambda = 1$ Por tanto

$$x^* = y^* = \frac{1}{2}$$

Este sería el candidato a óptimo ya que cumple las condiciones necesarias.

Otro ejemplo

Consideremos el problema

$$\begin{aligned} \max_{x,y \in \mathbb{R}} f(x,y) &= x y \\ \text{sujeto a } h(x,y) &= x^2 + y^2 - 1 = 0 \end{aligned}$$

El Lagrangiano es

$$\mathcal{L}(x,y,\lambda) = x y - \lambda(x^2 + y^2 - 1)$$

Las condiciones de primer orden son

$$\frac{\partial \mathcal{L}}{\partial x} = y - 2\lambda x = 0 \tag{2}$$

$$\frac{\partial \mathcal{L}}{\partial y} = x - 2\lambda y = 0 \tag{3}$$

$$\frac{\partial \mathcal{L}}{\partial \lambda} = -(x^2 + y^2 - 1) = 0 \tag{4}$$

De (2) y (3) se deduce

$$y = 2\lambda x \quad , \quad x = 2\lambda y \implies (2\lambda)^2 = 1 \implies \lambda = \pm \frac{1}{2}$$

Por la restricción $x^2 + y^2 = 1$ tenemos además

$$y = \pm x \quad , \quad x = \pm \frac{1}{\sqrt{2}} \quad , \quad y = \pm \frac{1}{\sqrt{2}}$$

Así, los puntos críticos son

$$\left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right), \left(-\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right), \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right), \left(-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$$

Que serían candidatos a máximos y mínimos.

Ejemplo económico: Maximización de utilidad con restricción presupuestaria

Consideremos un consumidor que elige cantidades $x_1, x_2 > 0$ de dos bienes para maximizar su utilidad

$$u(x_1, x_2) = x_1^\alpha x_2^{1-\alpha} \quad , \quad \alpha \in (0, 1)$$

sujeto a su restricción presupuestaria

$$p_1 x_1 + p_2 x_2 = M$$

donde $p_1, p_2 > 0$ son los precios y $M > 0$ su ingreso

El Lagrangiano es

$$\mathcal{L}(x_1, x_2, \lambda) = x_1^\alpha x_2^{1-\alpha} + \lambda(M - p_1 x_1 - p_2 x_2)$$

Las condiciones de primer orden son

$$\frac{\partial \mathcal{L}}{\partial x_1} = \alpha x_1^{\alpha-1} x_2^{1-\alpha} - \lambda p_1 = 0 \quad (5)$$

$$\frac{\partial \mathcal{L}}{\partial x_2} = (1 - \alpha) x_1^\alpha x_2^{-\alpha} - \lambda p_2 = 0 \quad (6)$$

$$\frac{\partial \mathcal{L}}{\partial \lambda} = M - p_1 x_1 - p_2 x_2 = 0 \quad (7)$$

De (5) y (6) obtenemos

$$\frac{\alpha}{1 - \alpha} \frac{x_2}{x_1} = \frac{p_1}{p_2} \implies x_2 = \frac{1 - \alpha}{\alpha} \frac{p_1}{p_2} x_1$$

Sustituyendo en (7) y resolviendo, se llega a las demandas óptimas

$$x_1^* = \frac{\alpha M}{p_1} \quad , \quad x_2^* = \frac{(1 - \alpha) M}{p_2}$$

Condiciones de segundo orden

Suponemos además que f y las g_i son de clase C^2 en un entorno de x^* .

Caso concreto: 2 variables independientes y una restricción

Sea

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad g : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad \mathcal{L}(x, y, \lambda) = f(x, y) + \lambda g(x, y).$$

En un punto estacionario (x^*, y^*, λ^*) se cumplen las condiciones de primer orden:

$$\nabla f(x^*, y^*) = \lambda^* \nabla g(x^*, y^*), \quad g(x^*, y^*) = 0.$$

Definimos las segundas derivadas de la función Lagrangiana $\mathcal{L}(x, y, \lambda) = f(x, y) + \lambda g(x, y)$ en el punto crítico (x^*, y^*, λ^*) como

$$\nabla_{(x, y, \lambda)}^2 \mathcal{L}(x^*, y^*, \lambda^*) = \begin{pmatrix} \mathcal{L}_{xx} & \mathcal{L}_{xy} & \mathcal{L}_{x\lambda} \\ \mathcal{L}_{yx} & \mathcal{L}_{yy} & \mathcal{L}_{y\lambda} \\ \mathcal{L}_{\lambda x} & \mathcal{L}_{\lambda y} & \mathcal{L}_{\lambda\lambda} \end{pmatrix}_{(x^*, y^*, \lambda^*)}.$$

Aquí,

$$\begin{aligned}\mathcal{L}_{xx} &= f_{xx} + \lambda^* g_{xx}, & \mathcal{L}_{xy} &= f_{xy} + \lambda^* g_{xy}, \\ \mathcal{L}_{yx} &= f_{yx} + \lambda^* g_{yx}, & \mathcal{L}_{yy} &= f_{yy} + \lambda^* g_{yy}, \\ \mathcal{L}_{x\lambda} &= g_x, & \mathcal{L}_{y\lambda} &= g_y, \\ \mathcal{L}_{\lambda x} &= g_x, & \mathcal{L}_{\lambda y} &= g_y, \\ \mathcal{L}_{\lambda\lambda} &= 0\end{aligned}$$

Por tanto, al evaluar:

$$\bar{H} = \nabla_{(x,y,\lambda)}^2 \mathcal{L}(x^*, y^*, \lambda^*) = \begin{pmatrix} f_{xx} + \lambda^* g_{xx} & f_{xy} + \lambda^* g_{xy} & g_x \\ f_{yx} + \lambda^* g_{yx} & f_{yy} + \lambda^* g_{yy} & g_y \\ g_x & g_y & 0 \end{pmatrix}_{(x^*, y^*, \lambda^*)}.$$

La submatriz central de orden 2×2 es precisamente las derivadas del lagrangiano con respecto a las variables x, y , y los elementos g_x, g_y crean el “borde” que la convierte en el hessiano orlado.

Restricción lineal

Cuando las restricciones son lineales el hessiano orlado se simplifica aún más: Supongamos

$$g(x, y) = a x + b y + c$$

con a, b, c constantes. Entonces:

- $\nabla g(x, y) = (g_x, g_y) = (a, b)$: las primeras derivadas $g_x = a$, $g_y = b$ son constantes.
- Las segundas derivadas se anulan:

$$g_{xx} = \frac{\partial}{\partial x}(g_x) = 0, \quad g_{xy} = \frac{\partial}{\partial y}(g_x) = 0, \quad g_{yy} = \frac{\partial}{\partial y}(g_y) = 0$$

Por tanto,

$$\bar{H} = \nabla_{(x,y,\lambda)}^2 \mathcal{L}(x^*, y^*, \lambda^*) = \begin{pmatrix} f_{xx} + \lambda^* g_{xx} & f_{xy} + \lambda^* g_{xy} & g_x \\ f_{yx} + \lambda^* g_{yx} & f_{yy} + \lambda^* g_{yy} & g_y \\ g_x & g_y & 0 \end{pmatrix}_{(x^*, y^*, \lambda^*)}.$$

los términos λg_{jk} desaparecen, y queda

$$\bar{H} = \nabla_{(x,y,\lambda)}^2 \mathcal{L}(x^*, y^*, \lambda^*) = \begin{pmatrix} f_{xx} & f_{xy} & g_x \\ f_{yx} & f_{yy} & g_y \\ g_x & g_y & 0 \end{pmatrix}_{(x^*, y^*, \lambda^*)}.$$

Condiciones suficientes para máximo o mínimo

Sea en el punto crítico (x^*, y^*, λ^*) el hessiano orlado

$$\bar{H}(x^*, y^*, \lambda^*) = \begin{pmatrix} 0 & g_x & g_y \\ g_x & f_{xx} + \lambda^* g_{xx} & f_{xy} + \lambda^* g_{xy} \\ g_y & f_{yx} + \lambda^* g_{yx} & f_{yy} + \lambda^* g_{yy} \end{pmatrix}_{(x^*, y^*, \lambda^*)}.$$

Las condiciones suficientes para máximos y mínimos son:

$$\det \bar{H}(x^*, y^*, \lambda^*) > 0 \implies (x^*, y^*) \text{ es un máximo local sujeto a } g = 0$$

$$\det \bar{H}(x^*, y^*, \lambda^*) < 0 \implies (x^*, y^*) \text{ es un mínimo local sujeto a } g = 0$$

Condiciones suficientes: caso general

Sea

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x), \\ \text{sujeto a} \quad & g_i(x) = 0, \quad i = 1, \dots, k \end{aligned}$$

o

$$\begin{aligned} \max_{x \in \mathbb{R}^n} \quad & f(x), \\ \text{sujeto a} \quad & g_i(x) = 0, \quad i = 1, \dots, k \end{aligned}$$

y sea el Lagrangiano

$$\mathcal{L}(x, \lambda) = f(x) + \sum_{i=1}^k \lambda_i g_i(x), \quad \lambda = (\lambda_1, \dots, \lambda_k)$$

Denotemos

$$\nabla g(x) = (\nabla g_1(x) \quad \dots \quad \nabla g_k(x)) \in \mathbb{R}^{n \times k}$$

Suponiendo que $n > k$ (más variables independientes que restricciones). Entonces el *hessiano orlado* se define como la matriz $(k+n) \times (k+n)$

$$\bar{H}(x, \lambda) = \begin{pmatrix} 0_{k \times k} & \nabla g(x) \\ \nabla g(x)^T & \nabla_{xx}^2 \mathcal{L}(x, \lambda) \end{pmatrix}$$

Este hessiano orlado tiene asociado $n+k$ menores principales de orden inicial pero solo basta con analizar estos $n-k$ últimos menores principales de orden inicial:

- **Mínimo local:** si los últimos menores principales de orden inicial (líderes) tienen el signo de $(-1)^k$. Entonces x^* es *mínimo* local sujeto a $g_i = 0$.
- **Máximo local:** Si los signos de los menores principales de orden inicial (líderes) se alternan terminando en el signo de $(-1)^n$ entonces x^* es *máximo* local sujeto a $g_i = 0$.

Veamos ejemplos de esto:

En el caso de dos variables y una restricción, $k = 1, n = 2$ (analizado antes)

Solo tenemos que analizar $2 - 1 = 1$ menor principal de orden inicial:

- **Mínimo local:** si:

$$|\bar{H}|$$

Tiene el signo de $(-1)^k = (-1)^1$ Es decir:

$$|\bar{H}| < 0$$

- **Máximo local:** si:

$$|\bar{H}|$$

Tiene el signo de $(-1)^n = (-1)^2$ Es decir:

$$|H| > 0$$

En el caso de tres variables y una restricción, $k = 1$, $n = 3$

El hessiano orlado asociado es el siguiente:

$$\bar{H}(x^*, y^*, z^*, \lambda^*) = \begin{pmatrix} 0 & g_x & g_y & g_z \\ g_x & f_{xx} + \lambda^* g_{xx} & f_{xy} + \lambda^* g_{xy} & f_{xz} + \lambda^* g_{xz} \\ g_y & f_{yx} + \lambda^* g_{yx} & f_{yy} + \lambda^* g_{yy} & f_{yz} + \lambda^* g_{yz} \\ g_z & f_{zx} + \lambda^* g_{zx} & f_{zy} + \lambda^* g_{zy} & f_{zz} + \lambda^* g_{zz} \end{pmatrix}_{(x^*, y^*, z^*, \lambda^*)}$$

Solo tenemos que analizar $3 - 1 = 2$ menores principales de orden inicial. Sean Δ_1 y Δ_2 los últimos dos menores principales de orden inicial:

$$\Delta_1 = \det \begin{pmatrix} 0 & g_x & g_y \\ g_x & f_{xx} + \lambda^* g_{xx} & f_{xy} + \lambda^* g_{xy} \\ g_y & f_{yx} + \lambda^* g_{yx} & f_{yy} + \lambda^* g_{yy} \end{pmatrix}$$

$$\Delta_2 = \det \begin{pmatrix} 0 & g_x & g_y & g_z \\ g_x & f_{xx} + \lambda^* g_{xx} & f_{xy} + \lambda^* g_{xy} & f_{xz} + \lambda^* g_{xz} \\ g_y & f_{yx} + \lambda^* g_{yx} & f_{yy} + \lambda^* g_{yy} & f_{yz} + \lambda^* g_{yz} \\ g_z & f_{zx} + \lambda^* g_{zx} & f_{zy} + \lambda^* g_{zy} & f_{zz} + \lambda^* g_{zz} \end{pmatrix}_{(x^*, y^*, z^*, \lambda^*)}$$

- **Mínimo local:** si:

$$\Delta_1, \Delta_2$$

Tienen el mismo signo que $(-1)^k = (-1)^1$ es decir

$$\Delta_1, \Delta_2 < 0$$

- **Máximo local:** si:

$$\Delta_1, \Delta_2$$

Alternan el signo terminando con el signo de $(-1)^n = (-1)^3$ Es decir:

$$\Delta_1 > 0$$

$$\Delta_2 < 0$$

En el caso de tres variables y dos restricciones, $k = 2$, $n = 3$

El hessiano orlado asociado en $(x^*, y^*, z^*, \lambda_1^*, \lambda_2^*)$ es

$$\bar{H}(x^*, y^*, z^*, \lambda_1^*, \lambda_2^*) = \begin{pmatrix} 0 & 0 & g_{1x} & g_{1y} & g_{1z} \\ 0 & 0 & g_{2x} & g_{2y} & g_{2z} \\ g_{1x} & g_{2x} & f_{xx} + \lambda_1^* g_{1xx} + \lambda_2^* g_{2xx} & f_{xy} + \lambda_1^* g_{1xy} + \lambda_2^* g_{2xy} & f_{xz} + \lambda_1^* g_{1xz} + \lambda_2^* g_{2xz} \\ g_{1y} & g_{2y} & f_{yx} + \lambda_1^* g_{1yx} + \lambda_2^* g_{2yx} & f_{yy} + \lambda_1^* g_{1yy} + \lambda_2^* g_{2yy} & f_{yz} + \lambda_1^* g_{1yz} + \lambda_2^* g_{2yz} \\ g_{1z} & g_{2z} & f_{zx} + \lambda_1^* g_{1zx} + \lambda_2^* g_{2zx} & f_{zy} + \lambda_1^* g_{1zy} + \lambda_2^* g_{2zy} & f_{zz} + \lambda_1^* g_{1zz} + \lambda_2^* g_{2zz} \end{pmatrix}$$

Solo tenemos que analizar $(3 - 2) = 1$ menor principal de orden inicial es decir $|\bar{H}|$.

- **Mínimo local:** si:

$$|\bar{H}|$$

Tiene el signo de $(-1)^k = (-1)^2$ Es decir:

$$|\bar{H}| > 0$$

- **Máximo local:** si:

$$|\bar{H}|$$

Tiene el signo de $(-1)^n = (-1)^3$ Es decir:

$$|H| < 0$$

Condiciones para máximos y mínimos globales y únicos

Al igual que en optimización no restringida es necesario especificar si la función es cóncava o convexa para la existencia de un máximo o mínimo global, con la optimización restringida ocurre lo mismo. Sea

$$f : \mathbb{R}^n \longrightarrow \mathbb{R}$$

la función objetivo y sea

$$C = \{x \in \mathbb{R}^n : h_j(x) = 0, j = 1, \dots, p\}$$

el conjunto factible.

Condiciones para máximo global y único

Si f es estrictamente cuasicóncava y el conjunto factible C es convexo, entonces cualquier óptimo local del problema

$$\max_{x \in C} f(x)$$

es también óptimo global y único.

Condiciones para mínimo global y único

Si f es estrictamente cuasiconvexa y el conjunto factible C es convexo, entonces cualquier óptimo local del problema

$$\min_{x \in C} f(x)$$

es también óptimo global y único.

22 Aplicaciones económicas con optimización con restricciones de igualdad

Interpretación del multiplicador de Lagrange

La interpretación del multiplicador de lagrange puede verse como el efecto que tiene relajar la restricción sobre la función objetivo. El significado de “relajar” la restricción dependerá de si estamos maximizando o minimizando. Para entender claramente vamos a ver un ejemplo de maximización de utilidad.

Consideremos un consumidor que elige $x = (x_1, x_2) \in \mathbb{R}_+^2$ para maximizar su utilidad sujeta a una restricción presupuestaria lineal:

$$\max_{x \geq 0} u(x_1, x_2) \quad \text{s.a.} \quad p_1 x_1 + p_2 x_2 = M,$$

donde $p = (p_1, p_2) \gg 0$ son los precios y $M > 0$ es el ingreso. Denotemos por

$$v(M, p) = u(x_1^*, x_2^*)$$

la *utilidad indirecta*. Usaremos la convención de Lagrangiano

$$\mathcal{L}(x, \lambda; M, p) = u(x) + \lambda (M - p_1 x_1 - p_2 x_2),$$

Teorema de la envolvente (versión paramétrica)

Las condiciones de primer orden requieren que:

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x_1}(x_1, x_2, \lambda) &= u_{x_1}(x_1, x_2) - \lambda p_1 = 0, \\ \frac{\partial \mathcal{L}}{\partial x_2}(x_1, x_2, \lambda) &= u_{x_2}(x_1, x_2) - \lambda p_2 = 0, \\ \frac{\partial \mathcal{L}}{\partial \lambda}(x_1, x_2, \lambda) &= M - p_1 x_1 - p_2 x_2 = 0. \end{aligned}$$

El teorema de la envolvente indica que si buscamos derivar la función objetivo en el óptimo respecto a un parámetro, podemos primero obtener la función de utilidad indirecta y después derivar o primero derivar y después reemplazar por los valores de x_1, x_2 en el óptimo. Es decir, dado que tanto x_1 , como x_2 y λ en el óptimo dependerían de M .

$$\mathcal{L}(x_1, x_2, \lambda; M, p) = u(x_1, x_2) + \lambda (M - p_1 x_1 - p_2 x_2),$$

y evaluando a lo largo de la solución óptima $(x_1^*(M, p), x_2^*(M, p), \lambda^*(M, p))$, se tiene

$$\frac{d}{dM} \mathcal{L}(x_1^*, x_2^*, \lambda^*; M, p) = \underbrace{\mathcal{L}'_{x_1}}_0 \frac{dx_1^*}{dM} + \underbrace{\mathcal{L}'_{x_2}}_0 \frac{dx_2^*}{dM} + \underbrace{\mathcal{L}'_{\lambda}}_0 \frac{d\lambda^*}{dM} + \underbrace{\mathcal{L}_M}_{=\lambda}.$$

Por las condiciones de primer orden en el óptimo,

$$\mathcal{L}'_{x_1}(x_1^*, x_2^*, \lambda^*; M, p) = 0, \quad \mathcal{L}'_{x_2}(x_1^*, x_2^*, \lambda^*; M, p) = 0, \quad \mathcal{L}'_{\lambda}(x_1^*, x_2^*, \lambda^*; M, p) = 0,$$

Entonces

$$\frac{d}{dM} \mathcal{L}(x_1^*, x_2^*, \lambda^*; M, p) = \mathcal{L}_M(x_1^*, x_2^*, \lambda^*; M, p) = \lambda^*(M, p).$$

En particular, como en el óptimo la restricción se cumple con igualdad $M - p_1 x_1^* - p_2 x_2^* = 0$, el Lagrangiano evaluado en el óptimo coincide con la utilidad:

$$v(M, p) = u(x_1^*, x_2^*) = \mathcal{L}(x_1^*, x_2^*, \lambda^*; M, p).$$

La conclusión entonces es que

$$\frac{\partial v(M, p)}{\partial M} = \frac{\partial \mathcal{L}}{\partial M} \Big|_{(x_1^*, x_2^*, \lambda^*; M, p)} = \lambda^*(M, p)$$

Es decir, λ^* mide el cambio marginal de la utilidad óptima cuando se *relaja* la restricción presupuestaria en una unidad, o sea, cuando se le da ingresos adicionales al individuo. Por eso λ^* se interpreta como *utilidad marginal del ingreso*. Esto puede ser útil ya que nos informa cómo cambia la utilidad si le brindamos al individuo una unidad monetaria adicional.

Ejemplo

Datos: $M = 100$, $p_1 = 10$, $p_2 = 20$, $u(x_1, x_2) = x_1^2 x_2^2$.

$$\max_{x_1, x_2 > 0} x_1^2 x_2^2 \quad \text{s.a.} \quad 10x_1 + 20x_2 = 100, \quad \mathcal{L}(x_1, x_2, \lambda) = x_1^2 x_2^2 + \lambda(100 - 10x_1 - 20x_2).$$

CPO

$$\mathcal{L}_{x_1} = 2x_1 x_2^2 - 10\lambda = 0, \quad \mathcal{L}_{x_2} = 2x_2 x_1^2 - 20\lambda = 0, \quad \mathcal{L}_\lambda = 100 - 10x_1 - 20x_2 = 0.$$

De las dos primeras:

$$\frac{2x_1 x_2^2}{10} = \lambda = \frac{2x_2 x_1^2}{20} \implies 2x_2 = x_1.$$

Con la restricción:

$$10(2x_2) + 20x_2 = 100 \implies 40x_2 = 100 \implies x_2^* = 2.5, \quad x_1^* = 5.$$

$$v(100, 10, 20) = u(x_1^*, x_2^*) = 5^2 \cdot 2.5^2 = 25 \cdot 6.25 = 156.25.$$

Multiplicador lagrangiano

$$\lambda^* = \frac{2x_1^*(x_2^*)^2}{10} = \frac{2 \cdot 5 \cdot (2.5)^2}{10} = \frac{10 \cdot 6.25}{10} = 6.25.$$

La interpretación es la siguiente: si aumentamos el ingreso en una unidad (manteniendo precios), la utilidad óptima aumenta en aproximadamente 6.25 unidades. O sea la nueva utilidad sería de 162.5

Ejemplo con minimización

El multiplicador de lagrange también puede interpretarse en el contexto de una minimización.

Datos: $w_1 = 10$, $w_2 = 40$, meta de producción = 100, tecnología $F(z_1, z_2) = \sqrt{z_1 z_2}$.

$$\min_{z_1, z_2 > 0} C = 10z_1 + 40z_2 \quad \text{s.a.} \quad \sqrt{z_1 z_2} = 100, \quad \mathcal{L}(z_1, z_2, \mu) = 10z_1 + 40z_2 + \mu(100 - \sqrt{z_1 z_2}).$$

CPO

$$\mathcal{L}_{z_1} = 10 - \mu \cdot \frac{1}{2} z_1^{-1/2} z_2^{1/2} = 0, \quad \mathcal{L}_{z_2} = 40 - \mu \cdot \frac{1}{2} z_2^{-1/2} z_1^{1/2} = 0, \quad \sqrt{z_1 z_2} = 100.$$

De las dos primeras:

$$\frac{10}{40} = \frac{z_2}{z_1} \implies z_2 = \frac{1}{4} z_1.$$

Con la restricción: $z_1 z_2 = 100^2 \implies z_1 \left(\frac{1}{4} z_1\right) = 10,000 \implies z_1^2 = 40,000 \implies z_1^* = 200$, $z_2^* = 50$.

Costo mínimo e interpretación de μ^*

$$C_{\min} = 10 \cdot 200 + 40 \cdot 50 = 2000 + 2000 = 4000.$$

$$\mu^* = 2\sqrt{w_1 w_2} = 2\sqrt{10 \cdot 40} = 40.$$

$\mu^* = 40$ nos indica que al relajar la restricción (es decir si en vez de exigir una producción de 100, exigimos solo 99 unidades), el costo mínimo se reduce aproximadamente en 40. Por lo tanto el costo nuevo sería de 3960.

Otro ejemplo económico: minimización de costes sujeto a restricción.

Consideremos una empresa cuya tecnología de producción viene dada por la función Cobb–Douglas

$$y = F(L, K) = L^\alpha K^{1-\alpha} \quad \alpha \in (0, 1)$$

donde L y K son trabajo y capital, y $y > 0$ es el nivel de output

Problema de minimización de costes

Dados los precios de los factores w (salario) y r (renta del capital) y el nivel y , la empresa resuelve

$$\min_{L, K} C = wL + rK \quad \text{sujeto a} \quad L^\alpha K^{1-\alpha} = y$$

Demanda condicionada y coste mínimo

Escribimos el Lagrangiano

$$\mathcal{L} = wL + rK + \mu(y - L^\alpha K^{1-\alpha})$$

Las condiciones de primer orden son

$$\frac{\partial \mathcal{L}}{\partial L} = w - \mu \alpha L^{\alpha-1} K^{1-\alpha} = 0 \quad \frac{\partial \mathcal{L}}{\partial K} = r - \mu (1-\alpha) L^\alpha K^{-\alpha} = 0$$

junto con la restricción $L^\alpha K^{1-\alpha} = y$. De las dos primeras:

$$\frac{w}{\alpha} L^{1-\alpha} K^{\alpha-1} = \frac{r}{1-\alpha} L^{-\alpha} K^\alpha \implies \frac{L^*}{K^*} = \frac{\alpha}{1-\alpha} \frac{r}{w}$$

Sustituyendo en $L^\alpha K^{1-\alpha} = y$ y resolviendo se obtienen las demandas condicionadas

$$L^*(w, r, y) = y \left(\frac{\alpha}{w} \right)^\alpha \left(\frac{1-\alpha}{r} \right)^{1-\alpha} \quad K^*(w, r, y) = y \left(\frac{\alpha}{w} \right)^\alpha \left(\frac{1-\alpha}{r} \right)^{1-\alpha} (1-\alpha)$$

El coste mínimo resultante es

$$C(w, r, y) = w L^*(w, r, y) + r K^*(w, r, y) = y \left(\frac{w}{\alpha} \right)^\alpha \left(\frac{r}{1-\alpha} \right)^{1-\alpha}$$

Lema de Shephard

La función de coste $C(w, r, y)$ es la envolvente de la familia de funciones $wL + rK$ sujeta a $F(L, K) = y$. Por el teorema de la envolvente, al derivar C con respecto a w (tratando y, r constantes) basta con tomar el efecto directo:

$$\frac{\partial C}{\partial w} = L^*(w, r, y)$$

De hecho, si derivamos la expresión encontrada:

$$\frac{\partial}{\partial w} \left[y (w/\alpha)^\alpha (r/(1-\alpha))^{1-\alpha} \right] = y \alpha (w/\alpha)^{\alpha-1} (r/(1-\alpha))^{1-\alpha} = L^*(w, r, y)$$

Análogamente,

$$\frac{\partial C}{\partial r} = K^*(w, r, y)$$

Interpretación

- $C(w, r, y)$ es la curva de coste de largo plazo: “envuelve” todas las rectas $wL + rK$ tangentes a las iso-productivas $L^\alpha K^{1-\alpha} = y$
- La envolvente simplifica el cálculo de las *demandas condicionadas*: no necesitamos derivar $L^*(w, r, y)$ ni $K^*(w, r, y)$ respecto a w o r para obtener $\partial C/\partial w$, $\partial C/\partial r$
- **Este resultado se conoce como el Lema de Shephard.** El cual nos dice que una vez que tenemos la función de costo indirecta basta con derivar esta con respecto a los precios de los insumos para encontrar la demanda de insumos condicionada.

23 Optimización con restricciones de desigualdad

Problema con una sola variable independiente

Consideremos el problema


$$\max_{x \geq 0} f(x), \quad f \in C^1(\mathbb{R}).$$

Un punto x^* es máximo local solo en una de estas dos situaciones:


- **Interior:** $x^* > 0$ y $f'(x^*) = 0$. Aquí la restricción no interviene y se cumple la condición clásica de primer orden.
- **Frontera:** $x^* = 0$ y $f'(0) \leq 0$.

Obsérvese que $f'(0) > 0$ no puede corresponder a un máximo, pues implicaría pendiente creciente al inicio de la región factible.


Gráficamente los casos son los siguientes: $f'(x) = 0$ por lo que la restricción no está activa.



Por otro lado $f'(x) < 0$ implica que la restricción está activa: $x = 0$.



Y por último también es posible que sucedan las dos cosas al mismo tiempo: $f'(x) = 0$ y $x = 0$.



Estas condiciones anteriores pueden resumirse:

$$f'(x) \leq 0, \quad x \geq 0, \quad x f'(x) = 0.$$

De esas condiciones se deduce que necesariamente

$$x = 0 \quad \text{o} \quad f'(x) = 0,$$

pues la última igualdad obliga a que al menos uno de los factores sea cero.

- $x \geq 0$:
- $f'(x) \leq 0$:
- $x f'(x) = 0$: *holgura complementaria*.

Minimización

Análogamente, para

$$\min_{x \geq 0} f(x),$$

las condiciones necesarias son

$$f'(x) \geq 0, \quad x \geq 0, \quad x f'(x) = 0,$$

Ejemplo

Consideremos el problema

$$\max_{x \geq 0} f(x), \quad f(x) = -x^2 - x - 1,$$

Caso 1: la restricción está inactiva (óptimo interior).

Si la restricción no actuase, existiría un máximo interior $x^* > 0$ y por lo tanto por la condición de holgura complementaria $x f'(x) = 0$ tenemos que:

$$f'(x^*) = 0.$$

Pero

$$f'(x) = -2x - 1,$$

luego

$$-2x^* - 1 = 0 \implies x^* = -\frac{1}{2},$$

que contradice $x^* > 0$. Por tanto no puede haber óptimo interior en la región factible.


Caso 2: la restricción está activa (óptimo en la frontera).

La única posibilidad restante es que $x^* = 0$. Para verificar que es un máximo local basta comprobar la condición de primer orden en la frontera:

$$f'(0) = -2 \cdot 0 - 1 = -1 \leq 0.$$

Conclusión: En este ejemplo la restricción $x \geq 0$ está activa en el óptimo ($x^* = 0$), y el valor óptimo es $f(0) = -1 < 0$.

Gráficamente:



Problema con n variables independientes y restricciones de no negatividad

Consideremos

$$\max_{x \in \mathbb{R}_+^n} f(x_1, \dots, x_n), \quad f \in C^1(\mathbb{R}^n),$$

es decir, sujeto a $x_j \geq 0$ para $j = 1, \dots, n$.

Las condiciones de primer orden adaptadas a estas restricciones son, para cada $j = 1, \dots, n$:

$$\frac{\partial f}{\partial x_j} \leq 0, \quad x_j \geq 0, \quad x_j \frac{\partial f}{\partial x_j} = 0,$$

Problema con tres variables y dos restricciones de desigualdad

Planteamos primero el problema en forma de desigualdades:

$$\max_{x_1, x_2, x_3} f(x_1, x_2, x_3)$$

sujeto a

$$\begin{cases} g^1(x_1, x_2, x_3) \leq r_1, \\ g^2(x_1, x_2, x_3) \leq r_2, \\ x_1, x_2, x_3 \geq 0. \end{cases}$$

Al añadir las variables ficticias $s_1, s_2 \geq 0$ podemos convertir cada desigualdad en una igualdad:

$$\begin{cases} g^1(x_1, x_2, x_3) + s_1 = r_1, \\ g^2(x_1, x_2, x_3) + s_2 = r_2, \\ x_1, x_2, x_3, s_1, s_2 \geq 0. \end{cases}$$

Lagrangiano y condiciones de primer orden

A partir del problema con variables de holgura

$$\begin{aligned} & \max_{x_1, x_2, x_3, s_1, s_2} f(x_1, x_2, x_3) \\ & \text{sujeto a } \begin{aligned} & g^1(x_1, x_2, x_3) + s_1 = r_1, \\ & g^2(x_1, x_2, x_3) + s_2 = r_2, \\ & x_j \geq 0 \ (j = 1, 2, 3), \quad s_i \geq 0 \ (i = 1, 2), \end{aligned} \end{aligned}$$

definimos el *Lagrangiano*

$$\mathcal{L}(x, s, \lambda) = f(x_1, x_2, x_3) + \lambda_1 [r_1 - g^1(x_1, x_2, x_3) - s_1] + \lambda_2 [r_2 - g^2(x_1, x_2, x_3) - s_2].$$

Aquí $\lambda_1, \lambda_2 \in \mathbb{R}$ son los multiplicadores asociados a las igualdades.

Condiciones de primer orden

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x_1} &= f_1(x) - \lambda_1 g_1^1(x) - \lambda_2 g_1^2(x) \leq 0, \quad x_1 \geq 0, \quad x_1 \frac{\partial \mathcal{L}}{\partial x_1} = 0, \\ \frac{\partial \mathcal{L}}{\partial x_2} &= f_2(x) - \lambda_1 g_2^1(x) - \lambda_2 g_2^2(x) \leq 0, \quad x_2 \geq 0, \quad x_2 \frac{\partial \mathcal{L}}{\partial x_2} = 0, \\ \frac{\partial \mathcal{L}}{\partial x_3} &= f_3(x) - \lambda_1 g_3^1(x) - \lambda_2 g_3^2(x) \leq 0, \quad x_3 \geq 0, \quad x_3 \frac{\partial \mathcal{L}}{\partial x_3} = 0, \\ \frac{\partial \mathcal{L}}{\partial s_1} &= -\lambda_1 \leq 0, \quad s_1 \geq 0, \quad s_1 \frac{\partial \mathcal{L}}{\partial s_1} = 0, \\ \frac{\partial \mathcal{L}}{\partial s_2} &= -\lambda_2 \leq 0, \quad s_2 \geq 0, \quad s_2 \frac{\partial \mathcal{L}}{\partial s_2} = 0, \\ \frac{\partial \mathcal{L}}{\partial \lambda_1} &= r_1 - g^1(x_1, x_2, x_3) - s_1 = 0, \\ \frac{\partial \mathcal{L}}{\partial \lambda_2} &= r_2 - g^2(x_1, x_2, x_3) - s_2 = 0. \end{aligned}$$

Eliminación de las variables ficticias de las condiciones de primer orden

Tomemos la condición respecto a un multiplicador de lagrange:

$$\frac{\partial \mathcal{L}}{\partial \lambda_i} = r_i - g^i(x_1, x_2, x_3) - s_i = 0,$$

se despeja inmediatamente

$$s_i = r_i - g^i(x_1, x_2, x_3), \quad i = 1, 2.$$

Ahora sustituimos s_i en las tres condiciones

$$\frac{\partial \mathcal{L}}{\partial s_i} \leq 0, \quad s_i \geq 0, \quad s_i \frac{\partial \mathcal{L}}{\partial s_i} = 0,$$

recordando que $\partial \mathcal{L} / \partial s_i = -\lambda_i$. Obtenemos:

$$\begin{aligned} -\lambda_i \leq 0 &\implies \lambda_i \geq 0, \\ r_i - g^i(x_1, x_2, x_3) &\geq 0 \\ (r_i - g^i(x_1, x_2, x_3)) (-\lambda_i) &= 0 \implies \lambda_i (r_i - g^i(x_1, x_2, x_3)) = 0. \end{aligned}$$

En consecuencia, las condiciones de Kuhn-Tucker quedan:

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial x_j} \leq 0, \\ x_j \geq 0, \\ x_j \frac{\partial \mathcal{L}}{\partial x_j} = 0 \end{cases} \quad (j = 1, 2, 3)$$

$$\begin{cases} r_i - g^i(x_1, x_2, x_3) \geq 0, \\ \lambda_i \geq 0, \\ \lambda_i [r_i - g^i(x_1, x_2, x_3)] = 0 \end{cases} \quad (i = 1, 2)$$

Véase que $r_i - g^i(x_1, x_2, x_3)$ coincide con la derivada del lagrangiano sin incluir las variables ficticias s_i . Entonces podemos expresar las condiciones de la siguiente manera:

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x_j} &\leq 0, \quad x_j \geq 0, \quad x_j \frac{\partial \mathcal{L}}{\partial x_j} = 0, \\ \frac{\partial \mathcal{L}}{\partial \lambda_i} &\geq 0, \quad \lambda_i \geq 0, \quad \lambda_i \frac{\partial \mathcal{L}}{\partial \lambda_i} = 0, \end{aligned}$$

Resumen de las condiciones

Sea

$$L(x, \lambda) = f(x_1, \dots, x_n) + \sum_{i=1}^k \lambda_i [r_i - g^i(x_1, \dots, x_n)]$$

el Lagrangiano asociado a

$$\max_{x \in \mathbb{R}_+^n} f(x) \quad \text{sujeto a} \quad g^i(x) \leq r_i \quad (i = 1, \dots, k)$$

donde

$$\mathbb{R}_+^n = \{x \in \mathbb{R}^n : x_j \geq 0 \quad \forall j = 1, \dots, n\}$$

Las condiciones de Kuhn-Tucker para un máximo son

$$\begin{cases} \frac{\partial L}{\partial x_j} \leq 0, & x_j \geq 0, & x_j \frac{\partial L}{\partial x_j} = 0 & j = 1, \dots, n \\ \frac{\partial L}{\partial \lambda_i} \geq 0, & \lambda_i \geq 0, & \lambda_i \frac{\partial L}{\partial \lambda_i} = 0 & i = 1, \dots, k \end{cases}$$

Condiciones Kuhn-Tucker generales para un mínimo

Sea

$$L(x, \lambda) = f(x_1, \dots, x_n) + \sum_{i=1}^k \lambda_i [r_i - g^i(x_1, \dots, x_n)]$$

el Lagrangiano asociado a

$$\min_{x \in \mathbb{R}_+^n} f(x) \quad \text{sujeto a} \quad g^i(x) \geq r_i \quad (i = 1, \dots, k)$$

donde

$$\mathbb{R}_+^n = \{x \in \mathbb{R}^n : x_j \geq 0 \quad \forall j = 1, \dots, n\}$$

Las condiciones de Kuhn-Tucker necesarias para un mínimo son

$$\begin{cases} \frac{\partial L}{\partial x_j} \geq 0, & x_j \geq 0, & x_j \frac{\partial L}{\partial x_j} = 0 & j = 1, \dots, n \\ \frac{\partial L}{\partial \lambda_i} \leq 0, & \lambda_i \geq 0, & \lambda_i \frac{\partial L}{\partial \lambda_i} = 0 & i = 1, \dots, k \end{cases}$$

Ejemplo maximización

Consideremos

$$\max_{x, y} U(x, y) = xy \quad \text{sujeto a} \quad \begin{cases} x + y \leq 100, \\ x \leq 40, \\ x \geq 0, y \geq 0. \end{cases}$$

Asignamos multiplicadores $\lambda_1, \lambda_2 \geq 0$ a las dos primeras desigualdades y construimos el Lagrangiano

$$\mathcal{L}(x, y, \lambda_1, \lambda_2) = xy + \lambda_1(100 - x - y) + \lambda_2(40 - x).$$

Las condiciones de Kuhn-Tucker se agrupan en:

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x} &= y - \lambda_1 - \lambda_2 \leq 0, & x &\geq 0, & x(y - \lambda_1 - \lambda_2) &= 0, \\ \frac{\partial \mathcal{L}}{\partial y} &= x - \lambda_1 \leq 0, & y &\geq 0, & y(x - \lambda_1) &= 0, \\ \frac{\partial \mathcal{L}}{\partial \lambda_1} &= 100 - x - y \geq 0, & \lambda_1 &\geq 0, & \lambda_1(100 - x - y) &= 0, \\ \frac{\partial \mathcal{L}}{\partial \lambda_2} &= 40 - x \geq 0, & \lambda_2 &\geq 0, & \lambda_2(40 - x) &= 0. \end{aligned}$$

Analizando las regiones:

En el óptimo $x^*, y^* > 0$ ya que de lo contrario la utilidad sería 0, entonces las dos primeras desigualdades se vuelven igualdades (por las condiciones de holgura complementaria)

$$y^* - \lambda_1 - \lambda_2 = 0, \quad x^* - \lambda_1 = 0.$$

Analizando las regiones, consideremos las cuatro combinaciones posibles de λ_1 y λ_2 :

Caso 1: $\lambda_1 = 0, \lambda_2 = 0$.

Entonces

$$\frac{\partial \mathcal{L}}{\partial x} = y \leq 0, \quad \frac{\partial \mathcal{L}}{\partial y} = x \leq 0 \quad \implies \quad x = y = 0,$$

con $x, y \geq 0$. Esto da $U = 0$, no es máximo interior con $U > 0$. (*Descartado.*)

Caso 2: $\lambda_1 > 0, \lambda_2 = 0$.

Por holgura complementaria en $x, y > 0$:

$$y - \lambda_1 = 0, \quad x - \lambda_1 = 0 \implies x = y = \lambda_1,$$

y por la restricción activa $x + y = 100$:

$$2\lambda_1 = 100 \implies x = y = 50,$$

pero viola $x \leq 40$. (*Descartado.*)

Caso 3: $\lambda_1 = 0, \lambda_2 > 0$.

Holgura complementaria obliga

$$40 - x = 0 \implies x = 40,$$

Y yendo a la segunda condición tenemos: $x - \lambda_1 = 0$. Pero como $\lambda_1 = 0$ y $x = 40$, esta condición no se cumple. (*Descartado.*)

Caso 4: $\lambda_1 > 0, \lambda_2 > 0$.

Ambas restricciones activas:

$$x + y = 100, \quad x = 40 \implies (x, y) = (40, 60).$$

De las derivadas:

$$x - \lambda_1 = 0 \implies \lambda_1 = 40, \quad y - \lambda_1 - \lambda_2 = 0 \implies \lambda_2 = 20 > 0,$$

todo consistente. $x^* = 40, y^* = 60, U = 2400$.

Ejemplo minimización

Consideremos el problema

$$\min_{x_1, x_2} C(x_1, x_2) = (x_1 - 4)^2 + (x_2 - 4)^2$$

sujeto a

$$\begin{cases} 2x_1 + 3x_2 \geq 6, \\ -3x_1 - 2x_2 \geq -12, \\ x_1 \geq 0, x_2 \geq 0. \end{cases}$$

Reescribimos las dos primeras como

$$g_1(x) \equiv 6 - 2x_1 - 3x_2 \leq 0, \quad g_2(x) \equiv 3x_1 + 2x_2 - 12 \leq 0,$$

y asignamos multiplicadores $\lambda_1, \lambda_2 \geq 0$. El Lagrangiano es

$$\mathcal{L} = (x_1 - 4)^2 + (x_2 - 4)^2 + \lambda_1 (6 - 2x_1 - 3x_2) + \lambda_2 (3x_1 + 2x_2 - 12).$$

Condiciones de Kuhn-Tucker

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial x_1} = 2(x_1 - 4) - 2\lambda_1 + 3\lambda_2 \geq 0, \quad x_1 \geq 0, \quad x_1 [2(x_1 - 4) - 2\lambda_1 + 3\lambda_2] = 0, \\ \frac{\partial \mathcal{L}}{\partial x_2} = 2(x_2 - 4) - 3\lambda_1 + 2\lambda_2 \geq 0, \quad x_2 \geq 0, \quad x_2 [2(x_2 - 4) - 3\lambda_1 + 2\lambda_2] = 0, \\ g_1(x) = 6 - 2x_1 - 3x_2 \leq 0, \quad \lambda_1 \geq 0, \quad \lambda_1 (6 - 2x_1 - 3x_2) = 0, \\ g_2(x) = 3x_1 + 2x_2 - 12 \leq 0, \quad \lambda_2 \geq 0, \quad \lambda_2 (3x_1 + 2x_2 - 12) = 0. \end{cases}$$

Análisis de casos Primero pensemos el caso de $(4, 4)$ que dada la función de costos puede ser un potencial óptimo. Sin embargo, $(4, 4)$ viola g_2 . Por lo que vamos a analizar los otros casos posibles, suponiendo que $x_1 > 0$ y $x_2 > 0$

$$x_1 > 0 \implies \frac{\partial \mathcal{L}}{\partial x_1} = 0, \quad x_2 > 0 \implies \frac{\partial \mathcal{L}}{\partial x_2} = 0,$$

y de que las dos restricciones pueden estar activas o inactivas. Hay cuatro combinaciones de $\lambda_1, \lambda_2 \geq 0$:

Caso 1: $\lambda_1 = 0, \lambda_2 = 0$.

De la derivada con respecto a x_1 : $2(x_1 - 4) = 0 \Rightarrow x_1 = 4$ y $2(x_2 - 4) = 0 \Rightarrow x_2 = 4$. Pero la segunda restricción $3x_1 + 2x_2 \leq 12$ se viola ($20 > 12$). *Descartado.*

Caso 2: $\lambda_1 > 0, \lambda_2 = 0$.

De las condiciones obtenemos que:

$$2(x_1 - 4) - 2\lambda_1 = 0 \quad (x_1 = 4 + \lambda_1), \quad 2(x_2 - 4) - 3\lambda_1 = 0 \quad (x_2 = 4 + \frac{3}{2}\lambda_1).$$

Además, $\lambda_1 > 0$ implica $2x_1 + 3x_2 = 6$, que no admite $\lambda_1 > 0$. *Descartado.*

Caso 3: $\lambda_1 = 0, \lambda_2 > 0$.

$$2(x_1 - 4) + 3\lambda_2 = 0 \Rightarrow x_1 = 4 - \frac{3}{2}\lambda_2,$$

$$2(x_2 - 4) + 2\lambda_2 = 0 \Rightarrow x_2 = 4 - \lambda_2,$$

y $\lambda_2 > 0$ obliga $3x_1 + 2x_2 = 12$. Resolviendo:

$$x_1 = \frac{28}{13}, \quad x_2 = \frac{36}{13}, \quad \lambda_2 = \frac{16}{13} > 0.$$

Se verifica $6 - 2x_1 - 3x_2 < 0$ (la primera restricción es inactiva). *Solución válida.*

Caso 4: $\lambda_1 > 0, \lambda_2 > 0$.

Ambas restricciones activas:

$$2x_1 + 3x_2 = 6, \quad 3x_1 + 2x_2 = 12 \implies (x_1, x_2) = (\frac{24}{5}, -\frac{6}{5}),$$

que viola $x_2 \geq 0$. *Descartado.*

Por tanto, el único caso factible es $\lambda_1 = 0, \lambda_2 = \frac{16}{13}$, con

$$(x_1^*, x_2^*) = \left(\frac{28}{13}, \frac{36}{13}\right).$$

Ejemplo sin restricciones de no negatividad

$$\begin{cases} \min f(x, y) = (x - 1)^4 + e^y \\ \text{s. a. } 2x + y \leq 5 \end{cases}$$

Problema de minimización propuesto

Consideremos el siguiente problema de optimización con restricción de desigualdad:

$$\min_{x,y} f(x,y) = (x-1)^4 + e^y$$

sujeto a

$$-2x - y \geq -5.$$

Notemos que la restricción puede reescribirse como

$$-2x - y + 5 \geq 0.$$

Para usar las condiciones de Kuhn–Tucker en la forma estándar $g(x,y) \leq 0$, definimos

$$g(x,y) \equiv (2x + y - 5) \leq 0.$$

Esta $g(x,y) \leq 0$ es algebraicamente la misma que la restricción original $-2x - y \geq -5$, sólo escrita al otro lado. Vamos a trabajar con $g(x,y)$ para construir el Lagrangiano, pero cuando verifiquemos factibilidad siempre vamos a chequear la forma original

$$-2x - y \geq -5.$$

Introducimos el multiplicador de Kuhn–Tucker $\lambda \geq 0$. El Lagrangiano es

$$\mathcal{L}(x,y,\lambda) = (x-1)^4 + e^y + \lambda(2x + y - 5).$$

Condiciones de Kuhn–Tucker Las condiciones KKT (necesarias y, como veremos, suficientes) son:

$$\left\{ \begin{array}{ll} (1) \text{ Estacionariedad:} & \frac{\partial \mathcal{L}}{\partial x} = 4(x-1)^3 + 2\lambda = 0, \\ & \frac{\partial \mathcal{L}}{\partial y} = e^y + \lambda = 0, \\ (2) \text{ Factibilidad primal:} & -2x - y \geq -5, \\ (3) \text{ Factibilidad dual:} & \lambda \geq 0, \\ (4) \text{ Holgura complementaria:} & \lambda(2x + y - 5) = 0. \end{array} \right.$$

Observación importante: En el Lagrangiano usamos $2x + y - 5$, pero la factibilidad primal la seguimos expresando en la forma original $-2x - y \geq -5$, es decir, “mayor o igual a un número”.

Análisis de casos Vamos a estudiar las dos posibilidades para λ .

Caso 1: $\lambda = 0$

Si $\lambda = 0$, las ecuaciones de estacionariedad quedan:

$$4(x-1)^3 + 0 = 0 \implies (x-1)^3 = 0 \implies x = 1,$$

y

$$e^y + 0 = 0 \implies e^y = 0,$$

lo cual es imposible porque $e^y > 0$ para todo y . Por lo tanto, $\lambda = 0$ no puede describir el óptimo.

Caso 2: $\lambda > 0$

Si $\lambda > 0$, por holgura complementaria debe cumplirse

$$2x + y - 5 = 0 \implies y = 5 - 2x.$$

Usamos estacionariedad otra vez. De

$$\frac{\partial \mathcal{L}}{\partial y} = e^y + \lambda = 0 \implies \lambda = -e^y.$$

Como $\lambda > 0$, esto nos dice que $-e^y > 0$, lo cual sería imposible. Esto sugiere que, con el Lagrangiano escrito como

$$\mathcal{L}(x, y, \lambda) = f(x, y) + \lambda(2x + y - 5),$$

el signo de λ que hace que KKT funcione debe ser $\lambda \leq 0$ si usamos $2x + y - 5$ directamente.

Para evitar esa inconsistencia de signos, es más cómodo (y estándar) definir la restricción *negada* en el Lagrangiano, tal como se hizo en el ejemplo anterior:

Reescribimos:

$$g(x, y) \equiv 5 - 2x - y \leq 0,$$

que es exactamente la misma restricción original $-2x - y \geq -5$, sólo movida de lado. Ahora tomamos el Lagrangiano en la forma

$$\tilde{\mathcal{L}}(x, y, \lambda) = (x - 1)^4 + e^y + \lambda(5 - 2x - y), \quad \lambda \geq 0.$$

Volvemos a plantear las KKT con esta versión (que es la convención usual y evita el problema de signo):

$$\left\{ \begin{array}{ll} (1) \text{ Estacionariedad:} & \begin{aligned} \frac{\partial \tilde{\mathcal{L}}}{\partial x} &= 4(x - 1)^3 - 2\lambda = 0, \\ \frac{\partial \tilde{\mathcal{L}}}{\partial y} &= e^y - \lambda = 0, \end{aligned} \\ (2) \text{ Factibilidad primal (forma original):} & -2x - y \geq -5, \\ (3) \text{ Factibilidad dual:} & \lambda \geq 0, \\ (4) \text{ Holgura complementaria:} & \lambda(5 - 2x - y) = 0. \end{array} \right.$$

Ahora sí, analizamos casos con esta $\tilde{\mathcal{L}}$.

Caso A: $\lambda = 0$

Si $\lambda = 0$, de estacionariedad:

$$4(x - 1)^3 - 0 = 0 \implies x = 1.$$

Y

$$e^y - 0 = 0 \implies e^y = 0,$$

imposible. Por lo tanto, $\lambda = 0$ sigue sin ser factible.

Caso B: $\lambda > 0$

Si $\lambda > 0$, por holgura complementaria la restricción está activa:

$$5 - 2x - y = 0 \implies y = 5 - 2x.$$

De $\frac{\partial \tilde{\mathcal{L}}}{\partial y} = 0$:

$$e^y - \lambda = 0 \implies \lambda = e^y = e^{5-2x}.$$

De $\frac{\partial \tilde{\mathcal{L}}}{\partial x} = 0$:

$$4(x-1)^3 - 2\lambda = 0 \implies 2(x-1)^3 = \lambda.$$

Igualando las dos expresiones de λ :

$$2(x-1)^3 = e^{5-2x}.$$

Esa ecuación determina el x óptimo. Resolviéndola numéricamente:

$$x^* \approx 2.0625.$$

Luego

$$y^* = 5 - 2x^* \approx 5 - 2(2.0625) \approx 0.8750.$$

Y el multiplicador

$$\lambda^* = e^{y^*} \approx e^{0.8750} \approx 2.3989 > 0,$$

consistente con la hipótesis $\lambda > 0$.

Ahora verificamos la factibilidad *en la forma original de la restricción*:

$$-2x^* - y^* \approx -2(2.0625) - 0.8750 \approx -5.0000 \geq -5.$$

Se cumple exactamente como igualdad: estamos sobre la frontera $-2x - y = -5$, es decir, “mayor o igual a -5 ”.

El valor de la función objetivo en (x^*, y^*) es

$$f(x^*, y^*) = (x^* - 1)^4 + e^{y^*} \approx (2.0625 - 1)^4 + e^{0.8750} \approx 3.6733.$$

Condiciones suficientes para mínimo global La función objetivo

$$f(x, y) = (x - 1)^4 + e^y$$

es convexa: $(x - 1)^4$ es convexa en x , y e^y es convexa en y ; la suma de convexas es convexa.

El conjunto factible definido por

$$-2x - y \geq -5$$

es un semiespacio afín (una región descrita por una desigualdad lineal), por lo tanto es convexo.

En un problema de minimización convexa con restricciones convexas (aquí lineales), cualquier punto que satisface KKT es óptimo global.

Como encontramos $(x^*, y^*) \approx (2.0625, 0.8750)$ con $\lambda^* > 0$ que satisface:

$$-2x^* - y^* \geq -5, \quad \text{y todas las condiciones KKT,}$$

concluimos que

$$(x^*, y^*) \approx (2.0625, 0.8750)$$

es el minimizador global del problema original con la restricción escrita en la forma

$$-2x - y \geq -5.$$

Condiciones suficientes

Como en el caso de optimización con restricciones y optimización libre, las condiciones suficientes van a estar asociadas a la concavidad de las funciones analizadas. Vamos a ver dos tipos de condiciones, una sobre concavidad y convexidad y otra más débil sobre cuasiconcavidad y cuasiconvexidad.

Condiciones suficientes para máximo (y global)

Supongamos que el problema a resolver es:

$$\begin{array}{ll} \text{Maximizar} & f(x) \\ \text{sujeto a} & g^i(x) \leq r_i \quad (i = 1, 2, \dots, k), \\ & x \geq 0. \end{array}$$

Con $x = (x_1, x_2, \dots)$ Asumiendo que se satisfacen las condiciones de Kuhn-Tucker. Si se satisfacen las siguientes condiciones en un punto x^*

1. La función objetivo $f(x)$ es diferenciable y *cóncava* en el cuadrante n -dimensional no negativo.
2. Cada función de restricción $g^i(x)$ es diferenciable y *convexa* en el cuadrante n -dimensional no negativo.

Entonces x^* da un máximo global de $f(x)$.

Existe un teorema asociado a condiciones más débiles para poder determinar que estamos ante un máximo, estas están asociados a la cuasiconcavidad y cuasiconvexidad de las funciones:

Teorema de Arrow-Enthoven para máximo

Supongamos que el problema a resolver es:

$$\begin{array}{ll} \text{Maximizar} & f(x) \\ \text{sujeto a} & g^i(x) \leq r_i \quad (i = 1, 2, \dots, k), \\ & x \geq 0. \end{array}$$

Asumiendo que se satisfacen las condiciones de Kuhn-Tucker. Si se satisfacen las siguientes condiciones en un punto x^*

1. La función objetivo $f(x)$ es diferenciable y *cuasiconcava* en el cuadrante n -dimensional no negativo.
2. Cada función de restricción $g^i(x)$ es diferenciable y *cuasiconvexa* en el cuadrante n -dimensional no negativo.
3. Se satisface cualquiera de los siguientes:
 - (a) $f_j(x^*) < 0$ para al menos una variable x_j .
 - (b) $f_j(x^*) > 0$ para alguna variable x_j relevante, esto quiere decir una variable que en el conjunto factible (que cumpla con las restricciones), esa variable tome un valor positivo.
 - (c) Las n derivadas $f_j(x^*)$ no son todas cero, y la función $f(x)$ es dos veces diferenciable en la vecindad de x^* (es decir, todas las derivadas parciales de segundo orden de $f(x)$ existen para x^*).
 - (d) La función $f(x)$ es cóncava.

Entonces x^* da un máximo global de $f(x)$.

Condiciones suficientes para mínimo (y global)

Supongamos que el problema a resolver es:

$$\begin{array}{ll} \text{Minimizar} & f(x) \\ \text{sujeto a} & g^i(x) \geq r_i \quad (i = 1, 2, \dots, k), \\ & x \geq 0. \end{array}$$

Con $x = (x_1, x_2, \dots)$ Asumiendo que se satisfacen las condiciones de Kuhn-Tucker. Si se satisfacen las siguientes condiciones en un punto x^*

1. La función objetivo $f(x)$ es diferenciable y *convexa* en el cuadrante n -dimensional no negativo.
2. Cada función de restricción $g^i(x)$ es diferenciable y *cóncava* en el cuadrante n -dimensional no negativo.

Entonces x^* da un mínimo global de $f(x)$.

Teorema de Arrow-Enthoven para mínimo

Supongamos que el problema a resolver es:

$$\begin{array}{ll} \text{Minimizar} & f(x) \\ \text{sujeto a} & g^i(x) \geq r_i \quad (i = 1, 2, \dots, k), \\ & x \geq 0. \end{array}$$

Asumiendo que se satisfacen las condiciones de Kuhn-Tucker. Si se satisfacen las siguientes condiciones en un punto x^*

1. La función objetivo $f(x)$ es diferenciable y *cuasiconvexa* en el cuadrante n -dimensional no negativo.
2. Cada función de restricción $g^i(x)$ es diferenciable y *cuasicóncava* en el cuadrante n -dimensional no negativo.
3. Se satisface cualquiera de los siguientes:
 - (a) $f_j(x^*) > 0$ para al menos una variable x_j .
 - (b) $f_j(x^*) < 0$ para alguna variable x_j relevante, esto quiere decir una variable que en el conjunto factible (que cumpla con las restricciones), esa variable tome un valor positivo.
 - (c) Las n derivadas $f_j(x^*)$ no son todas cero, y la función $f(x)$ es dos veces diferenciable en la vecindad de x^* (es decir, todas las derivadas parciales de segundo orden de $f(x)$ existen para x^*).
 - (d) La función $f(x)$ es convexa.

Entonces x^* da un mínimo global de $f(x)$.

Ejemplo

Volvamos a este ejemplo

$$\begin{array}{ll} \min_{x_1, x_2} & C(x_1, x_2) = (x_1 - 4)^2 + (x_2 - 4)^2 \\ \text{sujeto a} & 2x_1 + 3x_2 \geq 6, \\ & -3x_1 - 2x_2 \geq -12, \\ & x_1 \geq 0, \quad x_2 \geq 0. \end{array}$$

El potencial óptimo es $x_1 = 28/13$, $x_2 = 36/13$. Vamos a chequear las condiciones de segundo orden con el teorema de Arrow-Enthoven. La función objetivo en este caso es convexa por lo tanto es cuasiconvexa:

$$H(x_1, x_2) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

$$\Delta_1 = 2 > 0, \quad \Delta_2 = \det \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = 4 > 0$$

Por otro lado, las funciones de las restricciones son lineales con lo cual son cóncavas y convexas y por lo tanto son cuasicóncavas y cuasiconvexas. Por último, evaluamos una de las 4 condiciones de como por ejemplo: $f_j(x^*) < 0$, para algún x_j que tome un valor positivo en el óptimo:

Chequeando:

$$C'_{x_1} = 2(x_1^* - 4) < 0$$

Esto implica que el óptimo es mínimo global.

24 Temas adicionales de optimización

Calificación de las restricciones

Anteriormente cuando calculamos las condiciones de primer orden para máximos y mínimos argumentamos que estas son necesarias para obtener un punto óptimo. Sin embargo, existen casos donde por la naturaleza de las restricciones, las condiciones de primer orden dejan de ser válidas tanto para optimización con restricciones de igualdad como optimización con restricciones de desigualdad. Véase el siguiente ejemplo:

Consideremos el problema de maximizar $f(x, y) = x$ sujeto a la restricción definida por

$$h(x, y) = x^3 + y^2 = 0.$$

Armamos el lagrangiano:

$$L(x, y, \lambda) = f(x, y) + \lambda [-h(x, y)] = x + \lambda(-x^3 - y^2).$$

El sistema de ecuaciones que debemos resolver es:

$$\begin{cases} \frac{\partial L}{\partial x} = 1 - 3\lambda x^2 = 0, \\ \frac{\partial L}{\partial y} = -2\lambda y = 0, \\ \frac{\partial L}{\partial \lambda} = -(x^3 + y^2) = 0. \end{cases}$$

De $\frac{\partial L}{\partial y} = 0$ se sigue que $\lambda = 0$ o $y = 0$.

Caso 1: $\lambda = 0$. Entonces la primera ecuación da $1 - 3 \cdot 0 \cdot x^2 = 1 = 0$, que es imposible. Por lo tanto, $\lambda \neq 0$.


Caso 2: Como $\lambda \neq 0$, debe ser $y = 0$. La tercera ecuación impone $x^3 + y^2 = 0 \Rightarrow x^3 = 0 \Rightarrow x = 0$. Sustituyendo $x = 0$ en la primera ecuación:

$$1 - 3\lambda x^2 = 1 - 3\lambda \cdot 0 = 1 = 0,$$

nueva contradicción.

En ambos casos se arriba a una contradicción; por ende, el sistema no tiene solución.

Sin embargo el problema sí cuenta con un óptimo que es $(0, 0)$. Esto puede verse gráficamente. Graficando la restricción:




Como estamos maximizando una función que es $f(x, y) = x$, el punto óptimo se encuentra lo más al este posible pero que cumpla al mismo tiempo con la restricción, ese punto es el $(0, 0)$.

Veamos otro ejemplo pero con restricciones de desigualdad:

$$\begin{aligned} \max_{x_1, x_2} \quad & f = x_1 \\ \text{s.a.} \quad & \begin{cases} x_2 - (1 - x_1)^3 \leq 0, \\ x_1 \geq 0, \\ x_2 \geq 0. \end{cases} \end{aligned}$$

$$\mathcal{L}(x_1, x_2, \lambda_1) = x_1 + \lambda[x_2 - (1 - x_1)^3]$$

Este problema como el anterior puede ser resuelto gráficamente graficando la restricción:



El resultado es que el punto óptimo resulta ser: $(1, 0)$. Sin embargo si chequeamos las condiciones de primer orden, en particular la primera:

$$\frac{\partial \mathcal{L}}{\partial x_1} = 1 + 3\lambda(1 - x_1)^2 \leq 0$$

Si $x_1 = 1$ tenemos:

$$\frac{\partial \mathcal{L}}{\partial x_1} = 1 \leq 0$$

Lo cual es contradictorio, nuevamente lo que sucede es que las restricciones de este problema dejan sin efecto las condiciones necesarias. El problema que pueden generar estos casos "patológicos" es que a veces las restricciones no permiten la tangencia entre las curvas de nivel de la restricción y curvas de nivel de la función objetivo entre otras cosas. La forma de resolver este problema es requerir que el conjunto de restricciones cumpla con ciertas condiciones. Por ejemplo, si las restricciones fueran todas lineales, no habría problema, o si el problema fuera de maximización y las restricciones fueran todas convexas tampoco habría problema. Un resumen de las condiciones de calificación puede verse a continuación:

Teoremas de calificación de restricciones para máximos

Sea $f, g_1, \dots, g_k$ y supóngase que $x^* \in \mathbb{R}^n$ es un máximo local de f sobre el conjunto definido por las restricciones

$$g_1(x) \leq r_1, \dots, g_k(x) \leq r_k.$$

Para simplificar la notación, supóngase que $g_1, \dots, g_h$ son las restricciones *activas* en x^* , y que $g_{h+1}, \dots, g_k$ no lo son. Supóngase que las funciones de restricción activas satisfacen una de las siguientes propiedades:

- (a) La matriz jacobiana de las restricciones activas es

$$\left(\frac{\partial g_i}{\partial x_j}(x^*) \right), \quad i = 1, \dots, h, \quad j = 1, \dots, n.$$

Los gradientes de las restricciones activas son linealmente independientes en x^* , es decir, generan un subespacio de dimensión igual al número de restricciones activas.

- (b) $g_1, \dots, g_h$ son funciones convexas.
- (c) $g_1, \dots, g_h$ son funciones lineales.

Entonces, podemos aplicar las condiciones de primer orden sin problemas.

Teoremas de calificación de restricciones para mínimos

Sea $f, g_1, \dots, g_k$ y supóngase que $x^* \in \mathbb{R}^n$ es un mínimo local de f sobre el conjunto definido por las restricciones

$$g_1(x) \geq r_1, \dots, g_k(x) \geq r_k.$$

Para simplificar la notación, supóngase que $g_1, \dots, g_h$ son las restricciones *activas* en x^* , y que $g_{h+1}, \dots, g_k$ no lo son. Supóngase que las funciones de restricción activas satisfacen una de las siguientes propiedades:

- (a) La matriz jacobiana de las restricciones activas es

$$\left(\frac{\partial g_i}{\partial x_j}(x^*) \right), \quad i = 1, \dots, h, \quad j = 1, \dots, n.$$

Los gradientes de las restricciones activas son linealmente independientes en x^* , es decir, generan un subespacio de dimensión igual al número de restricciones activas.

- (b) $g_1, \dots, g_h$ son funciones cóncavas.
- (c) $g_1, \dots, g_h$ son funciones lineales.

Entonces, podemos aplicar las condiciones de primer orden sin problemas.

Volviendo con el ejemplo anterior, podemos ver que no hay independencia lineal en el gradiente de las restricciones ya que estos son:

Consideremos las restricciones en forma estándar $g_i(x_1, x_2) \leq 0$:

$$\begin{aligned} g_1(x_1, x_2) &= x_2 - (1 - x_1)^3, \\ g_2(x_1, x_2) &= -x_1, \\ g_3(x_1, x_2) &= -x_2. \end{aligned}$$

El punto candidato al óptimo es $x^* = (1, 0)$. Evaluamos cuáles restricciones son activas:

$$g_1(1, 0) = 0, \quad g_2(1, 0) = -1 < 0, \quad g_3(1, 0) = 0.$$

Por lo tanto, las restricciones activas son g_1 y g_3 .

Calculamos los gradientes:

$$\begin{aligned} \nabla g_1(x_1, x_2) &= \left(\frac{\partial g_1}{\partial x_1}, \frac{\partial g_1}{\partial x_2} \right) = (3(1 - x_1)^2, 1), \\ \nabla g_2(x_1, x_2) &= (-1, 0), \quad \nabla g_3(x_1, x_2) = (0, -1). \end{aligned}$$

Evaluando en $x^* = (1, 0)$:

$$\nabla g_1(1, 0) = (0, 1), \quad \nabla g_3(1, 0) = (0, -1).$$

Se observa que

$$\nabla g_3(1, 0) = -\nabla g_1(1, 0),$$

por lo que los gradientes de las restricciones activas **no son linealmente independientes en x^*** .

En consecuencia, la condición de independencia lineal de gradientes no se cumple en este punto. Tampoco se cumplen que las restricciones sean convexas ni lineales y por esa razón las condiciones de primer orden dejan de ser válidas.

25 Apéndice sobre Álgebra

Determinantes

Idea general

Para una matriz cuadrada $A \in \mathbb{R}^{n \times n}$, el determinante $\det(A)$ es un número que mide, entre otras cosas, el **factor de cambio de volumen** de la transformación lineal asociada, y nos permite saber si A es invertible

$$A \text{ es invertible} \iff \det(A) \neq 0$$

Para una intuición gráfica del determinante ver el video “El determinante” de [3Blue1Brown](#). Este apartado se reduce solamente al cálculo del mismo.

Fórmulas básicas

En el caso de una matriz 2×2 :

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix},$$

$$\det(A) = ad - bc$$

Para el caso más sencillo de una matriz 2×2 el determinante se calcula a través de multiplicar los elementos de una diagonal y restarlos por el producto de la otra.

Sea $A = \begin{pmatrix} 2 & 3 \\ 4 & 5 \end{pmatrix}$. Entonces

$$\det(A) = 2 \cdot 5 - 3 \cdot 4 = 10 - 12 = -2$$

Para el caso de una matriz 3×3
Podemos calcular a través de dos métodos diferentes:

Regla de Sarrus

Para $A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$, duplicamos las *dos primeras filas* debajo para formar la matriz *expandida*:

$$\begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \\ a & b & c \\ d & e & f \end{bmatrix}$$

Las tres diagonales *descendentes* ($\searrow$) se **suman** y las tres *ascendentes* ($\nearrow$) se **restan**. En notación de entradas a_{ij} y también con letras:

suman: aei , bfg , cdh

restan: ceg , afh , bdi

Por lo tanto

$$\det(A) = aei + bfg + cdh - ceg - afh - bdi$$

Ejemplo

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & -1 & 4 \\ 2 & 1 & 0 \end{pmatrix}$$

Duplicamos las dos primeras filas debajo para formar la matriz expandida

$$\begin{bmatrix} 1 & 2 & 3 \\ 0 & -1 & 4 \\ 2 & 1 & 0 \\ 1 & 2 & 3 \\ 0 & -1 & 4 \end{bmatrix}$$

Las diagonales descendentes $\searrow$ se **suman** y las ascendentes $\nearrow$ se **restan**

$$\text{suman: } 1 \cdot (-1) \cdot 0, 2 \cdot 4 \cdot 2, 3 \cdot 0 \cdot 1$$

$$\text{restan: } 3 \cdot (-1) \cdot 2, 1 \cdot 4 \cdot 1, 2 \cdot 0 \cdot 0$$

Por lo tanto

$$\det(A) = 1 \cdot (-1) \cdot 0 + 2 \cdot 4 \cdot 2 + 3 \cdot 0 \cdot 1 - 3 \cdot (-1) \cdot 2 - 1 \cdot 4 \cdot 1 - 2 \cdot 0 \cdot 0 = 18$$

A través de los cofactores (Laplace)

Sea $A = [a_{ij}]$. Para cada entrada a_{ij} , definimos su *menor* M_{ij} como el determinante de la submatriz que se obtiene al **borrar** la fila i y la columna j . El *cofactor* es

$$C_{ij} = (-1)^{i+j} M_{ij}$$

Con estos cofactores, podemos expandir por cualquier fila i o columna j

$$\det(A) = \sum_{j=1}^n a_{ij} C_{ij}$$

Veamos cómo hacerlo con una matriz 3×3 aunque este método sirve para matrices cuadradas de cualquier dimensión.

Tomemos

$$A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$$

Cofactor asociado al elemento $a = a_{11}$ Su menor se obtiene borrando la fila 1 y la columna 1, quedando la submatriz en **rojo**

$$A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$$

$$M_{11} = \det \begin{pmatrix} e & f \\ h & i \end{pmatrix} = ei - fh$$

Como $1 + 1$ es par, el cofactor es positivo

$$C_{11} = (-1)^{1+1} M_{11} = ei - fh$$

Cofactor asociado al elemento $b = a_{12}$ Ahora borramos la fila 1 y la columna 2, y el menor queda

$$A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$$

$$M_{12} = \det \begin{pmatrix} d & f \\ g & i \end{pmatrix} = di - fg$$

Como $1 + 2$ es impar, el cofactor cambia de signo

$$C_{12} = (-1)^{1+2} M_{12} = -(di - fg) = fg - di$$

Cofactor asociado al elemento $c = a_{13}$ Borrando la fila 1 y la columna 3

$$A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$$

$$M_{13} = \det \begin{pmatrix} d & e \\ g & h \end{pmatrix} = dh - eg$$

Y como $1 + 3$ es par

$$C_{13} = (-1)^{1+3} M_{13} = dh - eg$$

Expansión de Laplace por la primera fila La expansión $\det(A) = aC_{11} + bC_{12} + cC_{13}$ se ve, con nuestros colores, así

$$\det(A) = C_{11}a + C_{12}b + C_{13}c$$

es decir

$$\det(A) = a(ei - fh) + b(fg - di) + c(dh - eg)$$

De esta forma podemos calcular el determinante de una matriz tomando cualquier fila o columna de la misma y aplicando la expansión de Laplace. Una recomendación es siempre intentar elegir la fila o columna con mayor cantidad de ceros de tal forma de anular varios términos al escribir la expansión.

Ejemplo

Calculemos $\det(A)$ expandiendo por la **primera columna**

$$A = \begin{pmatrix} 2 & 0 & 3 \\ 1 & 4 & -1 \\ 0 & 2 & 5 \end{pmatrix}$$

Término con $a_{11} = 2$ Borramos fila 1 y columna 1. El *menor* es el determinante de la submatriz en rojo

$$A = \begin{pmatrix} 2 & 0 & 3 \\ 1 & 4 & -1 \\ 0 & 2 & 5 \end{pmatrix} \quad M_{11} = \det \begin{pmatrix} 4 & -1 \\ 2 & 5 \end{pmatrix} = 4 \cdot 5 - (-1) \cdot 2 = 22$$

$$C_{11} = (-1)^{1+1} M_{11} = 22 \quad \text{aporte} = a_{11} C_{11} = 2 \cdot 22 = 44$$

Término con $a_{21} = 1$ Borramos fila 2 y columna 1

$$A = \begin{pmatrix} 2 & 0 & 3 \\ 1 & 4 & -1 \\ 0 & 2 & 5 \end{pmatrix} \quad M_{21} = \det \begin{pmatrix} 0 & 3 \\ 2 & 5 \end{pmatrix} = 0 \cdot 5 - 3 \cdot 2 = -6$$

$$C_{21} = (-1)^{2+1} M_{21} = -(-6) = 6 \quad \text{aporte} = a_{21} C_{21} = 1 \cdot 6 = 6$$

Término con $a_{31} = 0$ Aporta 0, pero mostramos su menor para completar la idea

$$A = \begin{pmatrix} 2 & 0 & 3 \\ 1 & 4 & -1 \\ 0 & 2 & 5 \end{pmatrix} \quad M_{31} = \det \begin{pmatrix} 0 & 3 \\ 4 & -1 \end{pmatrix} = 0 \cdot (-1) - 3 \cdot 4 = -12$$

$$C_{31} = (-1)^{3+1} M_{31} = -12 \quad \text{aporte} = a_{31} C_{31} = 0 \cdot (-12) = 0$$

Suma de aportes

$$\det(A) = a_{11} C_{11} + a_{21} C_{21} + a_{31} C_{31} = 44 + 6 + 0 = 50$$

Multiplicación de matrices

Dados $A \in \mathbb{R}^{m \times n}$ y $B \in \mathbb{R}^{n \times p}$, definimos el producto $C = AB \in \mathbb{R}^{m \times p}$ por

$$c_{ij} = \sum_{k=1}^n a_{ik} b_{kj}$$

Solo podemos multiplicar matrices cuando el número de columnas de A coincide con el número de filas de B . En caso contrario, el producto no está definido. El resultado final es una matriz con la cantidad de filas de A y la cantidad de columnas de B .

Intuición

- **Fila por columna:** c_{ij} es el *producto punto* de la fila i de A con la columna j de B .¹⁵

Una forma de entender el procedimiento es que para cada elemento de fila i y columna j de la matriz final va a estar implicada la fila i de la primera matriz y la columna j de la segunda matriz.

Ejemplo

Sea

$$A = \begin{pmatrix} 2 & -1 & 0 \\ 1 & 3 & 2 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 4 \\ 0 & -1 \\ 2 & 5 \end{pmatrix}$$

Calculamos $C = AB \in \mathbb{R}^{2 \times 2}$ por *fila por columna*

$$c_{11} = (2)(1) + (-1)(0) + (0)(2) = 2$$

$$c_{12} = (2)(4) + (-1)(-1) + (0)(5) = 9$$

¹⁵ *Producto punto* entre dos vectores $\mathbf{u} = (u_1, \dots, u_n)$ y $\mathbf{v} = (v_1, \dots, v_n)$:

$$\mathbf{u} \cdot \mathbf{v} = \sum_{k=1}^n u_k v_k$$

$$c_{21} = (1)(1) + (3)(0) + (2)(2) = 5$$

$$c_{22} = (1)(4) + (3)(-1) + (2)(5) = 11$$

$$AB = \begin{pmatrix} 2 & 9 \\ 5 & 11 \end{pmatrix}$$

Ejemplo 2×2

Sea

$$A = \begin{pmatrix} 3 & -2 \\ 1 & 5 \end{pmatrix}, \quad B = \begin{pmatrix} 4 & 0 \\ -1 & 2 \end{pmatrix}$$

Calculamos $C = AB \in \mathbb{R}^{2 \times 2}$ por fila por columna

$$c_{11} = 3 \cdot 4 + (-2) \cdot (-1) = 12 + 2 = 14$$

$$c_{12} = 3 \cdot 0 + (-2) \cdot 2 = 0 - 4 = -4$$

$$c_{21} = 1 \cdot 4 + 5 \cdot (-1) = 4 - 5 = -1$$

$$c_{22} = 1 \cdot 0 + 5 \cdot 2 = 0 + 10 = 10$$

$$AB = \begin{pmatrix} 14 & -4 \\ -1 & 10 \end{pmatrix}$$

3×2 por 2×3

Sea

$$A = \begin{pmatrix} 1 & 2 \\ 0 & -1 \\ 3 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} 2 & 1 & 0 \\ -1 & 4 & 3 \end{pmatrix}$$

Calculamos $C = AB \in \mathbb{R}^{3 \times 3}$

$$c_{11} = 1 \cdot 2 + 2 \cdot (-1) = 2 - 2 = 0, \quad c_{12} = 1 \cdot 1 + 2 \cdot 4 = 1 + 8 = 9, \quad c_{13} = 1 \cdot 0 + 2 \cdot 3 = 0 + 6 = 6$$

$$c_{21} = 0 \cdot 2 + (-1) \cdot (-1) = 1, \quad c_{22} = 0 \cdot 1 + (-1) \cdot 4 = -4, \quad c_{23} = 0 \cdot 0 + (-1) \cdot 3 = -3$$

$$c_{31} = 3 \cdot 2 + 1 \cdot (-1) = 6 - 1 = 5, \quad c_{32} = 3 \cdot 1 + 1 \cdot 4 = 3 + 4 = 7, \quad c_{33} = 3 \cdot 0 + 1 \cdot 3 = 3$$

$$AB = \begin{pmatrix} 0 & 9 & 6 \\ 1 & -4 & -3 \\ 5 & 7 & 3 \end{pmatrix}$$