Matemática aplicada a Economía

Juan Andrés Cabral

Versión 2.2 — última versión del libro (click acá)

Sobre este libro

Este libro reúne notas y resoluciones de ejercicios de clase de Matemática Aplicada I (FCE–UBA). Su objetivo es acompañar la cursada: ordenar ideas, fijar métodos y ofrecer ejemplos resueltos. Puede contener errores u omisiones; toda corrección o sugerencia es bienvenida en jcabral@udesa.edu.ar.

Índice

1 Técnicas de estudio basadas en evidencia 3

2 Funciones de varias variables y curvas de nivel 7

3 Curvas de nivel en Economía 18

4 Optimización con curvas de nivel 26

5 Continuidad 35

6 Derivadas parciales 40

7 Diferencial 49

8 Aplicación económica de diferencial 54

9 Clasificación de bienes y elasticidad 57

10 Derivadas compuestas 62

11 Derivadas implícitas 67

12 Derivadas implícitas en sistemas de ecuaciones 72

13 IS-LM 80

14 Homogeneidad 83

15 Autovalores y autovectores 87

16 Formas cuadráticas 98

17 Menores 109

18 Concavidad y convexidad 115

19 Cuasiconcavidad y cuasiconvexidad 126

20 Optimización sin restricciones 135

21 Aplicaciones económicas de optimización libre 150

22 Optimización con restricciones de igualdad 157

23 Aplicaciones económicas con optimización con restricciones de igualdad 170

24 Optimización con restricciones de desigualdad 174

25 Temas adicionales de optimización 187

26 Apéndice sobre Álgebra 190

1 Técnicas de estudio basadas en evidencia

> "Somos malos jueces de cuándo estamos aprendiendo bien y cuándo no. Cuando el progreso es más difícil y más lento y no se siente productivo, tendemos a recurrir a estrategias que parecen más fructíferas, sin darnos cuenta de que las ganancias de esas estrategias suelen ser temporales." *Brown, Roediger y McDaniel, Make It Stick: The Science of Successful Learning. (traducción propia)*

La evidencia es clara: solemos juzgar mal nuestro propio aprendizaje y preferimos métodos que "se sienten" productivos pero no son eficientes (Brown, Roediger, y Mark A. McDaniel 2014). Por eso el primer capítulo del libro no es de cálculo ni de álgebra sino, una breve introducción a **técnicas de estudio con respaldo empírico.**

Por qué empezar por el *cómo* aprender

Estudiar matemática y aplicarla a algún campo concreto como Economía requiere conectar definiciones formales con intuiciones económicas, derivar condiciones de primer orden y, a la vez, interpretar esas condiciones con conceptos económicos. Ese "puente" exige memoria a largo plazo *y* flexibilidad conceptual. La literatura en psicología del aprendizaje muestra que dos prácticas destacan mucho por su utilidad: **recuperación activa** (practice testing) y **práctica espaciada** (distributed practice) (Dunlosky et al. 2013; Roediger III y Butler 2011; Cepeda, Pashler, et al. 2006; Cepeda, Vul, et al. 2008). Este capítulo propone incorporar estas y otras desde el primer día, con procedimientos concretos orientados a los temas que se tratan en los otros capítulos.

Qué evitar al momento del estudio

En general, cuando uno estudia hay ciertas conductas que se aplican por defecto sin cuestionamiento ni crítica. Estas técnicas pueden no ser las mejores ya que no son tan efectivas para mejorar la retención de lo aprendido o porque ocupan el tiempo limitado que puede ser utilizado para otras técnicas con mayor respaldo. Aquí, algunas técnicas que **no** son recomendables debido a la falta de eficacia probada:

Releer sin más. Releer crea una *sensación* de familiaridad que no garantiza retención ni transferencia. Varios estudios no encuentran ventajas de la relectura frente a métodos activos Callender y M. A. McDaniel 2009; Weinstein, McDermott, y Roediger III 2010; Agarwal et al. 2008. En este sentido, no es recomendable releer 10 veces un teorema para intentar acordarse del mismo.

Subrayar sin criterio. La evidencia es mixta: hay trabajos que no hallan beneficios o incluso efectos negativos si se subraya demasiado o mal Peterson 1991; Lorch y Klusewitz 1995; Winchell et al. 2018, y otros que muestran que *con instrucciones precisas* puede ayudar Yue et al. 2015; Miyatsu, Nguyen, y M. A. McDaniel 2018. Si uno decide usar esta técnica, la recomendación es que sea mínima y con reglas (p. ej., una idea clave por párrafo).

Resumir. Resumir puede ayudar si uno sabe qué y cómo destilar Bretzing y Kulhavy 1979; Rinehart, Stahl, y Erickson 1986, pero su efectividad es muy variable y suele perder frente a estrategias más activas como la autoexplicación o el auto-cuestionamiento Bednall y Kehoe 2011; King 1992; Dunlosky et al. 2013.

Lo que sí funciona y cómo aplicarlo

1) Recuperación activa (Active Recall). Consiste en *intentar recordar y reconstruir* sin mirar el material. Funciona en laboratorio y en aula, a corto y largo plazo M. A. McDaniel et al. 2007; Roediger III y Butler 2011; Larsen, Butler, y Roediger III 2009; Schmidmaier et al. 2011; Agarwal et al. 2008. Esta idea se basa en intentar simular situaciones de exámenes constantemente, haciéndose preguntas como ¿Cómo era

esta fórmula? ¿Cuál es la intuición detrás de esta ecuación? ¿Qué regla se utiliza acá? Este autotesteo requiere esfuerzo mental, el cual facilita la retención de los contenidos. Existe una relación entre el esfuerzo mental invertido en responder una pregunta y la cantidad de tiempo que va a transcurrir hasta que uno se olvide de cómo responderla. A mayor esfuerzo, recordamos más.

Cómo implementarlo: Al momento de leer un libro en vez de simplemente ir pasando página por página, detenerse cada cierto tiempo y preguntarse el porqué de los pasos realizados o intentar averiguar cuál es el procedimiento posterior para resolver un problema. Obviamente estos testeos no pueden durar demasiado ya que consumirían mucho tiempo, pero tomarse unos minutos para plantearse si uno está entendiendo lo explicado siempre es buena idea. Una vez finalizada la lectura sobre un tema, una buena práctica que cuenta con mucha evidencia a favor es realizar "flashcards". Las flashcards son tarjetas que de un lado contienen una pregunta y del otro lado una respuesta, son cortas y la idea es no estar demasiado tiempo pensando. Por ejemplo, una flashcard puede ser ¿Cuál es la fórmula para la elasticidad precio de la demanda? y del otro lado puede estar la fórmula. Estas flashcards pueden hacerse con lápiz y papel, pero también existen aplicaciones que permiten crearlas digitalmente como Anki.

2) Práctica espaciada. Repartir las sesiones en el tiempo aumenta la retención Bahrick 1979; Cepeda, Pashler, et al. 2006. El espaciado óptimo suele estar entre el 5–30% del intervalo hasta la evaluación Rohrer y Pashler 2007; Cepeda, Vul, et al. 2008.

Cómo implementarlo: Si el examen es en 30 días y se toma 10% como guía, conviene programar repasos cada 3 días ($30 \cdot 0.1 = 3$). Lo ideal es espaciar las sesiones de estudio y al momento de tenerlas, aplicar recuperación activa.

3) Autoexplicación y generación. Explicar con tus palabras por qué un paso es válido, o *generar* preguntas/respuestas propias, potencia el aprendizaje y supera en general al resumen pasivo King 1992; Weinstein, McDermott, y Roediger III 2010.

Cómo implementarlo: Después de una clase, tomar el cuaderno y ver si se entienden los pasos algebraicos o generar una explicación propia de la interpretación de las ecuaciones, etc.

4) Intercalado (*interleaving*) y variación. Alternar tipos de problemas, es decir, ir cambiando de tema constantemente. Esto dificulta un poco el estudio pero mejora la discriminación de métodos.

Cómo implementarlo: Por ejemplo, tomar ejercicios de las guías de forma aleatoria e intentar resolverlos uno después de otro, en vez de ir por los primeros 1, 2, 3 y así sucesivamente, saltearse ejercicios y resolver: 2, 6, 10, 3, 8,... y así.

Ejemplo

Supongamos que queremos estudiar dos temas diferentes: elasticidad de demanda y derivadas compuestas. La idea sería primero tener en cuenta que si el examen es dentro de un mes, planear estudiar cada cierta cantidad de días en vez de realizar pocas sesiones largas. Por otro lado, al momento de leer el material de estudio, ir preguntándose si uno entiende lo que está leyendo y generar flashcards con preguntas clave: ¿Cómo es la fórmula? ¿Para qué sirve? ¿Cómo interpreto este resultado? ¿Cuáles son los pasos a seguir? entre otras. Una vez hecho esto, practicar ejercicios combinando los dos temas en la misma sesión y no dejando un tema para una sesión de estudio y otro tema para otra sesión. Por último, al momento de realizar las últimas sesiones, intentar asemejar el contexto de estudio lo máximo posible al contexto de evaluación. Utilizar temporizadores, no tener a mano el libro para revisar las respuestas, solamente contar con las herramientas disponibles que van a estar en el examen, etc.

El rol de las inteligencias artificiales generativas

Es imposible ignorar que los chatbots generativos hoy en día cada vez son más populares. Más que un obstáculo, el uso de los mismos puede generar oportunidades. Algunas recomendaciones para utilizarlos

serían las siguientes:

1. Utilizarlos para generar problemas nuevos o que combinen ejercicios.
2. Solicitar intuiciones diferentes o puntos de vista distintos a los que uno tiene.
3. Usarlos para criticar nuestros razonamientos o intuiciones. Si creemos que tal vez nos equivocamos, una buena forma es darle a la IA nuestro razonamiento y pedirle que lo analice rigurosamente.
4. Generar ideas para flashcards.
5. Generar un plan de estudio separado por días y que tenga en cuenta las técnicas propuestas anteriormente.

Por último, es importante recordar que cualquier inteligencia artificial generativa al día de hoy comete errores, muchas veces sutiles y otras veces groseros. Esto último debe servir de advertencia no para restringir su uso sino, para ser críticos al momento de tomar en cuenta lo generado.

Referencias

Agarwal, P. K. et al. (2008). "Examining the testing effect with open- and closed-book tests". In: *Applied Cognitive Psychology* 22.7, pp. 861–876.

Bahrick, H. P. (1979). "Maintenance of knowledge: Questions about memory we forgot to ask". In: *Journal of Experimental Psychology: General* 108.3, p. 296.

Bednall, T. C. y E. J. Kehoe (2011). "Effects of self-regulatory instructional aids on self-directed study". In: *Instructional Science* 39.2, pp. 205–226.

Bretzing, B. H. y R. W. Kulhavy (1979). "Notetaking and depth of processing". In: *Contemporary Educational Psychology* 4.2, pp. 145–153.

Brown, Peter C., III Roediger Henry L., y Mark A. McDaniel (2014). *Make It Stick*. Harvard University Press.

Callender, A. A. y M. A. McDaniel (2009). "The limited benefits of rereading educational texts". In: *Contemporary Educational Psychology* 34.1, pp. 30–41.

Cepeda, N. J., H. Pashler, et al. (2006). "Distributed practice in verbal recall tasks: A review and quantitative synthesis". In: *Psychological Bulletin* 132.3, p. 354.

Cepeda, N. J., E. Vul, et al. (2008). "Spacing effects in learning: A temporal ridgeline of optimal retention". In: *Psychological Science* 19.11, pp. 1095–1102.

Dunlosky, J. et al. (2013). "Improving students' learning with effective learning techniques: Promising directions from cognitive and educational psychology". In: *Psychological Science in the Public Interest* 14.1, pp. 4–58.

King, A. (1992). "Comparison of self-questioning, summarizing, and notetaking-review as strategies for learning from lectures". In: *American Educational Research Journal* 29.2, pp. 303–323.

Larsen, D. P., A. C. Butler, y H. L. Roediger III (2009). "Repeated testing improves long-term retention relative to repeated study: a randomised controlled trial". In: *Medical Education* 43.12, pp. 1174–1181.

Lorch, E. P. y M. A. Klusewitz (1995). "Effects of typographical cues on reading and recall of text". In: *Contemporary Educational Psychology* 20.1, pp. 51–64.

McDaniel, M. A. et al. (2007). "Testing the testing effect in the classroom". In: *European Journal of Cognitive Psychology* 19.4–5, pp. 494–513.

Miyatsu, T., K. Nguyen, y M. A. McDaniel (2018). "Five popular study strategies: Their pitfalls and optimal implementations". In: *Perspectives on Psychological Science* 13.3, pp. 390–407.

Peterson, S. E. (1991). "The cognitive functions of underlining as a study technique". In: *Literacy Research and Instruction* 31.2, pp. 49–56.

Rinehart, S. D., S. A. Stahl, y L. G. Erickson (1986). "Some effects of summarization training on reading and studying". In: *Reading Research Quarterly*, pp. 422–438.

Roediger III, H. L. y A. C. Butler (2011). "The critical role of retrieval practice in long-term retention". In: *Trends in Cognitive Sciences* 15.1, pp. 20–27.

Rohrer, D. y H. Pashler (2007). "Increasing retention without increasing study time". In: *Current Directions in Psychological Science* 16.4, pp. 183–186.

Schmidmaier, R. et al. (2011). "Using electronic flashcards to promote learning in medical students: retesting versus restudying". In: *Medical Education* 45.11, pp. 1101–1110.

Weinstein, Y., K. B. McDermott, y H. L. Roediger III (2010). "A comparison of study strategies for passages: Rereading, answering questions, and generating questions". In: *Journal of Experimental Psychology: Applied* 16.3, p. 308.

Winchell, A. et al. (2018). "Textbook annotations as an early predictor of student learning". In: *Proceedings of the International Conference on Educational Data Mining (EDM)*.

Yue, C. L. et al. (2015). "Highlighting and its relation to distributed study and students' metacognitive beliefs". In: *Educational Psychology Review* 27.1, pp. 69–78.

2 Funciones de varias variables y curvas de nivel

Funciones de dos variables

Una *función de dos variables* f asigna a cada par (x, y) de un conjunto $D \subseteq \mathbb{R}^2$ un único número real $f(x, y)$. Se escribe

$$f\colon D \subseteq \mathbb{R}^2 \to \mathbb{R}$$

El conjunto D es el *dominio* de f. Las variables x e y son las variables independientes, y al valor de la función se lo suele llamar z:

$$z = f(x, y)$$

Por ejemplo, $f(x, y) = x^2 + 3xy - y$ le asigna al par $(1, 2)$ el número $f(1, 2) = 1 + 6 - 2 = 5$.

Del mismo modo, una función de n variables asigna un único número real $f(x_1, \dots, x_n)$ a cada punto $(x_1, \dots, x_n)$ de un conjunto $D \subseteq \mathbb{R}^n$, y se escribe $f\colon D \subseteq \mathbb{R}^n \to \mathbb{R}$. Por ejemplo, $f(x_1, x_2, x_3) = x_1x_2 + x_3^2$ es una función de tres variables.

Dominio

Cuando una función se da solo con su fórmula, su dominio es el conjunto de todos los puntos en los que la fórmula se puede calcular. Si la fórmula tiene solo sumas, restas, productos y potencias naturales, como $x^2 + 3xy - y$, el dominio es todo $\mathbb{R}^2$. Las restricciones aparecen con tres operaciones:

- **Raíces de índice par.** Lo que está adentro de la raíz tiene que ser mayor o igual que cero: en $\sqrt{g(x, y)}$, la condición es $g(x, y) \geq 0$.
- **Logaritmos.** El argumento tiene que ser positivo: en $\ln g(x, y)$, la condición es $g(x, y) > 0$.
- **Cocientes.** El denominador no puede ser cero: en $\dfrac{g(x, y)}{h(x, y)}$, la condición es $h(x, y) \neq 0$.

Si en la fórmula aparecen varias de estas operaciones, el dominio está formado por los puntos que cumplen todas las condiciones a la vez. Las mismas reglas valen con más variables: por ejemplo, el dominio de $\ln(x_1 + x_2 + x_3)$ es el conjunto de puntos de $\mathbb{R}^3$ en los que $x_1 + x_2 + x_3 > 0$.

Método 2.1 | Hallar y graficar el dominio

Cuándo usarlo. Cuando una función de dos variables está dada solo por su fórmula.

Pasos.

1. Buscar en la fórmula las raíces de índice par, los logaritmos y los cocientes. Si no hay ninguno, el dominio es todo $\mathbb{R}^2$.
2. Escribir una condición por cada uno: lo de adentro de la raíz, ≥ 0; el argumento del logaritmo, > 0; el denominador, $\neq 0$.
3. Para cada condición, dibujar la curva en la que vale la igualdad. Si la condición es $\geq$ o $>$, elegir de qué lado de la curva se cumple, probando con un punto que no esté sobre ella. Si es $\neq$, la condición deja afuera solo esa curva.
4. El dominio está formado por los puntos que cumplen todas las condiciones a la vez.

Chequeo. Tomar un punto de adentro del dominio y otro de afuera, y verificar que la fórmula se puede calcular en el primero y no en el segundo.

Cuidado. Con las raíces, el borde es parte del dominio ($\geq$); con los logaritmos y los cocientes, no ($>$ y $\neq$). Si una raíz está en el denominador, como en $1/\sqrt{g(x, y)}$, la condición es $g(x, y) > 0$. Las raíces de índice impar, como $\sqrt[3]{x + y}$, no restringen el dominio.

En los gráficos de los ejemplos, la región sombreada es el dominio; el borde que pertenece al dominio va con línea llena, y el que no, con línea discontinua.

Ejemplo 1

Sea $f(x,y) = \sqrt{4 - x^2 - y^2}$. Lo de adentro de la raíz tiene que ser mayor o igual que cero:

$$4 - x^2 - y^2 \geq 0 \iff x^2 + y^2 \leq 4$$

La igualdad $x^2 + y^2 = 4$ es la circunferencia de centro $(0,0)$ y radio 2. El origen cumple la desigualdad, porque $0 \leq 4$, así que la región es la de adentro.
Conclusión. El dominio es el círculo de centro $(0,0)$ y radio 2, con su circunferencia:

$$D = \{\, (x,y) \in \mathbb{R}^2 : x^2 + y^2 \leq 4 \,\}$$

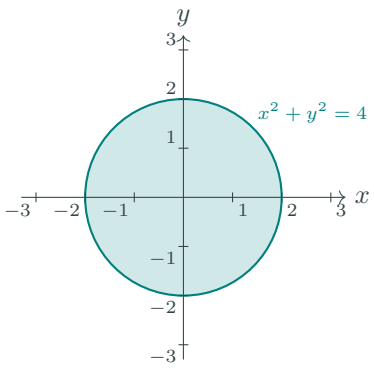


Figura 1: Dominio de $f(x,y) = \sqrt{4 - x^2 - y^2}$: el círculo de radio 2, con su circunferencia.

Ejemplo 2

Sea $f(x,y) = \ln(y - x^2)$. El argumento del logaritmo tiene que ser positivo:

$$y - x^2 > 0 \iff y > x^2$$

La igualdad $y = x^2$ es una parábola con vértice en el origen. El punto $(1,3)$ cumple la desigualdad, porque $3 > 1$, así que la región es la de arriba de la parábola.
Conclusión. El dominio es la región que está por encima de la parábola $y = x^2$, sin la parábola:

$$D = \{\, (x,y) \in \mathbb{R}^2 : y > x^2 \,\}$$

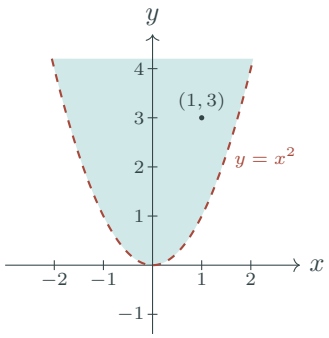


Figura 2: Dominio de $f(x,y) = \ln(y - x^2)$: la región por encima de la parábola $y = x^2$, sin la parábola.

Ejemplo 3

Sea $f(x,y) = \dfrac{\sqrt{x-y}}{x+y}$. Hay dos condiciones, una por la raíz y otra por el cociente:

$$x - y \geq 0 \iff y \leq x \qquad\qquad x + y \neq 0 \iff y \neq -x$$

La igualdad $y = x$ es una recta. El punto $(2,-1)$ cumple $-1 \leq 2$, así que la primera condición da el semiplano que está por debajo de la recta $y = x$, con la recta. La segunda condición saca de ese semiplano los puntos de la recta $y = -x$, que ahí forman la semirrecta con $x \geq 0$. El origen está sobre la recta $y = x$, que es parte del dominio, pero también sobre $y = -x$. Por lo tanto, no pertenece al dominio: en $(0,0)$ el denominador vale cero.

Conclusión. El dominio es el semiplano que está por debajo de la recta $y = x$, con la recta, salvo los puntos de la semirrecta $y = -x$ con $x \geq 0$:

$$D = \{\, (x,y) \in \mathbb{R}^2 : y \leq x,\ y \neq -x \,\}$$

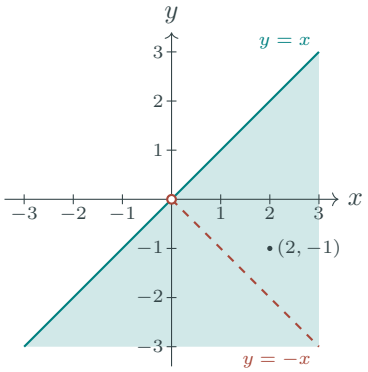


Figura 3: Dominio de $f(x,y) = \frac{\sqrt{x-y}}{x+y}$: el semiplano por debajo de $y = x$, con la recta, salvo la semirrecta de $y = -x$ con $x \geq 0$, que incluye el origen.

Gráfico

El *gráfico* de una función de dos variables es el conjunto de puntos de $\mathbb{R}^3$

$$\{\, (x,y,z) \in \mathbb{R}^3 : (x,y) \in D,\ z = f(x,y) \,\}$$

Para cada punto (x, y) del dominio, que está en el plano horizontal xy, el gráfico tiene un único punto, a altura $f(x, y)$: arriba del plano si $f(x, y) > 0$ y abajo si $f(x, y) < 0$. Por eso el gráfico de una función de dos variables es una superficie en el espacio.

Por ejemplo, el gráfico de $f(x, y) = \sqrt{4 - x^2 - y^2}$ es la mitad de arriba de la esfera de radio 2 con centro en el origen: si $z = \sqrt{4 - x^2 - y^2}$, entonces $z \geq 0$ y, elevando al cuadrado, $x^2 + y^2 + z^2 = 4$. La superficie está justo encima del dominio, el círculo de radio 2.

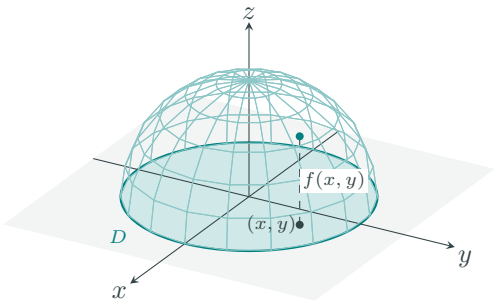


Figura 4: Gráfico de $f(x, y) = \sqrt{4 - x^2 - y^2}$, la mitad de arriba de la esfera de radio 2. Encima de cada punto (x, y) del dominio D, el gráfico está a altura $f(x, y)$.

Dibujar una superficie a mano es difícil, y con tres o más variables el gráfico está en $\mathbb{R}^4$ o más y ya no se puede dibujar. Por eso, para estudiar una función de dos variables se usan sus curvas de nivel, que se dibujan en el plano.

Curvas de nivel

Las curvas de nivel (o líneas de contorno) de una función de dos variables $z = f(x, y)$ se obtienen fijando un valor constante $z = c$ y resolviendo la ecuación

$$f(x, y) = c$$

Para cada valor de c, la curva de nivel es el conjunto de puntos del dominio en los que la función toma ese valor:

$$\{\, (x, y) \in D : f(x, y) = c \,\}$$

En general es una curva, pero puede reducirse a un punto, ser un par de rectas o no tener ningún punto, como se ve en los ejemplos.

Geométricamente, la curva de nivel c se obtiene cortando el gráfico de f con el plano horizontal $z = c$ y proyectando ese corte sobre el plano xy. Es la misma idea que las curvas de un mapa topográfico, que unen los puntos que están a la misma altura.

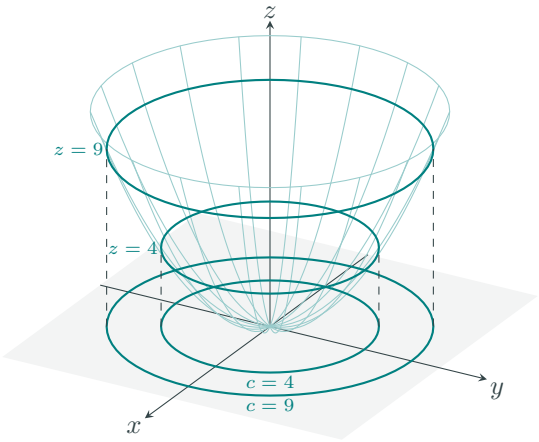


Figura 5: Gráfico de $f(x, y) = x^2 + y^2$ cortado por los planos $z = 4$ y $z = 9$. Al proyectar cada corte sobre el plano xy se obtienen las curvas de nivel $c = 4$ y $c = 9$, las circunferencias de radio 2 y 3.

Método 2.2 | Graficar curvas de nivel

Cuándo usarlo. Para dibujar las curvas de nivel de una función de dos variables dada por una fórmula.

Pasos.

1. Fijar un valor c para z (por ejemplo, $c = 0$, 1 o -1) y escribir la ecuación $f(x, y) = c$.
2. Identificar la curva: una circunferencia, una elipse, una hipérbola, una parábola, una recta u otra. Si además de los cuadrados aparecen términos lineales, como $-4x$, puede hacer falta completar cuadrados (ejemplo 4). Si no se reconoce ninguna, despejar y en función de x, cuando se pueda, y graficar esa función.
3. Encontrar las intersecciones con los ejes, los vértices y otros puntos notables, y las asíntotas si las hay.
4. Trazar la curva en el plano xy.
5. Repetir con otros valores de c en el mismo gráfico, y anotar sobre cada curva su valor de c. Así se ve hacia dónde crece la función.

Chequeo. Tomar un punto de cada curva, por ejemplo un vértice o un corte con los ejes, y verificar que f vale ahí el c anotado.

Cuidado. Según el valor de c, la curva de nivel puede ser un punto, un par de rectas o no tener ningún punto, así que hay que revisar por separado los casos $c > 0$, $c = 0$ y $c < 0$. Si el dominio de f no es todo el plano, la curva de nivel es solo la parte que está dentro del dominio.

Ejemplos de curvas de nivel

En los gráficos, cada curva está rotulada con su nivel, y las punteadas corresponden a niveles negativos. A la derecha de las curvas de nivel de cada ejemplo está el gráfico de la función, cortado por los planos $z = c$ de esos mismos niveles: cada curva de nivel es uno de esos cortes, visto desde arriba. La superficie tapa una parte de algunos cortes.

Ejemplo 1

Sea $f(x, y) = ax + by$, con a y b no ambos nulos. La curva de nivel c es

$$ax + by = c$$

Si $b \neq 0$, despejando y,

$$y = \frac{c}{b} - \frac{a}{b}\,x$$

Al cambiar c, cambia solo la ordenada al origen, c/b: la pendiente es siempre $-a/b$.
Conclusión. Las curvas de nivel de f son rectas paralelas: si $b \neq 0$, las rectas $y = \frac{c}{b} - \frac{a}{b}\,x$, de pendiente $-a/b$; si $b = 0$, las rectas verticales $x = c/a$.

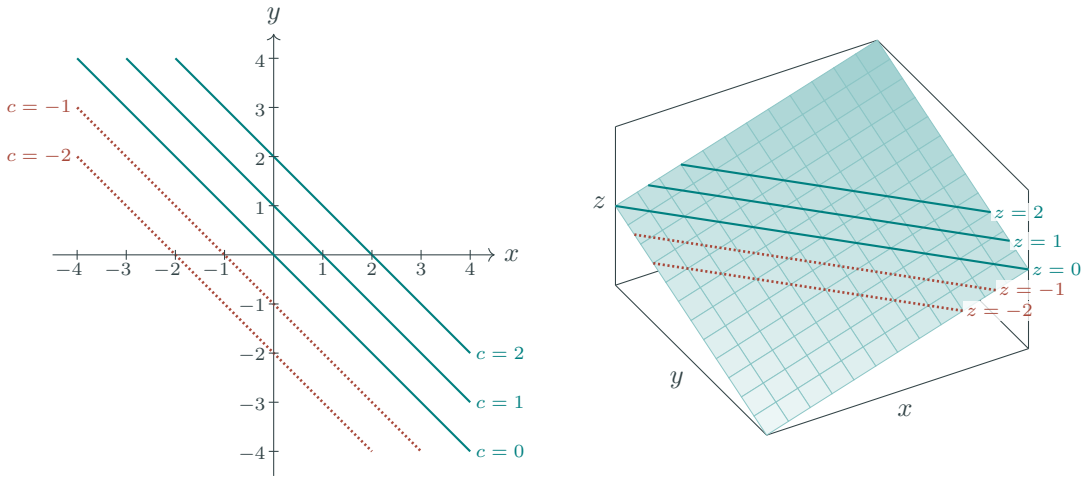


Figura 6: A la izquierda, las curvas de nivel de $f(x, y) = x + y$ ($a = b = 1$): rectas paralelas $x + y = c$. A la derecha, el gráfico de f, un plano, cortado a las mismas alturas.

Ejemplo 2

Sea $f(x, y) = y - x^2$. La curva de nivel c es

$$y - x^2 = c$$

y, despejando y,

$$y = x^2 + c$$

Como en el ejemplo anterior, hay una curva para cada valor de c, y todas tienen la misma forma.
Conclusión. La curva de nivel c es la parábola $y = x^2$ corrida c unidades hacia arriba ($|c|$ hacia abajo si $c < 0$), con vértice en $(0, c)$.

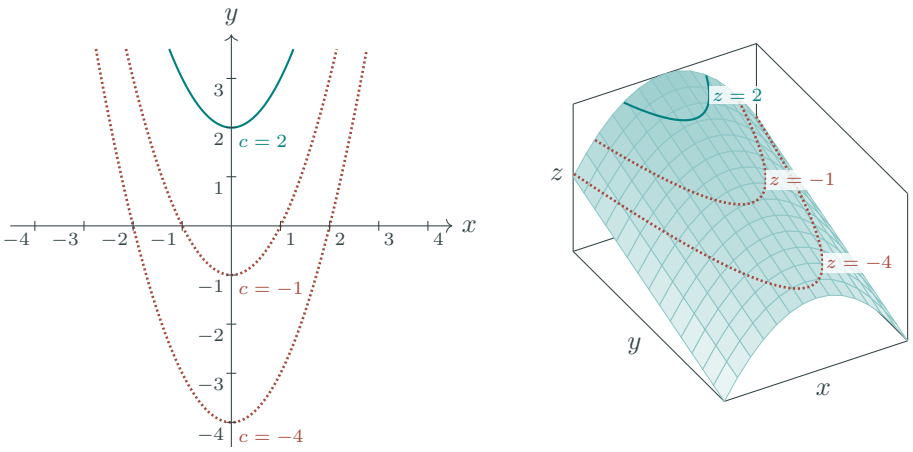


Figura 7: A la izquierda, las curvas de nivel de $f(x, y) = y - x^2$: parábolas $y = x^2 + c$, con vértice en $(0, c)$. A la derecha, el gráfico de f, cortado a las mismas alturas.

Ejemplo 3

Sea $f(x, y) = x^2 + y^2$. La curva de nivel c es

$$x^2 + y^2 = c$$

Como $x^2 + y^2$ nunca es negativo y solo vale cero en $(0, 0)$, si $c < 0$ la ecuación no tiene solución, y si $c = 0$ la única solución es el origen.

Conclusión. Si $c > 0$, la curva de nivel c es la circunferencia de centro $(0, 0)$ y radio $\sqrt{c}$. Si $c = 0$, es el punto $(0, 0)$. Si $c < 0$, no tiene ningún punto.

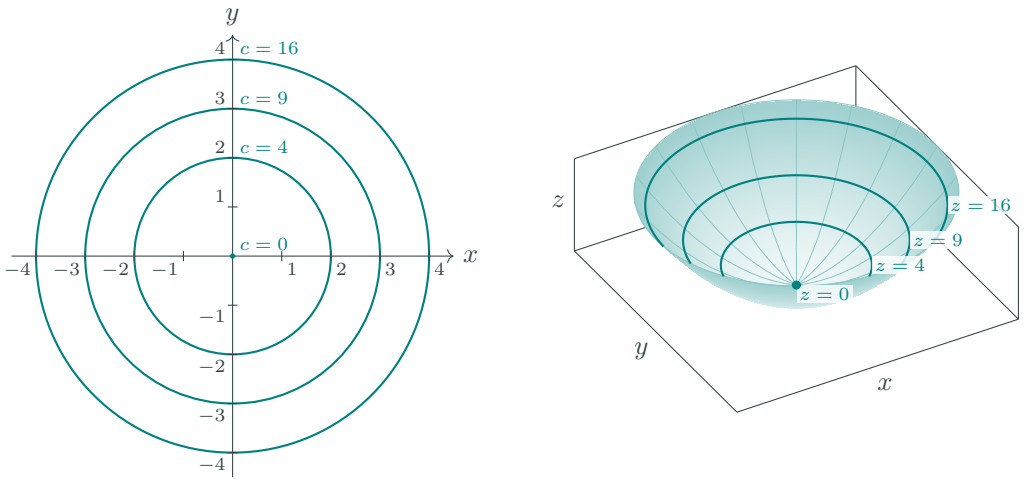


Figura 8: A la izquierda, las curvas de nivel de $f(x, y) = x^2 + y^2$: circunferencias de centro $(0, 0)$ y, para $c = 0$, el punto $(0, 0)$. A la derecha, el gráfico de f, un paraboloide, cortado a las mismas alturas.

Ejemplo 4

Sea $f(x, y) = x^2 + y^2 - 4x + 2y$. La curva de nivel c es

$$x^2 + y^2 - 4x + 2y = c$$

Completar cuadrados. En cada variable se usa $x^2 + kx = \left(x + \frac{k}{2}\right)^2 - \frac{k^2}{4}$. Acá,

$$x^2 - 4x = (x-2)^2 - 4 \qquad y^2 + 2y = (y+1)^2 - 1$$

así que la curva de nivel queda

$$(x-2)^2 + (y+1)^2 = c + 5$$

Conclusión. Si $c > -5$, la curva de nivel c es la circunferencia de centro $(2,-1)$ y radio $\sqrt{c+5}$. Si $c = -5$, es el punto $(2,-1)$. Si $c < -5$, no tiene ningún punto.

Completar cuadrados sirve igual para las elipses y para la hipérbola $x^2 - y^2$ cuando aparecen términos lineales: las curvas de nivel tienen la misma forma, pero con el centro corrido.

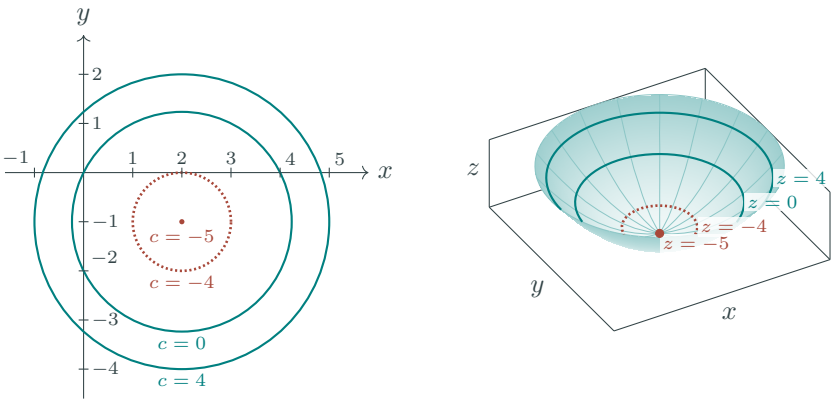


Figura 9: A la izquierda, las curvas de nivel de $f(x,y) = x^2 + y^2 - 4x + 2y$: circunferencias de centro $(2,-1)$ y radio $\sqrt{c+5}$. La de $c = 0$ pasa por el origen, porque ahí $f = 0$. A la derecha, el gráfico de f, un paraboloide con el vértice en $(2,-1,-5)$, cortado a las mismas alturas.

Ejemplo 5

Sea $f(x,y) = \dfrac{x^2}{a^2} + \dfrac{y^2}{b^2}$, con $a, b > 0$. La curva de nivel c es

$$\frac{x^2}{a^2} + \frac{y^2}{b^2} = c$$

Si $c > 0$, dividiendo por c,

$$\frac{x^2}{a^2 c} + \frac{y^2}{b^2 c} = 1$$

que es la ecuación de una elipse de centro $(0,0)$ con los denominadores $\left(a\sqrt{c}\right)^2$ y $\left(b\sqrt{c}\right)^2$. Como f nunca es negativa y solo vale cero en $(0,0)$, si $c = 0$ la única solución es el origen, y si $c < 0$ no hay ninguna.
Conclusión. Si $c > 0$, la curva de nivel c es la elipse de centro $(0,0)$ con semiejes $a\sqrt{c}$ en x y $b\sqrt{c}$ en y. Si $c = 0$, es el punto $(0,0)$. Si $c < 0$, no tiene ningún punto.

Otra forma de escribir la función. Si aparece como $f(x,y) = \dfrac{x^2}{a} + \dfrac{y^2}{b}$, con $a, b > 0$, es el mismo caso con $\sqrt{a}$ y $\sqrt{b}$ en lugar de a y b: los semiejes son $\sqrt{ac}$ en x y $\sqrt{bc}$ en y.

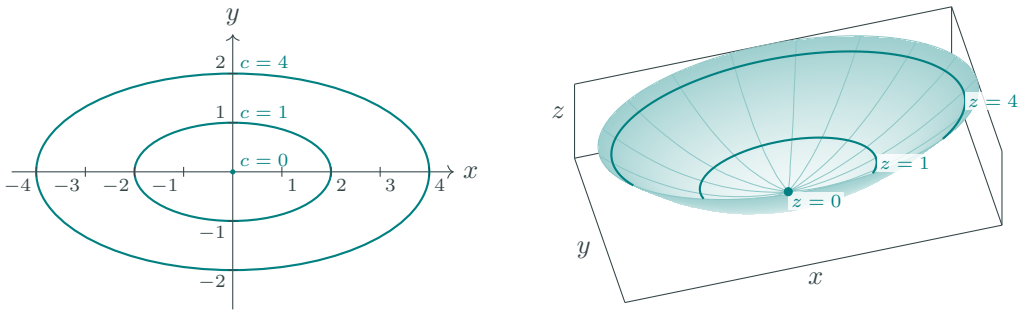


Figura 10: A la izquierda, las curvas de nivel de $f(x,y) = \frac{x^2}{4} + y^2$ ($a = 2$, $b = 1$): elipses de semiejes $2\sqrt{c}$ y $\sqrt{c}$. A la derecha, el gráfico de f, un paraboloide elíptico, cortado a las mismas alturas.

Ejemplo 6

Sea $f(x,y) = x^2 - y^2$. La curva de nivel c es

$$x^2 - y^2 = c$$

Si $c > 0$, dividiendo por c,

$$\frac{x^2}{c} - \frac{y^2}{c} = 1$$

que es una hipérbola con vértices en el eje x. Si $c < 0$, dividiendo por $-c = |c|$,

$$\frac{y^2}{|c|} - \frac{x^2}{|c|} = 1$$

que es una hipérbola con vértices en el eje y. Si $c = 0$, $x^2 - y^2 = (x-y)(x+y) = 0$, que se cumple cuando $y = x$ o $y = -x$.

Conclusión. Si $c > 0$, la curva de nivel c es la hipérbola con vértices $(\pm\sqrt{c}, 0)$. Si $c < 0$, es la hipérbola con vértices $(0, \pm\sqrt{|c|})$. Si $c = 0$, está formada por las rectas $y = x$ e $y = -x$, que son las asíntotas de todas las demás.

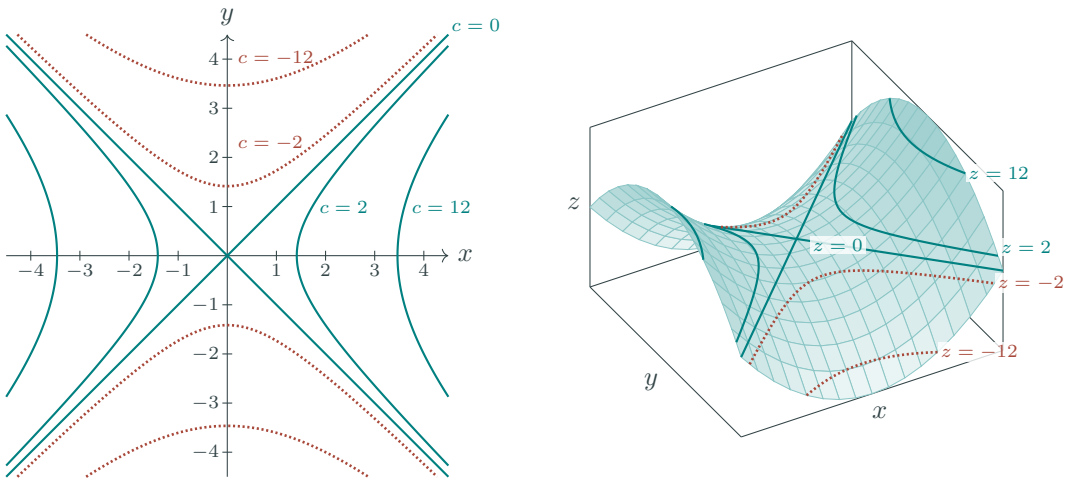


Figura 11: A la izquierda, las curvas de nivel de $f(x,y) = x^2 - y^2$: para $c > 0$, hipérbolas con vértices sobre el eje x; para $c < 0$, con vértices sobre el eje y; para $c = 0$, las rectas $y = \pm x$. A la derecha, el gráfico de f, una silla, cortado a las mismas alturas.

Ejemplo 7

Sea $f(x, y) = axy$, con $a \neq 0$. La curva de nivel c es

$$axy = c$$

Si $c \neq 0$, ni x ni y pueden valer cero y, despejando y,

$$y = \frac{c}{ax}$$

Si $c = 0$, la ecuación $axy = 0$ se cumple cuando $x = 0$ o $y = 0$.
Conclusión. Si $c \neq 0$, la curva de nivel c es la hipérbola $y = \frac{c}{ax}$, con asíntotas en los ejes y ramas en el primer y el tercer cuadrante si $c/a > 0$, y en el segundo y el cuarto si $c/a < 0$. Si $c = 0$, está formada por los ejes, $x = 0$ e $y = 0$.

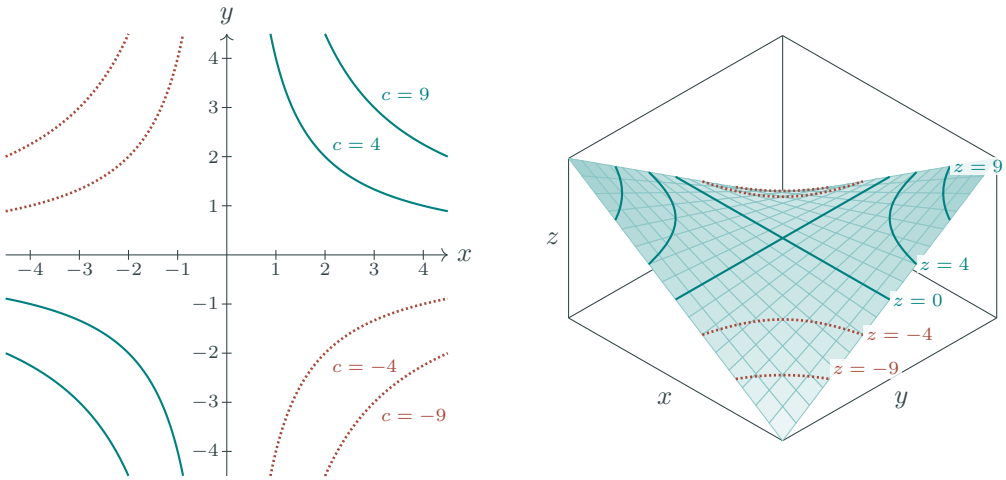
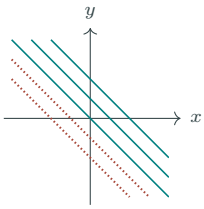
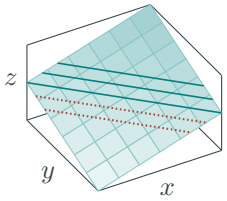
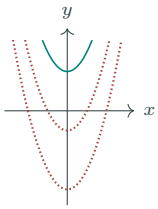
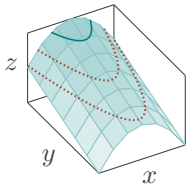
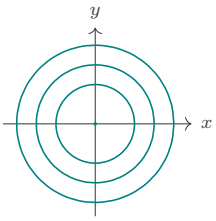
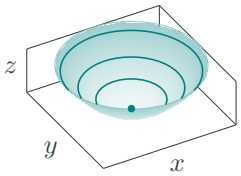
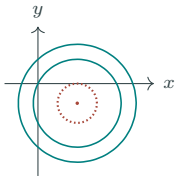
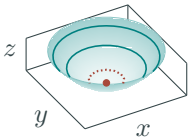
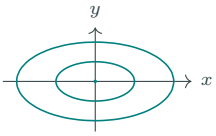
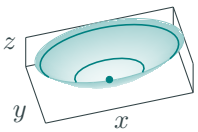
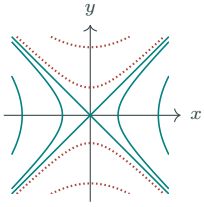
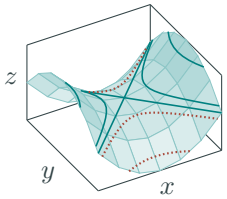
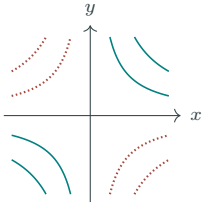
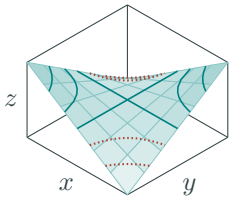


Figura 12: A la izquierda, las curvas de nivel de $f(x, y) = xy$ ($a = 1$): hipérbolas $y = c/x$; para $c = 0$, la curva de nivel está formada por los ejes. A la derecha, el gráfico de f, una silla, cortado a las mismas alturas.

Resumen gráfico

Las funciones de los ejemplos, cada una con sus curvas de nivel y su gráfico, con los mismos niveles que en los ejemplos. Las curvas punteadas corresponden a niveles negativos.

Función	**Curvas de nivel**	**Gráfico**
$f(x,y) = ax + by$ Plano. Curvas de nivel: rectas paralelas. En el dibujo, $a = b = 1$.		
$f(x,y) = y - x^2$ Curvas de nivel: parábolas iguales, corridas en vertical.		
$f(x,y) = x^2 + y^2$ Paraboloide. Curvas de nivel: circunferencias de centro $(0,0)$.		
$f(x,y) = x^2 + y^2 - 4x + 2y$ Paraboloide desplazado. Curvas de nivel: circunferencias de centro $(2,-1)$.		
$f(x,y) = \frac{x^2}{a^2} + \frac{y^2}{b^2}$ Paraboloide elíptico. Curvas de nivel: elipses de centro $(0,0)$. En el dibujo, $a = 2$ y $b = 1$.		
$f(x,y) = x^2 - y^2$ Silla. Curvas de nivel: hipérbolas y, para $c = 0$, las rectas $y = \pm x$.		
$f(x,y) = axy$ Silla. Curvas de nivel: hipérbolas con asíntotas en los ejes y, para $c = 0$, los ejes. En el dibujo, $a = 1$.		

3 Curvas de nivel en Economía

En este capítulo se analiza la importancia de las curvas de nivel en el contexto económico, enfocándonos en su uso para representar y analizar funciones de utilidad y de producción, y las rectas que aparecen en los problemas del consumidor y del productor.

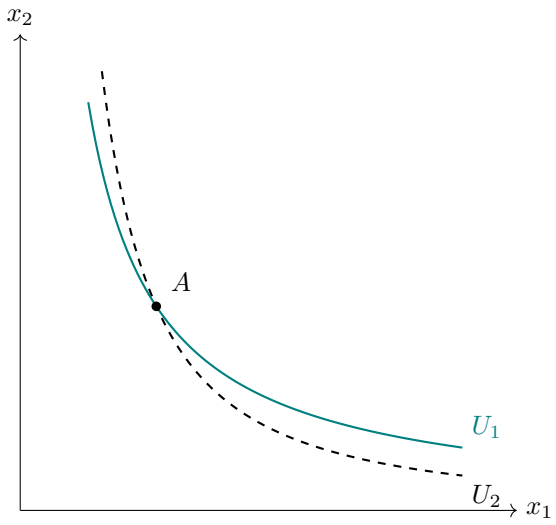
- Curvas de nivel: representan conjuntos de puntos en los cuales una función de dos variables mantiene un mismo valor. En economía, se utilizan para identificar combinaciones de bienes o de factores productivos que generan un mismo nivel de satisfacción o de producción
- Curvas de indiferencia: en el análisis de la utilidad, las curvas de nivel se conocen como curvas de indiferencia y representan combinaciones de bienes que proporcionan el mismo nivel de satisfacción al consumidor
- Isocuantas: en funciones de producción, las curvas de nivel se denominan isocuantas y muestran las combinaciones de factores productivos que producen una cantidad constante de producto
- Rectas presupuestaria, de isocosto y de isoingreso: son las curvas de nivel de funciones lineales (el gasto del consumidor, el costo de la empresa y su ingreso por ventas). Por eso son rectas, y las tres se grafican y se interpretan de la misma manera

Propiedades usuales de las curvas de indiferencia

Las curvas de nivel derivadas de funciones de utilidad suelen exhibir ciertas propiedades para reflejar comportamientos económicos razonables. A continuación, se describen las características y la intuición económica asociada a cada una. En cada caso, el gráfico muestra una curva que no cumple la propiedad, para ilustrar qué es lo que se está descartando.

1. No se cortan

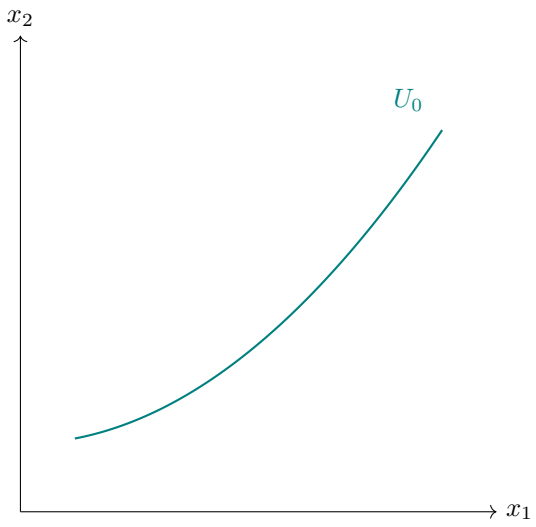
Cada curva de indiferencia representa un nivel único de utilidad. Si dos curvas correspondientes a niveles distintos se cruzaran, una misma combinación de bienes estaría asociada simultáneamente a dos niveles diferentes de utilidad, lo cual no es posible para una función de utilidad.



En el punto A, la misma canasta pertenece simultáneamente a las dos curvas dibujadas. Al cortarse, no pueden representar niveles distintos de una misma función de utilidad.

2. Pendiente negativa

Si ambos bienes son deseables, para mantener constante la utilidad un aumento en la cantidad de un bien debe ir acompañado de una disminución en la cantidad del otro.

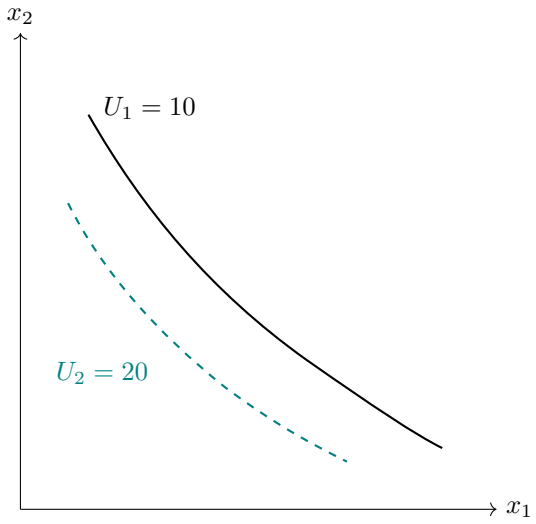


Este contraejemplo muestra una curva de indiferencia creciente. En ella, al aumentar x_1, también debe aumentar x_2 para permanecer sobre la misma curva. Esto solo es posible si uno de los dos bienes no es deseable (es un "mal"): el aumento de x_2 compensa la mayor utilidad que da el aumento de x_1. Esta propiedad es consecuencia de la monotonicidad estricta (propiedad 3).

3. Monotonicidad estricta

La monotonicidad estricta implica que, manteniendo constante la cantidad de un bien, un aumento en la cantidad del otro incrementa estrictamente la utilidad. Más generalmente, si una canasta contiene al menos tanta cantidad de ambos bienes como otra y una cantidad estrictamente mayor de al menos uno de ellos, el consumidor prefiere estrictamente la primera canasta.

Gráficamente, bajo monotonicidad estricta, las curvas de indiferencia asociadas a niveles de utilidad más elevados se encuentran hacia arriba y a la derecha.



Aquí la curva U_2, de utilidad 20, queda más cerca del origen que U_1, de utilidad 10. Hay canastas sobre U_1 que tienen más de ambos bienes que canastas sobre U_2 y, sin embargo, tienen menor utilidad, lo que contradice la monotonicidad estricta.

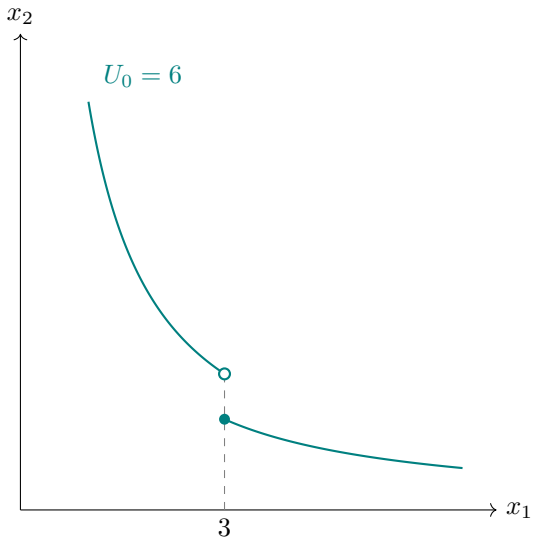
4. Continuidad

La continuidad asegura que pequeñas variaciones en las cantidades de bienes generan pequeños cambios en la utilidad. Esto permite representar las preferencias sin saltos abruptos en los niveles de satisfacción.

Como contraejemplo, consideremos la función

$$U(x_1, x_2) = \begin{cases} x_1 x_2 & \text{si } x_1 < 3 \\ x_1 x_2 + 2 & \text{si } x_1 \geq 3 \end{cases}$$

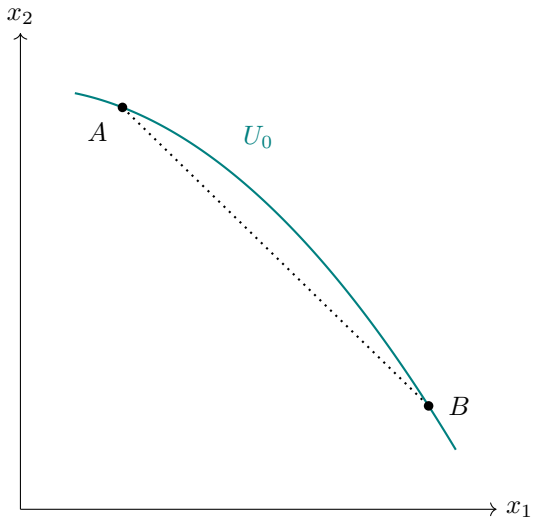
La función está definida para todas las canastas, pero tiene un salto en $x_1 = 3$. La curva de nivel $U_0 = 6$ está formada por $x_2 = 6/x_1$ para $x_1 < 3$ y por $x_2 = 4/x_1$ para $x_1 \geq 3$:



El círculo abierto es la canasta $(3, 2)$: las canastas de la curva se aproximan a ella, pero no pertenece a la curva, porque su utilidad es $3 \cdot 2 + 2 = 8$ y no 6. Por eso la curva se corta. Un cambio arbitrariamente pequeño en x_1 alrededor de 3 produce un cambio de utilidad de 2, y la función de utilidad no es continua en esos puntos.

5. Convexidad estricta al origen

La convexidad estricta refleja una preferencia por combinaciones relativamente balanceadas de bienes. Si dos canastas distintas proporcionan el mismo nivel de utilidad, cualquier combinación estrictamente intermedia de ambas proporciona un nivel de utilidad mayor.



La curva dibujada, en lugar de ser convexa al origen, es cóncava al origen. El segmento que une A y B queda por debajo de la curva. Si ambos bienes son deseables, los puntos interiores del segmento representan canastas estrictamente menos preferidas que los extremos.

Curvas de indiferencia Cobb-Douglas

Las curvas de indiferencia derivadas de una función de utilidad Cobb-Douglas representan combinaciones de bienes que otorgan un nivel constante de utilidad. Una forma general de esta función es

$$U(x_1, x_2) = x_1^{\alpha} x_2^{\beta}$$

donde $\alpha, \beta > 0$.

Graficando una curva de indiferencia

Para representar la curva de indiferencia correspondiente a un nivel de utilidad fijo $U_0 > 0$, partimos de

$$U_0 = x_1^{\alpha} x_2^{\beta}$$

y despejamos x_2:

$$x_2 = \left(\frac{U_0}{x_1^{\alpha}}\right)^{1/\beta}$$

o, equivalentemente,

$$x_2 = \frac{U_0^{1/\beta}}{x_1^{\alpha/\beta}}$$

Esto permite graficar la curva de indiferencia para un nivel dado de utilidad U_0, considerando distintos valores positivos de x_1.

- Las curvas son decrecientes, porque ambos bienes son deseables ($\alpha, \beta > 0$), y convexas al origen, de modo que cumplen las propiedades 2 y 5 vistas antes
- Para un nivel de utilidad $U_0 > 0$, las curvas no tocan los ejes, ya que si $x_1 = 0$ o $x_2 = 0$ la utilidad es igual a cero: los ejes son asíntotas y las curvas quedan dentro del primer cuadrante

Cada curva representa un nivel fijo de utilidad. Dado que $\alpha, \beta > 0$, mayores cantidades de los bienes generan mayores niveles de utilidad, por lo que las curvas correspondientes a niveles de utilidad más altos se encuentran hacia arriba y a la derecha.

Ejemplo

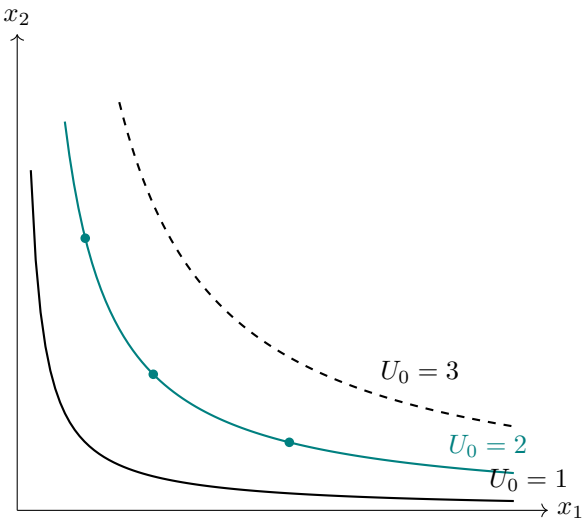
Sea $U(x_1, x_2) = x_1^{1/2} x_2^{1/2}$ y tomemos $U_0 = 2$. Con $\alpha = \beta = 1/2$, el despeje da

$$x_2 = \frac{2^2}{x_1^1} = \frac{4}{x_1}$$

Dando valores a x_1 obtenemos puntos de la curva:

x_1	0.5	1	2	4
x_2	8	4	2	1

Del mismo modo, $U_0 = 1$ da $x_2 = 1/x_1$ y $U_0 = 3$ da $x_2 = 9/x_1$. Las tres curvas se muestran en el gráfico, con los puntos $(1, 4)$, $(2, 2)$ y $(4, 1)$ marcados sobre la curva $U_0 = 2$.



Recta presupuestaria y cómo graficarla

Dados un ingreso (renta) R del consumidor y los precios p_1 y p_2, el conjunto presupuestario está formado por todas las combinaciones de bienes que el consumidor puede adquirir sin superar su ingreso:

$$p_1 x_1 + p_2 x_2 \leq R, \qquad x_1 \geq 0,\ x_2 \geq 0$$

La recta presupuestaria corresponde a las combinaciones en las que el consumidor gasta exactamente todo su ingreso:

$$p_1 x_1 + p_2 x_2 = R$$

Por lo tanto, los puntos ubicados por debajo de la recta representan canastas que el consumidor puede adquirir sin gastar todo su ingreso, mientras que los puntos ubicados por encima representan canastas que no puede adquirir con el ingreso disponible.

Método 1: despejar una variable en función de la otra

Despejando x_2 en función de x_1:

$$x_2 = \frac{R}{p_2} - \frac{p_1}{p_2}x_1$$

- Intuición: la ecuación muestra que, a medida que aumenta la cantidad de x_1, la cantidad de x_2 debe disminuir para mantener constante el gasto total R. La pendiente $-\frac{p_1}{p_2}$ refleja la tasa a la cual el mercado permite intercambiar un bien por el otro
- Aplicación: este método permite graficar la recta presupuestaria como una función lineal, facilitando el análisis algebraico de las posibilidades de consumo

Método 2: utilizar los interceptos

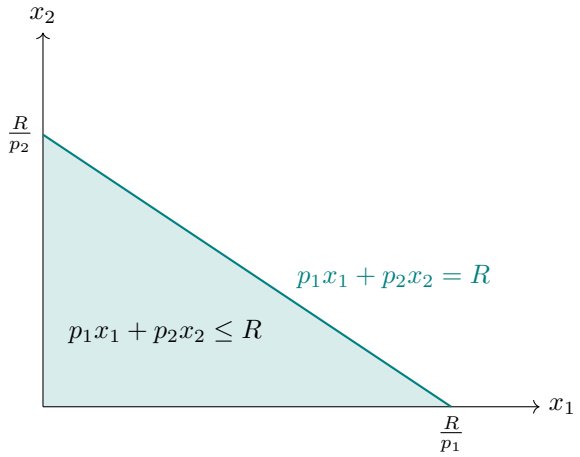
Si el consumidor dedica todo su ingreso al bien 1, entonces

$$x_1 = \frac{R}{p_1}$$

Si dedica todo su ingreso al bien 2, entonces

$$x_2 = \frac{R}{p_2}$$

- Intuición: estos interceptos representan las cantidades máximas que pueden adquirirse de cada bien si todo el ingreso se destina exclusivamente a ese bien
- Aplicación: conociendo ambos interceptos, puede trazarse la recta que los une. El área comprendida entre la recta y los ejes es el conjunto presupuestario definido arriba: las combinaciones de bienes que resultan accesibles para el consumidor



Cambios en el ingreso y en los precios

Para precios dados, un aumento del ingreso R desplaza la recta hacia afuera de forma paralela: los dos interceptos crecen, pero la pendiente $-\frac{p_1}{p_2}$ no cambia. Un aumento de p_1, con R y p_2 fijos, deja fijo el intercepto $\frac{R}{p_2}$ y acerca al origen el intercepto $\frac{R}{p_1}$: la recta rota alrededor de $\frac{R}{p_2}$ y se vuelve más empinada, ya que el bien 1 se encarece en relación al bien 2.

Isocuantas

Las isocuantas son las curvas de nivel asociadas a una función de producción. Representan todas las combinaciones de factores productivos que permiten obtener un mismo nivel de producción.

Si la función de producción es

$$q = F(x_1, x_2)$$

una isocuanta correspondiente al nivel de producción q_0 está determinada por

$$F(x_1, x_2) = q_0$$

Por ejemplo, si x_1 y x_2 representan dos factores productivos, distintos puntos pertenecientes a una misma isocuanta corresponden a distintas combinaciones de esos factores que permiten producir exactamente q_0 unidades.

- Las isocuantas asociadas a mayores niveles de producción se encuentran, en general, más alejadas del origen cuando una mayor utilización de los factores permite aumentar la producción
- Dos isocuantas correspondientes a niveles de producción diferentes no pueden cruzarse, ya que una misma combinación de factores no puede generar simultáneamente dos niveles distintos de producción bajo una misma función de producción
- Al igual que otras curvas de nivel, pueden graficarse fijando un nivel de producción y despejando uno de los factores en función del otro cuando esto sea posible

Las funciones de producción también suelen tener forma Cobb-Douglas,

$$q = x_1^{\alpha} x_2^{\beta}$$

con $\alpha, \beta > 0$. En ese caso, la isocuanta de nivel q_0 se obtiene con el mismo despeje que la curva de indiferencia Cobb-Douglas:

$$x_2 = \frac{q_0^{1/\beta}}{x_1^{\alpha/\beta}}$$

y tiene las mismas propiedades: es decreciente, convexa al origen y no toca los ejes.

Recta de isocosto

La recta de isocosto representa las combinaciones de factores productivos que generan un mismo costo total. Si w_1 y w_2 son los precios de los factores x_1 y x_2, respectivamente, la recta de isocosto correspondiente al costo total C está dada por

$$w_1 x_1 + w_2 x_2 = C$$

Despejando x_2 en función de x_1:

$$x_2 = \frac{C}{w_2} - \frac{w_1}{w_2} x_1$$

Por lo tanto, su pendiente es

$$-\frac{w_1}{w_2}$$

Los interceptos con los ejes son

$$x_1 = \frac{C}{w_1} \qquad x_2 = \frac{C}{w_2}$$

- Intuición: los interceptos representan las cantidades máximas de cada factor que pueden adquirirse si todo el costo se destina exclusivamente a uno de ellos
- La pendiente depende de los precios relativos de los factores y determina cómo debe modificarse la cantidad de un factor cuando cambia la del otro para mantener constante el costo total
- Para precios de los factores dados, un aumento del costo total C desplaza la recta de isocosto hacia afuera de forma paralela

Recta de isoingreso

Consideremos ahora una empresa que produce dos bienes en cantidades q_1 y q_2 y los vende a precios p_1 y p_2. La recta de isoingreso representa las combinaciones de productos que generan un ingreso total por ventas constante I:

$$p_1 q_1 + p_2 q_2 = I$$

Este ingreso es el de la empresa, por la venta de sus productos, y no debe confundirse con el ingreso R del consumidor de la recta presupuestaria.

Despejando q_2 en función de q_1:

$$q_2 = \frac{I}{p_2} - \frac{p_1}{p_2} q_1$$

Por lo tanto, su pendiente es $-\frac{p_1}{p_2}$ y los interceptos con los ejes son

$$q_1 = \frac{I}{p_1} \qquad q_2 = \frac{I}{p_2}$$

- Intuición: los interceptos representan la cantidad de cada producto que, vendida sola, genera exactamente el ingreso I
- La pendiente indica a cuántas unidades del producto 2 equivale, en términos de ingreso, una unidad del producto 1
- Para precios dados, un aumento del ingreso I desplaza la recta de isoingreso hacia afuera de forma paralela

4 Optimización con curvas de nivel

En este capítulo buscamos el máximo o el mínimo de una función objetivo $F(x, y)$ entre los puntos que cumplen una restricción $G(x, y) = b$. Por ejemplo, un consumidor elige, entre las canastas de su recta presupuestaria, la que le da más utilidad. Para resolverlo usamos las curvas de nivel $F(x, y) = K$ de los capítulos anteriores (en el ejemplo, las curvas de indiferencia).

Si buscamos un máximo, queremos la curva de nivel con el K más alto que todavía toca a la restricción. Cuando una curva de nivel corta a la restricción, como la de $K = 1000$ en la figura 13, al movernos sobre la restricción hacia un lado F aumenta y hacia el otro disminuye, así que en el punto de corte no hay ni máximo ni mínimo. La curva de nivel que pasa por el óptimo, en cambio, toca a la restricción sin cortarla (salvo en las soluciones de esquina, que vemos al final): es tangente a la restricción, y en ese punto las dos curvas tienen la misma pendiente. Los dos métodos de este capítulo se basan en esa condición. La tangencia no dice si el punto es un máximo o un mínimo; eso se verifica aparte.

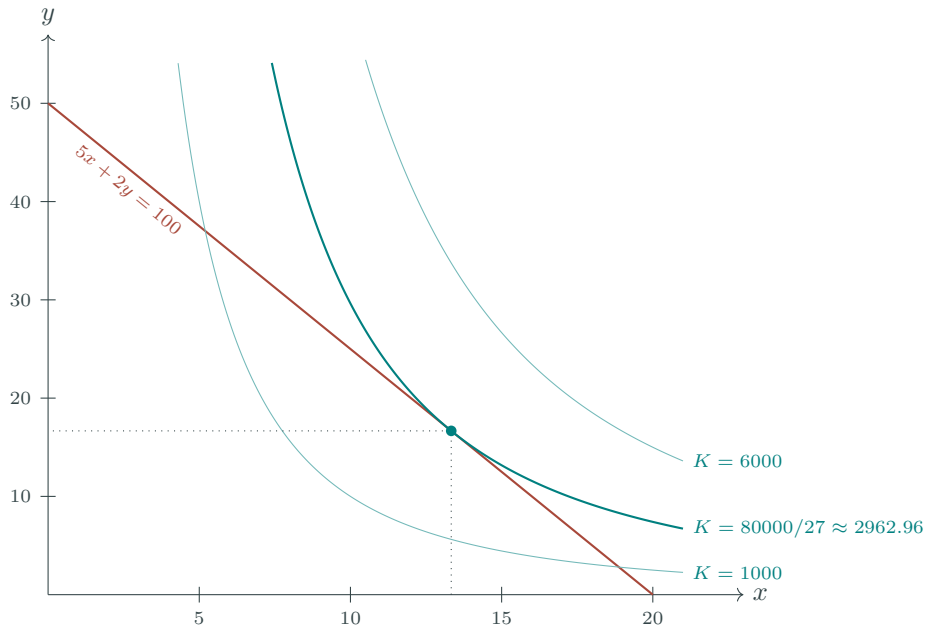


Figura 13: Curvas de nivel $x^2y = K$ y restricción $5x + 2y = 100$. La curva de $K = 1000$ corta a la restricción en dos puntos, la de $K = 6000$ no la alcanza y la de $K = \frac{80000}{27} \approx 2962.96$ es tangente a ella en el óptimo, $x = \frac{40}{3} \approx 13.33$, $y = \frac{50}{3} \approx 16.67$.

Método de igualación de derivadas para la optimización con restricción

Supongamos que queremos optimizar (maximizar o minimizar) una función objetivo $F(x, y)$ sujeta a una restricción $G(x, y) = b$. Llamamos K al valor de F en el óptimo, que todavía no conocemos: el óptimo está sobre la curva de nivel $F(x, y) = K$, y ahí esa curva es tangente a la restricción. Para usar la tangencia, despejamos la misma variable de la curva de nivel y de la restricción, derivamos cada despeje respecto de la otra variable e igualamos las derivadas. Si en esa igualdad aparece K, repetimos el proceso despejando la otra variable y eliminamos K entre las dos igualdades. Así obtenemos una relación entre x e y que, al sustituirla en la restricción, permite hallar la solución óptima.

El procedimiento se resume en el Método 4.1.

Método 4.1 | Igualación de derivadas

Cuándo usarlo. Para optimizar $F(x,y)$ sujeta a $G(x,y) = b$ cuando se puede despejar la misma variable de la curva de nivel $F(x,y) = K$ y de la restricción.

Pasos.

1. **Plantear la curva de nivel del óptimo:** Llamamos K al valor (desconocido) de la función objetivo en el óptimo, que está sobre la curva de nivel $F(x,y) = K$.
2. **Despejar x (o y) en función de y (o x):** Se despeja la misma variable de la curva de nivel y de la restricción:

$$x = n(y) \quad (\text{de } F(x,y) = K) \qquad \text{y} \qquad x = r(y) \quad (\text{de } G(x,y) = b)$$

3. **Derivar respecto a la otra variable:** Se derivan ambas expresiones con respecto a y:

$$\left.\frac{dx}{dy}\right|_{\text{nivel}} = n'(y) \quad \text{y} \quad \left.\frac{dx}{dy}\right|_{\text{restricción}} = r'(y)$$

4. **Igualar las derivadas:** En el punto óptimo ambas curvas son tangentes, por lo que sus pendientes deben coincidir. Esto implica:

$$n'(y) = r'(y)$$

   Esta igualdad da una relación entre K e y (si K no aparece, da directamente el valor de y).
5. **Si aparece K, realizar el proceso con el otro despeje:** Se despeja y en función de x de la curva de nivel y de la restricción:

$$y = \hat{n}(x) \quad (\text{de } F(x,y) = K) \qquad \text{y} \qquad y = \hat{r}(x) \quad (\text{de } G(x,y) = b)$$

   y se derivan ambas expresiones respecto a x:

$$\left.\frac{dy}{dx}\right|_{\text{nivel}} = \hat{n}'(x) \quad \text{y} \quad \left.\frac{dy}{dx}\right|_{\text{restricción}} = \hat{r}'(x)$$

   Igualando estas derivadas, $\hat{n}'(x) = \hat{r}'(x)$, se obtiene una relación entre K y x. Esta segunda igualdad, junto con la anterior, permite eliminar K y obtener una relación entre x e y.
6. **Sustituir en la restricción:** Se reemplaza la relación obtenida en la restricción $G(x,y) = b$ para calcular el valor óptimo de una de las variables y, a partir de allí, el de la otra.

Chequeo. La tangencia no distingue entre un máximo y un mínimo. Con curvas de indiferencia convexas al origen (como las Cobb-Douglas) y una recta presupuestaria, el punto de tangencia es un máximo; con una isocuanta convexa al origen y rectas de isocosto, es un mínimo. En los demás casos, el punto se puede clasificar con el método de sustitución.

Cuidado. Si las variables deben ser no negativas, el óptimo puede estar en una esquina, donde no hay tangencia (ver Soluciones de esquina).

Ejemplo: maximización de $f(x,y) = x^2y$ sujeta a $5x + 2y = 100$

Queremos maximizar

$$f(x,y) = x^2y$$

sujeta a la restricción

$$5x + 2y = 100$$

con $x \geq 0$ e $y \geq 0$. En términos del capítulo anterior, f es una utilidad Cobb-Douglas, sus curvas de nivel son curvas de indiferencia y la restricción es una recta presupuestaria con precios 5 y 2 e ingreso 100. Llamamos

K al valor de f en el óptimo, que está sobre la curva de nivel $x^2y = K$.

Despejar x en función de y

- **Desde la curva de nivel:** Partiendo de
$$x^2y = K$$
despejamos x (tomamos la raíz positiva porque $x \geq 0$):
$$x = \sqrt{\frac{K}{y}} = \sqrt{K}\, y^{-1/2}$$

- **Desde la restricción:** De
$$5x + 2y = 100$$
se obtiene:
$$x = \frac{100 - 2y}{5}$$

- **Derivar respecto a y:**
  - Para la curva de nivel:
$$\frac{dx}{dy} = -\frac{1}{2}\sqrt{K}\, y^{-3/2}$$
  - Para la restricción:
$$\frac{dx}{dy} = -\frac{2}{5}$$

- **Igualar las derivadas:** En el óptimo se tiene:
$$-\frac{1}{2}\sqrt{K}\, y^{-3/2} = -\frac{2}{5}$$
Cancelando el signo negativo y despejando $\sqrt{K}$:
$$\frac{1}{2}\sqrt{K}\, y^{-3/2} = \frac{2}{5} \quad \Longrightarrow \quad \sqrt{K} = \frac{4}{5}\, y^{3/2}$$
Elevando al cuadrado se obtiene:
$$K = \frac{16}{25}\, y^3$$

Despejar y en función de x

Como en la igualdad anterior aparece K, repetimos el proceso despejando y en función de x (paso 5 del Método 4.1).

- **Desde la curva de nivel:** Partiendo de
$$x^2y = K$$
despejamos y:
$$y = \frac{K}{x^2}$$

- **Desde la restricción:** De
$$5x + 2y = 100$$
despejamos y:
$$y = \frac{100 - 5x}{2}$$

- **Derivar respecto a x:**
  - Para la curva de nivel:
$$y = K\,x^{-2} \quad \Longrightarrow \quad \frac{dy}{dx} = -2K\,x^{-3}$$
  - Para la restricción:
$$\frac{dy}{dx} = -\frac{5}{2}$$
- **Igualar las derivadas:** Se igualan:
$$-2K\,x^{-3} = -\frac{5}{2}$$
  Cancelando el signo negativo y despejando K:
$$2K\,x^{-3} = \frac{5}{2} \quad \Longrightarrow \quad K = \frac{5}{4}\,x^3$$

Igualación de los valores de K y obtención de la relación entre x e y

De los dos procesos obtenemos:
$$K = \frac{16}{25}\,y^3 \quad \text{y} \quad K = \frac{5}{4}\,x^3$$
Igualando:
$$\frac{16}{25}\,y^3 = \frac{5}{4}\,x^3$$
Multiplicando ambos lados por 100:
$$64\,y^3 = 125\,x^3$$
Dividiendo ambos lados por $64x^3$:
$$\left(\frac{y}{x}\right)^3 = \frac{125}{64}$$
y, al tomar la raíz cúbica:
$$\frac{y}{x} = \frac{5}{4} = 1.25 \quad \Longrightarrow \quad y = \frac{5}{4}\,x$$

Sustitución en la restricción para hallar x e y

Sustituyendo $y = \frac{5}{4}\,x$ en la restricción
$$5x + 2y = 100$$
se tiene:
$$5x + 2\left(\frac{5}{4}\,x\right) = 5x + \frac{10}{4}\,x = 5x + \frac{5}{2}\,x = \frac{10x + 5x}{2} = \frac{15x}{2} = 100$$
Despejamos x:
$$x = \frac{100 \cdot 2}{15} = \frac{200}{15} = \frac{40}{3} \approx 13.33$$
Luego, y es:
$$y = \frac{5}{4}\,x = \frac{5}{4} \cdot \frac{40}{3} = \frac{200}{12} = \frac{50}{3} \approx 16.67$$

Valor óptimo de la función

Finalmente, el valor óptimo de la función es:

$$f\left(\frac{40}{3}, \frac{50}{3}\right) = \left(\frac{40}{3}\right)^2 \cdot \frac{50}{3} = \frac{1600}{9} \cdot \frac{50}{3} = \frac{80000}{27} \approx 2962.96$$

Como las curvas de indiferencia de x^2y son convexas al origen y la restricción es una recta presupuestaria, el punto hallado es un máximo. Además, es mejor que las esquinas, donde f vale 0.

Ejemplo: minimización de $C = 3x_1 + 6x_2 + 180$ sujeta a $x_1x_2 = 2$

Se desea minimizar

$$C = 3x_1 + 6x_2 + 180$$

sujeto a la restricción

$$x_1x_2 = 2$$

con $x_1 > 0$ y $x_2 > 0$. Las curvas de nivel de C son rectas de isocosto (con un costo fijo de 180) y la restricción es una isocuanta. Llamamos K al costo mínimo, que todavía no conocemos; el óptimo está sobre la recta de isocosto

$$3x_1 + 6x_2 + 180 = K$$

Paso 1: pendiente de la curva de nivel

Despejamos x_2 en función de x_1:

$$x_2 = \frac{K - 180 - 3x_1}{6}$$

Al derivar con respecto a x_1 se obtiene:

$$\frac{dx_2}{dx_1} = -\frac{3}{6} = -\frac{1}{2}$$

Nótese que la derivada no depende de K (la constante desaparece). Por eso, en este ejemplo no hace falta el paso 5 del Método 4.1.

Paso 2: pendiente de la restricción

A partir de la restricción

$$x_1x_2 = 2$$

despejamos x_2:

$$x_2 = \frac{2}{x_1}$$

Derivando respecto a x_1 se obtiene:

$$\frac{dx_2}{dx_1} = -\frac{2}{x_1^2}$$

Paso 3: igualar las derivadas

En el punto de tangencia entre la curva de nivel de la función objetivo y la curva de la restricción, sus pendientes deben ser iguales. Es decir:

$$-\frac{1}{2} = -\frac{2}{x_1^2}$$

Cancelando el signo negativo y resolviendo:

$$\frac{1}{2} = \frac{2}{x_1^2} \quad \Longrightarrow \quad x_1^2 = 4 \quad \Longrightarrow \quad x_1 = 2$$

ya que $x_1 > 0$.

Paso 4: determinar x_2 y el costo óptimo

Sustituyendo $x_1 = 2$ en la restricción:

$$x_2 = \frac{2}{2} = 1$$

Por tanto, el costo mínimo es:

$$C_{\min} = 3(2) + 6(1) + 180 = 6 + 6 + 180 = 192$$

Como la isocuanta $x_1 x_2 = 2$ es convexa al origen y las curvas de nivel de C son rectas de isocosto, el punto hallado es un mínimo.

Método de sustitución para la optimización con restricción

Supongamos que queremos optimizar (maximizar o minimizar) una función objetivo $F(x, y)$ sujeta a una restricción $G(x, y) = b$. Este método consiste en despejar de la restricción una variable, sustituir esa expresión en la función objetivo para **reducir el problema a una única variable**, derivar respecto a esa variable, igualar a cero y, finalmente, resolver para encontrar la solución óptima.

El procedimiento se resume en el Método 4.2.

Método 4.2 | Sustitución

Cuándo usarlo. Para optimizar $F(x, y)$ sujeta a $G(x, y) = b$ cuando se puede despejar una de las variables de la restricción.

Pasos.

1. **Resolver la restricción:** Dada la restricción
$$G(x, y) = b$$
se despeja una de las variables. Por ejemplo, si despejamos y obtenemos:
$$y = g(x)$$
2. **Sustituir en la función objetivo:** Se inserta $y = g(x)$ en la función objetivo $F(x, y)$ para obtener una función de una sola variable:
$$\tilde{F}(x) = F(x, g(x))$$
3. **Derivar e igualar a cero:** Se deriva $\tilde{F}(x)$ respecto a x y se impone la condición de primer orden:
$$\tilde{F}'(x) = 0$$
Las soluciones de esta ecuación son los candidatos a óptimo.
4. **Determinar la otra variable:** Finalmente, se sustituye x^* en la expresión $y = g(x)$ para obtener y^*.

Chequeo. Para clasificar los candidatos se usa la derivada segunda: si $\tilde{F}''(x^*) < 0$, en x^* hay un máximo, y si $\tilde{F}''(x^*) > 0$, un mínimo.

Cuidado. Si las variables deben ser no negativas, se compara además con el valor de $\tilde{F}$ en los extremos del intervalo en el que se mueve x (ver Soluciones de esquina).

Este método reduce el problema original de dos variables a uno de una sola variable, simplificando el proceso de optimización.

Ejemplo: maximización de $f(x,y) = x^2y$ sujeta a $5x + 2y = 100$ (método de sustitución)

Queremos maximizar

$$f(x,y) = x^2y$$

sujeta a la restricción

$$5x + 2y = 100$$

con $x \geq 0$ e $y \geq 0$.

Paso 1: resolver la restricción

De la ecuación

$$5x + 2y = 100$$

despejamos y:

$$y = \frac{100 - 5x}{2}$$

Paso 2: sustituir en la función objetivo

Insertamos la expresión de y en $f(x,y) = x^2y$:

$$\tilde{f}(x) = x^2\left(\frac{100 - 5x}{2}\right) = \frac{1}{2}\left(100x^2 - 5x^3\right)$$

Paso 3: derivar e igualar a cero

Derivamos $\tilde{f}(x)$ respecto a x:

$$\tilde{f}'(x) = \frac{1}{2}\left(200x - 15x^2\right) = 100x - \frac{15}{2}x^2$$

Para hallar los candidatos, igualamos la derivada a cero:

$$100x - \frac{15}{2}x^2 = 0$$

Factorizamos x:

$$x\left(100 - \frac{15}{2}x\right) = 0$$

Se obtienen dos candidatos: $x = 0$ y

$$100 - \frac{15}{2}x = 0 \quad \Longrightarrow \quad x = \frac{200}{15} = \frac{40}{3} \approx 13.33$$

Para clasificarlos usamos la derivada segunda, $\tilde{f}''(x) = 100 - 15x$. Como $\tilde{f}''(0) = 100 > 0$, en $x = 0$ hay un mínimo (ahí $f = 0$); como $\tilde{f}''\left(\frac{40}{3}\right) = 100 - 200 = -100 < 0$, en $x = \frac{40}{3}$ hay un máximo. Además, por $x \geq 0$ e $y \geq 0$, x se mueve en el intervalo $[0, 20]$, y en sus extremos f vale 0. Entonces el máximo está en $x^* = \frac{40}{3} \approx 13.33$.

Paso 4: determinar y

Sustituyendo $x^* = \frac{40}{3}$ en la expresión de y:

$$y^* = \frac{100 - 5\left(\frac{40}{3}\right)}{2} = \frac{100 - \frac{200}{3}}{2} = \frac{\frac{300-200}{3}}{2} = \frac{\frac{100}{3}}{2} = \frac{50}{3} \approx 16.67$$

Paso 5: valor óptimo de la función

El valor óptimo de la función es:

$$f\left(\frac{40}{3}, \frac{50}{3}\right) = \left(\frac{40}{3}\right)^2 \cdot \frac{50}{3} = \frac{80000}{27} \approx 2962.96$$

Ejemplo: minimización de $C = 3x_1 + 6x_2 + 180$ sujeta a $x_1 x_2 = 2$ (método de sustitución)

Se desea minimizar

$$C = 3x_1 + 6x_2 + 180$$

sujeto a la restricción

$$x_1 x_2 = 2$$

con $x_1 > 0$ y $x_2 > 0$.

Paso 1: despejar una variable de la restricción

A partir de la restricción $x_1 x_2 = 2$, despejamos x_2:

$$x_2 = \frac{2}{x_1}$$

Paso 2: sustituir en la función objetivo

Sustituimos la expresión de x_2 en la función objetivo:

$$\widetilde{C}(x_1) = 3x_1 + 6\left(\frac{2}{x_1}\right) + 180 = 3x_1 + \frac{12}{x_1} + 180$$

Paso 3: derivar e igualar a cero

Derivamos la función $\widetilde{C}(x_1)$ respecto a x_1:

$$\frac{d\widetilde{C}}{dx_1} = 3 - \frac{12}{x_1^2}$$

Para hallar los candidatos, igualamos la derivada a cero:

$$3 - \frac{12}{x_1^2} = 0$$

Resolviendo:

$$\frac{12}{x_1^2} = 3 \quad \Longrightarrow \quad x_1^2 = \frac{12}{3} = 4$$

por lo que, como $x_1 > 0$,

$$x_1^* = 2$$

Como $\widetilde{C}''(x_1) = \frac{24}{x_1^3} > 0$ para $x_1 > 0$, en $x_1^* = 2$ hay un mínimo.

Paso 4: determinar x_2 y el costo óptimo

Sustituyendo $x_1 = 2$ en la expresión de x_2:

$$x_2^* = \frac{2}{2} = 1$$

El costo mínimo es, entonces:

$$C_{\min} = 3(2) + 6(1) + 180 = 6 + 6 + 180 = 192$$

Soluciones de esquina

Los dos métodos buscan un punto donde la curva de nivel de la función objetivo es tangente a la restricción. Si las variables deben ser no negativas, el óptimo puede estar en un extremo de la restricción, con alguna variable igual a cero (una *solución de esquina*); ahí, en general, no hay tangencia y la igualación de derivadas no lo encuentra. Por eso, cuando hay condiciones como $x \geq 0$, $y \geq 0$, además de los puntos de tangencia hay que evaluar la función objetivo en las esquinas y quedarse con el mejor valor. En el método de sustitución, esto equivale a comparar con los extremos del intervalo en el que se mueve x.

Ejemplo breve: Consideremos la maximización de

$$f(x, y) = 2x + y$$

sujeta a

$$x + y = 1, \qquad x \geq 0, \quad y \geq 0$$

Las curvas de nivel $2x + y = K$ tienen pendiente -2 y la restricción tiene pendiente -1, así que nunca son tangentes: al igualar las derivadas queda $-2 = -1$, que es imposible. Con el método de sustitución, $y = 1 - x$ y

$$\tilde{f}(x) = 2x + (1 - x) = x + 1, \qquad 0 \leq x \leq 1$$

cuya derivada vale 1 y no se anula nunca. Como $\tilde{f}$ es creciente en $[0, 1]$, el máximo está en $x = 1$, $y = 0$ (una esquina), con $f = 2$.

Más adelante. En el capítulo de aplicación económica del diferencial vamos a ver que la pendiente de una curva de indiferencia es $-\text{TMS}$, así que la condición de tangencia del primer ejemplo dice que la TMS es igual al cociente de precios. En el capítulo de optimización con restricciones de igualdad, el método de Lagrange extiende esta condición a más variables y más restricciones, sin necesidad de despejar.

5 Continuidad

En este capítulo vamos a repasar rápidamente los límites y la continuidad en una variable y extenderemos las ideas al caso de dos variables (o más).

¿Por qué le importa la continuidad a un economista? Porque garantiza que los problemas de optimización tengan solución: una función continua sobre un conjunto cerrado y acotado alcanza un máximo y un mínimo (teorema de Weierstrass). Que el conjunto sea cerrado quiere decir que incluye su borde, y que sea acotado, que no se extiende hasta el infinito. Por ejemplo, si la utilidad es continua y los precios son positivos, entre todas las canastas que el consumidor puede pagar siempre hay una que es la mejor.

Repaso: límites y continuidad en una variable

Sea $f\colon I \subseteq \mathbb{R} \to \mathbb{R}$ y $a \in I$.

- **Límite en a**: escribimos
$$\lim_{x\to a} f(x) = L$$
si $f(x)$ se acerca a L cuando x se acerca a a, sin importar por qué lado lo haga. Lo que cuenta es qué pasa *cerca* de a, no el valor $f(a)$. Los límites laterales se escriben
$$\lim_{x\to a^-} f(x) \text{ (por izquierda)} \qquad \text{y} \qquad \lim_{x\to a^+} f(x) \text{ (por derecha)},$$
y el límite existe si y solo si los dos laterales existen y coinciden.

- **Continuidad en a**:
$$f \text{ es continua en } a \iff \lim_{x\to a} f(x) = f(a).$$

La definición de continuidad engloba tres condiciones:

- La función está definida en a: existe $f(a)$.
- El límite de la función existe cuando $x \to a$.
- El valor de la función en el punto y el límite coinciden.

Decimos que f es continua en I si es continua en cada punto de I.

Para reconocer funciones continuas sin hacer cuentas, conviene saber que las sumas, productos, cocientes (donde el denominador no se anula) y composiciones de funciones continuas son continuas. En particular, son continuas en todo su dominio las funciones polinómicas y racionales, e^x, $\ln x$ $(x > 0)$ y las potencias x^α $(x > 0)$.

Ejemplos

Sea
$$f(x) = (x+1)^2.$$
Tomemos $a = 1$. Verificamos continuidad en a con las tres condiciones:

- Existencia de $f(1)$: $f(1) = (1+1)^2 = 4$.
- Existencia del límite: Como f es polinómica, el límite se calcula evaluando:
$$\lim_{x\to 1} f(x) = \lim_{x\to 1} (x+1)^2 = (1+1)^2 = 4.$$

- Coincidencia límite–valor: $\lim_{x\to 1} f(x) = 4 = f(1)$.

Por lo tanto, f es continua en $x = 1$ (de hecho, en todo $\mathbb{R}$ por ser polinómica).

Veamos otro ejemplo. Definimos

$$g(x) = \begin{cases} \dfrac{x^2-1}{x-1}, & x \neq 1, \\ 0, & x = 1. \end{cases}$$

Observemos que para $x \neq 1$,

$$\frac{x^2-1}{x-1} = \frac{(x-1)(x+1)}{x-1} = x+1,$$

luego

$$\lim_{x\to 1} g(x) = \lim_{x\to 1}(x+1) = 2.$$

Sin embargo, $g(1) = 0$. Entonces:

- Existe $g(1)$: $g(1) = 0$.
- Existe el límite: $\lim_{x\to 1} g(x) = 2$.
- No coinciden: $2 \neq 0$.

Por lo tanto, g es discontinua en $x = 1$ (discontinuidad *evitable*, ya que si redefiniéramos $g(1) = 2$ se volvería continua).

Veamos un tercer ejemplo. Sea

$$h(x) = \frac{1}{x-2}.$$

Analicemos en $a = 2$.

- Existencia de $h(2)$: $h(2)$ no está definida, porque el denominador se anula. Es decir, 2 ni siquiera pertenece al dominio de h, así que la primera condición ya falla.
- Comportamiento del límite:

$$\lim_{x\to 2^-} \frac{1}{x-2} = -\infty, \qquad \lim_{x\to 2^+} \frac{1}{x-2} = +\infty.$$

Por lo tanto, $\lim_{x\to 2} h(x)$ no existe (los límites laterales son infinitos y de distinto signo).

En consecuencia, h presenta una discontinuidad *infinita* en $x = 2$ y la recta $x = 2$ es una *asíntota vertical*.

Un último ejemplo. Sea

$$k(x) = \begin{cases} x, & x < 1, \\ x+1, & x \geq 1. \end{cases}$$

Analicemos en $a = 1$.

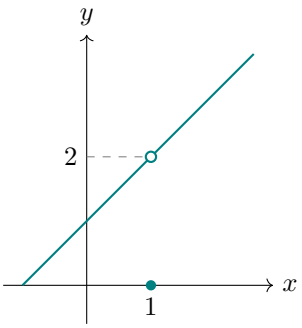
- Existencia de $k(1)$: $k(1) = 1 + 1 = 2$.
- Límites laterales:

$$\lim_{x\to 1^-} k(x) = \lim_{x\to 1^-} x = 1, \qquad \lim_{x\to 1^+} k(x) = \lim_{x\to 1^+} (x+1) = 2.$$

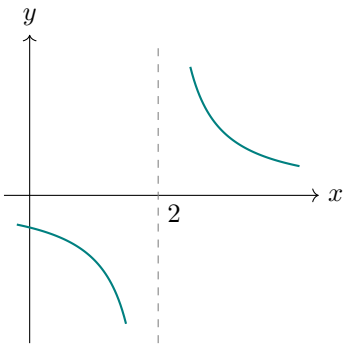
Los dos laterales existen, pero no coinciden, así que $\lim_{x\to 1} k(x)$ no existe.

En consecuencia, k presenta una discontinuidad *de salto* en $x = 1$: su gráfico salta de altura 1 a altura 2. Este tipo de discontinuidad es habitual en economía: un costo fijo que se paga recién al producir la primera unidad, o un impuesto que cobra un monto fijo distinto según el tramo de ingresos, hacen que la función salte en un punto.

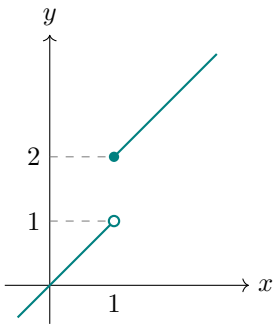
El gráfico muestra los tres tipos de discontinuidad que vimos.



g: evitable en $x = 1$



h: infinita en $x = 2$



k: de salto en $x = 1$

Límites y continuidad en dos variables

Sea $f\colon D \subseteq \mathbb{R}^2 \to \mathbb{R}$ y $\vec{a} = (a_1, a_2)^T \in D$.

- **Continuidad en $\vec{a}$**:

$$f \text{ es continua en } \vec{a} \iff \lim_{(x,y)\to(a_1,a_2)} f(x,y) = f(a_1,a_2).$$

Como en una variable, esta condición resume tres hechos:

- La función está definida en $\vec{a}$: $f(a_1, a_2)$ existe.
- El límite existe al acercarse a $\vec{a}$: $\lim\limits_{(x,y)\to(a_1,a_2)} f(x,y)$ existe.
- Coinciden límite y valor: $\lim\limits_{(x,y)\to(a_1,a_2)} f(x,y) = f(a_1,a_2)$.

Como antes, f es continua en D si lo es en cada punto de D.

En una variable solo hay dos formas de acercarse a a: por izquierda o por derecha (en el ejemplo del salto, esos dos caminos daban valores distintos). En dos variables hay infinitas: por rectas, por parábolas, en espiral. El límite existe, y vale L, cuando $f(x, y)$ se acerca al mismo valor L por *cualquier* camino que lleve a $\vec{a}$. En la práctica lo usamos al revés: si por dos caminos distintos obtenemos límites distintos, el límite no existe.

Las reglas para reconocer funciones continuas siguen valiendo: sumas, productos, cocientes (donde el denominador no se anula) y composiciones de funciones continuas son continuas. Por eso los polinomios en x e y son continuos en todo $\mathbb{R}^2$, y la Cobb-Douglas $f(x, y) = x^\alpha y^\beta$ es continua para $x, y > 0$.

Todo esto vale igual en $\mathbb{R}^n$: con $\vec{x} = (x_1, \ldots, x_n)^T$ y $\vec{a} = (a_1, \ldots, a_n)^T$,

$$f \text{ es continua en } \vec{a} \iff \lim_{\vec{x}\to\vec{a}} f(\vec{x}) = f(\vec{a}).$$

Ejemplos

Sea

$$f(x,y) = x^2 + 2xy + 3y^2.$$

Verifiquemos primero la continuidad en el punto $\vec{a} = (1,2)^T$.

- Existencia de $f(\vec{a})$:
$$f(1,2) = 1^2 + 2 \cdot 1 \cdot 2 + 3 \cdot 2^2 = 1 + 4 + 12 = 17.$$
- Existencia del límite y coincidencia con el valor: Como f es un polinomio (suma y producto de funciones continuas),
$$\lim_{(x,y)\to(1,2)} f(x,y) = f(1,2) = 17.$$

Por lo tanto, f es continua en $(1,2)$.

Además, como f es polinómica en x e y, es continua en todo $\mathbb{R}^2$; es decir, para cualquier $\vec{a} = (a_1, a_2)^T$,

$$\lim_{(x,y)\to(a_1,a_2)} f(x,y) = f(a_1,a_2).$$

Veamos otro caso. Definimos

$$g(x,y) = \begin{cases} 1, & (x,y) \neq (0,0), \\ 0, & (x,y) = (0,0). \end{cases}$$

Al acercarse a $(0,0)$, se tiene $\lim_{(x,y)\to(0,0)} g(x,y) = 1$ (porque g vale 1 en todo punto distinto del origen), pero $g(0,0) = 0$. Por lo tanto, $\lim_{(x,y)\to(0,0)} g(x,y) \neq g(0,0)$ y g es *discontinua* en $(0,0)$. Como en una variable, es una discontinuidad *evitable*: si redefiniéramos $g(0,0) = 1$, g sería la constante 1, que es continua.

Un último ejemplo. Sea

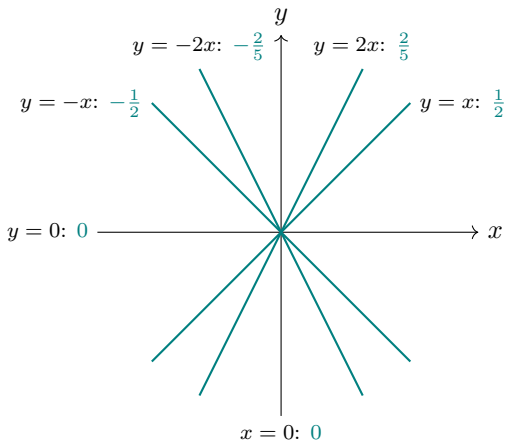
$$h(x,y) = \begin{cases} \dfrac{xy}{x^2+y^2}, & (x,y) \neq (0,0), \\ 0, & (x,y) = (0,0). \end{cases}$$

Consideremos los caminos rectos $y = mx$ que pasan por el origen; para $x \neq 0$,

$$h(x,mx) = \frac{x\,(mx)}{x^2 + m^2x^2} = \frac{m}{1+m^2},$$

cuyo límite cuando $x \to 0$ *depende* de m. Por ejemplo, por $y = x$ el límite vale $\frac{1}{2}$, mientras que por $y = -x$ vale $-\frac{1}{2}$. Luego $\lim_{(x,y)\to(0,0)} h(x,y)$ no existe y h es *discontinua* en $(0,0)$.

En el gráfico, cada recta por el origen lleva su ecuación y el valor que toma h sobre ella (fuera del origen), que es también el límite por ese camino. El valor cambia con la dirección.



Observación. En este ejemplo bastaron dos rectas para probar que el límite no existe. Al revés no funciona: que el límite dé lo mismo por todas las rectas *no* alcanza para asegurar que existe. Por ejemplo, sea

$$k(x,y) = \frac{x^2 y}{x^4 + y^2}, \qquad (x,y) \neq (0,0).$$

Por cualquier recta $y = mx$, para $x \neq 0$,

$$k(x, mx) = \frac{x^2\,(mx)}{x^4 + m^2x^2} = \frac{mx}{x^2 + m^2},$$

que tiende a 0 cuando $x \to 0$; y sobre el eje y, $k(0,y) = 0$. Pero sobre la parábola $y = x^2$,

$$k(x, x^2) = \frac{x^2\,x^2}{x^4 + x^4} = \frac{1}{2}.$$

Como $\frac{1}{2} \neq 0$, $\lim\limits_{(x,y)\to(0,0)} k(x,y)$ no existe.

Resumen

- Continuidad en un punto: f es continua en a si $f(a)$ existe, $\lim\limits_{x\to a} f(x)$ existe y los dos coinciden.
- Tipos de discontinuidad: *evitable* (el límite existe, pero no coincide con $f(a)$ o $f(a)$ no existe), *de salto* (los laterales existen, pero no coinciden) e *infinita* (algún lateral es infinito y hay una asíntota vertical).
- Funciones continuas: son continuas en su dominio las funciones polinómicas y racionales, e^x, $\ln x$, las potencias x^α, y las sumas, productos, cocientes y composiciones de funciones continuas.
- Dos variables: el límite tiene que dar lo mismo por todos los caminos. Dos caminos con límites distintos prueban que no existe; en cambio, que dé lo mismo por todas las rectas no alcanza para probar que existe.

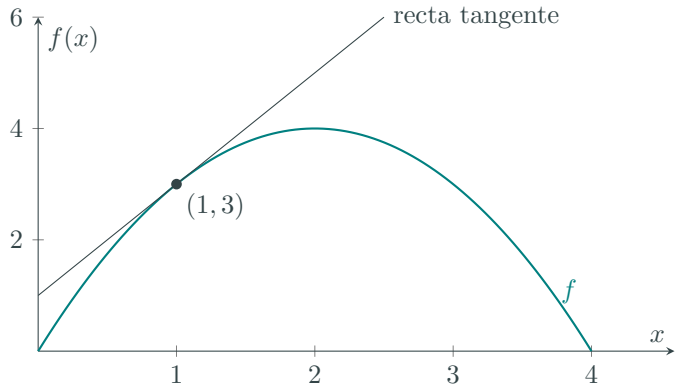
6 Derivadas parciales

Derivada de funciones de una variable

Para funciones de una variable, la derivada es el límite del cociente entre el incremento de la función y el incremento de la variable independiente (cociente incremental), cuando este último, h, tiende a cero:

$$f'(x_0) = \lim_{h\to 0} \frac{f(x_0+h) - f(x_0)}{h}$$

Gráficamente:



La función representada y su derivada son

$$f(x) = -(x-2)^2 + 4 \qquad\qquad f'(x) = -2(x-2)$$

En el punto $(1,3)$, la pendiente de la recta tangente es precisamente la derivada de f respecto a x:

$$\left.\frac{df}{dx}\right|_{x=1} = -2(1-2) = 2$$

Como esta pendiente es positiva, la función es creciente en ese punto.

Derivadas parciales

Para una función de dos variables, $z = f(x,y)$, debemos considerar el incremento de z asociado a cambios en las variables independientes x e y. Para ello, permitimos la variación de una variable manteniendo la otra constante.

Dada la función $z = f(x,y)$, se define la derivada parcial de f con respecto a x en el punto (x_0, y_0) como el valor del siguiente límite, si existe y es finito:

$$\frac{\partial f}{\partial x}(x_0,y_0) = \lim_{h\to 0} \frac{f(x_0+h,\, y_0) - f(x_0,y_0)}{h}$$

Del mismo modo, se define la derivada parcial de f con respecto a y en el punto (x_0, y_0) como el siguiente límite, si existe y es finito:

$$\frac{\partial f}{\partial y}(x_0,y_0) = \lim_{h\to 0} \frac{f(x_0,\, y_0+h) - f(x_0,y_0)}{h}$$

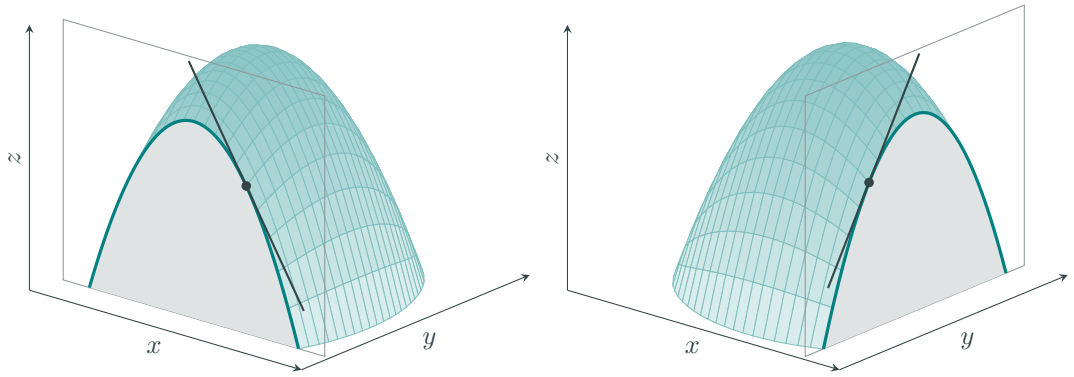
Estas derivadas también se escriben $f'_x(x_0,y_0)$ y $f'_y(x_0,y_0)$.

Intuición: Movemos una sola variable, x o y, en un incremento h, mientras la otra queda fija. Evaluamos f en el punto desplazado y le restamos su valor en el punto original: eso mide cuánto cambió f. Al dividir por h obtenemos la variación de f por unidad de cambio en esa variable, y el límite de ese cociente cuando $h \to 0$ es la derivada parcial en el punto.

Gráficamente, fijar $y = y_0$ es cortar la superficie $z = f(x, y)$ con el plano $y = y_0$. El corte es la curva $z = f(x, y_0)$, que depende solo de x, y $f'_x(x_0, y_0)$ es la pendiente de su recta tangente en x_0, como en una variable. Lo mismo vale para f'_y, cortando con el plano $x = x_0$.

En el gráfico, $f(x, y) = 5 - (x-2)^2 - (y-3)^2/4$ y el punto es $(3, 1)$. En cada panel se sacó la parte de la superficie que queda delante del plano, para que se vea el corte. El corte con $y = 1$ es la parábola $z = 4 - (x-2)^2$ del principio del capítulo, con pendiente -2 en $x = 3$: en ese punto, f baja al aumentar x. El corte con $x = 3$ es $z = 4 - (y-3)^2/4$, con pendiente 1 en $y = 1$: f sube al aumentar y.

Corte con $y = 1$: pendiente $f'_x(3, 1) = -2$ Corte con $x = 3$: pendiente $f'_y(3, 1) = 1$



Derivadas parciales en $\mathbb{R}^n$

Para generalizar lo anterior podemos pasar a n variables. En todo el libro, los vectores de $\mathbb{R}^n$ son vectores columna; cuando los escribimos en una línea usamos la notación $\vec{x} = (x_1, \ldots, x_n)^T$.

Sea $f\colon U \subseteq \mathbb{R}^n \to \mathbb{R}$, con U abierto,[1] y sea $\vec{a} = (a_1, \ldots, a_n)^T \in U$. Para cada $i = 1, \ldots, n$, la derivada parcial de f con respecto a la variable x_i en el punto $\vec{a}$ se define como

$$\frac{\partial f}{\partial x_i}(\vec{a}) = \lim_{h \to 0} \frac{f(a_1, \ldots, a_{i-1}, a_i + h, a_{i+1}, \ldots, a_n) - f(\vec{a})}{h}$$

y también se escribe $f'_{x_i}(\vec{a})$.

El vector que reúne las derivadas parciales es el *gradiente* de f en $\vec{a}$:

$$\nabla f(\vec{a}) = \left(\frac{\partial f}{\partial x_1}(\vec{a}), \ldots, \frac{\partial f}{\partial x_n}(\vec{a}) \right)^T$$

Reglas de derivación

En la práctica, las derivadas parciales se calculan con las mismas reglas de derivación que en una variable, tratando las demás variables como constantes. Por ejemplo, $\frac{\partial}{\partial x}(x^2 y) = 2xy$, porque y actúa como una constante que multiplica a x^2. Las reglas más utilizadas son:

[1] Que U sea abierto quiere decir que alrededor de cada punto de U hay un entorno contenido en U. Así, para h chico, el punto desplazado sigue en U y f está definida en él.

- **Regla de la potencia:**
$$\frac{d}{dx}\big(x^n\big) = nx^{n-1}$$

- **Derivada de la función logarítmica:**
$$\frac{d}{dx}(\ln x) = \frac{1}{x} \quad (x > 0)$$

- **Derivadas de las funciones trigonométricas:**
$$\frac{d}{dx}(\sin x) = \cos x \qquad \frac{d}{dx}(\cos x) = -\sin x$$

- **Derivadas de las funciones exponenciales:**
$$\frac{d}{dx}(a^x) = a^x \ln a \quad (a > 0,\ a \neq 1) \qquad \frac{d}{dx}(e^x) = e^x$$

- **Constantes y sumas:**
$$c' = 0 \qquad \big(cu + v\big)' = cu' + v' \qquad (c \text{ constante})$$

- **Regla del producto:**
$$\big(uv\big)' = u'v + uv'$$

- **Regla del cociente:**
$$\left(\frac{u}{v}\right)' = \frac{u'v - uv'}{v^2}$$

- **Regla de la cadena:**
$$\big(u(v(x))\big)' = u'\big(v(x)\big)v'(x)$$

Ejemplo

Sea la función
$$f(x, y) = x^2y + 3xy^2$$

Por definición

$$\frac{\partial f}{\partial x}(1,2) = \lim_{h\to 0} \frac{f(1+h,2) - f(1,2)}{h}$$

Calculamos

$$f(1+h,2) = 2(1+h)^2 + 12(1+h) = 2 + 4h + 2h^2 + 12 + 12h = 14 + 16h + 2h^2 \qquad \text{y} \qquad f(1,2) = 14$$

Luego

$$\frac{f(1+h,2) - f(1,2)}{h} = \frac{16h + 2h^2}{h} = 16 + 2h$$

y al tomar el límite

$$\frac{\partial f}{\partial x}(1,2) = 16$$

Por reglas de derivación

$$\frac{\partial f}{\partial x}(x,y) = 2xy + 3y^2 \quad \Longrightarrow \quad \frac{\partial f}{\partial x}(1,2) = 2\cdot 1\cdot 2 + 3\cdot 2^2 = 16$$

Otro ejemplo

Sea la función

$$f(x,y) = x^3y^2 + 5xy^3 - x^2y$$

Por definición

$$\frac{\partial f}{\partial x}(x,y) = \lim_{h\to 0} \frac{f(x+h,y) - f(x,y)}{h}$$

$$\begin{aligned} f(x+h,y) &= (x+h)^3y^2 + 5(x+h)y^3 - (x+h)^2y \\ &= x^3y^2 + 3x^2y^2h + 3xy^2h^2 + y^2h^3 + 5xy^3 + 5y^3h - x^2y - 2xyh - yh^2 \end{aligned}$$

$$\frac{f(x+h,y) - f(x,y)}{h} = 3x^2y^2 + 3xy^2h + y^2h^2 + 5y^3 - 2xy - yh \xrightarrow{h\to 0} 3x^2y^2 + 5y^3 - 2xy$$

$$\frac{\partial f}{\partial y}(x,y) = \lim_{h\to 0} \frac{f(x,y+h) - f(x,y)}{h}$$

$$\begin{aligned} f(x,y+h) &= x^3(y+h)^2 + 5x(y+h)^3 - x^2(y+h) \\ &= x^3y^2 + 2x^3yh + x^3h^2 + 5xy^3 + 15xy^2h + 15xyh^2 + 5xh^3 - x^2y - x^2h \end{aligned}$$

$$\frac{f(x,y+h) - f(x,y)}{h} = 2x^3y + x^3h + 15xy^2 + 15xyh + 5xh^2 - x^2 \xrightarrow{h\to 0} 2x^3y + 15xy^2 - x^2$$

Por reglas de derivación

$$\frac{\partial f}{\partial x}(x,y) = \frac{\partial}{\partial x}(x^3y^2) + \frac{\partial}{\partial x}(5xy^3) - \frac{\partial}{\partial x}(x^2y) = 3x^2y^2 + 5y^3 - 2xy$$

$$\frac{\partial f}{\partial y}(x,y) = \frac{\partial}{\partial y}(x^3y^2) + \frac{\partial}{\partial y}(5xy^3) - \frac{\partial}{\partial y}(x^2y) = 2x^3y + 15xy^2 - x^2$$

Ejemplo: gradiente en tres variables

Sea la función

$$f(x,y,z) = \frac{x}{y} + e^{xz}$$

definida para $y \neq 0$. Calculamos su gradiente en el punto $(1,1,0)$.

Derivamos con respecto a cada variable, tratando las otras dos como constantes. En x/y, al derivar con respecto a x, $1/y$ es una constante que multiplica a x; al derivar con respecto a y, x es una constante que multiplica a y^{-1}. En e^{xz} se usa la regla de la cadena: se multiplica por la derivada del exponente xz, que es z con respecto a x y x con respecto a z. Con respecto a y, e^{xz} es una constante y su derivada es 0.

$$f'_x(x,y,z) = \frac{1}{y} + ze^{xz} \qquad f'_y(x,y,z) = -\frac{x}{y^2} \qquad f'_z(x,y,z) = xe^{xz}$$

El gradiente reúne las tres derivadas en un vector columna:

$$\nabla f(x,y,z) = \begin{pmatrix} 1/y + ze^{xz} \\ -x/y^2 \\ xe^{xz} \end{pmatrix} \quad \Longrightarrow \quad \nabla f(1,1,0) = \begin{pmatrix} 1 + 0\cdot e^0 \\ -1 \\ 1\cdot e^0 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix}$$

Escrito en una línea, $\nabla f(1,1,0) = (1,-1,1)^T$.

Las reglas de derivación se deducen de la definición de derivada como límite, pero no sirven en dos casos: en una función partida, en el punto donde cambia la fórmula, y en un punto donde la derivada que dan las reglas no está definida (por ejemplo, porque divide por cero). En esos casos hay que calcular la derivada parcial con la definición.

Método 6.1 | Derivada parcial por definición

Cuándo usarlo. Cuando lo pide el enunciado, cuando f es partida y el punto es aquel donde cambia la fórmula, o cuando la derivada que dan las reglas no está definida en el punto. En los demás casos, se deriva con las reglas, tratando las otras variables como constantes.

Pasos.

1. Escribir el cociente incremental moviendo solo la variable con respecto a la que se deriva; para x, $\big(f(x_0+h,\, y_0) - f(x_0,y_0)\big)/h$.
2. Calcular $f(x_0+h,\, y_0)$ y $f(x_0,y_0)$.
3. Restar, simplificar y cancelar la h del denominador.
4. Tomar el límite cuando $h \to 0$.

Cuidado. En una función partida, el punto desplazado (con $h \neq 0$) se evalúa con la fórmula general, y el punto original, con el valor definido aparte.

Ejemplo con función partida

Sea la función

$$f(x,y) = \begin{cases} \dfrac{x^3}{x^2+y^2}, & (x,y) \neq (0,0) \\ 0, & (x,y) = (0,0) \end{cases}$$

Por definición

Para $h \neq 0$, $f(h,0) = h^3/h^2 = h$. Entonces

$$\frac{\partial f}{\partial x}(0,0) = \lim_{h\to 0} \frac{f(h,0) - f(0,0)}{h} = \lim_{h\to 0} \frac{h-0}{h} = 1$$

Del mismo modo, para $h \neq 0$, $f(0,h) = 0/h^2 = 0$, así que

$$\frac{\partial f}{\partial y}(0,0) = \lim_{h\to 0} \frac{f(0,h) - f(0,0)}{h} = \lim_{h\to 0} \frac{0-0}{h} = 0$$

Las reglas no sirven en el origen. Con la regla del cociente, para $(x,y) \neq (0,0)$ se obtiene

$$f'_x(x,y) = \frac{x^4 + 3x^2y^2}{(x^2+y^2)^2}$$

que en $(0,0)$ da $0/0$. Ni siquiera tomando límite se arregla: sobre el eje x esa expresión vale 1, y sobre el eje y vale 0.

Ejemplo: una derivada parcial que no existe

Sea la función

$$f(x,y) = \sqrt{x^2+y^2}$$

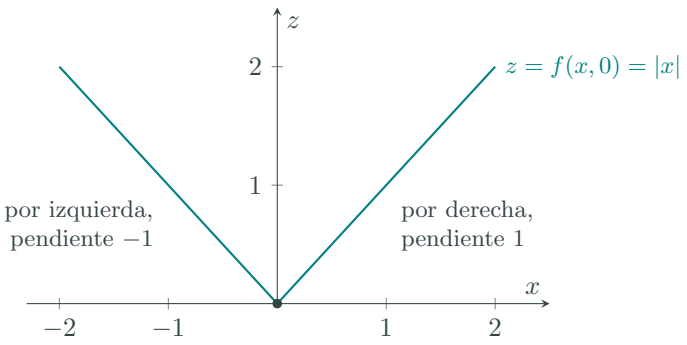
Acá la fórmula es una sola, pero las reglas no sirven en el origen: dan $f'_x(x,y) = x/\sqrt{x^2+y^2}$, que en $(0,0)$ divide por cero. Calculamos con la definición. Para $h \neq 0$, $f(h,0) = \sqrt{h^2} = |h|$, así que

$$\frac{f(h,0) - f(0,0)}{h} = \frac{|h|}{h} = \begin{cases} 1, & h > 0 \\ -1, & h < 0 \end{cases}$$

Por derecha el cociente vale 1 y por izquierda vale -1. Como los límites laterales son distintos, el límite no existe:

$$\frac{\partial f}{\partial x}(0,0) \text{ no existe}$$

Del mismo modo, $f(0,h) = |h|$ da el mismo cociente, así que $f'_y(0,0)$ tampoco existe. En el gráfico del corte con $y = 0$, $z = |x|$, se ve el pico del origen: las pendientes por derecha y por izquierda son distintas, y no hay una única recta tangente.



Derivadas sucesivas

En una sola variable ya conocemos las derivadas sucesivas:

$$f'(x), \quad f''(x), \quad \ldots, \quad f^{(n)}(x)$$

que se obtienen aplicando la definición de derivada reiteradamente sobre la función resultante.

En varias variables podemos también derivar más de una vez, ya sea respecto a la misma variable o a variables distintas. Así surgen las derivadas parciales de orden dos y superiores, por ejemplo:

$$\frac{\partial^2 f}{\partial x^2} = f''_{xx} \qquad \frac{\partial^2 f}{\partial y \partial x} = f''_{xy} \qquad \frac{\partial^2 f}{\partial x \partial y} = f''_{yx} \qquad \frac{\partial^2 f}{\partial y^2} = f''_{yy}$$

Las derivadas cruzadas f''_{xy} y f''_{yx} se obtienen derivando primero con respecto a x y luego a y, o viceversa. En n variables, primero se deriva con respecto a x_i y luego con respecto a x_j:

$$f''_{x_i x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}$$

En general, las derivadas sucesivas se calculan tomando la derivada parcial de la derivada parcial considerada como nueva función, es decir, si $g(x,y) = \frac{\partial f}{\partial x}(x,y)$, entonces

$$\frac{\partial^2 f}{\partial y \partial x}(x,y) = \frac{\partial}{\partial y}\big(g(x,y)\big)$$

y así sucesivamente para órdenes mayores.

Ejemplo

Sea la función

$$f(x,y) = e^x + e^y + y\sin(x)$$

Derivadas parciales de primer orden

$$\frac{\partial f}{\partial x}(x,y) = \frac{\partial}{\partial x}\big(e^x + e^y + y\sin(x)\big) = e^x + y\cos(x) \quad \Longrightarrow \quad f'_x(x,y) = e^x + y\cos(x)$$

$$\frac{\partial f}{\partial y}(x,y) = \frac{\partial}{\partial y}\big(e^x + e^y + y\sin(x)\big) = e^y + \sin(x) \quad \Longrightarrow \quad f'_y(x,y) = e^y + \sin(x)$$

Derivadas parciales de segundo orden

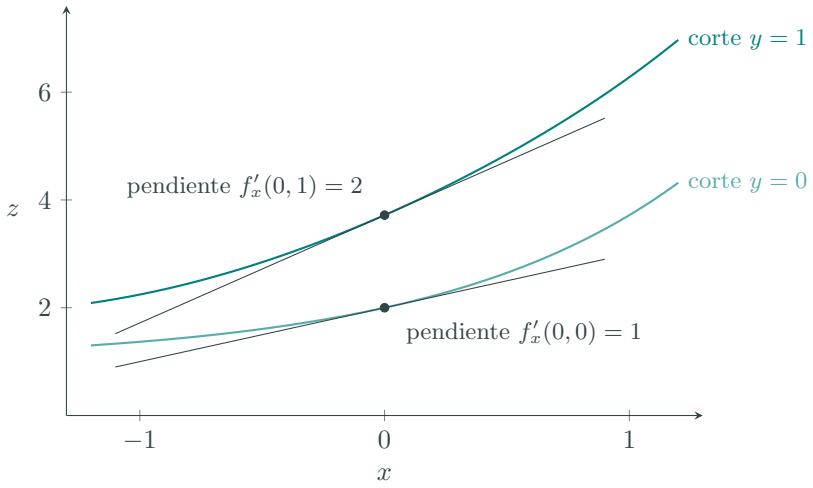
$$\frac{\partial^2 f}{\partial x^2} = \frac{\partial}{\partial x}\big(e^x + y\cos(x)\big) = e^x - y\sin(x) \quad \Longrightarrow \quad f''_{xx}(x,y) = e^x - y\sin(x)$$

$$\frac{\partial^2 f}{\partial y \partial x} = \frac{\partial}{\partial y}\big(e^x + y\cos(x)\big) = \cos(x) \quad \Longrightarrow \quad f''_{xy}(x,y) = \cos(x)$$

$$\frac{\partial^2 f}{\partial x \partial y} = \frac{\partial}{\partial x}\big(e^y + \sin(x)\big) = \cos(x) \quad \Longrightarrow \quad f''_{yx}(x,y) = \cos(x)$$

$$\frac{\partial^2 f}{\partial y^2} = \frac{\partial}{\partial y}\big(e^y + \sin(x)\big) = e^y \quad \Longrightarrow \quad f''_{yy}(x,y) = e^y$$

Gráficamente, f''_{xy} mide cuánto cambia la pendiente en la dirección de x cuando aumenta y. En este ejemplo, $f'_x(0,y) = 1 + y$: al pasar del corte $y = 0$ al corte $y = 1$, la pendiente en $x = 0$ sube de 1 a 2, y ese aumento por unidad de y es $f''_{xy}(0,y) = \cos(0) = 1$. A su vez, f''_{xx} da la concavidad de cada corte: $f''_{xx}(0,0) = f''_{xx}(0,1) = 1 > 0$, y por eso los dos cortes son convexos cerca de $x = 0$.



Las dos derivadas cruzadas dieron lo mismo. No es casualidad: es lo que asegura el teorema de Schwarz.

Teorema de Schwarz

Una función $f\colon U \subseteq \mathbb{R}^n \to \mathbb{R}$, con U abierto, es *de clase* C^1 en U si sus derivadas parciales de primer orden existen y son continuas en U, y *de clase* C^2 si además las de segundo orden existen y son continuas en U.

Teorema de Schwarz. Si f es de clase C^2 en U, las derivadas cruzadas coinciden en todo U:

$$f''_{x_i x_j} = f''_{x_j x_i} \qquad \text{para todo } i, j = 1, \ldots, n$$

En los libros de Economía suele aparecer como *teorema de Young*. En la práctica, si f es de clase C^2, alcanza con calcular una de las dos derivadas cruzadas. Son de clase C^2 los polinomios, las exponenciales, los logaritmos, las potencias x^a con $x > 0$, el seno y el coseno, y las funciones que se arman con ellos mediante sumas, productos, cocientes y composiciones, en los puntos donde no se divide por cero y donde lo que está dentro de cada logaritmo o de cada potencia de exponente no entero es positivo.

Método 6.2 | Derivadas de segundo orden

Pasos.

1. Calcular f'_x y f'_y.
2. Derivar f'_x con respecto a x y con respecto a y: se obtienen f''_{xx} y f''_{xy}.
3. Derivar f'_y con respecto a y: se obtiene f''_{yy}.
4. Si f es de clase C^2, por el teorema de Schwarz $f''_{yx} = f''_{xy}$, y no hace falta calcularla.

Cuidado. $f''_{xy} = \partial^2 f / \partial y \partial x$: en las dos notaciones se deriva primero con respecto a x, pero las letras aparecen en orden inverso.

Ejemplo

Sea la función

$$f(x, y) = x^2 y + e^{xy}$$

Como f es suma de un polinomio y de una exponencial compuesta con un polinomio, es de clase C^2 en $\mathbb{R}^2$. Por el teorema de Schwarz, $f''_{xy} = f''_{yx}$ en todo $\mathbb{R}^2$, y alcanza con calcular una de las dos.

Cálculo de las derivadas parciales

$$f'_x(x,y) = \frac{\partial}{\partial x}\left(x^2y + e^{xy}\right) = 2xy + ye^{xy} \qquad f'_y(x,y) = \frac{\partial}{\partial y}\left(x^2y + e^{xy}\right) = x^2 + xe^{xy}$$

Derivadas cruzadas

$$f''_{xy}(x,y) = \frac{\partial}{\partial y}\left(2xy + ye^{xy}\right) = 2x + e^{xy} + xye^{xy}$$

Como verificación, derivando f'_y con respecto a x se obtiene lo mismo:

$$f''_{yx}(x,y) = \frac{\partial}{\partial x}\left(x^2 + xe^{xy}\right) = 2x + e^{xy} + xye^{xy}$$

$$f''_{xy}(x,y) = f''_{yx}(x,y)$$

7 Diferencial

Recordatorio: cálculo univariable

Sea $f : \mathbb{R} \to \mathbb{R}$ diferenciable en x_0. La *aproximación lineal* (o *linealización*) alrededor de x_0 es

$$f(x_0 + h) \;\approx\; f(x_0) + f'(x_0)\,h, \quad \text{con } h = x - x_0$$

El *diferencial* de f en x_0 se define como

$$\mathrm{d}f \;=\; f'(x_0)\,\mathrm{d}x$$

Intuición: Al "hacer zoom" sobre la gráfica de f alrededor de x_0, la curva se vuelve casi recta: la *recta tangente*, con pendiente $f'(x_0)$, es la mejor aproximación local de f.

Dar un pequeño paso $\mathrm{d}x$ en x provoca un cambio real

$$\Delta f \;=\; f(x_0 + \mathrm{d}x) - f(x_0)$$

que es *aproximadamente igual* al diferencial:

$$\Delta f \;\approx\; \mathrm{d}f \;=\; f'(x_0)\,\mathrm{d}x$$

es decir, *pendiente* $\times$ *paso*.

También se puede expresar como

$$f(x_0 + h) = f(x_0) + f'(x_0)h + o(h) \quad \text{cuando } h \to 0$$

donde $o(h)$ denota un término tal que

$$\lim_{h \to 0} \frac{o(h)}{h} = 0$$

Es decir, el error entre la aproximación lineal y el valor real es despreciable frente a $|h|$ cuando $h \to 0$.

Definición en dos variables independientes

Sea $f\colon D \subseteq \mathbb{R}^2 \to \mathbb{R}$, con D abierto, y sea $(a, b) \in D$. Decimos que f es *diferenciable* en (a, b) si existen $f'_x(a, b)$ y $f'_y(a, b)$ y, como en una variable,

$$f(a + \mathrm{d}x,\, b + \mathrm{d}y) = f(a, b) + f'_x(a, b)\,\mathrm{d}x + f'_y(a, b)\,\mathrm{d}y + o\Big(\sqrt{(\mathrm{d}x)^2 + (\mathrm{d}y)^2}\Big)$$

cuando $(\mathrm{d}x, \mathrm{d}y) \to (0, 0)$. Es decir, el error de la aproximación es despreciable frente a la distancia entre (a, b) y el punto nuevo.

Equivalentemente,

$$f(a + \mathrm{d}x,\, b + \mathrm{d}y) \;\approx\; f(a, b) + f'_x(a, b)\,\mathrm{d}x + f'_y(a, b)\,\mathrm{d}y$$

Geometría: en dos variables, la aproximación *no es una recta*, sino un *plano tangente* a la gráfica $z = f(x, y)$ en (a, b):

$$z \;\approx\; f(a, b) + f'_x(a, b)\,(x - a) + f'_y(a, b)\,(y - b)$$

Intuición: Lo que buscamos es aproximar el cambio de z a partir de cambios pequeños en x e y. Cada derivada parcial $f'_x(a,b)$ y $f'_y(a,b)$ mide cuán sensible es z a cambios en x o en y, respectivamente.

Si nos movemos $\mathrm{d}x$ en x y $\mathrm{d}y$ en y, el cambio total se aproxima sumando ambos aportes:

$$\Delta z \;\approx\; \mathrm{d}f \;=\; f'_x(a,b)\,\mathrm{d}x + f'_y(a,b)\,\mathrm{d}y$$

es decir, *"pendiente en x" × "paso en x" + "pendiente en y" × "paso en y"*.

Condiciones suficientes

Si f'_x y f'_y existen en un entorno de (a,b) y son continuas en (a,b), entonces f es diferenciable en (a,b) y la aproximación lineal anterior es válida.

Intuición: Exigir que f'_x y f'_y sean continuas cerca de (a,b) garantiza que las pendientes en x y en y no cambien bruscamente. Si las pendientes varían de forma suave, entonces la superficie de f cerca de (a,b) se parece mucho a su plano tangente, y la aproximación lineal mediante el diferencial describe bien los cambios pequeños en z.

Caso general $\mathbb{R}^n \to \mathbb{R}$

Para $f:\mathbb{R}^n \to \mathbb{R}$ diferenciable en $\mathbf{a} \in \mathbb{R}^n$,

$$\mathrm{d}f \;=\; \frac{\partial f}{\partial x_1}(\mathbf{a})\,\mathrm{d}x_1 \;+\; \frac{\partial f}{\partial x_2}(\mathbf{a})\,\mathrm{d}x_2 \;+\; \cdots \;+\; \frac{\partial f}{\partial x_n}(\mathbf{a})\,\mathrm{d}x_n$$

Es decir,

$$\mathrm{d}f \;=\; \nabla f(\mathbf{a}) \cdot \mathrm{d}\mathbf{x} \;=\; \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\mathbf{a})\,\mathrm{d}x_i$$

De forma aproximada,

$$f(a_1 + \mathrm{d}x_1, \ldots, a_n + \mathrm{d}x_n) \;\approx\; f(a_1, \ldots, a_n) + \mathrm{d}f$$

Ejemplo

Sea $f(x,y) = x^2 y + e^{xy}$. Entonces

$$f'_x = 2xy + y\,e^{xy}, \qquad f'_y = x^2 + x\,e^{xy}$$

En $(a,b) = (1,1)$,

$$\mathrm{d}f \;=\; \big(2\cdot 1\cdot 1 + 1\cdot e\big)\,\mathrm{d}x + \big(1^2 + 1\cdot e\big)\,\mathrm{d}y \;=\; (2+e)\,\mathrm{d}x + (1+e)\,\mathrm{d}y$$

Para $\mathrm{d}x = 0.01$ y $\mathrm{d}y = -0.02$,

$$\Delta f \approx \mathrm{d}f = (2+e)(0.01) + (1+e)(-0.02) \approx -0.0272$$

El resultado negativo indica que, con un pequeño incremento en x y una disminución en y, el valor de la función f tiende a reducirse levemente. En otras palabras, el efecto de disminuir y en 0.02 supera el

incremento positivo producido al aumentar x en 0.01, de modo que el cambio neto es una pequeña disminución en f.

Si calculamos la variación real, obtenemos

$$\begin{aligned}\Delta f &= f(1.01,\, 0.98) - f(1,1)\\ &= (1.01)^2 \cdot 0.98 + e^{\,0.9898} - (1+e)\\ &= 3.6903942793 - 3.7182818285\\ &= -0.0278875492\end{aligned}$$

Este valor es cercano al obtenido mediante el diferencial. La pequeña diferencia se debe a que el diferencial proporciona una aproximación lineal del cambio real de la función.

Diferencial de segundo orden

Sea $f : \mathbb{R}^2 \to \mathbb{R}$ con derivadas parciales primeras y segundas existentes en un entorno de (a, b), y cuyas derivadas parciales de segundo orden son continuas en ese entorno. Su *diferencial de segundo orden* en (a, b) es

$$\mathrm{d}^2 f \;=\; f''_{xx}(a,b)\,(\mathrm{d}x)^2 + f''_{xy}(a,b)\,\mathrm{d}x\,\mathrm{d}y + f''_{yx}(a,b)\,\mathrm{d}y\,\mathrm{d}x + f''_{yy}(a,b)\,(\mathrm{d}y)^2$$

El diferencial de segundo orden incorpora información sobre la *curvatura local* de la función y describe la contribución de segundo orden a su variación. En particular, puede utilizarse para construir aproximaciones más precisas, como el polinomio de Taylor de segundo orden.

Polinomio de Taylor

El polinomio de Taylor permite aproximar una función alrededor de un punto utilizando información sobre sus derivadas en ese punto. La idea es extender la aproximación lineal: en lugar de utilizar solamente la pendiente, incorporamos también información sobre la curvatura y, si fuera necesario, derivadas de órdenes superiores.

Caso univariable

Sea $f : \mathbb{R} \to \mathbb{R}$ una función con suficientes derivadas alrededor de $x = a$. Recordemos que la aproximación lineal viene dada por

$$f(a+h) \approx f(a) + f'(a)h$$

Esta aproximación utiliza solamente el valor de la función y su pendiente en a. Si además queremos incorporar información sobre la curvatura de f, podemos agregar un término que involucra la segunda derivada:

$$f(a+h) \approx f(a) + f'(a)h + \frac{1}{2}f''(a)h^2$$

El lado derecho de esta expresión es el *polinomio de Taylor de segundo orden* de f alrededor de a.

Utilizando diferenciales, si $h = \mathrm{d}x$, podemos escribir

$$f(a+\mathrm{d}x) \approx f(a) + \underbrace{f'(a)\,\mathrm{d}x}_{\mathrm{d}f} + \frac{1}{2}\underbrace{f''(a)(\mathrm{d}x)^2}_{\mathrm{d}^2 f}$$

Por lo tanto,

$$f(a+\mathrm{d}x) \approx f(a) + \mathrm{d}f + \frac{1}{2}\mathrm{d}^2 f$$

Intuición: El término de primer orden describe el cambio lineal predicho por la pendiente de la función. El término de segundo orden corrige esa aproximación teniendo en cuenta su *curvatura local*.[2]

Si utilizamos derivadas de órdenes superiores, obtenemos aproximaciones que incorporan cada vez más información local sobre la función. El polinomio de Taylor de orden n alrededor de a es

$$P_n(x) = f(a) + f'(a)(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \cdots + \frac{f^{(n)}(a)}{n!}(x-a)^n$$

De manera compacta,

$$P_n(x) = \sum_{k=0}^{n} \frac{f^{(k)}(a)}{k!}(x-a)^k$$

Así, para valores de x suficientemente cercanos a a,

$$f(x) \approx P_n(x)$$

En general, al aumentar el orden del polinomio incorporamos más información local sobre la función y, bajo condiciones apropiadas, podemos obtener una mejor aproximación cerca del punto a.

Caso multivariable

La misma idea puede extenderse a funciones de varias variables.

Sea $f : \mathbb{R}^2 \to \mathbb{R}$ una función con suficientes derivadas parciales alrededor de (a, b). La aproximación de Taylor de primer orden es precisamente la aproximación lineal estudiada anteriormente:

$$f(a + \mathrm{d}x, b + \mathrm{d}y) \approx f(a,b) + f'_x(a,b)\,\mathrm{d}x + f'_y(a,b)\,\mathrm{d}y$$

Es decir,

$$f(a + \mathrm{d}x, b + \mathrm{d}y) \approx f(a,b) + \mathrm{d}f$$

Si además incorporamos las derivadas de segundo orden, obtenemos la aproximación de Taylor de segundo orden:

$$\begin{aligned} f(a + \mathrm{d}x, b + \mathrm{d}y) \approx f(a,b) &+ f'_x(a,b)\,\mathrm{d}x + f'_y(a,b)\,\mathrm{d}y \\ &+ \frac{1}{2}\Big[f''_{xx}(a,b)(\mathrm{d}x)^2 + 2f''_{xy}(a,b)\,\mathrm{d}x\,\mathrm{d}y + f''_{yy}(a,b)(\mathrm{d}y)^2\Big] \end{aligned}$$

donde hemos supuesto que las derivadas parciales mixtas son continuas, de modo que

$$f''_{xy}(a,b) = f''_{yx}(a,b)$$

Utilizando los diferenciales de primer y segundo orden, esta expresión puede escribirse de forma más compacta como

$$f(a + \mathrm{d}x, b + \mathrm{d}y) \approx f(a,b) + \mathrm{d}f + \frac{1}{2}\mathrm{d}^2 f$$

[2] El factor $\frac{1}{2}$ que aparece en el término de segundo orden puede escribirse como $\frac{1}{2!}$. En general, para el término de orden n aparece el factor $\frac{1}{n!}$, ya que al derivar n veces el término $(x-a)^n$ se obtiene $n!$. Dividir por $n!$ permite que la derivada de orden n del polinomio de Taylor, evaluada en $x = a$, coincida exactamente con la derivada de orden n de la función original evaluada en a.

Intuición: En varias variables ocurre algo similar al caso univariable. El diferencial de primer orden describe el comportamiento local de la función mediante su plano tangente, mientras que el diferencial de segundo orden incorpora información sobre su curvatura en las distintas direcciones.

Los términos

$$f''_{xx}(\mathrm{d}x)^2 \qquad \text{y} \qquad f''_{yy}(\mathrm{d}y)^2$$

describen las contribuciones de segundo orden asociadas a cada variable por separado, mientras que el término

$$2f''_{xy}\,\mathrm{d}x\,\mathrm{d}y$$

describe la interacción entre los cambios en x e y.

Plano tangente

En una variable, al "hacer zoom" alrededor de $x = a$, la gráfica se vuelve casi recta y la *recta tangente*, con pendiente $f'(a)$, constituye la mejor aproximación lineal local.

En dos variables, el análogo es el plano tangente a la superficie $z = f(x, y)$.

Sea $f : \mathbb{R}^2 \to \mathbb{R}$ diferenciable en (a, b). El *plano tangente* a la gráfica $z = f(x, y)$ en el punto $(a, b, f(a, b))$ es

$$z = f(a, b) + f'_x(a, b)\,(x - a) + f'_y(a, b)\,(y - b)$$

Ejemplo Tomemos $f(x, y) = \ln(x + y) + x^2y$, cuyo dominio está dado por $x + y > 0$. Entonces

$$f'_x = \frac{1}{x+y} + 2xy, \qquad f'_y = \frac{1}{x+y} + x^2$$

En $(a, b) = (2, 1)$,

$$f(2,1) = \ln 3 + 4, \qquad f'_x(2,1) = \frac{1}{3} + 4 = \frac{13}{3}, \qquad f'_y(2,1) = \frac{1}{3} + 4 = \frac{13}{3}$$

Por lo tanto, el plano tangente es

$$z = \ln 3 + 4 + \frac{13}{3}\,(x - 2) + \frac{13}{3}\,(y - 1)$$

El plano tangente proporciona una buena aproximación de la superficie original siempre que nos mantengamos en un entorno suficientemente cercano al punto analizado.

8 Aplicación económica de diferencial

Tasa marginal de sustitución (TMS)

Dada una función de utilidad que depende de las cantidades de dos bienes q_1 y q_2, llamamos *tasa marginal de sustitución (TMS)* a la tasa de compensación entre ellos. Es decir, es la cantidad que se estaría dispuesto a ceder de uno de los bienes para obtener una unidad adicional del otro, manteniendo constante el nivel de utilidad.

Calculamos el diferencial de la función de utilidad $u(q_1, q_2)$:

$$du = \frac{\partial u}{\partial q_1} dq_1 + \frac{\partial u}{\partial q_2} dq_2$$

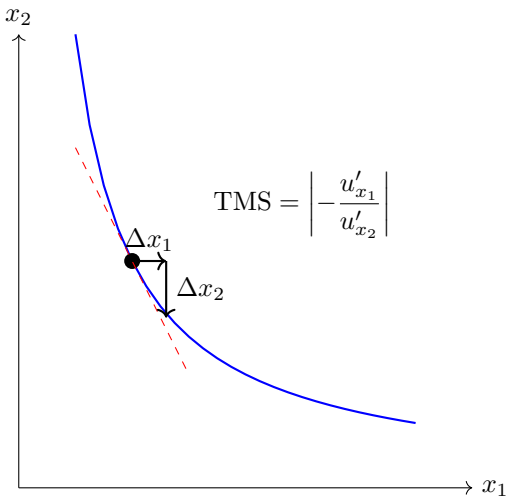
Como $du = 0$ sobre la curva de indiferencia:

$$\frac{\partial u}{\partial q_1} dq_1 + \frac{\partial u}{\partial q_2} dq_2 = 0 \Rightarrow \frac{dq_2}{dq_1} = -\frac{\frac{\partial u}{\partial q_1}}{\frac{\partial u}{\partial q_2}}$$

Esta pendiente o el módulo de la misma representa lo que se suele llamar tasa marginal de sustitución de bienes:

$$\text{TMS} = \left| \frac{dq_2}{dq_1} \right| = \frac{\frac{\partial u}{\partial q_1}}{\frac{\partial u}{\partial q_2}}$$

Graficamente



Ejemplo

Dada la función de utilidad $u(q_1, q_2) = 5q_1q_2$, calcular la TMS en el punto $(q_1 = 5, q_2 = 2)$.

$$\frac{\partial u}{\partial q_1} = 5q_2 = 5 \cdot 2 = 10$$
$$\frac{\partial u}{\partial q_2} = 5q_1 = 5 \cdot 5 = 25$$
$$\text{TMS} = \frac{10}{25} = 0.4$$

Interpretación: Para aumentar una unidad de q_1, se deben ceder 0.4 unidades de q_2 para mantener constante el nivel de utilidad

Si se invierte la tasa y se calcula $\frac{dq_1}{dq_2}$, obtenemos:

$$\frac{dq_1}{dq_2} = \frac{\frac{\partial u}{\partial q_2}}{\frac{\partial u}{\partial q_1}} = \frac{25}{10} = 2.5$$

Interpretación: Para aumentar una unidad de q_2, se deben ceder 2.5 unidades de q_1 para mantener constante el nivel de utilidad

Tasa de sustitución técnica

Dada una función de producción que depende de dos insumos x_1 y x_2, llamamos *tasa marginal de sustitución técnica (TST)* a la tasa a la que una empresa puede sustituir un factor productivo por otro, manteniendo constante el nivel de producción.

Calculamos el diferencial de la función de producción $q(x_1, x_2)$:

$$dq = \frac{\partial q}{\partial x_1} dx_1 + \frac{\partial q}{\partial x_2} dx_2$$

Como $dq = 0$ sobre la isocuanta:

$$\frac{\partial q}{\partial x_1} dx_1 + \frac{\partial q}{\partial x_2} dx_2 = 0 \Rightarrow \frac{dx_2}{dx_1} = -\frac{\frac{\partial q}{\partial x_1}}{\frac{\partial q}{\partial x_2}}$$

El módulo de esta pendiente representa la tasa marginal de sustitución técnica:

$$\text{TST} = \left|\frac{dx_2}{dx_1}\right| = \frac{\frac{\partial q}{\partial x_1}}{\frac{\partial q}{\partial x_2}}$$

Ejemplo

Dada la función de producción:

$$q(a, b) = 20 - 7a + 8b - a^2 + b^2$$

calcular la TST en el punto $a = 1.2, b = 2.2$.

$$\frac{\partial q}{\partial a} = -7 - 2a = -7 - 2(1.2) = -9.4$$
$$\frac{\partial q}{\partial b} = 8 + 2b = 8 + 2(2.2) = 12.4$$
$$\text{TST} = \frac{-9.4}{12.4} \approx -0.758$$

Interpretación: Para aumentar una unidad de a, se deben ceder aproximadamente 0.758 unidades de b para mantener constante el nivel de producción

Si se invierte la tasa y se calcula $\frac{dx_1}{dx_2}$, obtenemos:

$$\frac{dx_1}{dx_2} = \frac{\frac{\partial q}{\partial b}}{\frac{\partial q}{\partial a}} = \frac{12.4}{-9.4} \approx -1.319$$

Interpretación: Para aumentar una unidad de b, se deben ceder aproximadamente 1.319 unidades de a para mantener constante el nivel de producción

Notación

En muchos textos se utiliza una notación abreviada del tipo $\text{TMS}(x_1/x_2)$ para referirse a las tasas marginales de sustitución.

$\text{TMS}(x_1/x_2)$ representa la tasa marginal de sustitución donde el numerador es la derivada respecto de x_2 y el denominador la derivada respecto de x_1, es decir:

$$\text{TMS}(x_1/x_2) = \frac{dx_2}{dx_1} = \frac{\frac{\partial u}{\partial x_1}}{\frac{\partial u}{\partial x_2}}$$

Interpretación: indica cuántas unidades de x_2 deben cederse para obtener una unidad adicional de x_1, manteniendo constante el nivel de utilidad

De manera inversa, $\text{TMS}(x_2/x_1)$ representa la tasa marginal de sustitución donde el numerador es la derivada respecto de x_1 y el denominador la derivada respecto de x_2, es decir:

$$\text{TMS}(x_2/x_1) = \frac{dx_1}{dx_2} = \frac{\frac{\partial u}{\partial x_2}}{\frac{\partial u}{\partial x_1}}$$

Interpretación: indica cuántas unidades de x_1 deben cederse para obtener una unidad adicional de x_2, manteniendo constante el nivel de utilidad

Interpretación intuitiva

Cuando aparece una expresión como

$$\frac{dx_2}{dx_1} = \frac{\frac{\partial u}{\partial x_1}}{\frac{\partial u}{\partial x_2}}$$

se interpreta como: "cuánto debe reducirse x_2 para aumentar en una unidad x_1, manteniendo constante la utilidad".

Una forma intuitiva de pensarlo es:

- El numerador es lo que aumenta
- El denominador es lo que se entrega o cede

9 Clasificación de bienes y elasticidad

Conceptos clave

- **Funciones de demanda:** Representan la relación entre la cantidad demandada de un bien y variables como su precio propio, el precio de bienes relacionados y el ingreso del consumidor
- **Derivadas parciales:** Permiten analizar el efecto marginal de un cambio en una variable (precio o ingreso) sobre la cantidad demandada, manteniendo constantes las demás
- **Elasticidad:** Es la medida de sensibilidad de la cantidad demandada ante cambios porcentuales en el precio o ingreso, ayudando a clasificar el bien según su comportamiento

Clasificación de bienes

1. Según el precio propio

- **Bienes típicos:** Al aumentar el precio del bien, la cantidad demandada disminuye. La mayoría de bienes se comporta así:

$$\frac{\partial Q}{\partial P} < 0$$

- **Bienes Giffen:** En situaciones excepcionales, el aumento en el precio del bien provoca un aumento en su demanda, debido al efecto ingreso que supera al efecto sustitución. No confundir con los bienes Veblen, que son bienes de lujo demandados por sus características de señalizar estatus económico

$$\frac{\partial Q}{\partial P} > 0$$

Intuición: En condiciones normales, la relación inversa (mayor precio, menor demanda) es esperada; los bienes Giffen representan casos raros donde, por limitaciones presupuestarias, el aumento de precio lleva a consumir más del bien

2. Según el precio del otro bien

- **Bienes sustitutos:** Si al aumentar el precio de un bien la demanda del otro aumenta, se considera que los bienes son sustitutos. Esto ocurre cuando el consumidor opta por el bien relativamente más económico. Por ejemplo, marcas rivales: Coca Cola y Pepsi

$$\frac{\partial Q_1}{\partial P_2} > 0$$

- **Bienes complementarios:** Si el aumento en el precio de un bien reduce la demanda del otro, se clasifican como complementarios, ya que se consumen en conjunto. Por ejemplo, café y azúcar

$$\frac{\partial Q_1}{\partial P_2} < 0$$

Intuición: La existencia de bienes sustitutos permite al consumidor cambiar de producto al encarecerse uno, mientras que los bienes complementarios se consumen conjuntamente para satisfacer una necesidad

3. Según el ingreso

- **Bienes normales:** La demanda aumenta al incrementar el ingreso del consumidor, la mayoría de bienes tienden a ser normales
$$\frac{\partial Q}{\partial I} > 0$$

- **Bienes inferiores:** La demanda disminuye cuando aumenta el ingreso, ya que los consumidores optan por bienes de mayor calidad. Por ejemplo, marcas de segunda línea
$$\frac{\partial Q}{\partial I} < 0$$

Intuición: La clasificación según el ingreso refleja la capacidad del consumidor para ajustar sus hábitos de consumo en función de su poder adquisitivo

Elasticidad de la demanda

La elasticidad cuantifica la sensibilidad de la cantidad demandada ante cambios en precios o ingresos

Elasticidad precio e ingreso

$$\text{Elasticidad precio} = \frac{\Delta Q/Q}{\Delta P/P} = \frac{P}{Q}\frac{\partial Q}{\partial P}$$

- **Interpretación (en términos absolutos):**
  - Si
  $$\left|\frac{P}{Q}\frac{\partial Q}{\partial P}\right| > 1$$
  la demanda es **elástica** (sensible a cambios en el precio)
  - Si
  $$\left|\frac{P}{Q}\frac{\partial Q}{\partial P}\right| < 1$$
  la demanda es **inelástica** (poco sensible)
  - Si
  $$\left|\frac{P}{Q}\frac{\partial Q}{\partial P}\right| = 1$$
  la elasticidad es **unitaria** (la demanda se mueve exactamente en la misma proporción que el precio)
  - Si
  $$\frac{\partial Q}{\partial P} = 0 \quad \text{(lo que implica que } \left|\frac{P}{Q}\frac{\partial Q}{\partial P}\right| = 0\text{)}$$
  la demanda es **perfectamente inelástica** (la cantidad demandada permanece constante sin importar cambios en el precio)

- Aunque se presenta el concepto como **elasticidad precio**, esta noción se extiende a la **elasticidad ingreso** y a cualquier otra función que admita derivadas parciales. Por ejemplo, la elasticidad ingreso se define como:
$$\text{Elasticidad ingreso} = \frac{\Delta Q/Q}{\Delta I/I} = \frac{I}{Q}\frac{\partial Q}{\partial I}$$
donde I representa el ingreso

Bienes de lujo vs. bienes esenciales

La clasificación de bienes en términos de lujo o esencial se basa en la **elasticidad ingreso**, la cual mide la sensibilidad de la cantidad demandada ante cambios en el ingreso del consumidor. Es importante resaltar que esta clasificación se aplica únicamente a bienes **normales**

Bienes esenciales (necesidades básicas)

Para los bienes esenciales, la elasticidad ingreso se encuentra en el rango:

$$0 < E_I < 1$$

donde

$$E_I = \frac{I}{Q}\frac{\partial Q}{\partial I}$$

Esto significa que, ante un aumento porcentual en el ingreso, la cantidad demandada del bien aumenta en una proporción menor. Dichos bienes satisfacen necesidades básicas y su consumo tiende a estabilizarse incluso cuando el ingreso crece

Bienes de lujo

En cambio, los bienes de lujo se caracterizan por tener:

$$E_I > 1$$

Esto implica que un incremento porcentual en el ingreso genera un aumento porcentual mayor en la demanda del bien. Estos bienes son adquiridos en mayor medida cuando los consumidores disponen de mayores recursos, reflejando un comportamiento de consumo más discrecional

Ejemplos:

- **Bienes esenciales:** Alimentos básicos (por ejemplo, pan y arroz), medicamentos genéricos, vivienda
- **Bienes de lujo:** Ropa de diseñador, automóviles de alta gama, joyería fina

Ejemplo

Supongamos que la función de demanda de un bien se expresa como:

$$Q(P, I) = 200 + 0.3I - 4P$$

donde P es el precio del bien e I es el ingreso del consumidor

Cálculo de las derivadas parciales:

$$\frac{\partial Q}{\partial P} = -4, \quad \frac{\partial Q}{\partial I} = 0.3$$

El signo negativo en $\frac{\partial Q}{\partial P}$ indica que, al aumentar el precio, la cantidad demandada disminuye (bien típico). El signo positivo en $\frac{\partial Q}{\partial I}$ muestra que, al aumentar el ingreso, la demanda crece, lo que caracteriza al bien como normal

Evaluación en un punto específico:

Sea $P = 15$ e $I = 500$. Entonces:

$$Q(15, 500) = 200 + 0.3 \times 500 - 4 \times 15 = 200 + 150 - 60 = 290$$

Cálculo de la elasticidad precio:
La elasticidad precio se define como:

$$E_P = \frac{P}{Q}\frac{\partial Q}{\partial P}$$

Sustituyendo los valores:

$$E_P = \frac{15}{290} \times (-4) \approx -0.207$$

En valor absoluto, $|E_P| \approx 0.207$, lo que indica que la demanda es **inelástica** (poco sensible a cambios en el precio)

Cálculo de la elasticidad ingreso:

$$E_I = \frac{I}{Q}\frac{\partial Q}{\partial I}$$

Sustituyendo los valores:

$$E_I = \frac{500}{290} \times 0.3 \approx 0.517$$

Esto significa que, ante un aumento del 1% en el ingreso, la cantidad demandada incrementa aproximadamente en un 0.517%, también es inelástica respecto al ingreso

Interpretación respecto a bienes de lujo vs. esenciales:
Dado que $0 < E_I < 1$, el bien se clasifica como un **bien esencial** (o necesidad básica), ya que la respuesta de la demanda a cambios en el ingreso es relativamente baja

Nota sobre bienes Giffen

Como vimos anteriormente, los bienes Giffen son aquellos bienes para los cuales, cuando el precio aumenta, la demanda también aumenta

$$\frac{\partial Q}{\partial P} > 0$$

Los bienes Giffen aparecen en situaciones muy particulares. Se trata de bienes inferiores que suelen ocupar una parte importante del presupuesto de consumidores con ingresos bajos. Cuando el precio de ese bien básico aumenta, el consumidor pierde poder adquisitivo y, en algunos casos extremos, termina consumiendo aún más de ese mismo bien porque no puede reemplazarlo fácilmente por otros.

Un ejemplo clásico que suele utilizarse para ilustrar este fenómeno es el caso de la papa en Irlanda. La idea general es la siguiente: para muchos hogares pobres, la papa constituía una parte muy importante de la dieta porque era un alimento relativamente accesible y que aportaba una gran cantidad de calorías. Si el precio de ese bien básico aumentaba, esos hogares sufrían una caída fuerte de su poder adquisitivo real. En ese contexto, en lugar de poder reemplazar la papa por alimentos mejores o más variados, se veían obligados a reducir todavía más el consumo de otros bienes y a destinar una proporción aún mayor de su presupuesto a la compra de papas. Esto se debe a que los otros alimentos disponibles resultaban relativamente más caros en relación con las calorías que aportaban. En otras palabras, el aumento del precio no generaba una sustitución hacia otros bienes, sino una mayor dependencia del bien básico encarecido

Este ejemplo debe interpretarse con cuidado. No se trata de que el consumidor desee más el bien porque ahora sea más caro, sino de que, al empeorar su restricción presupuestaria, queda prácticamente forzado a concentrar más su consumo en ese bien de subsistencia. Por eso, el caso de los bienes Giffen requiere condiciones muy especiales: **el bien debe ser inferior, debe representar una fracción importante del gasto del consumidor y, además, deben existir pocas alternativas de reemplazo cercanas**

Por esta razón, los bienes Giffen son **casos muy limitados y poco frecuentes en la práctica**. Su importancia es sobre todo teórica, porque muestran que la relación entre precio y cantidad demandada no siempre tiene que ser negativa

No confundir con los bienes Veblen: un bien Giffen no es lo mismo que un bien Veblen. En ambos casos puede ocurrir que la demanda aumente cuando sube el precio, pero la razón económica es completamente distinta. En un **bien Giffen**, el aumento de la demanda se explica por una situación de restricción presupuestaria severa: el consumidor compra más del bien porque no puede desplazarse hacia alternativas mejores y necesita seguir cubriendo una necesidad básica. En cambio, en un **bien Veblen**, el aumento de la demanda se relaciona con el carácter de lujo, prestigio o señalización social del bien. Allí el precio alto vuelve al bien más atractivo precisamente porque comunica estatus, exclusividad o poder adquisitivo. De hecho, en un bien Veblen puede pensarse que el precio alto forma parte de la naturaleza misma del bien: si el precio dejara de ser el que es, el bien cambiaría también en su valor simbólico

10 Derivadas compuestas

En matemática aplicada a la economía es muy común que una variable dependa de otra *a través* de funciones intermedias. Por ejemplo, la cantidad demandada Q depende del precio P vía $Q = D(P)$, y el precio a su vez depende de un impuesto ad-valorem τ vía $P = P_0(1+\tau)$. Esta *composición* se modela como

$$y = g\big(h(x)\big)$$

donde g y h son funciones diferenciables. Una pregunta que puede surgir es ¿Cómo afecta el cambio en el impuesto a la demanda? La respuesta de esta pregunta se puede encontrar a través de la derivada de una función compuesta.

En una variable

Recordemos que si $y = f(x)$ y x cambia de a a $a + \Delta x$, definimos el incremento de y como

$$\Delta y \;=\; f(a+\Delta x) - f(a)$$

De acuerdo con la definición de derivada,

$$\lim_{\Delta x \to 0} \frac{\Delta y}{\Delta x} \;=\; f'(a)$$

Si denotamos por ε la diferencia entre el cociente incremental y la derivada, obtenemos

$$\lim_{\Delta x \to 0} \varepsilon = \lim_{\Delta x \to 0} \left(\frac{\Delta y}{\Delta x} - f'(a) \right) = f'(a) - f'(a) = 0$$

Pero

$$\varepsilon \;=\; \frac{\Delta y}{\Delta x} - f'(a) \quad \Longrightarrow \quad \Delta y \;=\; f'(a)\,\Delta x \;+\; \varepsilon\,\Delta x$$

Definimos $\varepsilon = 0$ cuando $\Delta x = 0$.

Así, para una función f diferenciable, podemos escribir

$$\Delta y \;=\; f'(a)\,\Delta x \;+\; \varepsilon\,\Delta x, \qquad \varepsilon \to 0 \text{ cuando } \Delta x \to 0 \tag{5}$$

y ε es función continua de Δx. Esta propiedad habilita la prueba de la regla de la cadena.

Prueba de la regla de la cadena

Supongamos $u = g(x)$ diferenciable en a y $y = f(u)$ diferenciable en $b = g(a)$. Si Δx es un incremento en x y $\Delta u, \Delta y$ los incrementos correspondientes en u e y, entonces, aplicando (5) a g en a,

$$\Delta u \;=\; g'(a)\,\Delta x \;+\; \varepsilon_1\,\Delta x \;=\; \big[g'(a) + \varepsilon_1\big]\Delta x, \qquad \varepsilon_1 \to 0 \text{ cuando } \Delta x \to 0 \tag{6}$$

De modo análogo, aplicando (5) a f en b,

$$\Delta y \;=\; f'(b)\,\Delta u \;+\; \varepsilon_2\,\Delta u \;=\; \big[f'(b) + \varepsilon_2\big]\Delta u \qquad \varepsilon_2 \to 0 \text{ cuando } \Delta u \to 0 \tag{7}$$

Sustituyendo Δu de (6) en (7), obtenemos

$$\Delta y \;=\; \big[f'(b) + \varepsilon_2\big]\big[g'(a) + \varepsilon_1\big]\Delta x, \qquad \text{por lo tanto} \qquad \frac{\Delta y}{\Delta x} \;=\; \big[f'(b) + \varepsilon_2\big]\big[g'(a) + \varepsilon_1\big]$$

Cuando $\Delta x \to 0$, la ecuación (6) muestra que $\Delta u \to 0$; así, $\varepsilon_1 \to 0$ y $\varepsilon_2 \to 0$. Luego

$$\frac{dy}{dx} = \lim_{\Delta x \to 0} \frac{\Delta y}{\Delta x} = \lim_{\Delta x \to 0} \big[f'(b) + \varepsilon_2\big]\big[g'(a) + \varepsilon_1\big] = f'(b)\,g'(a) = f'\big(g(a)\big)\,g'(a)$$

Ejemplo

Función: $y(x) = (\,1 + 2x\,)^5$.

Identificación de la composición:

$$g(u) = u^5, \qquad h(x) = 1 + 2x, \qquad y(x) = g\big(h(x)\big)$$

Derivadas de cada capa:

$$g'(u) = 5u^4, \qquad h'(x) = 2$$

Aplicación de la regla de la cadena:

$$y'(x) = g'\big(h(x)\big) \cdot h'(x) = 5\big(1 + 2x\big)^4 \cdot 2 = \; 10\big(1 + 2x\big)^4$$

Regla de la cadena (caso multivariable)

Un cambio Δt produce cambios $\Delta x = g(t_0 + \Delta t) - g(t_0)$ y $\Delta y = h(t_0 + \Delta t) - h(t_0)$. Por diferenciabilidad de f en (x_0, y_0),

$$\Delta z = f(x_0 + \Delta x,\, y_0 + \Delta y) - f(x_0, y_0) = \frac{\partial f}{\partial x}(x_0, y_0)\,\Delta x + \frac{\partial f}{\partial y}(x_0, y_0)\,\Delta y + \varepsilon_1(\Delta x, \Delta y)\,\Delta x + \varepsilon_2(\Delta x, \Delta y)\,\Delta y,$$

donde $\varepsilon_1(\Delta x, \Delta y) \to 0$ y $\varepsilon_2(\Delta x, \Delta y) \to 0$ cuando $(\Delta x, \Delta y) \to (0, 0)$ (si $(\Delta x, \Delta y) = (0, 0)$, definimos $\varepsilon_1 = \varepsilon_2 = 0$).

Dividiendo por Δt,

$$\frac{\Delta z}{\Delta t} = \frac{\partial f}{\partial x}(x_0, y_0)\,\frac{\Delta x}{\Delta t} + \frac{\partial f}{\partial y}(x_0, y_0)\,\frac{\Delta y}{\Delta t} + \varepsilon_1(\Delta x, \Delta y)\,\frac{\Delta x}{\Delta t} + \varepsilon_2(\Delta x, \Delta y)\,\frac{\Delta y}{\Delta t}.$$

Como g, h son derivables en t_0, se tiene $\Delta x/\Delta t \to g'(t_0)$ y $\Delta y/\Delta t \to h'(t_0)$; además $\Delta t \to 0 \Rightarrow (\Delta x, \Delta y) \to (0, 0)$, luego $\varepsilon_1, \varepsilon_2 \to 0$. Por lo tanto,

$$\begin{aligned}
\left.\frac{dz}{dt}\right|_{t_0} &= \lim_{\Delta t \to 0} \frac{\Delta z}{\Delta t} \\
&= \frac{\partial f}{\partial x}(x_0, y_0) \lim_{\Delta t \to 0} \frac{\Delta x}{\Delta t} + \frac{\partial f}{\partial y}(x_0, y_0) \lim_{\Delta t \to 0} \frac{\Delta y}{\Delta t} + \underbrace{\lim_{\Delta t \to 0} \varepsilon_1(\Delta x, \Delta y)}_{0} \underbrace{\lim_{\Delta t \to 0} \frac{\Delta x}{\Delta t}}_{g'(t_0)} + \underbrace{\lim_{\Delta t \to 0} \varepsilon_2(\Delta x, \Delta y)}_{0} \underbrace{\lim_{\Delta t \to 0} \frac{\Delta y}{\Delta t}}_{h'(t_0)} \\
&= \frac{\partial f}{\partial x}(x_0, y_0)\, g'(t_0) + \frac{\partial f}{\partial y}(x_0, y_0)\, h'(t_0).
\end{aligned}$$

Forma compacta. Usando $\partial z/\partial x = \partial f/\partial x$ y $\partial z/\partial y = \partial f/\partial y$, la regla queda

$$\frac{dz}{dt} = \frac{\partial z}{\partial x}\,\frac{dx}{dt} + \frac{\partial z}{\partial y}\,\frac{dy}{dt}$$

Un ejemplo más complejo

Supongamos funciones diferenciables

$$z = f(x, y), \qquad x = x(u, v), \qquad y = y(u, v)$$

Ahora podemos encontrar dos derivadas z'_u y z'_v, las cuales se calculan con la misma regla que antes

$$z_u \;=\; f_x\, x_u + f_y\, y_u, \qquad z_v \;=\; f_x\, x_v + f_y\, y_v$$

Cuando hay más dependencias de variables

En muchos problemas hay más dependencias entre variables. El esquema general es:

$$z = g(u_1, \dots, u_m), \qquad u_i = u_i(x_1, \dots, x_n)$$

Aquí g es diferenciable en $\mathbb{R}^m$ y cada u_i es diferenciable en $\mathbb{R}^n$.

Para cada variable básica x_j $(j = 1, \dots, n)$:

$$\frac{\partial z}{\partial x_j} = \sum_{i=1}^{m} \frac{\partial g}{\partial u_i} \frac{\partial u_i}{\partial x_j}$$

Dependencias encadenadas

Cuando hay varias capas, se *suman* los productos de derivadas a lo largo de cada camino.

$$y = y(u, v), \qquad u = u(p, q), \qquad v = v(q, s), \qquad p = p(t),\ q = q(t),\ s = s(t)$$

Entonces

$$\frac{dy}{dt} = y_u(u_p\, p' + u_q\, q') + y_v(v_q\, q' + v_s\, s')$$

Ejemplos

$$z = f(x, y) = x^2 y, \qquad x = g(t) = t^2, \qquad y = h(t) = e^t$$

Derivadas

$$f_x = 2xy, \qquad f_y = x^2, \qquad \frac{dx}{dt} = 2t, \qquad \frac{dy}{dt} = e^t$$

$$\frac{dz}{dt} = \frac{\partial f}{\partial x}\frac{dx}{dt} + \frac{\partial f}{\partial y}\frac{dy}{dt} = (2xy)(2t) + (x^2)(e^t)$$

Sustituyendo $x = t^2$ y $y = e^t$:

$$\frac{dz}{dt} = 2(t^2)(e^t)(2t) + (t^2)^2 e^t = 4t^3 e^t + t^4 e^t = e^t\big(4t^3 + t^4\big)$$

Comprobación directa. Como $z(t) = x(t)^2 y(t) = (t^2)^2 e^t = t^4 e^t$

$$\frac{d}{dt}\big(t^4 e^t\big) = 4t^3 e^t + t^4 e^t = e^t(4t^3 + t^4)$$

que coincide con el resultado obtenido por la regla de la cadena.

Otro caso

$$z = f(x, y) = x\, y^2, \qquad x = x(v, w) = v + w, \qquad y = y(v, w) = v - w$$

Derivadas parciales y derivadas de las dependencias:

$$f_x = y^2, \qquad f_y = 2xy, \qquad x_v = 1,\ x_w = 1, \qquad y_v = 1,\ y_w = -1$$

Regla de la cadena:

$$z_v = f_x\, x_v + f_y\, y_v, \qquad z_w = f_x\, x_w + f_y\, y_w$$

Cálculo:

$$z_v = y^2 \cdot 1 + (2xy) \cdot 1 = y^2 + 2xy, \qquad z_w = y^2 \cdot 1 + (2xy) \cdot (-1) = y^2 - 2xy$$

Sustituyendo $x = v + w,\ y = v - w$:

$$z_v = (v-w)^2 + 2(v+w)(v-w) = (v-w)\big[(v-w) + 2(v+w)\big] = (v-w)(3v+w)$$

$$z_w = (v-w)^2 - 2(v+w)(v-w) = (v-w)\big[(v-w) - 2(v+w)\big] = (v-w)(-v-3w)$$

Comprobación directa. Como $z(v,w) = x\,y^2 = (v+w)(v-w)^2$

$$\frac{\partial z}{\partial v} = (v-w)^2 + 2(v+w)(v-w) = (v-w)(3v+w)$$

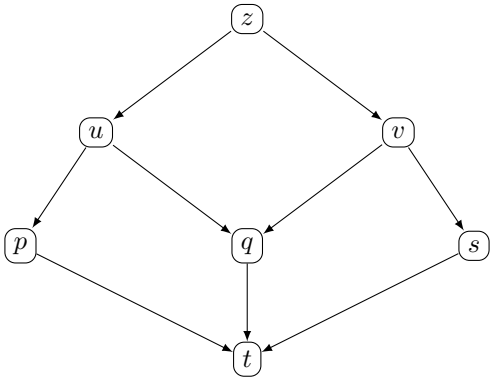
$$\frac{\partial z}{\partial w} = (v-w)^2 - 2(v+w)(v-w) = (v-w)(-v-3w)$$

coincidiendo con la regla de la cadena.

Otro ejemplo aún más complejo

$$z = z(u,v) = u^2 v, \qquad u = u(p,q) = p + q, \qquad v = v(q,s) = qs, \qquad p = 2t,\ q = t^2,\ s = e^t$$

En esta situación conviene graficar la relación entre variables para que quede claro:



Derivadas parciales y derivadas de las dependencias

$$z_u = 2uv, \qquad z_v = u^2$$

$$u_p = 1, \qquad u_q = 1, \qquad v_q = s, \qquad v_s = q$$

$$p' = 2, \qquad q' = 2t, \qquad s' = e^t$$

Regla de la cadena

$$\frac{dz}{dt} = z_u(u_p\,p' + u_q\,q') + z_v(v_q\,q' + v_s\,s')$$

Cálculo

$$\frac{dz}{dt} = (2uv)(1 \cdot 2 + 1 \cdot 2t) + (u^2)(s \cdot 2t + q \cdot e^t)$$

$$= 2uv(2+2t) + u^2(2ts + qe^t)$$

Sustituyendo $u = p + q = 2t + t^2$, $v = qs = t^2e^t$, $s = e^t$ y $q = t^2$

$$\frac{dz}{dt} = 2(2t+t^2)(t^2e^t)(2+2t) + (2t+t^2)^2(2te^t + t^2e^t)$$

$$= 2(2t+t^2)(t^2e^t)(2+2t) + (2t+t^2)^2e^t(2t+t^2)$$

$$= 4t^3e^t(2+t)(1+t) + t^3e^t(2+t)^3$$

$$= t^3e^t(2+t)\big(4(1+t) + (2+t)^2\big)$$

$$\frac{dz}{dt} = e^t t^3(2+t)(t^2+8t+8)$$

Comprobación directa

Como

$$z(t) = u(t)^2v(t) = (2t+t^2)^2(t^2e^t) = t^4(2+t)^2e^t$$

al derivar directamente

$$\frac{d}{dt}\Big(t^4(2+t)^2e^t\Big) = e^t t^3(2+t)(t^2+8t+8)$$

que coincide con el resultado obtenido por la regla de la cadena

11 Derivadas implícitas

Derivación implícita: deducción de la fórmula y requerimientos

En muchos casos en matemáticas y economía, las relaciones entre variables se presentan de forma implícita, es decir, mediante una ecuación de la forma

$$F(x, y) = 0$$

donde y se define como función de x de forma implícita (i.e., $y = f(x)$). Para poder aplicar la derivación implícita, es fundamental cumplir con ciertos requerimientos y condiciones.

Requerimientos para la aplicación de la derivación implícita

1. Verificación de la solución: se asume que el punto de interés (x_0, y_0) satisface la ecuación, es decir, $F(x_0, y_0) = 0$ (esto implica que $y_0 = f(x_0)$)
2. Diferenciabilidad de $F(x, y)$: la función F debe ser diferenciable en un entorno del punto de interés (x_0, y_0). Esto garantiza que existen las derivadas parciales F_x y F_y
3. No nulidad de la derivada parcial respecto a y: se requiere que $F_y(x_0, y_0) \neq 0$. Esta condición es esencial para aplicar el Teorema de la Función Implícita, el cual asegura que en un entorno de (x_0, y_0) se puede expresar y como una función diferenciable de x (i.e., $y = f(x)$)

Deducción de la fórmula de la derivada implícita

Consideremos la ecuación

$$F(x, y) = 0$$

donde suponemos que $y = f(x)$ y F es diferenciable en un entorno de (x_0, y_0). Como $F(x, f(x)) = 0$ para todos los x en dicho entorno, derivamos ambos lados de la igualdad con respecto a x, aplicando la regla de la cadena:

$$\frac{d}{dx}F(x, f(x)) = F_x(x, f(x)) + F_y(x, f(x)) \cdot f'(x) = 0$$

Aquí, F_x y F_y representan las derivadas parciales de F con respecto a x y y, respectivamente. Despejamos $f'(x)$ de la siguiente forma:

$$F_y(x, f(x)) \cdot f'(x) = -F_x(x, f(x))$$

$$\implies \quad f'(x) = -\frac{F_x(x, f(x))}{F_y(x, f(x))}$$

Esta es la fórmula general para la derivada de una función definida de forma implícita.

Ejemplo

Consideremos la ecuación de la circunferencia:

$$x^2 + y^2 = 25$$

Definimos la función $F(x, y)$ como:

$$F(x, y) = x^2 + y^2 - 25 = 0$$

Observamos que para cualquier punto (x, y) sobre la circunferencia se cumple $F(x, y) = 0$

Paso 1: calcular las derivadas parciales Se tiene:

$$F_x(x,y) = 2x \quad \text{y} \quad F_y(x,y) = 2y$$

Paso 2: aplicar la fórmula de la derivada implícita Utilizando la fórmula:

$$\frac{dy}{dx} = -\frac{F_x(x,y)}{F_y(x,y)} = -\frac{2x}{2y}$$

$$\implies \quad \frac{dy}{dx} = -\frac{x}{y}$$

Derivación implícita: función de dos variables independientes

En algunos problemas en matemáticas y economía, las relaciones entre variables se presentan de forma implícita mediante una ecuación de la forma

$$F(x,y,z) = 0$$

donde z se define implícitamente como función de x e y (i.e., $z = f(x,y)$). Para aplicar la derivación implícita en este contexto, es fundamental cumplir con ciertos requerimientos y condiciones.

Requerimientos para la aplicación de la derivación implícita

1. Verificación de la solución: se asume que el punto de interés $Q_0 = (x_0, y_0, z_0)$ satisface la ecuación, es decir, $F(x_0, y_0, z_0) = 0$ (lo que implica que $z_0 = f(x_0, y_0)$)
2. Diferenciabilidad de $F(x,y,z)$: la función F y sus derivadas parciales F_x, F_y y F_z deben existir y ser continuas en un entorno del punto Q_0
3. No nulidad de la derivada parcial respecto a z: se requiere que $F_z(x_0, y_0, z_0) \neq 0$. Esta condición es esencial para poder expresar z como una función diferenciable de x e y en el entorno de Q_0

Deducción de las fórmulas de las derivadas parciales

Consideremos la ecuación

$$F(x,y,z) = 0$$

donde suponemos que $z = f(x,y)$ y F es diferenciable en un entorno del punto $Q_0 = (x_0, y_0, z_0)$. Como $F(x, y, f(x,y)) = 0$ para todos los (x,y) en dicho entorno, derivamos ambos lados de la igualdad con respecto a x e y, aplicando la regla de la cadena.

Aplicación de la regla de la cadena

Para clarificar la deducción, se puede reescribir la función $F(x,y,z)$ definiendo $u = x$, $v = y$ y $z = f(x,y)$, de forma que

$$w = F(u,v,z) = 0$$

Aplicando la regla de la cadena respecto a x:

$$\frac{\partial w}{\partial x} = \frac{\partial F}{\partial u} \cdot \frac{\partial u}{\partial x} + \frac{\partial F}{\partial v} \cdot \frac{\partial v}{\partial x} + \frac{\partial F}{\partial z} \cdot \frac{\partial z}{\partial x} = 0$$

Como $\frac{\partial u}{\partial x} = 1$ y $\frac{\partial v}{\partial x} = 0$, se obtiene:

$$\frac{\partial F}{\partial x} + \frac{\partial F}{\partial z} \cdot \frac{\partial z}{\partial x} = 0 \quad \Longrightarrow \quad \frac{\partial z}{\partial x} = -\frac{F_x}{F_z}$$

El mismo procedimiento se aplica para obtener $\frac{\partial z}{\partial y}$

Estas fórmulas permiten calcular las derivadas parciales de $z = f(x, y)$ de forma implícita, siempre y cuando se cumplan los requerimientos indicados.

Ejemplo

Consideremos la función:

$$F(x, y, z) = x^2 y + \sin(z) - z\cos(y) + z^2 - 1 = 0$$

Observamos que para cualquier punto (x, y, z) que satisface esta ecuación se define implícitamente z como función de x e y (i.e., $z = f(x, y)$)

Paso 1: calcular las derivadas parciales Se tiene:

$$F_x(x, y, z) = 2xy$$

$$F_y(x, y, z) = x^2 + z\sin(y)$$

$$F_z(x, y, z) = \cos(z) - \cos(y) + 2z$$

Paso 2: aplicar la fórmula de la derivada implícita Las fórmulas para las derivadas parciales de $z = f(x, y)$ son:

$$\frac{\partial z}{\partial x} = -\frac{F_x(x, y, z)}{F_z(x, y, z)} \quad \text{y} \quad \frac{\partial z}{\partial y} = -\frac{F_y(x, y, z)}{F_z(x, y, z)}$$

Paso 3: evaluar en un punto Elijamos el punto $Q_0 = (1, 1, 0)$. Verificamos que:

$$1^2 \cdot 1 + \sin(0) - 0 \cdot \cos(1) + 0^2 - 1 = 1 - 1 = 0$$

por lo que Q_0 pertenece a la superficie definida por $F(x, y, z) = 0$

Evaluamos las derivadas parciales en Q_0:

$$F_x(1, 1, 0) = 2 \cdot 1 \cdot 1 = 2$$

$$F_y(1, 1, 0) = 1^2 + 0 \cdot \sin(1) = 1$$

$$F_z(1, 1, 0) = \cos(0) - \cos(1) + 2 \cdot 0 = 1 - \cos(1) \approx 0.46$$

Por lo tanto:

$$\frac{\partial z}{\partial x}\Big|_{(1,1,0)} = -\frac{2}{1 - \cos(1)} \approx -4.35$$

$$\frac{\partial z}{\partial y}\Big|_{(1,1,0)} = -\frac{1}{1 - \cos(1)} \approx -2.17$$

Derivadas implícitas sucesivas

Consideremos la función implícita:

$$F(x, y, z) = 2\sin(z) - xz + y^3 - 1 = 0$$

que define a $z = z(x, y)$. Se desea calcular las derivadas de segundo orden:

$$z_{xx}, \quad z_{xy}, \quad z_{yx}, \quad z_{yy}$$

evaluadas en el punto $Q_0 = (1, 1, 0)$

Paso 1: derivadas de primer orden

Dado que $F(x, y, z(x, y)) = 0$, diferenciamos implícitamente respecto de x:

$$F_x + F_z \cdot z_x = 0 \quad \Rightarrow \quad z_x = -\frac{F_x}{F_z}$$

Análogamente, derivando respecto de y:

$$F_y + F_z \cdot z_y = 0 \quad \Rightarrow \quad z_y = -\frac{F_y}{F_z}$$

Calculamos ahora las derivadas parciales necesarias:

$$F_x = \frac{\partial F}{\partial x} = -z, \quad F_y = \frac{\partial F}{\partial y} = 3y^2, \quad F_z = \frac{\partial F}{\partial z} = 2\cos(z) - x$$

Entonces:

$$z_x = \frac{z}{2\cos(z) - x}, \quad z_y = -\frac{3y^2}{2\cos(z) - x}$$

A partir de estas expresiones, aplicamos la regla del cociente para obtener las segundas derivadas sin evaluar numéricamente hasta el final.

Cálculo de z_{xx}

Derivamos $z_x = \frac{z}{2\cos(z)-x}$ respecto a x:

$$z_{xx} = \frac{d}{dx}\left(\frac{z}{2\cos(z) - x}\right) = \frac{\frac{dz}{dx}(2\cos(z) - x) - z\frac{d(2\cos(z)-x)}{dx}}{(2\cos(z) - x)^2}$$

$$\frac{d(2\cos(z) - x)}{dx} = -2\sin(z)\frac{dz}{dx} - 1 = -2\sin(z)\, z_x - 1$$

Sustituyendo:

$$z_{xx} = \frac{(z_x)(2\cos(z) - x) - z(-2\sin(z)z_x - 1)}{(2\cos(z) - x)^2}$$

$$z_{xx} = \frac{z_x(2\cos(z) - x) + z(2\sin(z)z_x + 1)}{(2\cos(z) - x)^2}$$

Evaluando en $Q_0 = (1, 1, 0)$ (con $z = 0, z_x = 0, \sin(0) = 0, \cos(0) = 1, x = 1$):

$$z_{xx}(1, 1) = \frac{(0)(2(1) - 1) + 0(2(0)(0) + 1)}{(2(1) - 1)^2} = \frac{0 + 0}{1^2} = 0$$

Cálculo de z_{xy}

Derivamos $z_x = \frac{z}{2\cos(z)-x}$ respecto a y:

$$z_{xy} = \frac{d}{dy}\left(\frac{z}{2\cos(z)-x}\right) = \frac{\frac{dz}{dy}(2\cos(z)-x) - z\frac{d(2\cos(z)-x)}{dy}}{(2\cos(z)-x)^2}$$

Calculamos las derivadas necesarias para el numerador:

$$\frac{d(2\cos(z)-x)}{dy} = -2\sin(z)\frac{dz}{dy} - 0 = -2\sin(z)z_y$$

Sustituyendo:

$$z_{xy} = \frac{(z_y)(2\cos(z)-x) - z(-2\sin(z)z_y)}{(2\cos(z)-x)^2}$$

$$z_{xy} = \frac{z_y(2\cos(z)-x) + 2z\sin(z)z_y}{(2\cos(z)-x)^2}$$

Evaluando en $Q_0 = (1,1,0)$ (con $z=0, z_y=-3, \sin(0)=0, \cos(0)=1, x=1$):

$$z_{xy}(1,1) = \frac{(-3)(2(1)-1) + 2(0)(0)(-3)}{(2(1)-1)^2} = \frac{(-3)(1)+0}{1^2} = -3$$

Por simetría de las derivadas cruzadas (asumiendo que se cumple el teorema de Schwarz):

$$z_{yx} = z_{xy}$$

Cálculo de z_{yy}

Derivamos $z_y = -\frac{3y^2}{2\cos(z)-x}$ respecto a y:

$$z_{yy} = \frac{d}{dy}\left(-\frac{3y^2}{2\cos(z)-x}\right) = -\frac{\frac{d(3y^2)}{dy}(2\cos(z)-x) - (3y^2)\frac{d(2\cos(z)-x)}{dy}}{(2\cos(z)-x)^2}$$

Calculamos las derivadas necesarias para el numerador:

$$\frac{d(3y^2)}{dy} = 6y$$

$$\frac{d(2\cos(z)-x)}{dy} = -2\sin(z)z_y \quad \text{(calculado antes)}$$

Sustituyendo:

$$z_{yy} = -\frac{(6y)(2\cos(z)-x) - (3y^2)(-2\sin(z)z_y)}{(2\cos(z)-x)^2}$$

$$z_{yy} = -\frac{6y(2\cos(z)-x) + 6y^2\sin(z)z_y}{(2\cos(z)-x)^2}$$

Evaluando en $Q_0 = (1,1,0)$ (con $y=1, z=0, z_y=-3, \sin(0)=0, \cos(0)=1, x=1$):

$$z_{yy}(1,1) = -\frac{6(1)(2(1)-1) + 6(1)^2(0)(-3)}{(2(1)-1)^2} = -\frac{6(1)+0}{1^2} = -6$$

12 Derivadas implícitas en sistemas de ecuaciones

Derivación Implícita en Sistemas de Ecuaciones con una variable independiente

Así como una superficie puede estar definida en forma implícita por una ecuación, una curva en el espacio puede estar definida implícitamente por un sistema de dos ecuaciones

$$\begin{cases} F(x,y,z)=0 \\ G(x,y,z)=0 \end{cases}$$

Por ejemplo, puede ocurrir que el sistema defina implícitamente a $y=f(x)$ y $z=g(x)$ es decir, que ambas dependan de una única variable independiente. En ese caso, se dice que el sistema define a dos de las tres variables como funciones de la restante

Requerimientos para Aplicar la Derivación Implícita

Para que sea posible derivar y y z respecto a x se deben cumplir las siguientes condiciones

1. **Verificación de la solución:** El punto de interés (x_0,y_0,z_0) debe satisfacer ambas ecuaciones es decir

$$F(x_0,y_0,z_0)=0 \quad \text{y} \quad G(x_0,y_0,z_0)=0$$

2. **Diferenciabilidad de F y G:** Ambas funciones deben ser diferenciables en un entorno del punto, con derivadas parciales continuas

3. **No anulación del Jacobiano respecto a y y z:** El determinante

$$J=\frac{\partial(F,G)}{\partial(y,z)}=\begin{vmatrix} F_y & F_z \\ G_y & G_z \end{vmatrix}\neq 0$$

debe ser distinto de cero para que el sistema tenga solución única para $\frac{dy}{dx}$ y $\frac{dz}{dx}$

Deducción de las Fórmulas de Derivadas

Partimos de las ecuaciones implícitas

$$F(x,y,z)=0, \quad G(x,y,z)=0$$

Por la definición de la derivada y la regla de la cadena, al derivar la igualdad respecto a x obtenemos

$$\frac{d}{dx}F\big(x,\,y(x),\,z(x)\big)=\frac{\partial F}{\partial x}(x,y,z)+\frac{\partial F}{\partial y}(x,y,z)\,\frac{dy}{dx}+\frac{\partial F}{\partial z}(x,y,z)\,\frac{dz}{dx}=0$$

Notamos que en este proceso se entiende que la derivada de x respecto a sí mismo es 1 Así, se llega directamente a

$$F_x(x,y,z)+F_y(x,y,z)\,\frac{dy}{dx}+F_z(x,y,z)\,\frac{dz}{dx}=0$$

De manera similar, si además se tiene otra función $G(x,y,z)=0$ (con y y z también funciones de x) aplicamos la regla de la cadena para obtener

$$G_x(x,y,z)+G_y(x,y,z)\,\frac{dy}{dx}+G_z(x,y,z)\,\frac{dz}{dx}=0$$

Por lo tanto tenemos el siguiente sistema

$$\begin{cases} F_x + F_y \frac{dy}{dx} + F_z \frac{dz}{dx} = 0 \\ G_x + G_y \frac{dy}{dx} + G_z \frac{dz}{dx} = 0 \end{cases}$$

$$\begin{cases} F_y \frac{dy}{dx} + F_z \frac{dz}{dx} = -F_x \\ G_y \frac{dy}{dx} + G_z \frac{dz}{dx} = -G_x \end{cases}$$

Escribimos el sistema en forma matricial

$$\begin{pmatrix} F_y & F_z \\ G_y & G_z \end{pmatrix} \begin{pmatrix} \frac{dy}{dx} \\ \frac{dz}{dx} \end{pmatrix} = - \begin{pmatrix} F_x \\ G_x \end{pmatrix}$$

Resolución con Regla de Cramer

Este sistema lineal en las incógnitas $\frac{dy}{dx}$ y $\frac{dz}{dx}$ se resuelve usando determinantes

$$\frac{dy}{dx} = \frac{\begin{vmatrix} -F_x & F_z \\ -G_x & G_z \end{vmatrix}}{J} \quad \text{y} \quad \frac{dz}{dx} = \frac{\begin{vmatrix} F_y & -F_x \\ G_y & -G_x \end{vmatrix}}{J}$$

También puede escribirse de forma compacta como cocientes de derivadas parciales mixtas

$$\frac{dy}{dx} = -\frac{\partial(F,G)/\partial(x,z)}{\partial(F,G)/\partial(y,z)} \quad \text{y} \quad \frac{dz}{dx} = -\frac{\partial(F,G)/\partial(y,x)}{\partial(F,G)/\partial(y,z)}$$

Ejemplo

Consideremos el sistema de ecuaciones

$$\begin{cases} xy + z = 2 \\ x - y + z^2 = 0 \end{cases}$$

que define implícitamente a y y z como funciones de x (i.e., $y = y(x)$ y $z = z(x)$). Dado el punto $P_0 = (-4, 0, 2)$ Para aplicar la derivación implícita, definimos

$$F(x,y,z) = xy + z - 2 = 0 \qquad G(x,y,z) = x - y + z^2 = 0$$

Chequeamos que el punto $P_0 = (-4, 0, 2)$ pertenece al conjunto solución:

$$F(-4,0,2) = (-4)(0) + 2 - 2 = 0,$$

$$G(-4,0,2) = (-4) - 0 + 2^2 = -4 + 4 = 0.$$

Por lo tanto, P_0 satisface simultáneamente $F = 0$ y $G = 0$.

Paso 1: Calcular las derivadas parciales Para $F(x,y,z)$

$$F_x = y, \quad F_y = x, \quad F_z = 1$$

Para $G(x,y,z)$

$$G_x = 1, \quad G_y = -1, \quad G_z = 2z$$

Paso 2: Diferenciar implícitamente y escribir el sistema Aplicando la regla de la cadena, tenemos

$$F_x + F_y \frac{dy}{dx} + F_z \frac{dz}{dx} = 0 \quad \Longrightarrow \quad y + x \frac{dy}{dx} + \frac{dz}{dx} = 0$$

$$G_x + G_y \frac{dy}{dx} + G_z \frac{dz}{dx} = 0 \quad \Longrightarrow \quad 1 - \frac{dy}{dx} + 2z \frac{dz}{dx} = 0$$

Reorganizando, obtenemos

$$\begin{cases} x \frac{dy}{dx} + \frac{dz}{dx} = -y \\ -\frac{dy}{dx} + 2z \frac{dz}{dx} = -1 \end{cases}$$

Paso 3: Escribir el sistema en forma matricial El sistema se puede expresar de la siguiente manera

$$\begin{pmatrix} F_y & F_z \\ G_y & G_z \end{pmatrix} \begin{pmatrix} \frac{dy}{dx} \\ \frac{dz}{dx} \end{pmatrix} = - \begin{pmatrix} F_x \\ G_x \end{pmatrix}$$

es decir,

$$\begin{pmatrix} x & 1 \\ -1 & 2z \end{pmatrix} \begin{pmatrix} \frac{dy}{dx} \\ \frac{dz}{dx} \end{pmatrix} = - \begin{pmatrix} y \\ 1 \end{pmatrix}$$

Paso 4: Resolver el sistema con la Regla de Cramer El determinante del sistema (Jacobiano) es

$$J = \begin{vmatrix} x & 1 \\ -1 & 2z \end{vmatrix} = 2xz + 1$$

Luego, aplicando la regla de Cramer, se tiene

Para $\dfrac{dy}{dx}$

$$\frac{dy}{dx} = \frac{\begin{vmatrix} -y & 1 \\ -1 & 2z \end{vmatrix}}{J} = \frac{(-y)(2z) - (1)(-1)}{2xz + 1} = \frac{-2yz + 1}{2xz + 1}$$

Para $\dfrac{dz}{dx}$

$$\frac{dz}{dx} = \frac{\begin{vmatrix} x & -y \\ -1 & -1 \end{vmatrix}}{J} = \frac{x(-1) - (-y)(-1)}{2xz + 1} = \frac{-x - y}{2xz + 1}$$

Paso 5: Chequeo del Jacobiano y evaluación de las derivadas en P_0 El determinante relevante (Jacobiano respecto de (y, z)) es

$$J(x, y, z) = \begin{vmatrix} F_y & F_z \\ G_y & G_z \end{vmatrix} = \begin{vmatrix} x & 1 \\ -1 & 2z \end{vmatrix} = 2xz + 1.$$

Evaluando en $P_0 = (-4, 0, 2)$:

$$J(P_0) = 2(-4)(2) + 1 = -16 + 1 = -15 \neq 0.$$

Luego, el sistema define localmente $y = y(x)$ y $z = z(x)$ alrededor de P_0, y podemos evaluar las derivadas.

Usando las expresiones obtenidas:

$$\frac{dy}{dx} = \frac{-2yz + 1}{2xz + 1}, \qquad \frac{dz}{dx} = \frac{-x - y}{2xz + 1},$$

y sustituyendo $x = -4$, $y = 0$, $z = 2$:

$$\left.\frac{dy}{dx}\right|_{P_0} = \frac{-2(0)(2)+1}{2(-4)(2)+1} = \frac{1}{-15} = -\frac{1}{15},$$

$$\left.\frac{dz}{dx}\right|_{P_0} = \frac{-(-4)-0}{2(-4)(2)+1} = \frac{4}{-15} = -\frac{4}{15}.$$

Derivación Implícita en Sistemas de Ecuaciones (2 Variables Independientes)

Planteamos la situación en la que dos ecuaciones

$$F(x,y,u,v) = 0 \quad \text{y} \quad G(x,y,u,v) = 0$$

definen implícitamente dos funciones de dos variables independientes

$$u = h(x,y) \quad \text{y} \quad v = m(x,y)$$

Deducción de las Fórmulas de las Derivadas Parciales

Partimos de las ecuaciones implícitas

$$F(x,y,u,v) = 0 \quad \text{y} \quad G(x,y,u,v) = 0$$

Para obtener las derivadas parciales de u y v respecto de x (manteniendo y constante) procedemos de la siguiente manera

(1) Derivadas parciales respecto a x:

Consideramos $u = u(x,y)$ y $v = v(x,y)$. Entonces, aplicando la regla de la cadena a $F(x,y,u,v) = 0$ se tiene

$$\frac{d}{dx}F\big(x,y,u(x,y),v(x,y)\big) = \frac{\partial F}{\partial x} + \frac{\partial F}{\partial u}\frac{\partial u}{\partial x} + \frac{\partial F}{\partial v}\frac{\partial v}{\partial x} = 0$$

Aquí se entiende que, al derivar con respecto a x, la variable y se considera constante

De manera similar, al derivar $G(x,y,u,v) = 0$ respecto a x se obtiene

$$\frac{d}{dx}G\big(x,y,u(x,y),v(x,y)\big) = \frac{\partial G}{\partial x} + \frac{\partial G}{\partial u}\frac{\partial u}{\partial x} + \frac{\partial G}{\partial v}\frac{\partial v}{\partial x} = 0$$

Podemos escribir el sistema resultante como

$$\begin{cases} F_x(x,y,u,v) + F_u(x,y,u,v)\,\frac{\partial u}{\partial x} + F_v(x,y,u,v)\,\frac{\partial v}{\partial x} = 0 \\ G_x(x,y,u,v) + G_u(x,y,u,v)\,\frac{\partial u}{\partial x} + G_v(x,y,u,v)\,\frac{\partial v}{\partial x} = 0 \end{cases}$$

Reorganizando para aislar las derivadas parciales de u y v se tiene

$$\begin{cases} F_u\,\frac{\partial u}{\partial x} + F_v\,\frac{\partial v}{\partial x} = -F_x \\ G_u\,\frac{\partial u}{\partial x} + G_v\,\frac{\partial v}{\partial x} = -G_x \end{cases}$$

Este sistema se puede escribir en forma matricial

$$\begin{pmatrix} F_u & F_v \\ G_u & G_v \end{pmatrix}\begin{pmatrix} \frac{\partial u}{\partial x} \\ \frac{\partial v}{\partial x} \end{pmatrix} = -\begin{pmatrix} F_x \\ G_x \end{pmatrix}$$

(2) Derivadas parciales respecto a y:

Ahora, derivamos con respecto a y (manteniendo x constante). Aplicando la regla de la cadena a $F(x, y, u, v) = 0$ se obtiene

$$\frac{d}{dy}F\big(x, y, u(x, y), v(x, y)\big) = \frac{\partial F}{\partial y} + \frac{\partial F}{\partial u}\frac{\partial u}{\partial y} + \frac{\partial F}{\partial v}\frac{\partial v}{\partial y} = 0$$

De forma análoga, para G se tiene

$$\frac{d}{dy}G\big(x, y, u(x, y), v(x, y)\big) = \frac{\partial G}{\partial y} + \frac{\partial G}{\partial u}\frac{\partial u}{\partial y} + \frac{\partial G}{\partial v}\frac{\partial v}{\partial y} = 0$$

El sistema resultante es

$$\begin{cases} F_y(x, y, u, v) + F_u(x, y, u, v)\,\frac{\partial u}{\partial y} + F_v(x, y, u, v)\,\frac{\partial v}{\partial y} = 0 \\ G_y(x, y, u, v) + G_u(x, y, u, v)\,\frac{\partial u}{\partial y} + G_v(x, y, u, v)\,\frac{\partial v}{\partial y} = 0 \end{cases}$$

Reorganizando se tiene

$$\begin{cases} F_u\,\frac{\partial u}{\partial y} + F_v\,\frac{\partial v}{\partial y} = -F_y \\ G_u\,\frac{\partial u}{\partial y} + G_v\,\frac{\partial v}{\partial y} = -G_y \end{cases}$$

En forma matricial

$$\begin{pmatrix} F_u & F_v \\ G_u & G_v \end{pmatrix} \begin{pmatrix} \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial y} \end{pmatrix} = - \begin{pmatrix} F_y \\ G_y \end{pmatrix}$$

Resolución con Regla de Cramer:

Sea

$$J = \begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix}$$

Entonces, aplicando la regla de Cramer para el sistema respecto a x obtenemos

$$\frac{\partial u}{\partial x} = \frac{\begin{vmatrix} -F_x & F_v \\ -G_x & G_v \end{vmatrix}}{J} \quad \frac{\partial v}{\partial x} = \frac{\begin{vmatrix} F_u & -F_x \\ G_u & -G_x \end{vmatrix}}{J}$$

Y para el sistema respecto a y

$$\frac{\partial u}{\partial y} = \frac{\begin{vmatrix} -F_y & F_v \\ -G_y & G_v \end{vmatrix}}{J} \quad \frac{\partial v}{\partial y} = \frac{\begin{vmatrix} F_u & -F_y \\ G_u & -G_y \end{vmatrix}}{J}$$

De esta forma, hemos obtenido las cuatro derivadas parciales que describen cómo varían u y v respecto de x e y

$$\frac{\partial u}{\partial x}, \quad \frac{\partial v}{\partial x}, \quad \frac{\partial u}{\partial y}, \quad \frac{\partial v}{\partial y}$$

Ejemplo

Consideremos el siguiente sistema de ecuaciones

$$\begin{cases} F(x, y, u, v) = x\,u + y\,v - 2 = 0 \\ G(x, y, u, v) = u^2 - v + x\,y = 0 \end{cases}$$

el cual define implícitamente a u y v como funciones de x e y es decir, $u = u(x, y)$ y $v = v(x, y)$. Y el punto:

$$P_0 = (1, 0, 2, 4).$$

Chequeamos:

(i) Chequeo de $F = 0$:

$$F(x, y, u, v) = xu + yv - 2$$
$$F(P_0) = 1 \cdot 2 + 0 \cdot 4 - 2 = 2 - 2 = 0.$$

(ii) Chequeo de $G = 0$:

$$G(x, y, u, v) = u^2 - v + xy$$
$$G(P_0) = 2^2 - 4 + 1 \cdot 0 = 4 - 4 + 0 = 0.$$

Por lo tanto, P_0 pertenece al conjunto solución.

Paso 1: Cálculo de las Derivadas Parciales de F y G

Para la función

$$F(x, y, u, v) = x\,u + y\,v - 2$$

se tiene

$$F_x = u, \quad F_y = v, \quad F_u = x, \quad F_v = y$$

Para la función

$$G(x, y, u, v) = u^2 - v + x\,y$$

se obtiene

$$G_x = y, \quad G_y = x, \quad G_u = 2u, \quad G_v = -1$$

Paso 2: Derivadas Parciales respecto a x

Dado que $u = u(x, y)$ y $v = v(x, y)$ aplicamos la regla de la cadena a cada ecuación (manteniendo y constante)

Para $F(x, y, u, v) = 0$

$$F_x + F_u\,u_x + F_v\,v_x = 0 \quad \Longrightarrow \quad u + x\,u_x + y\,v_x = 0$$

Para $G(x, y, u, v) = 0$

$$G_x + G_u\,u_x + G_v\,v_x = 0 \quad \Longrightarrow \quad y + 2u\,u_x - v_x = 0$$

Escribimos el sistema en forma matricial

$$\begin{pmatrix} F_u & F_v \\ G_u & G_v \end{pmatrix} \begin{pmatrix} u_x \\ v_x \end{pmatrix} = - \begin{pmatrix} F_x \\ G_x \end{pmatrix}$$

es decir,

$$\begin{pmatrix} x & y \\ 2u & -1 \end{pmatrix} \begin{pmatrix} u_x \\ v_x \end{pmatrix} = - \begin{pmatrix} u \\ y \end{pmatrix}$$

Definimos el Jacobiano del sistema (en las variables dependientes u y v)

$$J = \begin{vmatrix} x & y \\ 2u & -1 \end{vmatrix} = x(-1) - (y)(2u) = -x - 2u\,y$$

Aplicando la regla de Cramer
Para u_x

$$\frac{\partial u}{\partial x} = \frac{\begin{vmatrix} -F_x & F_v \\ -G_x & G_v \end{vmatrix}}{J} = \frac{\begin{vmatrix} -u & y \\ -y & -1 \end{vmatrix}}{-x - 2u\,y}$$

Calculamos el determinante

$$(-u)(-1) - y(-y) = u + y^2$$

Por lo tanto,

$$u_x = \frac{u + y^2}{-x - 2u\,y}$$

Para v_x

$$\frac{\partial v}{\partial x} = \frac{\begin{vmatrix} F_u & -F_x \\ G_u & -G_x \end{vmatrix}}{J} = \frac{\begin{vmatrix} x & -u \\ 2u & -y \end{vmatrix}}{-x - 2u\,y}$$

Calculamos el determinante

$$x(-y) - (-u)(2u) = -xy + 2u^2$$

Por lo tanto,

$$v_x = \frac{-xy + 2u^2}{-x - 2u\,y}$$

Paso 3: Derivadas Parciales respecto a y

Ahora, diferenciamos con respecto a y (manteniendo x constante)
Para $F(x, y, u, v) = 0$

$$F_y + F_u\,u_y + F_v\,v_y = 0 \quad \Longrightarrow \quad v + x\,u_y + y\,v_y = 0$$

Para $G(x, y, u, v) = 0$

$$G_y + G_u\,u_y + G_v\,v_y = 0 \quad \Longrightarrow \quad x + 2u\,u_y - v_y = 0$$

El sistema en forma matricial es el mismo

$$\begin{pmatrix} x & y \\ 2u & -1 \end{pmatrix} \begin{pmatrix} u_y \\ v_y \end{pmatrix} = - \begin{pmatrix} v \\ x \end{pmatrix}$$

Aplicando de nuevo la regla de Cramer
Para u_y

$$\frac{\partial u}{\partial y} = \frac{\begin{vmatrix} -F_y & F_v \\ -G_y & G_v \end{vmatrix}}{J} = \frac{\begin{vmatrix} -v & y \\ -x & -1 \end{vmatrix}}{-x - 2u\,y}$$

Determinante

$$(-v)(-1) - y(-x) = v + xy$$

Por lo tanto,

$$u_y = \frac{v + xy}{-x - 2u\,y}$$

Para v_y

$$\frac{\partial v}{\partial y} = \frac{\begin{vmatrix} F_u & -F_y \\ G_u & -G_y \end{vmatrix}}{J} = \frac{\begin{vmatrix} x & -v \\ 2u & -x \end{vmatrix}}{-x - 2u\,y}$$

Determinante

$$x(-x) - (-v)(2u) = -x^2 + 2u\,v$$

Por lo tanto,

$$v_y = \frac{-x^2 + 2u\,v}{-x - 2u\,y}$$

Paso final: Chequeo del Jacobiano y evaluación de derivadas en P_0

El Jacobiano en las variables dependientes (u, v) es

$$J(x, y, u, v) = \begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix} = \begin{vmatrix} x & y \\ 2u & -1 \end{vmatrix} = -x - 2uy.$$

En $P_0 = (1, 0, 2, 4)$:

$$J(P_0) = -(1) - 2(2)(0) = -1 \neq 0.$$

Luego, $u = u(x, y)$ y $v = v(x, y)$ están bien definidas localmente alrededor de P_0, y podemos evaluar las derivadas.

Usamos las expresiones obtenidas:

$$u_x = \frac{u + y^2}{-x - 2u\,y}, \qquad v_x = \frac{-xy + 2u^2}{-x - 2u\,y},$$

$$u_y = \frac{v + xy}{-x - 2u\,y}, \qquad v_y = \frac{-x^2 + 2u\,v}{-x - 2u\,y}.$$

Sustituyendo $x = 1$, $y = 0$, $u = 2$, $v = 4$:

$$u_x|_{P_0} = \frac{2 + 0}{-1} = -2, \qquad v_x|_{P_0} = \frac{0 + 2 \cdot 4}{-1} = -8,$$

$$u_y|_{P_0} = \frac{4 + 0}{-1} = -4, \qquad v_y|_{P_0} = \frac{-1 + 2 \cdot 2 \cdot 4}{-1} = \frac{15}{-1} = -15.$$

13 IS-LM

El modelo IS–LM determina simultáneamente el ingreso real Y y la tasa de interés r en el corto plazo, mediante el equilibrio en dos mercados: el de bienes y servicios (curva IS) y el monetario (curva LM). Además, incorpora la relación entre ingreso y recaudación fiscal.

$$\begin{cases} Y = C\big(Y_d\big) + I(r) + g \\ M_p = L\big(Y, r\big) \\ Y_d = Y - T\big(Y, \theta\big) \end{cases}$$

1. Mercado de bienes y servicios (IS)

$$Y = C\big(Y_d\big) + I(r) + g$$

- Y: producción (o ingreso) agregado.
- $C(Y_d)$: consumo de los hogares, función creciente de ingreso disponible Y_d.
- $I(r)$: inversión de las empresas, función decreciente de la tasa r.
- g: gasto público, exógeno.

La curva IS ("Investment–Saving") es el conjunto de (Y, r) que satisfacen esta identidad.

2. Mercado monetario (LM)

$$M_p = L\big(Y, r\big)$$

- M_p: oferta real de dinero (stock), fijada por la autoridad monetaria.
- $L(Y, r)$: demanda de dinero, creciente en Y ($\partial L/\partial Y > 0$) y decreciente en r ($\partial L/\partial r < 0$).

La curva LM ("Liquidity preference–Money supply") es el conjunto de puntos de (Y, r) que igualan oferta y demanda de dinero.

3. Ingreso disponible

$$Y_d = Y - T\big(Y, \theta\big)$$

donde $T(Y, \theta)$ es la recaudación fiscal, función creciente de Y. El ingreso disponible Y_d es el que efectivamente determina el consumo.

Resolución del modelo IS–LM por derivación implícita

Partimos del modelo:

$$\begin{cases} Y = C(Y_d) + I(r) + g \\ M_p = L(Y, r) \\ Y_d = Y - T(Y, \theta) \end{cases}$$

Variables endógenas	
Y	Ingreso (producción) de equilibrio
r	Tasa de interés de equilibrio

Variables exógenas	
g	Gasto público
M_p	Oferta real de dinero (stock monetario)
θ	Parámetro(s) fiscales en $T(Y,\theta)$

Hipótesis de comportamiento:

$$0 < C'\big(Y - T(Y,\theta)\big) < 1, \quad 0 < T_Y(Y,\theta) < 1, \quad I'(r) < 0, \quad L_Y(Y,r) > 0, \quad L_r(Y,r) < 0, \quad T_\theta(Y,\theta) > 0$$

Sustituyendo Y_d en la primera ecuación obtenemos dos ecuaciones en las variables endógenas Y y r:

$$\begin{cases} F(Y,r;g,\theta) \;=\; Y - C\big(Y - T(Y,\theta)\big) - I(r) - g \;=\; 0 \\ G(Y,r;M_p) \;=\; L(Y,r) - M_p \;=\; 0 \end{cases}$$

El objetivo es encontrar $\dfrac{\partial Y}{\partial g}$ y $\dfrac{\partial r}{\partial g}$. Es decir, el efecto que tiene un aumento del gasto público en el producto y en la tasa de interés.

Paso 1: Derivadas parciales

Derivamos ambas ecuaciones respecto a g, recordemos que Y depende de g, también r depende de g por lo tanto debemos utilizar regla de la cadena:

$$F'g = \frac{\partial F}{\partial Y}\frac{\partial Y}{\partial g} + \frac{\partial F}{\partial r}\frac{\partial r}{\partial g} + \frac{\partial F}{\partial g}\frac{\partial g}{\partial g} = 0$$

$$G'g = \frac{\partial G}{\partial Y}\frac{\partial Y}{\partial g} + \frac{\partial G}{\partial r}\frac{\partial r}{\partial g} + \frac{\partial G}{\partial g}\frac{\partial g}{\partial g} = 0$$

Derivamos ambas ecuaciones respecto a g, manteniendo M_p y θ constantes:

$$\frac{\partial}{\partial g}\Big[Y - C\big(Y - T(Y,\theta)\big) - I(r) - g\Big] = \Big(1 - C'\big(Y - T(Y,\theta)\big)\left[1 - T_Y(Y,\theta)\right]\Big)\frac{\partial Y}{\partial g} - I'(r)\frac{\partial r}{\partial g} - 1 = 0$$

$$\frac{\partial}{\partial g}\big[L(Y,r) - M_p\big] = L_Y(Y,r)\frac{\partial Y}{\partial g} + L_r(Y,r)\frac{\partial r}{\partial g} = 0$$

$$\begin{cases} \dfrac{\partial}{\partial g}\Big[Y - C\big(Y - T(Y,\theta)\big) - I(r) - g\Big] = \Big(1 - C'\big(Y - T(Y,\theta)\big)\left[1 - T_Y(Y,\theta)\right]\Big)\dfrac{\partial Y}{\partial g} - I'(r)\dfrac{\partial r}{\partial g} - 1 = 0 \\ \dfrac{\partial}{\partial g}\big[L(Y,r) - M_p\big] = L_Y(Y,r)\dfrac{\partial Y}{\partial g} + L_r(Y,r)\dfrac{\partial r}{\partial g} = 0 \end{cases}$$

Paso 2: Sistema matricial

De aquí obtenemos el sistema lineal

$$\begin{pmatrix} 1 - C'\big(Y - T(Y,\theta)\big)\left[1 - T_Y(Y,\theta)\right] & -I'(r) \\ L_Y(Y,r) & L_r(Y,r) \end{pmatrix}\begin{pmatrix} \dfrac{\partial Y}{\partial g} \\ \dfrac{\partial r}{\partial g} \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

Paso 3: Resolver con la Regla de Cramer

El determinante del sistema es

$$J \;=\; \left[1 - C'\big(Y - T(Y,\theta)\big)\,[1 - T_Y(Y,\theta)]\right]\, L_r(Y,r) \;-\; \left[-I'(r)\right]\, L_Y(Y,r)$$

Por Cramer,

$$\frac{\partial Y}{\partial g} = \frac{\begin{vmatrix} 1 & -I'(r) \\ 0 & L_r(Y,r) \end{vmatrix}}{J} = \frac{1 \cdot L_r(Y,r)}{J} = \frac{L_r(Y,r)}{J}$$

$$\frac{\partial r}{\partial g} = \frac{\begin{vmatrix} 1 - C'\big(Y - T(Y,\theta)\big)\,[1 - T_Y(Y,\theta)] & 1 \\ L_Y(Y,r) & 0 \end{vmatrix}}{J} = \frac{-\,L_Y(Y,r)}{J}$$

Paso 4: Signos e interpretación

Dado que

$$0 < C'\big(Y - T(Y,\theta)\big) < 1 \quad 0 < T_Y(Y,\theta) < 1 \quad I'(r) < 0 \quad L_Y(Y,r) > 0 \quad L_r(Y,r) < 0$$

se cumple

$$1 - C'\big(Y - T(Y,\theta)\big)\,[1 - T_Y(Y,\theta)] > 0 \quad -\; I'(r) > 0$$

Por tanto el determinante

$$J = \underbrace{\Big[1 - \overbrace{C'\big(Y - T(Y,\theta)\big)}^{0<\cdot<1} \times \overbrace{\big(1 - T_Y(Y,\theta)\big)}^{0<\cdot<1}\Big]}_{>0} \times \underbrace{L_r(Y,r)}_{<0} - \underbrace{\big(-I'(r)\big)}_{>0} \times \underbrace{L_Y(Y,r)}_{>0} \;<\; 0$$

Como $L_r < 0,\ L_Y > 0$, el numerador de $\partial Y/\partial g$ es negativo y el de $\partial r/\partial g$ también es negativo:

$$\frac{\partial Y}{\partial g} = \frac{L_r}{J} > 0 \qquad \frac{\partial r}{\partial g} = \frac{-\,L_Y}{J} > 0$$

Cuando el gobierno aumenta su gasto g, se desencadenan dos efectos:

Más demanda ⇒ más producción (Y)

- *Gasto directo*: el gobierno inyecta recursos pagando obras, sueldos, compras de insumos, etc.
- *Cadena de efectos*: esos pagos se convierten en ingresos para empresas y trabajadores, que a su vez consumen parte de ese ingreso extra, generando más ventas e ingresos en otros sectores.
- *Multiplicador*: cada unidad de gasto público produce más de una unidad de aumento en el ingreso agregado, pues el dinero circula y se vuelve a gastar varias veces.

Mayor Y ⇒ mayor demanda de dinero ⇒ sube r

- *Demanda de dinero transaccional*: al crecer Y, hogares y empresas realizan más transacciones y necesitan más liquidez.
- *Curva LM*: $L(Y,r)$ crece con Y y cae con r. Con M_p fijo, un aumento de L empuja la tasa r al alza hasta reequilibrar oferta y demanda monetaria.
- *Crowding-out parcial*: al subir r, el crédito se encarece y la inversión privada se modera, atenuando algo el impulso inicial sobre Y, pero sin anularlo.

14 Homogeneidad

Definición de Homogeneidad

Una función $F : \mathbb{R}^n_+ \to \mathbb{R}$ se dice *homogénea de grado k* si, para todo $\lambda > 0$ y todo $\mathbf{x} = (x_1, \ldots, x_n) \in \mathbb{R}^n_+$, se cumple

$$F(\lambda x_1, \ldots, \lambda x_n) = \lambda^k F(x_1, \ldots, x_n).$$

Cuando $k = 0$, se dice que la función es *homogénea de grado cero*.

Ejemplos

1. **Homogeneidad de grado 1.** Sea
$$F(x, y) = 3x + 5y.$$
Entonces, para cualquier $\lambda > 0$,
$$F(\lambda x, \lambda y) = 3(\lambda x) + 5(\lambda y) = \lambda\,(3x + 5y) = \lambda^1 F(x, y).$$
Por tanto, F es homogénea de grado $k = 1$.

2. **Homogeneidad de grado 0 (relación de precios).** Sea
$$G(x, y) = \frac{x}{y}.$$
Para $\lambda > 0$,
$$G(\lambda x, \lambda y) = \frac{\lambda x}{\lambda y} = \frac{x}{y} = \lambda^0 G(x, y).$$
Así, G es homogénea de grado $k = 0$.

Propiedades de las Funciones Homogéneas

1. **Multiplicación de escala:** Si F es homogénea de grado k, entonces para todo $\lambda, \mu > 0$
$$F(\lambda\mu\,\mathbf{x}) = (\lambda\mu)^k F(\mathbf{x}) = \lambda^k F(\mu\,\mathbf{x}).$$

2. **Combinación lineal:** Si F y G son homogéneas de grado k, y $a, b \in \mathbb{R}$, entonces
$$H(\mathbf{x}) = a\,F(\mathbf{x}) + b\,G(\mathbf{x})$$
es homogénea de grado k.

3. **Producto:** Si F es homogénea de grado k y G de grado m, entonces
$$(F \cdot G)(\mathbf{x}) = F(\mathbf{x})\,G(\mathbf{x})$$
es homogénea de grado $k + m$.

4. **Cociente:** Si $G(\mathbf{x}) \neq 0$ y F, G son homogéneas de grado k y m respectivamente, entonces
$$\left(\frac{F}{G}\right)(\mathbf{x}) = \frac{F(\mathbf{x})}{G(\mathbf{x})}$$
es homogénea de grado $k - m$.

5. **Derivadas:** Si F es homogénea de grado k y diferenciable, entonces todas sus derivadas parciales de orden m son homogéneas de grado $k - m$.

Teorema de Euler para Funciones Homogéneas

Teorema (Euler). Sea $F : \mathbb{R}^n_+ \to \mathbb{R}$ una función diferenciable y homogénea de grado k. Entonces

$$\sum_{i=1}^{n} x_i \, \frac{\partial F}{\partial x_i}(x_1, \ldots, x_n) = k \, F(x_1, \ldots, x_n).$$

Demostración. Dado que F es homogénea de grado k, para todo $\lambda > 0$ se cumple

$$F(\lambda x_1, \lambda x_2, \ldots, \lambda x_n) = \lambda^k \, F(x_1, x_2, \ldots, x_n).$$

Definamos la función de una sola variable

$$\Phi(\lambda) \;=\; F(\lambda x_1, \lambda x_2, \ldots, \lambda x_n).$$

Por la homogeneidad, también

$$\Phi(\lambda) \;=\; \lambda^k \, F(x_1, \ldots, x_n).$$

Como F es diferenciable, Φ es diferenciable y podemos derivar ambas expresiones respecto a λ.

- Por la regla de la cadena,

$$\Phi'(\lambda) = \sum_{i=1}^{n} \frac{\partial F}{\partial x_i}(\lambda x_1, \ldots, \lambda x_n) \, \frac{d}{d\lambda}(\lambda x_i) = \sum_{i=1}^{n} \frac{\partial F}{\partial x_i}(\lambda x_1, \ldots, \lambda x_n) \, x_i.$$

- Por derivar $\lambda^k F(x_1, \ldots, x_n)$,

$$\Phi'(\lambda) = \frac{d}{d\lambda}\big(\lambda^k \, F(x_1, \ldots, x_n)\big) = k \, \lambda^{k-1} \, F(x_1, \ldots, x_n).$$

  Igualando ambas expresiones para $\Phi'(\lambda)$,

$$\sum_{i=1}^{n} x_i \, \frac{\partial F}{\partial x_i}(\lambda x_1, \ldots, \lambda x_n) = k \, \lambda^{k-1} \, F(x_1, \ldots, x_n).$$

Finalmente, evaluamos en $\lambda = 1$:

$$\sum_{i=1}^{n} x_i \, \frac{\partial F}{\partial x_i}(x_1, \ldots, x_n) = k \, F(x_1, \ldots, x_n),$$

como queríamos demostrar. ■

Ejemplo

Consideremos la función polinómica

$$F(x, y) \;=\; x^3 \;+\; 2\,x\,y^2.$$

1. **Verificación de homogeneidad.** Observamos que cada término es de grado 3:

$$(\lambda x)^3 = \lambda^3 x^3, \qquad 2\,(\lambda x)\,(\lambda y)^2 = 2\,\lambda^3\,x\,y^2.$$

   Por tanto,

$$F(\lambda x, \lambda y) = (\lambda x)^3 + 2\,(\lambda x)\,(\lambda y)^2 = \lambda^3\big(x^3 + 2\,x\,y^2\big) = \lambda^3\,F(x, y),$$

   y concluimos que F es homogénea de grado $k = 3$.

2. **Derivadas parciales.**

$$F_x(x,y) = \frac{\partial}{\partial x}\big(x^3 + 2\,x\,y^2\big) = 3x^2 + 2\,y^2,$$

$$F_y(x,y) = \frac{\partial}{\partial y}\big(x^3 + 2\,x\,y^2\big) = 4\,x\,y.$$

3. **Comprobación del Teorema de Euler.** El teorema de Euler establece que, si F es homogénea de grado 3, entonces

$$x\,F_x(x,y) \;+\; y\,F_y(x,y) = 3\,F(x,y).$$

Calculemos el lado izquierdo:

$$x\big(3x^2 + 2y^2\big) \;+\; y\big(4xy\big) = 3x^3 + 2x\,y^2 + 4x\,y^2 = 3x^3 + 6x\,y^2.$$

Y el lado derecho:

$$3\,F(x,y) = 3\big(x^3 + 2x\,y^2\big) = 3x^3 + 6x\,y^2.$$

Como coinciden,

$$x\,F_x + y\,F_y = 3\,F(x,y),$$

confirmamos que el teorema de Euler se cumple.

Interpretación Económica

En economía, la homogeneidad y el Teorema de Euler tienen aplicaciones directas en teoría de la producción y en demanda:

- **Funciones de producción con rendimientos a escala:** Si la función de producción $Y = F(K, L)$ (capital K, trabajo L) es homogénea de grado k:

$$F(\lambda K, \lambda L) = \lambda^k F(K, L),$$

entonces:

  - $k = 1$ implica *rendimientos constantes a escala*: duplicar todos los insumos duplica la producción.
  - $k > 1$ implica *rendimientos crecientes a escala*: duplicar insumos más que duplica la producción.
  - $k < 1$ implica *rendimientos decrecientes a escala*: duplicar insumos menos que duplica la producción.

- **Demanda homogénea de grado cero en precios e ingreso:** Una función de demanda $x_i(p_1, \ldots, p_n, M)$ (precios p_j, ingreso M) es homogénea de grado cero:

$$x_i(\lambda p_1, \ldots, \lambda p_n, \lambda M) = x_i(p_1, \ldots, p_n, M).$$

Esto significa que si todos los precios y el ingreso cambian en la misma proporción, las cantidades demandadas no varían: sólo importan los precios relativos y el poder de compra real.

- **Elasticidades parciales y grado de homogeneidad:** Sea $F(K, L)$ una función de producción diferenciable y homogénea de grado k. Definimos las elasticidades parciales de la producción con respecto a cada factor como

$$\varepsilon_K = \frac{\partial F}{\partial K}\,\frac{K}{F(K,L)}, \qquad \varepsilon_L = \frac{\partial F}{\partial L}\,\frac{L}{F(K,L)}.$$

Aplicando el Teorema de Euler:

$$K\,F_K(K,L) + L\,F_L(K,L) = k\,F(K,L),$$

y dividiendo ambos lados por $F(K, L)$, obtenemos

$$\varepsilon_K + \varepsilon_L = k.$$

Interpretación: **la suma de las elasticidades parciales de la producción respecto al capital y al trabajo coincide con el grado de homogeneidad de la función. Económicamente, esto significa que los rendimientos a escala coinciden con la suma de elasticidades parciales**

- Si $\varepsilon_K + \varepsilon_L = k = 1$, rendimientos constantes a escala.
- Si $\varepsilon_K + \varepsilon_L = k > 1$, rendimientos crecientes a escala.
- Si $\varepsilon_K + \varepsilon_L = k < 1$, rendimientos decrecientes a escala.

15 Autovalores y autovectores

Definición de autovalor y autovector

Sea $A \in \mathbb{R}^{n \times n}$. En todo el capítulo, los vectores de $\mathbb{R}^n$ se marcan con una flecha y son vectores columna; cuando los escribimos en una línea usamos la notación $\vec{x} = (x_1, \ldots, x_n)^T$. El vector nulo es $\vec{0}$.

Un escalar $\lambda \in \mathbb{R}$ es autovalor de A si existe un vector $\vec{v} \in \mathbb{R}^n \setminus \{\vec{0}\}$ tal que

$$A\,\vec{v} = \lambda\,\vec{v}$$

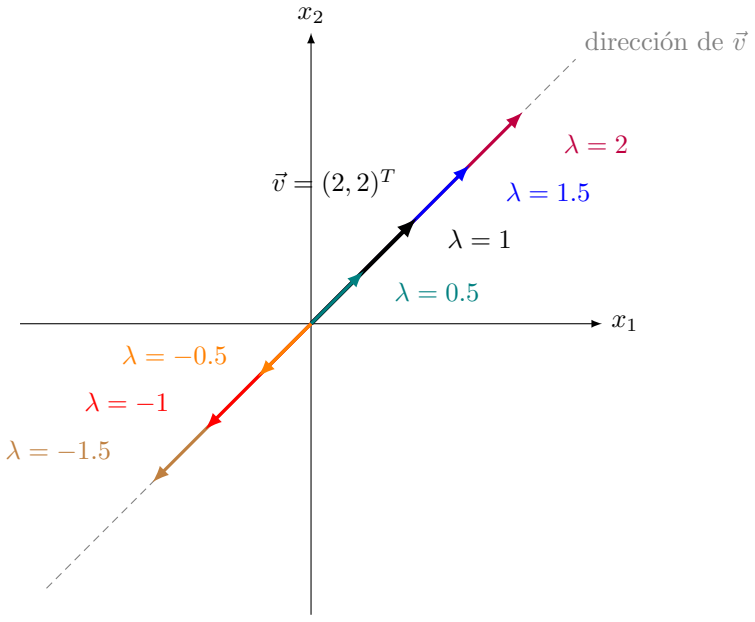
El vector $\vec{v}$ que satisface esta igualdad se llama autovector asociado al autovalor λ.

Una breve intuición de qué significa esto es la siguiente. Pensemos la matriz A como una transformación: así como una función toma un valor de entrada y lo cambia, la matriz A, al multiplicar por la izquierda a un vector $\vec{v}$ (es decir, al calcular $A\,\vec{v}$), puede girarlo, estirarlo, encogerlo, etc.

En este sentido, un autovector es un vector que, después de la transformación, queda sobre la misma recta por el origen: A no lo gira hacia otra dirección, solamente lo estira o lo encoge y, a veces, le invierte el sentido. El autovalor λ es el factor de escala de ese cambio:

- si $\lambda > 1$, el autovector se agranda, y si $0 < \lambda < 1$, se achica;
- si $\lambda = 1$, queda exactamente igual;
- si $\lambda < 0$, cambia de sentido (y además se agranda si $|\lambda| > 1$ o se achica si $|\lambda| < 1$);
- si $\lambda = 0$, es enviado al vector nulo, es decir, $A\,\vec{v} = \vec{0}$ (lo que no puede ser nulo es el autovector, no el autovalor).

En el siguiente gráfico se puede ver la naturaleza de un autovector: en este caso, un vector $\vec{v}$ con la dirección de $(1,1)^T$ (en el dibujo, $\vec{v} = (2,2)^T$, que corresponde a $\lambda = 1$). Al multiplicarlo por A, el resultado $A\,\vec{v} = \lambda\,\vec{v}$ queda siempre sobre la recta punteada: solamente puede agrandarse, achicarse o cambiar de sentido, según el valor de λ. Cada vector del gráfico muestra uno de esos resultados posibles (cada valor de λ corresponde a una matriz distinta, ya que para una matriz fija un autovector tiene un único autovalor).



Veamos ahora un ejemplo concreto. Sea

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

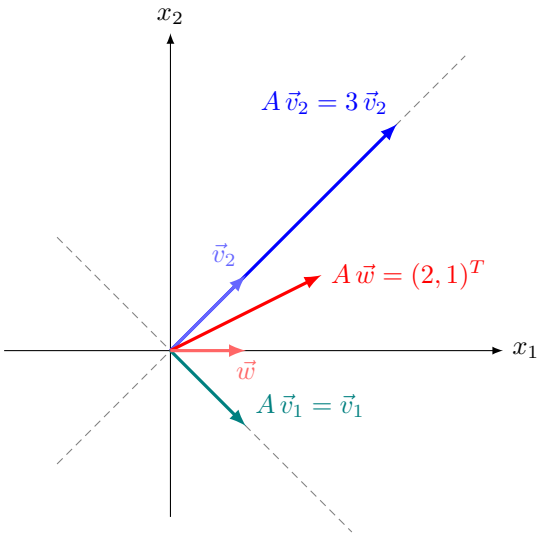
Al multiplicarla por tres vectores se obtiene

$$A \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix} = 3 \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$A \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 1 \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

$$A \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

Los dos primeros vectores son autovectores (con autovalores 3 y 1): después de multiplicar por A siguen sobre la misma recta. El tercero, en cambio, no es autovector: $(2,1)^T$ no es un múltiplo de $(1,0)^T$, así que A lo hizo cambiar de dirección. En el gráfico, las rectas punteadas son las direcciones de los autovectores. Los vectores $\vec{v}_2 = (1,1)^T$ y $\vec{w} = (1,0)^T$ se dibujan en un tono claro y sus imágenes por A, en el mismo color pero más oscuro; para $\vec{v}_1 = (1,-1)^T$ la imagen coincide con el propio vector.



Polinomio característico

Definición

Sea $A \in \mathbb{R}^{n\times n}$. El *polinomio característico*[3] de A se define como

$$\chi_A(\lambda) = \det(\lambda I - A)$$

El polinomio característico proviene de la siguiente deducción, dado:

$$A\,\vec{v} = \lambda\,\vec{v}, \quad \vec{v} \neq \vec{0}$$

[3]Se usa $\lambda I - A$ (y no $A - \lambda I$) para que χ_A sea un polinomio *mónico*, es decir, con coeficiente principal 1: $\chi_A(\lambda) = \lambda^n + c_{n-1}\lambda^{n-1} + \cdots + c_1\lambda + c_0$. Con $A - \lambda I$ el coeficiente principal sería $(-1)^n$. Para n par las dos definiciones dan el mismo polinomio, y para n impar difieren solamente en el signo, lo que no cambia las raíces.

Reordenando

$$(A - \lambda I)\vec{v} = \vec{0}$$

Este es un sistema homogéneo con solución no trivial $\vec{v} \neq \vec{0}$ *si y solo si* la matriz $A - \lambda I$ es **singular**. Una matriz cuadrada es singular $\Leftrightarrow$ su determinante es cero, entonces

$$\det(A - \lambda I) = 0$$

Como $\lambda I - A = -(A - \lambda I)$, se cumple $\det(\lambda I - A) = (-1)^n \det(A - \lambda I)$ (se cambia el signo de las n filas). Por lo tanto, $\det(\lambda I - A)$ y $\det(A - \lambda I)$ se anulan exactamente para los mismos valores de λ, y la condición anterior equivale a

$$\det(\lambda I - A) = 0$$

Los λ que anulan $\det(\lambda I - A)$ son exactamente los **autovalores** de A. Por eso se define el *polinomio característico*

$$\chi_A(\lambda) = \det(\lambda I - A)$$

y los autovalores son las raíces de χ_A.[4]

Ejemplo para matriz 2×2

Sea

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

Entonces

$$\lambda I - A = \begin{pmatrix} \lambda - a & -b \\ -c & \lambda - d \end{pmatrix}$$

y

$$\chi_A(\lambda) = \det \begin{pmatrix} \lambda - a & -b \\ -c & \lambda - d \end{pmatrix} = (\lambda - a)(\lambda - d) - bc = \lambda^2 - \underbrace{(a + d)}_{\mathrm{tr}(A)} \lambda + \underbrace{(ad - bc)}_{\det(A)}$$

donde $\mathrm{tr}(A) = a + d$ es la *traza* de A: la suma de los elementos de su diagonal principal. En general, para $A \in \mathbb{R}^{n \times n}$, $\mathrm{tr}(A) = \sum_{i=1}^{n} a_{ii}$.

Cálculo de autovalores y autovectores

Procedimiento

1. Formar la matriz $\lambda I - A$
2. Calcular $\chi_A(\lambda) = \det(\lambda I - A)$ y simplificarlo hasta obtener un polinomio en λ
3. Resolver $\chi_A(\lambda) = 0$ para obtener los autovalores $\lambda_1, \lambda_2, \lambda_3, \ldots$
4. Para cada λ_i, resolver $(A - \lambda_i I)\,\vec{v} = \vec{0}$ (equivalente a $(\lambda_i I - A)\,\vec{v} = \vec{0}$) buscando vectores no nulos

[4] Un polinomio con coeficientes reales no siempre tiene todas sus raíces reales (por ejemplo, $\lambda^2 + 1$ no tiene ninguna). En este capítulo trabajamos con matrices cuyo polinomio característico tiene todas sus raíces reales, contadas con su multiplicidad; es decir, $\chi_A(\lambda) = (\lambda - \lambda_1) \cdots (\lambda - \lambda_n)$. Esto se cumple siempre que A es simétrica ($A^T = A$); ver el *teorema espectral* en el capítulo de formas cuadráticas.

Ejemplo numérico para matriz 2×2

Sea

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

Entonces

$$\lambda I - A = \begin{pmatrix} \lambda & 0 \\ 0 & \lambda \end{pmatrix} - \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} \lambda - 2 & -1 \\ -1 & \lambda - 2 \end{pmatrix}$$

por lo que

$$\chi_A(\lambda) = \det\big(\lambda I - A\big) = \det \begin{pmatrix} \lambda - 2 & -1 \\ -1 & \lambda - 2 \end{pmatrix} = (\lambda - 2)^2 - 1 = \lambda^2 - 4\lambda + 3$$

Resolvemos

$$\lambda^2 - 4\lambda + 3 = 0$$

obteniendo

$$\lambda_1 = 1, \quad \lambda_2 = 3$$

Chequeo: como $\chi_A(\lambda) = \lambda^2 - \operatorname{tr}(A)\,\lambda + \det(A)$, la suma de las raíces debe ser $\operatorname{tr}(A)$ y su producto $\det(A)$:

$$\lambda_1 + \lambda_2 = 1 + 3 = 4 = \operatorname{tr}(A), \qquad \lambda_1 \lambda_2 = 1 \cdot 3 = 3 = \det(A)$$

Cálculo paso a paso de los autovectores

Para $\lambda_1 = 1$ Calculamos

$$A - I = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} - \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

Resolvemos el sistema

$$\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Lo que equivale a la ecuación única

$$x + y = 0$$

De aquí $y = -x$, por lo que los autovectores asociados a $\lambda_1 = 1$ son todos los de la forma

$$\begin{pmatrix} x \\ y \end{pmatrix} = x \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \quad x \neq 0$$

Tomamos $x = 1$ y elegimos $\vec{v}_1 = (1, -1)^T$.[5]

Para $\lambda_2 = 3$ Calculamos

$$A - 3I = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} - \begin{pmatrix} 3 & 0 \\ 0 & 3 \end{pmatrix} = \begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix}$$

Resolvemos el sistema

$$\begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Equivalente a

$$-x + y = 0 \quad \Longrightarrow \quad y = x$$

[5] Los autovectores asociados a un mismo autovalor no son únicos: cualquier múltiplo no nulo de un autovector es también un autovector del mismo autovalor. En efecto, si $A\,\vec{v} = \lambda\,\vec{v}$ y $c \neq 0$, entonces $A\,(c\,\vec{v}) = c\,A\,\vec{v} = c\,\lambda\,\vec{v} = \lambda\,(c\,\vec{v})$. Es decir, se puede tomar cualquiera de los siguientes vectores como autovector del autovalor $\lambda = 1$: $(1, -1)^T$, $(2, -2)^T$, $(-3, 3)^T$, etcétera; todos representan la misma dirección y son autovectores válidos del mismo autovalor.

Por lo tanto, los autovectores asociados a $\lambda_2 = 3$ son todos los de la forma

$$\begin{pmatrix} x \\ y \end{pmatrix} = x \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad x \neq 0$$

Tomamos $x = 1$ y elegimos $\vec{v}_2 = (1, 1)^T$.

En conclusión, tomando $x = 1$ en cada caso, obtenemos como autovectores representativos $\vec{v}_1 = (1, -1)^T$ para $\lambda = 1$ y $\vec{v}_2 = (1, 1)^T$ para $\lambda = 3$ (y todos sus múltiplos no nulos). Son los dos autovectores del segundo gráfico.

Verificación Comprobamos que se cumple $A\,\vec{v} = \lambda\,\vec{v}$:

$$A\,\vec{v}_1 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 1 \cdot \vec{v}_1$$

$$A\,\vec{v}_2 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix} = 3 \cdot \vec{v}_2$$

Propiedades de los autovalores

Sea el polinomio característico de A de grado n:

$$\chi_A(\lambda) = \det(\lambda I - A) = \lambda^n + c_{n-1}\lambda^{n-1} + \cdots + c_1\lambda + c_0$$

Coeficientes y autovalores

Si $\lambda_1, \ldots, \lambda_n$ son las raíces de χ_A (cada una repetida tantas veces como indique su multiplicidad, concepto que se formaliza en la sección siguiente), entonces $\chi_A(\lambda) = (\lambda - \lambda_1) \cdots (\lambda - \lambda_n)$ y, al desarrollar el producto,

$$c_{n-1} = -\sum_{i=1}^{n} \lambda_i, \quad c_0 = (-1)^n \prod_{i=1}^{n} \lambda_i$$

En palabras: el coeficiente c_{n-1} representa el negativo de la suma de todos los autovalores. Por su parte, c_0 corresponde al producto de los autovalores multiplicado por $(-1)^n$.

Traza y determinante

Recordando que:

$$\operatorname{tr}(A) = \sum_{i=1}^{n} a_{ii}$$

Existe una relación entre autovalores y traza y determinante (con las raíces contadas con su multiplicidad):

$$\sum_{i=1}^{n} \lambda_i = \operatorname{tr}(A), \qquad \prod_{i=1}^{n} \lambda_i = \det(A)$$

El caso $n = 2$ corresponde al ejemplo general 2×2 de la sección *Polinomio característico*.

Ejemplo numérico

Para la matriz

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

sus autovalores son $\lambda_1 = 1$ y $\lambda_2 = 3$ (los calculamos en la sección anterior). En este caso,

$$\operatorname{tr}(A) = 2 + 2 = 4 = \lambda_1 + \lambda_2 = 1 + 3, \quad \det(A) = 2 \cdot 2 - 1 \cdot 1 = 3 = \lambda_1\lambda_2 = 1 \cdot 3$$

Matrices triangulares y diagonales

Si A es triangular (superior o inferior), en particular si es diagonal, sus autovalores son los elementos de su diagonal principal.

En efecto, $\lambda I - A$ también es triangular, con $\lambda - a_{11}, \ldots, \lambda - a_{nn}$ en la diagonal, y el determinante de una matriz triangular es el producto de los elementos de su diagonal:

$$\chi_A(\lambda) = (\lambda - a_{11})(\lambda - a_{22}) \cdots (\lambda - a_{nn})$$

Cada autovalor se repite tantas veces como aparece en la diagonal. Por ejemplo, las matrices B, C y D de la sección siguiente son triangulares, y sus autovalores se leen directamente de la diagonal.

Autovalor cero y matrices singulares

$\lambda = 0$ es autovalor de A si y solo si A es singular (es decir, $\det(A) = 0$).

En efecto, 0 es autovalor $\Leftrightarrow$ existe $\vec{v} \neq \vec{0}$ tal que $A\,\vec{v} = 0 \cdot \vec{v} = \vec{0} \Leftrightarrow A$ es singular. Esto también se ve a partir de $\prod_{i=1}^{n} \lambda_i = \det(A)$: el producto es cero si y solo si algún factor es cero.

Autovectores de autovalores distintos

Autovectores asociados a autovalores distintos son linealmente independientes.

Veamos el caso de dos autovectores. Sean $A\,\vec{v}_1 = \lambda_1 \vec{v}_1$ y $A\,\vec{v}_2 = \lambda_2 \vec{v}_2$, con $\lambda_1 \neq \lambda_2$, y supongamos que

$$\alpha_1 \vec{v}_1 + \alpha_2 \vec{v}_2 = \vec{0}$$

Multiplicando por A se obtiene

$$\alpha_1 \lambda_1 \vec{v}_1 + \alpha_2 \lambda_2 \vec{v}_2 = \vec{0}$$

y restando λ_1 veces la primera igualdad queda

$$\alpha_2 (\lambda_2 - \lambda_1)\, \vec{v}_2 = \vec{0}$$

Como $\vec{v}_2 \neq \vec{0}$ y $\lambda_2 \neq \lambda_1$, resulta $\alpha_2 = 0$. Entonces $\alpha_1 \vec{v}_1 = \vec{0}$ y, como $\vec{v}_1 \neq \vec{0}$, también $\alpha_1 = 0$. El caso general se demuestra de la misma manera, por inducción.

En particular, si $A \in \mathbb{R}^{n \times n}$ tiene n autovalores distintos, tiene n autovectores linealmente independientes.

Si además A es simétrica ($A^T = A$), los autovectores de autovalores distintos son perpendiculares: $\vec{v}_1^T \vec{v}_2 = 0$. En el ejemplo 2×2, $\vec{v}_1^T \vec{v}_2 = (1, -1)\,(1, 1)^T = 1 - 1 = 0$. Los autovectores de un mismo autovalor repetido no siempre salen perpendiculares, pero se pueden elegir así (lo vemos en el ejemplo 3×3).

Raíces iguales y multiplicidad

Multiplicidad algebraica

Sea $A \in \mathbb{R}^{n \times n}$ y sean $\lambda_1, \ldots, \lambda_k$ los autovalores *distintos* de A (ahora sin repetir).

- La *multiplicidad algebraica* de λ_i, denotada $\text{mult}_{\text{alg}}(\lambda_i)$, es el grado con que λ_i aparece como raíz del polinomio característico $\chi_A(\lambda)$. Puede pensarse como la cantidad de veces que se repite el autovalor.

$$\chi_A(\lambda) = (\lambda - \lambda_1)^{m_1} \cdots (\lambda - \lambda_k)^{m_k}, \quad \text{mult}_{\text{alg}}(\lambda_i) = m_i$$

- Obsérvese que $\sum_{i=1}^{k} m_i = n$, es decir, la suma de todas las multiplicidades algebraicas es el grado del polinomio característico (recordemos que estamos suponiendo que todas las raíces de χ_A son reales).

Espacio propio

Antes de definir la multiplicidad geométrica conviene mirar *todos* los autovectores de un mismo autovalor a la vez. Ya vimos que si $\vec{v}$ es un autovector de λ, cualquier múltiplo no nulo de $\vec{v}$ también lo es: todos esos vectores están sobre una misma recta por el origen. Y si $\vec{u}$ y $\vec{w}$ son autovectores de λ que no son múltiplos entre sí, cualquier combinación lineal de ellos sigue siendo un autovector de λ (o el vector nulo), porque

$$A\,(\alpha\vec{u} + \beta\vec{w}) = \alpha\, A\,\vec{u} + \beta\, A\,\vec{w} = \alpha\lambda\,\vec{u} + \beta\lambda\,\vec{w} = \lambda\,(\alpha\vec{u} + \beta\vec{w})$$

Es decir, los vectores que A multiplica exactamente por λ forman una recta, un plano, etc., que pasa por el origen. A ese conjunto se lo llama *espacio propio* (o autoespacio) de λ:

$$E_\lambda = \{\, \vec{v} \in \mathbb{R}^n : A\,\vec{v} = \lambda\,\vec{v} \,\} = \ker(A - \lambda I)$$

Recordemos que $\ker(M) = \{\, \vec{v} : M\,\vec{v} = \vec{0} \,\}$ es el núcleo (o espacio nulo) de una matriz M; la igualdad anterior sale de $A\,\vec{v} = \lambda\,\vec{v} \Leftrightarrow (A - \lambda I)\,\vec{v} = \vec{0}$.

El espacio propio E_λ contiene a todos los autovectores de λ y, además, al vector nulo (que no es un autovector, pero cumple $A\,\vec{0} = \lambda\,\vec{0}$). Con el vector nulo incluido, E_λ es un subespacio vectorial de $\mathbb{R}^n$: contiene al $\vec{0}$ y es cerrado por sumas y por múltiplos escalares, como muestra la cuenta de arriba. Recordemos que la *dimensión* de un subespacio es la cantidad de vectores de una base suya; por ejemplo, en $\mathbb{R}^3$ los subespacios son el origen (dimensión 0), las rectas por el origen (dimensión 1), los planos por el origen (dimensión 2) y todo $\mathbb{R}^3$ (dimensión 3).

Ejemplo. Para $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, E_3 es la recta generada por $(1,1)^T$ y E_1 es la recta generada por $(1,-1)^T$: son las dos rectas punteadas del segundo gráfico.

Multiplicidad geométrica

Para cada autovalor λ, definimos su *multiplicidad geométrica* como la dimensión de su espacio propio:

$$\text{mult}_{\text{geom}}(\lambda) = \dim\big(E_\lambda\big) = \dim\big(\ker(A - \lambda I)\big)$$

Es el número de vectores de una base del espacio propio asociado a λ, es decir, la cantidad de autovectores linealmente independientes que se pueden conseguir para λ.

Entonces podemos preguntarnos:

¿Cuántos vectores necesito para formar una base de ese espacio propio?

Esa cantidad es la multiplicidad geométrica. En términos geométricos: $\text{mult}_{\text{geom}}(\lambda) = 1$ significa que los autovectores de λ llenan una recta, $\text{mult}_{\text{geom}}(\lambda) = 2$ que llenan un plano, y así sucesivamente.

Relación entre ambas multiplicidades

Para todo autovalor λ de A se tiene siempre:

$$1 \le \text{mult}_{\text{geom}}(\lambda) \le \text{mult}_{\text{alg}}(\lambda)$$

En particular, si $\text{mult}_{\text{alg}}(\lambda) = 1$ (raíz simple), entonces necesariamente $\text{mult}_{\text{geom}}(\lambda) = 1$: el espacio propio es una recta.

Ejemplo numérico

Considérese

$$B = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}$$

Su polinomio característico es

$$\chi_B(\lambda) = \det(\lambda I - B) = \det \begin{pmatrix} \lambda - 2 & -1 \\ 0 & \lambda - 2 \end{pmatrix} = (\lambda - 2)^2$$

luego $\lambda = 2$ tiene $\text{mult}_{\text{alg}}(2) = 2$.

Cálculo de los autovectores para $\lambda = 2$ Partimos de

$$B - 2I = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$$

y buscamos todos los vectores $\vec{v} = (x, y)^T$ tales que

$$(B - 2I)\,\vec{v} = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} y \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

De la igualdad $\big(y, 0\big)^T = (0, 0)^T$ se obtiene la única ecuación

$$y = 0$$

Así, x es libre y los autovectores asociados a $\lambda = 2$ son

$$\vec{v} = \begin{pmatrix} x \\ 0 \end{pmatrix}, \quad x \neq 0$$

Por ejemplo, para $x = 1$ podemos tomar como autovector base

$$\vec{v} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

Y por lo tanto tenemos multiplicidad geométrica igual a 1, porque el espacio propio es una recta (solamente hay un vector linealmente independiente).

Otro ejemplo numérico

$$C = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

Polinomio característico

$$\chi_C(\lambda) = \det(\lambda I - C) = \det \begin{pmatrix} \lambda - 2 & 0 \\ 0 & \lambda - 2 \end{pmatrix} = (\lambda - 2)^2$$

Entonces,

$$\lambda = 2 \quad \text{con} \quad \text{mult}_{\text{alg}}(2) = 2$$

Autovectores para $\lambda = 2$

$$C - 2I = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \Rightarrow (C - 2I)\vec{v} = \vec{0} \quad \text{para todo } \vec{v} \in \mathbb{R}^2$$

Por lo tanto, todos los vectores no nulos son autovectores y el espacio propio es todo $\mathbb{R}^2$, que tiene dimensión 2:

$$\text{mult}_{\text{geom}}(2) = 2$$

Conclusión: En este caso,

$$\text{mult}_{\text{alg}}(2) = \text{mult}_{\text{geom}}(2) = 2$$

Un conjunto base de autovectores puede ser:

$$\vec{v}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \vec{v}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

Un tercer ejemplo Sea $D = \left(\begin{smallmatrix} 2 & 0 \\ 0 & 3 \end{smallmatrix}\right)$. Por ser diagonal, sus autovalores son $\lambda_1 = 2$ y $\lambda_2 = 3$, ambos raíces simples; luego, por la relación $1 \leq \text{mult}_{\text{geom}}(\lambda) \leq \text{mult}_{\text{alg}}(\lambda)$, se tiene $\text{mult}_{\text{alg}} = \text{mult}_{\text{geom}} = 1$ para cada uno, con autovectores $(1, 0)^T$ y $(0, 1)^T$, respectivamente.

Resumen Los tres ejemplos juntos (una fila por autovalor):

Matriz	$\chi(\lambda)$	λ	mult_{alg}	$\text{mult}_{\text{geom}}$	¿$\text{mult}_{\text{geom}} = \text{mult}_{\text{alg}}$?
$B = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}$	$(\lambda - 2)^2$	2	2	1	No
$C = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$	$(\lambda - 2)^2$	2	2	2	Sí
$D = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$	$(\lambda - 2)(\lambda - 3)$	2	1	1	Sí
		3	1	1	Sí

Observemos que B y C tienen el mismo polinomio característico pero distinta multiplicidad geométrica: el polinomio característico determina mult_{alg}, pero no $\text{mult}_{\text{geom}}$.

Ejemplo con una matriz 3×3

Sea

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}$$

Seguimos los cuatro pasos del procedimiento.

Pasos 1 y 2: polinomio característico Formamos $\lambda I - A$:

$$\lambda I - A = \begin{pmatrix} \lambda - 2 & -1 & -1 \\ -1 & \lambda - 2 & -1 \\ -1 & -1 & \lambda - 2 \end{pmatrix}$$

y calculamos su determinante con la regla de Sarrus (las diagonales dan $(\lambda-2)^3$, -1 y -1; las antidiagonales dan $\lambda - 2$ tres veces):

$$\chi_A(\lambda) = (\lambda - 2)^3 + (-1) + (-1) - \big[(\lambda - 2) + (\lambda - 2) + (\lambda - 2)\big] = (\lambda - 2)^3 - 3(\lambda - 2) - 2$$

Desarrollando,

$$\chi_A(\lambda) = \lambda^3 - 6\lambda^2 + 9\lambda - 4$$

Paso 3: autovalores Buscamos las raíces de $\lambda^3 - 6\lambda^2 + 9\lambda - 4 = 0$. Como el polinomio es mónico y tiene coeficientes enteros, sus raíces enteras (si las hay) son divisores del término independiente -4, es decir, $\pm 1, \pm 2, \pm 4$. Probando, $\lambda = 1$ es raíz, porque $1 - 6 + 9 - 4 = 0$. Dividimos por $\lambda - 1$ con la regla de Ruffini:

	1	−6	9	−4
1		1	−5	4
	1	−5	4	0

de donde

$$\chi_A(\lambda) = (\lambda - 1)(\lambda^2 - 5\lambda + 4) = (\lambda - 1)(\lambda - 1)(\lambda - 4) = (\lambda - 1)^2(\lambda - 4)$$

Por lo tanto

$$\lambda_1 = 1 \quad (\text{mult}_{\text{alg}}(1) = 2), \qquad \lambda_2 = 4 \quad (\text{mult}_{\text{alg}}(4) = 1)$$

Chequeo con traza y determinante Tenemos $\text{tr}(A) = 2 + 2 + 2 = 6$ y $\det(A) = 4$ (por Sarrus, $8 + 1 + 1 - 2 - 2 - 2 = 4$). Contando cada autovalor tantas veces como su multiplicidad algebraica:

$$1 + 1 + 4 = 6 = \text{tr}(A), \qquad 1 \cdot 1 \cdot 4 = 4 = \det(A)$$

También se ve en los coeficientes de $\chi_A(\lambda) = \lambda^3 - 6\lambda^2 + 9\lambda - 4$: $c_2 = -6 = -\text{tr}(A)$ y $c_0 = -4 = (-1)^3 \det(A)$. Aquí, con $n = 3$, el factor $(-1)^n$ sí se nota.

Paso 4: autovectores Para cada autovalor resolvemos $(A - \lambda I)\vec{v} = \vec{0}$, con $\vec{v} = (x, y, z)^T$.

Para $\lambda = 1$ Calculamos

$$A - I = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}$$

Las tres ecuaciones de $(A - I)\vec{v} = \vec{0}$ son la misma:

$$x + y + z = 0$$

Hay dos variables libres ($z = -x - y$), de modo que

$$\vec{v} = \begin{pmatrix} x \\ y \\ -x - y \end{pmatrix} = x \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} + y \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}$$

Tomamos $\vec{v}_1 = (1, 0, -1)^T$ y $\vec{v}_2 = (0, 1, -1)^T$, que son linealmente independientes. El espacio propio E_1 es el plano $x + y + z = 0$ y $\text{mult}_{\text{geom}}(1) = 2$.

Para $\lambda = 4$ Calculamos

$$A - 4I = \begin{pmatrix} -2 & 1 & 1 \\ 1 & -2 & 1 \\ 1 & 1 & -2 \end{pmatrix}$$

y resolvemos $(A - 4I)\vec{v} = \vec{0}$:

$$\begin{cases} -2x + y + z = 0 \\ x - 2y + z = 0 \\ x + y - 2z = 0 \end{cases}$$

Restando la segunda ecuación de la primera se obtiene $-3x + 3y = 0$, o sea $y = x$; restando la tercera de la segunda, $-3y + 3z = 0$, o sea $z = y$. Luego $x = y = z$ y

$$\vec{v} = x \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}, \quad x \neq 0$$

El espacio propio E_4 es la recta generada por $\vec{v}_3 = (1, 1, 1)^T$, y $\text{mult}_{\text{geom}}(4) = 1$.

Verificación

$$A\,\vec{v}_1 = \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} = 1 \cdot \vec{v}_1, \qquad A\,\vec{v}_2 = \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix} = 1 \cdot \vec{v}_2, \qquad A\,\vec{v}_3 = \begin{pmatrix} 4 \\ 4 \\ 4 \end{pmatrix} = 4\,\vec{v}_3$$

Conclusión:

$$\text{mult}_{\text{alg}}(1) = \text{mult}_{\text{geom}}(1) = 2, \qquad \text{mult}_{\text{alg}}(4) = \text{mult}_{\text{geom}}(4) = 1$$

Aunque $\lambda = 1$ es raíz doble, tiene dos autovectores linealmente independientes: su espacio propio es un plano, no una recta.

Como A es simétrica, $\vec{v}_3$, que es de $\lambda = 4$, es perpendicular a $\vec{v}_1$ y a $\vec{v}_2$, que son de $\lambda = 1$: $\vec{v}_3^T \vec{v}_1 = 1 + 0 - 1 = 0$ y $\vec{v}_3^T \vec{v}_2 = 0 + 1 - 1 = 0$. En cambio, $\vec{v}_1$ y $\vec{v}_2$ no son perpendiculares entre sí ($\vec{v}_1^T \vec{v}_2 = 1$), pero dentro de E_1 se pueden elegir dos que sí lo sean, por ejemplo $(1, 0, -1)^T$ y $(1, -2, 1)^T$. Con autovectores perpendiculares entre sí y de norma 1 se arma la matriz ortogonal P del capítulo de formas cuadráticas.

16 Formas cuadráticas

Definición

Una forma cuadrática en las variables $x_1, \dots, x_n$ es un polinomio homogéneo de grado dos:

$$\begin{aligned} q(x_1, \dots, x_n) = a_{11}x_1^2 + a_{22}x_2^2 + \cdots + a_{nn}x_n^2 \\ + 2\big(a_{12}x_1x_2 + a_{13}x_1x_3 + \cdots + a_{n-1,n}x_{n-1}x_n\big) \end{aligned}$$

También se puede expresar de forma compacta mediante sumatorias:

$$q(x_1, \dots, x_n) = \sum_{i=1}^{n} a_{ii}x_i^2 + 2 \sum_{1 \le i < j \le n} a_{ij}x_ix_j$$

Representación matricial

Escribiendo

$$x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \quad \text{y} \quad Q = \big(a_{ij}\big)_{i,j=1}^{n}$$

con Q simétrica (es decir, $a_{ij} = a_{ji}$), la forma cuadrática se expresa de modo compacto como

$$q(x) = x^T Q\, x$$

En esta matriz, cada entrada diagonal $Q_{ii} = a_{ii}$ multiplica a x_i^2. Cada valor a_{ij} fuera de la diagonal aparece dos veces, en las posiciones (i, j) y (j, i), y entre las dos aportan el término $2a_{ij}x_ix_j$. De ahí sale la regla práctica para armar la matriz:

En la diagonal va el coeficiente de x_i^2, y fuera de la diagonal va la mitad del coeficiente de x_ix_j

¿Por qué pedimos que Q sea simétrica? Una misma forma cuadrática se puede escribir con muchas matrices distintas, porque en x^TQx solo importa la suma $Q_{ij}+Q_{ji}$, que es el coeficiente de x_ix_j. Por ejemplo, $x_1^2 + 4x_1x_2 + x_2^2$ se obtiene tanto con

$$\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \qquad \text{como con} \qquad \begin{pmatrix} 1 & 4 \\ 0 & 1 \end{pmatrix}$$

Entre todas esas matrices hay una sola simétrica: la que reparte el coeficiente de cada término cruzado en dos mitades iguales. Trabajamos siempre con esa porque, como veremos más adelante, es la única con la que funciona la clasificación por autovalores.

Ejemplo para 2 variables

Con dos variables, la forma cuadrática general es

$$q(x_1, x_2) = a_{11}x_1^2 + 2a_{12}x_1x_2 + a_{22}x_2^2$$

y su matriz simétrica asociada es

$$Q = \begin{pmatrix} a_{11} & a_{12} \\ a_{12} & a_{22} \end{pmatrix}$$

Es la regla práctica aplicada a dos variables: el coeficiente $2a_{12}$ del término cruzado se reparte en dos mitades iguales, una en cada posición fuera de la diagonal.

Consideremos la forma cuadrática en (x_1, x_2):

$$q(x_1, x_2) = 5x_1^2 - 4x_1x_2 + 2x_2^2$$

El coeficiente del término cruzado es -4, así que en cada posición fuera de la diagonal va la mitad, -2, con el mismo signo. La matriz asociada es

$$Q = \begin{pmatrix} 5 & -2 \\ -2 & 2 \end{pmatrix}$$

con lo que

$$q(x) = x^T Qx = \begin{pmatrix} x_1 & x_2 \end{pmatrix} \begin{pmatrix} 5 & -2 \\ -2 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

Primero multiplicamos las dos primeras matrices:

$$\begin{pmatrix} x_1 & x_2 \end{pmatrix} \begin{pmatrix} 5 & -2 \\ -2 & 2 \end{pmatrix} = \begin{pmatrix} 5x_1 - 2x_2 & -2x_1 + 2x_2 \end{pmatrix}$$

Entonces,

$$q(x) = \begin{pmatrix} 5x_1 - 2x_2 & -2x_1 + 2x_2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

Multiplicando ahora por la última matriz, obtenemos:

$$q(x) = (5x_1 - 2x_2)x_1 + (-2x_1 + 2x_2)x_2$$

Distribuyendo:

$$q(x) = 5x_1^2 - 2x_1x_2 - 2x_1x_2 + 2x_2^2$$

El término $-2x_1x_2$ aparece dos veces, una por cada entrada -2 fuera de la diagonal. Agrupando términos semejantes:

$$q(x) = 5x_1^2 - 4x_1x_2 + 2x_2^2$$

Por lo tanto, al calcular $x^T Qx$, recuperamos exactamente la forma cuadrática original

Ejemplo para 3 variables

Consideremos la forma cuadrática en (x_1, x_2, x_3):

$$q(x_1, x_2, x_3) = 3x_1^2 + 4x_2^2 + 5x_3^2 + 2x_1x_2 + 4x_1x_3 + 6x_2x_3$$

La matriz asociada es

$$Q = \begin{pmatrix} 3 & 1 & 2 \\ 1 & 4 & 3 \\ 2 & 3 & 5 \end{pmatrix}$$

con lo que

$$q(x) = x^T Qx = \begin{pmatrix} x_1 & x_2 & x_3 \end{pmatrix} \begin{pmatrix} 3 & 1 & 2 \\ 1 & 4 & 3 \\ 2 & 3 & 5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

Primero multiplicamos las dos primeras matrices:

$$\begin{pmatrix} x_1 & x_2 & x_3 \end{pmatrix} \begin{pmatrix} 3 & 1 & 2 \\ 1 & 4 & 3 \\ 2 & 3 & 5 \end{pmatrix}$$
$$= \begin{pmatrix} 3x_1 + x_2 + 2x_3 & x_1 + 4x_2 + 3x_3 & 2x_1 + 3x_2 + 5x_3 \end{pmatrix}$$

Entonces,

$$q(x) = \begin{pmatrix} 3x_1 + x_2 + 2x_3 & x_1 + 4x_2 + 3x_3 & 2x_1 + 3x_2 + 5x_3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

Multiplicando ahora por la última matriz, obtenemos:

$$q(x) = (3x_1 + x_2 + 2x_3)x_1 + (x_1 + 4x_2 + 3x_3)x_2 + (2x_1 + 3x_2 + 5x_3)x_3$$

Distribuyendo:

$$q(x) = 3x_1^2 + x_1x_2 + 2x_1x_3 + x_1x_2 + 4x_2^2 + 3x_2x_3 + 2x_1x_3 + 3x_2x_3 + 5x_3^2$$

Agrupando términos semejantes:

$$q(x) = 3x_1^2 + 4x_2^2 + 5x_3^2 + 2x_1x_2 + 4x_1x_3 + 6x_2x_3$$

Por lo tanto, al calcular x^TQx, recuperamos exactamente la forma cuadrática original

Clasificación de formas cuadráticas según autovalores

Sea una forma cuadrática $q(x) = x^TQx$ con matriz simétrica Q[6] y autovalores $\lambda_1, \ldots, \lambda_n$.

- **Definida positiva:** $q(x) > 0$ para todo $x \neq 0$. Se cumple si y solo si $\lambda_i > 0 \quad \forall i$.
- **Semidefinida positiva:** $q(x) \geq 0$ para todo x. Se cumple si y solo si $\lambda_i \geq 0 \quad \forall i$.
- **Definida negativa:** $q(x) < 0$ para todo $x \neq 0$. Se cumple si y solo si $\lambda_i < 0 \quad \forall i$.
- **Semidefinida negativa:** $q(x) \leq 0$ para todo x. Se cumple si y solo si $\lambda_i \leq 0 \quad \forall i$.
- **Indefinida:** $q(x)$ toma valores positivos y negativos. Se cumple si y solo si $\exists\, i, j : \ \lambda_i > 0,\ \lambda_j < 0$.

Observación sobre las definiciones. Con estas definiciones, las categorías no son excluyentes: toda forma definida positiva también es semidefinida positiva (si todos los autovalores son > 0, en particular son ≥ 0), y toda definida negativa también es semidefinida negativa.[7] La forma nula, $q(x) = 0$, es semidefinida positiva y semidefinida negativa a la vez.

¿Por qué funcionan los autovalores?

Toda matriz simétrica se puede diagonalizar[8] con una matriz ortogonal.[9] Este resultado, conocido como *teorema espectral*, es el que necesita la simetría: existe una matriz ortogonal P, cuyas columnas son autovectores

[6] El criterio se aplica a los autovalores de la matriz simétrica Q. Con otra matriz que represente la misma forma, los autovalores pueden dar una clasificación equivocada. Por ejemplo, $q(x_1, x_2) = x_1^2 + 4x_1x_2 + x_2^2$ también se escribe con la matriz no simétrica $\left(\begin{smallmatrix} 1 & 4 \\ 0 & 1 \end{smallmatrix}\right)$, cuyos autovalores son 1 y 1 (es triangular), lo que sugeriría que la forma es definida positiva. Sin embargo, $q(1, -1) = -2 < 0$. Con la matriz simétrica $\left(\begin{smallmatrix} 1 & 2 \\ 2 & 1 \end{smallmatrix}\right)$ se obtienen los autovalores correctos, 3 y -1: la forma es indefinida, como se ve en el Ejemplo 2 de esta sección.

[7] Algunos libros reservan la palabra *semidefinida* para las formas que son ≥ 0 (o ≤ 0) sin ser definidas, es decir, las que además tienen algún autovalor igual a 0.

[8] Diagonalizar una matriz cuadrada Q es encontrar una matriz invertible P tal que $P^{-1}QP = D$ sea diagonal. Cuando eso pasa, las columnas de P son autovectores de Q y la diagonal de D tiene los autovalores correspondientes. Para una forma cuadrática, diagonalizar equivale a encontrar un cambio de variables que elimine los términos cruzados.

[9] Una matriz P es ortogonal si $P^TP = I$, es decir, si su inversa es su traspuesta: $P^{-1} = P^T$. Equivalentemente, sus columnas tienen norma 1 y son perpendiculares entre sí. Multiplicar por una matriz ortogonal rota (o refleja) los vectores sin cambiar sus longitudes ni los ángulos entre ellos.

de Q, tal que

$$P^{-1}QP = P^TQP = D = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix}$$

Si hacemos el cambio de variables $x = Py$, la forma cuadrática queda

$$q(x) = x^TQx = (Py)^TQ(Py) = y^T\left(P^TQP\right)y = y^TDy$$

es decir,

$$q = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \cdots + \lambda_n y_n^2$$

En las nuevas variables no hay términos cruzados, y el signo de q depende solo de los signos de los λ_i. Además, como P es invertible, $x \neq 0$ si y solo si $y \neq 0$. Por eso:

- Si todos los λ_i son positivos, cada término $\lambda_i y_i^2$ es ≥ 0 y, si $y \neq 0$, al menos uno es > 0: la forma es definida positiva.
- Si todos los λ_i son ≥ 0, $q \geq 0$ siempre: la forma es semidefinida positiva. Si además algún $\lambda_i = 0$, la forma vale 0 a lo largo del autovector correspondiente, así que no es definida.
- Si hay un $\lambda_i > 0$ y un $\lambda_j < 0$, tomando y con un 1 en la posición i y ceros en el resto queda $q = \lambda_i > 0$, y con un 1 en la posición j queda $q = \lambda_j < 0$: la forma es indefinida.

Los casos negativos son análogos.

Por ejemplo, para la forma $5x_1^2 - 4x_1x_2 + 2x_2^2$ del ejemplo para 2 variables, los autovalores son 1 y 6 y, con

$$P = \frac{1}{\sqrt{5}}\begin{pmatrix} 1 & 2 \\ 2 & -1 \end{pmatrix}$$

el cambio $x = Py$ la convierte en $q = y_1^2 + 6y_2^2$, que es definida positiva.

En la sección de formas cuadráticas restringidas vamos a usar la misma idea: un cambio de variables $x = By$ que lleva la forma original a una forma más simple.

Intuición geométrica

La clasificación de una forma cuadrática nos dice qué forma tiene el gráfico de $q(x) = x^TQx$.

En el caso de dos variables independientes, $q(x_1, x_2)$, podemos dibujar su gráfico en tres dimensiones. La matriz Q determina si ese gráfico se parece a un bowl abierto hacia arriba, a un bowl dado vuelta, a una canaleta (hacia arriba o dada vuelta) o a una silla de montar.

Por eso, los autovalores de Q nos dan información sobre cómo se curva el gráfico en distintas direcciones. Como vimos en la sección anterior, a lo largo de la dirección de cada autovector el gráfico es la curva $\lambda_i t^2$: una parábola hacia arriba si $\lambda_i > 0$, una parábola hacia abajo si $\lambda_i < 0$ y una recta horizontal si $\lambda_i = 0$.

- **Definida positiva:** el gráfico tiene forma de bowl abierto hacia arriba, como un bowl de cereales. El origen es el punto más bajo y, al movernos en cualquier dirección distinta de cero, el valor de q aumenta.
- **Semidefinida positiva:** el gráfico mira hacia arriba, pero puede tener alguna dirección plana. Si la tiene, se parece a una canaleta: sube hacia los costados, pero es plano a lo largo de una recta, donde q vale 0. Un bowl achatado, en cambio, sigue siendo definido positivo: sube en todas las direcciones, aunque sea despacio.
- **Definida negativa:** el gráfico tiene forma de bowl dado vuelta, abierto hacia abajo. El origen es el punto más alto.

- **Semidefinida negativa:** el gráfico mira hacia abajo, pero puede tener alguna dirección plana. Si la tiene, se parece a una canaleta dada vuelta: baja hacia los costados, pero es plano a lo largo de una recta.
- **Indefinida:** el gráfico sube en algunas direcciones y baja en otras. En dos variables independientes, la figura típica es una silla de montar.

Aclaración sobre dimensiones mayores

La intuición del bowl o de la silla de montar es más fácil de visualizar con dos variables, porque el gráfico puede dibujarse en tres dimensiones.

Si la forma cuadrática tiene más variables, el gráfico estaría en más dimensiones y ya no podemos dibujarlo directamente. Sin embargo, la idea sigue siendo la misma: los autovalores indican cómo se comporta $q(x)$ en distintas direcciones.

Si todos los autovalores son positivos, $q(x)$ crece en todas las direcciones; si todos son negativos, decrece en todas las direcciones; si hay positivos y negativos, sube en algunas direcciones y baja en otras

Ejemplo 1

Planteamos una forma cuadrática homogénea de grado 2

$$q(x_1, x_2, x_3) = 2x_1^2 + 2x_2^2 + 3x_3^2 + 2x_1x_2$$

La matriz simétrica asociada es

$$Q = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix}$$

de modo que $q(x) = x^T Q x$

Polinomio característico:

$$\chi_Q(\lambda) = \det(Q - \lambda I) = \det \begin{pmatrix} 2-\lambda & 1 & 0 \\ 1 & 2-\lambda & 0 \\ 0 & 0 & 3-\lambda \end{pmatrix} = (3-\lambda)\big((2-\lambda)^2 - 1\big)$$

Factorización: el segundo factor es una diferencia de cuadrados,

$$(2-\lambda)^2 - 1 = \big((2-\lambda) - 1\big)\big((2-\lambda) + 1\big) = (1-\lambda)(3-\lambda)$$

así que

$$\chi_Q(\lambda) = (1-\lambda)(3-\lambda)^2$$

Autovalores

$$\lambda_1 = 1, \quad \lambda_2 = 3, \quad \lambda_3 = 3$$

($\lambda = 3$ es raíz doble del polinomio característico)

Como $\lambda_i > 0$ para todo i, concluimos que q es **definida positiva**

Ejemplo 2

Consideremos

$$q(x_1, x_2) = x_1^2 + 4x_1x_2 + x_2^2$$

cuya matriz simétrica es

$$Q = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$$

Polinomio característico:

$$\chi_Q(\lambda) = \det \begin{pmatrix} 1-\lambda & 2 \\ 2 & 1-\lambda \end{pmatrix} = (1-\lambda)^2 - 4 = \lambda^2 - 2\lambda - 3 = (\lambda - 3)(\lambda + 1)$$

Autovalores

$$\lambda_1 = 3, \quad \lambda_2 = -1$$

Hay un autovalor positivo y uno negativo, así que q toma valores de los dos signos. Lo podemos comprobar evaluando en las direcciones de los autovectores, $(1,1)$ y $(1,-1)$: $q(1,1) = 6 > 0$ y $q(1,-1) = -2 < 0$. A lo largo de la recta $x_2 = x_1$ el gráfico sube, y a lo largo de la recta $x_2 = -x_1$ baja.

Como $\lambda_1 > 0$ y $\lambda_2 < 0$, concluimos que q es **indefinida**: su gráfico es una silla de montar

Ejemplo 3

Consideremos

$$q(x_1, x_2) = x_1^2 - 2x_1x_2 + x_2^2 = (x_1 - x_2)^2$$

cuya matriz simétrica es

$$Q = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$$

Polinomio característico:

$$\chi_Q(\lambda) = (1-\lambda)^2 - 1 = \lambda^2 - 2\lambda = \lambda(\lambda - 2)$$

Autovalores

$$\lambda_1 = 0, \quad \lambda_2 = 2$$

Los dos autovalores son ≥ 0, y uno de ellos es nulo. Se ve también en la fórmula: $q = (x_1 - x_2)^2 \geq 0$, y vale 0 en todos los puntos de la recta $x_1 = x_2$, no solo en el origen. Esa recta es la dirección del autovector de $\lambda = 0$, y es donde el gráfico, una canaleta, es plano.

Como todos los autovalores son ≥ 0 y uno de ellos es 0, concluimos que q es **semidefinida positiva**, pero no definida positiva

Formas cuadráticas restringidas

Una forma cuadrática $q(x) = x^T Q x$ asigna a cada vector x un número real. Estudiar su signo significa preguntar si ese número es siempre positivo, siempre negativo, o si puede cambiar de signo según la dirección elegida.

Cuando aparecen restricciones lineales, ya no estudiamos la forma cuadrática en todo el espacio, sino solamente sobre los vectores que cumplen esas restricciones. Es decir, si las restricciones se escriben como

$$Cx = 0$$

entonces solo nos interesan los vectores x que satisfacen ese sistema de ecuaciones.

La idea central es que las restricciones reducen las direcciones posibles. Por eso, una forma cuadrática que no es definida positiva en todo el espacio podría ser definida positiva si la miramos solamente sobre las direcciones permitidas por las restricciones.

En cambio, una forma que ya es definida no deja de serlo al restringirla: si $q(x) > 0$ para todo $x \neq 0$, en particular $q(x) > 0$ para los $x \neq 0$ que cumplen las restricciones (y lo mismo pasa con las definidas negativas). Por eso:

Conviene empezar clasificando la forma sin restricciones: el análisis restringido aporta información nueva solo cuando la forma sin restricciones es indefinida o semidefinida

Procedimiento

Supongamos que hay m restricciones independientes (ninguna es combinación lineal de las otras) sobre n variables, escritas como $Cx = 0$, donde C es una matriz de $m \times n$ con una fila por restricción. La forma restringida se estudia en tres pasos.

1. Describir los vectores permitidos. Se resuelve el sistema $Cx = 0$ y se escribe la solución general en función de las variables libres. Como las restricciones son independientes, quedan $n - m$ variables libres, y todo vector permitido se puede escribir como

$$x = By$$

donde $y \in \mathbb{R}^{n-m}$ contiene las variables libres y B es una matriz de $n \times (n - m)$ cuyas columnas son las direcciones permitidas. Para comprobar que las columnas de B cumplen las restricciones se verifica que

$$CB = 0$$

Las columnas de B tienen que formar una *base* del conjunto de soluciones: ser linealmente independientes y, entre todas, generar todas las soluciones. Si fueran dependientes, la matriz M del paso siguiente tendría autovalores nulos que no vienen de la forma, y una forma definida parecería semidefinida. Si no generaran todas las soluciones, quedarían direcciones sin revisar, y se podría escapar justamente una dirección donde la forma es negativa. Al resolver el sistema como en los ejemplos, con una columna por cada variable libre, las dos condiciones se cumplen automáticamente.

2. Calcular la matriz restringida. Sustituimos $x = By$ en la forma cuadrática. Usando que $(By)^T = y^T B^T$:

$$q(By) = (By)^T Q\,(By) = y^T\, B^T Q B\, y$$

Por lo tanto, sobre los vectores permitidos, la forma original se convierte en una nueva forma cuadrática en las variables libres:

$$\psi(y) = y^T M y, \qquad \text{con} \qquad M = B^T Q B$$

La matriz M es simétrica y de tamaño $(n-m)\times(n-m)$. Calcular M es lo mismo que reemplazar la solución de las restricciones en la fórmula de q y simplificar: son dos maneras de hacer la misma cuenta.

3. Clasificar la matriz restringida. Se clasifica M con sus autovalores, igual que en la sección anterior. Su clasificación es la de q restringida a $Cx = 0$.

Ejemplo 1: una restricción que fija una variable

Estudiar el signo de

$$\varphi(x_1, x_2, x_3) = x_1^2 + 2x_2^2 - x_3^2$$

sujeta a la restricción

$$x_3 = 0$$

Sin restricciones. La matriz de la forma es

$$Q = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -1 \end{pmatrix}$$

con autovalores 1, 2 y -1. Sin restricciones, φ es **indefinida**: por ejemplo, $\varphi(1,0,0) = 1 > 0$ y $\varphi(0,0,1) = -1 < 0$. Además, φ solo puede ser negativa cuando $x_3 \neq 0$, porque $x_1^2 + 2x_2^2 \geq 0$.

1. Vectores permitidos. Todo vector que cumple $x_3 = 0$ tiene la forma

$$x = \begin{pmatrix} x_1 \\ x_2 \\ 0 \end{pmatrix} = y_1 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} + y_2 \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$$

con variables libres $y_1 = x_1$ e $y_2 = x_2$. Entonces $x = By$, con

$$B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}, \qquad y = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$$

La restricción es $Cx = 0$ con $C = \begin{pmatrix} 0 & 0 & 1 \end{pmatrix}$, y efectivamente $CB = \begin{pmatrix} 0 & 0 \end{pmatrix}$.

2. Matriz restringida. Primero calculamos

$$QB = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 2 \\ 0 & 0 \end{pmatrix}$$

y luego

$$M = B^T QB = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 2 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$$

La forma restringida es

$$\psi(y_1, y_2) = y^T My = y_1^2 + 2y_2^2$$

Como B solo toma las dos primeras coordenadas, M es la submatriz de Q que queda al tachar la tercera fila y la tercera columna. Esto pasa porque la restricción fija una variable sin mezclarla con las otras.

3. Clasificación. Los autovalores de M son 1 y 2, ambos positivos, así que la forma restringida es definida positiva.

Conclusión: φ es indefinida en $\mathbb{R}^3$, pero definida positiva sobre las direcciones permitidas por $x_3 = 0$. La restricción deja afuera justamente todas las direcciones donde φ podía ser negativa

Ejemplo 2: una restricción que mezcla las variables

Estudiar el signo de

$$\varphi(x_1, x_2, x_3) = 2x_1x_2 + 2x_1x_3 + 2x_2x_3$$

sujeta a

$$x_1 + x_2 + x_3 = 0$$

Sin restricciones. No hay términos al cuadrado, así que la diagonal de la matriz es nula, y cada término $2x_ix_j$ aporta un 1 en las posiciones (i, j) y (j, i):

$$Q = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix}$$

Su polinomio característico es

$$\chi_Q(\lambda) = \det \begin{pmatrix} -\lambda & 1 & 1 \\ 1 & -\lambda & 1 \\ 1 & 1 & -\lambda \end{pmatrix} = -\lambda^3 + 3\lambda + 2 = -(\lambda - 2)(\lambda + 1)^2$$

así que los autovalores son 2, -1 y -1. Sin restricciones, φ es **indefinida**: por ejemplo, $\varphi(1, 1, 1) = 6 > 0$ y $\varphi(1, -1, 0) = -2 < 0$.

1. Vectores permitidos. La restricción es $Cx = 0$ con

$$C = \begin{pmatrix} 1 & 1 & 1 \end{pmatrix}$$

Despejando $x_3 = -x_1 - x_2$ y tomando como variables libres $y_1 = x_1$ e $y_2 = x_2$:

$$x = \begin{pmatrix} y_1 \\ y_2 \\ -y_1 - y_2 \end{pmatrix} = y_1 \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} + y_2 \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}$$

Por lo tanto,

$$B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ -1 & -1 \end{pmatrix}$$

Con $m = 1$ restricción en $n = 3$ variables quedan $n - m = 2$ variables libres, por eso B tiene dos columnas. Verificamos que cumplen la restricción:

$$CB = \begin{pmatrix} 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ -1 & -1 \end{pmatrix} = \begin{pmatrix} 0 & 0 \end{pmatrix}$$

2. Matriz restringida. Primero calculamos

$$QB = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ -1 & -1 \end{pmatrix} = \begin{pmatrix} -1 & 0 \\ 0 & -1 \\ 1 & 1 \end{pmatrix}$$

y luego

$$M = B^T QB = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} -1 & 0 \\ 0 & -1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} -2 & -1 \\ -1 & -2 \end{pmatrix}$$

La forma restringida es

$$\psi(y_1, y_2) = y^T My = -2y_1^2 - 2y_1y_2 - 2y_2^2$$

A diferencia del ejemplo anterior, M no es una submatriz de Q: la restricción mezcla las variables, y aparecen términos al cuadrado que φ no tenía.

Comprobación por sustitución. Reemplazando directamente $x_3 = -y_1 - y_2$ en φ se obtiene la misma forma:

$$\begin{aligned} \varphi(y_1, y_2, -y_1 - y_2) &= 2y_1y_2 + 2y_1(-y_1 - y_2) + 2y_2(-y_1 - y_2) \\ &= 2y_1y_2 - 2y_1^2 - 2y_1y_2 - 2y_1y_2 - 2y_2^2 \\ &= -2y_1^2 - 2y_1y_2 - 2y_2^2 \end{aligned}$$

3. Clasificación. El polinomio característico de M es

$$\det(M - \lambda I) = \det \begin{pmatrix} -2 - \lambda & -1 \\ -1 & -2 - \lambda \end{pmatrix} = (\lambda + 2)^2 - 1 = (\lambda + 1)(\lambda + 3)$$

Los autovalores de M son -1 y -3, ambos negativos, así que la forma restringida es definida negativa.

Conclusión: φ es indefinida en $\mathbb{R}^3$, pero definida negativa sobre el plano $x_1 + x_2 + x_3 = 0$. El autovector del autovalor positivo es $(1, 1, 1)$, que es perpendicular a ese plano: la restricción deja afuera esa dirección

Ejemplo 3: la misma restricción con otra forma

Con la misma restricción $x_1 + x_2 + x_3 = 0$, estudiemos ahora

$$\varphi(x_1, x_2, x_3) = x_1^2 + x_2^2 - x_3^2$$

Sin restricciones es indefinida: su matriz es diagonal, con autovalores 1, 1 y -1. La matriz B es la misma del ejemplo anterior, porque depende solo de la restricción. Entonces

$$QB = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ -1 & -1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}$$

$$M = B^T QB = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 0 & -1 \\ -1 & 0 \end{pmatrix}$$

La forma restringida es

$$\psi(y_1, y_2) = -2y_1 y_2$$

Los autovalores de M son 1 y -1 (su polinomio característico es $\lambda^2 - 1$), así que la forma restringida sigue siendo indefinida. En las variables originales: $x = (1, -1, 0)$ cumple la restricción y da $\varphi = 2 > 0$, mientras que $x = (1, 1, -2)$ también la cumple y da $\varphi = -2 < 0$.

Conclusión: restringir no siempre cambia la clasificación. Acá el plano permitido contiene direcciones donde φ es positiva y direcciones donde es negativa

Ejemplo 4: dos restricciones

Estudiar el signo de

$$\varphi(x_1, x_2, x_3) = x_1^2 - 2x_1x_2 + 3x_2^2 + x_3^2$$

sujeta a

$$\begin{cases} x_1 + x_2 - x_3 = 0 \\ -x_1 + x_3 = 0 \end{cases} \qquad \text{es decir,} \qquad C = \begin{pmatrix} 1 & 1 & -1 \\ -1 & 0 & 1 \end{pmatrix}$$

1. Vectores permitidos. De la segunda ecuación se obtiene $x_3 = x_1$. Sustituyendo en la primera queda $x_1 + x_2 - x_1 = 0$, es decir, $x_2 = 0$. Entonces todo vector permitido es

$$x = \begin{pmatrix} x_1 \\ 0 \\ x_1 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} y, \qquad \text{con } y = x_1$$

Con $m = 2$ restricciones en $n = 3$ variables queda $n - m = 1$ variable libre, así que B tiene una sola columna:

$$B = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}, \qquad CB = \begin{pmatrix} 1 + 0 - 1 \\ -1 + 0 + 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

2. Matriz restringida. La matriz de la forma es

$$Q = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 3 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Primero calculamos

$$QB = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 3 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix}$$

y luego

$$M = B^T QB = \begin{pmatrix} 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix} = (2)$$

La forma restringida es $\psi(y) = 2y^2$.

3. Clasificación. Como $2y^2 > 0$ para todo $y \neq 0$, la forma restringida es definida positiva.

Cuando queda una sola variable libre, el conjunto permitido es una recta y M es un número: la forma restringida siempre es del tipo $c\,y^2$, y su signo es el signo de c.

En este ejemplo el resultado se podía anticipar, porque φ ya es definida positiva sin restricciones. Los autovalores de Q son 1, por la tercera variable, y $2 \pm \sqrt{2}$, las raíces de $\lambda^2 - 4\lambda + 2$, que es el polinomio característico del bloque $\left(\begin{smallmatrix} 1 & -1 \\ -1 & 3 \end{smallmatrix}\right)$. Todos son positivos.

Conclusión: φ es definida positiva sobre la recta que determinan las dos restricciones. Como ya lo era en todo $\mathbb{R}^3$, la restricción no aporta información nueva

17 Menores

Definiciones de menores

Sea $A = \big(a_{ij}\big)_{i,j=1}^{n} \in \mathbb{R}^{n\times n}$ una matriz simétrica (aunque las definiciones de menores se aplican a cualquier matriz cuadrada, el contexto de formas cuadráticas usualmente implica simetría).

Notación. En todo el capítulo, el supraíndice entre paréntesis indica el *orden* del menor (el tamaño de la submatriz) y el subíndice indica las filas y columnas que se toman para calcularlo. En el subíndice, los índices de cada conjunto se escriben seguidos y sin llaves, como en a_{13}. El paréntesis evita confundir el orden con una potencia: $\Delta^{(2)}$ es un menor de orden 2, no Δ al cuadrado.

Menor (general) de orden k. Un *menor (general) de orden k* de A es el determinante de una submatriz $k \times k$ de A. Esta submatriz se forma seleccionando un conjunto $I = \{i_1, \dots, i_k\}$ de k índices de filas (con $i_1 < i_2 < \cdots < i_k$) y un conjunto $J = \{j_1, \dots, j_k\}$ de k índices de columnas (con $j_1 < j_2 < \cdots < j_k$). Si $A[I, J]$ denota la submatriz formada por las filas en I y las columnas en J, es decir, $A[I, J] = \big(a_{i_p j_q}\big)_{p,q=1}^{k}$, el menor es

$$M_{I,J}^{(k)} = \det\big(A[I, J]\big)$$

En el subíndice van primero las filas y después, separadas por una coma, las columnas. Por ejemplo, con las filas 1 y 3 y las columnas 2 y 3:

$$M_{13,23}^{(2)} = \det \begin{pmatrix} a_{12} & a_{13} \\ a_{32} & a_{33} \end{pmatrix}$$

Menor principal de orden k. Un *menor principal de orden k* es un menor de orden k donde el conjunto de índices de las filas seleccionadas es el mismo que el conjunto de índices de las columnas seleccionadas. Como las filas y las columnas coinciden, en el subíndice alcanza con escribir un solo conjunto: si $I = \{i_1, \dots, i_k\} \subseteq \{1, 2, \dots, n\}$ con $i_1 < i_2 < \cdots < i_k$, el menor principal asociado a I es

$$\Delta_I^{(k)} = M_{I,I}^{(k)} = \det\big(A[I, I]\big)$$

donde $A[I, I] = \big(a_{i_p i_q}\big)_{p,q=1}^{k}$. Estos son los determinantes de las submatrices principales de A. Por ejemplo, con las filas y columnas 1 y 3:

$$\Delta_{13}^{(2)} = \det \begin{pmatrix} a_{11} & a_{13} \\ a_{31} & a_{33} \end{pmatrix}$$

Menor principal líder de orden k. Un *menor principal líder* de orden k (también llamado *inicial* o *dominante*) es el menor principal obtenido al seleccionar las primeras k filas y las primeras k columnas de A, es decir, $I = \{1, 2, \dots, k\}$. Como ese conjunto queda determinado por el orden, alcanza con el supraíndice[10]:

$$\Delta^{(k)} = \Delta_{12\cdots k}^{(k)} = \det \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1k} \\ a_{21} & a_{22} & \cdots & a_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ a_{k1} & a_{k2} & \cdots & a_{kk} \end{pmatrix}$$

Para $k = n$ hay un único menor principal, que coincide con el líder: $\Delta^{(n)} = \det A$. En general, una matriz $n \times n$ tiene $\binom{n}{k}^2$ menores de orden k, $\binom{n}{k}$ menores principales de orden k y un único menor principal líder de orden k. En total tiene $2^n - 1$ menores principales: 7 si $n = 3$ y 15 si $n = 4$.

En resumen, para una matriz A

[10] En otros libros se escribe $|A_k|$ en lugar de $\Delta^{(k)}$, donde A_k es la submatriz $k \times k$ superior izquierda de A.

- *Menor (general) de orden k*, $M_{I,J}^{(k)}$: determinante de cualquier submatriz $k \times k$ (los índices de las k filas elegidas pueden ser distintos de los índices de las k columnas elegidas). Ejemplo: $M_{13,23}^{(2)}$.
- *Menor principal de orden k*, $\Delta_I^{(k)}$: determinante de una submatriz $k \times k$ formada tomando el mismo conjunto I de k índices para las filas y para las columnas. Ejemplo: $\Delta_{13}^{(2)} = M_{13,13}^{(2)}$.
- *Menor principal líder de orden k*, $\Delta^{(k)}$: determinante de la submatriz $k \times k$ superior izquierda de A. Es un caso particular de menor principal. Ejemplo: $\Delta^{(2)} = \Delta_{12}^{(2)}$.

Ejemplo: menores de una matriz 3×3

Sea

$$A = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 3 & 1 \\ 0 & 1 & 2 \end{pmatrix}$$

1. Menores de orden 1 (todos los elementos de A, $M_{i,j}^{(1)} = a_{ij}$):

$$\begin{array}{lll} M_{1,1}^{(1)} = 2 & M_{1,2}^{(1)} = -1 & M_{1,3}^{(1)} = 0 \\ M_{2,1}^{(1)} = -1 & M_{2,2}^{(1)} = 3 & M_{2,3}^{(1)} = 1 \\ M_{3,1}^{(1)} = 0 & M_{3,2}^{(1)} = 1 & M_{3,3}^{(1)} = 2 \end{array}$$

2. Menores principales de orden 1: Son los elementos de la diagonal, $\Delta_i^{(1)} = M_{i,i}^{(1)}$:

$$\Delta_1^{(1)} = 2 \qquad \Delta_2^{(1)} = 3 \qquad \Delta_3^{(1)} = 2$$

3. Menores de orden 2 (todas las submatrices 2×2): En la fila I y la columna J de la tabla está $M_{I,J}^{(2)}$, calculado con las filas I y las columnas J de A. Por ejemplo, $M_{12,13}^{(2)} = 2$:

	$J = \{1,2\}$	$J = \{1,3\}$	$J = \{2,3\}$
$I = \{1,2\}$	$\det \begin{pmatrix} 2 & -1 \\ -1 & 3 \end{pmatrix} = 5$	$\det \begin{pmatrix} 2 & 0 \\ -1 & 1 \end{pmatrix} = 2$	$\det \begin{pmatrix} -1 & 0 \\ 3 & 1 \end{pmatrix} = -1$
$I = \{1,3\}$	$\det \begin{pmatrix} 2 & -1 \\ 0 & 1 \end{pmatrix} = 2$	$\det \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} = 4$	$\det \begin{pmatrix} -1 & 0 \\ 1 & 2 \end{pmatrix} = -2$
$I = \{2,3\}$	$\det \begin{pmatrix} -1 & 3 \\ 0 & 1 \end{pmatrix} = -1$	$\det \begin{pmatrix} -1 & 1 \\ 0 & 2 \end{pmatrix} = -2$	$\det \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix} = 5$

Como A es simétrica, $M_{I,J}^{(2)} = M_{J,I}^{(2)}$: la tabla es simétrica respecto de su diagonal.

4. Menores principales de orden 2: Son los de la diagonal de la tabla ($I = J$):

$$\Delta_{12}^{(2)} = 5 \qquad \Delta_{13}^{(2)} = 4 \qquad \Delta_{23}^{(2)} = 5$$

5. Menores principales líderes: Son los menores principales $\Delta_1^{(1)}$, $\Delta_{12}^{(2)}$ y $\Delta_{123}^{(3)}$:

$$\Delta^{(1)} = \det\begin{pmatrix} 2 \end{pmatrix} = 2 \qquad \Delta^{(2)} = \det \begin{pmatrix} 2 & -1 \\ -1 & 3 \end{pmatrix} = 5 \qquad \Delta^{(3)} = \det A = 8$$

Clasificación de formas cuadráticas mediante menores

Sea la forma cuadrática

$$Q(x) = x^T A\, x$$

con A simétrica y $x \in \mathbb{R}^n$. Usamos la notación de la sección anterior: $\Delta^{(k)}$ es el menor principal líder de orden k y $\Delta_I^{(k)}$ es el menor principal de orden k asociado a un conjunto $I \subseteq \{1, \dots, n\}$ de k índices.

Criterio de Sylvester (definitud estricta)

- Q es *definida positiva* si y solo si

$$\Delta^{(k)} > 0 \quad \text{para todo } k = 1, \dots, n$$

- Q es *definida negativa* si y solo si

$$(-1)^k\, \Delta^{(k)} > 0 \quad \text{para todo } k = 1, \dots, n$$

Criterio para semidefinitud

- Q es *semidefinida positiva* si y solo si todos sus menores principales son no negativos: $\Delta_I^{(k)} \geq 0$ para todo $k = 1, \dots, n$ y todo $I \subseteq \{1, \dots, n\}$ con k elementos.
- Q es *semidefinida negativa* si y solo si $(-1)^k\, \Delta_I^{(k)} \geq 0$ para todo $k = 1, \dots, n$ y todo $I \subseteq \{1, \dots, n\}$ con k elementos.

Criterio para formas cuadráticas indefinidas

Q es *indefinida* si y solo si no es semidefinida positiva ni semidefinida negativa. Por el criterio anterior, esto ocurre si y solo si

- algún menor principal de orden par es negativo: $\Delta_I^{(k)} < 0$ con k par, o
- hay dos menores principales de orden impar con signos opuestos: $\Delta_I^{(k)} > 0$ y $\Delta_J^{(m)} < 0$ con k y m impares.

Observaciones

- El criterio de Sylvester da condiciones necesarias y suficientes para la *definitud* de Q. Para la *semidefinitud*, en cambio, pedir lo mismo a los menores líderes con desigualdad débil ($\Delta^{(k)} \geq 0$, o $(-1)^k \Delta^{(k)} \geq 0$) es necesario pero no suficiente: hay que revisar todos los menores principales $\Delta_I^{(k)}$.
- Toda matriz definida positiva es también semidefinida positiva, y toda matriz definida negativa es también semidefinida negativa.

Algunos casos posibles con una matriz simétrica 4×4

Sea A una matriz simétrica 4×4 y sean $\Delta^{(1)}, \Delta^{(2)}, \Delta^{(3)}, \Delta^{(4)}$ sus menores principales líderes. En la práctica conviene empezar por ellos: si cumplen alguna de las dos condiciones del criterio de Sylvester, A es definida; si alguno de orden par es negativo, o dos de orden impar tienen signos opuestos, A es indefinida; si no ocurre nada de esto, hay que revisar todos los menores principales.

(a) Si $\Delta^{(1)} > 0$, $\Delta^{(2)} > 0$, $\Delta^{(3)} > 0$ y $\Delta^{(4)} > 0$, entonces A es definida positiva.

(b) Si $\Delta^{(1)} < 0$, $\Delta^{(2)} > 0$, $\Delta^{(3)} < 0$ y $\Delta^{(4)} > 0$, entonces A es definida negativa.

(c) Si $\Delta^{(1)} > 0$, $\Delta^{(2)} > 0$, $\Delta^{(3)} = 0$ y $\Delta^{(4)} < 0$, entonces A es indefinida debido a $\Delta^{(4)} < 0$.

(d) Si $\Delta^{(1)} < 0$, $\Delta^{(2)} < 0$, $\Delta^{(3)} < 0$ y $\Delta^{(4)} < 0$, entonces A es indefinida debido a $\Delta^{(2)} < 0$ y $\Delta^{(4)} < 0$.

(e) Si $\Delta^{(1)} = 0$, $\Delta^{(2)} < 0$, $\Delta^{(3)} > 0$ y $\Delta^{(4)} = 0$, entonces A es indefinida debido a $\Delta^{(2)} < 0$.

(f) Si $\Delta^{(1)} > 0$, $\Delta^{(2)} = 0$, $\Delta^{(3)} = 0$ y $\Delta^{(4)} = 0$, entonces A no es definida. No es semidefinida negativa, pero puede ser semidefinida positiva. Para comprobar la semidefinitud positiva, es necesario verificar los 15 menores principales de A, no solo los cuatro líderes. Si ninguno es negativo, A es semidefinida positiva; si al menos uno es negativo, A es indefinida. En 3×3, las matrices C y E de los ejemplos de más abajo muestran las dos posibilidades.

(g) Si $\Delta^{(1)} = 0$, $\Delta^{(2)} = 0$, $\Delta^{(3)} = 0$ y $\Delta^{(4)} = 0$, entonces A no es definida, pero puede ser semidefinida positiva o semidefinida negativa (o indefinida). Para decidirlo, es necesario comprobar nuevamente los 15 menores principales de A.

Ejemplo

Sea

$$B = \begin{pmatrix} -4 & 1 & 0 \\ 1 & -3 & 1 \\ 0 & 1 & -2 \end{pmatrix}$$

Menor principal líder de orden 1

$$\Delta^{(1)} = \det\big(-4\big) = -4$$

Menor principal líder de orden 2

$$\Delta^{(2)} = \det \begin{pmatrix} -4 & 1 \\ 1 & -3 \end{pmatrix} = (-4)(-3) - 1 \cdot 1 = 12 - 1 = 11$$

Menor principal líder de orden 3

$$\begin{aligned} \Delta^{(3)} = \det B &= -4 \det \begin{pmatrix} -3 & 1 \\ 1 & -2 \end{pmatrix} - 1 \det \begin{pmatrix} 1 & 1 \\ 0 & -2 \end{pmatrix} + 0 \det \begin{pmatrix} 1 & -3 \\ 0 & 1 \end{pmatrix} \\ &= -4\big((-3)(-2) - 1 \cdot 1\big) - 1\big(1 \cdot (-2) - 1 \cdot 0\big) \\ &= -4(6 - 1) - 1(-2) = -20 + 2 = -18 \end{aligned}$$

Verificación del criterio de Sylvester

$$(-1)^1 \Delta^{(1)} = -(-4) = 4 > 0 \qquad (-1)^2 \Delta^{(2)} = 11 > 0$$
$$(-1)^3 \Delta^{(3)} = -(-18) = 18 > 0$$

Por tanto B es definida negativa.

Otro ejemplo

Sea

$$C = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

Menores principales de orden 1

$$\Delta_1^{(1)} = 1 \qquad \Delta_2^{(1)} = 1 \qquad \Delta_3^{(1)} = 0$$

Menores principales de orden 2

$$\Delta_{12}^{(2)} = \det \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = 0 \quad \Delta_{13}^{(2)} = \det \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = 0 \quad \Delta_{23}^{(2)} = \det \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = 0$$

Menor principal de orden 3

$$\Delta^{(3)} = \det C = 0$$

Como todos los menores principales son ≥ 0, C es semidefinida positiva según el criterio completo de semidefinitud positiva. No es definida positiva, porque $\Delta^{(2)} = \Delta_{12}^{(2)} = 0$ y el criterio de Sylvester pide $\Delta^{(k)} > 0$ para todo k.

Otro ejemplo

Sea

$$D = \begin{pmatrix} -1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

Menores principales de orden 1

$$\Delta_1^{(1)} = -1 \qquad \Delta_2^{(1)} = -2 \qquad \Delta_3^{(1)} = 0$$

Menores principales de orden 2

$$\Delta_{12}^{(2)} = \det \begin{pmatrix} -1 & 0 \\ 0 & -2 \end{pmatrix} = (-1)(-2) - 0 \cdot 0 = 2$$

$$\Delta_{13}^{(2)} = \det \begin{pmatrix} -1 & 0 \\ 0 & 0 \end{pmatrix} = (-1) \cdot 0 - 0 \cdot 0 = 0$$

$$\Delta_{23}^{(2)} = \det \begin{pmatrix} -2 & 0 \\ 0 & 0 \end{pmatrix} = (-2) \cdot 0 - 0 \cdot 0 = 0$$

Menor principal de orden 3

$$\Delta^{(3)} = \det D = 0$$

Verificación del criterio de semidefinitud negativa

$$(-1)^1\Delta_1^{(1)} = (-1)(-1) = 1 \geq 0 \qquad (-1)^1\Delta_2^{(1)} = (-1)(-2) = 2 \geq 0$$
$$(-1)^1\Delta_3^{(1)} = (-1)\cdot 0 = 0 \geq 0 \qquad (-1)^2\Delta_{12}^{(2)} = 2 \geq 0$$
$$(-1)^2\Delta_{13}^{(2)} = 0 \geq 0 \qquad (-1)^2\Delta_{23}^{(2)} = 0 \geq 0$$
$$(-1)^3\Delta^{(3)} = (-1)\cdot 0 = 0 \geq 0$$

Por tanto D es semidefinida negativa. No es definida negativa, porque $(-1)^3\Delta^{(3)} = 0$ y el criterio de Sylvester pide $(-1)^k\Delta^{(k)} > 0$ para todo k.

Otro ejemplo

Sea

$$E = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & -1 \end{pmatrix}$$

Menores principales líderes

$$\Delta^{(1)} = 1 \qquad \Delta^{(2)} = \det\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = 0 \qquad \Delta^{(3)} = \det E = 0$$

Son los mismos que los de C. Como $\Delta^{(2)} = 0$, E no es definida, y como $\Delta^{(1)} > 0$, tampoco es semidefinida negativa. Que los tres sean ≥ 0 no alcanza para concluir que sea semidefinida positiva: hay que revisar todos los menores principales.

Menores principales de orden 1

$$\Delta_1^{(1)} = 1 \qquad \Delta_2^{(1)} = 0 \qquad \Delta_3^{(1)} = -1$$

Menores principales de orden 2

$$\Delta_{12}^{(2)} = \det\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = 0 \qquad \Delta_{13}^{(2)} = \det\begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} = -1$$
$$\Delta_{23}^{(2)} = \det\begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix} = 0$$

Como $\Delta_{13}^{(2)} = -1 < 0$ es un menor principal de orden par negativo, E es indefinida. También alcanza con $\Delta_1^{(1)} = 1 > 0$ y $\Delta_3^{(1)} = -1 < 0$, dos menores principales de orden impar con signos opuestos.

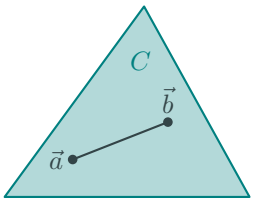
18 Concavidad y convexidad

Conjuntos convexos y no convexos

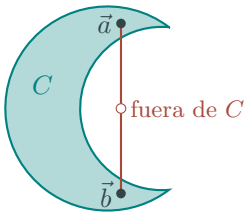
Un conjunto $C \subseteq \mathbb{R}^n$ es *convexo* si, para todo par de puntos $\vec{a}, \vec{b} \in C$ y todo $t \in [0,1]$, el punto

$$(1-t)\,\vec{a} + t\,\vec{b}$$

también pertenece a C. Es decir, el segmento que une dos puntos cualesquiera de C queda completamente dentro de C. Si para algún par de puntos el segmento se sale de C, el conjunto no es convexo.



Conjunto convexo

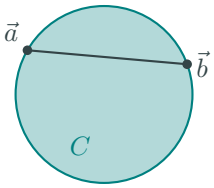


Conjunto no convexo

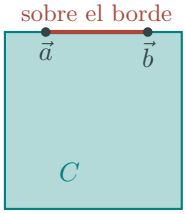
En $\mathbb{R}$, los conjuntos convexos son exactamente los intervalos. En $\mathbb{R}^2$, un triángulo como el de la figura, un rectángulo, un círculo y un semiplano son convexos; una media luna, como la de la figura, no lo es. La intersección de conjuntos convexos es convexa, porque un segmento que queda dentro de cada uno de ellos queda dentro de la intersección.

Conjuntos estrictamente convexos

Un conjunto convexo C es *estrictamente convexo* si, para todo par de puntos distintos $\vec{a}, \vec{b} \in C$ y todo $t \in (0,1)$, el punto $(1-t)\vec{a} + t\,\vec{b}$ es un punto interior de C, es decir, no está en el borde. Dicho de otro modo: el segmento que une dos puntos del conjunto, salvo en sus extremos, no toca el borde. Un círculo es estrictamente convexo: aunque $\vec{a}$ y $\vec{b}$ estén sobre la circunferencia, el resto del segmento queda adentro. Un cuadrado es convexo, pero no estrictamente: dos puntos de un mismo lado se unen por un segmento que queda sobre el borde. Entonces, un conjunto estrictamente convexo es un conjunto que, además de ser convexo, no tiene tramos rectos en el borde.



Estrictamente convexo



Convexo, pero no estrictamente

Definición de convexidad y concavidad para funciones de una variable

Sea $f\colon I \subseteq \mathbb{R} \to \mathbb{R}$, donde I es un intervalo. Decimos que:

- f es *convexa* si para todo $x_1, x_2 \in I$ y todo $t \in [0,1]$ se cumple

$$f\big((1-t)x_1 + t\,x_2\big) \;\leq\; (1-t)f(x_1) + t\,f(x_2)$$

Intuición geométrica. El término

$$(1-t)f(x_1) + t\,f(x_2)$$

coincide con el valor que adopta la recta secante en la posición intermedia $(1-t)x_1 + t\,x_2$. Por lo tanto, la desigualdad de la definición expresa que, en cada punto entre x_1 y x_2, la curva de f nunca queda por encima de esa secante.

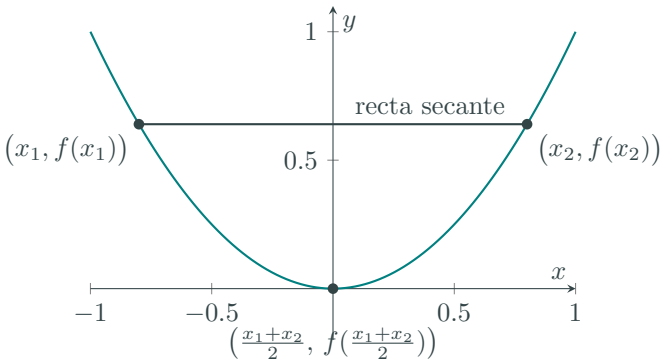
- f es *cóncava* si para todo $x_1, x_2 \in I$ y todo $t \in [0,1]$ se cumple

$$f\big((1-t)x_1 + t\,x_2\big) \;\geq\; (1-t)f(x_1) + t\,f(x_2)$$

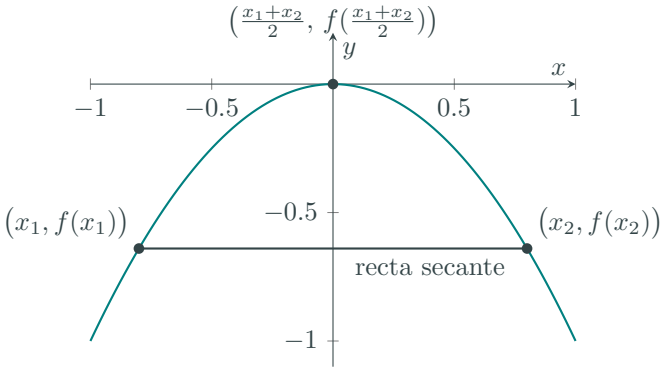
Intuición geométrica. Aquí la desigualdad se invierte: entre los puntos dados, el gráfico de f nunca queda por debajo de la recta secante.

En los gráficos siguientes, el punto del medio corresponde a $t = \frac{1}{2}$.

Ejemplo convexo: $f(x) = x^2$



Ejemplo cóncavo: $f(x) = -x^2$



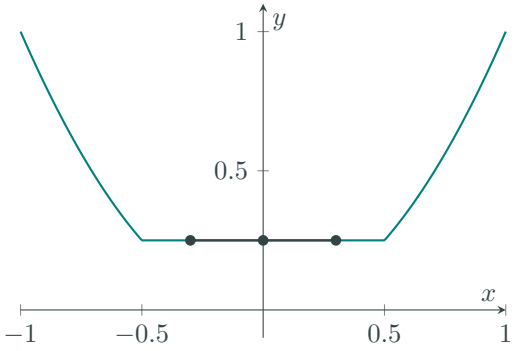
Los dos casos anteriores son de convexidad y concavidad **estrictas**: para cualquier par de puntos distintos, en el interior del segmento la curva queda estrictamente por debajo (o por encima) de la secante. Formalmente, f es *estrictamente convexa* si

$$f\big((1-t)x_1 + t\,x_2\big) \;<\; (1-t)f(x_1) + t\,f(x_2) \qquad \text{para todo } x_1 \neq x_2 \text{ en } I \text{ y todo } t \in (0,1)$$

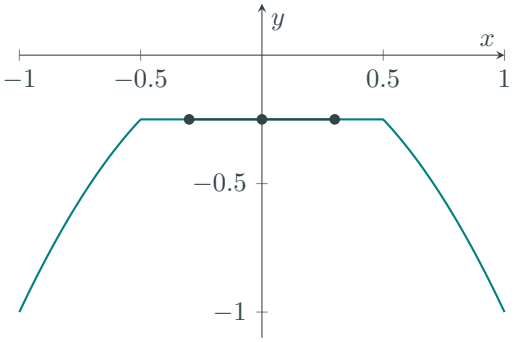
y es *estrictamente cóncava* si vale lo mismo con la desigualdad $>$.

También puede ocurrir que, para algunos pares de puntos, la secante coincida con la gráfica en un tramo. Ahí la desigualdad se cumple con igualdad y la función es convexa (o cóncava), pero no estrictamente. Es lo que pasa en los dos gráficos siguientes, que tienen un tramo recto en $[-\frac{1}{2}, \frac{1}{2}]$:

Convexa no estricta: $f(x) = \max\{x^2, \frac{1}{4}\}$



Cóncava no estricta: $f(x) = \min\{-x^2, -\frac{1}{4}\}$



Relacionando la concavidad y convexidad con conjuntos convexos

La convexidad y la concavidad de una función se pueden leer como la convexidad de un conjunto del plano:

- *Convexidad:* f es convexa si y solo si su *epígrafo*, la región

$$\big\{(x, y) \mid x \in I,\ y \geq f(x)\big\}$$

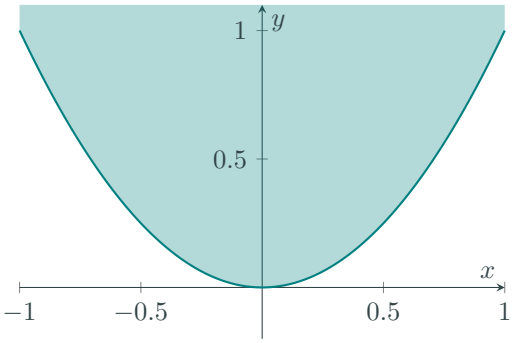
es un conjunto convexo. Esto significa que si tomamos dos puntos (x_1, y_1) y (x_2, y_2) por encima del gráfico de f, el segmento que los une nunca pasa por debajo de la curva.

- *Concavidad:* f es cóncava si y solo si su *hipógrafo*, la región

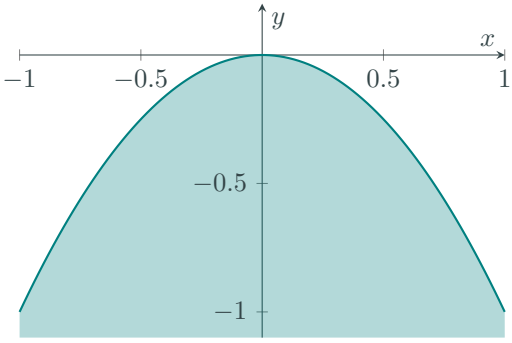
$$\big\{(x, y) \mid x \in I,\ y \leq f(x)\big\}$$

es un conjunto convexo. En este caso, cualquier segmento trazado entre dos puntos por debajo del gráfico de f queda enteramente dentro de esa región.

Epígrafo de $f(x) = x^2$



Hipógrafo de $f(x) = -x^2$



Concavidad y convexidad en $\mathbb{R}^2$

Definición. Sea $f\colon D \subseteq \mathbb{R}^2 \to \mathbb{R}$, donde D es un conjunto convexo (así, el segmento entre dos puntos de D queda dentro del dominio).

- f es *convexa* si para todo $\vec{a}, \vec{b} \in D$ y todo $t \in [0,1]$ se cumple

$$f\big((1-t)\,\vec{a} + t\,\vec{b}\big) \;\leq\; (1-t)\,f(\vec{a}) + t\,f(\vec{b})$$

- f es *cóncava* si $-f$ es convexa, es decir, si la desigualdad se invierte.

Como en una variable, f es *estrictamente* convexa (o cóncava) si la desigualdad es estricta para todo par de puntos distintos y todo $t \in (0,1)$. En $\mathbb{R}^n$ las definiciones son las mismas, con puntos de $D \subseteq \mathbb{R}^n$.
Intuición geométrica. La intuición se mantiene. Ahora la gráfica de f es una superficie, y la secante es el segmento que une los puntos de la superficie que están sobre $\vec{a}$ y sobre $\vec{b}$: si f es convexa, la superficie nunca queda por encima de ese segmento. Además, el epígrafo de una función convexa y el hipógrafo de una función cóncava siguen siendo conjuntos convexos.

Criterio de las derivadas segundas

Recordatorio: criterio para funciones de una variable. Sea $g\colon I \subseteq \mathbb{R} \to \mathbb{R}$ de clase C^2 en un intervalo I. Entonces

$$\begin{cases} g''(t) \geq 0 \quad \forall\, t \in I \implies g \text{ es convexa en } I \\ g''(t) \leq 0 \quad \forall\, t \in I \implies g \text{ es cóncava en } I \end{cases}$$

Con desigualdades estrictas, la conclusión también es estricta: si $g''(t) > 0$ para todo $t \in I$, g es estrictamente convexa, y si $g''(t) < 0$ para todo $t \in I$, g es estrictamente cóncava.

Funciones de dos variables

Sea $f\colon D \subseteq \mathbb{R}^2 \to \mathbb{R}$ de clase C^2, con D abierto y convexo. La desigualdad que define la convexidad de f solo involucra puntos de un segmento, así que alcanza con estudiar f sobre cada segmento. Para eso, dados dos puntos $\vec{a} = (x_1, y_1)^T$ y $\vec{b} = (x_2, y_2)^T$ de D, definimos

$$g(t) \;=\; f\big((1-t)x_1 + t\,x_2,\; (1-t)y_1 + t\,y_2\big), \quad t \in [0,1]$$

Vamos a ver que, si la hessiana es semidefinida positiva en todo D, g es convexa, porque su derivada segunda es la forma cuadrática de la hessiana en la dirección del segmento, y que su convexidad se transmite a f.

Intuición sobre g. Para entender qué hace g, primero observemos que

$$(x(t), y(t)) \;=\; \big((1-t)x_1 + t\,x_2,\; (1-t)y_1 + t\,y_2\big)$$

es la parametrización del segmento rectilíneo que une $\vec{a}$ y $\vec{b}$ en el plano. Por lo tanto,

$$g(t) \;=\; f\big(x(t), y(t)\big)$$

no es más que el valor de f al desplazarnos a lo largo de ese segmento:

- Cuando $t = 0$ estamos en $\vec{a}$.
- Cuando $t = 1$ estamos en $\vec{b}$.
- Para $t \in (0,1)$ recorremos los puntos intermedios.

Paso 1: cálculo de g''. Por la regla de la cadena aplicada a dos variables:

$$\begin{aligned} g'(t) &= f'_x\big(x(t),y(t)\big)\,\frac{d}{dt}\big((1-t)x_1 + t\,x_2\big) + f'_y\big(x(t),y(t)\big)\,\frac{d}{dt}\big((1-t)y_1 + t\,y_2\big) \\ &= f'_x(x(t),y(t))\,(x_2 - x_1) + f'_y(x(t),y(t))\,(y_2 - y_1) \end{aligned}$$

$$\begin{aligned} g''(t) &= \frac{d}{dt}\big[f'_x(x(t),y(t))\big]\,(x_2 - x_1) + \frac{d}{dt}\big[f'_y(x(t),y(t))\big]\,(y_2 - y_1) \\ &= \big[f''_{xx}(x(t),y(t))\,x'(t) + f''_{xy}(x(t),y(t))\,y'(t)\big]\,(x_2 - x_1) \\ &\quad + \big[f''_{yx}(x(t),y(t))\,x'(t) + f''_{yy}(x(t),y(t))\,y'(t)\big]\,(y_2 - y_1) \end{aligned}$$

Sabiendo que $x'(t) = x_2 - x_1$ y $y'(t) = y_2 - y_1$:

$$\begin{aligned} g''(t) = f''_{xx}(x(t),y(t))\,(x_2 - x_1)\,(x_2 - x_1) + f''_{xy}(x(t),y(t))\,(y_2 - y_1)\,(x_2 - x_1) \\ + f''_{yx}(x(t),y(t))\,(x_2 - x_1)\,(y_2 - y_1) + f''_{yy}(x(t),y(t))\,(y_2 - y_1)\,(y_2 - y_1) \end{aligned}$$

Como f es de clase C^2, por el teorema de Schwarz $f''_{xy} = f''_{yx}$, y se agrupan los términos mixtos:

$$g''(t) = f''_{xx}(x(t),y(t))\,(x_2-x_1)^2 + 2\,f''_{xy}(x(t),y(t))\,(x_2-x_1)(y_2-y_1) + f''_{yy}(x(t),y(t))\,(y_2-y_1)^2$$

Redefiniendo para mayor claridad:

$$w = x_2 - x_1 \qquad z = y_2 - y_1$$

$$g''(t) = f''_{xx}\big(x(t),y(t)\big)\,w^2 + 2\,f''_{xy}\big(x(t),y(t)\big)\,w\,z + f''_{yy}\big(x(t),y(t)\big)\,z^2$$

$$= \begin{pmatrix} w & z \end{pmatrix} \begin{pmatrix} f''_{xx}\big(x(t),y(t)\big) & f''_{xy}\big(x(t),y(t)\big) \\ f''_{xy}\big(x(t),y(t)\big) & f''_{yy}\big(x(t),y(t)\big) \end{pmatrix} \begin{pmatrix} w \\ z \end{pmatrix}$$

Paso 2: g es convexa. Si la matriz hessiana de f, la del paso 1, es semidefinida positiva en todo punto, entonces para cada $t \in [0,1]$

$$g''(t) \;\geq\; 0$$

y, por el criterio de una variable, g es convexa en $[0,1]$.

Paso 3: la convexidad de g pasa a f. Definamos la *recta secante* entre $(0,g(0))$ y $(1,g(1))$:

$$L(t) \;=\; g(0) \;+\; t\big(g(1)-g(0)\big) \;=\; (1-t)\,g(0) \;+\; t\,g(1)$$

Como g es convexa en $[0,1]$, la definición de convexidad aplicada a los puntos 0 y 1 da

$$g(t) = g\big((1-t)\cdot 0 + t\cdot 1\big) \;\leq\; (1-t)\,g(0) + t\,g(1) = L(t)$$

Finalmente, usando $g(0) = f(\vec{a})$ y $g(1) = f(\vec{b})$, concluimos

$$f\big((1-t)\,\vec{a} + t\,\vec{b}\big) \;=\; g(t) \;\leq\; (1-t)\,f(\vec{a}) \;+\; t\,f(\vec{b})$$

Como los puntos y t son arbitrarios, esta es precisamente la condición de convexidad de f en $\mathbb{R}^2$.

De forma análoga, si H_f es semidefinida *negativa*, entonces

$$g''(t) \leq 0 \quad\Longrightarrow\quad g(t) \geq (1-t)\,g(0) + t\,g(1)$$

y por lo tanto f es cóncava.

Extensión a $\mathbb{R}^n$

El mismo argumento se aplica en $\mathbb{R}^n$. Dados dos puntos $\vec{a},\vec{b} \in D \subseteq \mathbb{R}^n$, la función $g(t) = f\big((1-t)\vec{a} + t\,\vec{b}\big)$ tiene derivada segunda

$$g''(t) = (\vec{b}-\vec{a})^T\, H_f\big((1-t)\vec{a} + t\,\vec{b}\big)\,(\vec{b}-\vec{a})$$

Si la matriz hessiana es semidefinida positiva en todo punto, entonces $g''(t) \geq 0$, g es convexa y, por lo tanto, f es convexa. Análogamente, si la hessiana es semidefinida negativa en todo punto, f es cóncava.
Además, si la hessiana $H_f(\vec{x})$ es *definida positiva* en todo punto, entonces f es *estrictamente convexa* (para $\vec{a} \neq \vec{b}$ resulta $g''(t) > 0$, y por el caso estricto del criterio de una variable g es estrictamente convexa); y si $H_f(\vec{x})$ es *definida negativa* en todo punto, entonces f es *estrictamente cóncava*.

En resumen.

Hessiana $H_f(\vec{x})$	**Condición para todo $\vec{x} \in D,\ \vec{h} \in \mathbb{R}^n$**		**Función f**
Semidefinida positiva	$\vec{h}^T H_f(\vec{x})\,\vec{h} \;\geq\; 0$	$\Longleftrightarrow$	Convexa
Definida positiva	$\vec{h}^T H_f(\vec{x})\,\vec{h} \;>\; 0 \quad$ si $\vec{h} \neq \vec{0}$	$\Longrightarrow$	Estr. convexa
Semidefinida negativa	$\vec{h}^T H_f(\vec{x})\,\vec{h} \;\leq\; 0$	$\Longleftrightarrow$	Cóncava
Definida negativa	$\vec{h}^T H_f(\vec{x})\,\vec{h} \;<\; 0 \quad$ si $\vec{h} \neq \vec{0}$	$\Longrightarrow$	Estr. cóncava

(Aquí D, el dominio de f, es abierto y convexo. Las implicaciones $\Longrightarrow$ no valen al revés.[11])

Hessiana semidefinida, pero no definida. En este caso la tabla asegura que f es cóncava (o convexa), pero no dice si lo es estrictamente. Para decidirlo sirve una propiedad de las funciones cóncavas: si la desigualdad de la definición se cumple con igualdad para dos puntos distintos $\vec{a}, \vec{b}$ y algún $t \in (0,1)$, se cumple con igualdad en todo el segmento que los une.[12] Es decir, f es lineal sobre ese segmento: su gráfico tiene un tramo recto, como los de $\max\{x^2, \frac{1}{4}\}$ y $\min\{-x^2, -\frac{1}{4}\}$. Por eso, una función cóncava (o convexa) es estricta si y solo si no es lineal sobre ningún segmento de D. Sobre un segmento así, $g''(t) = 0$ para todo $t \in [0,1]$, de modo que el segmento va en una dirección $\vec{h} = \vec{b} - \vec{a}$ con $\vec{h}^T H_f(\vec{x})\,\vec{h} = 0$ en todos sus puntos: hay que buscarlo en esas direcciones. En particular, si la hessiana es definida en todo D salvo en puntos aislados, no hay ningún segmento así y f es estricta. Así se ve que x^4, el ejemplo de la nota 11, es estrictamente convexa: su derivada segunda, $12x^2$, solo se anula en $x = 0$.

Método 18.1 | Decidir si una función es cóncava o convexa, y si lo es estrictamente

Cuándo usarlo. Para decidir si una función f de clase C^2 en un dominio D abierto y convexo es cóncava, convexa o ninguna de las dos, y si lo es estrictamente.

Pasos.

1. Calcular las derivadas segundas y armar la hessiana $H_f(\vec{x})$ en un punto cualquiera de D, sin evaluarla en ningún punto en particular.
2. Calcular los menores principales líderes $\Delta^{(k)}$, los determinantes de las submatrices formadas por las primeras k filas y columnas. Si en todo D vale $\Delta^{(k)} > 0$ para todo k, la hessiana es definida positiva y f es estrictamente convexa. Si vale $(-1)^k \Delta^{(k)} > 0$ para todo k, es definida negativa y f es estrictamente cóncava.
3. Si no es definida en todo D, calcular todos los menores principales $\Delta_I^{(k)}$, los determinantes de las submatrices que toman las mismas k filas y columnas, las de un conjunto de índices I. Si en todo D vale $\Delta_I^{(k)} \geq 0$ para todos ellos, la hessiana es semidefinida positiva y f es convexa. Si vale $(-1)^k \Delta_I^{(k)} \geq 0$, es semidefinida negativa y f es cóncava. Si en algún punto de D la hessiana no es semidefinida positiva, f no es convexa; si no es semidefinida negativa, f no es cóncava.
4. Si la hessiana es semidefinida en todo D, pero no definida en algún punto, f es cóncava (o convexa) y falta ver si lo es estrictamente: no lo es si y solo si hay un segmento de D sobre el que f es lineal. Ese segmento se busca en una dirección $\vec{h}$ con $\vec{h}^T H_f(\vec{x})\,\vec{h} = 0$. Si la hessiana es definida salvo en puntos aislados, no hay ninguno y f es estricta.

Chequeo. La hessiana tiene que ser simétrica: $f''_{xy} = f''_{yx}$. Una forma de chequear es ver dos puntos de D y su punto medio: si f es cóncava, el valor de f en el punto medio no puede ser menor que el promedio de los valores en los extremos (si es convexa, no puede ser mayor).

Cuidado. La condición tiene que valer en todos los puntos de D: evaluar la hessiana en un solo punto no alcanza. Para la semidefinitud no alcanza con los menores principales líderes: hay que revisarlos todos. Y que la hessiana no sea definida en algún punto no quiere decir que f no sea estricta: x^4 es estrictamente convexa y su derivada segunda se anula en $x = 0$.

[11] Si D es abierto, las implicaciones para la convexidad y la concavidad valen también al revés. Si f es convexa, para cada $\vec{x} \in D$ y cada dirección $\vec{h}$ la función $t \mapsto f(\vec{x} + t\,\vec{h})$ es convexa cerca de $t = 0$, así que su derivada segunda en $t = 0$, que es $\vec{h}^T H_f(\vec{x})\,\vec{h}$, es mayor o igual que cero: $H_f(\vec{x})$ es semidefinida positiva. Para las versiones estrictas, en cambio, la recíproca es falsa: $f(x) = x^4$ es estrictamente convexa y $f''(0) = 0$. En dos variables, $x^4 + y^4$ es estrictamente convexa y su hessiana en el origen es la matriz nula.

[12] Llamemos $\vec{p}$ al punto donde vale la igualdad. Si en otro punto $\vec{c}$ del segmento f quedara estrictamente por encima de la secante, la secante que une el punto del gráfico sobre $\vec{c}$ con el del extremo que está del otro lado de $\vec{p}$ pasaría estrictamente por encima de la original en $\vec{p}$. Por la concavidad, $f(\vec{p})$ no puede quedar por debajo de esa secante, así que quedaría estrictamente por encima de la original, y eso contradice que en $\vec{p}$ valga la igualdad.

Operaciones que conservan la concavidad y la convexidad

Muchas veces se puede decidir si una función es cóncava o convexa sin armar su hessiana, viendo cómo está construida a partir de funciones que ya sabemos que lo son. En esta sección, todas las funciones están definidas en un mismo conjunto convexo D. Las funciones lineales, como $x+y$ o una constante, son cóncavas y convexas a la vez, porque cumplen la definición con igualdad.

Combinaciones con coeficientes no negativos.

$$f_1, \dots, f_m \text{ cóncavas y } \lambda_1, \dots, \lambda_m \geq 0 \implies \lambda_1 f_1 + \cdots + \lambda_m f_m \text{ cóncava}$$

Lo mismo vale con convexas. Para verlo, alcanza con multiplicar por λ_i la desigualdad de la definición de cada f_i y sumar: como los λ_i no son negativos, ninguna desigualdad cambia de sentido. Por ejemplo, $3\sqrt{x} + 2\ln y$ es cóncava en $\{(x,y) \mid x > 0,\ y > 0\}$, porque $\sqrt{x}$ y $\ln y$ son cóncavas: cada una depende de una sola variable y tiene derivada segunda negativa, $-\frac{1}{4}x^{-3/2}$ y $-1/y^2$. Del mismo modo, $x^2 + 4e^y$ es convexa en $\mathbb{R}^2$. En cambio, en $x^2 - y^2$ el coeficiente de y^2 es negativo, y la función no es cóncava ni convexa: sobre el eje x vale x^2, que no es cóncava, y sobre el eje y vale $-y^2$, que no es convexa (si f fuera cóncava o convexa, también lo sería sobre cada recta).

Composición. Sea $h = g \circ f$, donde g es una función de una variable definida en un intervalo que contiene los valores de f.

$$f \text{ cóncava y } g \text{ creciente y cóncava} \implies h \text{ cóncava}$$

Lo mismo vale con convexas: si f es convexa y g es creciente y convexa, h es convexa. En el caso cóncavo,

$$g\Big(f\big((1-t)\,\vec{a} + t\,\vec{b}\big)\Big) \;\geq\; g\big((1-t)\,f(\vec{a}) + t\,f(\vec{b})\big) \;\geq\; (1-t)\,g\big(f(\vec{a})\big) + t\,g\big(f(\vec{b})\big)$$

La primera desigualdad vale porque f es cóncava y g es creciente; la segunda, porque g es cóncava. Por ejemplo, $e^{x^2+y^2}$ es convexa en $\mathbb{R}^2$, porque $x^2 + y^2$ es convexa y e^z es creciente y convexa, y $\ln(x+y)$ es cóncava en $\{(x,y) \mid x + y > 0\}$, porque $x + y$ es lineal y $\ln z$ es creciente y cóncava. Que g sea creciente hace falta: x^2 es convexa y $g(z) = -z$ también (es lineal), pero $g(x^2) = -x^2$ no es convexa.

Máximo y mínimo.

$$f_1, f_2 \text{ convexas} \implies \max\{f_1, f_2\} \text{ convexa} \qquad f_1, f_2 \text{ cóncavas} \implies \min\{f_1, f_2\} \text{ cóncava}$$

Si $f = \max\{f_1, f_2\}$, para cada i se cumple

$$f_i\big((1-t)\,\vec{a} + t\,\vec{b}\big) \;\leq\; (1-t)\,f_i(\vec{a}) + t\,f_i(\vec{b}) \;\leq\; (1-t)\,f(\vec{a}) + t\,f(\vec{b})$$

porque $f_i \leq f$. Como vale para las dos, vale para su máximo. Así se ve que $\max\{x^2, \frac{1}{4}\}$, la de los gráficos de más arriba, es convexa: x^2 y la constante $\frac{1}{4}$ lo son. Del mismo modo, $\min\{-x^2, -\frac{1}{4}\}$ es cóncava. Al revés no vale: x y $-x$ son cóncavas, pero su máximo, $|x|$, no lo es.

Ejemplos

Ejemplo

Consideremos la función

$$f(x,y) \;=\; x^2 \;+\; 2\,x\,y \;+\; 3\,y^2 \qquad (x,y) \in \mathbb{R}^2$$

Cálculo de la hessiana. Las derivadas parciales primeras son

$$f'_x = 2x + 2y, \qquad f'_y = 2x + 6y$$

y las segundas son

$$f''_{xx} = 2, \quad f''_{xy} = 2, \quad f''_{yy} = 6$$

Por lo tanto, la matriz hessiana es

$$H_f(x,y) = \begin{pmatrix} 2 & 2 \\ 2 & 6 \end{pmatrix}$$

Comprobación de definitud (criterio de Sylvester). Calculamos los menores principales líderes:

$$\Delta^{(1)} = f''_{xx} = 2 > 0 \qquad \Delta^{(2)} = \det H_f = (2)(6) - (2)^2 = 12 - 4 = 8 > 0$$

Como $\Delta^{(1)} > 0$ y $\Delta^{(2)} > 0$, H_f es *definida positiva* en todo $\mathbb{R}^2$.

Conclusión. Al ser su hessiana definida positiva para todo (x, y), la función f es *estrictamente convexa* en $\mathbb{R}^2$.

Otro ejemplo

Consideremos

$$f(x,y) = -x^2 + 2\,x\,y - y^2 \qquad (x,y) \in \mathbb{R}^2$$

Cálculo de la hessiana. Las derivadas parciales primeras son

$$f'_x = -2x + 2y, \qquad f'_y = 2x - 2y$$

y las segundas son

$$f''_{xx} = -2, \quad f''_{xy} = 2, \quad f''_{yy} = -2$$

Por lo tanto, la matriz hessiana es

$$H_f(x,y) = \begin{pmatrix} -2 & 2 \\ 2 & -2 \end{pmatrix}$$

Comprobación de semidefinitud. Los menores principales líderes son

$$\Delta^{(1)} = f''_{xx} = -2 < 0 \qquad \Delta^{(2)} = \det H_f = (-2)(-2) - 2^2 = 4 - 4 = 0$$

Como $\Delta^{(2)} = 0$, H_f no es definida negativa: el criterio de Sylvester pediría $(-1)^2\Delta^{(2)} > 0$. Para ver si es semidefinida negativa hay que revisar todos los menores principales:

$$(-1)^1\Delta_1^{(1)} = 2 \geq 0 \qquad (-1)^1\Delta_2^{(1)} = 2 \geq 0 \qquad (-1)^2\Delta_{12}^{(2)} = 0 \geq 0$$

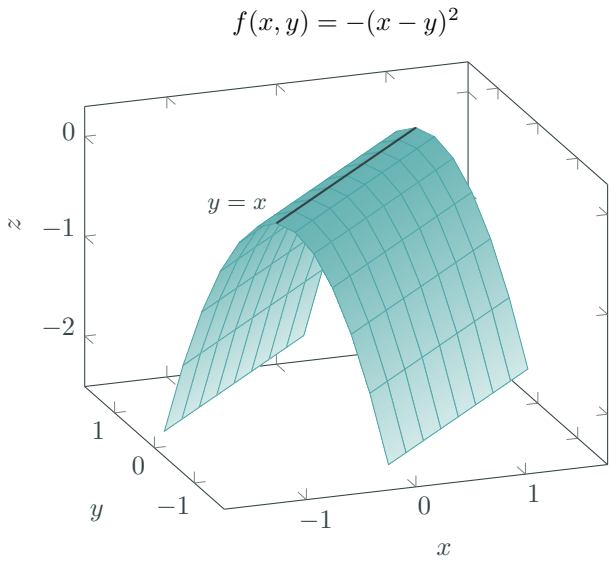
Entonces H_f es *semidefinida negativa* en todo $\mathbb{R}^2$, pero no definida negativa, y f es cóncava.

¿Es estrictamente cóncava? Que la hessiana no sea definida negativa no alcanza para responder, porque esa condición es suficiente pero no necesaria (ver la nota 11). Lo comprobamos con la definición. Como $f(x,y) = -(x-y)^2$, la función vale 0 en todos los puntos de la recta $y = x$. Con $\vec{a} = (0,0)^T$, $\vec{b} = (1,1)^T$ y $t = \frac{1}{2}$,

$$f\left(\tfrac{1}{2}\vec{a} + \tfrac{1}{2}\vec{b}\right) = f\left(\tfrac{1}{2}, \tfrac{1}{2}\right) = 0 = \tfrac{1}{2}f(\vec{a}) + \tfrac{1}{2}f(\vec{b})$$

La desigualdad se cumple con igualdad, así que f no es estrictamente cóncava.

Lo mismo pasa sobre cualquier recta paralela a $y = x$: como f solo depende de la diferencia $x - y$, es constante a lo largo de cada una. Su gráfico es una canaleta dada vuelta, con la parte más alta sobre la recta $y = x$:



Esa dirección, la de la recta $y = x$, es justamente aquella en la que se anula la forma cuadrática de la hessiana, y por eso la hessiana no es definida: con $\vec{h} = (1,1)^T$,

$$\vec{h}^T H_f \vec{h} = \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} -2 & 2 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix} = 0$$

Conclusión. La hessiana de f es semidefinida negativa, pero no definida negativa: f es *cóncava*, pero no estrictamente cóncava.

Un ejemplo en el que importa el dominio

Consideremos

$$f(x,y) = x^3 + y^2$$

primero en $D = \{(x,y) \in \mathbb{R}^2 \mid x > 0\}$, que es abierto y convexo (es un semiplano), y después en todo $\mathbb{R}^2$.

Cálculo de la hessiana. Las derivadas parciales primeras son

$$f'_x = 3x^2, \qquad f'_y = 2y$$

y las segundas son

$$f''_{xx} = 6x, \quad f''_{xy} = 0, \quad f''_{yy} = 2$$

Por lo tanto, la matriz hessiana es

$$H_f(x,y) = \begin{pmatrix} 6x & 0 \\ 0 & 2 \end{pmatrix}$$

A diferencia de los ejemplos anteriores, la hessiana depende del punto, así que hay que estudiarla en todo el dominio.

En $D = \{x > 0\}$. Los menores principales líderes son

$$\Delta^{(1)} = 6x > 0 \qquad \Delta^{(2)} = \det H_f = 12x > 0$$

porque $x > 0$ en todo D. La hessiana es definida positiva en todo D, así que f es estrictamente convexa en D.

En $\mathbb{R}^2$. Ahora también hay puntos con $x < 0$. En $(-1, 0)$, por ejemplo,

$$H_f(-1,0) = \begin{pmatrix} -6 & 0 \\ 0 & 2 \end{pmatrix}$$

y sus menores principales de orden 1 son $\Delta_1^{(1)} = -6$ y $\Delta_2^{(1)} = 2$. Como uno es negativo, la hessiana no es semidefinida positiva, y como el otro es positivo, tampoco es semidefinida negativa. Por lo tanto, f no es convexa ni cóncava en $\mathbb{R}^2$. También se ve sin la hessiana: sobre el eje x, $f(x, 0) = x^3$, que no es convexa ni cóncava.

Conclusión. f es estrictamente convexa en $D = \{x > 0\}$, pero en $\mathbb{R}^2$ no es convexa ni cóncava: la condición sobre la hessiana tiene que valer en todos los puntos del dominio.

19 Cuasiconcavidad y cuasiconvexidad

En Economía, muchas veces, más allá de la concavidad o convexidad de una función, es importante la concavidad o convexidad de las curvas de nivel de dicha función. Esta propiedad de las curvas de nivel hace referencia a la cuasiconcavidad. Empecemos definiendo lo que es un conjunto de nivel para poder definir la convexidad o concavidad de las curvas de nivel.

Conjuntos de nivel

Sea $f\colon D \subseteq \mathbb{R}^n \to \mathbb{R}$, con D convexo. Recordemos que la *curva de nivel* de f para un valor α es el conjunto

$$\{\,\vec{x} \in D : f(\vec{x}) = \alpha\}$$

Los *conjuntos de nivel* son las regiones delimitadas por esas curvas. Hay dos, según de qué lado de la curva queda la región: el *subnivel* es la región donde f toma valores por debajo de α, y el *supernivel*, la región donde toma valores por arriba de α. En los dos casos la curva de nivel queda incluida:

$$L_\alpha(f) = \{\,\vec{x} \in D : f(\vec{x}) \leq \alpha\}$$
$$U^\alpha(f) = \{\,\vec{x} \in D : f(\vec{x}) \geq \alpha\}$$

Definición

Recordemos que un conjunto es *convexo* si el segmento que une dos puntos cualesquiera del conjunto queda dentro de él.

- f es *cuasiconvexa* si todos sus *subniveles* $L_\alpha(f)$ son conjuntos convexos.
- f es *cuasicóncava* si todos sus *superniveles* $U^\alpha(f)$ son conjuntos convexos.

Equivalentemente, f es cuasiconvexa si y solo si, para todo $\vec{a}, \vec{b} \in D$ y todo $t \in [0,1]$,

$$f\big((1-t)\vec{a} + t\,\vec{b}\big) \leq \max\{f(\vec{a}), f(\vec{b})\}$$

y es cuasicóncava si y solo si

$$f\big((1-t)\vec{a} + t\,\vec{b}\big) \geq \min\{f(\vec{a}), f(\vec{b})\}$$

En palabras: a lo largo de cualquier segmento, una función cuasicóncava nunca baja del menor de sus dos valores en los extremos, y una cuasiconvexa nunca supera el mayor.
Con esta forma se ve enseguida que:

- Toda función *cóncava* es *cuasicóncava*, porque $(1-t)f(\vec{a}) + t\,f(\vec{b})$ es un promedio de $f(\vec{a})$ y $f(\vec{b})$, y un promedio nunca es menor que el mínimo:

$$f\big((1-t)\vec{a} + t\,\vec{b}\big) \geq (1-t)f(\vec{a}) + t\,f(\vec{b}) \geq \min\{f(\vec{a}), f(\vec{b})\}$$

- Toda función *convexa* es *cuasiconvexa*, por el argumento análogo con el máximo.

Versión estricta

Recordemos que un conjunto convexo es *estrictamente convexo* si el segmento que une dos puntos cualesquiera del conjunto, salvo en sus extremos, no toca el borde: un círculo lo es, y un cuadrado no, porque su borde tiene tramos rectos. Para f continua en un dominio abierto:

- f es **estrictamente cuasiconvexa** si cada subnivel $L_\alpha(f)$ es un conjunto estrictamente convexo y f no tiene mesetas.

- f es **estrictamente cuasicóncava** si cada supernivel $U^\alpha(f)$ es un conjunto estrictamente convexo y f no tiene mesetas.

Que f no tenga *mesetas* significa que no hay ningún círculo, por chico que sea, en el que f tome el mismo valor en todos los puntos.[13] Equivalentemente, las desigualdades de la definición son estrictas: para todo $\vec{a} \neq \vec{b}$ en D y todo $t \in (0,1)$,

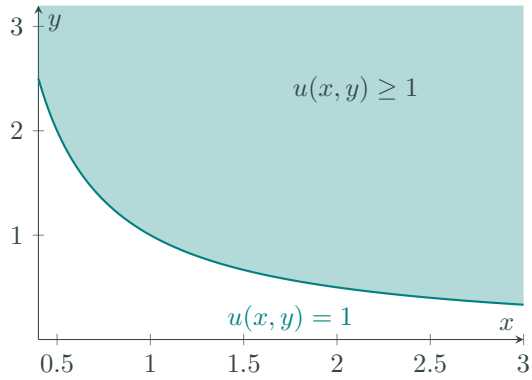
$$f\big((1-t)\vec{a} + t\,\vec{b}\big) < \max\{f(\vec{a}), f(\vec{b})\} \quad \text{(estrictamente cuasiconvexa)}$$

$$f\big((1-t)\vec{a} + t\,\vec{b}\big) > \min\{f(\vec{a}), f(\vec{b})\} \quad \text{(estrictamente cuasicóncava)}$$

Ejemplos gráficos

En los siguientes ejemplos graficamos una curva de nivel de cada función y sombreamos el supernivel o el subnivel correspondiente. Cada gráfico muestra un solo nivel α, pero la definición pide que los superniveles (o subniveles) sean convexos para *todo* α; en estas funciones, los demás niveles tienen la misma forma que el dibujado. Para mostrar que una función *no* es cuasicóncava (o cuasiconvexa), en cambio, alcanza con un solo nivel cuyo supernivel (o subnivel) no sea convexo, como en el gráfico "No cuasiconvexa" de los casos univariables.

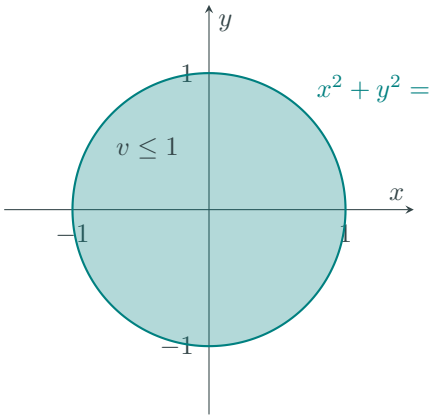
Estrictamente cuasicóncava, pero no cóncava: $u(x,y) = xy$, $x > 0$, $y > 0$



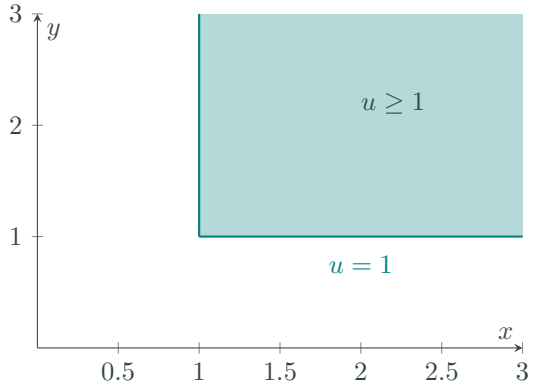
[13] El círculo de centro $\vec{c}$ y radio $r > 0$ es el conjunto de los puntos que están a distancia menor que r de $\vec{c}$: la región encerrada por una circunferencia. En más de dos variables se llama bola, y en una variable, con centro $c \in \mathbb{R}$, es el intervalo $(c-r,\, c+r)$. Que f tome el mismo valor en muchos puntos cercanos entre sí no es una meseta: eso pasa a lo largo de cualquier curva de nivel. En una meseta, f toma el mismo valor en todos los puntos alrededor de uno dado, en todas las direcciones. En una variable, la condición dice que el gráfico de f no tiene tramos horizontales.

La condición no se puede omitir. Una función constante tiene como superniveles a todo su dominio o al conjunto vacío, que son estrictamente convexos, y sin embargo no es estrictamente cuasicóncava: al maximizarla, todos los puntos son óptimos. Un ejemplo menos trivial es $f(x,y) = \min\{0,\, 1 - \sqrt{x^2+y^2}\}$. Para $\alpha < 0$, la curva de nivel α es la circunferencia de radio $1-\alpha$, y el supernivel es el círculo que encierra. Pero el conjunto donde f vale 0 no es una curva: es todo el círculo de radio 1, porque ahí $1 - \sqrt{x^2+y^2} \geq 0$ y el mínimo vale 0. Esa es la meseta. Todos los superniveles no vacíos son círculos, estrictamente convexos, y sin embargo la desigualdad estricta falla: con $\vec{a} = (0,0)^T$ y $\vec{b} = (\frac{1}{2}, 0)^T$ resulta $f(\vec{a}) = f(\vec{b}) = 0$, y en el punto medio f también vale 0, no más que el mínimo. Con esta condición, una función estrictamente cuasicóncava alcanza su máximo en un conjunto convexo, si lo tiene, en un solo punto: si lo alcanzara en dos, en el punto medio valdría más.

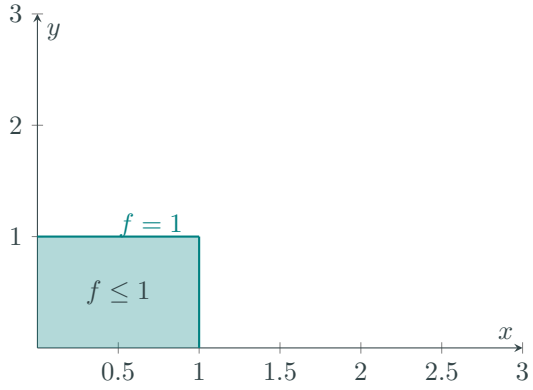
Estrictamente cuasiconvexa: $v(x,y) = x^2 + y^2$



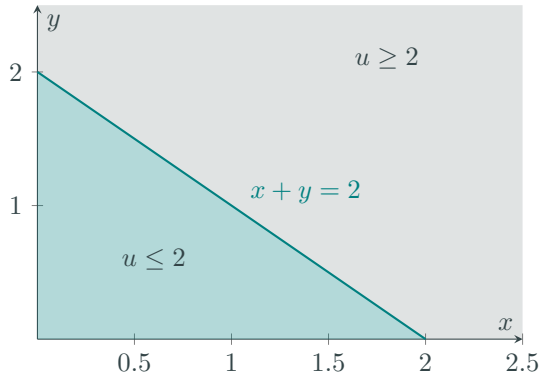
Cuasicóncava (no estricta): $u(x,y) = \min\{x,y\}$



Cuasiconvexa (no estricta): $f(x,y) = \max\{x,y\}$



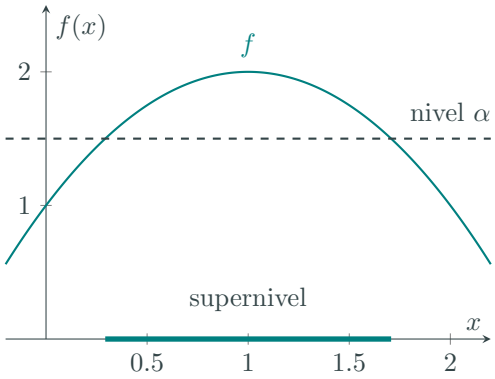
Cuasiconvexa (no estricta) y cuasicóncava (no estricta): $u(x, y) = x + y$



Casos univariables

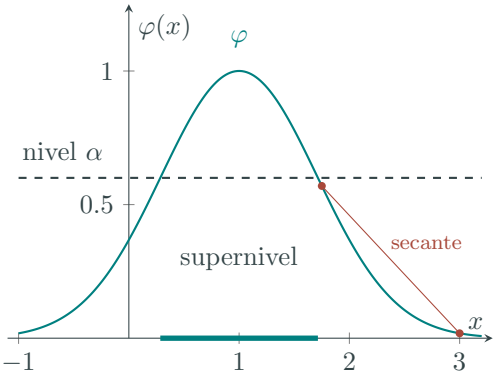
Para funciones de una sola variable el análisis gráfico es análogo. Los subniveles y superniveles son ahora subconjuntos de la recta: son convexos cuando forman un solo intervalo y no lo son cuando quedan cortados en varios pedazos.

Cuasicóncava

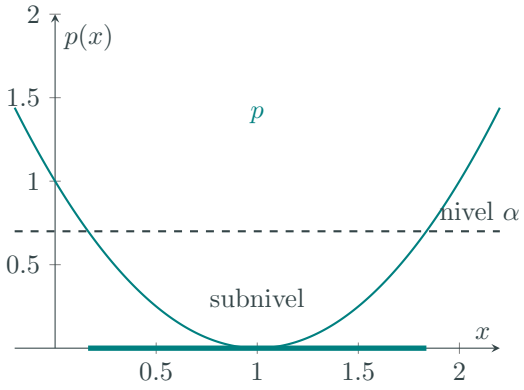


La función del gráfico anterior es cóncava. La campana $\varphi(x) = e^{-(x-1)^2}$ muestra que la cuasiconcavidad es más débil: es cuasicóncava, porque crece hasta $x = 1$ y después decrece, así que sus superniveles son intervalos; pero no es cóncava, porque en las colas se curva hacia arriba ($\varphi''(x) > 0$ cuando $|x - 1| > 1/\sqrt{2}$) y ahí la curva queda por debajo de sus secantes.

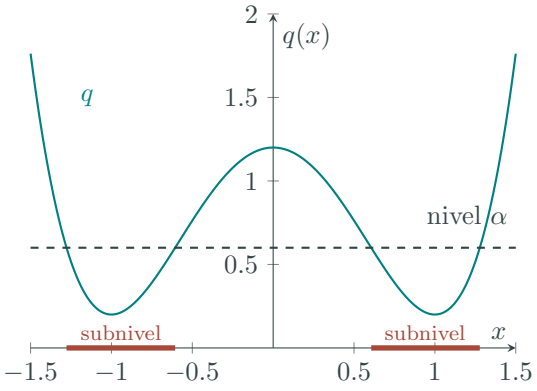
Cuasicóncava, pero no cóncava



Cuasiconvexa



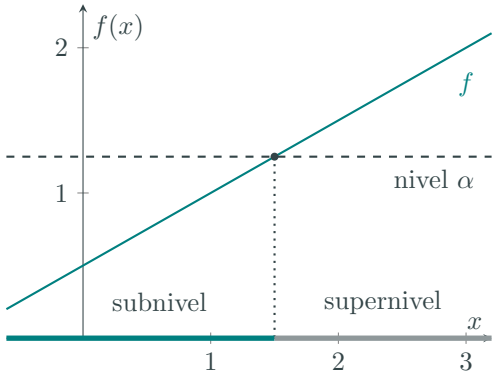
No cuasiconvexa



Teorema (monotonicidad, cuasiconcavidad y cuasiconvexidad en una variable). Sea $f\colon I \to \mathbb{R}$, con $I \subseteq \mathbb{R}$ un intervalo. Si f es creciente o decreciente en I, entonces es cuasicóncava y cuasiconvexa en I. Si es estrictamente creciente o estrictamente decreciente, es estrictamente cuasicóncava y estrictamente cuasiconvexa. Si f es derivable, alcanza con que $f'(x) \geq 0$ para todo $x \in I$, o $f'(x) \leq 0$ para todo $x \in I$; para la versión estricta, con que además f' se anule solo en puntos aislados, como la derivada de x^3 en $x = 0$.

La razón es que los subniveles y los superniveles de una función monótona son siempre intervalos. En el gráfico siguiente, f es una recta con pendiente positiva, y por lo tanto creciente: los puntos donde f queda por debajo del nivel α forman una semirrecta hacia la izquierda, y los puntos donde queda por arriba, una semirrecta hacia la derecha. Las dos son intervalos, y lo mismo pasa con cualquier otro nivel.

Creciente: cuasicóncava y cuasiconvexa



En una variable vale además una caracterización completa: una función continua es cuasicóncava si y solo si es monótona o primero crece y después decrece (tiene un solo pico), y es cuasiconvexa si y solo si es monótona o primero decrece y después crece.

Criterio de hessiano orlado para cuasiconvexidad y cuasiconcavidad

Sea $f\colon D \subseteq \mathbb{R}^n \to \mathbb{R}$ de clase C^2 en un conjunto D abierto y convexo. Definimos el *hessiano orlado* de f en $\vec{x}$ como la matriz

$$B(\vec{x}) = \begin{pmatrix} 0 & \nabla f(\vec{x})^T \\ \nabla f(\vec{x}) & H_f(\vec{x}) \end{pmatrix}$$

donde $H_f(\vec{x})$ es la hessiana usual de f y el gradiente $\nabla f(\vec{x})$ es un vector columna. Para $k = 1, \dots, n$ llamamos B_k a la submatriz formada por el borde y las primeras k variables, y $|B_k|$ a su determinante (para abreviar, escribimos $f'_i = f'_{x_i}$ y $f''_{ij} = f''_{x_i x_j}$):

$$B_k = \begin{pmatrix} 0 & f'_1 & \cdots & f'_k \\ f'_1 & f''_{11} & \cdots & f''_{1k} \\ \vdots & \vdots & \ddots & \vdots \\ f'_k & f''_{k1} & \cdots & f''_{kk} \end{pmatrix}$$

Es $\Delta^{(k+1)}$, el menor principal líder de orden $k+1$ de B: el determinante de la submatriz formada por sus primeras $k+1$ filas y columnas. El menor de orden 1 es siempre 0 y no interviene.
Las condiciones se evalúan en todo $\vec{x} \in D$ y para $k = 1, \dots, n$:

	Condición necesaria	**Condición suficiente (y estricta)**
Cuasicóncava	$(-1)^k \lvert B_k\rvert \geq 0$	$(-1)^k \lvert B_k\rvert > 0$
Cuasiconvexa	$\lvert B_k\rvert \leq 0$	$\lvert B_k\rvert < 0$

En palabras: para la cuasiconcavidad, $|B_1|, |B_2|, \dots, |B_n|$ alternan de signo empezando por el negativo; para la cuasiconvexidad, son todos negativos. La condición necesaria admite ceros y se cumple siempre que f tenga la propiedad. La suficiente pide desigualdades estrictas y, cuando se cumple, asegura además la versión estricta.

Observación. Siempre vale

$$|B_1| = \det \begin{pmatrix} 0 & f'_1 \\ f'_1 & f''_{11} \end{pmatrix} = -(f'_1)^2 \leq 0$$

Por eso las dos condiciones necesarias empiezan igual, y la condición suficiente pide $|B_1| < 0$, es decir, $f'_1 \neq 0$. Por ejemplo, para $v(x, y) = x^2 + y^2$ resulta $|B_1| = -4x^2$ y $|B_2| = -8(x^2 + y^2)$: en el semiplano $x > 0$ se

cumple la condición suficiente de cuasiconvexidad estricta, pero sobre el eje $x = 0$ el criterio no concluye, aunque v es estrictamente cuasiconvexa en todo $\mathbb{R}^2$. Las condiciones suficientes no son necesarias.

Ejemplo

Sea

$$f\colon A \to \mathbb{R}, \qquad A = \{(x,y) \in \mathbb{R}^2 : x > 0,\ y > 0\}, \quad f(x,y) = x\,y$$

Derivadas parciales y hessiana.

$$f'_x = y, \quad f'_y = x, \qquad H_f(x,y) = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

Hessiano orlado. Definimos las siguientes matrices:

$$B_1 = \begin{pmatrix} 0 & y \\ y & 0 \end{pmatrix} \qquad B_2 = \begin{pmatrix} 0 & y & x \\ y & 0 & 1 \\ x & 1 & 0 \end{pmatrix}$$

Cálculo de determinantes.

$$|B_1| = -\,y^2 \qquad |B_2| = 2\,x\,y$$

Para probar que f es estrictamente cuasicóncava usamos directamente la condición suficiente: alcanza con que $|B_1| < 0$ y $|B_2| > 0$ en todo A. Como $x, y > 0$, ambas se cumplen.
Conclusión. $f(x,y) = x\,y$ es estrictamente cuasicóncava en A.

Observación. En cambio, xy no es cóncava: su hessiana tiene $\Delta^{(2)} = \det H_f = -1 < 0$, así que es indefinida. Es el ejemplo típico de una función cuasicóncava que no es cóncava.

Relación y diferencias entre cuasiconcavidad y concavidad (o cuasiconvexidad y convexidad)

- **Relación entre ambas.**
  - Toda función *cóncava* es *cuasicóncava*, pero la recíproca no es cierta: xy es cuasicóncava en A y no es cóncava (ver el ejemplo anterior).
  - Toda función *convexa* es *cuasiconvexa*, pero la recíproca no es cierta: x^3 es creciente, y por lo tanto cuasiconvexa, pero no es convexa, porque su derivada segunda $6x$ es negativa para $x < 0$.
  - Toda función *estrictamente cóncava* es *estrictamente cuasicóncava*. La recíproca tampoco vale: $\sqrt{xy}$ es estrictamente cuasicóncava en A ($|B_1| = -\frac{y}{4x} < 0$ y $|B_2| = \frac{1}{4\sqrt{xy}} > 0$), pero no es estrictamente cóncava: sobre cada rayo que sale del origen es lineal, porque $\sqrt{(\lambda x)(\lambda y)} = \lambda\sqrt{xy}$ para $\lambda > 0$, así que ahí la desigualdad de concavidad se cumple con igualdad. Por ejemplo, en $(1,1)^T$ y $(2,2)^T$ vale 1 y 2, y en el punto medio, $\frac{3}{2} = 1.5$.
  - Toda función *estrictamente convexa* es *estrictamente cuasiconvexa*. La recíproca tampoco vale: x^3 es estrictamente creciente, y por lo tanto estrictamente cuasiconvexa, pero no es convexa.
- **Operaciones y composición.**
  - La suma de funciones cuasicóncavas no siempre es cuasicóncava, y lo mismo pasa con las cuasiconvexas. Por ejemplo, x^3 y $-3x$ son monótonas, y por lo tanto cuasicóncavas y cuasiconvexas, pero su suma no es ninguna de las dos: $x^3 - 3x \geq 0$ en $[-\sqrt{3}, 0] \cup [\sqrt{3}, \infty)$ y $x^3 - 3x \leq 0$ en $(-\infty, -\sqrt{3}] \cup [0, \sqrt{3}]$, y ninguno de esos conjuntos es convexo.

- La cuasiconcavidad se conserva bajo transformaciones crecientes: si f es cuasicóncava y g es creciente, $g \circ f$ es cuasicóncava. Si además f es estrictamente cuasicóncava y g es estrictamente creciente, $g \circ f$ es estrictamente cuasicóncava. Lo mismo vale para la cuasiconvexidad. Por eso la cuasiconcavidad es una propiedad *ordinal*. Son estrictamente crecientes, por ejemplo, $g(s) = as+b$ con $a > 0$, $g(s) = e^s$ y $g(s) = s^3$ en todo $\mathbb{R}$, y $g(s) = \ln s$, $g(s) = \sqrt{s}$ y $g(s) = s^2$ en $(0, \infty)$: en todos los casos $g'(s) > 0$, salvo para s^3 en $s = 0$. Alcanza con que g sea estrictamente creciente en los valores que toma f: s^2 no lo es en todo $\mathbb{R}$, pero xy toma solo valores positivos en A. Así, como xy es estrictamente cuasicóncava en A, también lo son e^{xy}, $(xy)^3$, $\sqrt{xy}$ y x^2y^2.
- Para la concavidad y la convexidad, en cambio, no alcanza con que g sea creciente. Por ejemplo, $\ln x$ es cóncava en $(0, \infty)$ y $g(s) = e^{2s}$ es creciente, pero $g(\ln x) = e^{2 \ln x} = x^2$ no es cóncava; sí sigue siendo cuasicóncava, porque es creciente en $(0, \infty)$.

Ejemplo

Anteriormente probamos que $f(x, y) = xy$ es estrictamente cuasicóncava en A. Veamos la transformación

$$h(x, y) = \ln(xy) = \ln x + \ln y, \qquad (x, y) \in A$$

Por composición. $h = g \circ f$ con $g(s) = \ln s$, que es estrictamente creciente en $(0, \infty)$. Como f es estrictamente cuasicóncava, h también lo es.

Con el hessiano orlado. Lo verificamos con el criterio:

$$h'_x = \frac{1}{x}, \quad h'_y = \frac{1}{y}, \qquad h''_{xx} = -\frac{1}{x^2},\ h''_{xy} = 0,\ h''_{yy} = -\frac{1}{y^2}$$

$$B_1(x, y) = \begin{pmatrix} 0 & h'_x \\ h'_x & h''_{xx} \end{pmatrix} = \begin{pmatrix} 0 & \frac{1}{x} \\ \frac{1}{x} & -\frac{1}{x^2} \end{pmatrix} \qquad |B_1| = -\frac{1}{x^2} < 0$$

$$B_2(x, y) = \begin{pmatrix} 0 & h'_x & h'_y \\ h'_x & h''_{xx} & h''_{xy} \\ h'_y & h''_{xy} & h''_{yy} \end{pmatrix} = \begin{pmatrix} 0 & \frac{1}{x} & \frac{1}{y} \\ \frac{1}{x} & -\frac{1}{x^2} & 0 \\ \frac{1}{y} & 0 & -\frac{1}{y^2} \end{pmatrix} \qquad |B_2| = \frac{2}{x^2\, y^2} > 0$$

Se cumple la condición suficiente, como esperábamos.

Más aún, h es cóncava. Su hessiana

$$H_h(x, y) = \begin{pmatrix} -\frac{1}{x^2} & 0 \\ 0 & -\frac{1}{y^2} \end{pmatrix}$$

tiene $\Delta^{(1)} = -\frac{1}{x^2} < 0$ y $\Delta^{(2)} = \frac{1}{x^2 y^2} > 0$: es definida negativa en todo A, así que h es estrictamente cóncava. La transformación creciente ln volvió estrictamente cóncava a una función que no era cóncava: la concavidad depende de la escala, y la cuasiconcavidad, no.

Conclusión. $h(x, y) = \ln(xy)$ es estrictamente cuasicóncava en A; de hecho, es estrictamente cóncava.

Otras condiciones suficientes

La condición suficiente del hessiano orlado prueba la versión estricta, y con ella también la no estricta. Pero si falla en algún punto, el criterio no concluye, y las condiciones débiles no alcanzan para probar la propiedad, porque son solo necesarias: sirven para descartarla, cuando fallan en algún punto. Por ejemplo:

- $x+y$ es cuasicóncava y cuasiconvexa, pero $|B_2| = 0$ en todo punto, así que la condición suficiente nunca se cumple.

- $q(x) = (x^2 - 1)^2 + 0.2$, la función del gráfico "No cuasiconvexa", cumple las condiciones débiles, porque $|B_1| = -q'(x)^2 \leq 0$, y sin embargo no es cuasicóncava ni cuasiconvexa.

Para esos casos hay otras condiciones suficientes que también usan derivadas:

- **Concavidad.** Si la hessiana de f es semidefinida negativa en todo D, f es cóncava y, por lo tanto, cuasicóncava. Así se prueba para $x + y$.
- **Una transformación creciente que la vuelva cóncava.** Si g es estrictamente creciente y la hessiana de $g \circ f$ es semidefinida negativa en todo D, entonces f es cuasicóncava, porque $f = g^{-1} \circ (g \circ f)$ y las transformaciones crecientes conservan la cuasiconcavidad. Si la hessiana de $g \circ f$ es definida negativa, f es estrictamente cuasicóncava. Es lo que vimos con xy y ln. Lo mismo vale para cualquier función de la forma $x^a y^b$ con $a, b > 0$ en A: $\ln(x^a y^b) = a \ln x + b \ln y$ es estrictamente cóncava, aunque $x^a y^b$ no sea cóncava cuando $a + b > 1$.
- **En una variable, el signo de f'.** Si f es monótona, o si $f' \geq 0$ hasta un punto y $f' \leq 0$ después, f es cuasicóncava, porque sus superniveles son intervalos.

Para la cuasiconvexidad valen las mismas condiciones, cambiando semidefinida negativa por semidefinida positiva, definida negativa por definida positiva, cóncava por convexa, y $f' \geq 0$ seguido de $f' \leq 0$ por $f' \leq 0$ seguido de $f' \geq 0$.

El recuadro siguiente junta las condiciones suficientes del capítulo en el orden en que conviene probarlas.

Método 19.1 | Probar que una función es cuasicóncava o cuasiconvexa

Cuándo usarlo. El enunciado pide probar que f es cuasicóncava o cuasiconvexa, estricta o no, en un conjunto convexo D.

En una variable. No hacen falta los pasos: alcanza con el signo de f'. Si f' no cambia de signo, f es cuasicóncava y cuasiconvexa. Si $f' \geq 0$ hasta un punto y $f' \leq 0$ después, es cuasicóncava; si $f' \leq 0$ hasta un punto y $f' \geq 0$ después, es cuasiconvexa. Si además f' se anula solo en puntos aislados, la propiedad es estricta.

Pasos.

1. Calcular ∇f y H_f, armar $B_1, \ldots, B_n$ y calcular $|B_1|, \ldots, |B_n|$.
2. Mirar los signos en todo D. Si alternan empezando por el negativo, es decir, $(-1)^k |B_k| > 0$ para todo k, f es estrictamente cuasicóncava. Si son todos negativos, $|B_k| < 0$ para todo k, es estrictamente cuasiconvexa.
3. Si algún $|B_k|$ se anula en algún punto, el criterio no concluye. Probar con las otras condiciones suficientes:
   - H_f semidefinida negativa en todo D: f es cóncava y, por lo tanto, cuasicóncava. Con semidefinida positiva, es convexa y cuasiconvexa.
   - $f = g \circ k$, con k cuasicóncava (cuasiconvexa) y g creciente: f es cuasicóncava (cuasiconvexa).
   - $g \circ f$ cóncava (convexa) para alguna g estrictamente creciente, como ln en los productos de potencias: f es cuasicóncava (cuasiconvexa).

   Con hessiana definida, o con k estricta y g estrictamente creciente, la propiedad es estricta.

Chequeo. $|B_1| = -(f_1')^2$ nunca es positivo: si da positivo, hay un error de cuentas.

Cuidado. Con $\geq$ o $\leq$, las condiciones del orlado son solo necesarias: sirven para descartar, no para probar. Si $(-1)^k |B_k| < 0$ para algún k en algún punto, f no es cuasicóncava; si $|B_k| > 0$, no es cuasiconvexa. Que el criterio no concluya no quiere decir que f no tenga la propiedad: $x + y$ es cuasicóncava aunque $|B_2| = 0$. Tampoco se puede probar sumando: la suma de funciones cuasicóncavas puede no serlo.

20 Optimización sin restricciones

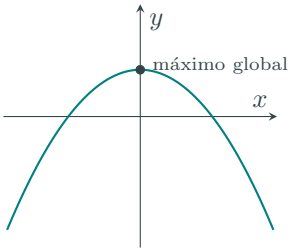
Cálculo univariable

Sea $f\colon I \to \mathbb{R}$ una función de clase C^2, donde $I \subseteq \mathbb{R}$ es un intervalo abierto.[14]

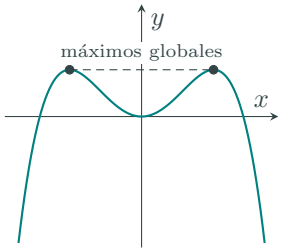
Definiciones. Un punto $x^* \in I$ es un *mínimo local* de f si existe $r > 0$ tal que $f(x^*) \leq f(x)$ para todo $x \in I$ con $|x - x^*| < r$, es decir, si ningún punto cercano a x^* da un valor menor. Es un *mínimo global* si $f(x^*) \leq f(x)$ para todo $x \in I$. Cuando la desigualdad es estricta para todo $x \neq x^*$, el mínimo es *estricto*; un mínimo global estricto es el único mínimo global de f. Los máximos se definen igual, invirtiendo la desigualdad, y a los máximos y mínimos los llamamos *extremos* u *óptimos*.

En el gráfico, $1 - x^2$ tiene un máximo global único, en $x = 0$. En cambio, $2x^2 - x^4$ vale 1 en $x = -1$ y en $x = 1$, y en ningún punto vale más, así que tiene dos máximos globales: el máximo global no es único. Por último, $x^3 - 3x$ tiene un máximo local en $x = -1$, donde vale 2, que no es global: para $x > 2$ la función supera ese valor y sigue subiendo.

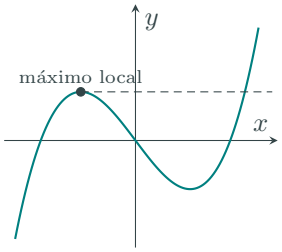
Máximo global único
$f(x) = 1 - x^2$



Máximo global no único
$f(x) = 2x^2 - x^4$



Máximo local que no es global
$f(x) = x^3 - 3x$



Para encontrar extremos locales de f aplicamos el siguiente procedimiento:

1. **Condición de primer orden.** Calcular la derivada primera y resolver

$$f'(x^*) = 0$$

Los puntos x^* que satisfacen esta ecuación son los *puntos críticos*. Es una condición necesaria: como I es abierto, todo extremo local de f es un punto crítico. No es suficiente: más abajo veremos que x^3 tiene un punto crítico en 0 que no es un extremo.

2. **Condición de segundo orden.** Evaluar la derivada segunda en cada x^*:

$$f''(x^*) \begin{cases} > 0 & \Rightarrow \ x^* \text{ es un mínimo local} \\ < 0 & \Rightarrow \ x^* \text{ es un máximo local} \\ = 0 & \Rightarrow \ \text{el criterio no nos permite concluir nada} \end{cases}$$

Cuando $f''(x^*) = 0$, x^* puede ser un mínimo, un máximo o ninguno de los dos: x^4, $-x^4$ y x^3 cumplen $f'(0) = f''(0) = 0$, y en 0 tienen, respectivamente, un mínimo, un máximo y un punto de inflexión.

Ejemplo rápido. Busquemos los extremos locales de $f(x) = x^3 - 3x$ en $\mathbb{R}$.

$$f'(x) = 3x^2 - 3, \ f'(x) = 0 \Rightarrow x = \pm 1; \quad f''(x) = 6x$$

$$f''(1) = 6 > 0 \ \Rightarrow \ x = 1 \text{ mínimo local}, \qquad f''(-1) = -6 < 0 \ \Rightarrow \ x = -1 \text{ máximo local}$$

Ninguno es global, porque $f(x) \to +\infty$ cuando $x \to +\infty$ y $f(x) \to -\infty$ cuando $x \to -\infty$.

[14] Pedimos I abierto para que alrededor de cada punto haya lugar a ambos lados. Si x^* es un mínimo, f no baja al movernos hacia la derecha ni hacia la izquierda: los cocientes incrementales son ≥ 0 de un lado y ≤ 0 del otro, y en el límite eso obliga a que $f'(x^*) = 0$. En el borde de un intervalo cerrado hay un solo lado, y un extremo puede tener $f' \neq 0$: $f(x) = x$ en $[0, 1]$ tiene su mínimo en 0, donde $f'(0) = 1$. Por la misma razón, en n variables pedimos U abierto.

Pasando a n variables

Denotemos

$$\vec{x} = (x_1, x_2, \ldots, x_n)^T \in \mathbb{R}^n$$

(los vectores de $\mathbb{R}^n$ son columna; cuando los escribimos en una línea, los ponemos como fila transpuesta) y sea

$$F\colon U \subseteq \mathbb{R}^n \to \mathbb{R}$$

una función de clase C^2, con U abierto. Las definiciones de extremo local y global son las del caso univariable, cambiando $|x - x^*|$ por la distancia entre $\vec{x}$ y $\vec{x}^*$,

$$\|\vec{x} - \vec{x}^*\| = \sqrt{(x_1 - x_1^*)^2 + \cdots + (x_n - x_n^*)^2}$$

Por ejemplo, $\vec{x}^*$ es un mínimo local de F si existe $r > 0$ tal que $F(\vec{x}^*) \leq F(\vec{x})$ para todo $\vec{x} \in U$ con $\|\vec{x} - \vec{x}^*\| < r$, es decir, en un entorno de $\vec{x}^*$.

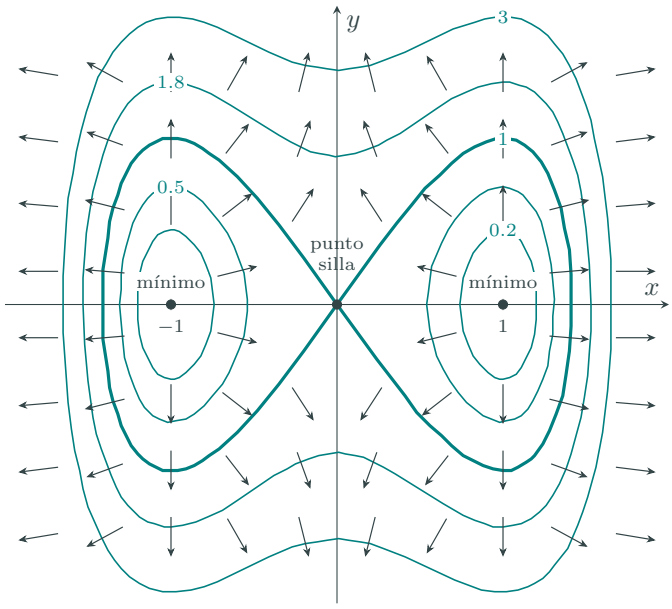
La *condición de primer orden* (CPO) se generaliza a

$$\nabla F(\vec{x}^*) = \vec{0}$$

es decir, todas las derivadas parciales de F deben anularse en $\vec{x}^* = (x_1^*, x_2^*, \ldots, x_n^*)^T$. Los puntos que cumplen esta condición son los *puntos críticos* de F. Como en una variable, la condición es necesaria pero no suficiente: todo extremo local de F es un punto crítico, pero un punto crítico puede no ser un extremo. Un punto crítico que no es ni mínimo ni máximo local se llama *punto silla*: en cualquier entorno de $\vec{x}^*$ hay puntos donde F es mayor que $F(\vec{x}^*)$ y puntos donde es menor. (En una variable, un caso así, como el de x^3 en 0, suele llamarse punto de inflexión.)

Por ejemplo, para $F(x, y) = (x^2 - 1)^2 + y^2$ el gradiente $\nabla F(x, y) = \big(4x(x^2 - 1), 2y\big)^T$ se anula en $(-1, 0)$, $(1, 0)$ y $(0, 0)$. En el gráfico, cada flecha indica la dirección del gradiente, que es hacia donde F crece más rápido, y corta a las curvas de nivel en ángulo recto; cada curva está rotulada con su nivel. Como $F \geq 0$ y vale 0 en $(-1, 0)$ y en $(1, 0)$, esos dos puntos son mínimos, y alrededor de ellos las flechas apuntan hacia afuera. El origen es un punto silla. Como $F(0, 0) = 1$, la curva de nivel $F = 1$ pasa por él: adentro de sus dos lazos F es menor que 1, y afuera, mayor. Así, cerca del origen hay puntos donde F es mayor que $F(0, 0)$, arriba y abajo, y puntos donde es menor, a los costados, que es lo que pide la definición.

Curvas de nivel y gradiente de $F(x, y) = (x^2 - 1)^2 + y^2$



La *condición de segundo orden* se extrae de la matriz hessiana $H(\vec{x}) = \nabla^2 F(\vec{x})$, que reúne todas las derivadas segundas de F. Como F es de clase C^2, por el teorema de Schwarz las derivadas cruzadas coinciden, $F''_{x_i x_j} = F''_{x_j x_i}$, así que $H(\vec{x})$ es simétrica y le podemos aplicar los criterios de definitud de las matrices simétricas. Así como en una variable el signo de $f''(x^*)$ dice si x^* es un mínimo o un máximo local, saber si $H(\vec{x}^*)$ es definida positiva, definida negativa o indefinida nos permitirá determinar si F tiene en $\vec{x}^*$ un mínimo local, un máximo local o un punto silla.[15]

Para abreviar, escribimos $H \succ 0$ si H es definida positiva, $H \succeq 0$ si es semidefinida positiva, $H \prec 0$ si es definida negativa y $H \preceq 0$ si es semidefinida negativa.

Condiciones suficientes y criterio de la matriz hessiana

Sea

$$F\colon U \subseteq \mathbb{R}^n \longrightarrow \mathbb{R}$$

de clase C^2, con U abierto, y sea $\vec{x}^* \in U$ un punto crítico, es decir,

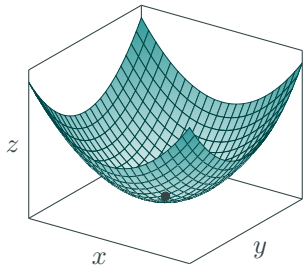
$$\nabla F(\vec{x}^*) = \vec{0}$$

Criterio de la hessiana.

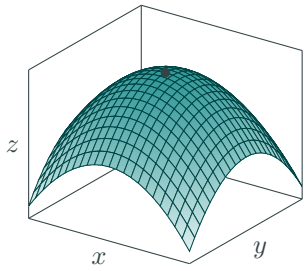
- Si $H(\vec{x}^*)$ es *definida negativa*, entonces $\vec{x}^*$ es *máximo local*.
- Si $H(\vec{x}^*)$ es *definida positiva*, entonces $\vec{x}^*$ es *mínimo local*.
- Si $H(\vec{x}^*)$ es *indefinida*, entonces $\vec{x}^*$ no es ni mínimo ni máximo local (punto silla).

Los tres casos del criterio se ven en las funciones más simples de dos variables. En la silla están marcados los cortes por los ejes: sobre el eje x la función tiene un mínimo y sobre el eje y, un máximo.

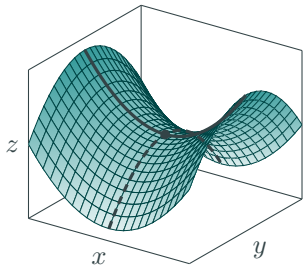
$x^2 + y^2$: $H \succ 0$, mínimo



$-x^2 - y^2$: $H \prec 0$, máximo

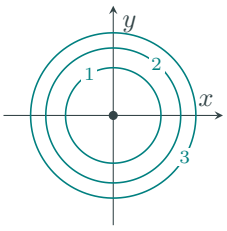


$x^2 - y^2$: H indefinida, silla

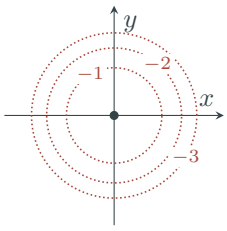


En curvas de nivel, los mismos tres casos se ven así: alrededor de un mínimo o de un máximo las curvas son cerradas (en el mínimo los niveles crecen hacia afuera, y en el máximo decrecen), y en un punto silla la curva de nivel que pasa por el punto se cruza consigo misma. Para $x^2 - y^2$, la curva de nivel 0 son las rectas $y = x$ e $y = -x$. Cada curva está rotulada con su nivel, y las punteadas corresponden a niveles negativos.

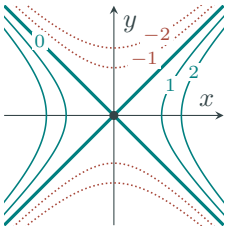
$x^2 + y^2$: mínimo



$-x^2 - y^2$: máximo



$x^2 - y^2$: punto silla



[15] Una forma de verlo es con el polinomio de Taylor de segundo orden: como $\nabla F(\vec{x}^*) = \vec{0}$, cerca de $\vec{x}^*$ vale $F(\vec{x}^* + \vec{h}) - F(\vec{x}^*) \approx \frac{1}{2}\,\vec{h}^T H(\vec{x}^*)\,\vec{h}$, así que, para $\vec{h}$ chico, el signo de la diferencia lo da la forma cuadrática asociada a $H(\vec{x}^*)$.

Criterio de los menores principales para óptimo local

Sea

$$F\colon U \subseteq \mathbb{R}^n \longrightarrow \mathbb{R}$$

de clase C^2, con U abierto, y supongamos que $\vec{x}^* \in U$ es un punto crítico:

$$\nabla F(\vec{x}^*) = \vec{0}$$

Denotemos por $\Delta^{(k)}$ el menor principal líder de orden k de la matriz hessiana evaluada en el punto crítico, es decir, el determinante de la submatriz formada por sus primeras k filas y columnas. En general, un menor principal es el determinante de la submatriz que se forma eligiendo las mismas filas y columnas. Lo escribimos $\Delta_I^{(k)}$, donde I es el conjunto de filas y columnas elegidas; por ejemplo, en dos variables, $\Delta_1^{(1)} = F''_{xx}$, $\Delta_2^{(1)} = F''_{yy}$ y $\Delta_{12}^{(2)} = \det H$.

Condición para máximo local. Si los menores principales líderes alternan de signo, empezando por el negativo:

$$\Delta^{(1)} < 0, \quad \Delta^{(2)} > 0, \quad \Delta^{(3)} < 0, \ \ldots, \ (-1)^n \Delta^{(n)} > 0$$

entonces $\vec{x}^*$ es un *máximo local* de F.

Condición para mínimo local. Si todos los menores principales líderes son positivos:

$$\Delta^{(1)} > 0, \quad \Delta^{(2)} > 0, \quad \Delta^{(3)} > 0, \ \ldots, \ \Delta^{(n)} > 0$$

entonces $\vec{x}^*$ es un *mínimo local* de F.

Condición para punto silla. Si $H(\vec{x}^*)$ es indefinida, $\vec{x}^*$ es un *punto silla*. Esto ocurre si algún menor principal de orden par es negativo, o si hay dos menores principales de orden impar con signos opuestos. Si $\det H(\vec{x}^*) \neq 0$, basta mirar los menores líderes: si no siguen ninguno de los dos patrones anteriores, $H(\vec{x}^*)$ es indefinida. En dos variables alcanza con que

$$\Delta^{(2)} = \det H(\vec{x}^*) < 0$$

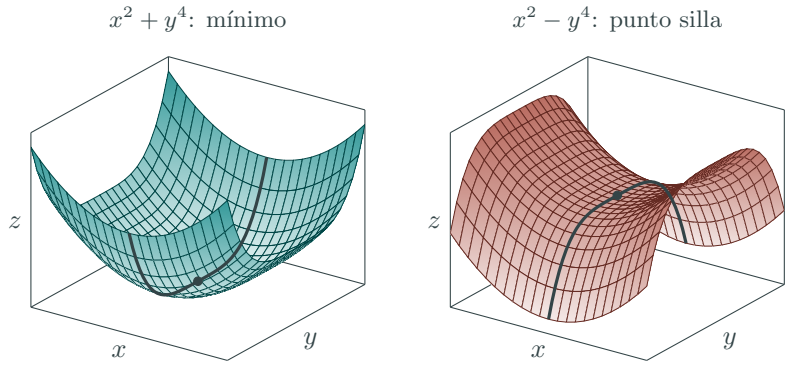
Condición necesaria de segundo orden y casos no concluyentes

Los criterios anteriores dan condiciones suficientes. También hay una condición necesaria: si $\vec{x}^*$ es un mínimo local de F, entonces $H(\vec{x}^*)$ es semidefinida positiva, y si es un máximo local, $H(\vec{x}^*)$ es semidefinida negativa. Por eso, cuando $H(\vec{x}^*)$ es indefinida, $\vec{x}^*$ no puede ser ni mínimo ni máximo.

Si $H(\vec{x}^*)$ es semidefinida pero no definida, el criterio no nos permite concluir nada. Si $H(\vec{x}^*) \succeq 0$ y no es la matriz nula, la condición necesaria descarta que $\vec{x}^*$ sea un máximo, pero puede ser un mínimo o un punto silla. Por ejemplo, $x^2 + y^4$ y $x^2 - y^4$ tienen la misma hessiana en el origen,

$$H(0,0) = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}$$

y la primera tiene ahí un mínimo y la segunda, un punto silla. En el gráfico, el corte por el eje y sube en la primera y baja en la segunda: la diferencia está en el término $\pm y^4$, que la hessiana no ve.



Con $H(\vec{x}^*) \preceq 0$ pasa lo análogo: puede haber un máximo o un punto silla. Si $H(\vec{x}^*)$ es la matriz nula, puede pasar cualquiera de las tres cosas: las funciones

$$x^4 + y^4, \qquad -x^4 - y^4, \qquad x^4 - y^4$$

tienen un punto crítico en el origen con hessiana nula, y ahí tienen, respectivamente, un mínimo, un máximo y un punto silla.

Criterio de los menores principales para óptimo global

En esta sección U es, además, convexo.

Mínimo global. Supongamos que la matriz hessiana $H(\vec{x})$ es semidefinida positiva en *todos* los puntos $\vec{x} \in U$. En términos de menores principales, esto equivale a

$$\Delta_I^{(k)}(\vec{x}) \geq 0 \quad \text{para todos los menores principales y todo } \vec{x} \in U$$

Cuando esto se cumple, F es convexa y cualquier punto crítico es automáticamente un mínimo global. La condición no asegura que F *tenga* un mínimo: en una variable, $F(x) = \mathrm{e}^x$ es convexa y no tiene ningún punto crítico, porque $F'(x) = \mathrm{e}^x$ nunca se anula.

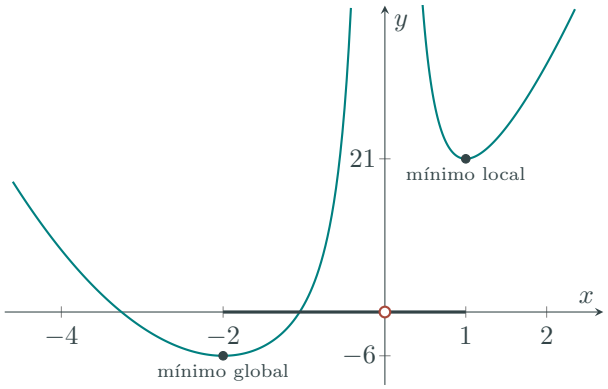
Máximo global. Análogamente, supongamos que $H(\vec{x})$ es semidefinida negativa en todo U. En términos de menores principales, esto equivale a

$$(-1)^k\, \Delta_I^{(k)}(\vec{x}) \geq 0 \quad \text{para todos los menores principales y todo } \vec{x} \in U$$

Bajo esta condición, F es cóncava y cada punto crítico será un máximo global. Tampoco aquí está asegurada la existencia: $-\mathrm{e}^x$ es cóncava y no tiene máximo.

Por qué hace falta que U sea convexo. La función $f(x) = 3x^2 + 10x + 8/x^2$ está definida en $U = (-\infty, 0) \cup (0, +\infty)$, que no es convexo: en una variable, los conjuntos convexos son los intervalos. Además, $f''(x) = 6 + 48/x^4 > 0$ en todo U, y sus puntos críticos, las soluciones de $f'(x) = 6x + 10 - 16/x^3 = 0$, son $x = 1$ y $x = -2$. Si se aplicara el criterio sin mirar el dominio, se concluiría que los dos son mínimos globales. Pero $f(1) = 21$ y $f(-2) = -6$, así que $x = 1$ es solo un mínimo local. El criterio falla porque la convexidad compara los valores de la función a lo largo de segmentos, y el segmento que va de $x = -2$ a $x = 1$, marcado en el gráfico sobre el eje, pasa por $x = 0$, que no está en U. Si el dominio no es convexo, el criterio no se puede usar en todo U, pero sí en cada semirrecta, que es convexa: en $(-\infty, 0)$ el mínimo es $x = -2$, y en $(0, +\infty)$, $x = 1$. Como $f(-2) < f(1)$, el mínimo global de f es $x = -2$.

$$f(x) = 3x^2 + 10x + \frac{8}{x^2}$$



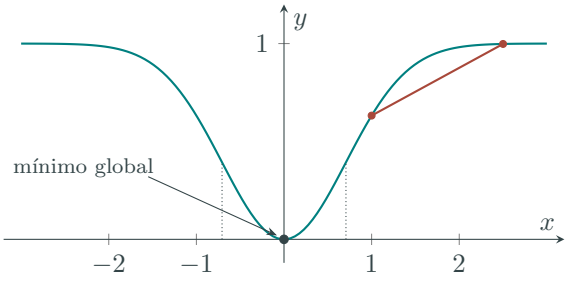
Diferencia entre óptimos locales y globales

Para un óptimo local, la hessiana se evalúa en el punto crítico: si es definida, cerca de ese punto la función se comporta como una estrictamente convexa o cóncava. Para un óptimo global, la hessiana se estudia en todo el dominio, sin evaluarla en un punto, para ver si la función es convexa o cóncava.

La convexidad (o la concavidad) es una condición suficiente para que un óptimo sea global, pero no necesaria: $h(x) = 1 - \mathrm{e}^{-x^2}$ tiene un mínimo global en $x = 0$, porque $h(x) \geq 0 = h(0)$, y no es convexa, porque $h''(x) = 2(1 - 2x^2)\,\mathrm{e}^{-x^2}$ es negativa para $|x| > 1/\sqrt{2}$.

En el gráfico, la secante entre $x = 1$ y $x = 2.5$ queda por debajo de la curva, así que h no es convexa, aunque el origen sea su mínimo global. Las líneas de puntos marcan los puntos de inflexión, en $x = \pm 1/\sqrt{2} \approx \pm 0.71$.

Mínimo global sin convexidad: $h(x) = 1 - \mathrm{e}^{-x^2}$



Resumiendo lo anterior tenemos:

Teorema (convexidad y óptimos globales). Sea $F\colon U \to \mathbb{R}$, con $U \subseteq \mathbb{R}^n$ abierto y convexo, $F \in C^1(U)$, y sea $\vec{x}^* \in U$ un punto crítico de F. Se verifica:

1. Si F es convexa en U, entonces F presenta en $\vec{x}^*$ un mínimo global.
2. Si F es estrictamente convexa en U, entonces F presenta en $\vec{x}^*$ un mínimo global único.
3. Si F es cóncava en U, entonces F presenta en $\vec{x}^*$ un máximo global.
4. Si F es estrictamente cóncava en U, entonces F presenta en $\vec{x}^*$ un máximo global único.

Método 20.1 | Encontrar y clasificar los extremos de una función

Cuándo usarlo. Para buscar los máximos y mínimos de una función F de clase C^2 en un conjunto abierto $U \subseteq \mathbb{R}^n$, sin restricciones.

Pasos.

1. Resolver $\nabla F(\vec{x}) = \vec{0}$. Sus soluciones, los puntos críticos, son los únicos candidatos.
2. Calcular la hessiana en cada punto crítico y clasificarla con sus menores: si es definida positiva, el punto es un mínimo local; si es definida negativa, un máximo local, y si es indefinida, un punto silla. Si $\det H(\vec{x}^*) \neq 0$ y los menores líderes no siguen el patrón de definida positiva ni el de definida negativa, es indefinida. En dos variables, $\det H(\vec{x}^*) < 0$ ya indica un punto silla.
3. Si $H(\vec{x}^*)$ es solo semidefinida, el criterio no nos permite concluir nada: hay que estudiar F cerca del punto. Si sobre una recta que pasa por él F sube y sobre otra baja, es un punto silla; si $F(\vec{x}) \geq F(\vec{x}^*)$ para los $\vec{x}$ cercanos, es un mínimo (con $\leq$, un máximo).
4. Para saber si un extremo es global (con U convexo), analizar la hessiana en todo U, sin evaluarla en un punto. Si es semidefinida positiva en todo U (todos los menores principales ≥ 0), F es convexa y cada punto crítico es un mínimo global; si además es definida positiva, el mínimo es único. Para los máximos, lo mismo con semidefinida negativa (cada menor principal de orden k, multiplicado por $(-1)^k$, ≥ 0) y definida negativa.
5. Si F no es convexa ni cóncava, o si U no es convexo, comparar valores: si F no es acotada inferiormente (por ejemplo, sobre una recta), no tiene mínimo global, y si no es acotada superiormente, no tiene máximo global.

Chequeo. Reemplazar cada punto crítico en ∇F (tiene que dar $\vec{0}$) y verificar que esté en U. La hessiana tiene que ser simétrica.

Cuidado. Para la semidefinitud no alcanza con los menores principales líderes: hay que revisarlos todos. Si U no es convexo, el paso 4 no vale, aunque la hessiana sea semidefinida en todo U. Que F sea convexa no asegura que tenga un mínimo: e^x es convexa y no tiene puntos críticos. La convexidad es suficiente para que un extremo sea global, pero no necesaria. Si $F > 0$, puede convenir trabajar con $\ln F$, que tiene los mismos extremos.

Ejemplo: $F(x, y) = x^2 + y^2$

1. Derivadas parciales y punto crítico

Busquemos los extremos de

$$F(x, y) = x^2 + y^2, \qquad (x, y) \in \mathbb{R}^2$$

Calculamos las derivadas parciales:

$$F'_x = 2x, \quad F'_y = 2y$$

El único punto crítico se obtiene resolviendo

$$2x = 0, \quad 2y = 0 \implies (x, y) = (0, 0)$$

2. Hessiana y clasificación de extremos locales

La hessiana es constante:

$$H(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

Sus menores principales líderes son

$$\Delta^{(1)} = 2 > 0, \qquad \Delta^{(2)} = \det H = 4 > 0$$

de modo que la matriz es *definida positiva* en todo $\mathbb{R}^2$. Por el criterio de segundo orden, $(0,0)$ es un *mínimo local*.

3. Convexidad global y mínimo global

Como $H(x,y) \succ 0$ en todo $\mathbb{R}^2$ (en particular, $H(x,y) \succeq 0$), F es *convexa* en $\mathbb{R}^2$, y en toda función convexa cualquier mínimo local es también *mínimo global*. Más aún, F es *estrictamente convexa*, así que $(0,0)$ es el *único* mínimo global.

Conclusión. $(0,0)$ es el único mínimo global de F.

Ejemplo: $F(x,y) = x^3 - y^3 + 9xy$

1. Derivadas parciales y puntos críticos

Busquemos y clasifiquemos los extremos de

$$F(x,y) = x^3 - y^3 + 9\,x\,y, \qquad (x,y) \in \mathbb{R}^2$$

Calculamos las derivadas parciales:

$$F'_x = 3x^2 + 9y, \qquad F'_y = -3y^2 + 9x$$

Para hallar los puntos críticos resolvemos

$$\begin{cases} 3x^2 + 9y = 0 \\ -3y^2 + 9x = 0 \end{cases}$$

De la primera ecuación:

$$y = -\frac{x^2}{3}$$

Sustituyendo en la segunda:

$$\begin{aligned} -3\left(-\tfrac{x^2}{3}\right)^2 + 9x = 0 \implies -3\,\frac{x^4}{9} + 9x = 0 \implies -\tfrac{x^4}{3} + 9x = 0 \\ \implies -x^4 + 27x = 0 \implies x\,(-x^3 + 27) = 0 \end{aligned}$$

De aquí obtenemos

$$x = 0 \implies y = 0, \qquad -x^3 + 27 = 0 \implies x^3 = 27 \implies x = 3 \implies y = -\frac{3^2}{3} = -3$$

Por lo tanto, los puntos críticos son

$$(0,0) \quad \text{y} \quad (3,-3)$$

2. Hessiana y clasificación de extremos locales

La hessiana es

$$H(x,y) = \begin{pmatrix} F''_{xx} & F''_{xy} \\ F''_{yx} & F''_{yy} \end{pmatrix} = \begin{pmatrix} 6x & 9 \\ 9 & -6y \end{pmatrix}$$

1. **En** $(0,0)$**.**

$$H(0,0) = \begin{pmatrix} 0 & 9 \\ 9 & 0 \end{pmatrix}, \quad \Delta^{(1)} = 0, \quad \Delta^{(2)} = -81 < 0$$

   Como $\Delta^{(2)} < 0$, la hessiana es indefinida y $(0,0)$ es un punto silla.

2. **En** $(3,-3)$**.**

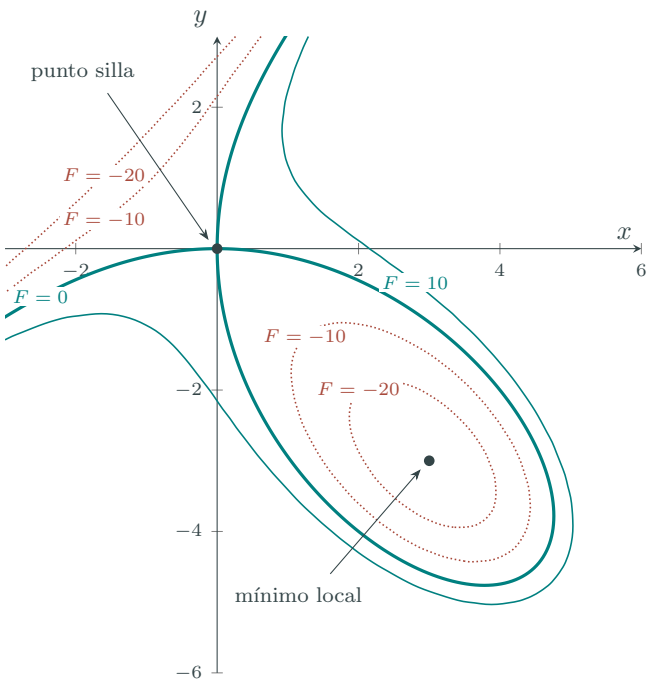
$$H(3,-3) = \begin{pmatrix} 18 & 9 \\ 9 & 18 \end{pmatrix}, \quad \Delta^{(1)} = 18 > 0, \quad \Delta^{(2)} = 18 \cdot 18 - 9 \cdot 9 = 243 > 0$$

   Aquí la hessiana es definida positiva, por lo que $(3,-3)$ es un mínimo local.

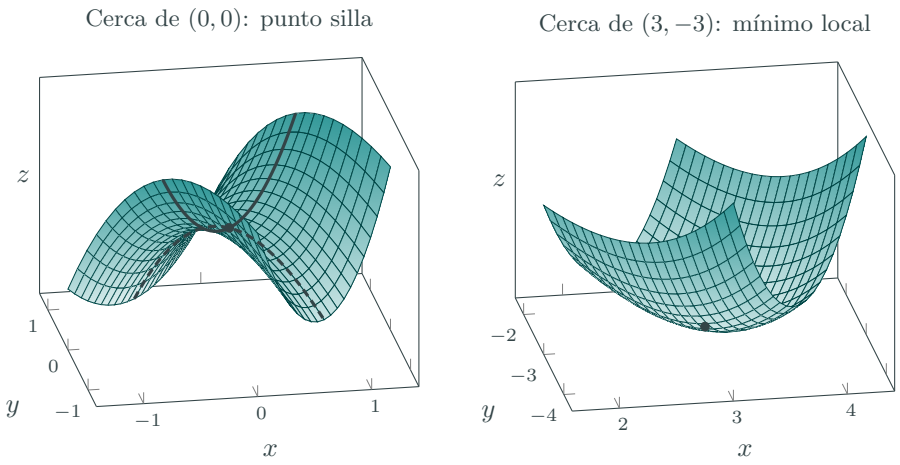
Conclusión. $(0,0)$ es un punto silla y $(3,-3)$ es un mínimo local de F. No hay máximos locales.

En el gráfico de curvas de nivel se ven los dos casos. Alrededor del mínimo local las curvas de nivel son cerradas, y F crece a medida que nos alejamos de $(3,-3)$. En el punto silla, en cambio, se cruzan dos ramas de la curva de nivel $F = 0$: en dos de los cuatro sectores que forman, F es positiva, y en los otros dos, negativa. En el gráfico, cada curva está rotulada con su nivel, y las punteadas corresponden a niveles negativos.

Curvas de nivel de $F(x,y) = x^3 - y^3 + 9xy$



En la superficie se ve lo mismo: cerca de cada punto crítico, F tiene la forma que indica su hessiana. Desde $(0,0)$, F sube a lo largo de la recta $y = x$ y baja a lo largo de $y = -x$; en el gráfico están marcados los dos cortes, y el de $y = -x$ va en trazos. Alrededor de $(3,-3)$, en cambio, F crece en todas las direcciones.



3. Concavidad/convexidad global de F

Para determinar si el mínimo local es también global, intentamos aplicar el teorema anterior, que pide que F sea convexa o cóncava en todo $\mathbb{R}^2$. Volvemos a la hessiana general:

$$H(x,y) = \begin{pmatrix} 6x & 9 \\ 9 & -6y \end{pmatrix}$$

Los menores principales no tienen un signo fijo en $\mathbb{R}^2$: por ejemplo, $6x$ es positivo si $x > 0$ y negativo si $x < 0$. Lo mismo pasa con $-6y$ y con $\det H$. Con este criterio, no podemos afirmar que tenemos un óptimo global.

De hecho, F no es convexa ni cóncava, y para verlo alcanza con el punto silla. Si F fuera convexa, por el teorema todo punto crítico sería un mínimo global, y $(0,0)$ no lo es. Si fuera cóncava, $(0,0)$ sería un máximo global, y tampoco lo es.

Que el teorema no se aplique no deja la pregunta sin respuesta: podemos comprobar directamente que $(3,-3)$ no es un mínimo global. Por ejemplo, $F(3,-3) = -27$ y $F(-4,0) = -64 < -27$. Más aún, sobre el eje x la función queda $F(x,0) = x^3$, que tiende a $-\infty$ cuando $x \to -\infty$, así que F no tiene mínimo global. Del mismo modo, $F(0,y) = -y^3$ tiende a $+\infty$ cuando $y \to -\infty$, así que tampoco tiene máximo global.

Conclusión. $(3,-3)$ es un mínimo local de F, pero no global, y F no tiene mínimo ni máximo global.

Ejemplo: $F(x,y) = (x+y)^2$

Busquemos los extremos de

$$F(x,y) = (x+y)^2, \qquad (x,y) \in \mathbb{R}^2$$

En este ejemplo pasa lo contrario que en el anterior: el criterio local no nos permite concluir nada, pero el global sí.

1. Derivadas parciales y puntos críticos

$$F'_x = 2(x+y), \qquad F'_y = 2(x+y)$$

Las dos se anulan si y solo si $x + y = 0$, así que los puntos críticos son todos los puntos de la recta

$$y = -x$$

2. Hessiana y clasificación de extremos locales

La hessiana es constante:

$$H(x,y) = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}, \qquad \Delta^{(1)} = 2 > 0, \qquad \Delta^{(2)} = \det H = 0$$

Como $\Delta^{(2)} = 0$, la hessiana no es definida, y el criterio de los menores para óptimos locales no nos permite concluir nada en ninguno de los puntos críticos.

3. Convexidad global y mínimo global

Para el criterio global hay que revisar todos los menores principales, no solo los líderes:

$$\Delta_1^{(1)} = 2 \geq 0, \qquad \Delta_2^{(1)} = 2 \geq 0, \qquad \Delta_{12}^{(2)} = \det H = 0 \geq 0$$

Entonces $H(x,y) \succeq 0$ en todo $\mathbb{R}^2$, F es convexa y, por el teorema, todo punto crítico es un mínimo global. Lo confirma la función misma: $F(x,y) = (x+y)^2 \geq 0$, y vale 0 sobre toda la recta $y = -x$. El mínimo no es único porque F vale 0 en toda esa recta. Eso muestra, además, que F no es estrictamente convexa: si lo fuera, el mínimo sería único.

Conclusión. El mínimo global de F se alcanza en todos los puntos de la recta $y = -x$, así que no es único. Con el criterio global podemos concluir, aunque con el local no.

Ejemplo: $F(x,y,z) = 4x + 2y - x^2 - y^2 - z^2 + xy + yz$

Busquemos los extremos de

$$F(x,y,z) = 4x + 2y - x^2 - y^2 - z^2 + xy + yz, \qquad (x,y,z) \in \mathbb{R}^3$$

En tres variables, el criterio de los menores líderes mira también $\Delta^{(3)} = \det H$.

1. Derivadas parciales y puntos críticos

$$F'_x = 4 - 2x + y, \qquad F'_y = 2 - 2y + x + z, \qquad F'_z = -2z + y$$

Para hallar los puntos críticos resolvemos

$$\begin{cases} 4 - 2x + y = 0 \\ 2 - 2y + x + z = 0 \\ -2z + y = 0 \end{cases}$$

De la primera ecuación, $y = 2x - 4$, y de la tercera, $z = y/2 = x - 2$. Sustituyendo en la segunda:

$$2 - 2(2x - 4) + x + (x - 2) = 0 \implies 8 - 2x = 0 \implies x = 4$$

así que $y = 4$ y $z = 2$. El único punto crítico es

$$(4, 4, 2)$$

2. Hessiana y clasificación de extremos locales

La hessiana es constante:

$$H(x,y,z) = \begin{pmatrix} F''_{xx} & F''_{xy} & F''_{xz} \\ F''_{yx} & F''_{yy} & F''_{yz} \\ F''_{zx} & F''_{zy} & F''_{zz} \end{pmatrix} = \begin{pmatrix} -2 & 1 & 0 \\ 1 & -2 & 1 \\ 0 & 1 & -2 \end{pmatrix}$$

Sus menores principales líderes son

$$\Delta^{(1)} = -2 < 0, \qquad \Delta^{(2)} = \det \begin{pmatrix} -2 & 1 \\ 1 & -2 \end{pmatrix} = 4 - 1 = 3 > 0$$

$$\Delta^{(3)} = \det H = -2 \cdot \det \begin{pmatrix} -2 & 1 \\ 1 & -2 \end{pmatrix} - 1 \cdot \det \begin{pmatrix} 1 & 1 \\ 0 & -2 \end{pmatrix} = -2 \cdot 3 - 1 \cdot (-2) = -4 < 0$$

Alternan de signo empezando por el negativo, así que H es definida negativa y $(4,4,2)$ es un máximo local.

3. Concavidad global y máximo global

Como la hessiana no depende del punto, es definida negativa en todo $\mathbb{R}^3$. Entonces F es estrictamente cóncava y, por el teorema, $(4,4,2)$ es su único máximo global, con

$$F(4,4,2) = 16 + 8 - 16 - 16 - 4 + 16 + 8 = 12$$

Conclusión. $(4,4,2)$ es el único máximo global de F, con $F(4,4,2) = 12$.

Preservación de máximos y mínimos bajo transformaciones crecientes

Sea $F\colon U \subseteq \mathbb{R}^n \to \mathbb{R}$ y sea φ una función estrictamente creciente, definida en un conjunto que contiene a la imagen de F. Entonces F y $\varphi \circ F$ alcanzan sus máximos y mínimos, locales y globales, en los mismos puntos, porque

$$F(\vec{x}^*) \geq F(\vec{x}) \iff \varphi\big(F(\vec{x}^*)\big) \geq \varphi\big(F(\vec{x})\big)$$

Por eso, para buscar los extremos de una función positiva se puede trabajar con su logaritmo, como en el ejemplo de esta sección. Este resultado no necesita que φ sea derivable.

Con derivadas se puede decir algo más: el criterio de la hessiana sigue funcionando después de transformar. Sea $D \subseteq \mathbb{R}$ un conjunto abierto y sea $\varphi\colon D \to \mathbb{R}$ una función de clase C^2 tal que $\varphi'(t) > 0$ para todo $t \in D$. Sea $F\colon U \subseteq \mathbb{R}^n \to \mathbb{R}$ de clase C^2, con U abierto, tal que $F(\vec{x}) \in D$ para todo $\vec{x} \in U$. Entonces:

1. $\vec{x}^*$ es punto crítico de F si y solo si es punto crítico de $\varphi \circ F$.
2. Si $\vec{x}^*$ es punto crítico de F, la hessiana de $\varphi \circ F$ en $\vec{x}^*$ tiene la misma clasificación que $H_F(\vec{x}^*)$: si una es definida negativa (máximo local), definida positiva (mínimo local), indefinida (punto silla) o semidefinida, la otra también.

Demostración. Por la regla de la cadena,

$$\nabla(\varphi \circ F)(\vec{x}) = \varphi'\big(F(\vec{x})\big)\, \nabla F(\vec{x})$$

y como $\varphi' > 0$, un gradiente se anula si y solo si se anula el otro. Derivando otra vez,

$$H_{\varphi \circ F}(\vec{x}) = \varphi''\big(F(\vec{x})\big)\, \nabla F(\vec{x})\, \nabla F(\vec{x})^T + \varphi'\big(F(\vec{x})\big)\, H_F(\vec{x})$$

En un punto crítico el primer término se anula, y queda

$$H_{\varphi\circ F}(\vec{x}^*) = \varphi'\big(F(\vec{x}^*)\big)\, H_F(\vec{x}^*)$$

La hessiana queda multiplicada por un número positivo, y eso no cambia el signo de $\vec{h}^T H\, \vec{h}$ para ningún $\vec{h}$: la clasificación es la misma.

Observación. Fuera de los puntos críticos, la definitud sí puede cambiar. Con $F(x,y) = 3x - x^2 - y^2$ y $\varphi(t) = \mathrm{e}^t$, en el origen

$$H_F(0,0) = \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix} \qquad H_{\varphi\circ F}(0,0) = \begin{pmatrix} 7 & 0 \\ 0 & -2 \end{pmatrix}$$

La primera es definida negativa y la segunda es indefinida. Por eso el ítem 2 pide que $\vec{x}^*$ sea un punto crítico.

Ejemplos de φ.

- $\varphi(t) = a\,t + b$, con $a > 0$.
- $\varphi(t) = \mathrm{e}^t$.
- $\varphi(t) = \ln(t + c)$, con $c \in \mathbb{R}$ (dominio $t > -c$). Con $c = 0$ queda $\ln t$, la del ejemplo de esta sección.
- $\varphi(t) = t^3$ (con $t \neq 0$).
- $\varphi(t) = \sqrt{t}$ (en $t > 0$).

El caso $\varphi(t) = t^3$ muestra la diferencia entre conservar los óptimos y conservar el criterio. Como t^3 es estrictamente creciente en todo $\mathbb{R}$, siempre conserva los óptimos. Pero $\varphi'(0) = 0$, y por eso se excluye $t = 0$: $F(x,y) = x^2 + y^2$ tiene un mínimo en el origen, donde vale 0, y la hessiana de $(x^2 + y^2)^3$ en el origen es la matriz nula. El mínimo sigue estando, pero el criterio de la hessiana ya no lo detecta.

Ejemplo: $F(x,y) = x\,y\,\mathrm{e}^{-x-y}$

Busquemos los extremos de

$$F(x,y) = x\,y\,\mathrm{e}^{-x-y}, \qquad (x,y) \in U = \{(x,y) \in \mathbb{R}^2 : x > 0,\ y > 0\}$$

Se puede derivar F directamente, pero como $F > 0$ en U es más simple trabajar con $G = \ln F$, porque ln es estrictamente creciente:

$$G(x,y) = \ln x + \ln y - x - y$$

Puntos críticos.

$$G'_x = \frac{1}{x} - 1 = 0, \qquad G'_y = \frac{1}{y} - 1 = 0 \quad \Longrightarrow \quad (x,y) = (1,1)$$

Por el ítem 1, $(1,1)$ es también el único punto crítico de F en U.

Hessiana.

$$H_G(x,y) = \begin{pmatrix} -\frac{1}{x^2} & 0 \\ 0 & -\frac{1}{y^2} \end{pmatrix}, \qquad \Delta^{(1)} = -\frac{1}{x^2} < 0, \qquad \Delta^{(2)} = \frac{1}{x^2 y^2} > 0$$

La hessiana de G es definida negativa en todo U, que es abierto y convexo, así que G es estrictamente cóncava y $(1,1)$ es su único máximo global. Por el primer resultado de esta sección, $(1,1)$ es también el único máximo global de F, con $F(1,1) = \mathrm{e}^{-2} \approx 0.14$.

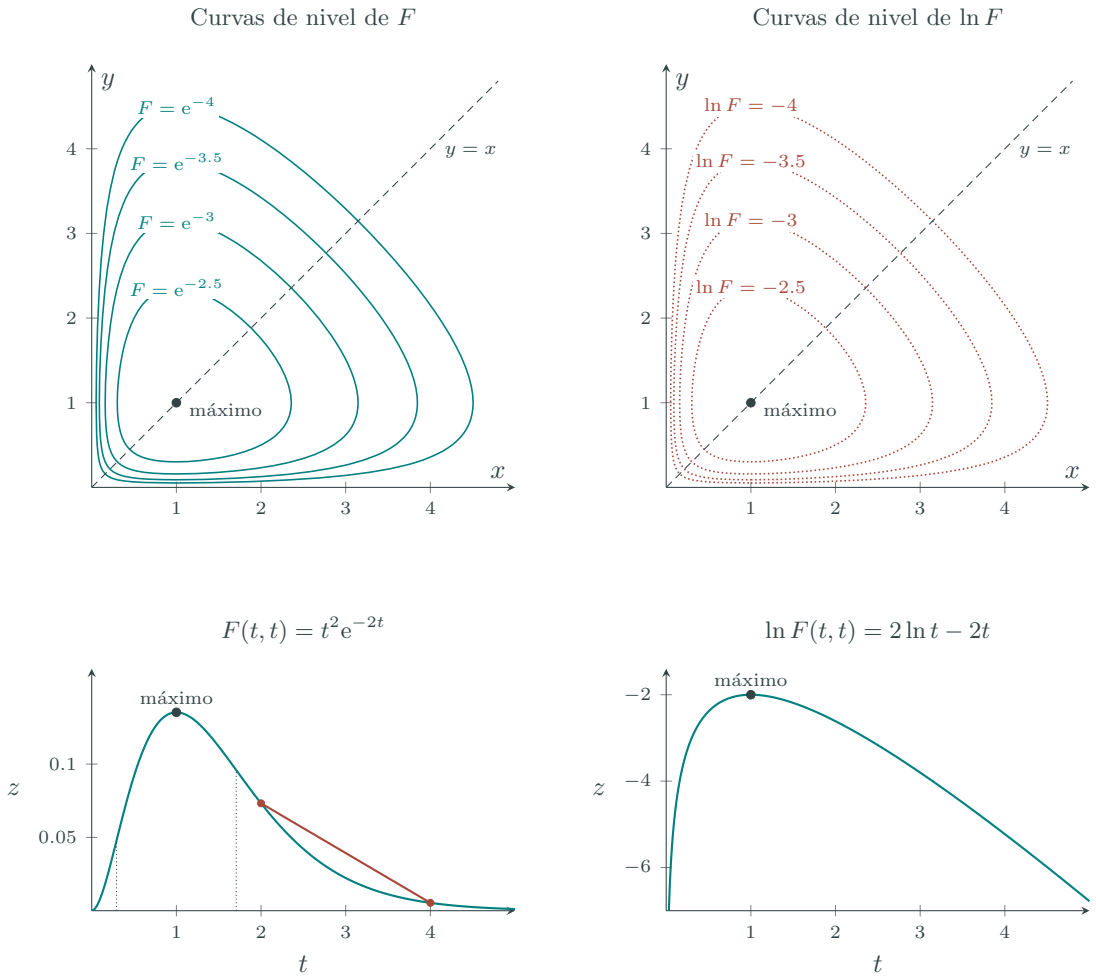
Observación. F no es cóncava. Por ejemplo,

$$H_F(2,2) = \mathrm{e}^{-4} \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

es indefinida. El teorema de óptimos globales no se aplica a F, pero sí a $G = \ln F$: la transformación creciente es la que permite concluir.

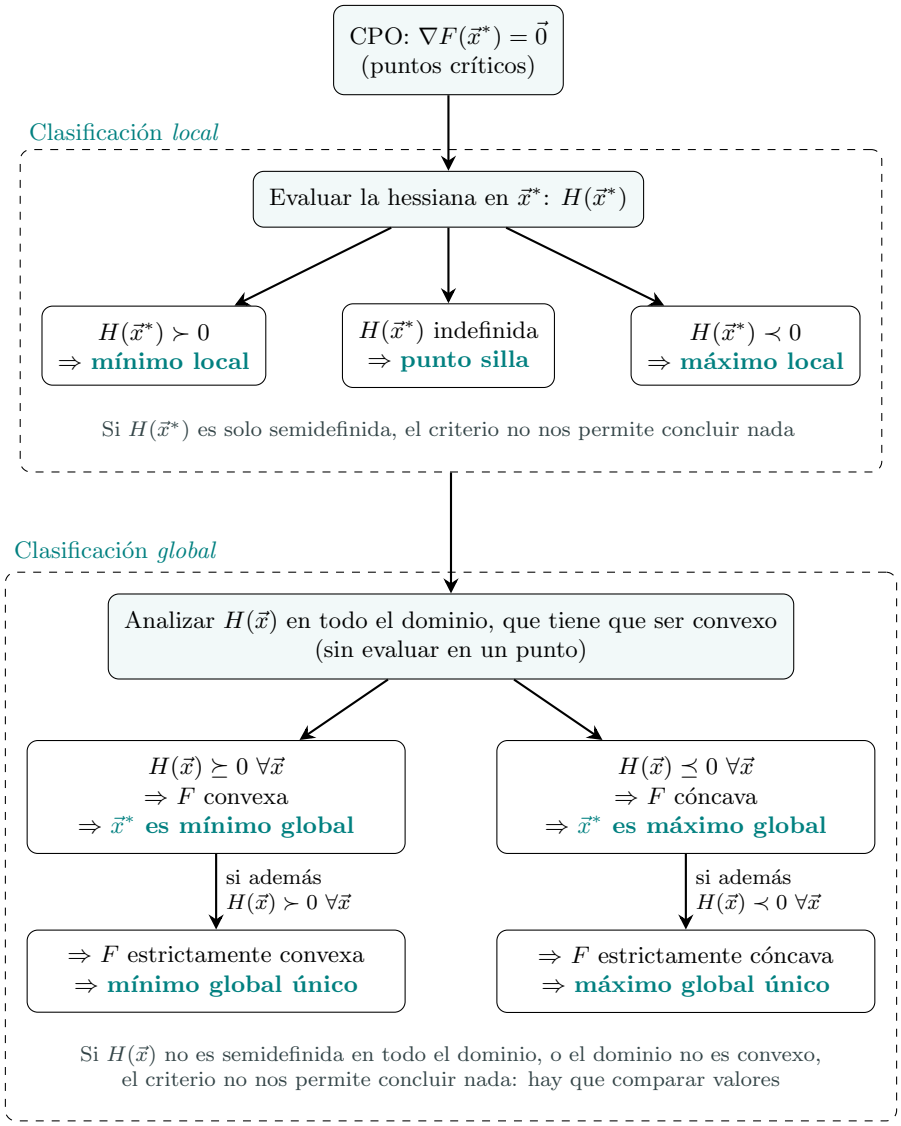
En el gráfico, arriba están las curvas de nivel de F y de $G = \ln F$: son las mismas, porque la transformación cambia el valor de cada nivel, no la curva, y por eso las dos funciones alcanzan el máximo en el mismo punto. Las de G van punteadas porque sus niveles son negativos.

Abajo está el valor de cada función sobre la recta $y = x$, que pasa por el máximo. Los puntos de esa recta son de la forma (t, t), así que se grafican $F(t,t) = t^2 e^{-2t}$ y $\ln F(t,t) = 2\ln t - 2t$, con la misma escala horizontal que arriba: es la curva que queda sobre la superficie si se la corta con el plano vertical que pasa por esa recta. Las líneas de puntos marcan los puntos de inflexión de $F(t,t)$, en $t = 1 \pm 1/\sqrt{2}$, es decir, $t \approx 0.29$ y $t \approx 1.71$, y la secante entre $t = 2$ y $t = 4$ queda por encima de la curva. Si F fuera cóncava, también lo sería sobre cualquier recta, así que F no es cóncava. En cambio, $\ln F(t,t)$ es cóncava, como G.



Conclusión. $(1, 1)$ es el único máximo global de F en U.

Esquema de análisis (sin restricciones)



21 Aplicaciones económicas de optimización libre

Teorema de la envolvente

Consideremos el problema de maximización sin restricciones

$$\max_{x,y} \; f(x, y, \phi)$$

donde x, y son variables endógenas y ϕ es un parámetro exógeno.

Condiciones de óptimo. Supongamos que f es de clase C^2. Las condiciones necesarias de primer orden en el óptimo $(x^*(\phi), y^*(\phi))$ son

$$f'_x\big(x^*(\phi),\, y^*(\phi),\, \phi\big) = 0 \qquad f'_y\big(x^*(\phi),\, y^*(\phi),\, \phi\big) = 0 \tag{1}$$

Para que el punto sea un máximo alcanza con la condición de segundo orden: que la hessiana de f respecto de x e y, evaluada en el óptimo, sea definida negativa.[16]

Función de valor. Sustituyendo en la función objetivo obtenemos la función de valor (también llamada función objetivo indirecta)

$$V(\phi) = f\big(x^*(\phi),\, y^*(\phi),\, \phi\big)$$

La función V depende solo de ϕ, mientras que f depende de x, de y y de ϕ.

Derivada de la función de valor. Al derivar V respecto de ϕ con la regla de la cadena:

$$\frac{dV}{d\phi} = f'_x \frac{dx^*}{d\phi} + f'_y \frac{dy^*}{d\phi} + f'_\phi$$

donde todos los términos f'_x, f'_y, f'_ϕ se evalúan en $\big(x^*(\phi), y^*(\phi), \phi\big)$.

Pero por las condiciones de primer orden (1) se tiene $f'_x = f'_y = 0$ en el óptimo, y por lo tanto

$$\frac{dV}{d\phi} = f'_\phi\big(x^*(\phi),\, y^*(\phi),\, \phi\big)$$

Teorema de la envolvente. La derivada de la función de valor respecto del parámetro ϕ es el efecto directo de ϕ sobre f, evaluado en el óptimo. Los efectos indirectos, a través de $x^*(\phi)$ e $y^*(\phi)$, no se ignoran: se anulan, porque en el óptimo $f'_x = f'_y = 0$.

Interpretación. El resultado muestra que, en el óptimo, no hace falta calcular $dx^*/d\phi$ ni $dy^*/d\phi$ para conocer $\frac{dV}{d\phi}$: basta con el efecto directo f'_ϕ.

Método 21.1 | Calcular cómo cambia el valor óptimo cuando cambia un parámetro

Cuándo usarlo. En un problema sin restricciones, se pide cómo cambia el valor máximo (o mínimo) cuando cambia un parámetro; por ejemplo, cómo cambia el beneficio máximo de una empresa cuando sube el precio.

Pasos.

1. Escribir la función objetivo con el parámetro a la vista, $f(x, y, \phi)$, y hallar el óptimo $\big(x^*(\phi), y^*(\phi)\big)$.
2. Derivar f respecto de ϕ, con x e y fijas: $f'_\phi(x, y, \phi)$.

[16] Para derivar V con la regla de la cadena hace falta, además, que x^* e y^* sean funciones derivables de ϕ. Eso lo da el teorema de la función implícita: las condiciones de primer orden son un sistema de dos ecuaciones con incógnitas x e y, y el teorema pide que el jacobiano del sistema respecto de (x, y) no se anule en el óptimo. Como el sistema se arma con f'_x y f'_y, su jacobiano es el determinante de la hessiana de f: $J = \det\left(\begin{smallmatrix} f''_{xx} & f''_{xy} \\ f''_{yx} & f''_{yy} \end{smallmatrix}\right) = \det H$. Son dos condiciones distintas sobre la misma matriz, y la primera implica la segunda: si H es definida negativa, $\det H > 0$, así que $J \neq 0$.

3. Evaluar esa derivada en el óptimo: $\dfrac{dV}{d\phi} = f'_\phi\big(x^*(\phi), y^*(\phi), \phi\big)$.

Chequeo. Si $V(\phi)$ tiene una fórmula, derivarla directamente tiene que dar lo mismo.

Cuidado. Primero se deriva y después se reemplaza el óptimo. Si se reemplaza antes, lo que queda es $V(\phi)$, y hay que derivarla entera con la regla de la cadena (el camino largo del Chequeo). Y f'_ϕ evaluada fuera del óptimo no es $dV/d\phi$.

Intuición: ¿por qué "teorema de la envolvente"?

Fijemos un punto (x_0, y_0) y miremos $f(x_0, y_0, \phi)$ como función de ϕ solamente: su gráfico es una curva en el plano (ϕ, z), y hay una curva así por cada punto (x_0, y_0). Como $V(\phi)$ es el máximo de f sobre todos los puntos,

$$V(\phi) \geq f(x_0, y_0, \phi) \qquad \text{para todo } \phi$$

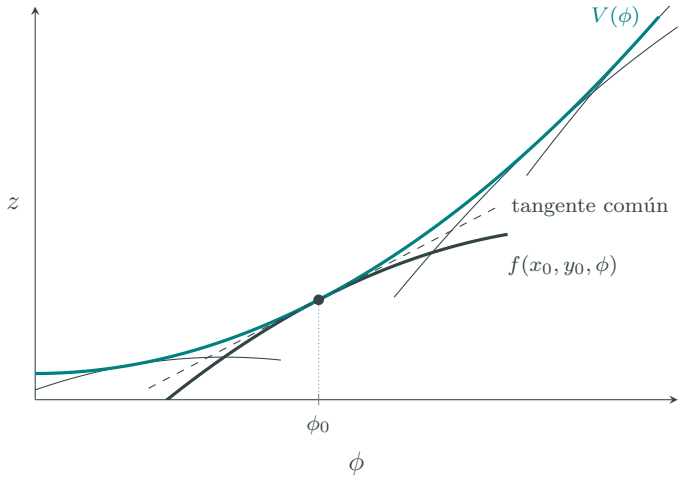
así que el gráfico de V queda por encima de todas esas curvas. Si además (x_0, y_0) es el óptimo cuando el parámetro vale ϕ_0, en ϕ_0 vale la igualdad y la curva toca al gráfico de V. Por eso se dice que V es la *envolvente* de la familia de curvas.

En el punto de contacto, V y la curva son tangentes. La diferencia $V(\phi) - f(x_0, y_0, \phi)$ nunca es negativa y vale 0 en ϕ_0, así que tiene un mínimo en ϕ_0 y su derivada se anula ahí:

$$V'(\phi_0) = f'_\phi(x_0, y_0, \phi_0)$$

Es el teorema de la envolvente, visto en el gráfico: la pendiente de V es la pendiente de la curva que la toca.

En la figura, cada curva es f con (x, y) fijo en un punto distinto. Todas quedan por debajo de V, y cada una la toca en el valor de ϕ para el que su punto es el óptimo. La curva resaltada es la del punto (x_0, y_0): toca a V en ϕ_0, y ahí las dos tienen la misma recta tangente, así que la misma pendiente.



Ejemplo de envolvente con $f(x;t) = t\,x^2 + x + 10$

Consideremos la familia de funciones

$$f(x;t) = t\,x^2 + x + 10 \qquad x \in \mathbb{R},\ t < 0$$

donde x es la variable de decisión y t un parámetro exógeno. Tomamos $t < 0$ para garantizar que la maximización en x sea bien comportada (coeficiente de x^2 negativo).

Función de valor. Definimos la función de valor

$$V(t) = \max_{x \in \mathbb{R}} f(x;t)$$

Condición de primer orden. Para cada $t < 0$, el óptimo $x^*(t)$ satisface

$$f'_x = 2\,t\,x + 1 = 0 \quad \Longrightarrow \quad x^*(t) = -\frac{1}{2t}$$

Cálculo de la envolvente. Sustituyendo $x^*(t)$ en f:

$$V(t) = f\big(x^*(t);t\big) = t\Big(-\tfrac{1}{2t}\Big)^2 + \Big(-\tfrac{1}{2t}\Big) + 10 = \frac{1}{4t} - \frac{1}{2t} + 10 = 10 - \frac{1}{4t}$$

Derivada de la función de valor. Directamente,

$$V'(t) = \frac{d}{dt}\Big(10 - \tfrac{1}{4t}\Big) = \frac{1}{4t^2}$$

Por el teorema de la envolvente, también debe cumplirse

$$V'(t) = f'_t\big(x^*(t);t\big) = x^*(t)^2 = \Big(-\tfrac{1}{2t}\Big)^2 = \frac{1}{4t^2}$$

confirmando que los efectos indirectos vía $x^*(t)$ se anulan en la derivada de la función de valor.

Interpretación.

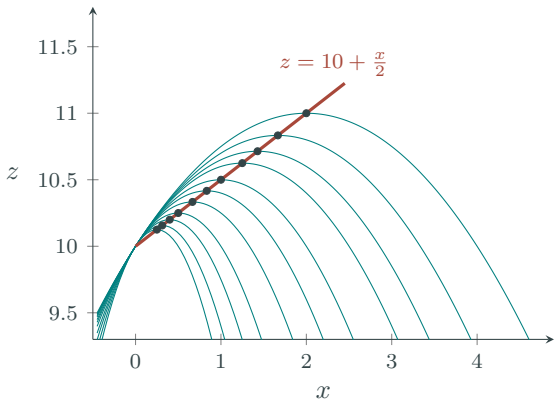
- Cada f es una parábola cóncava en x (porque $t < 0$).
- El teorema de la envolvente nos dice que para medir el impacto de t sobre el máximo, basta con f'_t evaluada en el óptimo.

La envolvente en el gráfico. Para cada x_0 fijo, $f(x_0;t) = x_0^2\,t + x_0 + 10$ es una recta en el plano (t,z), con pendiente x_0^2. Como $x^*(t) = -1/(2t)$, el punto $x_0 > 0$ es el óptimo cuando $t_0 = -1/(2x_0)$, y ahí la recta toca a V con la misma pendiente:

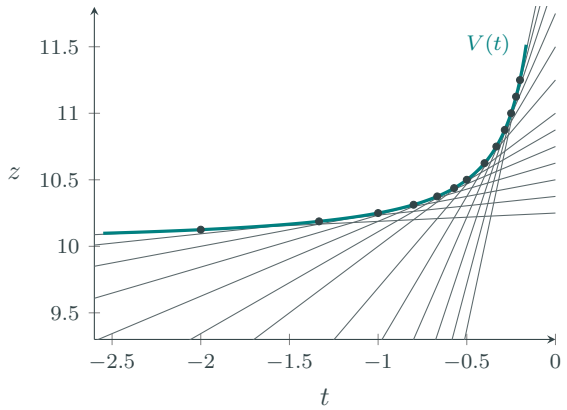
$$V'(t_0) = \frac{1}{4t_0^2} = x_0^2 = f'_t(x_0;t_0)$$

A la izquierda, parábolas de la familia, con su máximo marcado: está en $x^*(t)$ y su altura es $V(t)$. A la derecha, esas alturas como función de t forman el gráfico de V, y cada recta es f con x fijo. Por ejemplo, la parábola de $t = -0.25$, la de más afuera, tiene su máximo en $x = 2$, a la altura 11, y la recta de $x = 2$ toca a V en $t = -0.25$, a la misma altura.

Parábolas $f(x;t)$, con t fijo



Rectas $f(x;t)$, con x fijo, y $V(t)$



En el gráfico se ve la diferencia entre los dos planos. A la izquierda, con x fijo, f crece con t (porque $f'_t = x^2 > 0$ si $x \neq 0$), así que las parábolas no se cruzan, salvo en $(0, 10)$, por donde pasan todas. La recta $z = 10 + x/2$ pasa por sus máximos (en el máximo, $x^* = -1/(2t)$ y $V = 10 - 1/(4t) = 10 + x^*/2$), pero las atraviesa: no es tangente a ninguna, así que no es una envolvente. A la derecha, cada recta toca al gráfico de V en un punto y queda por debajo en el resto, y V aparece como el borde de arriba de todas ellas: es su envolvente.

Maximización de beneficios: lema de Hotelling

Consideremos una empresa que produce una cantidad $q > 0$ de un bien y enfrenta un precio de mercado $p > 0$. Su beneficio π viene dado por

$$\pi(q; p) = p\,q - C(q)$$

donde $C(q)$ es su función de costos, asumida de clase C^2 y estrictamente convexa ($C''(q) > 0$).

Problema de optimización. Para cada precio p la empresa elige q para

$$\max_{q>0} \ \pi(q; p)$$

Las condiciones de primer y segundo orden son:

$$\pi'_q = p - C'(q) = 0 \quad \Longrightarrow \quad C'(q^*) = p$$

$$\pi''_{qq} = -C''(q) < 0 \text{ para todo } q \quad \Longrightarrow \quad \pi \text{ es estrictamente cóncava en } q \text{ y } q^*(p) \text{ es el único máximo}$$

Beneficio máximo. Definimos la función de valor (el beneficio máximo) como

$$\Pi(p) = \pi\big(q^*(p); p\big) = p\,q^*(p) - C\big(q^*(p)\big)$$

Derivada del beneficio máximo. Al derivar $\Pi(p)$ respecto de p, por el teorema de la envolvente

$$\frac{d\Pi}{dp} = \pi'_p\big(q^*(p); p\big) = q^*(p)$$

sin necesidad de calcular dq^*/dp, porque $\pi'_q = 0$ en el óptimo. **Lema de Hotelling.** La derivada del beneficio máximo respecto del precio es la oferta de la empresa.

Función concreta. Supongamos $C(q) = \frac{1}{2}\,c\,q^2$ con $c > 0$. Entonces

$$C'(q) = c\,q \quad C''(q) = c > 0$$

y la condición de primer orden $p = c\,q$ da

$$q^*(p) = \frac{p}{c} \qquad \Pi(p) = p \cdot \frac{p}{c} - \tfrac{1}{2}\,c\Big(\tfrac{p}{c}\Big)^2 = \frac{p^2}{2c}$$

Verifiquemos la envolvente:

$$\frac{d\Pi}{dp} = \frac{d}{dp}\Big(\tfrac{p^2}{2c}\Big) = \frac{p}{c} = q^*(p)$$

Cómo cambia la cantidad óptima. La envolvente dice cómo cambia el beneficio máximo, no cómo cambia q^*. Para eso se deriva la condición de primer orden respecto del parámetro. Con una sola variable de decisión, como $f'_x\big(x^*(\phi), \phi\big) = 0$ para todo ϕ,

$$f''_{xx}\,\frac{dx^*}{d\phi} + f''_{x\phi} = 0 \quad \Longrightarrow \quad \frac{dx^*}{d\phi} = -\frac{f''_{x\phi}}{f''_{xx}}$$

con las derivadas evaluadas en $\big(x^*(\phi), \phi\big)$. En la empresa, $\pi''_{qp} = 1$ y $\pi''_{qq} = -C''(q)$, así que

$$\frac{dq^*}{dp} = \frac{1}{C''\big(q^*(p)\big)} > 0$$

y la oferta tiene pendiente positiva. Con $C(q) = \frac{1}{2}\, c\, q^2$ da $1/c$, lo mismo que derivar $q^*(p) = p/c$.

Interpretación.

- La condición de primer orden $\pi'_q = 0$ da la oferta óptima $q^*(p)$.
- El teorema de la envolvente permite calcular la sensibilidad del beneficio máximo al precio p simplemente con $\pi'_p = q$, evaluada en $q^*(p)$, sin derivar la curva de oferta $q^*(p)$. Como $\frac{d\Pi}{dp} = q^*(p) > 0$, el beneficio máximo aumenta con el precio, a una tasa igual a la cantidad producida.

Una empresa que elige capital y trabajo

Una empresa produce con capital $K > 0$ y trabajo $L > 0$, con la función de producción $F(K, L) = K^{1/4} L^{1/4}$. Vende lo que produce a un precio p, paga un salario w por unidad de trabajo y un alquiler r por unidad de capital. Su beneficio es

$$\pi(K, L; p, w, r) = p\, K^{1/4} L^{1/4} - w\, L - r\, K$$

y elige K y L sin restricciones.

Condiciones de primer orden.

$$\pi'_K = \tfrac{1}{4}\, p\, K^{-3/4} L^{1/4} - r = 0 \qquad \pi'_L = \tfrac{1}{4}\, p\, K^{1/4} L^{-3/4} - w = 0$$

Pasando r y w al otro lado y dividiendo la primera ecuación por la segunda, $L/K = r/w$. Reemplazando $L = (r/w)\, K$ en la primera, $\frac{1}{4}\, p\, K^{-1/2} (r/w)^{1/4} = r$, y despejando:

$$K^* = \frac{p^2}{16\, r^{3/2}\, w^{1/2}} \qquad L^* = \frac{p^2}{16\, w^{3/2}\, r^{1/2}}$$

La cantidad producida es $q^* = F(K^*, L^*) = \dfrac{p}{4\sqrt{rw}}$.

Condición de segundo orden. La hessiana de π respecto de (K, L) es

$$H_\pi = \begin{pmatrix} -\frac{3}{16}\, p\, K^{-7/4} L^{1/4} & \frac{1}{16}\, p\, K^{-3/4} L^{-3/4} \\ \frac{1}{16}\, p\, K^{-3/4} L^{-3/4} & -\frac{3}{16}\, p\, K^{1/4} L^{-7/4} \end{pmatrix}$$

Sus menores principales líderes son $-\frac{3}{16}\, p\, K^{-7/4} L^{1/4} < 0$ y $\det H_\pi = \frac{1}{32}\, p^2 (KL)^{-3/2} > 0$ para todo $K, L > 0$: es definida negativa en todo el dominio. Por lo tanto, π es estrictamente cóncava y (K^*, L^*) es el único máximo global.

Derivadas del beneficio máximo. Sea $\Pi(p, w, r) = \pi\big(K^*, L^*; p, w, r\big)$ el beneficio máximo. Por el teorema de la envolvente, basta con derivar π respecto de cada precio, con K y L fijos, y evaluar en el óptimo:

$$\Pi'_w = -L^* \qquad \Pi'_r = -K^* \qquad \Pi'_p = F(K^*, L^*) = q^*$$

Si sube el salario, el beneficio máximo baja a una tasa igual al trabajo que la empresa contrata, y si sube el alquiler del capital, a una tasa igual al capital que usa. Es el lema de Hotelling con dos factores: las derivadas del beneficio máximo dan las demandas de los factores, con el signo cambiado, y la oferta. Para obtenerlas no hizo falta calcular Π, porque K^* y L^* ya estaban calculados al resolver el problema.

Chequeo. Por el camino largo, reemplazando K^* y L^* en π (con $wL^* = rK^*$), $\Pi(p, w, r) = \dfrac{p^2}{8\sqrt{rw}}$, y derivando, $\Pi'_w = -\dfrac{p^2}{16\, w^{3/2}\, r^{1/2}} = -L^*$. Lo mismo con r y con p.

Con números. Con $p = 4$ y $w = r = 1$: $K^* = L^* = 1$, $q^* = 1$ y $\Pi = 4 - 1 - 1 = 2$. Si el salario sube a 1.1, la envolvente da

$$\Delta\Pi \approx \Pi'_w \, \Delta w = -1 \cdot 0.1 = -0.1$$

y el cambio exacto es $\frac{2}{\sqrt{1.1}} - 2 \approx -0.09$. La diferencia es lo que gana la empresa al usar menos trabajo (y también menos capital) cuando sube el salario; para cambios chicos es despreciable.

Otro ejemplo: monopolista con dos bienes

Sea un monopolista que produce dos bienes, en cantidades $q_1, q_2 > 0$, con demanda inversa lineal

$$p_1(q_1, q_2) = a_1 - b_{11}\, q_1 - b_{12}\, q_2 \qquad p_2(q_1, q_2) = a_2 - b_{21}\, q_1 - b_{22}\, q_2$$

y costos lineales

$$C(q_1, q_2) = c_1\, q_1 + c_2\, q_2$$

Cada a_i es la ordenada al origen de la demanda inversa del bien i, cada b_{ij} dice cuánto baja el precio del bien i cuando aumenta la cantidad del bien j, y cada c_i es el costo marginal del bien i. Entonces el beneficio es

$$\begin{aligned}\pi(q_1, q_2) &= p_1\, q_1 + p_2\, q_2 - C(q_1, q_2) \\ &= \big(a_1 - b_{11}q_1 - b_{12}q_2\big)q_1 + \big(a_2 - b_{21}q_1 - b_{22}q_2\big)q_2 - \big(c_1q_1 + c_2q_2\big)\end{aligned}$$

Condiciones de primer orden. Para encontrar el máximo, derivamos la función de beneficio respecto a cada cantidad e igualamos a cero. Hay que tener en cuenta que q_1 también aparece en el ingreso del bien 2: p_2q_2 tiene el término $-b_{21}\, q_1q_2$, que al derivar respecto de q_1 da $-b_{21}\, q_2$.

La derivada respecto a q_1 es:

$$\pi'_{q_1} = (a_1 - 2b_{11}\, q_1 - b_{12}\, q_2) + (-b_{21}\, q_2) - c_1 = a_1 - c_1 - 2b_{11}\, q_1 - (b_{12} + b_{21})\, q_2 = 0$$

La derivada respecto a q_2 es:

$$\pi'_{q_2} = (-b_{12}\, q_1) + (a_2 - b_{21}\, q_1 - 2b_{22}\, q_2) - c_2 = a_2 - c_2 - (b_{12} + b_{21})\, q_1 - 2b_{22}\, q_2 = 0$$

Esto nos da un sistema de dos ecuaciones lineales:

$$\begin{cases} 2b_{11}\, q_1 + (b_{12} + b_{21})\, q_2 = a_1 - c_1 \\ (b_{12} + b_{21})\, q_1 + 2b_{22}\, q_2 = a_2 - c_2 \end{cases}$$

Resolviendo este sistema (por ejemplo, usando la regla de Cramer o sustitución) se obtienen las cantidades óptimas:

$$q_1^* = \frac{2b_{22}\,(a_1 - c_1) - (b_{12} + b_{21})(a_2 - c_2)}{4b_{11}b_{22} - (b_{12} + b_{21})^2}$$

$$q_2^* = \frac{2b_{11}\,(a_2 - c_2) - (b_{12} + b_{21})(a_1 - c_1)}{4b_{11}b_{22} - (b_{12} + b_{21})^2}$$

Condición de segundo orden. La hessiana de π respecto a (q_1, q_2) es:

$$H_\pi = \begin{pmatrix} \pi''_{q_1q_1} & \pi''_{q_1q_2} \\ \pi''_{q_2q_1} & \pi''_{q_2q_2} \end{pmatrix} = \begin{pmatrix} -2b_{11} & -(b_{12} + b_{21}) \\ -(b_{12} + b_{21}) & -2b_{22} \end{pmatrix}$$

Si la hessiana es definida negativa, (q_1^*, q_2^*) es un máximo. Como no depende de q_1 ni de q_2 (π es cuadrática), es definida negativa en todo el dominio: π es estrictamente cóncava y el máximo es global y único. La hessiana es definida negativa si

$$-2b_{11} < 0 \quad \Longrightarrow \quad b_{11} > 0$$

y su determinante es positivo:

$$\det H_\pi = (-2b_{11})(-2b_{22}) - \big(-(b_{12}+b_{21})\big)\big(-(b_{12}+b_{21})\big) = 4\,b_{11}\,b_{22} - (b_{12}+b_{21})^2 > 0$$

Notemos que este determinante es el denominador de q_1^* y q_2^* (es el jacobiano del sistema de condiciones de primer orden): si se cumple la condición de segundo orden, es positivo y el sistema tiene una única solución.

Sensibilidad respecto de b_{11} y a_2. Al aplicar el teorema de la envolvente al beneficio máximo Π, basta con derivar la función de beneficio π respecto de los parámetros b_{11} y a_2, y después evaluar en el óptimo (q_1^*, q_2^*).

$$\pi'_{b_{11}} = -\,q_1^2 \quad \Longrightarrow \quad \Pi'_{b_{11}} = -\big(q_1^*\big)^2$$

$$\pi'_{a_2} = q_2 \quad \Longrightarrow \quad \Pi'_{a_2} = q_2^*$$

Cómo cambian las cantidades. La envolvente dice cómo cambia el beneficio máximo. Para ver cómo cambian las cantidades alcanza con derivar q_1^* y q_2^*, que son explícitas. Con $D = 4b_{11}b_{22} - (b_{12}+b_{21})^2$, la derivada de q_2^* respecto de a_2 es $2b_{11}/D > 0$, y la de q_1^*, $-(b_{12}+b_{21})/D$. Si $b_{12}+b_{21} > 0$, cuando sube la demanda del bien 2 el monopolista produce más del bien 2 y menos del bien 1.

Interpretación.

- Un aumento de b_{11} (el precio del bien 1 baja más rápido cuando aumenta su cantidad) **reduce el beneficio máximo**, ya que $\Pi'_{b_{11}} = -(q_1^*)^2 < 0$.
- Un aumento de a_2 (mayor disposición a pagar por el bien 2) **incrementa el beneficio máximo**, ya que $\Pi'_{a_2} = q_2^*$, que es positiva si el monopolista produce el bien 2.

22 Optimización con restricciones de igualdad

Optimización con restricciones y lagrangiano

En muchos problemas de optimización no basta con minimizar (o maximizar) una función objetivo $f\colon \mathbb{R}^n \to \mathbb{R}$ libremente: es preciso hacerlo sujeto a ciertas restricciones que deben cumplirse. En este apartado vamos a revisar el método de los *multiplicadores de Lagrange* (o método del lagrangiano), que es una herramienta fundamental para abordar problemas con restricciones de igualdad.

Formulación del problema

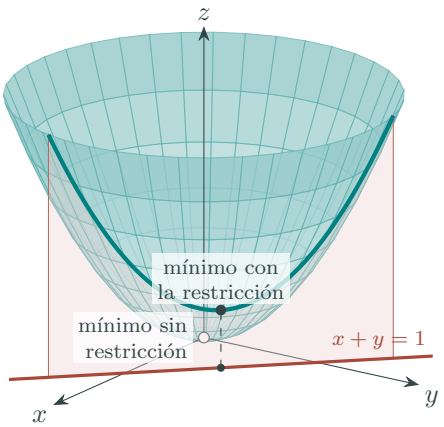
Consideremos el problema de minimizar (o maximizar) f sujeta a k restricciones:

$$\begin{aligned} &\min_{\vec{x}\in\mathbb{R}^n} f(\vec{x}) \\ &\text{sujeto a} \quad g_i(\vec{x}) = c_i, \quad i = 1, \dots, k \end{aligned}$$

donde $f\colon \mathbb{R}^n \to \mathbb{R}$ y $g_i\colon \mathbb{R}^n \to \mathbb{R}$ son funciones de clase C^1, los c_i son constantes, $k < n$ (más variables que restricciones) y las ecuaciones $g_i(\vec{x}) = c_i$ definen el conjunto factible. Todos los vectores son columna; cuando los escribimos en una línea, van como fila transpuesta: $\vec{x} = (x_1, \dots, x_n)^T$.

Con dos variables, optimizar f sujeta a $g(x, y) = c$ es buscar el punto más alto o más bajo de la curva que queda sobre la superficie $z = f(x, y)$, justo arriba de la restricción. En la figura, $f(x, y) = x^2 + y^2$ y la restricción es la recta $x + y = 1$: sobre ella, f vale $x^2 + (1 - x)^2$, una parábola cuyo punto más bajo está arriba de $\left(\frac{1}{2}, \frac{1}{2}\right)$, a la altura 0.5. El mínimo de f sin la restricción, en el origen, no está sobre la recta.

$$f(x, y) = x^2 + y^2 \text{ sobre la recta } x + y = 1$$



El lagrangiano

Definimos la función lagrangiana asociada al problema como

$$\mathcal{L}(\vec{x}, \vec{\lambda}) = f(\vec{x}) + \sum_{i=1}^{k} \lambda_i \left(c_i - g_i(\vec{x})\right)$$

donde $\vec{\lambda} = (\lambda_1, \dots, \lambda_k)^T$ tiene un multiplicador por cada restricción. Cada restricción entra con la constante menos la función: por ejemplo, con la restricción $x + y = 1$, el lagrangiano es $f(x, y) + \lambda\,(1 - x - y)$.

El lagrangiano también puede armarse al revés:

$$\mathcal{L}(\vec{x}, \vec{\lambda}) = f(\vec{x}) + \sum_{i=1}^{k} \lambda_i \left(g_i(\vec{x}) - c_i\right)$$

Da lo mismo, porque cada λ_i es una variable artificial que puede ser positiva o negativa (de hecho, la restricción $g_i(\vec{x}) = c_i$ puede multiplicarse por -1 en ambos lados y sigue siendo válida). Lo único que cambia es el signo de los λ_i que se obtienen. En este libro usamos siempre la primera forma.

Condiciones de primer orden

Si $\vec{x}^*$ es un máximo o un mínimo local del problema[17], existe $\vec{\lambda}^*$ tal que $(\vec{x}^*, \vec{\lambda}^*)$ satisface las siguientes condiciones:

$$\nabla f(\vec{x}^*) = \sum_{i=1}^{k} \lambda_i^* \nabla g_i(\vec{x}^*) \qquad g_i(\vec{x}^*) = c_i, \quad i = 1, \ldots, k$$

La primera dice que se anulan las derivadas de $\mathcal{L}$ respecto de cada x_j, es decir, $\nabla_{\vec{x}} \mathcal{L}(\vec{x}^*, \vec{\lambda}^*) = \vec{0}$. La segunda, que se anulan las derivadas respecto de cada λ_i, porque $\mathcal{L}'_{\lambda_i} = c_i - g_i$.

Estas condiciones son las mismas para maximizar o minimizar: son las de un punto crítico de $\mathcal{L}$, como en un problema de optimización libre, por lo que el método del lagrangiano nos proporciona una simplificación del problema a cambio de agregar un multiplicador por cada restricción. Pero $(\vec{x}^*, \vec{\lambda}^*)$ no es un máximo ni un mínimo de $\mathcal{L}$ (es un punto silla), así que para clasificarlo no sirve el criterio de la hessiana: se usa el hessiano orlado, que presentamos en las condiciones de segundo orden.

Interpretación geométrica

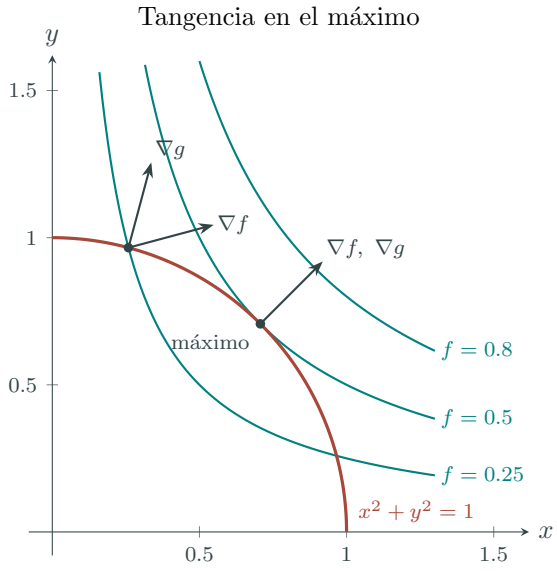
Geométricamente, en el punto óptimo $\vec{x}^*$ el gradiente de la función objetivo debe poder expresarse como combinación lineal de los gradientes de las restricciones:

$$\nabla f(\vec{x}^*) \in \text{span}\{\nabla g_1(\vec{x}^*), \ldots, \nabla g_k(\vec{x}^*)\}$$

Con dos variables y una restricción, $\nabla f(\vec{x}^*)$ y $\nabla g(\vec{x}^*)$ son paralelos: la curva de nivel de f que pasa por $\vec{x}^*$ es tangente a la curva $g = c$.

La figura lo muestra para $f(x, y) = xy$ con la restricción $x^2 + y^2 = 1$, que es el segundo ejemplo de esta sección (las flechas indican solo la dirección de cada gradiente, no su largo). En $\left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$, la curva de nivel $f = 0.5$ toca la circunferencia sin cortarla, y los dos gradientes tienen la misma dirección. En el otro punto marcado, donde la circunferencia corta a la curva $f = 0.25$, los gradientes no son paralelos: moviéndose sobre la circunferencia hacia la recta $y = x$, f aumenta, así que ese punto no es un máximo. Los niveles mayores que 0.5, como $f = 0.8$, no llegan a tocar la circunferencia.

[17] Hace falta, además, que los gradientes $\nabla g_1(\vec{x}^*), \ldots, \nabla g_k(\vec{x}^*)$ sean linealmente independientes; con una sola restricción, que $\nabla g(\vec{x}^*) \neq \vec{0}$. Sin esta hipótesis el resultado puede fallar: el máximo de $f(x, y) = x$ sujeto a $x^3 + y^2 = 0$ está en $(0, 0)$ (la restricción obliga a que $x \leq 0$), pero ahí $\nabla g = \vec{0}$ y $\nabla f = (1, 0)^T$, así que ningún λ cumple $\nabla f = \lambda \nabla g$.



Ejemplo: minimización con restricción lineal

Consideremos el problema

$$\min_{x,y\in\mathbb{R}} f(x,y) = x^2 + y^2$$
$$\text{sujeto a} \quad x + y = 1$$

El lagrangiano asociado es

$$\mathcal{L}(x,y,\lambda) = x^2 + y^2 + \lambda\,(1 - x - y)$$

Las condiciones de primer orden son

$$\mathcal{L}'_x = 2x - \lambda = 0 \qquad \mathcal{L}'_y = 2y - \lambda = 0 \qquad \mathcal{L}'_\lambda = 1 - x - y = 0$$

Es conveniente recordar que la condición $\mathcal{L}'_\lambda = 0$ no es más que la restricción $x + y = 1$.

De las dos primeras ecuaciones se obtiene

$$x = \frac{\lambda}{2} \qquad y = \frac{\lambda}{2}$$

y sustituyendo en la restricción $x + y = 1$ resulta $\lambda = 1$. Por lo tanto,

$$x^* = y^* = \tfrac{1}{2} = 0.5$$

Es el único candidato. Lo clasificamos más adelante, con las condiciones de segundo orden.

Ejemplo: maximización con restricción no lineal

Consideremos el problema

$$\max_{x,y\in\mathbb{R}} f(x,y) = x\,y$$
$$\text{sujeto a} \quad x^2 + y^2 = 1$$

El lagrangiano es

$$\mathcal{L}(x,y,\lambda) = x\,y + \lambda\big(1 - x^2 - y^2\big)$$

Las condiciones de primer orden son

$$\mathcal{L}'_x = y - 2\lambda\,x = 0 \tag{2}$$

$$\mathcal{L}'_y = x - 2\lambda y = 0 \tag{3}$$

$$\mathcal{L}'_\lambda = 1 - x^2 - y^2 = 0 \tag{4}$$

De (2) y (3), $y = 2\lambda x$ y $x = 2\lambda y$, así que $y = 4\lambda^2 y$, es decir, $y\,(1 - 4\lambda^2) = 0$. Si $y = 0$, (3) da $x = 0$, y el origen no cumple la restricción. Por lo tanto, $4\lambda^2 = 1$ y $\lambda = \pm\frac{1}{2}$.

- Con $\lambda = \frac{1}{2}$, (2) da $y = x$, y la restricción, $2x^2 = 1$: los puntos $\left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ y $\left(-\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right)$.
- Con $\lambda = -\frac{1}{2}$, $y = -x$: los puntos $\left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right)$ y $\left(-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$.

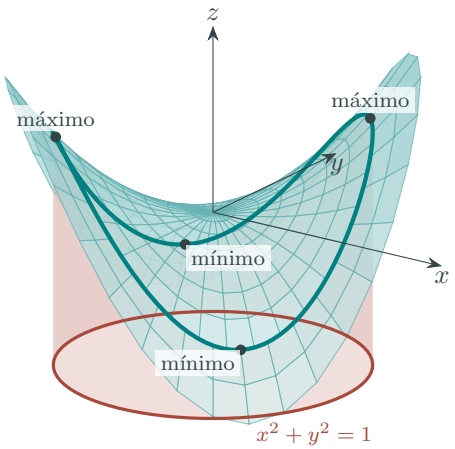
Así, los puntos críticos son

$$\left(\tfrac{1}{\sqrt{2}}, \tfrac{1}{\sqrt{2}}\right) \qquad \left(-\tfrac{1}{\sqrt{2}}, -\tfrac{1}{\sqrt{2}}\right) \qquad \left(\tfrac{1}{\sqrt{2}}, -\tfrac{1}{\sqrt{2}}\right) \qquad \left(-\tfrac{1}{\sqrt{2}}, \tfrac{1}{\sqrt{2}}\right)$$

con $\frac{1}{\sqrt{2}} \approx 0.71$. Son los candidatos a máximo (y a mínimo); los clasificamos más adelante, con las condiciones de segundo orden.

En la figura, la pared está parada sobre la circunferencia $x^2 + y^2 = 1$ y llega hasta la superficie $z = xy$: su borde de arriba son los valores de f sobre la restricción. Esa curva sube y baja dos veces, y los cuatro puntos críticos son sus dos picos, a la altura 0.5, y sus dos valles, a la altura -0.5.

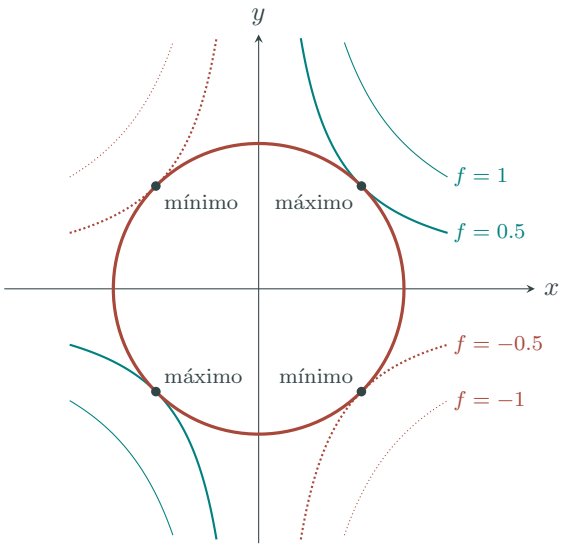
$z = xy$ sobre la circunferencia $x^2 + y^2 = 1$



Condiciones de segundo orden

Las condiciones de primer orden no distinguen un máximo de un mínimo. En el segundo ejemplo, en los cuatro candidatos la curva de nivel que pasa por el punto es tangente a la circunferencia: en los máximos, la de $f = 0.5$, y en los mínimos, la de $f = -0.5$ (cada curva está rotulada con su nivel, y las punteadas corresponden a niveles negativos). Para separarlos están las condiciones de segundo orden.

Tangencia en los máximos y en los mínimos



Para eso suponemos además que f y las g_i son de clase C^2 en un entorno de $\vec{x}^*$.

Caso concreto: dos variables y una restricción

Sea

$$f\colon \mathbb{R}^2 \to \mathbb{R} \qquad g\colon \mathbb{R}^2 \to \mathbb{R} \qquad \mathcal{L}(x,y,\lambda) = f(x,y) + \lambda\left(c - g(x,y)\right)$$

En un punto crítico (x^*, y^*, λ^*) se cumplen las condiciones de primer orden:

$$\nabla f(x^*,y^*) = \lambda^* \nabla g(x^*,y^*) \qquad g(x^*,y^*) = c$$

Definimos el *hessiano orlado* a partir de las derivadas segundas de la función lagrangiana, con λ como primera variable, en el punto crítico:

$$\begin{pmatrix} \mathcal{L}''_{\lambda\lambda} & \mathcal{L}''_{\lambda x} & \mathcal{L}''_{\lambda y} \\ \mathcal{L}''_{x\lambda} & \mathcal{L}''_{xx} & \mathcal{L}''_{xy} \\ \mathcal{L}''_{y\lambda} & \mathcal{L}''_{yx} & \mathcal{L}''_{yy} \end{pmatrix}_{(x^*,y^*,\lambda^*)}$$

Aquí,

$$\begin{aligned} \mathcal{L}''_{xx} &= f''_{xx} - \lambda^* g''_{xx} & \mathcal{L}''_{xy} &= f''_{xy} - \lambda^* g''_{xy} \\ \mathcal{L}''_{yx} &= f''_{yx} - \lambda^* g''_{yx} & \mathcal{L}''_{yy} &= f''_{yy} - \lambda^* g''_{yy} \\ \mathcal{L}''_{\lambda x} &= \mathcal{L}''_{x\lambda} = -g'_x & \mathcal{L}''_{\lambda y} &= \mathcal{L}''_{y\lambda} = -g'_y \\ \mathcal{L}''_{\lambda\lambda} &= 0 \end{aligned}$$

Por lo tanto, al evaluar:[18]

$$\bar{H} = \begin{pmatrix} 0 & g'_x & g'_y \\ g'_x & f''_{xx} - \lambda^* g''_{xx} & f''_{xy} - \lambda^* g''_{xy} \\ g'_y & f''_{yx} - \lambda^* g''_{yx} & f''_{yy} - \lambda^* g''_{yy} \end{pmatrix}_{(x^*,y^*,\lambda^*)}$$

[18] Las derivadas segundas de $\mathcal{L}$ respecto de λ son $-g'_x$ y $-g'_y$, pero el borde se escribe con g'_x y g'_y. Cambiarles el signo a la primera fila y a la primera columna multiplica el determinante dos veces por -1, así que no lo cambia, y lo mismo pasa con los menores que usa el criterio, porque todos incluyen la primera fila y la primera columna.

La submatriz de 2×2 de abajo a la derecha tiene las derivadas segundas del lagrangiano respecto de x e y, y los elementos g'_x, g'_y forman el "borde" que la convierte en el hessiano orlado. Lo escribimos $\bar{H}$ para distinguirlo del hessiano orlado que se usa para estudiar la cuasiconcavidad, que lleva en el borde las derivadas de f.

Si las variables se ordenan como (x, y, λ), el borde queda en la última fila y la última columna. Da lo mismo, porque el determinante es el mismo; en este libro el borde va siempre primero.

Restricción lineal

Cuando la restricción es lineal, el hessiano orlado se simplifica aún más: supongamos

$$g(x, y) = a\,x + b\,y$$

con a, b constantes, y la restricción $ax + by = c$. Entonces las primeras derivadas, $g'_x = a$ y $g'_y = b$, son constantes, y las segundas se anulan: $g''_{xx} = g''_{xy} = g''_{yy} = 0$. Por lo tanto, los términos con λ^* desaparecen y queda

$$\bar{H} = \begin{pmatrix} 0 & a & b \\ a & f''_{xx} & f''_{xy} \\ b & f''_{yx} & f''_{yy} \end{pmatrix}_{(x^*, y^*)}$$

Condiciones suficientes para máximo o mínimo

Las condiciones suficientes para máximos y mínimos se leen en el determinante del hessiano orlado en el punto crítico:

$$|\bar{H}| > 0 \quad \Longrightarrow \quad (x^*, y^*) \text{ es un máximo local sujeto a } g = c$$

$$|\bar{H}| < 0 \quad \Longrightarrow \quad (x^*, y^*) \text{ es un mínimo local sujeto a } g = c$$

Si $|\bar{H}| = 0$, el criterio no nos permite concluir nada.

Qué mide $|\bar{H}|$. Parados en el punto crítico, hay una sola dirección en la que nos podemos mover sin salir de la restricción: la de la recta tangente a la curva $g = c$, que es perpendicular a ∇g. Esa dirección es

$$\vec{t} = (-g'_y,\, g'_x)^T$$

Para saber si el punto es un máximo o un mínimo, alcanza con mirar la forma cuadrática de $H_{\mathcal{L}}$, la hessiana del lagrangiano respecto de x e y (el bloque de abajo a la derecha de $\bar{H}$), solo en esa dirección: el número $M = \vec{t}^{\,T} H_{\mathcal{L}}\, \vec{t}$. Si $M < 0$, f se curva hacia abajo cuando nos movemos sobre la restricción, como en un máximo de una variable; si $M > 0$, se curva hacia arriba, como en un mínimo. Al desarrollar el determinante de $\bar{H}$ aparece exactamente ese número, con el signo cambiado:

$$|\bar{H}| = -\big((g'_y)^2\, \mathcal{L}''_{xx} - 2 g'_x g'_y\, \mathcal{L}''_{xy} + (g'_x)^2\, \mathcal{L}''_{yy}\big) = -\,\vec{t}^{\,T} H_{\mathcal{L}}\, \vec{t} = -M$$

Por eso los signos del criterio están al revés que en una variable: $|\bar{H}| > 0$ quiere decir $M < 0$ (máximo), y $|\bar{H}| < 0$, $M > 0$ (mínimo). El hessiano orlado da el signo de M sin tener que buscar $\vec{t}$. Se usa la hessiana de $\mathcal{L}$, y no la de f, porque la restricción puede ser curva: el término $-\lambda^* g''$ tiene en cuenta esa curvatura. Con una restricción lineal, $g'' = 0$ y $H_{\mathcal{L}}$ es la hessiana de f. Con más variables y restricciones, la forma cuadrática se mira en todas las direcciones en las que nos podemos mover sobre la restricción, y los menores del caso general son el atajo para clasificarla.

Por ejemplo, con $f(x, y) = x^2 + y^2$ y la restricción $x + y = 1$, $\nabla g = (1, 1)^T$ y $\vec{t} = (-1, 1)^T$. Como la restricción es lineal, $H_{\mathcal{L}}$ es la hessiana de f:

$$M = \begin{pmatrix} -1 & 1 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} -1 \\ 1 \end{pmatrix} = 4 > 0$$

Sobre la recta, f se curva hacia arriba: es la parábola $x^2 + (1 - x)^2$ de la primera figura. Es un mínimo, y $|\bar{H}| = -4$.

Condiciones suficientes: caso general

Con n variables y k restricciones $g_i(\vec{x}) = c_i$, el lagrangiano es

$$\mathcal{L}(\vec{x}, \vec{\lambda}) = f(\vec{x}) + \sum_{i=1}^{k} \lambda_i \left(c_i - g_i(\vec{x})\right)$$

Denotemos

$$\nabla g(\vec{x}) = \begin{pmatrix} \nabla g_1(\vec{x}) & \cdots & \nabla g_k(\vec{x}) \end{pmatrix} \in \mathbb{R}^{n \times k}$$

la matriz que tiene por columnas los gradientes de las restricciones. Entonces el *hessiano orlado* es la matriz de $(k+n) \times (k+n)$

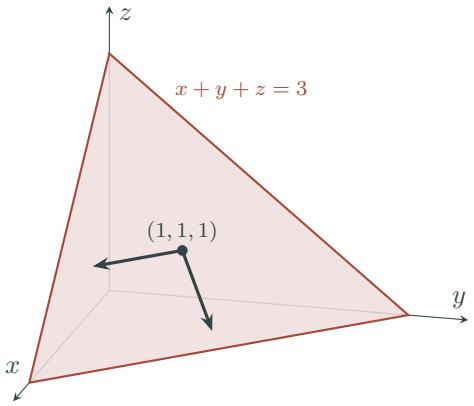
$$\bar{H} = \begin{pmatrix} 0_{k\times k} & \nabla g(\vec{x}^*)^T \\ \nabla g(\vec{x}^*) & \nabla^2_{\vec{x}\vec{x}} \mathcal{L}(\vec{x}^*, \vec{\lambda}^*) \end{pmatrix}$$

donde $\nabla^2_{\vec{x}\vec{x}}\mathcal{L}$ es la hessiana de $\mathcal{L}$ respecto de $x_1, \ldots, x_n$ (las derivadas segundas de f menos las de cada g_i multiplicadas por λ_i^*). Como en dos variables, es la matriz de las derivadas segundas de $\mathcal{L}$ con los multiplicadores como primeras variables.[19]

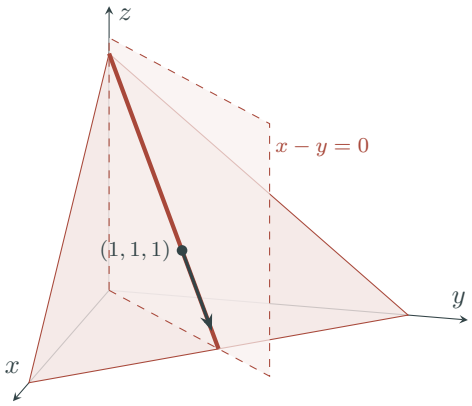
Para $j = 1, \ldots, n$, llamamos $\bar{H}_j$ a la submatriz formada por el borde (las primeras k filas y columnas) y las primeras j variables, y $|\bar{H}_j|$ a su determinante; $\bar{H}_n$ es toda la matriz. Este hessiano orlado tiene $n+k$ menores principales líderes, pero alcanza con analizar los últimos $n-k$: $|\bar{H}_{k+1}|, \ldots, |\bar{H}_n|$.

Hay que mirar $n-k$ menores porque sobre C quedan $n-k$ direcciones para moverse: cada restricción saca una. Por ejemplo, con la restricción $x+y+z=3$, C es un plano, con dos direcciones en $(1,1,1)$, y se miran dos menores, $|\bar{H}_2|$ y $|\bar{H}_3|$. Si se agrega la restricción $x-y=0$, C es la recta donde se cortan los dos planos, con una sola dirección, y se mira un solo menor, $|\bar{H}_3|$. Con $f = x^2+y^2+z^2$ (el ejemplo de tres variables de más abajo), $(1,1,1)$ es el mínimo en los dos casos; con las dos restricciones, $|\bar{H}_3| = 12 > 0$, que tiene el signo de $(-1)^2$.

Una restricción: un plano



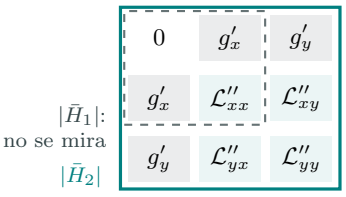
Dos restricciones: una recta



Cada $\bar{H}_j$ es el borde con las primeras j variables. La figura muestra cuáles se miran en cuatro casos (con dos restricciones, llamadas g y h; en el de cuatro variables, $x_1, \ldots, x_4$, con $g'_i = g'_{x_i}$, $h'_i = h'_{x_i}$ y $\mathcal{L}''_{ij} = \mathcal{L}''_{x_i x_j}$). Siempre se empieza en $|\bar{H}_{k+1}|$ y se termina en el de toda la matriz. Los menores más chicos no se miran porque dependen solo de las restricciones: con una restricción, $|\bar{H}_1| = -(g'_x)^2$, y con dos, $|\bar{H}_2| = (g'_x h'_y - g'_y h'_x)^2$.

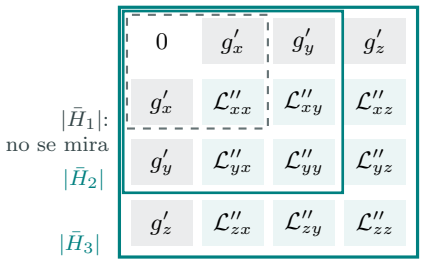
[19] Salvo el signo del borde, que, como en dos variables, no cambia los menores.

Dos variables, una restricción ($n = 2$, $k = 1$)



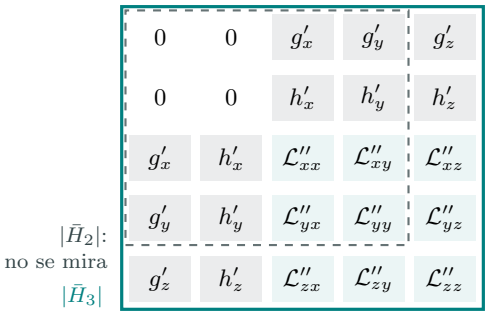
Se mira: $|\bar{H}_2|$

Tres variables, una restricción ($n = 3$, $k = 1$)



Se miran: $|\bar{H}_2|$ y $|\bar{H}_3|$

Tres variables, dos restricciones ($n = 3$, $k = 2$)



Se mira: $|\bar{H}_3|$

Cuatro variables, dos restricciones ($n = 4$, $k = 2$)



Se miran: $|\bar{H}_3|$ y $|\bar{H}_4|$

Mínimo local. Todos tienen el signo de $(-1)^k$:

$$(-1)^k \, |\bar{H}_j| > 0 \qquad j = k+1, \ldots, n$$

Máximo local. Alternan de signo, y el último, $|\bar{H}_n|$, tiene el signo de $(-1)^n$:

$$(-1)^j \, |\bar{H}_j| > 0 \qquad j = k+1, \ldots, n$$

Si ninguno es 0 y no siguen ninguno de los dos patrones, $\vec{x}^*$ no es un máximo ni un mínimo local. Si alguno es 0, el criterio no nos permite concluir nada.

Con el borde al final (los multiplicadores como últimas variables), cada $|\bar{H}_j|$ se arma igual, con el borde y las primeras j variables, y da el mismo valor. Pero esas submatrices ya no son las de arriba a la izquierda, así que no son los menores principales líderes: por eso conviene poner el borde primero.

Veamos los casos más comunes.

Dos variables y una restricción: $n = 2$, $k = 1$

Solo tenemos que analizar $2 - 1 = 1$ menor, $|\bar{H}_2| = |\bar{H}|$, el de toda la matriz.
Mínimo local. $|\bar{H}|$ tiene el signo de $(-1)^k = (-1)^1$: $|\bar{H}| < 0$.
Máximo local. $|\bar{H}|$ tiene el signo de $(-1)^n = (-1)^2$: $|\bar{H}| > 0$.

Son las condiciones del caso concreto.

Tres variables y una restricción: $n = 3$, $k = 1$

El hessiano orlado es

$$\bar{H} = \begin{pmatrix} 0 & g'_x & g'_y & g'_z \\ g'_x & \mathcal{L}''_{xx} & \mathcal{L}''_{xy} & \mathcal{L}''_{xz} \\ g'_y & \mathcal{L}''_{yx} & \mathcal{L}''_{yy} & \mathcal{L}''_{yz} \\ g'_z & \mathcal{L}''_{zx} & \mathcal{L}''_{zy} & \mathcal{L}''_{zz} \end{pmatrix}_{(x^*,y^*,z^*,\lambda^*)}$$

con $\mathcal{L}''_{xx} = f''_{xx} - \lambda^* g''_{xx}$, $\mathcal{L}''_{xy} = f''_{xy} - \lambda^* g''_{xy}$, y lo mismo con las demás. Solo tenemos que analizar $3 - 1 = 2$ menores: $|\bar{H}_2|$, el de la submatriz de 3×3 de arriba a la izquierda,

$$|\bar{H}_2| = \begin{vmatrix} 0 & g'_x & g'_y \\ g'_x & \mathcal{L}''_{xx} & \mathcal{L}''_{xy} \\ g'_y & \mathcal{L}''_{yx} & \mathcal{L}''_{yy} \end{vmatrix}$$

y $|\bar{H}_3| = |\bar{H}|$, el de toda la matriz.
Mínimo local. Los dos tienen el signo de $(-1)^k = (-1)^1$: $|\bar{H}_2| < 0$ y $|\bar{H}_3| < 0$.
Máximo local. Alternan de signo, terminando con el signo de $(-1)^n = (-1)^3$: $|\bar{H}_2| > 0$ y $|\bar{H}_3| < 0$.

Tres variables y dos restricciones: $n = 3$, $k = 2$

Con dos restricciones, $g(x, y, z) = c_1$ y $h(x, y, z) = c_2$, el lagrangiano es $\mathcal{L} = f + \lambda\,(c_1 - g) + \mu\,(c_2 - h)$, y el hessiano orlado en $(x^*, y^*, z^*, \lambda^*, \mu^*)$ es

$$\bar{H} = \begin{pmatrix} 0 & 0 & g'_x & g'_y & g'_z \\ 0 & 0 & h'_x & h'_y & h'_z \\ g'_x & h'_x & \mathcal{L}''_{xx} & \mathcal{L}''_{xy} & \mathcal{L}''_{xz} \\ g'_y & h'_y & \mathcal{L}''_{yx} & \mathcal{L}''_{yy} & \mathcal{L}''_{yz} \\ g'_z & h'_z & \mathcal{L}''_{zx} & \mathcal{L}''_{zy} & \mathcal{L}''_{zz} \end{pmatrix}$$

con $\mathcal{L}''_{xx} = f''_{xx} - \lambda^* g''_{xx} - \mu^* h''_{xx}$, y lo mismo con las demás. Solo tenemos que analizar $3 - 2 = 1$ menor, $|\bar{H}_3| = |\bar{H}|$, el de toda la matriz.
Mínimo local. $|\bar{H}|$ tiene el signo de $(-1)^k = (-1)^2$: $|\bar{H}| > 0$.
Máximo local. $|\bar{H}|$ tiene el signo de $(-1)^n = (-1)^3$: $|\bar{H}| < 0$.

Ejemplos

Minimización con restricción lineal. En el primer ejemplo, la restricción $x+y = 1$ es lineal: $g'_x = g'_y = 1$, y el bloque de abajo a la derecha tiene las derivadas segundas de $f = x^2 + y^2$, $f''_{xx} = f''_{yy} = 2$ y $f''_{xy} = 0$:

$$|\bar{H}| = \begin{vmatrix} 0 & 1 & 1 \\ 1 & 2 & 0 \\ 1 & 0 & 2 \end{vmatrix} = -4 < 0$$

Conclusión. $\left(\frac{1}{2}, \frac{1}{2}\right) = (0.5, 0.5)$ es un mínimo local, con $f = \frac{1}{2} = 0.5$.

Maximización con restricción no lineal. En el segundo, $\mathcal{L} = xy + \lambda\,(1 - x^2 - y^2)$, así que $\mathcal{L}''_{xx} = \mathcal{L}''_{yy} = -2\lambda$ y $\mathcal{L}''_{xy} = 1$, y el borde tiene $g'_x = 2x$ y $g'_y = 2y$:

$$|\bar{H}| = \begin{vmatrix} 0 & 2x & 2y \\ 2x & -2\lambda & 1 \\ 2y & 1 & -2\lambda \end{vmatrix} = 8\lambda\,(x^2 + y^2) + 8xy = 8\lambda + 8xy$$

donde la última igualdad usa la restricción. Como el bloque de abajo a la derecha depende de λ, en cada candidato va su λ^*. Con $\lambda^* = \frac{1}{2}$ e $y = x$, $xy = \frac{1}{2}$ y $|\bar{H}| = 4 + 4 = 8 > 0$. Con $\lambda^* = -\frac{1}{2}$ e $y = -x$, $xy = -\frac{1}{2}$ y $|\bar{H}| = -4 - 4 = -8 < 0$.
Conclusión. $\left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ y $\left(-\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right)$ son máximos locales, con $f = \frac{1}{2} = 0.5$. Los otros dos, $\left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right)$ y $\left(-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$, son mínimos locales, con $f = -\frac{1}{2} = -0.5$.

Máximo de xy sobre una recta. Busquemos el máximo de $f(x, y) = xy$ sujeto a $x + 2y = 8$, con $x > 0$ e $y > 0$. Con $\mathcal{L} = xy + \lambda(8 - x - 2y)$, las condiciones de primer orden son

$$\mathcal{L}'_x = y - \lambda = 0 \qquad \mathcal{L}'_y = x - 2\lambda = 0 \qquad \mathcal{L}'_\lambda = 8 - x - 2y = 0$$

De las dos primeras, $y = \lambda$ y $x = 2\lambda$; en la restricción, $4\lambda = 8$, así que $\lambda^* = 2$, $x^* = 4$ e $y^* = 2$. Como la restricción es lineal, el borde tiene $g'_x = 1$ y $g'_y = 2$, y el bloque de abajo a la derecha, las derivadas segundas de f: $f''_{xx} = f''_{yy} = 0$ y $f''_{xy} = 1$.

$$|\bar{H}| = \begin{vmatrix} 0 & 1 & 2 \\ 1 & 0 & 1 \\ 2 & 1 & 0 \end{vmatrix} = 4 > 0$$

Conclusión. $(4, 2)$ es un máximo local, con $f = 8$.

Un ejemplo con tres variables. Busquemos el mínimo de $f(x, y, z) = x^2 + y^2 + z^2$ sujeto a $x + y + z = 3$, en $\mathbb{R}^3$. Con $\mathcal{L} = x^2 + y^2 + z^2 + \lambda(3 - x - y - z)$, las condiciones de primer orden dan $2x = 2y = 2z = \lambda$; en la restricción, $\frac{3}{2}\lambda = 3$, así que $\lambda^* = 2$ y el candidato es $(1, 1, 1)$. La restricción es lineal, así que en el bloque de abajo a la derecha van las derivadas segundas de f:

$$\bar{H} = \begin{pmatrix} 0 & 1 & 1 & 1 \\ 1 & 2 & 0 & 0 \\ 1 & 0 & 2 & 0 \\ 1 & 0 & 0 & 2 \end{pmatrix}$$

Hay que analizar $3 - 1 = 2$ menores:

$$|\bar{H}_2| = \begin{vmatrix} 0 & 1 & 1 \\ 1 & 2 & 0 \\ 1 & 0 & 2 \end{vmatrix} = -4 < 0 \qquad |\bar{H}_3| = |\bar{H}| = -12 < 0$$

(el de 4×4, desarrollando por la primera fila). Los dos tienen el signo de $(-1)^1$.
Conclusión. $(1, 1, 1)$ es un mínimo local, con $f = 3$.

Condiciones para máximos y mínimos globales y únicos

Las condiciones de segundo orden dicen si un candidato es un máximo o un mínimo local. Para saber si además es global y único, alcanza con una condición sobre f y sobre el conjunto factible

$$C = \left\{\vec{x} \in \mathbb{R}^n : \ g_i(\vec{x}) = c_i, \ i = 1, \ldots, k\right\}$$

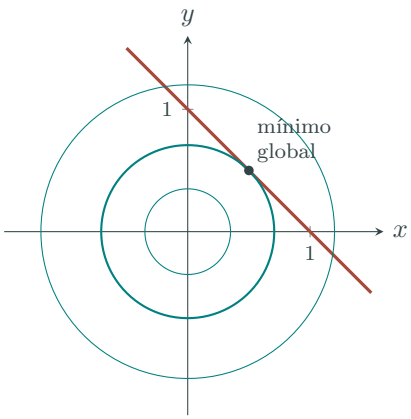
(si el problema pide además, por ejemplo, $x > 0$, esa condición también forma parte de C). Es una condición suficiente, no necesaria (un extremo puede ser global sin que se cumpla), y no asegura que haya un extremo: dice que, si hay uno local, es global y único.
Teorema (cuasiconcavidad y óptimos globales). Sea C convexo.

- Si f es estrictamente cuasicóncava, todo máximo local de f en C es su único máximo global.
- Si f es estrictamente cuasiconvexa, todo mínimo local de f en C es su único mínimo global.

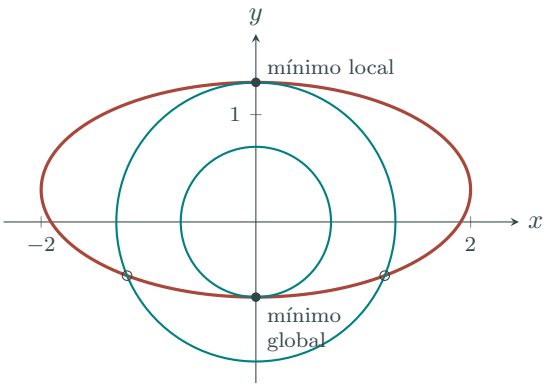
Con restricciones de igualdad, C es convexo cuando las restricciones son lineales (una recta, un plano o la intersección de varios). Con una restricción no lineal, en general no lo es: la circunferencia $x^2 + y^2 = 1$ no es convexa, porque el segmento que une dos de sus puntos pasa por adentro del círculo.

En los dos gráficos se minimiza $f(x, y) = x^2 + y^2$, que es estrictamente convexa; sus curvas de nivel son circunferencias centradas en el origen. A la izquierda, C es la recta $x + y = 1$, que es convexa: la curva de nivel toca a C en un solo punto, el mínimo global. A la derecha, C es la elipse $\frac{x^2}{4} + (y - 0.3)^2 = 1$, que no es convexa. Hay dos puntos de tangencia: $(0, -0.7)$, con $f = 0.49$, y $(0, 1.3)$, con $f = 1.69$, y el hessiano orlado da mínimo local en los dos ($|\bar{H}| = -6.6$ y $|\bar{H}| = -5.4$). Pero solo el primero es global: la curva $f = 1.69$ toca a la elipse arriba y la corta en $(\pm 1.2, -0.5)$, así que hay puntos de C con valores más chicos.

C convexo: la recta $x + y = 1$



C no convexo: una elipse



Ejemplos

Sumas de cuadrados. En el ejemplo de minimización con restricción lineal y en el de tres variables, f es una suma de cuadrados. Su hessiana es diagonal, con 2 en la diagonal, así que es definida positiva y f es estrictamente convexa; toda función estrictamente convexa es, además, estrictamente cuasiconvexa. Además, C es la recta $x + y = 1$ en el primero y el plano $x + y + z = 3$ en el segundo, que son convexos.
Conclusión. $\left(\frac{1}{2}, \frac{1}{2}\right) = (0.5, 0.5)$ es el único mínimo global de $x^2 + y^2$ sobre la recta, con $f = \frac{1}{2} = 0.5$, y $(1, 1, 1)$ es el único mínimo global de $x^2 + y^2 + z^2$ sobre el plano, con $f = 3$.

Máximo de xy sobre una recta. El conjunto factible, $C = \{(x, y) : \ x + 2y = 8, \ x > 0, \ y > 0\}$, es un segmento sin sus extremos, que es convexo. Para ver que xy es estrictamente cuasicóncava en $x > 0$, $y > 0$, usamos el hessiano orlado de f, que lleva en el borde el gradiente de f (no el de la restricción, como $\bar{H}$):

$$B = \begin{pmatrix} 0 & f'_x & f'_y \\ f'_x & f''_{xx} & f''_{xy} \\ f'_y & f''_{yx} & f''_{yy} \end{pmatrix} = \begin{pmatrix} 0 & y & x \\ y & 0 & 1 \\ x & 1 & 0 \end{pmatrix}$$

Sus menores son

$$|B_1| = \begin{vmatrix} 0 & y \\ y & 0 \end{vmatrix} = -y^2 < 0 \qquad |B_2| = |B| = 2xy > 0$$

en todo ese conjunto. Esos signos (alternados, empezando por el negativo) aseguran que xy es estrictamente cuasicóncava.
Conclusión. $(4, 2)$ es el único máximo global, con $f = 8$.

Un conjunto factible que no es convexo. En el ejemplo de maximización con restricción no lineal, C es la circunferencia $x^2 + y^2 = 1$, que no es convexa, y el teorema no se puede usar. Igual, los máximos son globales: como $(x - y)^2 \geq 0$, $xy \leq \frac{1}{2}(x^2 + y^2) = \frac{1}{2}$ en toda la circunferencia, y los máximos alcanzan ese valor. Del mismo modo, $(x + y)^2 \geq 0$ da $xy \geq -\frac{1}{2}$.

Conclusión. Los dos máximos, con $f = 0.5$, y los dos mínimos, con $f = -0.5$, son globales, pero no únicos.

Es un ejemplo de por qué la condición es suficiente, pero no necesaria: hay máximos globales aunque C no sea convexo.

Método 22.1 | Optimizar con restricciones de igualdad

Cuándo usarlo. Para hallar y clasificar los extremos de $f(\vec{x})$ sujeta a k restricciones de igualdad, con $k < n$.

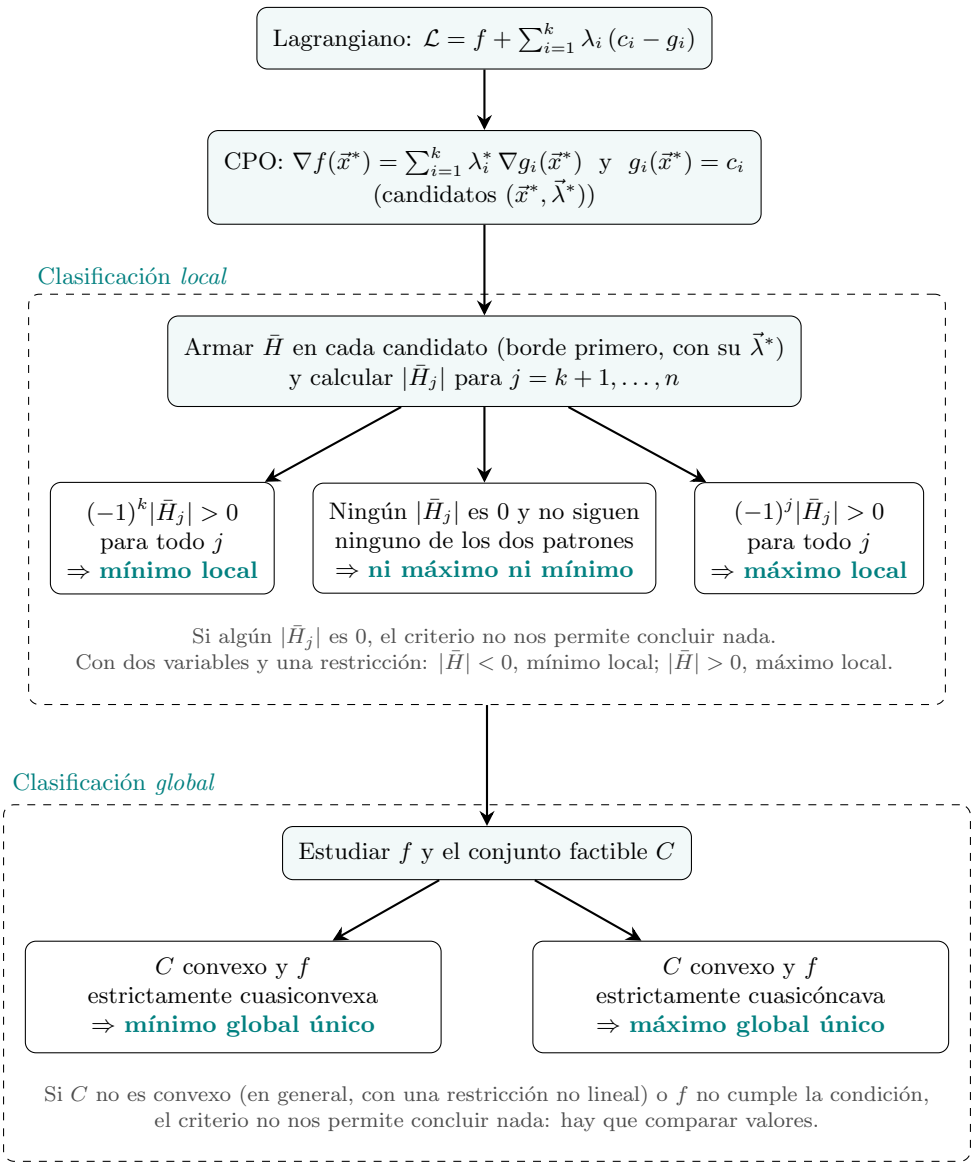
Pasos.

1. Escribir cada restricción como $g_i(\vec{x}) = c_i$ y armar $\mathcal{L} = f + \sum_{i=1}^{k} \lambda_i (c_i - g_i)$.
2. Resolver las condiciones de primer orden: $\nabla f(\vec{x}) = \sum_{i=1}^{k} \lambda_i \nabla g_i(\vec{x})$ junto con las k restricciones. Cada solución $(\vec{x}^*, \vec{\lambda}^*)$ es un candidato.
3. En cada candidato, armar $\bar{H}$: primero el borde, con las derivadas de las g_i; abajo a la derecha, las derivadas segundas de $\mathcal{L}$ respecto de las variables (las de f menos λ_i^* por las de cada g_i), con el $\vec{\lambda}^*$ de ese candidato.
4. Calcular $|\bar{H}_j|$ para $j = k+1, \ldots, n$. Si $(-1)^k |\bar{H}_j| > 0$ para todos, es un mínimo local; si $(-1)^j |\bar{H}_j| > 0$ para todos, un máximo local; si ninguno es 0 y no siguen ninguno de los dos patrones, no es ni máximo ni mínimo. Con dos variables y una restricción: $|\bar{H}| > 0$, máximo; $|\bar{H}| < 0$, mínimo.
5. Para que sea global y único: C convexo, y f estrictamente cuasicóncava (máximo) o estrictamente cuasiconvexa (mínimo). Si no se cumple, comparar valores.

Chequeo. Cada candidato cumple todas las restricciones, y $\bar{H}$ tiene que ser simétrica.

Cuidado. El $\vec{\lambda}^*$ que va en $\bar{H}$ es el que dan las condiciones de primer orden de $\mathcal{L} = f + \sum_{i=1}^{k} \lambda_i (c_i - g_i)$: si se toma el de un lagrangiano armado al revés, el signo queda cambiado. Si algún $|\bar{H}_j|$ es 0, el criterio no nos permite concluir nada. Con una restricción no lineal, en general C no es convexo.

Esquema de análisis (con restricciones de igualdad)



23 Aplicaciones económicas con optimización con restricciones de igualdad

Interpretación del multiplicador de Lagrange

La interpretación del multiplicador de lagrange puede verse como el efecto que tiene relajar la restricción sobre la función objetivo. El significado de "relajar" la restricción dependerá de si estamos maximizando o minimizando. Para entender claramente vamos a ver un ejemplo de maximización de utilidad.

Consideremos un consumidor que elige $x = (x_1, x_2) \in \mathbb{R}^2_+$ para maximizar su utilidad sujeta a una restricción presupuestaria lineal:

$$\max_{x \geq 0} \; u(x_1, x_2) \qquad \text{s.a.} \qquad p_1 x_1 + p_2 x_2 = M,$$

donde $p = (p_1, p_2) \gg 0$ son los precios y $M > 0$ es el ingreso. Denotemos por

$$v(M, p) \; = u(x_1^*, x_2^*)$$

la *utilidad indirecta*. Usaremos la convención de Lagrangiano

$$\mathcal{L}(x, \lambda; M, p) \; = \; u(x) \; + \; \lambda \left(M - p_1 x_1 - p_2 x_2\right),$$

Teorema de la envolvente (versión paramétrica)

Las condiciones de primer orden requieren que:

$$\begin{aligned}
\frac{\partial \mathcal{L}}{\partial x_1}(x_1, x_2, \lambda) = u_{x_1}(x_1, x_2) - \lambda\, p_1 \; &= \; 0, \\
\frac{\partial \mathcal{L}}{\partial x_2}(x_1, x_2, \lambda) = u_{x_2}(x_1, x_2) - \lambda\, p_2 \; &= \; 0, \\
\frac{\partial \mathcal{L}}{\partial \lambda}(x_1, x_2, \lambda) = M - p_1 x_1 - p_2 x_2 \; &= \; 0.
\end{aligned}$$

El teorema de la envolvente indica que si buscamos derivar la función objetivo en el óptimo respecto a un parámetro, podemos primero obtener la función de utilidad indirecta y después derivar o primero derivar y después reemplazar por los valores de x_1, x_2 en el óptimo. Es decir, dado que tanto x_1, como x_2 y λ en el óptimo dependerían de M.

$$\mathcal{L}(x_1, x_2, \lambda; M, p) = u(x_1, x_2) + \lambda \left(M - p_1 x_1 - p_2 x_2\right),$$

y evaluando a lo largo de la solución óptima $(x_1^*(M,p), x_2^*(M,p), \lambda^*(M,p))$, se tiene

$$\frac{d}{dM}\, \mathcal{L}\big(x_1^*, x_2^*, \lambda^*; M, p\big) = \underbrace{\mathcal{L}'_{x_1}}_{0} \frac{dx_1^*}{dM} \; + \; \underbrace{\mathcal{L}'_{x_2}}_{0} \frac{dx_2^*}{dM} \; + \; \underbrace{\mathcal{L}'_{\lambda}}_{0} \frac{d\lambda^*}{dM} \; + \; \underbrace{\mathcal{L}_{M}}_{=\lambda}.$$

Por las condiciones de primer orden en el óptimo,

$$\mathcal{L}'_{x_1}(x_1^*, x_2^*, \lambda^*; M, p) = 0, \qquad \mathcal{L}'_{x_2}(x_1^*, x_2^*, \lambda^*; M, p) = 0, \qquad \mathcal{L}'_{\lambda}(x_1^*, x_2^*, \lambda^*; M, p) = 0,$$

Entonces

$$\frac{d}{dM}\, \mathcal{L}\big(x_1^*, x_2^*, \lambda^*; M, p\big) = \mathcal{L}_M(x_1^*, x_2^*, \lambda^*; M, p) = \lambda^*(M, p)\,.$$

En particular, como en el óptimo la restricción se cumple con igualdad $M - p_1 x_1^* - p_2 x_2^* = 0$, el Lagrangiano evaluado en el óptimo coincide con la utilidad:

$$v(M, p) \; = \; u(x_1^*, x_2^*) \; = \; \mathcal{L}(x_1^*, x_2^*, \lambda^*; M, p).$$

La conclusión entonces es que

$$\frac{\partial v(M,p)}{\partial M} = \frac{\partial \mathcal{L}}{\partial M}\Big|_{(x_1^*,x_2^*,\lambda^*;M,p)} = \lambda^*(M,p)$$

Es decir, λ^* mide el cambio marginal de la utilidad óptima cuando se *relaja* la restricción presupuestaria en una unidad, o sea, cuando se le da ingresos adicionales al individuo. Por eso λ^* se interpreta como *utilidad marginal del ingreso*. Esto puede ser útil ya que nos informa cómo cambia la utilidad si le brindamos al individuo una unidad monetaria adicional.

Ejemplo

Datos: $M = 100$, $p_1 = 10$, $p_2 = 20$, $u(x_1, x_2) = x_1^2 x_2^2$.

$$\max_{x_1,x_2>0} \; x_1^2x_2^2 \quad \text{s.a.} \quad 10x_1 + 20x_2 = 100, \qquad \mathcal{L}(x_1,x_2,\lambda) = x_1^2x_2^2 + \lambda\,(100 - 10x_1 - 20x_2).$$

CPO

$$\mathcal{L}_{x_1} = 2x_1x_2^2 - 10\lambda = 0, \qquad \mathcal{L}_{x_2} = 2x_2x_1^2 - 20\lambda = 0, \qquad \mathcal{L}_{\lambda} = 100 - 10x_1 - 20x_2 = 0.$$

De las dos primeras:

$$\frac{2x_1x_2^2}{10} = \lambda = \frac{2x_2x_1^2}{20} \implies 2x_2 = x_1.$$

Con la restricción:

$$10(2x_2) + 20x_2 = 100 \implies 40x_2 = 100 \implies x_2^* = 2.5, \quad x_1^* = 5.$$

$$v(100,10,20) = u(x_1^*, x_2^*) = 5^2 \cdot 2.5^2 = 25 \cdot 6.25 = 156.25.$$

Multiplicador lagrangiano

$$\lambda^* = \frac{2x_1^*(x_2^*)^2}{10} = \frac{2 \cdot 5 \cdot (2.5)^2}{10} = \frac{10 \cdot 6.25}{10} = 6.25.$$

La interpretación es la siguiente: si aumentamos el ingreso en una unidad (manteniendo precios), la utilidad óptima aumenta en aproximadamente 6.25 unidades. O sea la nueva utilidad sería de 162.5

Ejemplo con minimización

El multiplicador de lagrange también puede interpretarse en el contexto de una minimización.

Datos: $w_1 = 10$, $w_2 = 40$, meta de producción $= 100$, tecnología $F(z_1, z_2) = \sqrt{z_1 z_2}$.

$$\min_{z_1,z_2>0} \; C = 10\,z_1 + 40\,z_2 \quad \text{s.a.} \quad \sqrt{z_1z_2} = 100, \qquad \mathcal{L}(z_1,z_2,\mu) = 10z_1 + 40z_2 + \mu\,(100 - \sqrt{z_1z_2}).$$

CPO

$$\mathcal{L}_{z_1} = 10 - \mu \cdot \tfrac{1}{2}\, z_1^{-1/2} z_2^{1/2} = 0, \quad \mathcal{L}_{z_2} = 40 - \mu \cdot \tfrac{1}{2}\, z_2^{-1/2} z_1^{1/2} = 0, \quad \sqrt{z_1z_2} = 100.$$

De las dos primeras:

$$\frac{10}{40} = \frac{z_2}{z_1} \implies z_2 = \frac{1}{4}\, z_1.$$

Con la restricción: $z_1 z_2 = 100^2 \Rightarrow z_1\left(\frac{1}{4} z_1\right) = 10{,}000 \Rightarrow z_1^2 = 40{,}000 \Rightarrow z_1^* = 200,\ z_2^* = 50.$

Costo mínimo e interpretación de μ^*

$$C_{\min} = 10 \cdot 200 + 40 \cdot 50 = 2000 + 2000 = 4000.$$

$$\mu^* \;=\; 2\sqrt{w_1 w_2} \;=\; 2\sqrt{10 \cdot 40} = 40.$$

$\mu^* = 40$ nos indica que al relajar la restricción (es decir si en vez de exigir una producción de 100, exigimos solo 99 unidades), el costo mínimo se reduce aproximadamente en 40. Por lo tanto el costo nuevo sería de 3960.

Otro ejemplo económico: minimización de costes sujeto a restricción.

Consideremos una empresa cuya tecnología de producción viene dada por la función Cobb–Douglas

$$y = F(L, K) = L^{\alpha} K^{1-\alpha} \qquad \alpha \in (0, 1)$$

donde L y K son trabajo y capital, y $y > 0$ es el nivel de output

Problema de minimización de costes

Dados los precios de los factores w (salario) y r (renta del capital) y el nivel y, la empresa resuelve

$$\min_{L,K} \;\; C = w\,L \;+\; r\,K \quad \text{sujeto a} \quad L^{\alpha} K^{1-\alpha} = y$$

Demanda condicionada y coste mínimo

Escribimos el Lagrangiano

$$\mathcal{L} = wL + rK + \mu\big(y - L^{\alpha} K^{1-\alpha}\big)$$

Las condiciones de primer orden son

$$\frac{\partial \mathcal{L}}{\partial L} = w - \mu\,\alpha\,L^{\alpha-1} K^{1-\alpha} = 0 \qquad \frac{\partial \mathcal{L}}{\partial K} = r - \mu\,(1-\alpha)\,L^{\alpha} K^{-\alpha} = 0$$

junto con la restricción $L^{\alpha} K^{1-\alpha} = y$. De las dos primeras:

$$\frac{w}{\alpha} L^{1-\alpha} K^{\alpha-1} \;=\; \frac{r}{1-\alpha} L^{-\alpha} K^{\alpha} \quad \Longrightarrow \quad \frac{L^*}{K^*} = \frac{\alpha}{1-\alpha}\,\frac{r}{w}$$

Sustituyendo en $L^{\alpha} K^{1-\alpha} = y$ y resolviendo se obtienen las demandas condicionadas

$$L^*(w, r, y) = y \left(\frac{\alpha}{w}\right)^{\alpha} \left(\frac{1-\alpha}{r}\right)^{1-\alpha} \alpha \quad K^*(w, r, y) = y \left(\frac{\alpha}{w}\right)^{\alpha} \left(\frac{1-\alpha}{r}\right)^{1-\alpha} (1-\alpha)$$

El coste mínimo resultante es

$$C(w, r, y) = w\,L^*(w, r, y) + r\,K^*(w, r, y) = y \left(\tfrac{w}{\alpha}\right)^{\alpha} \left(\tfrac{r}{1-\alpha}\right)^{1-\alpha}$$

Lema de Shephard

La función de coste $C(w, r, y)$ es la envolvente de la familia de funciones $wL + rK$ sujeta a $F(L, K) = y$ Por el teorema de la envolvente, al derivar C con respecto a w (tratando y, r constantes) basta con tomar el efecto directo:

$$\frac{\partial C}{\partial w} = L^*(w, r, y)$$

De hecho, si derivamos la expresión encontrada:

$$\frac{\partial}{\partial w}\left[y\,(w/\alpha)^{\alpha}(r/(1-\alpha))^{1-\alpha}\right] = y\,\alpha\,(w/\alpha)^{\alpha-1}(r/(1-\alpha))^{1-\alpha} = L^*(w, r, y)$$

Análogamente,

$$\frac{\partial C}{\partial r} = K^*(w, r, y)$$

Interpretación

- $C(w, r, y)$ es la curva de coste de largo plazo: "envuelve" todas las rectas $wL + rK$ tangentes a las iso-productivas $L^{\alpha}K^{1-\alpha} = y$
- La envolvente simplifica el cálculo de las *demandas condicionadas*: no necesitamos derivar $L^*(w, r, y)$ ni $K^*(w, r, y)$ respecto a w o r para obtener $\partial C/\partial w$, $\partial C/\partial r$
- **Este resultado se conoce como el Lema de Shephard**. El cual nos dice que una vez que tenemos la función de costo indirecta basta con derivar esta con respecto a los precios de los insumos para encontrar la demanda de insumos condicionada.

24 Optimización con restricciones de desigualdad

Problema con una sola variable independiente

Consideremos el problema

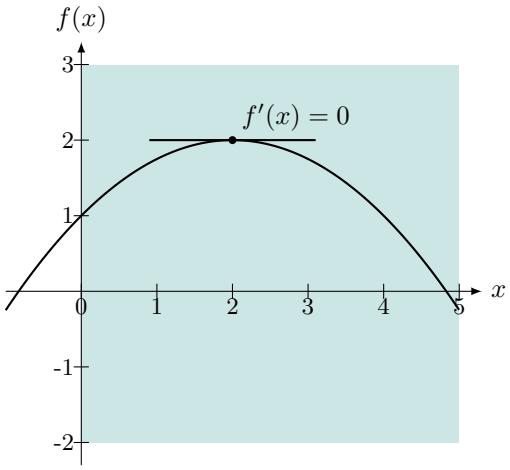
$$\max_{x \geq 0} f(x), \qquad f \in C^1(\mathbb{R}).$$

Un punto x^* es máximo local solo en una de estas dos situaciones:

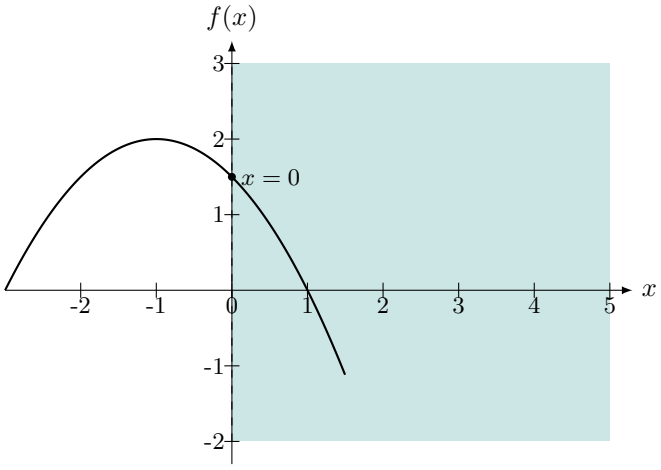
- **Interior:** $x^* > 0$ y $f'(x^*) = 0$. Aquí la restricción no interviene y se cumple la condición clásica de primer orden.
- **Frontera:** $x^* = 0$ y $f'(0) \leq 0$.

Obsérvese que $f'(0) > 0$ no puede corresponder a un máximo, pues implicaría pendiente creciente al inicio de la región factible.

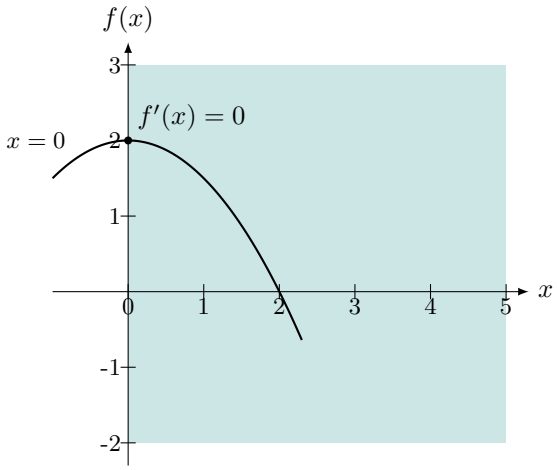
Gráficamente los casos son los siguientes: $f'(x) = 0$ por lo que la restricción no está activa.



Por otro lado $f'(x) < 0$ implica que la restricción está activa: $x = 0$.



Y por último también es posible que sucedan las dos cosas al mismo tiempo: $f'(x) = 0$ y $x = 0$.



Estas condiciones anteriores pueden resumirse:

$$f'(x) \leq 0, \quad x \geq 0, \quad x\, f'(x) = 0.$$

De esas condiciones se deduce que necesariamente

$$x = 0 \quad \text{o} \quad f'(x) = 0,$$

pues la última igualdad obliga a que al menos uno de los factores sea cero.

- $x \geq 0$:
- $f'(x) \leq 0$:
- $x\, f'(x) = 0$: *holgura complementaria.*

Minimización

Análogamente, para

$$\min_{x \geq 0} f(x),$$

las condiciones necesarias son

$$f'(x) \geq 0, \quad x \geq 0, \quad x\, f'(x) = 0,$$

Ejemplo

Consideremos el problema

$$\max_{x \geq 0} f(x), \quad f(x) = -x^2 - x - 1,$$

Caso 1: la restricción está inactiva (óptimo interior).
Si la restricción no actuase, existiría un máximo interior $x^* > 0$ y por lo tanto por la condición de holgura complementaria $xf'(x) = 0$ tenemos que:

$$f'(x^*) = 0.$$

Pero

$$f'(x) = -2x - 1,$$

luego

$$-2x^* - 1 = 0 \quad \Longrightarrow \quad x^* = -\tfrac{1}{2},$$

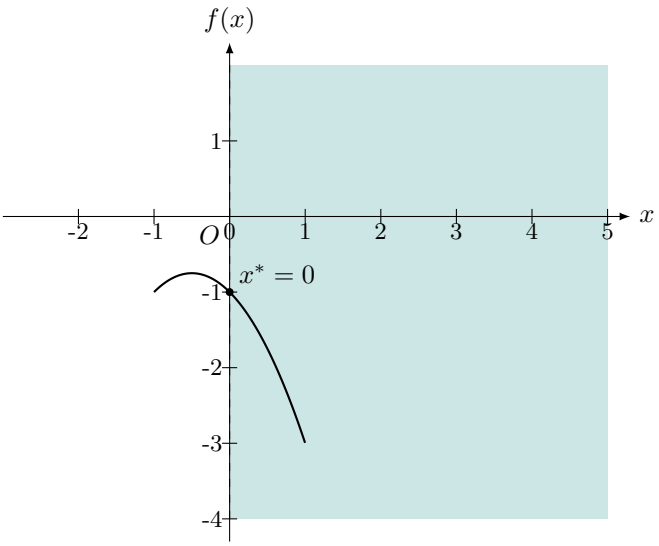
que contradice $x^* > 0$. Por tanto no puede haber óptimo interior en la región factible.

Caso 2: la restricción está activa (óptimo en la frontera).
La única posibilidad restante es que $x^* = 0$. Para verificar que es un máximo local basta comprobar la condición de primer orden en la frontera:

$$f'(0) = -2 \cdot 0 - 1 = -1 \leq 0.$$

Conclusión: En este ejemplo la restricción $x \geq 0$ está activa en el óptimo ($x^* = 0$), y el valor óptimo es $f(0) = -1 < 0$.

Gráficamente:



Problema con n variables independientes y restricciones de no negatividad

Consideremos

$$\max_{x \in \mathbb{R}^n_+} \; f(x_1, \ldots, x_n), \qquad f \in C^1(\mathbb{R}^n),$$

es decir, sujeto a $x_j \geq 0$ para $j = 1, \ldots, n$.

Las condiciones de primer orden adaptadas a estas restricciones son, para cada $j = 1, \ldots, n$:

$$\frac{\partial f}{\partial x_j} \; \leq \; 0, \qquad x_j \; \geq \; 0, \qquad x_j \, \frac{\partial f}{\partial x_j} \; = \; 0,$$

Problema con tres variables y dos restricciones de desigualdad

Planteamos primero el problema en forma de desigualdades:

$$\max_{x_1, x_2, x_3} \; f(x_1, x_2, x_3)$$

sujeto a

$$\begin{cases} g^1(x_1, x_2, x_3) \leq r_1, \\ g^2(x_1, x_2, x_3) \leq r_2, \\ x_1,\ x_2,\ x_3 \geq 0. \end{cases}$$

Al añadir las variables ficticias $s_1, s_2 \geq 0$ podemos convertir cada desigualdad en una igualdad:

$$\begin{cases} g^1(x_1, x_2, x_3) + s_1 = r_1, \\ g^2(x_1, x_2, x_3) + s_2 = r_2, \\ x_1,\ x_2,\ x_3,\ s_1,\ s_2 \geq 0. \end{cases}$$

Lagrangiano y condiciones de primer orden

A partir del problema con variables de holgura

$$\begin{aligned} \max_{x_1, x_2, x_3, s_1, s_2} \quad & f(x_1, x_2, x_3) \\ \text{sujeto a} \quad & g^1(x_1, x_2, x_3) + s_1 = r_1, \\ & g^2(x_1, x_2, x_3) + s_2 = r_2, \\ & x_j \geq 0 \ (j = 1, 2, 3), \quad s_i \geq 0 \ (i = 1, 2), \end{aligned}$$

definimos el *Lagrangiano*

$$\mathcal{L}(x, s, \lambda) \ = \ f(x_1, x_2, x_3) \ + \ \lambda_1 \big[r_1 - g^1(x_1, x_2, x_3) - s_1 \big] \ + \ \lambda_2 \big[r_2 - g^2(x_1, x_2, x_3) - s_2 \big].$$

Aquí $\lambda_1, \lambda_2 \in \mathbb{R}$ son los multiplicadores asociados a las igualdades.

Condiciones de primer orden

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x_1} &= f_1(x) - \lambda_1 g_1^1(x) - \lambda_2 g_1^2(x) \ \leq \ 0, \quad x_1 \ \geq \ 0, \quad x_1 \frac{\partial \mathcal{L}}{\partial x_1} = 0, \\ \frac{\partial \mathcal{L}}{\partial x_2} &= f_2(x) - \lambda_1 g_2^1(x) - \lambda_2 g_2^2(x) \ \leq \ 0, \quad x_2 \ \geq \ 0, \quad x_2 \frac{\partial \mathcal{L}}{\partial x_2} = 0, \\ \frac{\partial \mathcal{L}}{\partial x_3} &= f_3(x) - \lambda_1 g_3^1(x) - \lambda_2 g_3^2(x) \ \leq \ 0, \quad x_3 \ \geq \ 0, \quad x_3 \frac{\partial \mathcal{L}}{\partial x_3} = 0, \\ \frac{\partial \mathcal{L}}{\partial s_1} &= -\lambda_1 \ \leq \ 0, \quad s_1 \ \geq \ 0, \quad s_1 \frac{\partial \mathcal{L}}{\partial s_1} = 0, \\ \frac{\partial \mathcal{L}}{\partial s_2} &= -\lambda_2 \ \leq \ 0, \quad s_2 \ \geq \ 0, \quad s_2 \frac{\partial \mathcal{L}}{\partial s_2} = 0, \\ \frac{\partial \mathcal{L}}{\partial \lambda_1} &= r_1 - g^1(x_1, x_2, x_3) - s_1 = 0, \\ \frac{\partial \mathcal{L}}{\partial \lambda_2} &= r_2 - g^2(x_1, x_2, x_3) - s_2 = 0. \end{aligned}$$

Eliminación de las variables ficticias de las condiciones de primer orden

Tomemos la condición respecto a un multiplicador de lagrange:

$$\frac{\partial \mathcal{L}}{\partial \lambda_i} \ = \ r_i - g^i(x_1, x_2, x_3) - s_i \ = \ 0,$$

se despeja inmediatamente

$$s_i \;=\; r_i - g^i(x_1, x_2, x_3), \qquad i = 1, 2.$$

Ahora sustituimos s_i en las tres condiciones

$$\frac{\partial \mathcal{L}}{\partial s_i} \leq 0, \quad s_i \geq 0, \quad s_i \frac{\partial \mathcal{L}}{\partial s_i} = 0,$$

recordando que $\partial \mathcal{L}/\partial s_i = -\lambda_i$. Obtenemos:

$$\begin{aligned} -\lambda_i \leq 0 \quad &\Longrightarrow \quad \lambda_i \geq 0, \\ r_i - g^i(x_1, x_2, x_3) \geq 0 \quad & \\ \big(r_i - g^i(x_1, x_2, x_3)\big)\big(-\lambda_i\big) = 0 \quad &\Longrightarrow \quad \lambda_i \left(r_i - g^i(x_1, x_2, x_3)\right) = 0. \end{aligned}$$

En consecuencia, las condiciones de Kuhn-Tucker quedan:

$$\begin{cases} \dfrac{\partial \mathcal{L}}{\partial x_j} \;\leq\; 0, & \\ x_j \;\geq\; 0, & (j = 1, 2, 3) \\ x_j \dfrac{\partial \mathcal{L}}{\partial x_j} \;=\; 0 & \end{cases}$$

$$\begin{cases} r_i - g^i(x_1, x_2, x_3) \;\geq\; 0, & \\ \lambda_i \;\geq\; 0, & (i = 1, 2) \\ \lambda_i \left[r_i - g^i(x_1, x_2, x_3)\right] \;=\; 0 & \end{cases}$$

Véase que $r_i - g^i(x_1, x_2, x_3)$ coincide con la derivada del lagrangiano sin incluir las variables ficticias s_i. Entonces podemos expresar las condiciones de la siguiente manera:

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x_j} \leq 0, \quad x_j \geq 0, \quad x_j \frac{\partial \mathcal{L}}{\partial x_j} = 0, \\ \frac{\partial \mathcal{L}}{\partial \lambda_i} \geq 0, \quad \lambda_i \geq 0, \quad \lambda_i \frac{\partial \mathcal{L}}{\partial \lambda_i} = 0, \end{aligned}$$

Resumen de las condiciones

Sea

$$L(x, \lambda) = f(x_1, \ldots, x_n) + \sum_{i=1}^{k} \lambda_i \big[r_i - g^i(x_1, \ldots, x_n)\big]$$

el Lagrangiano asociado a

$$\max_{x \in \mathbb{R}^n_+} f(x) \quad \text{sujeto a} \quad g^i(x) \leq r_i \; (i = 1, \ldots, k)$$

donde

$$\mathbb{R}^n_+ = \{x \in \mathbb{R}^n : x_j \geq 0 \; \forall j = 1, \ldots, n\}$$

Las condiciones de Kuhn–Tucker para un máximo son

$$\begin{cases} \dfrac{\partial L}{\partial x_j} \leq 0, \quad x_j \geq 0, \quad x_j \dfrac{\partial L}{\partial x_j} = 0 \quad j = 1, \ldots, n \\ \dfrac{\partial L}{\partial \lambda_i} \geq 0, \quad \lambda_i \geq 0, \quad \lambda_i \dfrac{\partial L}{\partial \lambda_i} = 0 \quad i = 1, \ldots, k \end{cases}$$

Condiciones Kuhn-Tucker generales para un mínimo

Sea

$$L(x,\lambda) = f(x_1,\dots,x_n) + \sum_{i=1}^{k} \lambda_i \big[r_i - g^i(x_1,\dots,x_n)\big]$$

el Lagrangiano asociado a

$$\min_{x\in\mathbb{R}^n_+} f(x) \quad \text{sujeto a} \quad g^i(x) \geq r_i \ (i = 1,\dots,k)$$

donde

$$\mathbb{R}^n_+ = \{x \in \mathbb{R}^n : x_j \geq 0 \ \forall j = 1,\dots,n\}$$

Las condiciones de Kuhn–Tucker necesarias para un mínimo son

$$\begin{cases} \dfrac{\partial L}{\partial x_j} \geq 0, \quad x_j \geq 0, \quad x_j \dfrac{\partial L}{\partial x_j} = 0 \quad j = 1,\dots,n \\ \dfrac{\partial L}{\partial \lambda_i} \leq 0, \quad \lambda_i \geq 0, \quad \lambda_i \dfrac{\partial L}{\partial \lambda_i} = 0 \quad i = 1,\dots,k \end{cases}$$

Ejemplo maximización

Consideremos

$$\max_{x,y} U(x,y) = xy \quad \text{sujeto a} \quad \begin{cases} x + y \leq 100, \\ x \leq 40, \\ x \geq 0, \ y \geq 0. \end{cases}$$

Asignamos multiplicadores $\lambda_1, \lambda_2 \geq 0$ a las dos primeras desigualdades y construimos el Lagrangiano

$$\mathcal{L}(x,y,\lambda_1,\lambda_2) = xy + \lambda_1\big(100 - x - y\big) + \lambda_2\big(40 - x\big).$$

Las condiciones de Kuhn-Tucker se agrupan en:

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x} &= y - \lambda_1 - \lambda_2 \ \leq 0, \quad x \ \geq 0, \quad x\big(y - \lambda_1 - \lambda_2\big) = 0, \\ \frac{\partial \mathcal{L}}{\partial y} &= x - \lambda_1 \ \leq 0, \quad y \ \geq 0, \quad y\big(x - \lambda_1\big) = 0, \\ \frac{\partial \mathcal{L}}{\partial \lambda_1} &= 100 - x - y \ \geq 0, \quad \lambda_1 \ \geq 0, \quad \lambda_1\big(100 - x - y\big) = 0, \\ \frac{\partial \mathcal{L}}{\partial \lambda_2} &= 40 - x \ \geq 0, \quad \lambda_2 \ \geq 0, \quad \lambda_2\big(40 - x\big) = 0. \end{aligned}$$

Analizando las regiones:
En el óptimo $x^*, y^* > 0$ ya que de lo contrario la utilidad sería 0, entonces las dos primeras desigualdades se vuelven igualdades (por las condiciones de holgura complementaria)

$$y^* - \lambda_1 - \lambda_2 = 0, \quad x^* - \lambda_1 = 0.$$

Analizando las regiones, consideremos las cuatro combinaciones posibles de λ_1 y λ_2:

Caso 1: $\lambda_1 = 0, \ \lambda_2 = 0.$
Entonces

$$\frac{\partial \mathcal{L}}{\partial x} = y \leq 0, \quad \frac{\partial \mathcal{L}}{\partial y} = x \leq 0 \quad \Longrightarrow \quad x = y = 0,$$

con $x, y \geq 0$. Esto da $U = 0$, no es máximo interior con $U > 0$. *(Descartado.)*

Caso 2: $\lambda_1 > 0,\ \lambda_2 = 0.$
Por holgura complementaria en $x, y > 0$:

$$y - \lambda_1 = 0, \quad x - \lambda_1 = 0 \quad \Longrightarrow \quad x = y = \lambda_1,$$

y por la restricción activa $x + y = 100$:

$$2\lambda_1 = 100 \ \Rightarrow \ x = y = 50,$$

pero viola $x \leq 40$. *(Descartado.)*

Caso 3: $\lambda_1 = 0,\ \lambda_2 > 0.$
Holgura complementaria obliga

$$40 - x = 0 \ \Rightarrow \ x = 40,$$

Y yendo a la segunda condición tenemos: $x - \lambda_1 = 0$. Pero como $\lambda_1 = 0$ y $x = 40$, esta condición no se cumple. *(Descartado.)*

Caso 4: $\lambda_1 > 0,\ \lambda_2 > 0.$
Ambas restricciones activas:

$$x + y = 100, \quad x = 40 \quad \Longrightarrow \quad (x, y) = (40, 60).$$

De las derivadas:

$$x - \lambda_1 = 0 \ \Rightarrow \ \lambda_1 = 40, \quad y - \lambda_1 - \lambda_2 = 0 \ \Rightarrow \ \lambda_2 = 20 > 0,$$

todo consistente. $x^* = 40,\ y^* = 60,\ U = 2400.$

Ejemplo minimización

Consideremos el problema

$$\min_{x_1, x_2} \ C(x_1, x_2) \ = \ (x_1 - 4)^2 \ + \ (x_2 - 4)^2$$

sujeto a

$$\begin{cases} 2x_1 + 3x_2 \ \geq \ 6, \\ -3x_1 - 2x_2 \ \geq \ -12, \\ x_1 \geq 0,\ x_2 \geq 0. \end{cases}$$

Reescribimos las dos primeras como

$$g_1(x) \equiv 6 - 2x_1 - 3x_2 \ \leq \ 0, \quad g_2(x) \equiv 3x_1 + 2x_2 - 12 \ \leq \ 0,$$

y asignamos multiplicadores $\lambda_1, \lambda_2 \geq 0$. El Lagrangiano es

$$\mathcal{L} = (x_1 - 4)^2 + (x_2 - 4)^2 + \lambda_1 (6 - 2x_1 - 3x_2) + \lambda_2 (3x_1 + 2x_2 - 12).$$

Condiciones de Kuhn-Tucker

$$\begin{cases} \dfrac{\partial \mathcal{L}}{\partial x_1} = 2(x_1 - 4) \ - \ 2\lambda_1 \ + \ 3\lambda_2 \ \geq \ 0,\ x_1 \geq 0,\ x_1\big[2(x_1 - 4) - 2\lambda_1 + 3\lambda_2\big] = 0, \\ \dfrac{\partial \mathcal{L}}{\partial x_2} = 2(x_2 - 4) \ - \ 3\lambda_1 \ + \ 2\lambda_2 \ \geq \ 0,\ x_2 \geq 0,\ x_2\big[2(x_2 - 4) - 3\lambda_1 + 2\lambda_2\big] = 0, \\ g_1(x) = 6 - 2x_1 - 3x_2 \leq 0,\ \lambda_1 \geq 0,\ \lambda_1 (6 - 2x_1 - 3x_2) = 0, \\ g_2(x) = 3x_1 + 2x_2 - 12 \leq 0,\ \lambda_2 \geq 0,\ \lambda_2 (3x_1 + 2x_2 - 12) = 0. \end{cases}$$

Análisis de casos Primero pensemos el caso de $(4,4)$ que dada la función de costos puede ser un potencial óptimo. Sin embargo, $(4,4)$ viola g_2. Por lo que vamos a analizar los otros casos posibles, suponiendo que $x_1 > 0$ y $x_2 > 0$

$$x_1 > 0 \implies \frac{\partial \mathcal{L}}{\partial x_1} = 0, \quad x_2 > 0 \implies \frac{\partial \mathcal{L}}{\partial x_2} = 0,$$

y de que las dos restricciones pueden estar activas o inactivas. Hay cuatro combinaciones de $\lambda_1, \lambda_2 \geq 0$:

Caso 1: $\lambda_1 = 0,\ \lambda_2 = 0$.
De la derivada con respecto a x_1: $2(x_1 - 4) = 0 \Rightarrow x_1 = 4$ y $2(x_2 - 4) = 0 \Rightarrow x_2 = 4$. Pero la segunda restricción $3x_1 + 2x_2 \leq 12$ se viola $(20 > 12)$. *Descartado.*

Caso 2: $\lambda_1 > 0,\ \lambda_2 = 0$.
De las condiciones obtenemos que:

$$2(x_1 - 4) - 2\lambda_1 = 0 \quad \big(x_1 = 4 + \lambda_1\big), \qquad 2(x_2 - 4) - 3\lambda_1 = 0 \quad \big(x_2 = 4 + \tfrac{3}{2}\lambda_1\big).$$

Además, $\lambda_1 > 0$ implica $2x_1 + 3x_2 = 6$, que no admite $\lambda_1 > 0$. *Descartado.*

Caso 3: $\lambda_1 = 0,\ \lambda_2 > 0$.

$$2(x_1 - 4) + 3\lambda_2 = 0 \ \Rightarrow\ x_1 = 4 - \tfrac{3}{2}\lambda_2,$$
$$2(x_2 - 4) + 2\lambda_2 = 0 \ \Rightarrow\ x_2 = 4 - \lambda_2,$$

y $\lambda_2 > 0$ obliga $3x_1 + 2x_2 = 12$. Resolviendo:

$$x_1 = \frac{28}{13}, \quad x_2 = \frac{36}{13}, \quad \lambda_2 = \frac{16}{13} > 0.$$

Se verifica $6 - 2x_1 - 3x_2 < 0$ (la primera restricción es inactiva). Solución válida.

Caso 4: $\lambda_1 > 0,\ \lambda_2 > 0$.
Ambas restricciones activas:

$$2x_1 + 3x_2 = 6, \quad 3x_1 + 2x_2 = 12 \implies (x_1, x_2) = (\tfrac{24}{5}, -\tfrac{6}{5}),$$

que viola $x_2 \geq 0$. *Descartado.*

Por tanto, el único caso factible es $\lambda_1 = 0,\ \lambda_2 = \frac{16}{13}$, con

$$(x_1^*, x_2^*) = \left(\tfrac{28}{13}, \tfrac{36}{13}\right).$$

Ejemplo sin restricciones de no negatividad

$$\begin{cases} \min\ f(x,y) = (x-1)^4 + e^y \\ \text{s. a.}\ \ 2x + y \leq 5 \end{cases}$$

Problema de minimización propuesto

Consideremos el siguiente problema de optimización con restricción de desigualdad:

$$\min_{x,y} f(x,y) \;=\; (x-1)^4 + e^y$$

sujeto a

$$-2x - y \;\geq\; -5.$$

Notemos que la restricción puede reescribirse como

$$-2x - y + 5 \;\geq\; 0.$$

Para usar las condiciones de Kuhn–Tucker en la forma estándar $g(x,y) \leq 0$, definimos

$$g(x,y) \;\equiv\; (2x + y - 5) \;\leq\; 0.$$

Esta $g(x,y) \leq 0$ es algebraicamente la misma que la restricción original $-2x - y \geq -5$, sólo escrita al otro lado. Vamos a trabajar con $g(x,y)$ para construir el Lagrangiano, pero cuando verifiquemos factibilidad siempre vamos a chequear la forma original

$$-2x - y \;\geq\; -5.$$

Introducimos el multiplicador de Kuhn–Tucker $\lambda \geq 0$. El Lagrangiano es

$$\mathcal{L}(x,y,\lambda) = (x-1)^4 + e^y + \lambda\big(2x + y - 5\big).$$

Condiciones de Kuhn–Tucker Las condiciones KKT (necesarias y, como veremos, suficientes) son:

$$\begin{cases} \text{(1) Estacionariedad:} & \dfrac{\partial \mathcal{L}}{\partial x} = 4(x-1)^3 + 2\lambda = 0, \\ & \dfrac{\partial \mathcal{L}}{\partial y} = e^y + \lambda = 0, \\ \text{(2) Factibilidad primal:} & -2x - y \;\geq\; -5, \\ \text{(3) Factibilidad dual:} & \lambda \;\geq\; 0, \\ \text{(4) Holgura complementaria:} & \lambda\big(2x + y - 5\big) = 0. \end{cases}$$

Observación importante: En el Lagrangiano usamos $2x + y - 5$, pero la factibilidad primal la seguimos expresando en la forma original $-2x - y \geq -5$, es decir, "mayor o igual a un número".

Análisis de casos Vamos a estudiar las dos posibilidades para λ.

Caso 1: $\lambda = 0$

Si $\lambda = 0$, las ecuaciones de estacionariedad quedan:

$$4(x-1)^3 + 0 = 0 \quad\Longrightarrow\quad (x-1)^3 = 0 \quad\Longrightarrow\quad x = 1,$$

y

$$e^y + 0 = 0 \quad\Longrightarrow\quad e^y = 0,$$

lo cual es imposible porque $e^y > 0$ para todo y. Por lo tanto, $\lambda = 0$ no puede describir el óptimo.

Caso 2: $\lambda > 0$

Si $\lambda > 0$, por holgura complementaria debe cumplirse

$$2x + y - 5 = 0 \quad \Longrightarrow \quad y = 5 - 2x.$$

Usamos estacionariedad otra vez. De

$$\frac{\partial \mathcal{L}}{\partial y} = e^y + \lambda = 0 \quad \Longrightarrow \quad \lambda = -\,e^y.$$

Como $\lambda > 0$, esto nos dice que $-e^y > 0$, lo cual sería imposible. Esto sugiere que, con el Lagrangiano escrito como

$$\mathcal{L}(x, y, \lambda) = f(x, y) + \lambda(2x + y - 5),$$

el signo de λ que hace que KKT funcione debe ser $\lambda \leq 0$ si usamos $2x + y - 5$ directamente.

Para evitar esa inconsistencia de signos, es más cómodo (y estándar) definir la restricción *negada* en el Lagrangiano, tal como se hizo en el ejemplo anterior:

Reescribimos:

$$g(x, y) \equiv 5 - 2x - y \ \leq \ 0,$$

que es exactamente la misma restricción original $-2x - y \geq -5$, sólo movida de lado. Ahora tomamos el Lagrangiano en la forma

$$\widetilde{\mathcal{L}}(x, y, \lambda) = (x - 1)^4 + e^y + \lambda \left(5 - 2x - y\right), \quad \lambda \geq 0.$$

Volvemos a plantear las KKT con esta versión (que es la convención usual y evita el problema de signo):

$$\begin{cases} (1)\ \text{Estacionariedad:} & \dfrac{\partial \widetilde{\mathcal{L}}}{\partial x} = 4(x-1)^3 - 2\lambda = 0, \\ & \dfrac{\partial \widetilde{\mathcal{L}}}{\partial y} = e^y - \lambda = 0, \\ (2)\ \text{Factibilidad primal (forma original):} & -2x - y \ \geq \ -5, \\ (3)\ \text{Factibilidad dual:} & \lambda \ \geq \ 0, \\ (4)\ \text{Holgura complementaria:} & \lambda \left(5 - 2x - y\right) = 0. \end{cases}$$

Ahora sí, analizamos casos con esta $\widetilde{\mathcal{L}}$.

Caso A: $\lambda = 0$

Si $\lambda = 0$, de estacionariedad:

$$4(x - 1)^3 - 0 = 0 \quad \Longrightarrow \quad x = 1.$$

Y

$$e^y - 0 = 0 \quad \Longrightarrow \quad e^y = 0,$$

imposible. Por lo tanto, $\lambda = 0$ sigue sin ser factible.

Caso B: $\lambda > 0$

Si $\lambda > 0$, por holgura complementaria la restricción está activa:

$$5 - 2x - y = 0 \quad \Longrightarrow \quad y = 5 - 2x.$$

De $\frac{\partial \widetilde{\mathcal{L}}}{\partial y} = 0$:

$$e^y - \lambda = 0 \quad \Longrightarrow \quad \lambda = e^y = e^{\,5-2x}.$$

De $\frac{\partial \widetilde{\mathcal{L}}}{\partial x} = 0$:

$$4(x-1)^3 - 2\lambda = 0 \quad \Longrightarrow \quad 2(x-1)^3 = \lambda.$$

Igualando las dos expresiones de λ:

$$2(x-1)^3 \;=\; e^{\,5-2x}.$$

Esa ecuación determina el x óptimo. Resolviéndola numéricamente:

$$x^* \;\approx\; 2.0625.$$

Luego

$$y^* = 5 - 2x^* \;\approx\; 5 - 2(2.0625) \;\approx\; 0.8750.$$

Y el multiplicador

$$\lambda^* = e^{y^*} \;\approx\; e^{0.8750} \;\approx\; 2.3989 \;>\; 0,$$

consistente con la hipótesis $\lambda > 0$.

Ahora verificamos la factibilidad *en la forma original de la restricción*:

$$-2x^* - y^* \;\approx\; -2(2.0625) - 0.8750 \;\approx\; -5.0000 \;\geq\; -5.$$

Se cumple exactamente como igualdad: estamos sobre la frontera $-2x - y = -5$, es decir, "mayor o igual a -5".

El valor de la función objetivo en (x^*, y^*) es

$$f(x^*, y^*) = (x^* - 1)^4 + e^{y^*} \;\approx\; (2.0625 - 1)^4 + e^{0.8750} \;\approx\; 3.6733.$$

Condiciones suficientes para mínimo global La función objetivo

$$f(x, y) = (x-1)^4 + e^y$$

es convexa: $(x-1)^4$ es convexa en x, y e^y es convexa en y; la suma de convexas es convexa.

El conjunto factible definido por

$$-2x - y \;\geq\; -5$$

es un semiespacio afín (una región descrita por una desigualdad lineal), por lo tanto es convexo.

En un problema de minimización convexa con restricciones convexas (aquí lineales), cualquier punto que satisface KKT es óptimo global.

Como encontramos $(x^*, y^*) \approx (2.0625,\ 0.8750)$ con $\lambda^* > 0$ que satisface:

$$-2x^* - y^* \;\geq\; -5, \quad \text{y todas las condiciones KKT,}$$

concluimos que

$$(x^*, y^*) \approx (2.0625,\ 0.8750)$$

es el minimizador global del problema original con la restricción escrita en la forma

$$-2x - y \;\geq\; -5.$$

Condiciones suficientes

Como en el caso de optimización con restricciones y optimización libre, las condiciones suficientes van a estar asociadas a la concavidad de las funciones analizadas. Vamos a ver dos tipos de condiciones, una sobre concavidad y convexidad y otra más débil sobre cuasiconcavidad y cuasiconvexidad.

Condiciones suficientes para máximo (y global)

Supongamos que el problema a resolver es:

$$\begin{aligned} &\text{Maximizar} \quad f(x) \\ &\text{sujeto a} \qquad g^i(x) \leq r_i \quad (i = 1, 2, \ldots, k), \\ &\qquad\qquad\quad x \geq 0. \end{aligned}$$

Con $x = (x_1, x_2, ...)$ Asumiendo que se satisfacen las condiciones de Kuhn-Tucker. Si se satisfacen las siguientes condiciones en un punto x^*

1. La función objetivo $f(x)$ es diferenciable y *cóncava* en el cuadrante n-dimensional no negativo.
2. Cada función de restricción $g^i(x)$ es diferenciable y *convexa* en el cuadrante n-dimensional no negativo.

Entonces x^* da un máximo global de $f(x)$.

Existe un teorema asociado a condiciones más débiles para poder determinar que estamos ante un máximo, estas están asociados a la cuasiconcavidad y cuasiconvexidad de las funciones:

Teorema de Arrow-Enthoven para máximo

Supongamos que el problema a resolver es:

$$\begin{aligned} &\text{Maximizar} \quad f(x) \\ &\text{sujeto a} \qquad g^i(x) \leq r_i \quad (i = 1, 2, \ldots, k), \\ &\qquad\qquad\quad x \geq 0. \end{aligned}$$

Asumiendo que se satisfacen las condiciones de Kuhn-Tucker. Si se satisfacen las siguientes condiciones en un punto x^*

1. La función objetivo $f(x)$ es diferenciable y *cuasiconcava* en el cuadrante n-dimensional no negativo.
2. Cada función de restricción $g^i(x)$ es diferenciable y *cuasiconvexa* en el cuadrante n-dimensional no negativo.
3. Se satisface cualquiera de los siguientes:
   (a) $f_j(x^*) < 0$ para al menos una variable x_j.
   (b) $f_j(x^*) > 0$ para alguna variable x_j relevante, esto quiere decir una variable que en el conjunto factible (que cumpla con las restricciones), esa variable tome un valor positivo.
   (c) Las n derivadas $f_j(x^*)$ no son todas cero, y la función $f(x)$ es dos veces diferenciable en la vecindad de x^* (es decir, todas las derivadas parciales de segundo orden de $f(x)$ existen para x^*).
   (d) La función $f(x)$ es cóncava.

   Entonces x^* da un máximo global de $f(x)$.

Condiciones suficientes para mínimo (y global)

Supongamos que el problema a resolver es:

$$\begin{aligned} &\text{Minimizar} \quad f(x) \\ &\text{sujeto a} \qquad g^i(x) \geq r_i \quad (i = 1, 2, \ldots, k), \\ &\qquad\qquad\quad x \geq 0. \end{aligned}$$

Con $x = (x_1, x_2, ...)$ Asumiendo que se satisfacen las condiciones de Kuhn-Tucker. Si se satisfacen las siguientes condiciones en un punto x^*

1. La función objetivo $f(x)$ es diferenciable y *convexa* en el cuadrante n-dimensional no negativo.
2. Cada función de restricción $g^i(x)$ es diferenciable y *cóncava* en el cuadrante n-dimensional no negativo.

Entonces x^* da un mínimo global de $f(x)$.

Teorema de Arrow-Enthoven para mínimo

Supongamos que el problema a resolver es:

$$\begin{aligned} &\text{Minimizar} \quad f(x) \\ &\text{sujeto a} \qquad g^i(x) \ \geq \ r_i \quad (i = 1, 2, \ldots, k), \\ &\qquad\qquad\quad\ x \ \geq \ 0. \end{aligned}$$

Asumiendo que se satisfacen las condiciones de Kuhn-Tucker. Si se satisfacen las siguientes condiciones en un punto x^*

1. La función objetivo $f(x)$ es diferenciable y *cuasiconvexa* en el cuadrante n-dimensional no negativo.
2. Cada función de restricción $g^i(x)$ es diferenciable y *cuasicóncava* en el cuadrante n-dimensional no negativo.
3. Se satisface cualquiera de los siguientes:
   (a) $f_j(x^*) > 0$ para al menos una variable x_j.
   (b) $f_j(x^*) < 0$ para alguna variable x_j relevante, esto quiere decir una variable que en el conjunto factible (que cumpla con las restricciones), esa variable tome un valor positivo.
   (c) Las n derivadas $f_j(x^*)$ no son todas cero, y la función $f(x)$ es dos veces diferenciable en la vecindad de x^* (es decir, todas las derivadas parciales de segundo orden de $f(x)$ existen para x^*).
   (d) La función $f(x)$ es convexa.

   Entonces x^* da un mínimo global de $f(x)$.

Ejemplo

Volvamos a este ejemplo

$$\begin{aligned} \min_{x_1, x_2} \quad & C(x_1, x_2) = (x_1 - 4)^2 + (x_2 - 4)^2 \\ \text{sujeto a} \quad & 2x_1 + 3x_2 \geq 6, \\ & -3x_1 - 2x_2 \geq -12, \\ & x_1 \geq 0, \quad x_2 \geq 0. \end{aligned}$$

El potencial óptimo es $x_1 = 28/13$, $x_2 = 36/13$. Vamos a chequear las condiciones de segundo orden con el teorema de Arrow-Enthoven. La función objetivo en este caso es convexa por lo tanto es cuasiconvexa:

$$H(x_1, x_2) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

$$\Delta_1 = 2 > 0, \qquad \Delta_2 = \det \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = 4 > 0$$

Por otro lado, las funciones de las restricciones son lineales con lo cual son cóncavas y convexas y por lo tanto son cuasicóncavas y cuasiconvexas. Por último, evaluamos una de las 4 condiciones de como por ejemplo: $f_j(x^*) < 0$, para algún x_j que tome un valor positivo en el óptimo:

Chequeando:

$$C'_{x_1} = 2(x_1^* - 4) < 0$$

Esto implica que el óptimo es mínimo global.

25 Temas adicionales de optimización

Calificación de las restricciones

Anteriormente cuando calculamos las condiciones de primer orden para máximos y mínimos argumentamos que estas son necesarias para obtener un punto óptimo. Sin embargo, existen casos donde por la naturaleza de las restricciones, las condiciones de primer orden dejan de ser válidas tanto para optimización con restricciones de igualdad como optimización con restricciones de desigualdad. Véase el siguiente ejemplo:

Consideremos el problema de maximizar $f(x, y) = x$ sujeto a la restricción definida por

$$h(x, y) = x^3 + y^2 = 0.$$

Armamos el lagrangiano:

$$L(x, y, \lambda) = f(x, y) + \lambda\left[-h(x, y)\right] = x + \lambda(-x^3 - y^2).$$

El sistema de ecuaciones que debemos resolver es:

$$\begin{cases} \dfrac{\partial L}{\partial x} = 1 - 3\lambda x^2 = 0, \\ \dfrac{\partial L}{\partial y} = -2\lambda y = 0, \\ \dfrac{\partial L}{\partial \lambda} = -(x^3 + y^2) = 0. \end{cases}$$

De $\dfrac{\partial L}{\partial y} = 0$ se sigue que $\lambda = 0$ **o** $y = 0$.

Caso 1: $\lambda = 0$. Entonces la primera ecuación da $1 - 3 \cdot 0 \cdot x^2 = 1 = 0$, que es imposible. Por lo tanto, $\lambda \neq 0$.

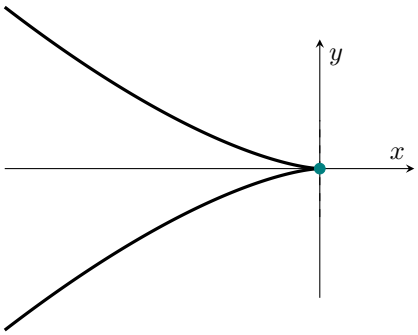
Caso 2: Como $\lambda \neq 0$, debe ser $y = 0$. La tercera ecuación impone $x^3 + y^2 = 0 \Rightarrow x^3 = 0 \Rightarrow x = 0$. Sustituyendo $x = 0$ en la primera ecuación:

$$1 - 3\lambda x^2 = 1 - 3\lambda \cdot 0 = 1 = 0,$$

nueva contradicción.

En ambos casos se arriba a una contradicción; por ende, el sistema no tiene solución.

Sin embargo el problema sí cuenta con un óptimo que es $(0, 0)$. Esto puede verse gráficamente. Graficando la restricción:



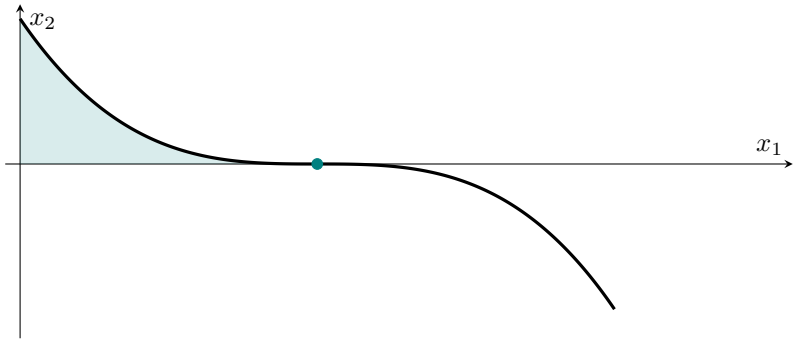
Como estamos maximizando una función que es $f(x, y) = x$, el punto óptimo se encuentra lo más al este posible pero que cumpla al mismo tiempo con la restricción, ese punto es el $(0, 0)$.

Veamos otro ejemplo pero con restricciones de desigualdad:

$$\max_{x_1,x_2} \quad f = x_1$$
$$\text{s.a.} \quad \begin{cases} x_2 - (1-x_1)^3 \leq 0, \\ x_1 \geq 0, \\ x_2 \geq 0. \end{cases}$$

$$\mathcal{L}(x_1, x_2, \lambda_1) = x_1 \ + \ \lambda\big[x_2 - (1-x_1)^3\big]$$

Este problema como el anterior puede ser resuelto gráficamente graficando la restricción:



El resultado es que el punto óptimo resulta ser: $(1, 0)$. Sin embargo si chequeamos las condiciones de primer orden, en particular la primera:

$$\frac{\partial \mathcal{L}}{\partial x_1} = 1 \ + \ 3\lambda(1-x_1)^2 \leq 0$$

Si $x_1 = 1$ tenemos:

$$\frac{\partial \mathcal{L}}{\partial x_1} = 1 \leq 0$$

Lo cual es contradictorio, nuevamente lo que sucede es que las restricciones de este problema dejan sin efecto las condiciones necesarias. El problema que pueden generar estos casos "patológicos" es que a veces las restricciones no permiten la tangencia entre las curvas de nivel de la restricción y curvas de nivel de la función objetivo entre otras cosas. La forma de resolver este problema es requerir que el conjunto de restricciones cumpla con ciertas condiciones. Por ejemplo, si las restricciones fueran todas lineales, no habría problema, o si el problema fuera de maximización y las restricciones fueran todas convexas tampoco habría problema. Un resumen de las condiciones de calificación puede verse a continuación:

Teoremas de calificación de restricciones para máximos

Sea $f, g_1, \ldots, g_k$ y supóngase que $x^* \in \mathbb{R}^n$ es un máximo local de f sobre el conjunto definido por las restricciones

$$g_1(x) \leq r_1, \ \ldots, \ g_k(x) \leq r_k.$$

Para simplificar la notación, supóngase que $g_1, \ldots, g_h$ son las restricciones *activas* en x^*, y que $g_{h+1}, \ldots, g_k$ no lo son. Supóngase que las funciones de restricción activas satisfacen una de las siguientes propiedades:

(a) La matriz jacobiana de las restricciones activas es

$$\left(\frac{\partial g_i}{\partial x_j}(x^*)\right), \quad i = 1, \ldots, h, \ j = 1, \ldots, n.$$

Los gradientes de las restricciones activas son linealmente independientes en x^*, es decir, generan un subespacio de dimensión igual al número de restricciones activas.

(b) $g_1, \ldots, g_h$ son funciones convexas.

(c) $g_1, \ldots, g_h$ son funciones lineales.

Entonces, podemos aplicar las condiciones de primer orden sin problemas.

Teoremas de calificación de restricciones para mínimos

Sea $f, g_1, \ldots, g_k$ y supóngase que $x^* \in \mathbb{R}^n$ es un mínimo local de f sobre el conjunto definido por las restricciones

$$g_1(x) \geq r_1, \ \ldots, \ g_k(x) \geq r_k.$$

Para simplificar la notación, supóngase que $g_1, \ldots, g_h$ son las restricciones *activas* en x^*, y que $g_{h+1}, \ldots, g_k$ no lo son. Supóngase que las funciones de restricción activas satisfacen una de las siguientes propiedades:

(a) La matriz jacobiana de las restricciones activas es

$$\left(\frac{\partial g_i}{\partial x_j}(x^*)\right), \quad i = 1, \ldots, h, \ j = 1, \ldots, n.$$

Los gradientes de las restricciones activas son linealmente independientes en x^*, es decir, generan un subespacio de dimensión igual al número de restricciones activas.

(b) $g_1, \ldots, g_h$ son funciones cóncavas.

(c) $g_1, \ldots, g_h$ son funciones lineales.

Entonces, podemos aplicar las condiciones de primer orden sin problemas.

Volviendo con el ejemplo anterior, podemos ver que no hay independencia lineal en el gradiente de las restricciones ya que estos son:

Consideremos las restricciones en forma estándar $g_i(x_1, x_2) \leq 0$:

$$g_1(x_1, x_2) = x_2 - (1 - x_1)^3,$$
$$g_2(x_1, x_2) = -x_1,$$
$$g_3(x_1, x_2) = -x_2.$$

El punto candidato al óptimo es $x^* = (1, 0)$. Evaluamos cuáles restricciones son activas:

$$g_1(1, 0) = 0, \qquad g_2(1, 0) = -1 < 0, \qquad g_3(1, 0) = 0.$$

Por lo tanto, las restricciones activas son g_1 y g_3.

Calculamos los gradientes:

$$\nabla g_1(x_1, x_2) = \left(\frac{\partial g_1}{\partial x_1}, \frac{\partial g_1}{\partial x_2}\right) = \big(3(1 - x_1)^2, \, 1\big),$$
$$\nabla g_2(x_1, x_2) = (-1, \, 0), \qquad \nabla g_3(x_1, x_2) = (0, \, -1).$$

Evaluando en $x^* = (1, 0)$:

$$\nabla g_1(1, 0) = (0, \, 1), \qquad \nabla g_3(1, 0) = (0, \, -1).$$

Se observa que

$$\nabla g_3(1, 0) = -\nabla g_1(1, 0),$$

por lo que los gradientes de las restricciones activas **no son linealmente independientes en** x^*.

En consecuencia, la condición de independencia lineal de gradientes no se cumple en este punto. Tampoco se cumplen que las restricciones sean convexas ni lineales y por esa razón las condiciones de primer orden dejan de ser válidas.

26 Apéndice sobre Álgebra

Determinantes

Idea general

Para una matriz cuadrada $A \in \mathbb{R}^{n\times n}$, el determinante $\det(A)$ es un número que mide, entre otras cosas, el factor de cambio de volumen de la transformación lineal asociada, y nos permite saber si A es invertible

$$A \text{ es invertible } \iff \det(A) \neq 0$$

Para una intuición gráfica del determinante ver el video "El determinante" de 3Blue1Brown. Este apartado se reduce solamente al cálculo del mismo.

Fórmulas básicas

En el caso de una matriz 2×2:
$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$,

$$\det(A) = ad - bc$$

Para el caso más sencillo de una matriz 2×2 el determinante se calcula a través de multiplicar los elementos de una diagonal y restarlos por el producto de la otra.

Sea $A = \begin{pmatrix} 2 & 3 \\ 4 & 5 \end{pmatrix}$. Entonces

$$\det(A) = 2 \cdot 5 - 3 \cdot 4 = 10 - 12 = -2$$

Para el caso de una matriz 3×3
Podemos calcular a través de dos métodos diferentes:

Regla de Sarrus

Para $A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$, duplicamos las *dos primeras filas* debajo para formar la matriz *expandida*:

$$\begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \\ a & b & c \\ d & e & f \end{bmatrix}$$

Las tres diagonales *descendentes* ($\searrow$) se **suman** y las tres *ascendentes* ($\nearrow$) se **restan**. En notación de entradas a_{ij} y también con letras:

$$\text{suman: } aei, \quad bfg, \quad cdh$$
$$\text{restan: } ceg, \quad afh, \quad bdi$$

Por lo tanto

$$\det(A) = aei + bfg + cdh - ceg - afh - bdi$$

Ejemplo

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & -1 & 4 \\ 2 & 1 & 0 \end{pmatrix}$$

Duplicamos las dos primeras filas debajo para formar la matriz expandida

$$\begin{bmatrix} 1 & 2 & 3 \\ 0 & -1 & 4 \\ 2 & 1 & 0 \\ 1 & 2 & 3 \\ 0 & -1 & 4 \end{bmatrix}$$

Las diagonales descendentes $\searrow$ se **suman** y las ascendentes $\nearrow$ se **restan**

$$\text{suman: } 1 \cdot (-1) \cdot 0,\ 2 \cdot 4 \cdot 2,\ 3 \cdot 0 \cdot 1$$

$$\text{restan: } 3 \cdot (-1) \cdot 2,\ 1 \cdot 4 \cdot 1,\ 2 \cdot 0 \cdot 0$$

Por lo tanto

$$\det(A) = 1 \cdot (-1) \cdot 0 + 2 \cdot 4 \cdot 2 + 3 \cdot 0 \cdot 1 - 3 \cdot (-1) \cdot 2 - 1 \cdot 4 \cdot 1 - 2 \cdot 0 \cdot 0 = 18$$

A través de los cofactores (Laplace)

Sea $A = [a_{ij}]$. Para cada entrada a_{ij}, definimos su *menor* M_{ij} como el determinante de la submatriz que se obtiene al **borrar** la fila i y la columna j. El *cofactor* es

$$C_{ij} = (-1)^{i+j} M_{ij}$$

Con estos cofactores, podemos expandir por cualquier fila i o columna j

$$\det(A) = \sum_{j=1}^{n} a_{ij} C_{ij}$$

Veamos cómo hacerlo con una matriz 3×3 aunque este método sirve para matrices cuadradas de cualquier dimensión.

Tomemos

$$A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$$

Cofactor asociado al elemento $a = a_{11}$ Su menor se obtiene borrando la fila 1 y la columna 1, quedando la submatriz en rojo

$$A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$$

$$M_{11} = \det\left(\begin{pmatrix} e & f \\ h & i \end{pmatrix}\right) = ei - fh$$

Como $1 + 1$ es par, el cofactor es positivo

$$C_{11} = (-1)^{1+1} M_{11} = ei - fh$$

Cofactor asociado al elemento $b = a_{12}$ Ahora borramos la fila 1 y la columna 2, y el menor queda

$$A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$$

$$M_{12} = \det\left(\begin{pmatrix} d & f \\ g & i \end{pmatrix}\right) = di - fg$$

Como $1 + 2$ es impar, el cofactor cambia de signo

$$C_{12} = (-1)^{1+2} M_{12} = -(di - fg) = fg - di$$

Cofactor asociado al elemento $c = a_{13}$ Borrando la fila 1 y la columna 3

$$A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$$

$$M_{13} = \det\left(\begin{pmatrix} d & e \\ g & h \end{pmatrix}\right) = dh - eg$$

Y como $1 + 3$ es par

$$C_{13} = (-1)^{1+3} M_{13} = dh - eg$$

Expansión de Laplace por la primera fila La expansión $\det(A) = a\,C_{11} + b\,C_{12} + c\,C_{13}$ se ve, con nuestros colores, así

$$\det(A) = C_{11}\,a + C_{12}\,b + C_{13}\,c$$

es decir

$$\det(A) = a\,(ei - fh) + b\,(fg - di) + c\,(dh - eg)$$

De esta forma podemos calcular el determinante de una matriz tomando cualquier fila o columna de la misma y aplicando la expansión de Laplace. Una recomendación es siempre intentar elegir la fila o columna con mayor cantidad de ceros de tal forma de anular varios términos al escribir la expansión.

Ejemplo

Calculemos $\det(A)$ expandiendo por la **primera columna**

$$A = \begin{pmatrix} 2 & 0 & 3 \\ 1 & 4 & -1 \\ 0 & 2 & 5 \end{pmatrix}$$

Término con $a_{11} = 2$ Borramos fila 1 y columna 1. El *menor* es el determinante de la submatriz en rojo

$$A = \begin{pmatrix} 2 & 0 & 3 \\ 1 & 4 & -1 \\ 0 & 2 & 5 \end{pmatrix} \qquad M_{11} = \det\begin{pmatrix} 4 & -1 \\ 2 & 5 \end{pmatrix} = 4 \cdot 5 - (-1) \cdot 2 = 22$$

$$C_{11} = (-1)^{1+1} M_{11} = 22 \qquad \text{aporte } = a_{11}\,C_{11} = 2 \cdot 22 = 44$$

Término con $a_{21} = 1$ Borramos fila 2 y columna 1

$$A = \begin{pmatrix} 2 & 0 & 3 \\ 1 & 4 & -1 \\ 0 & 2 & 5 \end{pmatrix} \qquad M_{21} = \det\begin{pmatrix} 0 & 3 \\ 2 & 5 \end{pmatrix} = 0 \cdot 5 - 3 \cdot 2 = -6$$

$$C_{21} = (-1)^{2+1} M_{21} = -(-6) = 6 \qquad \text{aporte } = a_{21}\, C_{21} = 1 \cdot 6 = 6$$

Término con $a_{31} = 0$ Aporta 0, pero mostramos su menor para completar la idea

$$A = \begin{pmatrix} 2 & 0 & 3 \\ 1 & 4 & -1 \\ 0 & 2 & 5 \end{pmatrix} \qquad M_{31} = \det\begin{pmatrix} 0 & 3 \\ 4 & -1 \end{pmatrix} = 0 \cdot (-1) - 3 \cdot 4 = -12$$

$$C_{31} = (-1)^{3+1} M_{31} = -12 \qquad \text{aporte } = a_{31}\, C_{31} = 0 \cdot (-12) = 0$$

Suma de aportes

$$\det(A) = a_{11}C_{11} + a_{21}C_{21} + a_{31}C_{31} = 44 + 6 + 0 = 50$$

Multiplicación de matrices

Dados $A \in \mathbb{R}^{m \times n}$ y $B \in \mathbb{R}^{n \times p}$, definimos el producto $C = AB \in \mathbb{R}^{m \times p}$ por

$$c_{ij} = \sum_{k=1}^{n} a_{ik}\, b_{kj}$$

Solo podemos multiplicar matrices cuando el número de columnas de A coincide con el número de filas de B. En caso contrario, el producto no está definido. El resultado final es una matriz con la cantidad de filas de A y la cantidad de columnas de B.

Intuición

- **Fila por columna**: c_{ij} es el *producto punto* de la fila i de A con la columna j de B.[20]

Una forma de entender el procedimiento es que para cada elemento de fila i y columna j de la matriz final va a estar implicada la fila i de la primera matriz y la columna j de la segunda matriz.

Ejemplo

Sea

$$A = \begin{pmatrix} 2 & -1 & 0 \\ 1 & 3 & 2 \end{pmatrix}, \qquad B = \begin{pmatrix} 1 & 4 \\ 0 & -1 \\ 2 & 5 \end{pmatrix}$$

Calculamos $C = AB \in \mathbb{R}^{2 \times 2}$ por *fila por columna*

$$c_{11} = (2)(1) + (-1)(0) + (0)(2) = 2$$

$$c_{12} = (2)(4) + (-1)(-1) + (0)(5) = 9$$

[20] *Producto punto* entre dos vectores $\mathbf{u} = (u_1, \ldots, u_n)$ y $\mathbf{v} = (v_1, \ldots, v_n)$:

$$\mathbf{u} \cdot \mathbf{v} = \sum_{k=1}^{n} u_k\, v_k$$

$$c_{21} = (1)(1) + (3)(0) + (2)(2) = 5$$
$$c_{22} = (1)(4) + (3)(-1) + (2)(5) = 11$$
$$AB = \begin{pmatrix} 2 & 9 \\ 5 & 11 \end{pmatrix}$$

Ejemplo 2×2

Sea

$$A = \begin{pmatrix} 3 & -2 \\ 1 & 5 \end{pmatrix}, \qquad B = \begin{pmatrix} 4 & 0 \\ -1 & 2 \end{pmatrix}$$

Calculamos $C = AB \in \mathbb{R}^{2\times 2}$ por fila por columna

$$c_{11} = 3 \cdot 4 + (-2) \cdot (-1) = 12 + 2 = 14$$
$$c_{12} = 3 \cdot 0 + (-2) \cdot 2 = 0 - 4 = -4$$
$$c_{21} = 1 \cdot 4 + 5 \cdot (-1) = 4 - 5 = -1$$
$$c_{22} = 1 \cdot 0 + 5 \cdot 2 = 0 + 10 = 10$$
$$AB = \begin{pmatrix} 14 & -4 \\ -1 & 10 \end{pmatrix}$$

3×2 **por** 2×3

Sea

$$A = \begin{pmatrix} 1 & 2 \\ 0 & -1 \\ 3 & 1 \end{pmatrix}, \qquad B = \begin{pmatrix} 2 & 1 & 0 \\ -1 & 4 & 3 \end{pmatrix}$$

Calculamos $C = AB \in \mathbb{R}^{3\times 3}$

$$c_{11} = 1 \cdot 2 + 2 \cdot (-1) = 2 - 2 = 0, \quad c_{12} = 1 \cdot 1 + 2 \cdot 4 = 1 + 8 = 9, \quad c_{13} = 1 \cdot 0 + 2 \cdot 3 = 0 + 6 = 6$$
$$c_{21} = 0 \cdot 2 + (-1) \cdot (-1) = 1, \quad c_{22} = 0 \cdot 1 + (-1) \cdot 4 = -4, \quad c_{23} = 0 \cdot 0 + (-1) \cdot 3 = -3$$
$$c_{31} = 3 \cdot 2 + 1 \cdot (-1) = 6 - 1 = 5, \quad c_{32} = 3 \cdot 1 + 1 \cdot 4 = 3 + 4 = 7, \quad c_{33} = 3 \cdot 0 + 1 \cdot 3 = 3$$
$$AB = \begin{pmatrix} 0 & 9 & 6 \\ 1 & -4 & -3 \\ 5 & 7 & 3 \end{pmatrix}$$